



红外技术
Infrared Technology
ISSN 1001-8891, CN 53-1053/TN

《红外技术》网络首发论文

题目：基于 BISTD-YOLO 的机场鸟类红外小目标检测算法
作者：李红梅，张洋，张红瑞
收稿日期：2025-03-26
网络首发日期：2025-11-03
引用格式：李红梅，张洋，张红瑞. 基于 BISTD-YOLO 的机场鸟类红外小目标检测算法 [J/OL]. 红外技术. <https://link.cnki.net/urlid/53.1053.TN.20251103.0847.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于 BISTD-YOLO 的机场鸟类红外小目标检测算法

李红梅, 张 洋, 张红瑞

(太原师范学院 计算机科学与技术学院, 山西 晋中 030619)

摘要: 鸟类活动对航空安全构成严重威胁, 实现机场周边鸟类的实时精准监测是航空安全领域亟待解决的关键问题。针对当前机场红外监测场景中背景干扰和低信噪比导致的鸟类小目标定位精度不足等问题, 本文基于 YOLOv8n 提出了一种轻量化的检测模型 BISTD-YOLO。首先, 为了降低模型参数并增强小目标细节的捕获能力, 分别在 Backbone 和 Neck 结构中设计了轻量级多尺度卷积模块 C2f-LMSC 和边缘引导模块 C2f-E-LMSC; 其次, 通过重构网络颈部和检测头结构, 在保留浅层细节信息的同时降低模型复杂度; 然后, 构建了跨空间注意力增强特征金字塔 CSAEFPN 结构, 通过 BiFPN 与 SimAM 协同优化, 有效抑制复杂背景干扰并解决特征丢失问题; 最后, 引入归一化 Wasserstein 距离损失函数替代传统 IoU 指标, 优化小目标定位精度。实验在自建的机场红外鸟类数据集 AIBD 上进行, 结果表明, 与 YOLOv8n 相比, 所提模型的 mAP@0.5 和 mAP@0.5:0.95 分别提升了 5.5% 和 2.2%, 参数量减少了 38.2%, 模型大小仅为 4MB。在泛化测试中, 所提模型在 NUAA-SIRST、NUDT-SIRST 和 IRSTD-1k 数据集上的 mAP@0.5 分别提升了 2.5%、1.2% 和 0.6%。

关键词: 机场鸟类; 红外小目标; 轻量化; 多尺度卷积; 边缘算法; 特征金字塔

中图分类号: TP391.4 **文献标识码:** A

Bird Detection Algorithm for Airport Infrared Small Targets Based on BISTD-YOLO

LI Hongmei, ZHANG Yang, ZHANG Hongrui

(School of Computer Science and Technology, Taiyuan Normal University, Jinzhong 030619, China)

Abstract: Bird activity poses a severe threat to aviation safety, and real-time, accurate monitoring of birds around airports is a critical issue in aviation safety that needs to be resolved. To address problems such as low location accuracy of small bird targets in infrared monitoring at airports due to background interference and low signal-to-noise ratios, this paper proposes a lightweight detection model, BISTD-YOLO, based on YOLOv8n. Firstly, to reduce model parameters and enhance the ability to capture small target details, a lightweight multi-scale convolutional module C2f-LMSC and an edge-guided module C2f-E-LMSC are designed in the Backbone and Neck structures respectively. Secondly, the network neck and detection head structures are reconstructed to retain shallow detail information while reducing model complexity. Then, a cross-space attention enhanced feature pyramid structure CSAEFPN is built. It effectively suppresses background interference and solves the feature loss problem through the synergy of BiFPN and SimAM. Finally, the normalized Wasserstein distance loss function is introduced to replace the traditional IoU metric to optimize the location accuracy of small targets. Experiments are carried out on the self-constructed AIBD. Results show that, compared to YOLOv8n, the proposed model increases mAP@0.5 and mAP@0.5:0.95 by 5.5% and 2.2%, reduces parameters by 38.2%, and is only 4MB in size. In generalization tests, it boosts mAP@0.5 by 2.5%, 1.2%, and 0.6% on NUAA-SIRST, NUDT-SIRST, and ISTD-1k respectively.

Key words: airport birds, infrared small targets, lightweight, multi-scale convolution, edge algorithm, feature pyramid

收稿日期: 2025-03-26; 修订日期: 2025-04-28.

作者简介: 李红梅 (1983-), 女, 工学博士, 讲师, 主要从事机器学习与智能信息处理方向研究。E-mail: hongmeili@tyedu.cn。

通信作者: 张洋 (1997-), 男, 硕士研究生, 主要从事目标检测方向研究。E-mail: 252978324@qq.com。

基金项目: 山西省高等学校科技创新计划项目 (2022L400); 2024 年度太原师范学院研究生教育创新项目 (SYJYSYC-2474); 山西省科技战略研究专项重点项目 (202304031401011)。

0 引言

鸟击是指航空器在起降或飞行过程中与鸟类等生物发生碰撞,或因为动物活动干扰正常飞行的事件^[1]。根据美国联邦航空局(Federal Aviation Administration, FAA)公布的野生动物撞击数据库统计,1990年至2022年,全球共记录了276846起鸟击事件,其中272016起发生在美国,且鸟击事件数量呈逐年上升趋势^[2]。鉴于鸟击对航空安全构成的重大威胁,国际民航组织(ICAO)已将鸟击事件列为“A”类航空灾难^[3]。在军用和民用航空领域,鸟类活动对飞行安全构成严重威胁,不仅可能造成巨大的经济损失,还可能引发机毁人亡的严重后果。因此,机场周边鸟类的准确实时监测至关重要,这对于采取有效的驱鸟措施和保障航空安全具有极其重要的意义。

在实施驱鸟措施之前,需先精准探测鸟类的位置。当前,红外相机因能够在夜间或光线不足的环境下工作,提供全天候的监测服务,已经成为机场鸟类监测的主要工具之一。然而,由于红外成像的特性,鸟类在红外图像中缺乏明显的形态特征与色彩纹理信息。此外,鸟类通常飞行距离较远,在图像中仅占少量像素,表现为红外小目标。同时,因大气散射、光学散焦及噪声等因素的影响,进一步降低了图像的信噪比,导致目标纹理细节不足^[4,5]。这些因素给鸟类的精准定位和识别带来了巨大挑战。

近年来,许多研究者已对红外小目标检测进行了大量研究,主要集中在多尺度特征融合、噪抑制和轻量化设计等方面。然而,仍面临以下挑战: Xiaozhong T等^[6]提出的增强不对称注意力U-Net(EAA U-Net)通过全局上下文卷积增强特征融合,但在复杂背景下,深层网络仍存在小目标特征衰减问题,且在多尺度特征动态融合方面表现不足; M Zhang等^[7]设计的红外形状网络(ISNet)利用泰勒有限差分边缘块抑制噪声,但其双重注意力聚合模块在多尺度特征的动态适配方面仍存在不足,导致微小目标边缘信息模糊化,尤其在复杂噪声环境下效果有限; H Deng等^[8]的FMR-YOLO通过多尺度加权融合提升了检测鲁棒性,但冗余层级设计限制了小目标定位精度,特征金字塔设计存在一定局限性; Boyang L等^[9]提出的DNA-Net通过三向密集交互模块缓解特征丢失问题,但级联注意力机制的高计算复杂度难以满足实时性需求,在终端设备上部署面临挑战。何奇晗等^[10]提出的DM-IUAV尽管融合了跨空间注意力以保留细节信息,但其多分支结构参数量较大,在终端推理时效率降低,在资源受限的环境下适用性较差。

针对上述问题,本文基于YOLOv8模型进行改进,提出了BISTD-YOLO模型,主要贡献如下:

1) 设计了两种轻量级多尺度卷积模块C2f-LMSC和C2f-E-LMSC,增强了红外小目标的边缘信息,降低了模型计算成本,减少了模型参数量,并加快了推理时间。

2) 提出了基于加权双向特征金字塔BiFPN和轻量级注意力机制SimAM的跨尺度注意力增强特征金字塔网络CSAEFPN,有效解决了小目标在深层网络中信息丢失的问题。

3) 构建了机场红外鸟类数据集AIBD,并通过实验验证了所提出算法的有效性。

1 BISTD-YOLO 模型

为了解决红外图像中鸟类小目标检测的精度与性能不足的问题,本文基于YOLOv8n^[11]模型进行了优化设计,提出了一种新型网络结构——BISTD-YOLO(Birds Infrared Small Target Detection)模型,其整体结构如图1所示。首先,设计了两种轻量级多尺度卷积模块C2f-LMSC和C2f-E-LMSC,通过替换Backbone和Neck部分的传统C2f模块,增强了红外小目标的边缘信息提取能力,显著减少了计算量和模型参数量,进而提升了推理速度。其次,在Neck和Head部分,通过增加P2小目标检测层并去除P5大目标层,形成了P2、P3、P4检测头结构,因而提高了小目标的检测精度。此外,为了解决复杂背景干扰和深层网络中红外小目标信息丢失的问题,本文提出了CSAEFPN结构,通过结合BiFPN和SimAM机制,进一步提升了目标识别能力。最后,引入了基于归一化Wasserstein距离的回归损失函数NWD,通过优化目标定位损失的计算方式,提高了红外小目标的定位和识别准确度。

1.1 C2f-LMSC 模块

在目标检测任务中,特征提取的初始阶段至关重要,尽管YOLOv8n中的C2F模块增强了目标特征的表达能力,但其固定尺度的卷积核难以适应目标的尺度变化。为此设计了C2f-LMSC模块,将其应用于模型的Backbone部分,如图2所示。C2f-LMSC通过动态调整感受野的大小,平衡了细节捕捉能力,不仅显著降低了模型的参数量和计算开销,还能够在复杂的红外背景中更精确地聚焦于鸟类小目标的纹理信息,提升了推理效率的同时,保证其检测性能。

LMSC(Lightweight Multi-scale Convolution)模块采用 3×3 和 5×5 的卷积核来提取多尺度特征。与这两个分支并行的 1×1 卷积则在分割通道上完成细粒




图1 BISTD-YOLO 算法网络结构

Fig.1 Network structure of BISTD-YOLO algorithm

度信息捕捉，不仅减少了冗余特征，还能在融合过程中保留各通道最为关键的特征差异。LMSC 模块的数学表达式为：

$$F_A = \text{Conv}_{3 \times 3}(X) \quad (1)$$

$$F_c, F_s = \text{Split}(F_A, [C_c, C_s]) \quad (2)$$

$$F_c^* = \text{Conv}_{1 \times 1}(F_c) \quad (3)$$

$$F_M, F_N = \text{Split}(F_s, [C_M, C_N]) \quad (4)$$

$$F_M^* = \text{Conv}_{3 \times 3}(F_M) \quad (5)$$

$$F_N^* = \text{Conv}_{5 \times 5}(F_N) \quad (6)$$

$$F_O = \text{Conv}_{1 \times 1}(\text{Concat}(F_c^*, F_M^*, F_N^*)) \quad (7)$$

$$F_T = F_O + X \quad (8)$$

式中： F_A 表示输入特征图 X 经过 3×3 卷积后的特征图， C_c 和 C_s 为第一次通道分割参数。 F_c 和 F_s 分别表示 F_A 分割后的输出特征图。 F_c^* 表示 F_c 经过 1×1 卷积后的输出图。 C_M 和 C_N 为第二次通道分割参数， F_M 和 F_N 分别表示 F_s 分割后的输出特征图。 F_M^* 表示 F_M 经过 3×3 卷积后的输出特征图。 F_N^* 表

示 F_N 经过 5×5 卷积后的输出特征图。 F_O 表示 F_c^*, F_M^*, F_N^* 通道拼接后经过 1×1 卷积后的输出图。 F_T 表示 F_O 与输入特征图 X 残差连接。




图2 C2f-LMSC 模块示意图

Fig.2 Schematic diagram of the C2f-LMSC module

1.2 C2f-E-LMSC 模块

经过初步的特征提取和下采样后，在模型的 Neck 部分加入 C2f-E-LMSC，如图 3 所示。E-LMSC (Edge-fused Lightweight Multi-scale Convolution) 是在 LMSC 基础上进一步引入边缘检测分支，通过

Sobel 卷积算子提取水平方向与垂直方向的梯度信息，并通过元素加权和通道拼接的方式将其与多尺度深度特征相融合，进一步提高红外小目标边缘信息提取能力。E-LMSC 模块的数学表达式为：

$$F_x(x, y) = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix} * X(x, y) \quad (9)$$

$$F_y(x, y) = \begin{bmatrix} +1 & +2 & +1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} * X(x, y) \quad (10)$$

$$F_Q = F_x + F_y \quad (11)$$

$$F_P = \text{Conv}_{1 \times 1}(\text{Concat}(F_Q, F_O)) + X \quad (12)$$

式中：\$F_x\$ 和 \$F_y\$ 分别代表输入特征图 \$X\$ 经水平及垂直边缘检测的输出特征图。\$F_Q\$ 表示 \$F_x\$ 和 \$F_y\$ 相加后生成的特征图，符号 \$*\$ 表示卷积运算。\$F_P\$ 表示 \$F_Q\$ 和 \$F_O\$ 通道拼接后经过 \$1 \times 1\$ 卷积通道转换后与输入特征图 \$X\$ 残差连接的输出特征图。




图3 C2F-E-LMSC 模块示意图

Fig.3 Schematic diagram of the C2F-E-LMSC module

1.3 颈部和检测头网络结构的优化设计

在目标检测中，处理多尺度目标识别是一项难题。传统卷积神经网络（CNN）因采用固定分辨率进行特征提取，难以同时处理小尺度和大尺度目标。不同尺度的目标特征差异大，使得单尺度特征图无法有效捕捉，限制了模型的检测精度和泛化能力。为应对这一挑战，研究者提出了特征金字塔网络（Feature Pyramid Network, FPN）^[12]等方案。FPN 通

过构建自顶向下的路径与自底向上的路径结合，实现在不同层次特征图间的有效融合。这使低层特征图能够引入高层的语义信息，高层特征图也能继承低层的细节信息，从而提升了模型对于多尺度目标的敏感度和检测准确性。

针对小目标的特性，本文对 YOLOv8n 中的 Neck 和 Head 部分的检测头结构进行了优化设计，结构如图 4 所示。在 Neck 和 Head 部分增设了 P2 小目标检测层，并引入了 \$160 \times 160\$ 像素的小感受野特征图尺度检测头输出，在 P2 层提取的高分辨率特征图中，保留了丰富的小目标的细节信息和位置信息，有效避免了因低分辨率图像带来的信息丢失问题。同时移除了传统结构中的 P5 大目标检测层和 \$20 \times 20\$ 像素大感受野的尺度检测头输出，移除 P5 层不仅减少了冗余计算量和参数数量，还使模型能够更专注于小目标的特征提取。因此，通过对颈部和检测头结构的优化，增强小目标的检测精度，提升模型的计算效率。




图4 重构颈部和检测头网络结构

Fig.4 Reconstruct the neck and detection head network structure

1.4 跨尺度注意力增强特征金字塔网络（CSAEFPN）

在红外小目标检测中，传统检测网络在浅层难以提取到足够的细节特征，而深层特征则更关注高阶语义，导致小目标特征在多次下采样和连续卷积过程中逐渐丢失或弱化，而且红外图像容易受到噪声、天气变化及复杂背景干扰，最终引发检测精度低、漏检率高等问题。

为解决上述问题，增强网络对红外小目标的细节捕捉能力，并提升多尺度融合时对目标边缘和显著区域的关注度，本文设计了一种跨尺度注意力增

强特征金字塔网络 CSAEFPN (Cross-scale Attention Enhancement Feature Pyramid Network) 结构, 如图 5 所示, 通过引入加权双向特征金字塔 BiFPN 和轻量级注意力机制 SimAM, 有效解决特征丢失和背景干扰的问题。




图 5 CSAEFPN 结构

Fig.5 CSAEFPN structure diagram

1.4.1 加权双向特征金字塔 BiFPN

YOLOv8n 的 Neck 部分采用了路径聚合结构 (Path Aggregation Network, PANet)^[13], 如图 6(a)所示。PANet 通过自顶向下和自底向上两条并行路径聚合不同层级的特征, 然而, 在特征融合阶段, 它仅依赖简单的拼接操作, 这导致不同输入特征对最终融合输出的贡献不均衡。加权双向特征金字塔 (Bidirectional Feature Pyramid Network, BiFPN)^[14], 如图 6(b)所示, BiFPN 在 PANet 基础上删除单一输入节点, 重复使用双向特征融合单元加深特征交互, 并引入可学习权重因子, 实现多尺度特征的动态加权融合。此外, 在同一尺度的特征融合中加入了残差连接, 实现跨层级的特征融合。本文通过引入 BiFPN 的双向动态加权融合和跨层残差连接, 为多次融合提供更多信息通道, 以增强特征间交互, 减少关键信息因重复叠加而丢失的风险。

在特征融合过程中, BiFPN 采用快速归一化融合方法为各输入特征分配权重, 并通过可学习因子动态调整多尺度特征的融合权重。其公式为:

$$o = \sum_i \frac{\omega_i I_i}{\varepsilon_i + \sum_j \omega_j} \quad (13)$$

其中, I_i 为输入特征, o 为输出特征; ω_i 和 ω_j 为可学习的权重参数, 通过 ReLU 激活函数将其缩放在 $[0,1]$ 之间, $\varepsilon=0.0001$ 用于防止数值不稳定。




图 6 不同特征金字塔结构

Fig.6 Pyramid structure with different characteristics

1.4.2 SimAM 注意力机制

现有注意力机制中, 部分方法 (如 SE^[15] 和 SA⁰) 仅关注通道或空间单一维度的特征重要性, 而混合注意力机制 (如 CBAM⁰ 和 BAM^[16]) 虽结合双维度, 但需引入额外参数与复杂操作, 导致模型复杂度显著增加。SimAM^[17] 作为一种无参数的 3D 注意力机制, 结构如图 7 所示, 在不增加复杂度的情况下, 能够同步建模通道与空间维度的特征重要性, 自适应的分配特征权重, 使网络聚焦于关键区域以提升目标感知能力, 同时抑制背景噪声和冗余信息, 在复杂场景下的目标检测与图像分割任务中表现优异。




图 7 SimAM 注意力机制结构

Fig.7 Structure diagram of SimAM attention mechanism

在 BiFPN 的每次跨尺度拼接后的关键层级 (如 P2/P3/P4) 引入 SimAM, 通过最小化能量函数评估神经元重要性, 有效增强目标显著性, 抑制背景干

扰。最小能量函数定义为:

$$e_i^* = \frac{4(\hat{\sigma}^2 + \lambda)}{(t - \hat{\mu})^2 + 2\hat{\sigma}^2 + 2\lambda} \quad (14)$$

式中: t 为目标神经元; λ 为正则化系数, 用于避免分母为零并提升数值稳定性; $\hat{\mu}$ 为当前通道神经元的均值; $\hat{\sigma}^2$ 为方差; e_i^* 为能量值。能量值越低, 表明目标神经元与周围特征的线性可分性越强, 重要性越高。

将所有神经元的最小能量进行求和, 即可得到一个全局能量值 E 。最后, 通过下式对输入特征进行加权处理, 实现注意力增强:

$$\tilde{X} = \text{sigmoid}\left(\frac{1}{E}\right) \odot X \quad (15)$$

式中: $\odot$ 表示逐元素相乘操作, sigmoid 函数的作用是将输出值映射到(0,1)的范围内, 以防止极端权重引起的数值不稳定现象。通过这种方式, 周围神经元差异明显、能量相对低的目标神经元会获得更高的注意力权重, 从而在后续卷积或检测头中发挥更佳的作用。

1.5 NWD 损失函数

在 YOLOv8n 模型中, 采用 CIoU 损失函数处理红外小目标时, 由于目标的边界框交集较小或形状与背景差异较小, 导致 CIoU 的定位和检测不够精确。针对 CIoU 在红外小目标检测中存在的局限性, 本文引入了基于归一化高斯 (Wasserstein) 距离的回归损失函数 NWD^[18] (Normalized Wasserstein Distance)。NWD 通过将目标边界框建模为二维高斯分布, 不仅考虑了目标框的中心位置, 还通过高斯分布的协方差矩阵对目标的大小和形状进行建模, 由此来提升小目标的定位精确度和检测准确性。

Wasserstein 距离是一种度量概率分布之间差异的距离度量。对于二维高斯分布的边界框, 假设预测边界框的高斯分布为 $\mu_1 = (m_1, \Sigma_1)$, 真实边界框的高斯分布为 $\mu_2 = (m_2, \Sigma_2)$, 其中 m_1 和 m_2 分别是预测和真实边界框的均值, Σ_1 和 Σ_2 是其协方差矩阵。其二阶 Wasserstein 距离的计算公式为:

$$W_2^2(\mu_1, \mu_2) = \|m_1 - m_2\|_2^2 + \text{Tr}\left[\Sigma_1 + \Sigma_2 - 2\left(\Sigma_1^{\frac{1}{2}}\Sigma_2\Sigma_1^{\frac{1}{2}}\right)^{\frac{1}{2}}\right] \quad (16)$$

式中: $\|\cdot\|_2$ 是欧几里得距离, Tr 表示矩阵的迹。在目标边界框的建模中, 从边界框 $N_a = (cx_a, cy_a, w_a, h_a)$ 和建 $N_b = (cx_b, cy_b, w_b, h_b)$ 模高斯分布 μ_a 和 μ_b , 式(16)可进一步简化为:

$$\left\| \left[\begin{matrix} cx_a & cy_a & \frac{w_a}{2} & \frac{h_a}{2} \end{matrix} \right]^T, \left[\begin{matrix} cx_b & cy_b & \frac{w_b}{2} & \frac{h_b}{2} \end{matrix} \right]^T \right\|_2^2 \quad (17)$$

由于 $W_2^2(\mu_a, \mu_b)$ 为距离度量, 无法直接对比两个边界框的相似度, 因此将 Wasserstein 距离转化为相似度度量, 对其进行指数形式归一化得到新的 NWD:

$$NWD(N_a, N_b) = \exp\left[-\frac{\sqrt{W_2^2(N_a, N_b)}}{C}\right] \quad (18)$$

式中: C 是与数据集紧密相关的常数, 用于调整 NWD 的取值范围。

2 实验与结果分析

2.1 实验环境与数据集

本实验的硬件配置如下, GPU: NVIDIA GeForce RTX 4090, 显存: 24 GB, CPU: 13th Gen Intel(R) Core(TM) i9-13900K@3.00 GHz, Windows 11 操作系统。实验软件环境基于 Python 3.9, PyTorch 2.0.0 和 CUDA 11.8 搭建。优化器选择随机梯度下降法 (SGD), 训练批次 batch size 设置为 32, 训练轮次为 300 轮。

由于目前公开数据集中缺乏专门的红外鸟类数据集, 本文通过红外设备在机场附近进行拍摄, 然后对图像进行筛选和标注, 构建了一个全新的机场红外鸟类数据集 AIBD (Airport Infrared Bird Dataset)。如图 8 所示, 数据集中标注的红外鸟类小目标在图像中宽高比例主要集中在 2% 以内, 目标面积占图像总面积的比例集中在 0.04% 以内。根据 CHEN 等^[19]的研究, 目标框面积占总面积小于 0.58% 的目标可定义为小目标, 因此 AIBD 数据集中的目标符合小目标的定义。AIBD 数据集共有 7925 张红外图像, 按照 6:2:2 比例随机划分为训练集、验证集和测试集, 其中训练集 4755 张, 验证集 1585 张, 测试集 1585 张。

2.2 评价指标

为验证和评估模型性能, 采用精确度 (P)、召回率 (R)、平均精度 (mAP)、参数量 (Parameters)、计算量 (FLOPs)、检测速度 (FPS) 和模型大小 (Weights Size) 作为评价指标。

2.3 消融实验

为验证 BISTD-YOLO 模型中各改进点对红外鸟类小目标检测性能的影响, 本文以 YOLOv8n 为基准模型, 在 AIBD 数据集上进行消融实验。实验结果如表 1 所示。

表 1 消融实验

Table 1 Ablation experiments

YOLOv8n	C2f-improve	P2、P3、P4	CSAEFPN	NWD	P/%	R/%	mAP@0.5 /%	mAP@0.5:0.95/%	Parameter s/M	FLOPs/G	FPS	Weights size/MB
√					91.2	83.6	88.9	41.7	3.01	8.1	256.3	6.0
√	√				90.8	84.0	88.9	41.3	2.79	7.5	145.5	5.7
√		√			92.7	93.1	93.6	43.5	2.01	11.5	234.6	4.2
√				√	91.1	85.0	89.6	41.8	3.01	8.1	265.7	6.0
√		√	√		93.4	92.9	93.9	43.9	2.03	11.6	206.8	4.2
√	√	√			92.9	92.7	93.6	43.0	1.84	10.9	140.2	4.0
√		√		√	93.0	92.6	93.9	43.9	2.01	11.5	234.6	4.2
√		√	√	√	93.4	92.7	94.1	44.2	2.03	11.6	207.2	4.2
√	√	√		√	93.1	92.8	94.0	43.4	1.84	10.9	140.2	4.0
√	√	√	√		92.9	92.7	94.1	43.0	1.86	11.0	117.6	4.0
√	√	√	√	√	93.8	93.2	94.4	43.9	1.86	11.0	126.7	4.0




图 8 标注框相对宽高占比

Fig.8 The relative width and height ratio of the label frame

实验结果表明，对 C2f 模块进行轻量化改进设计后，模型参数量从 3.01M 降至 2.79M（降幅 7.3%），计算量由 8.1G 减少至 7.5G（降幅 7.4%），模型大小从 6.0 MB 压缩至 5.7MB，检测精度（mAP@0.5）保持不变，模型轻量化的同时保证检测精度稳定；重构颈部与检测头结构形成 P2、P3、P4 多尺度特征融合后，检测性能显著提升，mAP@0.5 从基线模型的 88.9%提高至 93.6%（提升 4.7%），召回率从 83.6%提高至 93.1%（提升 9.5%），参数量从 3.01 M 降至 2.01M（降幅 33.2%）；接着添加 CSAEFPN 跨尺度注意力模块后，模型 mAP@0.5 提升 0.3%，mAP@0.5:0.95 提升 0.4%，进一步提高了模型检测精度；最后引入 NWD 损失函数，在不改变模型参数量和计算量的前提下，mAP@0.5 提升 0.7%，召回率提升 1.4%，推理速度从 256.3FPS 提高至 265.7FPS，小幅提升模型的检测性能。

综合实验结果，与原始 YOLOv8n 相比，BISTD-

YOLO 的 mAP@0.5 提升 5.5%，mAP@0.5:0.95 提升 2.2%，精确度提升 2.6%，召回率提升 9.6%，参数量减少 38.2%，模型大小压缩 33.3%。实验验证了各改进模块在降低计算成本、增强多尺度特征表达、优化检测精度与速度平衡方面的有效性，验证得出 BISTD-YOLO 模型的优越性能。

2.4 损失函数消融实验

在红外小目标检测中，边界框的细微定位偏差容易引发目标偏移问题，针对 YOLOv8n 模型采用 CIoU 损失函数时梯度增益缺乏动态调节机制的缺陷，本文通过引入多种改进损失函数优化目标定位能力。如表 2 消融实验结果可见：采用 WIoU^[20]替代 CIoU 使 mAP@0.5 提升至 89.4%，验证其能有效优化边界框匹配质量；引入 MPDIoU^[21]与 ShapeIoU^[22]后 mAP@0.5 稍有提升，但精度 P 和召回率 R 变化不大；引入 NWD 损失函数后召回率显著提升至 85.0%，mAP@0.5 达 89.6%，综合检测性能最优。研究表明，NWD 通过优化目标匹配策略，在小目标检测任务中展现出比其他损失函数更强的检测效果。

表 2 不同损失函数的消融实验

Table 2 Ablation experiments with different loss functions

Models	P/%	R/%	mAP@0.5%
YOLOv8n	91.2	83.6	88.9
+WIoU	90.7	84.1	89.4
+MPDIoU	90.9	83.5	89.2
+ShapeIoU	91.6	83.8	89.5
+NWD	91.1	85.0	89.6

2.5 对比实验

为验证 BISTD-YOLO 模型在红外鸟类小目标检测任务中的综合性能,本文在 AIBD 数据集上与当前主流 YOLO 系列算法进行了对比实验。实验以平均精度均值 (mAP)、参数量和模型大小作为核心评价指标,结果如表 3 所示。

实验结果表明,BISTD-YOLO 在检测精度、模型轻量化和计算效率方面均表现出显著优势。在检测精度方面,BISTD-YOLO 的 mAP@0.5 达到 94.4%,较 YOLOv5s 和 YOLOv7-Tiny 分别提升了 4.1 和 4.7 个百分点;同时,其 mAP@0.5:0.95 为 43.9%,在所有对比模型中表现最优。从参数量来看,BISTD-YOLO 的参数量仅为 1.86M,相较于参数量较少的 YOLOv11n,减少了 0.74M。在模型大小方面,BISTD-YOLO 的模型大小仅为 4.0 MB,相较于 YOLOv8s 和 YOLOv11s 分别减少 81.4%和 78.1%,显著优于其他对比模型。综上所述,BISTD-YOLO 通过极低的模型大小、参数量与卓越的检测精度,验证了其在轻量化高精度检测任务中的显著优势,非常适用于资源受限的嵌入式场景部署。

2.6 泛化实验

为验证 BISTD-YOLO 模型的泛化性能,本文在三个公开的红外小目标数据集上进行泛化实验:NUAA-SIRST^[23],NUDT-SIRST^[9]和 IRSTD-1k^[7]。为确保合理的评估,每个数据集按照 6:2:2 的比例划分为训练集、验证集和测试集。使用精确度 (P)、召回率 (R) 和平均精度 (mAP) 作为评价指标,并与 YOLOv8n 模型进行对比。

实验结果如表 4 所示,在 NUAA-SIRST 数据集上,BISTD-YOLO 的 mAP@0.5 达到 97.5%,相比 YOLOv8n 提升 2.5 个百分点,召回率提升 2.7%;在 NUDT-SIRST 数据集上,BISTD-YOLO 获得 96.8%的 mAP@0.5,较 YOLOv8n 提高 1.2 个百分点,召回率提升 1.4%;在 IRSTD-1k 数据集上,BISTD-YOLO 的 mAP@0.5 达 84.1%,提升幅度为 5.6%,召回率也提高 4.9%。综合实验结果表明,BISTD-YOLO 模型在多个数据集上均能保持较高检测性能,展现出较强的泛化能力和鲁棒性。尽管不同数据集间性能提升存在差异,但整体优势明显,进一步验证了模型在复杂背景下红外小目标检测中的实际应用潜力。

表 3 不同模型对比实验

Table 3 Comparative experiments with different models

Models	P/%	R/%	mAP@0.5%	mAP@0.5:0.95/%	Parameters/M	FLOPs/G	FPS	Weights size/MB
YOLOv5s	92.6	88.1	90.3	41.4	7.01	15.8	264.6	14.4
YOLOv7-Tiny	91.2	89.7	89.7	37.7	6.01	13.0	170.3	11.7
YOLOv8n	91.2	83.6	88.9	41.7	3.01	8.1	256.3	6.0
YOLOv8s	92.3	84.1	90.0	42.2	11.13	28.4	262.3	21.5
YOLOv10n	89.7	79.3	86.2	38.2	2.69	8.2	173.6	5.5
YOLOv10s	89.2	81.2	87.0	38.6	8.04	24.4	166.9	15.8
YOLOv11n	91.2	83.3	88.7	41.5	2.58	6.3	198.0	5.2
YOLOv11s	91.3	83.7	89.4	42.2	9.41	21.3	199.6	18.3
BISTD-YOLO	93.8	93.2	94.4	43.9	1.86	11.0	126.7	4.0

表 4 不同数据集的泛化实验

Table 4 Generalization experiments with different datasets

Models	NUAA-SIRST			NUDT-SIRST			IRSTD-1k		
	P/%	R/%	mAP@0.5%	P/%	R/%	mAP@0.5%	P/%	R/%	mAP@0.5%
YOLOv8n	94.1	92.0	95.0	90.4	91.3	95.6	86.8	76.8	83.5
BISTD-YOLO	94.7	94.3	97.5	92.0	94.3	96.8	88.2	77.9	84.1

2.7 可视化实验效果与分析

为了验证 BISTD-YOLO 模型的实际检测性能,本文从 AISD、NUAA-SIRST、NUDT-SIRST 和 IRSTD-1k 的数据集中随机选取红外图像进行检测,并将检测结果可视化对比展示于图 9。图中,前两行

为 AISD 数据集的检测结果,第 3~4 行为 NUAA-SIRST 数据集的检测结果,第 5~6 行为 NUDT-SIRST 数据集的检测结果,最后两行为 IRSTD-1k 数据集的检测结果。(a)列为目标标签的可视化图像;(b)列为 YOLOv8n 模型的检测效果;(c)列为 BISTD-

YOLO 模型的检测效果。在对比图中第 1、3、5、7 行为目标较小或模糊的困难样本,第 2、4、6、8 行为目标在云端等复杂背景下的样本。对比结果观察得出,相较于 YOLOv8n 模型,在处理困难目标样本时, BISTD-YOLO 模型显著降低了漏检问题并提升了目标的检测准确率。此外, BISTD-YOLO 模型在抑制背景方面表现出明显优势,有效减少了复杂背景对目标检测的干扰,从而提高了红外小目标的检测精度。综合分析表明, BISTD-YOLO 模型在复杂背景下的红外小目标检测任务中,展现了更强的鲁棒性和更卓越的检测性能,进一步证实了其在实际应用中的巨大潜力。





图9 可视化检测效果对比

Fig.9 Visualization of the comparison of detection results

3 结论

针对机场环境下红外鸟类小目标检测存在的低信噪比、背景干扰所导致的定位精度不足等问题,本文提出了一种轻量化的 BISTD-YOLO 模型。通过设计两种轻量级 C2f 模块 C2f-LMSC 和 C2f-E-LMSC,在降低参数数量和加快推理时间的同时,增强了对目标边缘信息的提取能力;通过重构颈部和检测头结构,保留了浅层细节信息的同时,降低了模型复杂度;提出的跨空间注意力增强特征金字塔网络 CSAEFPN,结合了 BiFPN 和 SimAM 机制,有效增强了红外小目标的特征表达能力;引入了 NWD 损失函数,显著改善了小目标定位偏差问题。实验结果表明,在自建的 AIBD 数据集上, BISTD-YOLO 的 $mAP@0.5$ 达到 94.4%, $mAP@0.5:0.95$ 达到 43.9%,较 YOLOv8n 模型分别提升了 5.5%和 2.2%,精确度和召回率分别提升 2.6%和 9.6%,且模型的参数数量和模型大小分别减少了 38.2%和 33.3%。在 NUAA-SIRST,NUDT-SIRST 和 IRSTD-1k 数据集上的泛化实验进一步验证了 BISTD-YOLO 的优越性, $mAP@0.5$ 分别提升了 2.5%、1.2%和 0.6%。综合来看, BISTD-YOLO 模型在红外小目标检测任务中展现了出色的性能。

参考文献:

- [1] 陈小龙,陈唯实,饶云华,等.飞鸟与无人机目标雷达探测与识别技术进展与展望[J].雷达学报,2020,9(5): 803-827.
CHEN Xiaolong, CHEN Weishi, RAO Yunhua, et al. Progress and prospects of radar target detection and recognition technology for flying birds and unmanned aerial vehicles[J]. *Journal of Radars*, 2020, 9(5): 803-827.
- [2] 孔建国,张向伟,赵志伟,等.基于改进 YOLOv8 的机场飞鸟实时

- 目标检测方法[J]. 科学技术与工程, 2024, **24**(32): 13944-13952.
- KONG Jianguo, ZHANG Xiangwei, ZHAO Zhiwei, et al. Real time object detection method for airport flying birds based on improved YOLOv8[J]. *Science Technology and Engineering*, 2024, **24**(32): 13944-13952.
- [3] 金麟雨, 李舒萌, 刘艳艳, 等. 样线法和网捕法在机场鸟情调查中的应用比较[J]. *生态学报*, 2022, **42**(22): 9348-9358.
- JIN L Y, LI S M, LIU Y Y, et al. Comparisons of line transect and mist-net capture in bird surveys applied in airports[J]. *Acta Ecologica Sinica*, 2022, **42**(22): 9348-9358.
- [4] 寇人可, 王春平, 罗迎, 等. 单帧红外图像多尺度小目标检测技术综述[J]. *中国图象图形学报*, 2024, **29**(9): 2625-2649.
- Kou R K, Wang C P, Luo Y, et al. Multiscale small-target detection techniques in single-frame infrared images: a review[J]. *Journal of Image and Graphics*, 2024, **29**(9): 2625-2649.
- [5] 范鹏程, 张卫国, 刘万刚, 等. 基于嵌入式 GPU 的红外弱小目标检测算法[J]. *应用光学*, 2020, **41**(5): 1089-1095.
- FAN Pengcheng, ZHANG Weiguo, LIU Wangang, et al. Infrared weak and small target detection algorithm based on embedded GPU[J]. *Journal of Applied Optics*, 2020, **41**(5): 1089-1095.
- [6] TONG X, SUN B, WEI J, et al. EAAU-Net: enhanced asymmetric attention U-Net for infrared small target detection[J]. *Remote Sensing*, 2021, **13**(16): 3200.
- [7] ZHANG M, ZHANG R, YANG Y, et al. ISNet: shape matters for infrared small target detection[C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022: 877-886.
- [8] DENG H, ZHANG Y. FMR-YOLO: Infrared ship rotating target detection based on synthetic fog and multiscale weighted feature fusion[J]. *IEEE Transactions on Instrumentation and Measurement*, 2023, **73**: 1-17.
- [9] Boyang L, CHAO X, Longguang W, et al. Dense nested attention network for infrared small target detection[J]. *IEEE Transactions on Image Processing*, 2022, **32**: 1745-1758.
- [10] 何奇晗, 李中旭, 任凌飞, 等. 细节与全局多级融合的红外无人机目标检测[J/OL]. *红外技术*, 1-8[2025-05-05]. <http://kns.cnki.net/kcms/detail/53.1053.TN.20241202.1502.002.html>.
- HE Qihan, LI Zhongxu, REN Lingfei, et al. Infrared UAV target detection with multi-level fusion of details and global[J/OL]. *Infrared Technology*, 1-8[2025-05-05]. <http://kns.cnki.net/kcms/detail/53.1053.TN.20241202.1502.002.html>.
- [11] Varghese R, Sambath M. Yolov8: A novel object detection algorithm with enhanced performance and robustness[C]// *2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS)*. IEEE, 2024: 1-6.
- [12] LIN T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]// *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*. 2017: 2117-2125.
- [13] LIU S, QI L, QIN H, et al. Path aggregation network for instance segmentation[C]// *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018: 8759-8768.
- [14] TAN M, PANG R, LE Q V. Efficientdet: scalable and efficient object detection[C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020: 10781-10790.
- [15] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]// *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018: 7132-7141.
- ZHONG Z, LIN Z Q, Bidart R, et al. Squeeze-and-attention networks for semantic segmentation[C]// *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2020: 13065-13074.
- Woo S, Park J, Lee J Y, et al. Cbam: convolutional block attention module[C]// *Proceedings of the European Conference on Computer vision (ECCV)*, 2018: 3-19.
- [16] Park J, Woo S, Lee J Y, et al. Bam: Bottleneck attention module[J]. arxiv preprint arxiv:1807.06514, 2018.
- [17] YANG L, ZHANG R Y, LI L, et al. Simam: a simple, parameter-free attention module for convolutional neural networks[C]// *International Conference on Machine Learning*, PMLR, 2021: 11863-11874.
- [18] WANG J, XU C, YANG W, et al. A normalized Gaussian Wasserstein distance for tiny object detection[J]. arxiv preprint arxiv:2110.13389, 2021.
- [19] CHEN C, LIU M Y, Tuzel O, et al. R-CNN for small object detection[C]// *Asian Conference on Computer Vision*, Cham: Springer International Publishing, 2016: 214-230.
- [20] TONG Z, CHEN Y, XU Z, et al. Wise-IoU: bounding box regression loss with dynamic focusing mechanism[J]. arxiv preprint arxiv:2301.10051, 2023.
- [21] M Ma S, XU Y. Mpdio: a loss for efficient and accurate bounding box regression[J]. arxiv preprint arxiv:2307.07662, 2023.
- [22] ZHANG H, ZHANG S. Shape-iou: more accurate metric considering bounding box shape and scale[J]. arxiv preprint arxiv:2312.17663, 2023.
- [23] DAI Y, WU Y, ZHOU F, et al. Asymmetric contextual modulation for infrared small target detection [C]// *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, 2021: 950-959.