

引用格式: 李宁, 朱树先, 曹江山, 等. 基于 RTDETR 的无人机视角目标检测算法[J]. 微电子学与计算机, 2025, 42(9): 14-24.

LI N, ZHU S X, CAO J S, et al. RTDETR-based algorithm for target detection in drone aerial imagery[J]. Microelectronics & Computer, 2025, 42(9): 14-24.

DOI: 10.19304/J.ISSN1000-7180.2024.0588

基于 RTDETR 的无人机视角目标检测算法

李 宁¹, 朱树先^{1,2}, 曹江山², 史宝龙¹

(1 苏州科技大学 物理科学与技术学院, 江苏 苏州 215009;

2 苏州科技大学 电子与信息工程学院, 江苏 苏州 215009)

摘 要: 为解决无人机视角图像的小目标检测中存在的误检、漏检和检测性能差等问题, 提出了一种改进 RTDETR 模型。在主干网络融入由轻量级可变卷积核 (AKConv) 和中值增强空间通道注意力机制组成 BasicAK MECS 模块, 增强了特征提取效果; Neck 部分引入 Slim-neck, 轻量化模型的同时提高检测的准确性和效率; 在上采样部分, 利用动态尺度序列特征融合 (DySSFF) 模块, 提升小目标特征信息提取能力。损失函数使用 Inner-SIoU, 注入边界框的形状和尺度信息, 增强边界框回归效果。实验结果表明, 所提出的模型在 Visdrone2019 数据集上的 mAP 和 mAP_s 分别提升了 2.2% 和 0.9%, 有效提高了模型目标检测能力。

关键词: 目标检测; 图像处理; 深度学习; RTDETR; 无人机图像

中图分类号: TP391

文献标识码: A

文章编号: 1000-7180(2025)09-0014-11

RTDETR-based algorithm for target detection in drone aerial imagery

LI Ning¹, ZHU Shuxian^{1,2}, CAO Jiangshan², SHI Baolong¹

(1 School of Physical Science and Technology, Suzhou University of Science and Technology, Suzhou 215009, China;

2 School of Electronics and Information Engineering, Suzhou University of Science and Technology, Suzhou 215009, China)

Abstract: To address issues such as false positives, missed detections, and poor detection performance in small object detection from drone imagery, an improved RTDETR model is proposed. The backbone network is enhanced with a BasicAK MECS module, which integrates a lightweight adaptable kernel convolution (AKConv) and a median-enhanced spatial channel attention mechanism, thereby improving feature extraction. The Neck component incorporates Slim-neck to both lighten the model and increase detection accuracy and efficiency. In the upsampling stage, a Dynamic Scale Sequence Feature Fusion (DySSFF) module is utilized to enhance the extraction of small object features. The loss function employed is Inner-SIoU, which incorporates shape and scale information of bounding boxes to improve bounding box regression performance. Experimental results demonstrate that the proposed model achieves a 2.2% increase in mAP and a 0.9% increase in mAP_s on the Visdrone2019 dataset, significantly enhancing the model's object detection capability.

Key words: object detection; image processing; deep learning; RTDETR; drone imagery

1 引言

随着无人机技术的快速发展, 在智能交通监控、

灾害救援、地形勘探和电力巡检等领域广泛使用无人机完成目标检测任务^[1]。由于航拍图像中存在目标尺度变化大、背景复杂遮挡目标、分辨率低、分

收稿日期: 2024-08-15; 修回日期: 2024-08-28

基金项目: 国家自然科学基金(61703296)

<https://www.journalmc.com>

布密集、天气影响等挑战，小目标检测精度有待提高。

近年来,许多学者致力于改进无人机航拍图像的目标检测。Lin 等^[2]提出的 FPN 算法被引入到无人机航拍图像的小目标检测领域,可以在多个不同尺度的融合特征进行预测提高对小目标的检测性能;Chen 等^[3]提出了 RRNet,在密集场景中实现更好的多尺度目标检测性能。YOLO 系列算法及 Faster R-CNN 网络能够快速获取目标的类别和边界框。卷积神经网络能够高效的提取局部图像信息,但缺乏对远距离关系的表示。transformer 的多头注意力机制能够捕捉全局图像信息,但忽略局部特征信息^[4]。

DETR 首次将视觉卷积 Transformer 用于端到端基线网络，相比于以往的网络，DETR 利用直接集合预测的思想，简化检测流程并舍弃锚点生成和非最大值抑制。RTDETR(Real-Time DEtection TRansformer)是百度公司的在 2023 年 4 月提出的一种新型实时目标检测器。首次实现了在实时目标检测任

务中端到端检测，并且在速度和准确性方面取得了显著进步。本文基于 RTDETR，针对航拍图像特征信息少、背景复杂等问题，提出了 RTDETR-SDI 目标检测模型，基于 Visdrone2019 无人机图像数据集，降低模型复杂度的同时实现了高准确率和优于目前主流目标检测模型的高效检测性能。

2 RTDETR 模型

RTDETR 由主干网络、编码器和解码器这 3 个部分组成^[5]。主干部分使用 ResNet 网络减少特征图的处理，输出最后 3 个特征图；Neck 部分使用 Transformer 的 Encoder 层处理主干网络输出的特征，使用 CCFM 尺度融合网络进行多尺度特征融合；使用 IOU-Aware Query Selection 选择固定数量的图像特征，解决分类得分和位置置信度分布差异的问题，并引入 IOU 约束初始对象查询；用辅助检测头的解码器优化查询对象，生成方框和置信度得分^[6]。RTDETR-R18 模型结构如图 1 所示。




图 1 RTDETR-R18 模型结构

Fig. 1 RTDETR-R18 model structure

3 改进的 RTDETR 模型

本文在主干网络，提出了轻量化结合中值增强通道空间注意力动态特征提取模块 BasicAK MECS Block，提升 RTDETR 模型获取不同尺度目标特征信息的检测能力，轻量化改进并提高特征融合能力；在 Neck 部分引入 Sim-neck 结构，提高效率并进一步

步减少参数量；改进后的 RTDETR-SDI 模型结构如图 2 所示，主干网络使用 BasicAK MECS Block 模块替换了原始 Basic Block 模块。在编码器部分加入了 DySSFF 模块，输出结果与 3D 卷积堆栈输出结果相加，提高多级特征图的融合能力；使用 Inner-SIoU 替换原有的损失函数，加快边界框回归速度；选用 Lion 优化器替代 AdamW，加快模型运行速度。




图2 改进的 RTDETR-SDI 模型结构

Fig. 2 Improved RTDETR-SDI model structure

3.1 Backbone 网络卷积的轻量化改进

标准卷积采样形状是固定的,卷积核运算局限于局部窗口,无法获取其他位置信息,不能很好的处理无人机航拍图像中多样形状的小目标^[7]。本文引入 AKConv 可变形卷积代替 Basic Block 的标准卷积(见图 3),该方法突破了传统卷积局限于固定采

样形状的限制,提供任意数量的参数和任意采样形状,卷积参数的数量可以实现线性上升或下降,使得卷积操作能够更加精准地适应图像中不同位置的目标^[8]。选用较小卷积核的卷积,使卷积参数量呈线性增减,用于轻量化模型。




图3 Basic Block 模块结构

Fig. 3 Basic Block model structure

基于卷积进行运算,使用采样网格将特征定位在相应的位置。设 R 表示采样网格,则 R 表示为

$$R = \{(-1, -1), (-1, 0), \dots, (0, 1), (1, 1)\} \quad (1)$$

任意大小的卷积都可以生成初始采样坐标,设置坐标左上角(0, 0)为采样原点。设定位置 P_0 处的相应卷积运算定义为

<https://www.journalmc.com>

$$\text{Conv}(P_0) = \sum \omega \times (P_0 + P_n) \quad (2)$$

式中: ω 为卷积参数。

AKConv 通过卷积运算得到所需卷积核偏离量来调整不规则卷积核的初始采样形状^[9],提高了特征提取的准确性,卷积核形状动态调整以适应图像特征,与原始采样形状相比,每个位置的采样形状都通过重采样发生改变,根据图像内容动态调整其

操作, 能够更好的提取不规则特征。

3.2 主干网络注意力的改进

无人机数据集由于采集过程中天气、地理环境等因素会对图像产生影响, 图像中的小目标具有分辨率低、信息有限的特点^[10]。现有注意力机制不能

很好的从含有噪声的特征图提取特征, 本文结合了通道注意力和空间注意力的思想, 提出中值增强空间通道注意力(Median-Enhanced Channel and Spatial attention block, MECS)加入主干网络, 其结构如图4所示。




图4 MECS 中值增强空间通道注意力结构

Fig. 4 The architecture of median-enhanced channel and spatial attention block

在通道注意力中, 结合全局平均池化和全局最大池化操作, 提取全局统计信息, 保留重要特征信息的同时去除噪声^[11]。在空间注意力中, 利用多尺度深度卷积捕捉不同尺度的空间特征, 提升模型在捕捉复杂场景中不同方向和不同尺寸目标的能力^[12]。结合的中值增强注意力为小目标检测提供更丰富的特征表示, 增强特征提取的效果和鲁棒性。

通道注意力模块首先对输入特征图进行全局平均池化、全局最大池化和全局中值池化^[12], 每个池化结果的尺寸均为 $\mathbb{R}^{C \times 1 \times 1}$, 其中 C 为通道数。

将3个池化结果输入共享的多层感知器(Multilayer Perceptron, MLP), 通过第一个卷积层降低特征维度, 再通过第二个卷积层将恢复特征维度, 再使用Sigmoid激活函数压缩输出值, 通过元素级相加注意力图得到通道注意力图。再将通道注意力图与原始输入特征图进行元素级相乘, 得到加权后的特征图^[13-14], 其表达式为

$$F_c = \sigma(\text{MLP}(\text{AvgPool}(F))) + \sigma(\text{MLP}(\text{MaxPool}(F))) + \sigma(\text{MLP}(\text{MedianPool}(F))) \quad (3)$$

$$F' = F_c \odot F \quad (4)$$

式中: σ 为Sigmoid函数; $\odot$ 表示元素及相乘。

空间注意力模块首先输入的通道特征图首先经过深度卷积层提取特征。再分别通过多个不同尺寸

的深度卷积层, 如 1×11 、 1×7 等尺寸的卷积提取多尺度特征。元素级相加输出结果, 得到融合后的特征图。将融合后的特征图通过一个 1×1 卷积层, 生成空间注意力图。空间注意力图与通道加权后的特征图进行元素级相乘, 得到最终输出特征图^[15-16]。

$$F_s = \sum_{i=1}^n D_i(F') \quad (5)$$

$$F'' = \text{Conv}1 \times 1(F_s) \odot F' \quad (6)$$

式中: n 为深度卷积的数量; $\text{Conv}1 \times 1$ 表示 1×1 卷积操作。

在Basic Block中结合AKconv和MECS注意力机制确保了每个特征组内空间语义特征的均匀分布, 有助于维护与通道相关的信息, 并减小计算开销。使模块能够更专注于小目标区域, 从而在复杂场景中具有更高的针对性和有效性。BasicAK MECS结构如图5所示。

3.3 基于VOV-GSCSP模块的Neck改进

本文在Neck部分, 引入Sim-neck结构提高检测的准确性和效率, 减少参数计算量。Sim-neck架构中, 不同尺度的特征图(P_3 、 P_4 、 P_5)首先通过GSCConv模块处理, 保持较低时间复杂度的同时, 尽可能地保留通道之间的隐藏连接, 在减少特征图压缩和通道扩充过程中语义信息的丢失, 加快CNN的图像预测计算^[17]。然后通过上采样和拼接操

<https://www.journalmc.com>

作与其他尺度的特征图结合。处理后的特征图再次通过 GSConv 模块,最后通过 GS 瓶颈(GS bottleneck)和跨阶段部分网络(Global Scheduling Cross-Stage Partial network, GSCSP)组成的 VOV-GSCSP

模块来进步提取和融合特征^[18-19],如图 6 所示。输入到最终的检测头(Head₁、Head₂和 Head₃)进行目标检测,这些模块结构设计更简单,提升性能的同时更易于硬件实现。




图 5 BasicAK MECS 模块

Fig. 5 BasicAK MECS block




图 6 VOV-GSCSP 模块结构

Fig. 6 The architecture of VOV-GSCSP block

3.4 基于 DySSFF 模块的上采样改进

为了让模型能够检测到不同尺寸的航拍图像目标,需要对不同层次的特征进行特征融合。RTDETR 采用简单的拼接或者加和来进行特征融合,并未能有效地利用所有金字塔特征图之间的相关性^[20]。

为了更好地结合深层特征图的高维信息和浅层特征图的详细信息,本文引入 DySSFF 模块^[21]。在上采样提取关键信息,上采样后的图像通过高斯滤波器进行平滑处理,生成具有相同分辨率但不同尺寸的图像,拼接特征图并利用三维卷积提取尺度序列特征^[22]。指定上采样的点采样角度,更充分地利用了特征图中的语义信息,丰富了不同尺度之间的语义关系。能够更好地适应特征图的像素信息和内容特征,避免了上采样过程中可能削弱小目标特征信息的问题。

DySSFF 模块充分发挥了动态上采样和特征融

合的优势,实现了更加有效的多尺度特征融合能力。

3.5 损失函数的优化

现阶段,IoU 无法根据不同的检测任务进行自适应的调整。区分不同的回归样本以及使用不同尺度的辅助边界框计算损失可以有效加速边界框回归过程^[23]。

本文为加强对航拍图像中小目标检测的效果,加入由 Inner-IoU 和 SIoU 结合构成新的损失函数 Inner-SIoU 替换原有的损失函数。通过融入角度考虑和规模敏感性,加入一个缩放因子以控制计算损失的辅助边界框的尺寸大小来加速边界框回归,同时也增强了损失函数的泛化能力^[24-25]。解决了以往损失函数的局限性,根据期望回归间的向量角度调整角度惩罚度量,使预测框快速以回归到最近的轴,随后则只需要回归一个坐标(x 或 y),这有效地减少了自由度的总数,其原理如图 7 所示。




图7 SIoU 的距离损失和角度损失

Fig. 7 Distance loss and angle loss in SIoU

$$\Lambda = 1 - 2 * \sin^2 \left(\arcsin \left(\frac{c_h}{\sigma} \right) - \frac{\pi}{4} \right) = \cos \left(2 * \left(\arcsin \left(\frac{c_h}{\sigma} \right) - \frac{\pi}{4} \right) \right) \quad (7)$$

$$\frac{c_h}{\sigma} = \sin(\alpha), \sigma = \sqrt{(b_{c_x}^{gt} - b_{c_x})^2 + (b_{c_y}^{gt} - b_{c_y})^2} \quad (8)$$

$$c_h = \max(b_{c_x}^{gt}, b_{c_y}) - \min(b_{c_x}^{gt}, b_{c_y}) \quad (9)$$

式中: σ 为预测框和真实框中心点连线的长度; c_h 为中心点高度差; $b_{c_x}^{gt}$ 、 $b_{c_y}^{gt}$ 为真实框中心点的坐标; b_{c_x} 、 b_{c_y} 为预测框中心点坐标。

$$\gamma = 2 - \Lambda \quad (10)$$

$$\Delta = \sum_{t=x,y} (1 - e^{-\gamma \rho^t}) = 2 - e^{-\gamma \rho^x} - e^{-\gamma \rho^y} \quad (11)$$

$$\Omega = \sum_{t=w,h} (1 - e^{-w_t})^\theta = (1 - e^{-w})^\theta + (1 - e^{-h})^\theta \quad (12)$$

$$w_w = \frac{|w - w^{gt}|}{\max(w, w^{gt})}, w_h = \frac{|h - h^{gt}|}{\max(h, h^{gt})} \quad (13)$$

$$\text{Loss}_{\text{SIoU}} = 1 - \text{IoU} + \frac{\Delta + \Omega}{2} \quad (14)$$

式中: Λ 为角度损失; Δ 为距离损失; Ω 为形状损失。SIoU 损失整合了 IoU 损失与角度损失、距离损失和形状损失, 能够有效增强预测准确性。

3.6 Lion 优化器

本文选用 Lion 优化器替代 AdamW 用于提升模型的运行速度, Lion 引入动量, 通过积累历史梯度的一部分来加速梯度更新, 对梯度进行动态调整, 以实现参数分布的均衡^[26]。这样可以增加参数更新的稳定性, 避免陷入震荡或振荡状态, 将额外的内存占用减半, 满足轻量化模型的目标。模型运行具有更快的运行时间, 相比 AdamW 和 Adafactor 提速 2% ~ 15%。

4 实验及结果分析

4.1 数据集及预处理

本文选取由国际无人机视觉领域权威数据集 VisDrone2019 作为实验验证对象, 使用各种无人机从中国 14 个地区包含白天和黑夜场景, 不同天气条件下城市和农村环境的图像。俯拍视角的图像具有小目标聚集、容易互相遮挡、清晰度低、目标尺寸多样、背景复杂等特点^[27]。包括训练集 7 766 张, 验证集 548 张和测试集 3 190 张。10 类对象, 多种图像尺寸^[28], 数据集分布如图 8 所示。




图8 目标类别和尺寸分布图

Fig. 8 Target category distribution and size diagram

分别从测试集和验证集中随机选取 500 张、200 张图像与训练集图像进行替换, 以避免训练过

拟合问题, 提高模型训练的鲁棒性。对图像切片处理, 调整图像尺寸为 640×640 像素, 适应训练需求

<https://www.journalmc.com>

且提高训练速度。

4.2 实验设置及评价指标

本文实验采用的硬件处理器 13th Gen Intel Core i5-13600K, GPU: NVIDIA GeForce RTX 4060 Ti, 16 GB 显存; 软件操作系统为 Windows 10, 编程语言为 Python3.8, 采用 Pytorch 框架。

实验中的网络参数有以下设置: 使用 Lion 优化器, 学习率为 1×10^{-4} , Batch Size 为 4, Momentum 为 0.9, 输入图像大小为 640×640 , 网络的训练次数为 500 次, 每 10 次保存训练参数信息。

本文选用平均精度 mAP(mean Average Precision, 记为 m_{AP}), 按照 COCO 数据集的分类标准, 定义面积小于 32×32 像素的目标为小目标, 面积在 $32 \times 32 \sim 64 \times 64$ 像素为中目标, 面积大于 64×64 像素为大目标, 大中小目标平均精度分别为($m_{AP,l}$)、($m_{AP,m}$)和($m_{AP,s}$)^[29]。采用精确度 P (Precision)、召回率 R (Recall)、参数量 p (Parameters)、检测速度 (FPS)作为评价指标验证模型检测效果^[30-31], 表达式分别为

$$m_{AP} = \frac{\sum_i^N A_{Pi}}{N} \quad (15)$$

$$P = \frac{TP}{TP + FP} \quad (16)$$

$$R = \frac{TP}{TP + FN} \quad (17)$$

4.3 不同算法对比实验

选取具有代表性的目标检测算法(Faster R-CNN、CenterNet、YOLOv5s、YOLOv7、CA-YOLOv8、YOLOv8s、YOLOv8m、DETR、RTDETR)^[32-34]和本文提出的 RTDETR-SDI 进行对比实验。实验过程中, 保持相同的实验硬件设备和软件环境及参数设置, 在最优模型训练相同轮数时选取生成的图像进行分析。

图 9 为不同目标检测模型在相同实验设置下 3 种场景的检测结果, 每行从左到右依次为 RTDETR、YOLOv7、YOLOv8m、RTDETR-SDI。通过可视化结果分析可以发现其他主流检测模型出现检测性能不佳、小目标遗漏等现象。本文提出的模型检测精确率更高, 小目标漏检率更低, 在较高高度下对目标密集的城市街道和黑暗场景中仍有较强的检测能力。




图 9 各网络的对比实验结果

Fig. 9 Comparative experimental results of different net-work

各模型对比实验的结果如表 1 所示。本文提出的 RTDETR-SDI 模型基于评价标准可以认为各指标均有效提升, 优于其他算法, 可以认为实现了更强的目标检测性能。

表 2 列出了各模型对数据集 10 个类别的检测精度。分析可知, RTDETR-SDI 模型各类别精度均有提升。
<https://www.journalmc.com>

不同程度的提升, 提升最明显的是行人, 较 RTDETR 提升幅度为 13%, 自行车、摩托车等检测也有较明显改善。在航拍图像中小尺寸目标更容易出现不清晰的现象, 在场景中较为密集更容易被遮挡。这几类目标的检测结果数值的提升, 也表明了 RTDETR-SDI 模型小目标的检测性能优于目前主流模型。

表 1 对比实验

Tab. 1 Comparative experiments

模型	GFLOPS/GB	mAP@50/%	mAP@50:95/%	P /%	R/%	p/MB	FPS/(frame·s ⁻¹)
FasterRCNN	206.4	33.2	17.0	43.5	35.6	41.29	25.4
CenterNet	62.7	24.2	10.7	21.1	35.6	24.6	21.0
Yolov5s	15.8	35.3	19.4	44.5	32.6	7.03	89.0
Yolov7	103.5	46.1	24.0	52.3	42.5	37.24	36.0
CA-Yolov8	165.2	38.9	21.7	53.5	41.9	43.7	34.0
Yolov8s	28.8	39.2	23.4	50.5	38.1	11.13	120.2
Yolov8m	78.7	42.7	26.6	53.2	42.0	25.9	82.4
DDETR	186.8	43.1	27.1	46.5	39.2	40.04	65.0
RTDETR	58.2	47.6	29.4	51.2	45.8	40.5	54.1
Ours	52.4	49.8	30.3	54.6	47.5	34.2	40.6

表 2 各算法在 VisDrone2019 测试集上的检测结果对比

Tab. 2 Comparison of detection results of different algorithms on the VisDrone2019 test set

类别模型	Awning-tricycle	Bus	Bicycle	Car	Motor	Pedestrian	People	Tricycle	Truck	Van	m _{AP} /%
FasterRCNN	8.7	31.4	6.7	51.7	20.7	21.4	15.6	15.0	19	29.5	21.7
CenterNet	17.4	37.9	14.6	59.7	23.7	22.6	20.6	20.1	21.3	24.0	26.2
Yolov5s	20.8	57.8	9.9	72.5	25.3	28.4	15.1	18.1	30.8	35.2	33.2
Yolov7	13.2	48.1	11.4	77.9	23.7	41.5	37.2	23.6	32.8	39.8	37.1
CA-Yolov8	22.3	64.6	23.5	83.5	57.5	51.5	42.8	34.8	42.1	42.6	45.8
Yolov8s	16.1	55.7	12.2	79.6	34.5	42.7	32.6	28.2	36.8	44.4	39.3
Yolov8m	20.0	59.5	10.6	73.6	32.4	31.2	17.0	20.4	42.3	40.5	40.6
DDETR	10.1	40.4	12.6	70.5	39.1	38.6	34.9	34.9	24.9	34.7	32.6
RTDETR	19.7	64.3	18.8	85.8	46.0	48.8	42.9	33.3	39.0	44.8	41.0
Ours	21.7	62.1	49.4	87.2	52.3	51.6	43.4	40.6	43.7	45.9	42.5

4.4 消融实验

为系统分析各改进点对模型的改善情况, 依次定义使用 Lion 优化函数的基准模型 A、改进 BasicAK MECS block 特征提取与融合的模型 A+B、改进 Neck 和上采样模块的模型 A+C、改进损失函数的模型 A+D、改进模型 A+B+C(特征提取与融合、注意力机制、Neck)、改进模型 A+B+D(特征提取与融合、注意力机制、损失函数)、改进模型 A+B+C+D(特征提取与融合、注意力机制、损失函数), 并定量探讨六种模型评价指标的变化, 在验证集的实验结果如表 3 所示。

分析表 3 实验结果可知: BasicAK MECS Block 特征提取模块的加入使模型的 mAP@50 和 mAP@

50:95 分别提高了 0.9%、0.6%。DyASSFF 特征融合结构的引入和轻量化 Neck 改进让模型的 AP_s 增加了 0.4%, 增强了小目标的检测精度。每个改进模块都能小幅度的提升模型性能。数据表明本文提出的 RTDETR-SDI 模型相较于 RTDETR 降低模型参数的同时, 在 mAP@50 和 mAP@50:95 上取得了 2.2% 和 0.9% 的提升, 精确度和召回率提高 0.6% 和 0.7%。

改进的 RTDETR-SDI 模型与原模型 RTDETR 对比结果如图 10 所示, 本文提出的 RTDETR-SDI 模型 mAP@50 和 mAP@50:95 值均随着迭代次数逐渐提高, 在第 200 轮后趋于平稳。

<https://www.journalmc.com>

表 3 消融实验结果对比

Tab. 3 Ablation experiments

模型	mAP@50/%	mAP@50:95/%	AP _s /%	AP _m /%	AP _l /%	P/%	R/%	p/MB	FPS/(frame·s ⁻¹)
A	47.6	29.4	19.2	37.0	42.6	62.8	45.9	40.5	54.0
A+B	48.5	30.0	19.6	37.4	44.3	62.4	46.6	35.2	43.5
A+C	48.6	29.7	19.6	37.2	42.1	62.8	46.9	40.8	46.8
A+D	47.9	29.5	19.4	37.0	42.9	62.5	46.2	40.7	52.6
A+B+C	49.1	30.2	19.7	37.6	43.2	63.2	47.1	35.3	45.2
A+B+D	49.2	29.9	19.9	37.4	43.4	63.0	47.4	35.9	44.6
A+C+D	48.7	30.1	19.8	37.2	42.6	42.9	47.3	40.0	42.7
A+B+C+D	49.8	30.3	20.1	37.6	43.6	63.5	47.6	34.0	41.5




图 10 模型改进对比图

Fig. 10 Model improvement comparison diagram

各改进模型检测结果如图 11 所示。与 RTDETR 基础模型相比,改进的各模块均能提升检测置信度,

减少漏检和误检概率。显著增强了检测性能,在检测被遮挡和分布密集的小目标时表现优越。




图 11 各改进模型检测结果

Fig. 11 Detection results of each improved model

5 结束语

针对在无人机航拍图像出现分辨率差、目标集中、目标尺寸多样、互相遮挡等现象,检测过程容易出现的误检、漏检等问题,本文从基于RTDETR模型在通道特征融合、注意力机制、轻量化改进、定位回归损失函数和Neck等方面进行了优化,提出RTDETR-SDI目标检测算法。在Visdrone2019数据集的实验结果中,通过消融实验验证了各改进部分能有效提升检测精度,所提算法的mAP和mAP_s分别提高了2.2%和0.9%,其余指标均有提升,处理密集且遮挡的目标时表现优越,表明目标检测性能优于目前主流目标检测算法。

在未来的任务中,将探讨如何在降低计算复杂度的同时提高小目标的检测精度,保持模型准确性的同时加快推理速度以适应在计算资源有限和硬件限制的无人机航拍场景的应用。

参考文献:

- [1] CAI Y M, CAI G Y, CAI J. Action-transformer for action recognition in short videos[C]// Proceedings of the 11th International Conference on Intelligent Control and Information Processing. Piscataway: IEEE, 2021: 278-283. DOI: [10.1109/ICICIP53388.2021.9642184](https://doi.org/10.1109/ICICIP53388.2021.9642184).
- [2] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature pyramid networks for object detection[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Piscataway: IEEE, 2017: 936-944. DOI: [10.1109/CVPR.2017.106.2117-2125](https://doi.org/10.1109/CVPR.2017.106.2117-2125).
- [3] CHEN X, LI Y, ZHANG Z. RRNet: A hybrid detector for object detection in dense scenes[J]. IEEE Transactions on Image Processing, 2020, 29, 6789-6801.
- [4] 董刚, 谢维成, 黄小龙, 等. 深度学习小目标检测算法综述[J]. 计算机工程与应用, 2023, 59(11): 16-27. DOI: [10.3778/j.issn.1002-8331.2211-0377](https://doi.org/10.3778/j.issn.1002-8331.2211-0377).
DONG G, XIE W C, HUANG X L, et al. Review of small object detection algorithms based on deep learning[J]. Computer Engineering and Applications, 2023, 59(11): 16-27. DOI: [10.3778/j.issn.1002-8331.2211-0377](https://doi.org/10.3778/j.issn.1002-8331.2211-0377).
- [5] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]// 16th European Conference on Computer Vision. Heidelberg: Springer, 2020: 213-229. DOI: [10.1007/978-3-030-58452-8_13](https://doi.org/10.1007/978-3-030-58452-8_13).
- [6] REDMON J, FARHADI A. YOLOv3: An incremental improvement[J]. arXiv: 1804.02767, 2018. DOI: [10.48550/arXiv.1804.02767](https://doi.org/10.48550/arXiv.1804.02767).
- [7] LI C Y, LI L L, JIANG H L, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv: 2209.02976, 2022. DOI: [10.48550/arXiv.2209.02976](https://doi.org/10.48550/arXiv.2209.02976).
- [8] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2023: 7464-7475. DOI: [10.1109/CVPR52729.2023.00721](https://doi.org/10.1109/CVPR52729.2023.00721).
- [9] REIS D, KUPEC J, HONG J, et al. Real-time flying object detection with YOLOv8[J]. arXiv: 2305.09972, 2023. DOI: [10.48550/arXiv.2305.09972](https://doi.org/10.48550/arXiv.2305.09972).
- [10] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[C]// Proceedings of the 29th International Conference on Neural Information Processing Systems. Cambridge: MIT Press, 2015: 91-99.
- [11] HE K M, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN[C]// Proceedings of the 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 2980-2988. DOI: [10.1109/ICCV.2017.322](https://doi.org/10.1109/ICCV.2017.322).
- [12] KIRILLOV A, WU Y X, HE K M, et al. PointRend: Image segmentation as rendering[C]// Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 9796-9805. DOI: [10.1109/CVPR42600.2020.00982](https://doi.org/10.1109/CVPR42600.2020.00982).
- [13] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]// European conference on computer vision. Cham: Springer International Publishing, 2020: 213-229.
- [14] ZHU X Z, SU W J, LU L W, et al. Deformable DETR: Deformable transformers for end-to-end object detection [C]//9th International Conference on Learning Representations. [S.I.]: OpenReview, 2021.
- [15] MENG D P, CHEN X K, FAN Z J, et al. Conditional DETR for fast training convergence[C]// Proceedings of the 2021 IEEE/CVF International Conference on Computer Vision. Piscataway: IEEE, 2021: 3631-3640. DOI: [10.1109/ICCV48922.2021.00363](https://doi.org/10.1109/ICCV48922.2021.00363).
- [16] GUO C X, FAN B, ZHANG Q, et al. AugFPN: Improving multi-scale feature learning for object detection[C]// 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2020: 12592-12601. DOI: [10.1109/CVPR42600.2020.01261](https://doi.org/10.1109/CVPR42600.2020.01261).
- [17] ZHU X K, LYU S C, WANG X, et al. TPH-YOLOv5: Improved YOLOv5 based on transformer prediction head for object detection on drone-captured scenarios[C]// 2021 IEEE/CVF International Conference on Computer Vision Workshops. Piscataway: IEEE, 2021: 2778-2788. DOI: [10.1109/ICCVW54120.2021.00312](https://doi.org/10.1109/ICCVW54120.2021.00312).
- [18] WOO S, PARK J, LEE J Y, et al. CBAM: Convolutional block attention module[C]//15th European Conference <https://www.journalmcc.com>

- on Computer Vision. Heidelberg: Springer, 2018: 3-19. DOI: [10.1007/978-3-030-01234-2_1](https://doi.org/10.1007/978-3-030-01234-2_1).
- [19] LIU R, LEHMAN J, MOLINO P, et al. An intriguing failing of convolutional neural networks and the CoordConv solution[C]// Proceedings of the 32nd International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2018: 9628-9639.
- [20] HU J, SHEN L, ALBANIE S, et al. Gather-excite: Exploiting feature context in convolutional neural networks [C]// Proceedings of the 32nd International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2018: 9423-9433.
- [21] ZHENG Z H, WANG P, LIU W, et al. Distance-IoU loss: Faster and better learning for bounding box regression [C]// Proceedings of the AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2020: 12993-13000. DOI: [10.1609/aaai.v34i07.6999](https://doi.org/10.1609/aaai.v34i07.6999).
- [22] TONG Z J, CHEN Y H, XU Z W, et al. Wise-IoU: Bounding box regression loss with dynamic focusing mechanism[J]. arXiv: 2301.10051, 2023. DOI: [10.48550/arXiv.2301.10051](https://doi.org/10.48550/arXiv.2301.10051).
- [23] ZENG S, YANG W Z, JAO Y Y, et al. SCA-YOLO: A new small object detection model for UAV images[J]. *The Visual Computer*, 2024, 40(3): 1787-1803. DOI: [10.1007/s00371-023-02886-y](https://doi.org/10.1007/s00371-023-02886-y).
- [24] 于傲泽, 魏维伟, 王平, 等. 基于分块复合注意力的无人机小目标检测算法[J]. *航空学报*, 2024, 45(14): 629148. DOI: [10.7527/S1000-6893.2023.29148](https://doi.org/10.7527/S1000-6893.2023.29148).
- YU A Z, WEI W W, WANG P, et al. Small target detection algorithm for UAV based on patch-wise co-attention[J]. *Acta Aeronautica et Astronautica Sinica*, 2024, 45(14): 629148. DOI: [10.7527/S1000-6893.2023.29148](https://doi.org/10.7527/S1000-6893.2023.29148).
- [25] DONG G, XIE W C, HUANG X L, et al. Review of small object detection algorithms based on deep learning[D]. *Computer Engineering and Applications*, 2023, 59(11): 16-27.
- [26] ZHENG Q H, ZHAO P H, LI Y, et al. Spectrum interference-based two-level data augmentation method in deep learning for automatic modulation classification[J]. *Neural Computing and Applications*, 2021, 33(13): 7723-7745. DOI: [10.1007/s00521-020-05514-1](https://doi.org/10.1007/s00521-020-05514-1).
- [27] ZHENG Q H, TIAN X Y, YU Z G, et al. Application of wavelet-packet transform driven deep learning method in PM_{2.5} concentration prediction: A case study of Qingdao, China[J]. *Sustainable Cities and Society*, 2023, 92: 104486. DOI: [10.1016/j.scs.2023.104486](https://doi.org/10.1016/j.scs.2023.104486).
- [28] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]// 2017 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2017: 2999-3007. DOI: [10.1109/ICCV.2017.324](https://doi.org/10.1109/ICCV.2017.324).
- [29] LI J N, LIANG X D, WEI Y C, et al. Perceptual generative adversarial networks for small object detection[C]// 2017 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2017: 1951-1959. DOI: [10.1109/CVPR.2017.211](https://doi.org/10.1109/CVPR.2017.211).
- [30] LIU S, QI L, QIN H F, et al. Path aggregation network for instance segmentation[C]// 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2018: 8759-8768. DOI: [10.1109/CVPR.2018.00913](https://doi.org/10.1109/CVPR.2018.00913).
- [31] CHEN C R, ZHANG Y, LV Q X, et al. RRNet: A hybrid detector for object detection in drone-captured images [C]// 2019 IEEE/CVF International Conference on Computer Vision Workshop. Piscataway: IEEE, 2019: 100-108. DOI: [10.1109/ICCVW.2019.00018](https://doi.org/10.1109/ICCVW.2019.00018).
- [32] LIN Q Z, DING Y, XU H, et al. ECascade-RCNN: Enhanced cascade RCNN for multi-scale object detection in UAV images[C]// 2021 7th International Conference on Automation, Robotics and Applications. Piscataway: IEEE, 2021: 268-272. DOI: [10.1109/ICARA51699.2021.9376456](https://doi.org/10.1109/ICARA51699.2021.9376456).
- [33] TANG W Q, SUN J, WANG G. Horizontal feature pyramid network for object detection in UAV images[C]// 2021 China Automation Congress. Piscataway: IEEE, 2021: 7746-7750. DOI: [10.1109/CAC53003.2021.9727887](https://doi.org/10.1109/CAC53003.2021.9727887).
- [34] LIU X, ZHANG Z Y. A vision-based target detection, tracking, and positioning algorithm for unmanned aerial vehicle[J]. *Wireless Communications and Mobile Computing*, 2021, 2021: 5565589. DOI: [10.1155/2021/5565589](https://doi.org/10.1155/2021/5565589).

作者简介:

李 宁 硕士研究生, lining200105@163.com

朱树先(通信作者) 博士, 副教授,

zhushuxian1970@163.com