

基于 YOLO v5 的桥梁缺陷检测的研究

杨 洋*,王洁松,袁春花

(江苏航运职业技术学院,江苏 南通)

摘 要:近年来,深度学习技术特别是卷积神经网络(CNN)在图像识别领域的应用取得了显著成就,而 YOLO 系列模型因其高效实时的目标检测性能而备受青睐。然而,YOLO v5 在桥梁缺陷检测上的表现并不尽如人意。为此,研究人员基于 YOLO v5 框架,引入了坐标注意力(Coordinate Attention, CA)机制,开发了一种改进的桥梁缺陷检测方法,使得模型能够根据特征图中的不同位置自适应地分配权重,从而增强了模型对关键特征的捕捉能力。在实验阶段,团队对数据集进行了预处理,并采用了多种数据增强技术来增加小尺寸目标的数量。最终的实验结果表明,改进后的算法在各项关键性能指标上都超越了原有算法,尤其是在准确率、召回率及 mAP 值方面的提升更为显著。

关键词:YOLO;缺陷检测;深度学习

中图分类号:TU17;TP311

文献标识码:A

文章编号:2096-4390(2025)21-0150-04

引言

桥梁作为重要的基础设施,在交通运输网络中起着关键作用。确保桥梁的安全性与耐久性意义重大。然而,随着时间的流逝,桥梁结构会遭受诸如混凝土裂缝、钢筋腐蚀以及桥面空洞等多种损伤,若这些问题不及时处理,将严重影响桥梁的整体性能。

传统的桥梁检测主要依赖人工目视检查,此方式效率低下,且易受检查者经验和技术水平影响,致使潜在安全隐患可能无法及时发现。为提升桥梁缺陷检测的准确性和效率,现代信息技术,特别是机器学习技术,已成为重要的研究方向。

近年来,深度学习技术,尤其是卷积神经网络(Convolutional Neural Networks,CNN)在图像识别领域取得了重大突破。从 1998 年 LeCun 提出的 LeNet-5^[1],到 2012 年 AlexNet 的成功应用^[2],再到 2015 年 ResNet 和 YOLO 的推出,这些技术的发展极大地推动了图像识别和目标检测的进步。特别是 YOLO (You Only Look Once)系列模型,因其实现了高速度与高准确性的平衡,成为实时检测任务的理想之选。

在桥梁缺陷检测这一特定应用领域,已有众多研究成果。例如,宋冬梅的研究通过改进 YOLO v3 模型

提高了指针式仪表的识别精度,但在多目标检测方面仍存在问题^[3];赵麟坤团队通过优化 Faster RCNN 模型改善了碳纤维编织物的缺陷检测,却未能在检测速度上有显著提升^[4];杨彬等人通过引入变形卷积操作增强 Mask RCNN 模型对焊接缺陷的识别能力,但未充分考虑实时性要求^[5]。

鉴于此,本研究提出一种基于改进 YOLO v5 的桥梁缺陷检测算法。YOLO v5 因其卓越的泛化能力和快速响应特性成为首选模型。在此基础上,我们对特征融合层进行针对性优化,以更好地捕捉桥梁结构中细微的缺陷特征,同时保持模型的实时检测能力。

1 YOLO v5 的整体架构

在目标检测算法中,YOLOv5 作为 YOLO 家族的一员,凭借其卓越的整体性能,超越了同类的端到端检测方法,如 YOLOv3 和 SSD,成为应用最为广泛的一种检测算法^[6]。具体而言,可以被划分成如下三个部分。

1.1 输入与特征提取

首先,将待检测图像经过切片划分为四张通道数一致的特征图,并在通道维度进行拼接,来降低参数量。这样的设计使输入特征能沿着两条路径进行传

课题编号:HYKY/2023B04 江苏航运职业技术学院校级课题。

通讯作者:杨洋(1981-),男,硕士研究生,讲师,研究方向:人工智能。

播,能降低模型的计算复杂度。然后,通过 SPP 模块 (Spatial Pyramid Pooling) 根据不同池化尺度来生成多级特征图,特征图拼接后传递到后续 neck 网络中。

1.2 特征融合层

从骨干网络提取的三个不同尺度的桥梁缺陷特征图 ($56*20*20$ 、 $256*40*40$ 和 $256*80*80$) 输入到 PANet(Path-aggregation Network)。在该网络中,浅层的细节特征与深层的语义特征相互融合,从而提升了模型对多尺度信息的综合理解能力。

1.3 Head

检测头由三个卷积模块组成,分别对应尺寸为 $80*80$ 、 $40*40$ 和 $20*20$ 的特征层输出。每个特征层包含 10 个通道,其中 5 个通道用于表示 5 种不同的缺陷类别,4 个通道用于描述边界框的位置坐标,另外 1 个通道用于指示缺陷的存在概率。通过这种设计,检测头能够全面地输出每个潜在缺陷的相关信息。

2 改进的 YOLO v5 模型

实际中的桥梁缺陷种类繁多且变化复杂,检测模型不仅要具备轻量的结构来保证高效处理,还需要满足精度的要求。YOLOv5 凭借其优异的综合性能,非常适合用于桥梁缺陷检测任务。研究基于 YOLOv5 网络,提出了一种改进的桥梁缺陷检测算法,其整体架构如图 1 所示。

该研究在 YOLOv5 的基础上集成了 CA(Coordinate Attention)注意力机制,以提升桥梁缺陷检测的精度和鲁棒性。

首先,尺寸为 $640*640*3$ 待检测图像输入特征提取网络,这个特征提取网络由卷积模块、C3 模块以及 PPS(Spatial Pyramid Pooling)模块组成。随着网络深




图 1 改进后的算法整体结构




图 2 CA 流程

度增加,骨干网络利用卷积操作提取特征,从浅层纹理、边缘信息到深层的语义特征。最后,通过 FPN 网络 (Feature Pyramid Network) 融合不同层次的特征,来

提升检测性能。FPN 网络存在两个问题:一是原模型在顶层特征中使用了单尺度 SPP 模块,会很容易导致参数冗余及信息丢失;二是简单降维合并特征图会降低对噪声和复杂背景的鲁棒性。

为解决这些问题同时实现对不同尺寸缺陷的高效识别,并保持模型轻量化,研究引入了 CA 注意力机制。该机制借鉴了人类视觉系统的原理,使网络能够聚焦关键信息,而忽略无关细节。具体来说,CA 将二维全局池化分解为一维操作,更精准捕捉特征图中的重要信息,而不是随机分配权重。这使得模型能在低复杂度条件下适应分配资源,有效抑制噪声的干扰,专注于缺陷特征的提取。

在实际应用中,桥梁缺陷检测往往面临低光照环境和复杂背景噪声等挑战。尽管 YOLOv5 能有效处理多尺寸目标,但在复杂背景下,其多尺度特征融合不足的问题会影响检测准确性。因此,本研究通过集成 CA 机制来优化特征融合过程,提升整体架构的性能。如图 2 所示,展示了如何在特征图内高效分配权重,从而显著改善主干网络的特征提取能力。

CA 流程分为两个步骤。第一步,坐标信息嵌入模块将坐标信息嵌入到尺寸为 $C \times H \times W$ 的特征图中,沿水平方向和垂直方向进行池化操作,为每个通道生成编码。具体计算公式如下所示

$$z^h(h) = \frac{1}{W} \sum_{0 \leq j < W} X(h, j) \quad (1)$$

$$z^w(w) = \frac{1}{H} \sum_{0 \leq j < H} X(j, w) \quad (2)$$

z^h, z^w 这两个张量的尺寸分别为 $C \times H \times 1$ 和 $C \times W \times 1$,它们的转换使模型能够在空间维度上捕捉依赖关系,聚焦于重要的语义信息。第二步,坐标注意力生成模块将有坐标信息的部分输出张量沿空间维度进行拼接,生成特征图 f ,该特征图融合了水平方向和垂直方向的信息。最后,特征图经过归一化和激活处理,被拆分为两个独立的向量,通过特定计算得到相应的权重。

$$g^h = \sigma(F_h(f^h)) \quad (3)$$

$$g^w = \sigma(F_w(f^w)) \quad (4)$$

F_h 和 F_w 表示对 f^h 与 f^w 通过使用 1×1 卷积核进行转换,使注意力张量与输入张量保持相同的通道数量。转换完后,用 sigmoid 函数对张量进行归一化,最终得出 g^h, g^w 注意力权重。

针对桥梁缺陷的多样性和复杂性,研究在主干网络中加入了 CA 注意力模块,通过更高效的方式捕捉位置信息和通道信息的相互作用,从而提升网络的特征提取能力。

3 实验和结果分析

3.1 数据集及预处理

为了提高数据集中小目标场景,研究采用了多种数据增强技术,如随机翻转、随机缩放和随机裁剪,从而显著增加含有小目标的样本数量。除此之外,研究对整个图像集进行规范化命名,保证每张图片都有一致的标识,便于管理和处理。在构建训时,研究遵循常见的 80/20 原则,将数据集分为两个部分:80%的图片用于训练,优化模型的学习;剩余 20%图片用于定期评估模型性能,监控模型的泛化能力,并且根据评估结果来调整训练策略。

3.2 实验环境和训练策略

实验的环境如表 1 所示。

表 1 实验环境

配置	参数
CPU	Intel i7-11700
GPU	GeForce RTX 4090
操作系统	Windows 10
语言框架	PyTorch
开发语言	PyCharm
其它	CUDA 11.8

在模型的训练过程中,对神经网络的参数配置如下:批量大小设为 16,迭代次数定为 20 000,最大学习率设为 0.002,权重衰减系数设定为 0.000 3。

3.3 实验结果

表 2 不同模型算法在数据集上的实验结果(%)

方法	准确率	召回率	mAP
YOLO V5	65.7	66.1	65.8
YOLO V5+CA	66.8	68.5	67.1

实验结果表明,经过改进的算法在准确率上达到了 66.8%,召回率达到了 68.5%,mAP 值也上升到了 67.1%。这些数据显示,改进后的算法在各个指标上均

优于原算法。

参考文献

- [1] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [2] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks [J]. Communications of the ACM, 2017, 60(6):84-90.
- [3] 宋冬梅. 基于机器视觉的指针式仪表检测[J]. 中国仪器仪表, 2023, 43(1):69-72.
- [4] 赵麟坤, 陈玉洁, 张玉井, 等. 基于改进的 Faster RCNN 碳纤维编织物缺陷检测 [J]. 棉纺织技术, 2023, 51(2):48-54.
- [5] 杨彬, 亚森江·木沙, 安波. 改进 Mask RCNN 的焊缝缺陷检测[J]. 机械设计与制造, 2023, 61(6):157-161.
- [6] Redmon J, Divalla S, Girshick R. You only look once: Unified, real-time object detection[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2016:779-788.

Research on Bridge Defect Detection Based on YOLO v5

Yang Yang*, Wang Jiesong, Yuan Chunhua

(Jiangsu Shipping College, Nantong, China)

Abstract: In recent years, deep learning technologies, particularly convolutional neural networks (CNNs), have achieved remarkable success in the field of image recognition. The YOLO series of models have been favored for their efficient real-time object detection performance. However, the performance of YOLO v5 in bridge defect detection has not been entirely satisfactory. To address this, researchers have developed an improved bridge defect detection method based on the YOLO v5 framework by introducing the Coordinate Attention (CA) mechanism. This enables the model to adaptively assign weights according to different positions within the feature map, thereby enhancing the model's ability to capture key features. During the experimental phase, the team performed preprocessing on the dataset and adopted various data augmentation techniques to increase the number of small target objects. The final experimental results indicate that the improved algorithm surpasses the original algorithm in all key performance metrics, with particularly significant improvements in accuracy, recall, and mean Average Precision (mAP) values.

Key words: YOLO; defect detection; deep learning