

杨国亮,吴永淦,丁 睿,等. 基于改进 RT-DETR 的草莓成熟度检测[J]. 江苏农业科学,2024,52(20):129-137.

doi:10.15889/j.issn.1002-1302.2024.20.016

基于改进 RT-DETR 的草莓成熟度检测

杨国亮, 吴永淦, 丁 睿, 盛杨杨

(江西理工大学电气工程与自动化学院,江西赣州 341000)

摘要:在自然果园环境下,草莓果实生长分布密集易受枝叶遮挡,不同生长周期的草莓形态大小不一,面对遮挡、小尺寸草莓现有的检测模型容易出现误检、漏检问题。针对上述问题,提出了一种基于改进 RT-DETR 的实时草莓成熟度检测算法 Strawberry Ripeness-DETR(SR-DETR)。首先,根据 PConv 卷积设计 FasterBlock 模块替换原模型主干网络中的 BasicBlock 模块,提高模型特征提取能力的同时还有效降低模型参数量;然后,基于 GSConv 卷积和 VOVGSCSP 模块设计了颈部特征融合模块(Light-CCFM),削弱复杂背景和冗余信息的干扰,提高小目标的识别率;最后,引入 SSFF 模块改进特征融合层,增加 SR-DETR 网络的多尺度融合能力,使模型具有更强的鲁棒性。改进后的模型在自建草莓数据集上进行试验,结果显示,SR-DETR 模型的精确度、召回率和平均精度均值分别为 93.0%、90.2%、91.7%,相比于原模型分别提升 1.6、1.8、1.5 个百分点,同时模型参数量、模型大小和计算复杂度分别降低 31.2%、31.1% 和 23.6%。SR-DETR 模型不仅提高了不同成熟度草莓的识别精度,还降低了遮挡目标的漏检率,检测速度达到 60.9 帧/s,可以便捷地部署到终端完成实时检测。

关键词:草莓;成熟度;RT-DETR;目标检测;GSConv;VOVGSCSP

中图分类号:TP391.41 **文献标志码:**A **文章编号:**1002-1302(2024)20-0129-09

草莓色泽艳丽、味道美妙,而且营养价值极高,它富含维生素 C、膳食纤维和多种抗氧化物质,这些成分对人体健康有着诸多益处^[1]。我国作为农业大国,在草莓的生产规模上更是位于世界前列^[2]。我国草莓的种植区域主要位于华东、中南、西南地区,其种植面积在近年来逐渐增长。对草莓采摘的时间把握是非常重要的,不同成熟度的草莓所含有的营养价值不同^[3]。如果采摘过早,草莓还未成熟,其营养价值不高,并且口感酸涩;如果采摘过晚,草莓在运输过程中就容易腐烂,影响后期的售卖。当前,草莓的采摘主要分为人工采摘和机械化采摘 2 种方式^[4]。人工采摘通过人工观察草莓的生长情况来采摘草莓,其采摘周期长,容易错过采摘的最佳时间。而机械化采摘主要是机器通过草莓的表皮颜色判断草莓是否成熟进而进行采摘。但是由于机器难以准确判断草莓的成熟度,导致容

易出现误采、漏采等现象^[5]。因此,研究一款高效准确的草莓成熟度检测系统对草莓的机械化采摘具有重要作用。

近年来,国内外学者通过研究机器视觉技术和光谱分析的方法来实现对苹果、菠萝、葡萄等果实成熟度进行检测^[6]。陈仁凡等提出一种轻量化的基于 YOLO-ODM 的草莓成熟度检测方法,实现了在温室环境下草莓果实的快速识别,检测效果达到 97.4%^[7]。张小花等提出了基于 EfficientDet-D1 的草莓快速检测及分类方法,实现了在自然环境下快速识别成熟草莓与未成熟草莓,识别精度达到 97.50%^[8]。熊俊涛等利用轻量化 YOLO v5-Lite 对木瓜的成熟度进行分类识别,实现了对不同拍摄距离、不同遮挡情况以及不同光照下的果实总体检测效果达 92.4%^[9]。Raj 等将草莓的全光谱信息输入到支持向量机(SVM)中检测草莓成熟度,达到 98% 的准确率^[10]。胡仕林等为了实现复杂环境中苹果采摘机器人目标快速检测,提出一种基于深度可分离卷积 YOLO v5 的目标检测方法,算法检测精度达 95.8%,检测速率达 53 帧/s,机器人单次采摘时间为 4.7 s,采摘成功率达 93.9%^[11]。赵德安等利用改进的 YOLO v3 算法,实现各类复杂环境下的苹果识别,该算法的检测速度可达 60 帧/s,具有良

收稿日期:2024-07-17

基金项目:江西省教育厅科技项目(编号:GJJ210861);江西省教育厅科技计划(编号:GJJ200879)。

作者简介:杨国亮(1973—),男,江西宜春人,博士,教授,主要从事人工智能和模式识别研究。E-mail:ygliang30@126.com。

通信作者:吴永淦,硕士研究生,主要从事人工智能和模式识别研究。E-mail:wyg19914682903@163.com。

好的实时性,但在检测密集场景下的苹果时效果较差^[12]。黄威等为准检测果园中未成熟与成熟的苹果,提出一种基于改进 YOLOX-S 的苹果成熟度检测方法,对苹果低成熟度、中等成熟度和高等成熟度的检测精度分别达 90.85%、95.10% 和 80.50%^[13]。通过上述关于各种水果成熟度检测的研究发现,当前仍然存在一些挑战:虽然提出的模型对目标的识别精度提高了,但模型的参数量往往也会增加,这将导致模型在农业采摘设备当中难以部署;并且模型在复杂环境下识别困难,特别是对于未成熟的草莓,由于未成熟的草莓与叶片的颜色相混合、叶片遮挡果实以及目标数量多且密集等因素,从而导致特征提取困难,识别准确率低。

基于 CNN 的模型在检测精度与速度方面表现良好,但是其中阈值筛选与非极大值抑制(non-maximum suppression, NMS) 2 个关键步骤,会导致模型的鲁棒性和检测速度降低^[14]。RT-DETR 作为一种新的目标检测方法,无需 NMS 后处理,其优化难度减小、鲁棒性得到增强,但其仍存在主干网络结构相对复杂冗余、不同模块间数据流动差等问题^[15]。因此,本研究基于 RT-DETR 提出改进的 SR-DETR 检测模型,主要贡献有:(1) 针对 RT-DETR 主干网络结构存在冗余问题,使用 FasterBlock 模块替换主干中使用的 BasicBlock 模块,在不影响目标检测精度的同时极大地减小了模型的参数量;(2) 针对 RT-DETR 的颈部网络特征信息融合不充分的问题,用 GSConv 卷积去替换颈部的标准卷积,引用 VOVGSCGP 模块对特征融合模块进行细化,提高模型对密集目标的检测能力^[16];(3) 为了快速、准确地识别小目标,在颈部引入了 SSFF 模块,结合空间和尺度特征,提高小目标的检测能力^[17]。最后,通过试验对所提出的 SR-DETR 模型的性能进行验证。

1 RT-DETR 模型介绍

RT-DETR 是基于 Transformer 的一个实时目标检测模型,它包括 1 个主干网络(BackBone)、1 个高效混合编码器和 1 个带有辅助预测头的解码器。其模型的设计官方提供了以 ResNet 和 HGNet 等为主干的多种模型,本研究结合草莓成熟度检测的实际需求,选择网络深度和检测精度较为平衡的 RT-DETR-R18 作为基础网络,网络结构如图 1 所示。模型中的高效混合编码器由基于注意力的尺度内

特征交互(AIFI)和基于 CNN 的跨尺度特征融合(CCFM)模块组成,AIFI 模块类似于 Transformer 中的 Encoder,对 S5 特征进行编码,CCFM 基于跨尺度融合模块进行优化,该模块在融合路径中插入多个由卷积层组成的融合块。解码器则通过 IoU 感知查询模块,该模块构建和优化了认知不确定性来建模编码器特征的联合潜在变量,从而为解码器提供高质量的查询。



2 SR-DETR 模型设计原理

2.1 SR-DETR 模型总体结构

本研究针对 RT-DETR 检测性能不足的问题,提出了改进的草莓成熟度检测模型 SR-DETR。首先,在主干网络中使用 FasterBlock 模块进行特征提取,减少计算冗余的同时提取更丰富的特征信息。其次,在颈部网络中采用轻量级卷积 GSConv 和 VOVGSCSP 模块减轻模型的复杂性,实现骨干网络特征图信息的有效融合,实现高性能检测。最后,为进一步解决多尺度融合问题和轻量级卷积带来的精度下降问题,在特征融合层中加入 SSFF 模块,加速了不同尺度特征之间的融合过程,提高了模型的计算效率和推理速度。SR-DETR 整体网络构架如图 2 所示。

2.2 FasterBlock 模块

在 CNN 构架中,通常采用跨步卷积和池化去除冗余信息,大多数卷积如深度卷积(DWConv)和群卷积(GConv)提取空间特征,虽然通过减少参数量和计算复杂度,在一定程度上缓解这一问题,但是由于它们仍然需要频繁地访问内存,并不能有效地加快运算速度。FasterNet 网络中提出一种新的部分卷积(PConv),它通过减少计算冗余以及内存访问的数量,能够更有效地提取空间特征^[18]。PConv 卷积的核心在于对于输入特征图的通道进行选择性地处理,而非像标准卷积那样应用所有通道。具体来说,PConv 卷积在每一次卷积操作中,选取输入特征图的一部分连续通道进行空间特征提取,而剩余通道则直接保持不变传递到输出特征图中。它通常将输入特征图的第 1 个或最后 1 个连续通道作为整个特征映射的代表进行计算,既减少实际参与计算的通道数,又保证输入和输出特征映射的通道数相同。而标准卷积则是采用卷积核通道数与输入特征映射通道数相同的特征提取方式。PConv 卷积与标准卷积的结构如图 3 所示。






图3 PConv 与 Conv 结构

假设输入和输出的通道数相同,那么 PConv 卷积的计算量(FLOPs)和内存访问量(MAC)分别为:

$$F_{\text{PConv}} = h \times w \times k^2 \times c_p^2; \quad (1)$$

$$M_{\text{PConv}} = h \times w \times 2c_p + k^2 \times c_p^2 \approx h \times w \times 2c_p. \quad (2)$$

标准卷积 Conv 的计算量和内存访问量分别为:

$$F_{\text{Conv}} = h \times w \times k^2 \times c^2; \quad (3)$$

$$M_{\text{Conv}} = h \times w \times 2c + k^2 \times c^2 \approx h \times w \times 2c. \quad (4)$$

其中, h 、 w 分别表示输入特征图的高度、宽度; k 表示卷积核的大小; c 表示通道数。由上述公式可得:

如果 $c_p/c = 1/4$ 时,那么 PConv 的 FLOPs 就仅为标准卷积的 1/16,内存访问量将是卷积的 1/4。

原始模型主干网络中的 BasicBlock 模块由 2 个卷积层和残差连接结构组成,多个标准卷积的残差连接使得网络结构变得更加复杂,计算量大。针对这一问题,使用 PConv 去替换残差结构中的标准卷积,构成新的 FasterBlock 模块,在减少计算冗余的同时提取更丰富的特征信息。FasterBlock 模块结构见图 4。




图4 FasterBlock 模块

2.3 颈部特征融合模块 Light_CCFM

在实现机械化采摘草莓时往往面临一个显著挑战,大多数果实会被错综复杂的枝干和密集的叶片所遮挡,导致系统难以全面准确捕捉到所有果实,仅有部分特征形态能够被识别到,尤其是远景图像中的小目标草莓。为解决这一问题,本研究设计出 Light_CCFM 模块。一方面,将颈部网络中的标准卷积替换为轻量级的 GSConv 卷积,减小模型的参数量和计算复杂度;另一方面,使用 VOVGSCSP 模块替换 RepC3 模块,进一步提升模型的多尺度特征融合能力和特征提取能力。

GSConv 卷积的独特之处在于集成了标准卷积、深度可分离卷积(DWConv)的参数效率和 shuffle 模块的通道混洗机制,其网络结构见图 5。这不仅保留通道间的隐藏链接,增强了模型非线性特征表达能力,还减小了模型的参数量和计算复杂度。GSConv 卷积首先将输入数据通过标准卷积层进行初步的特征提取;然后将提取出的特征传递给 DWConv 层,该层对每个通道独立进行卷积操作,极大减少计算量;最后由 shuffle 模块介入,通过重新排列通道顺序,将标准卷积与 DWConv 卷积提取的

特征进行深度混合,增强了模型对复杂场景下的特征表征能力。GSConv 的输入和输出的通道数与标准卷积相同,在图 5 中,经过标准卷积和 DWConv 得到的特征图通道数均为 $C_1/2$,其中 DWConv 使得该模块实现了接近标准卷积的性能,同时降低了计算复杂度。如图 3-b 所示,在标准卷积中卷积核的维度等于输入维度,输出等于卷积核个数。GSConv 卷积的计算量公式如(5)、(6)所示。

$$F_{\text{GSConv}} = h \times w \times k^2 \times \frac{c_1}{2} \times c + h \times w \times k^2 \times \frac{c_1}{2}; \quad (5)$$

$$\frac{F_{\text{Conv}}}{F_{\text{GSConv}}} = \frac{h \times w \times k^2 \times c^2}{h \times w \times k^2 \times \frac{c_1}{2} \times c + h \times w \times k^2 \times \frac{c_1}{2}} = \frac{2c}{c+1} \approx 2. \quad (6)$$

由公式(6)可知,将 GSConv 卷积与标准卷积的计算量进行比较,当 $c \gg 1$ 时,标准卷积的计算量是 GSConv 卷积的 2 倍。

VOVGSCSP 模块能够按照一定顺序将不同尺度的网络特征图链接起来,形成一个深度增加、信息更丰富的特征向量。这种特征融合策略不仅丰富了特征的层次结构,还增强了模型对不同尺度目标特征的敏感度与捕捉能力,能够精确识别复杂场景




图5 GSCnv 结构

下的目标特征。VOVGSCSP 结构如图 6 所示。基于 GSCnv 和 VOVGSCSP 模型设计出的 Light_CCFM

模块能够降低网络结构的复杂性和计算量,适用于计算资源受限的环境,拓宽了模型的应用范围。




图6 VOVGSCSP 模块

2.4 SSFF 与 VOVGSCSP 特征融合

在图像处理领域中,多尺度问题一直是研究的热点与难点,它要求网络能够同时捕捉并整合图像中细微到宏观的复杂信息。传统方法采用特征金字塔通过逐步降采样构建不同分辨率的特征图,使用求和或拼接等简单操作融合特征图。但在处理图像中的小目标且密集分布等复杂场景时显得力不从心,因为它未能充分利用金字塔中各层特征图之间的潜在相关性。并且采用轻量级卷积虽然会降低模型的计算复杂度,但也带来了精度下降的问题。为克服这一局限,有研究提出了一种尺度序列特征融合模块(SSFF)^[17]。SSFF 模块的设计在于更高效精确地将深度特征图的高层次语义信息与浅层特征图的丰富细节信息相结合,在保证图像整体结构特征的同时不丢失任何细节信息,以提高模型的检测性能。该模块通过特定的融合策略,增强了神经网络在提取不同尺度特征时的能力。这使得模型在处理具有复杂尺度变化的对象时,能够表现出更高的鲁棒性和准确性。SSFF 模块的原理表达式如下:

$$F_{\sigma}(w, h) = G_{\sigma}(w, h) \times f(w, h); \quad (7)$$

$$G_{\sigma}(w, h) = \frac{1}{2\pi\sigma^2} e^{-\frac{(w^2 + h^2)}{2\sigma^2}}。 \quad (8)$$

其中, $f(w, h)$ 表示宽度为 w 、高度为 h 的2D输入图像。 $F_{\sigma}(w, h)$ 通过使用一系列卷积在2D高斯滤波器 $G_{\sigma}(w, h)$ 下进行平滑生成。 σ 用于卷积的2D高斯滤波器的标准偏差参数。由于高分辨率特征图级别S3包含对小目标检测的重要信息,所以SSFF模块使用最近邻插值方法调整S4和S5的大小以适应S3级别的尺寸。为了增加每个特征层的维度,使用升维操作将特征图从3D张量转换为4D张量。然后沿着深度维度进行拼接形成3D特征图,再使用3D卷积和SiLU激活函数完成尺度序列特征提取。

将SSFF模块与VOVGSCSP模块的输出特征进行拼接,生成更丰富的多尺度信息,实现信息的互补,从而提高整体网络的性能。SSFF模块通过独特的三维卷积策略,有效融合不同尺度的特征,提高了模型在处理多尺度问题时的检测性能,尤其是在目标检测任务中,能够更精确地捕捉不同大小和形状的目标。

3 试验与结果分析

3.1 数据集与评估指标

3.1.1 数据集介绍 使用自建的草莓数据集,主要

来源于网络公开数据集和大棚实地拍摄,为了更好地还原实地采摘时的复杂场景,拍摄了傍晚、灯光、晴天、阴天 4 个场景下的草莓图片,结合公开数据集图片筛选得到 1 645 张图片,使用 Labelimg 数据标注工具对每张图片进行标记。为了增强模型的泛化能力和鲁棒性,使用数据增强技术,包括随机旋

转、裁剪、缩放、颜色调整、平移等方法,对数据集进行扩充,最终得到 3 290 张图像,并按照 8 : 1 : 1 的方式分为训练集 2 632 张、验证集 328 张、测试集 330 张,其中包含成熟、半成熟、未成熟草莓 3 种类别。部分样本图片如图 7 所示。



图7 草莓样本图片

3.1.2 评估指标 采用参数量、模型大小、帧率(帧/s)、召回率(R)、精确度(P)、平均精度均值(mAP)作为草莓成熟度目标检测的评估指标。

$$R = \frac{TP}{TP + FN} \times 100\%; \quad (9)$$

$$P = \frac{TP}{TP + FP} \times 100\%; \quad (10)$$

$$mAP = \frac{1}{M} \sum_{k=1}^M AP(k)。 \quad (11)$$

式中: TP 为正样本被正确识别为正样本的个数; FN 为正样本被错误识别为负样本的个数; FP 为负样本

被错误识别为正样本的个数; AP 为平均精度; M 为被检测样本数量。

3.2 试验环境及参数调整

本试验的操作系统是 Windows 10,使用 PyTorch 作为深度学习模型的框架,配置如表 1 所示。具体试验超参数如下:训练轮次为 200 轮,批次大小为 8,输入图像尺寸为 640×640 ,采用 AdamW 优化器,初始学习率为 0.000 1,权重衰减系数为 0.000 1。此次试验于 2024 年 6 月 20 号在江西理工大学电气学院 415 实验室完成。

表 1 试验配置

类别	配置
中央处理器	Intel® core™ i9 - 9000CPU@ 3.10 GHz 32 GB
图形处理器	NVIDIA GeForce RTX 3090 24GB
系统环境	Windows 10
框架	PyTorch 2.0.0
编程语言	Python 3.8

3.3 试验结果与分析

3.3.1 消融试验分析 为了验证改进后算法的有效性,本研究使用原始网络 RT - DETR 与改进的 SR - DETR 网络在草莓数据集上进行消融试验。具体流程就是在原有模型的基础上先单独加入改进的模块,对单个模块的性能进行验证,然后依次采用如下改进措施,如训练时加入 FasterBlock 模块,在颈部使用改进的特征融合模块 Lingt_CCFM,特征融合网络中加入 SSFF 模块。然后逐一比较每次改变后模型的性能,在采用某一改进策略就用“√”表示,具体试验效果见表 2。从表 2 可以看出,在 RT - DETR 网络采用 FasterBlock 模块进行特征提取后,召回率、平均精度均值相较于原模型分别提

升了 0.7、0.5 百分点,说明 FasterBlock 模块在对部分特征进行空间提取时保留了更多的空间信息,提供了模型对小目标的检测效果。仅采用 Light_CCFM 特征融合模块进行特征融合后,平均精度均值提高了 0.8 百分点,表明该结构充分利用不同尺度特征的细节信息,提高了多尺度融合特征图的特征质量。仅采用 SSFF 模块后,精确度、召回率、平均精度均值分别提高了 0.3、2.0、1.2 百分点,说明该模块具有更强的特征提取能力,能够充分将高层次语义信息与浅层特征图的细节相结合,提高模型检测性能。在模型的推理性能方面,添加 SSFF 模块保留了更多的特征信息,导致模型的参数量和计算复杂度较原模型略微增加,而添加 FasterBlock 模块和 Light_CCFM 模块虽然模型提升的精度幅度不大,但是都降低了模型的参数量和计算复杂度。在整合所有模块后,与原模型相比精确度、召回率和平均精度均值分别提高 1.6、1.8、1.5 百分点,提升较为明显,模型的参数量、大小和计算复杂度分别减少了 31.2%、31.1% 和 23.6%,极大地减小了模型,扩大了模型的适用范围。

表 2 消融试验结果

序号	Faster Block	Light_CCFM	SSFF	精确度 (%)	召回率 (%)	平均精度均值 (%)	参数量 (M)	模型大小 (MB)	计算量 (GFLOPs)	帧率 (帧/s)
1	—	—	—	91.4	88.4	90.2	19.9	40.5	56.9	52.6
2	√	—	—	91.7	89.1	90.7	14.0	28.7	42.8	57.2
3	—	√	—	91.3	88.6	91.0	19.3	39.0	53.2	46.0
4	—	—	√	91.7	90.4	91.4	20.2	41.0	61.4	51.2
5	√	√	—	91.9	89.4	91.1	13.4	27.3	39.1	47.6
6	√	√	√	93.0	90.2	91.7	13.7	27.9	43.5	60.9

3.3.2 对比试验分析 为了进一步验证 SR - DETR 模型在草莓检测方面的优越性,将其与主流的 YOLO 系列模型和 Faster - RCNN 模型进行对比。所有模型均在同一数据集进行训练和测试,且试验环境和参数设置保持一致。具体试验结果如表 3 所示。从表 3 可知,提出的模型的在精确度、召回率、平均精度均值等评价指标上均优于其他算法,分别达到 93.0%、90.2% 和 91.7%。这充分说明了模型在提升检测效果方面的有效性,尤其是在草莓检测任务中的表现优越。尽管在检测速度方面,SR - DETR 模型相较于广泛应用于实时检测场景的 YOLO 系列而言略有不足,但其速度依然能够满足大多数实时检测任务的需求,并且在参数量、模型

大小和计算复杂度上均明显低于其他模型,使得它在计算资源有限的场景下具有更强的适应性,拓宽了它的应用范围。同时,SR - DETR 作为一种端到端的检测模型,不需要传统目标检测算法中的后处理过程,如非极大抑制等,这不仅降低了模型在应用过程中的部署难度,还保证了检测速度的稳定性,为模型的部署和应用奠定了坚实的基础。

3.3.3 可视化分析 为了进一步验证 SR - DETR 模型的有效性,对不同模型的检测效果进行可视化处理,可视化效果图如图 8 所示。图 8 - a 列中展示了草莓处于傍晚时的情况。由于图片的场景较为昏暗并且大棚在灯光的照射下出现反光,使得 YOLO v5 模型出现漏检, YOLO v8 模型虽然检测出

表 3 对比试验结果

模型	精确度 (%)	召回率 (%)	平均精度均值 (%)	参数量 (M)	模型大小 (MB)	计算量 (GFLOPs)	帧率 (帧/s)
YOLO v5m	84.5	79.4	88.2	25.1	50.5	64.0	69.6
YOLO v6m	82.1	77.5	86.8	52.0	104.3	161.1	97.1
YOLO v7	82.7	78.6	87.1	37.2	74.8	105.1	73.8
YOLO v8m	84.3	80.5	88.6	25.9	52.0	78.7	77.4
Faster – RCNN	82.4	77.8	84.2	80.3	82.0	196.0	24.9
RT – DETR	91.4	88.4	90.2	19.9	40.5	56.9	52.6
SR – DETR	93.0	90.2	91.7	13.7	27.9	43.5	60.9




图8 检测效果对比

所有目标,但将叶片和大棚薄膜错误识别为不成熟草莓。而 SR – DETR 模型具有更强的特征表达能力和更丰富的判别信息,在这种情况下不仅将所有目标识别出来,还在原模型的基础上出现检测精度提升。图 8 – b 列中,由于草莓的分布比较密集,导致检测难度提升。YOLO v5 和 RT – DETR 模型都出现漏检的情况,RT – DETR 模型更是出现误检。

YOLO v8 和 SR – DETR 都检测出所有目标,但 SR – DETR 的检测精度更高并更正了原模型的错误识别。图 8 – c 列中,由于枝干和叶片的遮挡面积较多,容易与未成熟的草莓产生混淆,增加模型的检测难度。YOLO v5、YOLO v8 和 RT – DETR 模型都将草莓花蕾误检为未成熟草莓,但是 SR – DETR 依靠强大的特征提取能力,正确的识别出未成熟草莓

的位置。在图 8-d 列中,由于草莓果实被叶片严重遮挡,导致特征信息不明显,使得 YOLO v5 和 RT-DETR 模型未能识别出被遮挡的部分,YOLO v8 模型虽然能够识别遮挡部分,但却在图片左侧出现误检,只有 SR-DETR 模型正确识别出所有目标。因此,SR-DETR 在光照不良、目标分布密集、环境特征与目标特征相似以及目标被严重遮挡等情况下,凭借其强大的特征提取能力和细节信息判别能力,能够准确检测出目标的同时不出现误检情况。

4 结论

本研究针对机械化采摘草莓时机器难以判断草莓的不同成熟度,导致容易出现误检、漏检等问题,在 RT-DETR 模型的基础上,用 FasterBlock 模块替换主干网络中的 BasicBlock 模块以减小模型的参数量及模型大小;替换颈部网络中的标准卷积,采用轻量级卷积 GSConv,并用 VOVGSCSP 模块替换 RepC3 模块,完成对特征融合模块 CCFM 模块的重新设计,在减少模型参数量和计算复杂度的同时,提升模型的特征融合能力;在颈部网络中添加 SSFF 模块,提高模型对不同尺度特征图的提取能力,增加模型的鲁棒性和准确性,最终研制出计算复杂度低且检测精度较高的 SR-DETR 草莓成熟度目标检测模型。

试验表明,在相同试验条件下,改进的 SR-DETR 通过与 Faster-RCNN 和 YOLO 系列模型等进行对比,改进的模型在草莓成熟度数据集上取得较优的效果,相比原模型,精确度、召回率和平均精度值分别提高了 1.6、1.8、1.5 百分点,并且模型的参数量、模型大小和计算复杂度分别下降了 31.2%、31.1% 和 23.6%。改进后模型的精确度等均优于对比算法,同时模型参数量和模型大小均为最低,为大棚中草莓成熟度快速检测提供了方法支持。

SR-DETR 模型尚未对颈部编码网络进行优化改进,未来可以基于任务需求来优化颈部编码网络,以提高检测精度和速度。并且在数据集方面,数据集里的草莓图片大都是处于阳光或照明条件下,后续会收集夜间昏暗环境下的草莓图片来丰富数据集,提高模型的泛化性能。

参考文献:

[1] 李红丹,帅璐宇,徐雪环,等. 基于改进 YOLO v7 的草莓成熟度检测方法[J]. 四川农业大学学报,2024,42(3):561-571.

[2] 邱 畅,田光兆,赵嘉威,等. 基于改进 YOLO v5 的草莓病害识别[J]. 中国农机化学报,2024,45(3):198-204.

[3] 刘莫尘,褚镇源,崔明诗,等. 基于改进 YOLO v8-Pose 的红熟期草莓识别和果柄关键点检测[J/OL]. 农业机械学报,2023;1-12(2023-09-12)[2024-07-10]. <http://kns.cnki.net/kcms/detail/11.1964.S.20230911.2024.046.html>.

[4] 张晖耀,黄力湘,陈继清,等. 基于改进 YOLO v5s 的草莓成熟度检测算法[J/OL]. 南京农业大学学报,2024;1-12(2024-06-13)[2024-07-10]. <https://link.cnki.net/urlid/32.1148.S.20240612.1734.006>.

[5] Liu H, Wang X X, Zhao F Y, et al. Upgrading swin-B transformer-based model for accurately identifying ripe strawberries by coupling task-aligned one-stage object detection mechanism[J]. Computers and Electronics in Agriculture, 2024, 218: 108674.

[6] 周 涛,王 骥,麦仁贵. 基于改进 YOLO v8 的实时菠萝成熟度目标检测方法[J]. 华中农业大学学报,2024,43(5):10-20.

[7] 陈仁凡,谢 知,林 晨. 基于 YOLO-ODM 的温室草莓成熟度的快速检测[J]. 华中农业大学学报,2023,42(4):262-269.

[8] 张小花,李浩林,李善军,等. 基于 EfficientDet-D1 的草莓快速检测及分类[J]. 华中农业大学学报,2022,41(6):262-269.

[9] 熊俊涛,韩咏林,王 潇,等. 基于 YOLO v5-Lite 的自然环境木瓜成熟度检测方法[J]. 农业机械学报,2023,54(6):243-252.

[10] Raj R, Cosgun A, Kulić D N. Strawberry water content estimation and ripeness classification using hyperspectral sensing[J]. Agronomy, 2022, 12(2):425.

[11] 胡仕林,陈 伟,张境锋,等. 基于改进 YOLO v5 的苹果采摘机器人目标检测方法[J]. 农机化研究,2024,46(6):48-55.

[12] 赵德安,吴任迪,刘晓洋,等. 基于 YOLO 深度卷积神经网络的复杂背景下机器人采摘苹果定位[J]. 农业工程学报,2019,35(3):164-173.

[13] 黄 威,刘义亭,李佩娟,等. 基于改进 YOLOX-S 的苹果成熟度检测方法[J]. 中国农机化学报,2024,45(3):226-232.

[14] 许小伟,陈燕玲,占 柳,等. 基于改进 RT-DETR 的路面坑槽检测模型[J/OL]. 武汉科技大学学报,2024;1-10(2024-04-26)[2024-06-20]. <https://link.cnki.net/urlid/42.1608.N.20240426.1710.002>.

[15] Zhao Y, Lv W, Xu S, et al. Detrs beat yolos on real-time object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, WA, USA: IEEE, 2024:16965-16974.

[16] Li H L, Li J, Wei H B, et al. Slim-neck by GSConv: a better design paradigm of detector architectures for autonomous vehicles[J]. Journal of Real-Time Image Processing, 2024, 21:62.

[17] Kang M, Ting C M, Ting F F, et al. ASF-YOLO: a novel YOLO model with attentional scale sequence fusion for cell instance segmentation[J]. Image and Vision Computing, 2024, 147: 105057.

[18] Chen J R, Kao S H, He H, et al. Run, don't walk: chasing higher FLOPS for faster neural networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, BC, Canada: IEEE, 2023:12021-12031.