



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目：基于改进 RT-DETR 的锻件表面缺陷检测算法
作者：张国文，张上，张岳，李琼，张军
网络首发日期：2025-07-07
引用格式：张国文，张上，张岳，李琼，张军. 基于改进 RT-DETR 的锻件表面缺陷检测算法[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20250707.1238.017>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于改进 RT-DETR 的锻件表面缺陷检测算法

张国文¹, 张上¹⁺, 张岳¹, 李琼², 张军²

1. 三峡大学 湖北省建筑质量检测装备工程技术研究中心, 湖北 宜昌 443002

2. 三峡大学 计算机与信息学院, 湖北 宜昌 443002

+ 通信作者 E-mail: 512784685@qq.com

摘要：锻件表面缺陷危害大，检测效率低，针对目前锻件表面缺陷检测存在的问题，提出了一种基于改进 RT-DETR 的算法。首先，在湖北三环锻造有限公司车辆转向节生产车间采集磁粉检测图像作为数据集；然后，提出轻量级跨阶段热传导模块，将模拟热扩散过程引入频域建模机制，实现全局感知并抑制高频噪声；同时，引入上下文感知特征金字塔模块，通过动态通道对齐和空间注意力引导实现多尺度特征融合，增强语义一致性和目标的上下文融合；最后，引用一种动态位置偏置模块增强对跨尺度特征的提取能力。在锻件表面裂纹数据集的实验结果表明，模型精度达到 87.9%，参数量和计算量分别减少 20.7% 和 9.3%，优于其他主流算法。在 NEU-DET 数据集上，改进后的 RTDETR 模型在 mAP 上相较基准模型提升 1.2%，证明算法具有泛化性。综上，该算法精度提高，模型复杂度降低，适用于实际生产环境部署与应用。

关键词：RT-DETR; 缺陷检测; 特征提取; 锻件; 动态位置偏置模块

文献标志码:A 中图分类号:TP391.4 doi: 10.3778/j.issn.1002-8331.2503-0277

Surface Defect Detection Algorithm for Forgings Based on RT-DETR

ZHANG Guowen¹, ZHANG Shang¹⁺, ZHANG Yue¹, LI Qiong², ZHANG Jun²

1. Hubei Province Engineering Technology Research Center for Construction Quality Testing Equipment, China Three Gorges University, Yichang 443002, Hubei, China

2. College of Computer and Information, China Three Gorges University, Yichang, Hubei 443002, China

Abstract: The forging surface defects are harmful with low detection efficiency. To address the existing problems of forging surface defects detection, we proposed an algorithm based on improved RT-DETR. First, we collected magnetic particle inspection images as datasets in the vehicle steering knuckle manufacturing workshop of Hubei Sanhuan Forging Co. Then, A lightweight cross-stage heat conduction module is proposed, which introduces a simulated heat diffusion process into the frequency-domain modeling mechanism to achieve global perception and suppress high-frequency noise; meanwhile, we introduced Context Guide Feature Pyramid Network to realize multi-scale feature fusion through dynamic channel alignment and spatial attention guidance, thereby enhancing semantic consistency and contextual integration of targets; finally, we used Dynamic Position Bias DPB module to enhance the extracting ability of cross-scale features. The experimental results on the forging surface crack dataset show that the mAP value reaches 87.9%, and the parameters and FLOPs are reduced by 20.7% and 9.3%, which is better than other mainstream algorithms. On the NEU-DET dataset, the improved RTDETR model improves 1.2% in mAP compared to the benchmark model, which proves that the algorithm is generalizable. In conclusion, the algorithm has improved accuracy and reduced model complexity, it is suitable for deployment and application in real manufacturing situations.

Key words: RT-DETR; defect detection; feature extraction; forgings; Dynamic Positional Bias module

基金项目：湖北省数字经济试点示范建设专项 (项目编号: 2312-420625-04-02-996363); 湖北省国家级大学生创新创业训练计划 (项目编号: S202311075047); 国家级大学生创新创业训练计划 (项目编号: 202111075012, 202011075013)。

作者简介：张国文 (2001-), 男, 硕士研究生, 三峡大学计算机与信息学院, 主要从事计算机视觉和深度学习的研究, E-mail: 512784685@qq.com; 张上 (1979-), 男, 副教授, 博士, 三峡大学计算机与信息学院, 主要从事计算机视觉、物联网工程等方面的研究, E-mail: zhangshang@ctgu.edu.cn; 张岳 (1998-), 男, 硕士研究生, 三峡大学计算机与信息学院, 主要从事计算机视觉和智能制造的研究, E-mail: zhangyue980202@ctgu.edu.cn; 李琼 (1975-), 女, 副教授, 博士, 三峡大学数理学院, 主要从事最优化理论和算法的研究, E-mail: liqiongmanj@163.com; 张军 (1989-), 男, 网络工程师 (中级), 湖北三环锻造有限公司, 主要从事工业互联网和智能制造的研究, E-mail: 429339008@qq.com。

在钢材生产过程中, 锻件广泛应用于船舶部件、汽车零件制造以及铁路轨道连接部件的生产。例如, 在汽车转向桥的制造过程中, 锻件需经历高温重铸和挤压成型等工艺, 因此对其质量要求极为严格^[1]。然而, 在锻造过程中, 锻件表面常因工艺因素产生裂纹、孔隙、氧化层等缺陷, 这些缺陷若未能及时检测并控制, 可能会影响最终产品的结构完整性与服役安全。为保障产品质量, 采用无损检测(NDT, Non-Destructive Testing)技术对锻件进行质量评估至关重要。其中, 磁粉检测(Magnetic Particle Testing, MPT)作为一种常见的无损检测方法, 主要用于检测锻件表面的裂纹缺陷。

传统的无损检测主要依赖于人工视觉检测和经验判断, 但此方法存在较大的主观性, 易受人为因素影响, 导致误判率较高。此外, 由于检测过程往往需要专业人员长时间进行高强度操作, 特别是对于大尺寸和高重量的工件, 检测过程的体能消耗较大, 进一步降低了检测效率。这些因素可能导致产品质量控制的不稳定性, 甚至引发潜在的安全隐患^[2]。因此, 提高锻件缺陷检测的准确性与自动化程度对于提升生产效率和产品质量至关重要。

近年来, 随着计算机视觉技术与深度学习方法的发展, 机器视觉逐渐取代传统人工检测, 成为工业检测的重要手段^[3]。相较于传统的物理检测方法, 机器视觉检测通常在精度和一致性方面表现更优。例如 HOG+SVM 模型和 DPM 模型。然而, 因其分布处理并且其检测性能容易受到光照变化、表面反射、成像噪声等因素的影响, 导致检测鲁棒性下降。此外, 传统基于规则的机器视觉方法在面对复杂工业环境时, 泛化能力有限, 难以应对不同类型的缺陷检测任务。

为克服上述问题, 基于深度学习的目标检测方法在工业缺陷检测领域得到了广泛应用。当前, 深度学习目标检测方法主要分为两类: 两阶段检测器(Two-Stage Detectors)和单阶段检测器(One-Stage Detectors)^[4]。两阶段检测器, 如 R-CNN 系列, 首先生成候选区域(Region Proposals), 然后对候选区域进行特征提取和分类, 该方法在目标定位和识别精度上具有较高的优势, 但检测速度较慢。相比之下, 单阶段检测器, 如 YOLO 和 SSD 直接回归目标框并进行分类, 避免了候选区域生成步骤, 使其在检测速度上显著优于两阶段方法。近年来尤其是以 YOLO 系列为代表的单阶段检测网络, 因其速度快、部署灵活等优势, 被广泛用于冶金、机械等场景。徐彦威等^[5]人介绍从

YOLOv1 到 YOLOv9 算法通过骨干网络重构、注意力机制融合等改进, 逐步提升了检测精度和速度的平衡性。

在目标检测领域, 基于 Transformer 的检测框架逐渐受到关注。Carion 等^[6]人提出了 DETECTION TRANSFORMER(DETR), 该模型结合 CNN 与 Transformer 结构, 采用端到端的方式进行目标检测, 实现了目标位置的直接回归, 避免了传统方法中的候选框生成与非极大值抑制(NMS, Non-Maximum Suppression)操作。然而, DETR 仍然存在推理速度较慢、训练收敛缓慢, 以及在小目标检测任务中表现不佳的问题。为改进 DETR 的缺陷, Zhu 等^[7]人提出了 Deformable DETR, 该方法引入了一种可变形注意力机制(Deformable Attention), 通过局部稀疏采样和动态偏移预测, 有效提升了检测速度与收敛速度, 并改善了对小目标的检测性能。

在实际工业应用中, 为了能够在计算资源受限的嵌入式设备或边缘计算平台上高效部署并进行实时推理, 轻量级实时目标检测模型成为研究热点。Lv 等^[8]人提出了 RT-DETR(Real-Time DETR), 该模型通过优化特征提取与解码策略, 在 COCO 数据集上的检测速度和精度均超过了同等规模的 YOLO 系列检测器, 首次在实时目标检测任务中取得了领先表现。RT-DETR 的出现进一步推动了 Transformer 在实时目标检测任务中的应用, 为工业缺陷检测提供了新的技术支持。然而在锻件表面缺陷检测中, 由于终端计算能力有限, 导致实际部署仍面临巨大挑战。

为了解决上述挑战, 一些研究者提出了锻件表面的缺陷检测模型, 例如张伟健等^[9]人在 RTDETR 算法中引入 RepNCSPELAN4 模块和 SlideVarifocalLoss 损失函数, 提升了模型的精度和降低模型参数。张岳等^[10]人在 YOLOv8s 算法中引入轻量级卷积 LMSConv 和 LSKA-SPPF 金字塔模块, 实现跨尺度特征融合, 提升了精度。刘宏志等^[11]人在 YOLOv11n 算法中融合 C3K2-SG 模块和 FPSConv 模块, 提升特征抓取能力和保证模型的轻量化。王蕾等^[12]人在 YOLOv7 算法中引入渐进特征金字塔(AFPN)、高效注意力机制(EMA)和损失函数 SIOU, 提升多尺度融合能力, 显著提升蜗杆表面小目标缺陷的检测精度。赵佰亭等^[13]人在 YOLOv5s 中构建特征增强模块 RLKM、提出注意力机制 DCAM 和引入轻量化卷积 GSConv, 减少模型参数量并提升了罐道缺陷的检测精度。Weidong Zhao 等^[14]

人在 Faster R-CNN 算法中重构网络结构,采用多尺度融合训练网络提高小目标的抓取能力,对于复杂背景用可变的卷积网络代替部分卷积,有效的识别锻件表面的细小缺陷。Yu He 等^[15]人在 DDN 算法中提出多级特征融合网络 MFN 和采用区域建议网络 RPN 生成 ROI,并基于此生成最终检测结果,提高了检测精度和检测速度。胡丹等^[16]人通过采用激光视觉成像和方向梯度直方图(HOG)提取特征,建立支持向量机(SVM)智能识别与分类焊缝表面缺陷的模型,在同等条件下显著优于其他分类模型的性能。当前主流检测器需要使用 NMS 去除重复的预测框,导致推理速度受到影响。

鉴于上述研究的局限性,本文提出了一种高精度、轻量化的表面缺陷检测算法,该模型以 RTDETR 为基准,首先引入轻量级跨阶段热传导模块(Cross Thermal Spectral Operator, CTSO)结合主干部分,提升了特征提取能力。同时将上下文感知特征金字塔模块(Context Guide Feature Pyramid Network, CGFPN)改进头部部分,旨在提升对不同层级的特征抓取能力。此外改进了基于注意力的同尺度特征交互(AIFI)融入了一种动态位置偏置模块(Dynamic Position Bias, DPB),从而增强了检测能力,提高精度。最后进一步在 NEU-DET 数据集上验证算法的泛化性。改进的算法在锻件的表面缺陷中实现了较少的参数和精度的平衡,满足了工业

的需求。

1 RTDETR 网络模型

RTDETR 模型由三个主要部分组成:主干网络、高效混合的编码器和带有辅助预测头的变压器解码器。主干网络从输入的图像中提取特征,通过一系列卷积层处理图像,生成不同尺度的特征图。高效的混合编码器是 RTDETR 模型的核心组件。它包含两个模块:基于注意力的同尺度特征交互(AIFI)和基于卷积神经网络的跨尺度特征融合(CCFM)。AIFI 增强捕捉局部特征,提高鲁棒性,避免低层特征进行冗余计算,提高计算效率。CCFM 融合来自不同尺度的特征生成一个新的特征以增强在不同场景下的检测能力。Transformer 解码器通过自注意力机制增强了全局特征交互,提升计算效率显著提高了在复杂情景下表面检测的表现。因此在很多领域 RTDETR 都有良好的应用,但仍存在可优化之处:1)提高检测精度。2)缩小模型参数量。RTDETR 模型提供了多个型号,如 R18, R34, R50, R50m, R101, L 和 X。本文选择的基准模型是 RTDETR-r18,基于上述优化之处进行改进,模型的结构如图 1 所示。




图1 RTDETR-r18 网络结构图

Fig.1 Network Architecture of RTDETR-r18

2 改进的 RTDETR

基准网络模型 RTDETR 尽管因其在实时目标检测过程中不依赖后处理(NMS)的端到端检测器,减少

了推理延迟,并提高了检测速度,但在复杂背景下检测精度不足,对于小目标检测困难以及计算量太大。基于此本文提出一种基于 RTDETR 模型的名 GDC-DETR 的新型算法以解决上述问题。如图 2 所示。




图 2 改进的 RTDETR-r18 网络结构图

Fig.2 Improved Network Architecture of RTDETR-r18

2.1 轻量级跨阶段热传导模块

针对 RTDETR-r18 模型提取全局特征能力差,本文设计模型的主干网络从 vHeat 框架中的热传导算子(HCO)得到启发^[19],该框架通过热传导从局部源向全局扩散从而实现高效的全局特征交互。

本文设计引入了 HCO 模块,它使用二维离散余弦变换(DCT)和反离散余弦变换(IDCT)的并行性注意力机制,显著提升了训练和推理的效率,同时有效扩展了全局感知领域。相比传统的自注意力机制其复杂度为 $O(N^2)$,HCO 的模块复杂度为 $O(N^{1.5})$,在计算效率上具有明显优势。在 HCO 层中,深度可分离卷积(DWConv)、线性变换、层归一化(LN)和 Swish 激活函数与 HCO 相结合形成了多分支结构。Swish 激活函数结合了线性和 Sigmoid 的平滑性,能够有效缓解梯度消失问题。与传统的 ReLU 函数相比,Swish 在负输入时仍能保持梯度的稳定,促进训练的收敛。通过这种设计,HCO 模块不仅可以保留局部特征提取,而且能

够增强全局信息传播。以下是 HCO 的推导公示:

设 $u(x,y,t)$ 表示在二维区域 $D \in R^2$ 内时刻 t 点 (x,y) 的温度,经典的物理热方程表示为:

$$\frac{\partial u}{\partial t} = k \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right)$$

其中 $k > 0$ 为测量材料传热速率的热扩散率。方程两边应用傅里叶变化得:

$$\mathcal{F} \left(\frac{\partial u}{\partial t} \right) = k \mathcal{F} \left(\frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} \right)$$

左边利用时间导数,右边利用空间二阶导数得到频域 ODE,最终解得:

$$\tilde{u}(\omega_x, \omega_y, t) = \tilde{f}(\omega_x, \omega_y) e^{-k(\omega_x^2 + \omega_y^2)t}$$

最后进行反傅里叶变换($\mathcal{F}^{-1}$),得到热方程在空间的通解:

$$u(x, y, t) = \mathcal{F}^{-1}(\tilde{f}(\omega_x, \omega_y) e^{-k(\omega_x^2 + \omega_y^2)t}) \\ = \frac{1}{4\pi^2} \int_D \tilde{f}(\omega_x, \omega_y) e^{-k(\omega_x^2 + \omega_y^2)t} e^{i(\omega_x x + \omega_y y)} d\omega_x d\omega_y.$$

为了应用于图像块特征将连续解离散化, HCO 模块引入 DCT 和 IDCT, 图像满足诺伊曼边界条件, 傅里叶变换替换为离散余弦变换, 最终 HCO 的离散实现表现为:

$$U^t = IDCT_{2D}(DCT_{2D}(U^0)e^{-k(\omega_x^2 + \omega_y^2)t})$$

该表达方式不仅具备良好的可微性和结构可嵌入性, 同时保证了频域建模的物理可解释性, 有效模拟了各向异性扩散特性。

为解决卷积神经网络在处理高分辨率图像和复杂场景时面临的感受野受限、全局建模能力不足以及计算效率较低等问题, 本文提出轻量级跨阶段热传导模块(CTSO), 通过整合 vHeat 模型中的热传导算子(HCO)与跨阶段频域融合模块(C2f), 以实现全局-局部协同感知机制。如图 3 所示, CTSO 模块保留了 C2f 的多分支, 并用热传导网络(Heatneck)取代了原来的主干网络结构。这种融合不仅保留了 HCO 的全局感知能力更好的抑制高频噪声, 更好的理解复杂场景, 而且保留了 C2f 增强关键细节, 提升计算效率。在 CTSO 模块中, HCO 层作为热传导核心, 替代原有主干网络的部分卷积层, 既保留了局部特征提取能力, 又增强了全局信息的传播。因此, CTSO 模块通过基于傅里叶域的特征扩散建模用于模拟图像特征各向异性传导和多尺度特征融合。该过程通过 DCT 将空间特征转换为频域表示, 有效压缩特征并捕捉长程依赖。热扩散的解析解形式在频率维度上对高频成分实施指数衰减操作, 使得全局语义特征在保持空间一致性的同时能够显式传播。这种各向异性的频率调制机制相比传统卷积操作具有更大的感受野, 克服了局部卷积在建模全局上下文关系方面的局限。并利用 IDCT 将全局频域信息高效还原至空间域, 使得模型在恢复高语义特征同时保持空间一致性, 提升了复杂背景下目标形态建模的稳定性, 从而实现全局上下文信息的建模。为进一步明确热传导方程的频域建模在神经网络中的实现机制, 本文在 HCO 模块中通过子模块实现了基于 DCT/IDCT 的热扩散建模机制。该模块通过频域建模

以实现全局依赖传播与方向敏感感知, 为复杂背景下的细粒度目标检测提供语义支撑。具体而言, 输入特征图首先经过深度可分离卷积提取局部信息, 再借助有位置编码构建的二维余弦基函数进行张量投影, 实现无参数的 DCT 操作。该余弦核由固定正交矩阵构成, 通过点乘方式对特征图进行频域编码。随后, 为模拟热传导方程在频域中的解析解形式, 构建频率衰减核函数:

$$H_{n,m} = \exp\left(-\left[\left(\frac{n\pi}{H}\right)^2 + \left(\frac{m\pi}{W}\right)^2\right] \cdot kt\right)$$

其中 k 和 t 为可学习参数。用于调控扩散强度和尺度。该函数通过张量乘法作用于频域特征, 使不同频率方向的响应呈现异向调制, 物理意义上对应热扩散中的各向异性传导行为。该机制提升了模型对不同空间频率方向变化的建模能力, 增强了方向敏感性与物理可解释性。最后, 通过乘以余弦核的转置形式完成 IDCT, 将频域特征还原为空间特征图。该过程无需显式变换函数, 完全在网络中以卷积形式高效实现, 具有良好的可微性与可扩展性。上述热扩散机制与主干网络深度堆叠, 构成 CTSO 的关键组成部分, 有效提升了模型在全局上下文建模与细粒度特征保持方面的能力。在结构实现方面, HCO 模块与 C2f 模块融合构建 CTSO 模块。CTSO 以多分支形式引入热扩散建模路径, 通过可分离卷积、频率调控核与张量重建等子结构, 显著扩展了感受野并提升了模型的全局建模能力。相比传统 CNN 主干仅依赖局部感受野进行特征提取, CTSO 更具跨尺度、多方向信息整合能力, 适用于复杂背景下的裂纹检测任务。

综上所述, CTSO 模块通过频域热扩散机制实现了低复杂度、强感受、高适应性的特征建模。该机制不仅提升了模型对复杂背景中细粒度结构的检测能力, 还显著增强了 GDC-DETR 全文算法的全局建模能力与检测鲁棒性。




图3 CTSO 的结构、HCOneck 和 HCOblock

Fig.3 Structure of CTSO, HCOneck, and HCOblock

2.2 上下文感知特征金字塔网络

RTDETR-r18 模型通常采用特征拼接(Concat)方法进行多尺度特征融合,该方法能够有效地结合不同尺度的信息,但由于特征冗余,低层特征往往受到高层特征的不必要干扰,从而导致信息丢失和计算浪费。




图4 CGFPN 模块结构图

Fig.4 Structure of the CGFPN Module

该模块通过动态通道对齐、自注意力引导和交叉特征增强三个核心机制实现跨层级特征的上下文感知融合,从而提升对多尺度目标的表达能力和检测精度。具体而言,该模块的工作原理如下:在深度网络的特征提取过程中,不同层级的特征图通常具有不同的通道数。如果直接进行特征拼接或加权融合,可能会导致信息不匹配或影响特征传递的有效性。因此为实现不同层级特征图的有效融合,CGFPN 模块引入了动态通道对齐机制和上下文引导融合结构。设底层特征 $X_0 \in R^{C_0 \times H \times W}$ 和高层特征 $X_1 \in R^{C_1 \times H \times W}$, 为避免通道维度不一致造成融合偏差,首先通过 1×1 卷积将低层特征的通道数调整为与高层特征一致,即采用通道变换:




图5 SE 注意力模块结构图

Fig.5 Structure of the SE Attention Module

计算跨通道的注意力权重:

$$X_{attn} = f_{SE}(X_{concat}) \in R^{2C_1 \times H \times W}$$

其中 f_{SE} 由全局池化、全连接层、ReLU 和 Sigmoid 激活函数组成,能够捕捉通道维度上的重要性信息。随后,我们将其拆分为两个部分,分别对应于 X_0' 和 X_1 的注意力权重:

$$W_0, W_1 = \text{Split}(X_{attn}, [C_1, C_1], \text{dim} = 1)$$

最终,通过逐元素乘法(Hadamard 乘积),将注意

针对以上 Concat 方法不能充分利用各个尺度特征之间的上下文关系,从而影响对小目标和复杂背景的检测能力,本文提出一种新的网络上下文感知特征金字塔网络(CGFPN),该网络使用 CGFPN 模块替换 Concat 模块。CGFPN 是一种用于多尺度特征融合模块,如图4所示。

$$X_0' = f_{conv1 \times 1}(X_0) \in R^{C_1 \times H \times W}$$

其中 $f_{conv1 \times 1}$ 表示 1×1 卷积操作,用于调整通道数,

使得 X_0' 和 X_1 具有相同的维度。该对齐策略以高层语义特征为通道基准,保留其抽象表达优势,同时为了避免高维信息在融合过程中丢失,调整后的特征与高层特征在通道上兼容后,进行拼接。随后为了在融合过程中分配不同的特征权重,本文引入了通道注意力机制(SEAttention)。首先,将对齐后的低层特征 X_0' 和高层特征 X_1 进行拼接,形成一个增强的特征表示:

$$X_{concat} = \text{Concat}(X_0', X_1) \in R^{2C_1 \times H \times W}$$

然后,该拼接后的特征经过 SE 注意力模块,SE 注意力模块的结构图如图5所示。

力权重应用到特征图上:

$$X_0^{\text{weighted}} = X_0' \odot W_0, X_1^{\text{weighted}} = X_1 \odot W_1$$

为了进一步提升跨层级信息的交互,本文采用双向信息流融合,即在融合过程中,每个特征不仅仅增强自身信息,同时也吸收另一特征的增强信息:

$$X_0^{\text{fused}} = X_0' + X_1^{\text{weighted}}$$

$$X_1^{\text{fused}} = X_1 + X_0^{\text{weighted}}$$

这样,低层特征可以从高层特征中获得更丰富的

语义信息,而高层特征也能保留来自低层的细节信息,使得不同层级的特征能够互相补充,从而增强检测网络的多尺度建模能力。最终,将两个增强后的特征拼接:

$$X_{output} = \text{Concat}(X_0^{fused}, X_1^{fused}) \in R^{2C_1 \times H \times W}$$

该过程确保了跨层级的深度信息交互,并通过自适应调整不同特征的权重,使得模型在目标检测任务中能够更好地融合局部细节与全局上下文信息。在多尺度融合方面,CGFPN 模块通过动态通道对齐机制,实现不同层级特征图在通道维度上的语义统一。该机制根据各层特征的内容自适应调整通道间映射关系,使浅层的纹理信息与深层的语义信息在融合前具备对比一致性,有效避免传统特征金字塔网络(FPN)中因直接拼接而引发的语义错配问题。与标准 FPN 结构采用统一卷积处理融合特征的方式不同,CGFPN 融合过程中引入了注意力引导机制,对通道重要性与空间响应进行显式建模,进一步抑制了背景干扰与无效特征的传递。该设计不仅增强了模型对目标边界及结构细节的感知能力,同时提升了跨层级特征融合的鲁棒性与判别能力。同时,引入的上下文注意机制可对关键区域进行显著性增强,在融合过程中抑制无关背景干扰,提升细节结构在多尺度信息中的表达权重。多分支残差连接路径进一步稳定了语义交互过程中的特征退化问题,提升了融合过程的鲁棒性。

相较于传统 Concat 融合方式,CGFPN 在结构设计和语义统一方面具有显著优势。Concat 通常将不同层级的特征直接在通道维度上拼接后统一卷积处理。然而各尺度特征的表达差异与分布不一致容易导致语义信息稀释或边界特征被覆盖,尤其在检测小目标或边界模糊缺陷时存在不稳定。为解决上述问题,CGFPN 采用 1×1 卷积实现通道维度对齐,确保融合前特征表达的一致性。同时,引入注意力加权机制对关键语义区域进行显式增强,并通过残差式多路径连接结构提升语义流的传递效率与稳定性。

2.3 动态位置偏置模块

传统注意力机制(Transformer)中的相对位置偏置(RPB)使用固定大小的矩阵存储不同相对位置对应的偏置值。面对多尺度输入时,RPB 无法适应超出预设范围的偏移,因此需要重新调整矩阵,导致性能下降。针对以上问题本文根据 CrossFormer 视觉架构^[21]中提

出的一种动态位置偏置模块(DPB),本文将 DPB 引入 Transformer Encoder。DPB 是一个基于多层感知机(MLP)的模块,如图 6 所示。




图 6 DPB 模块结构图

Fig.6 Structure of the DPB Module

DPB 旨在通过动态的生成位置偏置来解决 RPB 的局限性。在形式上,RPB 在 LSDA 的注意图变为:

$$Attention = \text{Softmax}(QK^T / \sqrt{d} + B)V$$

其中 $Q, K, V \in R^{G^2 \times D}$ 分别表示自注意模块中的查询、关键字、值。 $B \in R^{G^2 \times G^2}$ 是 RPB 的矩阵。其中 $B_{ij} = \hat{B}_{\Delta x_{ij}, \Delta y_{ij}}$, $\hat{B}$ 为固定大小矩阵, $(\Delta x_{ij}, \Delta y_{ij})$ 为坐标距离。因此当 $(\Delta x_{ij}, \Delta y_{ij})$ 超过 $\hat{B}$ 大小时,图像大小就会受到限制。然而 DPB 可生成动态的相对位置偏差,即

$$B_{ij} = DPB(\Delta x_{ij}, \Delta y_{ij}).$$

DPB 的核心由级联的前馈网络构成,采用标准化层与 ReLU 激活函数的结构设计。其输入端接收二维空间坐标差异向量 $(\Delta x_{ij}, \Delta y_{ij})$,经过特征映射后,最终输出标量 B_{ij} 表征两位置间的空间关联特性。DPB 在 Transformer 结构的整体优化过程中共同学习,并且具备对任何输入尺寸图像的适应能力,无需对 $(\Delta x_{ij}, \Delta y_{ij})$ 的取值范围进行约束。相较于 RPB,DPB 通过 MLP 生成可学习的偏置参数,具备更强的空间感知与变形目标适应能力,显著提升了细长目标与非结构化缺陷的定位精度。此外在图像或特征组大小保持不变时,DPB 与 RPB 具有等效性。

综上,本文将 DPB 模块代替基准 RTDETR 的 AIFI 模块,通过多层感知机架构生成动态位置偏置,为多尺度输入提供更强灵活性,从而降低计算复杂度和提升检测精度。

3 实验及结果分析

3.1 实验环境

本文使用为主干网络的 RTDETR-r18 训练。按照表 1 的训练参数进行设置。实验平台为 Windows 11 系统, GPU 为 NVIDIA GeForce GTX 1080, 详细配置如表 2 所示。

表 1 实验相关参数

Table 1 Parameters related to the experiment

参数名称	参数值
Epochs	200
Batch	4
Optimizer	AdamW
lr0	0.0001
Weight_decay	0.0001

表 2 实验设备

Table 2 Experimental equipment

名称	配置
CPU	Intel(R) Core(TM) i3-12100F

内存	32G
GPU	NVIDIA GeForce GTX 1080
CUDA	11.8
PyTorch	2.1.0

3.2 实验数据集

本文数据集来源于湖北三环锻造有限公司东风重型卡车转向节生产流水线, 主要针对探伤车间的磁粉探测环节。为保证数据的多样性, 拍摄时采集不同角度、距离及光照条件, 以尽可能贴合实际检测场景。原始数据集共 362 张图象, 难以满足深度学习模型的训练需求。为提升泛化能力, 采用图像增强库进行数据扩充, 增强方式包括旋转、翻转和亮度调整。本文将图像上下与左右翻转的概率均设为 50%, 旋转角度在 -20° 至 20° 之间, 以模拟多角度检测场景。亮度调整范围设定为原始亮度的 0.8 倍至 1.2 倍, 提高模型对不同光照环境的适应能力。经过数据增强后, 训练集扩展至 3206 张图象, 包含 11700 个缺陷目标, 所有目标均为“defect”类别。数据集中部分图片如图 7 所示。




图 7 数据集内部分图片

Fig.7 Some images from the dataset

3.3 评价指标

本实验采用平均精度均值 (mAP)、准确率 (Precision, P)、召回率 (Recall, R)、计算量 (浮点操作, FLOPs)、参数量 (params) 与每秒检测帧数 (FPS) 等。对于部分计算公式如下:

$$AP = \int_0^1 PdR$$

$$mAP = \frac{\sum_{i=1}^N AP_i}{N}$$

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$FPS = \frac{1000}{t}$$

其中, mAP 是指模型在测试集上检测所有目标的准确率平均值, 该指标越高代表模型对不同目标检测效果越好。Precision 值是模型检测正确值占总数的比例。params 用来衡量模型的复杂度, 参数量越小模型越轻便, 对硬件性能要求越低。FPS 为模型 1s 内推理的图片数量, 该值是衡量模型实时性的重要指标。

3.4 消融实验

在工业检测场景中, 锻件表面缺陷常表现为结构细长、边缘模糊的裂纹形态, 并伴随纹理干扰、光照反射等复杂背景噪声因素, 显著提升了目标检测任务的难度。为应对上述挑战, 本文构建的 GDC-DETR 模型基于模块化设计思路, 引入多种结构性改进模块,

以提升模型在复杂环境下的鲁棒性与精度表现。其中,CTSO 模块采用基于热传导方程的频域建模机制,强化图像中的低频主导结构,在特征传播过程中有效抑制高频干扰,提升模型在复杂背景下的判别能力。该机制具备明确的物理可解释性,能够在无需显式注意力机制的前提下建模长距离依赖关系,增强模型的全局上下文建模能力。CGFPN 模块通过引入动态通道对齐机制与注意力引导策略,实现多尺度特征之间的语义统一与信息强化,特别增强了浅层纹理细节的保持能力。该模块有效缓解了传统 FPN 结构对小目标边界信息的弱化问题,对于裂纹类目标的精细边界建模具有显著优势。DPB 模块则基于位置感知的动态偏置

表 3 消融实验结果

Table 3 Results of the Ablation Study

算法	模块			P/%	R/%	mAP/%	计算量 /GFLOPs	参 数 量/M
	CTSO	CGFPN	DPB					
BASE				85.7	84.1	86.1	56.9	19.87
B	✓			86.4	80.9	87.2	51.3	15.61
C		✓		85.8	81.6	87.4	56.9	20.00
D			✓	86.5	83	86.5	57.2	19.87
E	✓	✓		84.2	83.8	87.5	51.3	15.75
F	✓		✓	85.1	82.2	87.2	51.5	15.61
G		✓	✓	85.0	81.3	86.3	57.2	20.00
GDC-DETR	✓	✓	✓	85.0	82.6	87.9	51.6	15.75

实验结果表明,相较于基准模型,本文所提出的网络模型在平均检测精度提升 1.8%,相较于基准模型有提升,并且计算量降低 9.3%,模型计算复杂度减小,实现了轻量化,参数量相较于基准模型降低了 20.7%,空间复杂度减小,提升模型的实时推理能力以及对计算成本的降低,准确率和召回率相较于基准模型分别降低 0.7%和 1.5%,检测正确的比例略有降低。

另外,根据消融实验可以发现,仅加入 CTSO 改进模块时,对检测精度和正确率有所的提升,并且对计算量和参数量大幅度降低,对裂纹的检测精度有所提升。仅加入 DPB 改进模块时,导致计算量提升,但是检测正确率提升,此模块在损失一定计算量的情况下提升了检测的正确率。仅加入 CGFPN 模块时进一步提升平均精度,准确率有所提升,尤其在裂纹等边界模糊小目标的检测中误检率显著增加,说明 CGFPN 在特征对齐与注意力引导方面的设计更利于细粒度语义保持与判别区域突出,但召回率下降。

从消融实验结果看,尽管 CTSO、CGFPN 和 DPB 模块在单独引入时均表现出不同程度的性能提升,但在联合集成为完整的 GDC-DETR 模型后,其性能提升趋于收敛。该现象并不证明各个模块的缺乏相互作用,而主要源于以下两个因素:

首先模块之间功能存在语义冗余,各模块均提升了上下文建模能力与多尺度特征融合,导致集成时出现特征增强重叠现象,从而引发边际效益递减。

建模策略,提升检测头对空间位移、细长结构及目标形变的适应能力。该机制使模型在裂纹等非刚性目标检测任务中具备更高的定位精度与结构拟合能力,从而增强整体检测性能。

为验证本文提出算法各个改动点的有效性,本文在重卡转向节裂纹数据集上进行了实验,实验结果如表所示。其中 CTSO 改进模块为将 C2f 和 HCO 相结合代替主干网络,用 CGFPN 代替原颈部网络中的 Concat 特征融合模块;用 DPB 模块代替 AIFI 特征交互。首先在每组实验中,仅加入一个创新点。随后根据改进点进行排列组合做实验。消融实验的结果如表 3 所示,其中“✓”表示引入某种模块,而空格则表示未引入该模块。

其次目前模块之间采用结构并联式集成,缺乏更深入的互导机制与交互式融合策略,限制了其潜在的协同建模能力。

本文提出的多模块集成策略虽在轻量化与精度提升方面达成平衡,但模块间协同作用尚未达到理想状态。未来的研究将聚焦于多源特征路径的交互建模机制与结构耦合策略的优化设计,进一步提升整体系统的协同建模能力。

3.5 对比试验

本文将本文提出的算法对比目前应用在目标检测领域的主流算法,如 SSD、YOLO 系列,同时选取经典的 DETR 改进算法 DEIM,最新的 YOLO 变体文献[10]、文献[11]、文献[12]和文献[13],最新的 RTDETR 变体文献[9],以及基准模型 RTDETR。此外本文提到的文献[16]因传统机器学习方法与深度学习评价方法指标不统一难以直接在对比如实验比较,故不放在实验环节进一步描述。沿用表一的参数训练其余模型,各个模型对比结果如表 4 所示。从实验结果得出,本文算法相较于传统的一阶段 SSD 模型参数少了 33.8%,计算量少了 81.1%并且平均检测精度提升 5.3%,准确率提升 0.5%,召回率提升 3%。YOLOv10n 模型相较于本文模型虽然计算量和参数量低,但是本文平均检测精度提高 4.6%,召回率提升 4.1%,准确率提升 1.7%。本文模型的平均检测精度比 YOLOv11n 模型提升 2.5%,召回率提升 2.4%,准确率降低 1%。但是计算量

明显高于 YOLOv11n。对比 YOLOv12n 模型中本文模型平均检测精度提高 5.6%，准确率提高 2.6%，召回率提高 6.4%，但计算量和参数明显不如 YOLOv12n。在对基准模型 RTDETR-r18 的对比中，平均检测精度提升 1.8%，计算量降低 9.3%，参数量相较于基准模型降低了 20.7%，但准确率降低 1.7%，召回率降低 1.5%。对比 RTDETR-r34 模型中本文模型不仅分别降低参数量和计算量 49.3% 和 41.9%，而且检测精度也有所提升。对比文献[9]中的改进模型本文模型平均检测精度提高 1.3%，参数量和计算量分别降低 6.7% 和 3.2%，但准确率降低 0.6%，召回率降低 0.9%。对比文献[10]中本文模型平均检测精度提升 2.7%，召回率提升 8%，但准确率降低 4.3%，计算量和参数量高于文献[10]。对比文献[11]中，本文模型的准确率不如文献[11]，降低 1.8%，但在平均准确率和召回率上明显优于文献[11]，分别提升 1.6% 和 1.1%。对比文献[12]中本文模型平均检测精度提升 1.3%，计算量和参数量明显优于文献[12]，分别为 46% 和 56%，但在召回率和准确率上略有降低。对比文献[13]中本文模型平均检测精度提升 3.6%，召回率提升 1.4%，但准确率降低 0.2%，计算量和参数量高于文献[13]。对比 DEIM 模型中本文模型平均准确率提升 1.7%，召回率提升 10.2%，计算量降低 42.4%，参数量降低 50.1%，但准确率不如

表 4 模型对比实验结果

Table 4 Results of the Model Comparison Experiment

模型算法	mAP/%	P/%	R/%	计 算 量 /GFLOPs	参数量 /M	FPS
SSD	82.6	83.5	79.6	274.3	23.8	39
YOLOv10n	83.3	82.3	78.5	8.2	2.69	47
YOLOv11n	85.4	85.8	80.2	6.3	2.58	61
YOLOv12n	82.3	81.4	76.2	5.8	2.51	39
RTDETR-r18	86.1	85.7	84.1	56.9	19.87	24
RTDETR-r34	87.3	85.6	82.2	88.8	31.11	19
文献[9]	86.6	84.6	83.5	53.3	16.88	23
文献[10]	85.2	88.3	74.6	23.8	12.53	36
文献[11]	86.3	85.8	81.5	6.8	2.52	63
文献[12]	86.6	84.2	83.6	95.7	35.83	61
文献[13]	84.3	84.4	81.2	11.7	7.94	48
DEIM	86.2	86.4	72.4	89.7	31.58	10
GDC-DETR	87.9	84.0	82.6	51.6	15.75	36

DEIM，降低 2.4%。本文算法 FPS 达到 36 帧/s，远远优于基准模型，并且在精度上优于 YOLOv11n 等轻量化模型。此外，由图 8 分析可知，本文算法处于高精度，中高速度的位置，实现了较好的检测精度并且在满足实时性（FPS>25 帧/s）检测的需求，具备较强的工业部署适应性。由表四和图 8 可知本文算法相较于其他最新的优秀模型具有更好的检测性能。实验表明 RTDETR 的检测精度上是优于 YOLO 算法的，改进后的 GDC-DETR 模型在计算量和检测精度上远远优于原始模型，但其准确率和召回率相较于原始模型略有下降。本文分析认为，主干网络中引入 CTSO 模块以替代部分传统卷积结构，虽然提升模型的精度和检测速度，但是也可能导致部分浅层特征的空间分辨退化，特别是在对低信噪比的局部结构特征或轻微裂纹等缺陷的识别过程中，特征丢失的情况较为显著，直接导致部分目标的漏检，从而影响准确率和召回率。锻件表面缺陷多表现为细长裂纹、浅表划痕等小目标。由于背景复杂、非均匀光照和反光材质等因素，导致模型检测降低了召回率。另一方面 DPB 模块在处理目标边界定位时，由于其动态位置学习策略，在某些对目标精确定位要求较高的场景中，可能存在边界回归偏差。这种偏移导致预测框与真实框的重叠度下降，从而影响准确率。




图8 mAP-FPS折线图

Fig.8 mAP-FPS line chart

3.6 可视化对比实验

为了进一步验证改进 RTDETR 算法的有效性, 本文选取了 RTDETR 和 GDC-RTDETR 两种算法在测试集上采用最优的训练模型进行可视化实验。鉴于本文所采用的锻件缺陷数据集采集自实际生产车间, 主要针对表面裂纹类缺陷进行无损检测, 不涉及孔隙、氧化层等其他类型的缺陷。因此, 可视化实验部分仅展

示了裂纹类缺陷的检测结果, 以符合实际工业应用场景的任务需求。实验结果如图 9 所示, 两种检测模型均能正常的识别转向节上的缺陷, 但本文提出的模型在准确率上表现更好, 更关注小目标的检测范围有更强的鲁棒性。对比(a)(b)两种算法的检测结果可以看出来, (b)模型不仅精度高于(a), 并且检测到了(a)没有检测到的缺陷, 尤其对小目标的检测能力优于(a)。综上所述, GDC-RTDETR 模型相较于基准模型 RTDETR 检测精度更高, 不易出现漏检。




图9 可视化对比实验结果

Fig.9 Visualization of the Comparative Experiment Results

3.7 泛化性实验

为了进一步验证本算法的泛化能力, 本文使用 NEU-DET 数据集进行实验。该数据集是由东北大学制作的带钢表面缺陷数据集, 数据集中的缺陷有六种类型, 包括银纹、夹杂物、补丁、点蚀表面、卷入的鳞片和划痕, 具有代表性强、类别多样的特点。需要指

出的是, 为确保泛化能力评估的客观性和公正性, 本文在 NEU-DET 数据集上未采用任何形式的训练、微调或域适应策略, 所用模型参数完全基于锻件表面缺陷数据集训练所得。测试过程中亦未对 NEU-DET 数据进行额外的数据增强处理或分布匹配调整。因此, 该实验构成一次典型的零样本泛化 (zero-shot generalization) 测试, 其性能反映的是模型结构改进在跨数据

集场景下的自然迁移能力。本文用 RTDETR-r18、YOLOv10n、YOLO v11n、YOLOv12n 和本文改进的 RTDETR-r18 模型进行实验比较,泛化性实验结果如表 5 所示。结果显示在 RTDETR-r18 中除了 Rs 和 Sc 缺陷之外的各类缺陷检测精度都有所提升, mAP 从 77.5%提高至 78.7%。在对比 YOLOv10n 中除 Cr 和 Ps 缺陷之外的各类缺陷检测精度都有所提升, mAP 从

表 5 泛化能力实验结果

Table 5 Results of the Generalization Ability Experiment

模型算法	mAP/%	Cr/%	In/%	Pa/%s	Ps/%	Rs/%	Sc/%
RTDETR-r18	77.5	43.9	63.2	96.3	96.7	71.9	93.0
YOLOv10n	77.0	51.1	72.1	94.3	98.6	58.6	87.4
YOLOv11n	77.7	53.3	82.2	94.7	98.2	55.1	82.7
YOLOv12n	75.0	45.3	71.4	91.3	93.3	61.2	87.4
RTDETR-r34	77.1	43.4	72.5	98.9	96.7	61.8	89.1
GDC-DETR	78.7	47.1	67.2	98.3	98.5	69.3	91.3

4 结论

针对工业产品表面缺陷形状多样、结构复杂和小目标较多以及参数量大等问题。本文提出一种以 RTDETR 为主要框架,以 CTSO 作为主干网络的缺陷检测模型,并在自建的数据集上测试实现 mAP 为 87.9%,并且在参数量和计算量方面显著下降。有效的改善了当前算法在锻件表面缺陷检测领域内无法平衡精度和参数量上的问题;此外,在未对 NEU-DET 数据集进行任何微调或适配操作的前提下,模型依然保持了良好的跨数据集性能,表明其结构改进在不同工业场景中具有良好的通用性与迁移能力。尽管如此, GDC-DETR 仍存在以下局限性。例如,对于小尺寸或边缘模糊的缺陷,其检测表现有待提高;在极端复杂的实际场景中,模型受到光照变化和表面反射的影响,检测鲁棒性仍有待增强,虽然模型的计算量和参数量有所优化,也满足于实时检测基本要求,在 NVIDIA GeForce GTX 1080 平台上达到了 36 FPS 的推理速度,已超过工业生产线通常要求的 25 FPS 最低帧率,但距离更高实时性需求仍存在优化空间。为提升模型在边缘端与高吞吐工业环境中的部署效率,未来工作将围绕以下方向展开:基于 CTSO 模块的开展剪枝策略探索 30%~50% 的通道剪枝比例,以降低模型冗余并压缩推理负载;同时结合知识蒸馏技术,通过教师-学生网络框架实现跨模型的语义知识迁移,从而在保证检测精度的同时进一步降低推理延迟与资源占用。此外,鉴于实际生产场所的探伤车间中仅包含裂纹类缺陷,未涉及孔隙与氧化层的探伤等其他类型。后续工作中我们会进一步完善数据集内容,让缺陷类型更加全面;同时,我们将引入更具挑战性的公开工业数据集(如 AITEX、DAGM2007)上开展验证,以全面评估模型在跨行业、跨场景的泛化能力与实际适用性。

77.0 提升至 78.7%。在对比 YOLOv11n 中除 Cr 和 In 缺陷之外的各类缺陷检测精度都有所提升, mAP 从 77.7%提升至 78.7%。在对比 YOLOv12n 中除 In 缺陷之外的各类缺陷检测精度都有所提升, mAP 从 75.0 提升至 78.7%。在 RTDETR-r34 对比中除了 In 和 Pa 缺陷之外的各类缺陷检测精度都有所提升, mAP 从 77.1%提高至 78.7%。

参考文献:

- [1] 蒋鹏,方刚,曹世金,等.奔驰重卡转向节挤压锻造复合工艺的有限元分析[J].锻压技术,2006,(01):22-27.
JIANG P,FANG G,CAO S J,et al. FEM analysis of the extrusion-forging compound process for knuckle of Benz heavy truck[J]. Forging technology,2006,(01):22-27.
- [2] 汤勃,孔建益,伍世度.机器视觉表面缺陷检测综述[J].中国图象图形学报,2017,22(12):1640-1663.
TANG B,KONG J Y,WU S Y.Review of surface defect detection based on machine vision[J].Journal of Image and Graphics,2017,22(12):1640-1663.
- [3] 陶显,侯伟,徐德.基于深度学习的表面缺陷检测方法综述[J].自动化学报,2021,47(05):1017-1034.DOI:10.16383/j.aas.c190811.
TAO X,HOU W,XU D. A Survey of Surface Defect Detection Methods Based on Deep Learning[J].Acta Automatica Sinica, 2021, 47(05):1017-1034. DOI:10.16383/j.aas.c190811.
- [4] 伍麟,郝鸿宇,宋友.基于计算机视觉的工业金属表面缺陷检测综述[J].自动化学报, 2024, 50(07): 1261-1283. DOI:10.16383/j.aas.c230039.
WU L,HAO H Y,SONG Y. A Review of Metal Surface Defect Detection Based on Computer Vision[J]. Acta Automatica Sinica, 2024, 50(07): 1261-1283. DOI:10.16383/j.aas.c230039.
- [5] 徐彦威,李军,董元方,等. YOLO 系列目标检测算法综述[J]. 计算机科学与探索, 2024, 18 (9): 2221-2238.
XU YW, LI J, DONG Y F, et al. Survey of Development of YOLO Object Detection Algorithms[J] Journal of Frontiers

- of Computer Science and Technology, 2024, 18(9): 2221-2238.
- [6] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]//European conference on computer vision. Cham: Springer International Publishing, 2020: 213-229.
- [7] ZHU X, SU W, LU L, et al. Deformable detr: Deformable transformers for end-to-end object detection[J]. arxiv preprint arxiv:2010.04159, 2020.
- [8] ZHAO Y, LV W, XU S, et al. Detsrs beat yolos on real-time object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 16965-16974.
- [9] 张伟健,徐向英,章永龙.改进 RT-DETR 的锻件表面缺陷检测算法[J/OL]. 机械科学与技术, 1-9 [2025-03-18]. <https://doi.org/10.13433/j.cnki.1003-8728.20250009>.
ZHANG W J, XU X Y, ZHANG Y L. Improved RT-DETR algorithm for detecting surfacedefects in steel[J/OL]. Mechanical Science and Technology, 1-9 [2025-03-18]. <https://doi.org/10.13433/j.cnki.1003-8728.20250009>.
- [10] 张岳,张上,王恒涛,等.基于跨尺度特征提取的锻件表面裂纹检测算法[J]. 计算机集成制造系统, 2025, 31(02): 499-511.DOI:10.13196/j.cims.2023.0698.
ZHANG Y, ZHANG S, WANG H T, et al. Crack detection algorithm for forging surface based on cross-scale feature extraction[J]. Computer-integrated manufacturing systems, 2025, 31(02): 499-511.DOI:10.13196/j.cims.2023.0698.
- [11] 刘宏志,黄振龙,邱彬,等.基于改进 YOLOv11n 的输电线路主要缺陷检测方法[J/OL]. 高电压技术, 1-12 [2025-03-19]. <https://doi.org/10.13336/j.1003-6520.hve.20241908>.
LIU H Z, HUANG Z L, QIU B, et al. Major Defect Detection Method for Transmission Lines Based on Improved YOLOv11n[J/OL]. High voltage technology, 1-12 [2025-03-19]. <https://doi.org/10.13336/j.1003-6520.hve.20241908>.
- [12] 王蕾,郭文平,陈欣慰,等.融合多尺度特征的蜗杆表面缺陷检测[J]. 光学精密工程, 2024, 32 (11): 1746-1758.
WANG L, GUO W P, CHEN X W, et al. Detection of surface defects on worm gears by integrating multi-scale features [J] Optical Precision Engineering, 2024, 32 (11): 1746-1758.
- [13] 赵佰亭,吴俊东,贾晓芬.融合特征增强的轻量化罐道缺陷检测算法[J]. 电子测量与仪器学报, 2023, 37 (06): 159-168. DOI:10.13382/j.jemi.B2306325.
ZHAO B T, WU J D, JIA X F. Lightweight Tank Track Defect Detection Algorithm Based on Feature Fusion Enhancement[J] Journal of Electronic Measurement and Instrumentation, 2023, 37 (06): 159-168. DOI:10.13382/j.jemi.B2306325
- [14] ZHAO W, CHEN F, HUANG H, et al. A new steel defect detection algorithm based on deep learning[J]. Computational Intelligence and Neuroscience, 2021, 2021(1): 5592878.
- [15] HE Y, SONG K, MENG Q, et al. An end-to-end steel surface defect detection approach via fusing multiple hierarchical features[J]. IEEE transactions on instrumentation and measurement, 2019, 69(4): 1493-1504.
- [16] 胡丹,吕波,王静静,等.焊缝表面缺陷激光视觉传感 HOG-SVM 的检测方法 [J]. 焊接学报, 2023, 44 (01): 57-62+70+131-132
HU D, LV B, WANG J J, et al. Detection method for surface defects in weld seams using laser vision sensing HOG-SVM.[J]. Journal of Welding, 2023, 44 (01): 57-62+70+131-132
- [17] HU H, LI Y, LIU M, et al. Classification of defects in steel strip surface based on multiclass support vector machine[J]. Multimedia tools and applications, 2014, 69: 199-216.
- [18] HUANG J, ZHOU J, YANG H, et al. A small-target forest fire smoke detection model based on deformable transformer for end-to-end object detection[J]. Forests, 2023, 14(1): 162.
- [19] WANG Z, LIU Y, LIU Y, et al. vheat: Building vision models upon heat conduction[J]. arxiv preprint arxiv:2405.16555, 2024.
- [20] TANG L, ZHANG H, XU H, et al. Rethinking the necessity of image fusion in high-level vision tasks: A practical infrared and visible image fusion network based on progressive semantic injection and scene fidelity[J]. Information Fusion, 2023, 99: 101870.
- [21] WANG W, CHEN W, QIU Q, et al. Crossformer++: A versatile vision transformer hinging on cross-scale attention[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023, 46(5): 3123-3136.
- [22] 项新建,汤卉,肖家乐,等.基于多尺度特征融合 SSDLite 的光伏组件缺陷检测[J]. 太阳能学报, 2025, 46(01): 669-675.DOI:10.19912/j.0254-0096.tynxb.2023-1544.
XIANG X J, TANG H, XIAO J L, et al. Defect detection of photovoltaic modules based on multi-scale feature fusion SSDLite[J]. Acta Solaria Sinica, 2025, 46(01): 669-675. DOI:10.19912/j.0254-0096.tynxb.2023-1544.
- [23] WANG H, ZHANG J, TIAN Y, et al. A simple guidance

- template-based defect detection method for strip steel surfaces[J]. *IEEE Transactions on Industrial Informatics*, 2018, 15(5): 2798-2809.
- [24] ZHANG Y, GAO Y, SHEN L Y. Steel Defect Detection Based on Modified RetinaNet[C]//2022 26th International Conference on Pattern Recognition (ICPR). IEEE, 2022: 3572-3579.
- [25] XIAO, D., XIE, F.T., GAO, Y, et al. A detection method of spangle defects on zinc-coated steel surfaces based on improved YOLO-v5[J]. *The International Journal of Advanced Manufacturing Technology*, 2023, 128(1-2): 937-951.
- [26] YANG D, CUI Y, YU Z, et al. Deep learning based steel pipe weld defect detection[J]. *Applied Artificial Intelligence*, 2021, 35(15): 1237-1249.
- [27] AKHYAR F, LIU Y, HSU C Y, et al. FDD: a deep learning-based steel defect detectors[J]. *The International Journal of Advanced Manufacturing Technology*, 2023, 126(3): 1093-1107.
- [28] ZHAO B T, CHEN Y R, JIA X F, et al. Steel surface defect detection algorithm in complex background scenarios[J]. *Measurement*, 2024, 237: 115189.
- [29] ABU M, AMIR A, LEAN Y H, et al. The performance analysis of transfer learning for steel defect detection by using deep learning[C]//*Journal of Physics: Conference Series*. IOP Publishing, 2021, 1755(1): 012041.