

钢铁
Iron & Steel
ISSN 0449-749X, CN 11-2118/TF

《钢铁》网络首发论文

题目: 基于改进 RTDETR 的边缘多尺度焦粉检测
作者: 张学锋, 秦继洋, 龙红明, 夏琴, 余正伟
DOI: 10.13228/j.boyuan.issn0449-749x.20250388
收稿日期: 2025-07-21
网络首发日期: 2025-09-15
引用格式: 张学锋, 秦继洋, 龙红明, 夏琴, 余正伟. 基于改进 RTDETR 的边缘多尺度焦粉检测[J/OL]. 钢铁.
<https://doi.org/10.13228/j.boyuan.issn0449-749x.20250388>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

DOI: 10.13228/j.boyuan.issn0449-749x.20250388

基于改进 RTDETR 的边缘多尺度焦粉检测

张学锋¹, 秦继洋², 龙红明³, 夏琴⁴, 余正伟³

(1.冶金工程与资源综合利用安徽省重点实验室(安徽工业大学), 安徽 马鞍山 243032; 2.安徽工业大学计算机科学与技术学院, 安徽 马鞍山 243032; 3.安徽工业大学冶金工程学院, 安徽 马鞍山 243032; 4.青岛西海岸新区交通运输局, 山东 青岛 266400)

摘要: 针对冶金工业中燃料焦粉检测存在的复杂图像噪声、焦粉与背景分离度低、现场采集图像模糊等导致的粒径难以准确检测等问题, 提出了基于改进 RT-DETR 算法的焦粉检测模型 ESGE-RTDETR (Edge-Sparse Graph-enhanced Efficient Real-Time DETR), 针对焦粉检测场景能够对焦粉粒度进行高效准确检测。针对焦粉边缘特征提出 MutiScaleEdge 多尺度边缘卷积模块并结合 ConvEdgeFusion 边缘特征融合模块, 得到不同维度信息的特征图, 采用窗口化注意力和动态自适应稀疏注意力, 优化计算复杂度, 通过 CSP-MSF 融合模块进行颈部特征融合, 最终输入检测头得出焦粉检测结果。为提升训练精度, 融合 PowerIoU 和 FocalerIoU 的特点, 提出了 FocalPowerIoU 替换原有的 GIoU, 使得训练较快收敛且稳定训练, 提高了模型的准确度。通过可视化模型所聚焦的特征提取点及区域, 提升模型检测过程的可解释性。在实际生产过程中, 检测预处理阶段经试验对比后选择采用自适应直方图均衡化 (CLAHE) 进行图像增强, 突出焦粉边缘特征, 为模型检测提供稳定输入, 通过 CLAHE 图像增强提高了模型推理结果的全面性及准确性。在某钢铁厂焦粉图像数据集上试验结果表明, ESGE-RTDETR 模型相较于主流目标检测模型对焦粉多尺度粒度的识别精度有较好的提升作用, 相较于原始 RT-DETR 模型, mAP₅₀ 准确率提升 20.6 个百分点, 召回率提升了 14.1 个百分点, 相较于主流检测 YOLOv8, mAP₅₀ 准确率提升了 8.9 个百分点, 召回率提升了 8.5 个百分点, 能够为现场生产及焦粉粒度工业闭环控制提供技术支持, 经某钢厂实际生产验证, 满足生产检测精度及速度要求。

关键词: 焦粉粒度; 目标检测; 多尺度; 深度学习; 图像增强; RT-DETR; IoU; 工业自动化

文献标志码: A 文章编号: 0449-749X (2025) 12-0000-00

Edge multi-foot coke particle detection based on improved RTDETR

ZHANG Xuefeng¹, QIN Jiyang², LONG Hongming³, XIA Qin⁴, YU Zhengwei³

(1. Anhui Provincial Key Laboratory of Metallurgical Engineering and Comprehensive Utilization of Resources (Anhui University of Technology), Maanshan 243032, Anhui, China; 2. School of Computer Science and Technology, Anhui University of Technology, Maanshan 243032, Anhui, China; 3. School of Metallurgical Engineering, Anhui University of Technology, Maanshan 243032, Anhui, China; 4. Qingdao West Coast New Area Transportation Bureau, Qingdao 266400, Shandong, China)

Abstract: Aiming at the problems of complex image noise, low separation between coke powder and background, and blurred images collected on the spot in the detection of fuel coke powder in metallurgical industry, it is difficult to accurately detect the particle size. A coke powder detection model ESGE-RTDETR (Edge-Sparse Graph-enhanced Efficient Real-Time DETR) based on the improved RT-DETR algorithm is proposed, which can efficiently and accurately detect the coke powder particle size in coke powder detection scenarios. The MutiScaleEdge multi-scale edge convolution module combined with the ConvEdgeFusion edge feature fusion module is proposed to obtain feature maps with different dimensions of information. Windowed attention and dynamic adaptive sparse attention are used to optimize the calculation complexity. The neck feature is fused through the CSP-MSF fusion module, and finally the coke powder detection results are obtained by inputting the detection head. In order to improve the training accuracy, combining the characteristics of PowerIoU and FocalerIoU, FocalPowerIoU is proposed to replace the original GIoU, which makes the training faster convergent and stable, and improves the accuracy of the model. Enhance the interpretability of the model detection process by

基金项目: 安徽省重点实验室开放基金资助项目 (SKF24-04)

作者简介: 张学锋 (1978—), 男, 博士, 教授;

E-mail: zxf_06@ahut.edu.cn;

收稿日期: 2025-07-21

通信作者: 龙红明 (1979—), 男, 博士, 教授;

E-mail: yafilm@126.com

visualizing the feature extraction points and regions focused by the model. In the actual production process, adaptive histogram equalization (CLAHE) is selected to enhance the image after experimental comparison in the preprocessing stage of detection, highlighting the edge characteristics of coke powder, providing stable input for model detection, and improving the comprehensiveness and accuracy of model reasoning results through CLAHE image enhancement. The experimental results on the coke powder image data set of a steel plant show that the ESGE-RTDETR model has a better effect on improving the recognition accuracy of coke powder multi-scale particle size compared with the mainstream target detection model. Compared with the original RT-DETR model, the accuracy The rate of mAP₅₀ has increased by 20.6 percentage points, and the recall rate has increased by 14.1 percentage points. Compared with the mainstream detection YOLOv8, the accuracy rate of mAP₅₀ has increased by 8.9 percentage points, and the recall rate has increased by 8.5 percentage points. It can provide technical support for on-site production and industrial closed-loop control of coke powder particle size. The actual production verification of a steel plant meets the requirements of production detection accuracy and speed.

Key words: coke powder particle size; object detection; multiscale; deep learning; image enhancement; RT-DETR; IoU; industrial automation

烧结工艺是钢铁冶金生产过程重要的预处理环节,其能耗约占整个钢铁企业总能耗的 10%~15%。而在烧结能耗构成中,作为主要固体燃料的焦粉,其消耗所占比例高达 75%~80%,是烧结过程能耗控制的核心焦点^[1]。焦粉粒度分布直接决定了燃烧带的宽度、高温停留时间及液相生成量,进而影响烧结矿的强度、返矿率和能源利用。从燃烧效率来看,细粒焦粉(小于 1 mm)虽然燃烧迅速,但高温停留时间短,热量利用率低,导致烧结矿强度下降、返矿率上升;粗粒焦粉(大于 3 mm)则燃烧缓慢,使烧结速度降低、局部过熔,同样削弱烧结矿强度^[2];而 1~3 mm 粒级所占比例超过 55%时,可平衡燃烧速率与高温持续时间,显著提升转鼓强度、降低返矿率^[3]。在料层透气性方面,细粉过多易堵塞料隙,粗粒所占比例过高则引发燃料偏析,均会降低成品率,将小于 0.5 mm 的粒级控制在 30%以内、1~3 mm 粒级保持为 35%~50%,平均粒径维持为 1.9~2.2 mm 时,成品率可达最优^[4]。在能耗层面,不合理的粒度分布会增加固体燃耗、降低余热回收效率并增加风机电耗,而粒度优化后,固体燃耗可显著降低,余热回收效率得以提升。因此,燃料粒度的精准检测和控制是烧结工序至关重要的环节之一。然而,当前冶金企业普遍采用的焦粉粒度检测方法仍高度依赖人工筛分。这种方法不仅劳动强度大、效率低下,而且存在显著弊端,如检测结果受操作人员主观因素影响大、重复性差;取样离散且频次低,无法实时反映粒度波动;离线检测导致调控滞后,难以满足烧结智能化闭环控制的实时性需求。

机器视觉技术凭借其非接触、快速、可在线自动化的特点,为焦粉粒度的实时、智能化检测提供了极具潜力的新思路。通过图像采集与分析,理论上可以实现对输送带或料仓中焦粉的连续粒度识别。然而,将机器视觉技术应用于烧结现场焦粉粒度检测时,面临着现场粉尘弥漫、光照不均、振动等导致的图像噪声干扰,焦粉与运输皮带、料仓背景颜色相近造成的分离度低,颗粒形状不规则且输送中堆叠、运动引发的图像模糊,以及物料密集堆叠和小于 1 mm 粉状焦粉带来的识别检测难题。为应对上述难题,基于计算机视觉焦粉粒度检测的已有部分研究,如董铭江等^[5]提出自适应形态学的烧结焦粉粒度图像分割方法;袁君奇等^[6]采用自适应分水岭分割算法对焦粉进行检测,计算粒径分级分布;李福民^[7]采用 Re-Unet 网络通过跳跃连接的方式优化网络并且降低了特征的损失,提高了混合料的精准性;刘计尊^[8]采用改进 YOLO 算法对钢铁物料进行检测。上述方法在特定场景下取得一定成效,但仍普遍存在精度不足、对复杂现场适应性弱、对小目标检测不敏感等问题。在目标检测领域,采用 Anchor-Based 方法的 YOLO 系列和采用 Transformer-Based 架构的 DETR 系列广泛应用于工业领域,前者具有良好的实时性但对于小目标存在漏检现象,且在高噪背景下精度大幅降低^[9-10];后者及其改进版 Deformable DETR^[11]、RT-DETR^[12]具有全局感知能力,在复杂背景下具有更优目标检测能力,然而,其检测速度和训练稳定性为工业部署带来挑战^[13]。

针对上述冶金工业焦粉粒度视觉检测中存在的核心难题,以及现有目标检测模型在应对这些挑战时的局限性,本文提出基于改进 RT-DETR 算法的焦粉检测模型 ESGE-RTDETR (Edge-Sparse Graph-enhanced Efficient Real-Time DETR)。该模型旨在实现对烧结焦粉粒度的高效、准确在线识别,为烧结智能化控制提供可靠的数据支撑。本研究核心贡献在于:1) 针对焦粉边缘特征提出 MutiScaleEdge 多尺度边缘卷积模块并结合 ConvEdgeFusion 边缘特征融合模块,强化关键特征的提取与融合;2) 采用窗口化注意力和动态自适应稀疏注意力机制优化 Transformer 架构,大幅降低计算复杂度,提升实时性;3) 通过创新的 CSP-MSF

融合模块优化颈部特征融合；4) 设计新型 FocalPowerIoU 损失函数，融合 PowerIoU 与 FocalerIoU 优势，显著提升模型训练收敛速度、稳定性和检测精度。在实际钢厂部署环境中，模型推理速度达到了 16FPS,单张图片检测时间为 62ms 相较于传统人工筛分及目测方式（单张需时 8-12s），检测效率提升近 160 倍；功率能耗低于 15W,显著提升了工业检测效率及资源利用率，证实了 ESGE-RTDETR 在焦粉粒度视觉检测任务中的优越性能。

1 改进 RT-DETR

1.1 改进模型架构

针对 RT-DETR 对小目标检测及复杂场景下对边缘不敏感的不足之处,本文提出 ESGE-RTDETR(Edge-Sparse Graph-enhanced Efficient Real-Time DETR),改进的整体架构如图 1 所示。主要针对 Backbone、Neck、Attention 进行改进并且针对焦粉场景优化损失函数。




图 1 ESGE-RTDETR 网络整体结构图

Fig. 1 ESGE-RTDETR network overall structure diagram

1.2 BackBone 网络改进

常规目标检测网络对被检查物体边缘关注不足,对焦粉而言其重要特征恰恰为边缘特征,受到 Holistic Edge Attention^[14]的启发,本文在主干网络浅层设计了多尺度边缘信息生成模块 MutiScaleEdegInfoGenerator,以生成多尺度边缘信息特征,并将提取后的多尺度边缘信息传递到整个主干网络中。为增强网络对边缘信息的感知能力,借鉴 U2-Net^[15]的多尺度注意力与深度监督机制设计 ConvEdgeFusion 模块,并采用通道融合和卷积特征提取。下文将对多尺度边缘信息产生器以及边缘信息融合模块展开介绍。

1.2.1 MutiScaleEdge 模块设计

针对焦粉边缘的特征不敏感问题,设计该模块以获取对边缘信息更高感知的特征,并通过多次下采样获得不同尺度的特征图,为后续融合做准备。模块整体设计如图 2 所示。




图 2 MultiScaleEdgeInfoGenerator 网络结构图

Fig. 2 MultiScaleEdgeInfoGenerator network structure diagram

经过基本卷积处理后，输入检测图像被下采样 4 倍，得到对应的 FeatureMap，经过多尺度边缘信息产生器处理后，则会产生 8 倍、16 倍、32 倍下采样边缘信息特征图。首先，使用 Sobel 算子^[16]计算 x 方向及 y 向的梯度信息，得到边缘特征并进行融合，再采用 MaxPool 层后调整通道数以适配后续的网络，即分别得到 (256, 256)、(128, 128)、(64, 64) 不同尺度的特征图，分别对应的通道数为 64、128、256，输入到后续的融合模块。

经过 3D 卷积后，则进行梯度计算，获取某个点的像素相对于其邻域的变化率。计算公式为

$$G_x = I * S_x, G_y = I * S_y \quad (1)$$

式中： G_x 为水平方向梯度图； G_y 为垂直方向梯度图； $*$ 为卷积运算； S_x 、 S_y 分别为 Sobel 算子 x 方向和 y 方向卷积核； I 为输入特征图。

1.2.2 ConvEdgeFusion 模块设计

该模块设计进行主干网络信息初步融合，分别在输入后与输出前施加 1×1 卷积以实现通道信息融合，并且在 2 个 1×1 卷积之间采用 3×3 卷积的方式进行空间信息融合。融合模块设计如图 3 所示。




图 3 ConvEdgeFusion 模块图

Fig. 3 ConvEdgeFusion module diagram

以往的特征融合往往采用 2 个 3×3 卷积进行，设输入特征图的维度为 $C \times H \times W$ ，其中 C 表示通道数， H 表示高度， W 表示宽度，则单个 3×3 卷积计算量为 $9C^2HW$ ，总计算量为 $18C^2HW$ ，对比 ConvEdgeFusion 模块，该模块 1×1 卷积计算量为 $C^2HW/2$ ，总计算量为 $6.25C^2HW$ ，计算量下降约 64%，显著减少了计算开销，提高了推理速度，提升了不同特征之间的交互，使得信息融合得更加充分。类似设计在 MobileNet^[17]中已被证明是有效的。

1.3 Neck 网络改进

在主干网络完成特征提取并经过注意力层筛选之后，颈部网络需进一步融合多尺度信息并增强边缘感知能力。受 TridentNet^[18]启发，本文在 FPN 结构中引入自适应多尺度卷积核，在不同特征层动态选择不同的卷积核，增强多尺度特征表达能力，并参考 BiFPN^[19]，采用加权特征融合替换传统的 Concat 连接，降低计算量的同时强化特征权重学习。为适应焦粉场景检测存在多种粒度分布的情况，借鉴 MAF-YOLO^[20]中 CSP 结构针对多尺度特征提取设计。本文设计 CSP-MSF (Cross Stage Partial Multi-Scale

Fusion)模块，结合 CSP 结构及多尺度并行分支，保留高分辨率特征。并采用 DUSFB (Depthwise UpSampling Fusion Block) [21] 的高效上采样模块优化高维特征还原质量，进一步提高检测精度。

在焦粉检测任务中，图像边缘信息、纹理特征及多尺度特征的提取尤为重要。本文提出的 CSP-MSF 模块则是通过采用分支策略、多尺度特征提取、深度可分离卷积以及特征融合机制来提升检测性能。模块网络图如图 4 所示。




图 4 CSP-MSF 模块图

Fig. 4 CSP-MSF module diagram

由于焦粉颗粒尺度存在不均匀性，网络需引入多尺度感受野以获取不同尺度的特征表示。此外，受制于焦粉边缘模糊和对比度低的影响，还需进一步增强局部边缘特征。为此，通过 MSConv (Multi-Scale Convolution) 进行多尺度特征提取，并结合深度可分离卷积 (DWC 提取特征，采用 CSP (Cross Stage Partial) 结构实现特征分支。最后采用通道打乱操作增强特征交互，以提高信息的利用率。整体计算流程如下：

针对 MSConv 的输入特征 X ，采用不同尺度的深度可分离卷积可表示为

$$X_{dw} = \text{ReLU}(\text{BN}(\text{DWC}_i(X))) \quad i \in \{(1,3,5), (3,5,7), (5,7,9)\} \quad (2)$$

式中：ReLU 为激活函数；BN 为批量归一化； X_{dw} 为经过深度可分离卷积后的图像特征。

再经过不同尺度特征拼接并逐步累加输出多尺度特征结果，即

$$X_{out} = \text{ConvNormLayer}(\text{Concat}(X_{shortcut}, X_{shuffle}, X_{MsConv})) \quad (3)$$

式中：ConvNormLayer 为卷积归一化层； $X_{shortcut}$ 为残差分支； $X_{shuffle}$ 为 MSConv 主分支； X_{MsConv} 为 MSConv 额外分支； X_{out} 为模块输出特征。

1.4 自注意力机制模块改进

Transformer 能够针对不同特征分配不同的关注权重，从而突出重要特征，在 Deformable-DETR、Sparse R-CNN[22]等方法中展现出性能的有效提升。本文结合上述两者优势，采用窗口化注意力机制与动

态选择策略，由 Adaptive Sparse Self-Attention^[23]的设计出发，增加注意力的稀疏性并保留全局注意力的优势，相较于 AIFI 其降低了计算量。但针对当前的焦粉检测场景仍然存在一些问题，如其 DSA 分支采用全局注意力计算成本高，而 SSA 分支采用了固定的稀疏注意力机制，关注度不足。鉴于 Deformable-DETR 和 Sparse R-CNN 对动态区域选择的精准度和效率，本文提出 SWASA-AIFI (Sparse Window Adaptive Sparse Attention - Adaptive Input Feature Interaction)，结合窗口化注意力和动态自适应稀疏注意力，优化计算复杂度，提高检测精度。具体网络模块如图 5 所示。




图 5 SWASA-AIFI 模块图

Fig. 5 SWASA-AIFI module diagram

本模块所采用的局部窗口稀疏注意力机制，利用 Top-K 筛选注意力分数，减少计算量并提升关键区域的能力。在每个窗口内，仅对前 K 个最相关的 Query-Key 对，计算其注意力权重，并通过 SoftMax 归一化得到概率分布。随后，根据注意力权重对对应的 Value 进行加权求和，生成的局部窗口内的特征表示为 Z 。其稀疏注意力可形式化表示为

$$Z = \text{Softmax} \left(\text{Top-K} \left(\frac{QK^T}{\sqrt{d}} \right) \right) V \quad (4)$$

式中：Top-K 为稀疏选择算子，只保留每个查询向量与键向量之间相关性最高的 K 个值，其余置负无穷大； Q 、 K 、 V 分别为查询、键、值矩阵； K^T 为键矩阵的转置； d 为特征向量的维度； Z 为输出矩阵。

得到窗口划分即稀疏注意力后，经 WindowMerge 与 DropPath 残差路径组合，再接入 GELU 激活和 MLP 模块最终得到注意力输出特征。

$$X_{mid} = \text{LayerNorm}(X_{seq}) + \text{DropPath}(\text{WindowMerge}(Z)) \in \mathbb{R}^{B \times H \times W \times C} \quad (5)$$

$$F_{output} = \text{GELU}(X_{LN2} W_1) \odot X_{LN2} W_2 \quad (6)$$

$$X_{out} = X_{mid} + \text{DropPath}(F_{output}) \quad (7)$$

式中： X_{seq} 为输入的序列化特征； Z 为稀疏注意力后的特征矩阵； $\text{WindowMerge}(\cdot)$ 为窗口合并操作； $\text{DropPath}(\cdot)$ 为随机深度残差路径； $\text{LayerNorm}(\cdot)$ 为层归一化操作； W_1 、 W_2 为全连接层权重矩阵； $\odot$ 为逐元素乘法； X_{mid} 、 F_{output} 、 X_{out} 分别为中间特征、MLP 输出特征、最终输出特征。

最后再通过维度变化将序列各式恢复为图像空间结构，为后续的特征融合做准备。

1.5 损失函数优化

焦粉检测场景中，由于目标密集、背景复杂、粒径不均，边界框的准确回归显得尤为关键。GIoU 只解决了无重叠梯度的问题，但其并未显式约束边界框角点和中心点的偏移，也未能有效关注低 IoU 的困难样本。为提升焦粉小粒径和模糊边界检测效果，本文结合 Powerful-IoU^[24]中的位置偏移惩罚机制以及 Focaler-IoU^[25]的低 IoU 强化策略，提出 FocalPowerIoU 损失函数。该损失能够增强模型对焦粉目标位置的感知能力，同时提升对模糊边界的检测精度。量化角点偏移过程可表示为

$$P = \frac{1}{4} \left(\frac{dw_1 + dw_2}{w_2} + \frac{dh_1 + dh_2}{h_2} \right) \quad (8)$$

$$\text{PowerIoU} = \text{IoU} \cdot e^{-P^2} \quad (9)$$

式中： P 为归一化的综合位置偏移惩罚（值越大表示偏移越严重）； dw_1 、 dw_2 、 dh_1 、 dh_2 分别为左边界、右边界、上边界、下边界预测框边界和真实边界的偏移； w_2 、 h_2 分别为真实框的宽度和高度； e^{-p^2} 为高斯函数形式的偏移衰减因子； $PowerIoU$ 为修正后的IoU（偏移越大，值越小，损失越大）。

Focaler-IoU 通过归一化和阈值控制，使得低 IoU 样本的损失贡献被放大，从而增强模型对困难样本的学习能力。结合两者优势，FocalPowerIoU 的损失表达式可表示为

$$L = \lambda \cdot (1 - PowerIoU) \cdot \frac{1}{IoU_{focaler}} \quad (10)$$

式中： L 为损失函数； λ 为角点偏移的惩罚强度，此处设为超参数 3； $IoU_{focaler}$ 为动态检测难易程度权重值。

图 6 所示为损失函数改进示意图。




图 6 损失函数改进示意图

Fig. 6 Schematic diagram of loss function improvement

2 试验设计与结果分析

2.1 数据集介绍

本研究所用数据集采集于某钢厂实际焦粉粒度检测场景。采集系统包括 2500 万像素工业相机、双侧补光灯、除灰装置及工控机，面向皮带输送过程中的焦粉进行图像获取。为增强模型泛化能力，连续 4 天在不同时间段采集图像，每日随机选取 60 张，共构建 400 张原始图像样本，图像分辨率为 2048×2048，涵盖不同班次与光照变化条件。为提高模型的鲁棒性与适应性，对原始图像进行多种增强操作，包括随机旋转、仿射变换、Gamma 校正（模拟不同光照条件）、几何与透视变换以及仿湿焦模拟等。经过增强后，最终构建的数据集包含 3200 张训练图像、400 张验证图像以及 400 张测试图像，能够覆盖不同焦粉密集度和背景干扰的多样化检测环境。

2.2 评价指标

本文中衡量模型的性能采用以下几个评价指标，即精确率 P (Precision)、召回率 R (Recall) 平均精度均值 mAP_{50} (Mean Average Precision@50) 在预测框与真实框有 50% 以上重叠时，模型检测的平均精度，单类别下 mAP 即 AP 、FPS (Frames Per Second, 帧/秒) 用于衡量推理速度。

$$Precision = \frac{TP}{TP+FP} \quad (11)$$

$$Recall = \frac{TP}{TP+FN} \quad (12)$$

$$AP = \int_0^1 p(r)dr \quad (13)$$

$$FPS = \frac{1}{t_p} \quad (14)$$

式中：TP 为模型预测为目标且与真实目标匹配的样本数量；FP 为模型预测为目标，但实际并非目标的样本数量；FN 为模型未预测为目标，但实际为目标的样本数量；AP 为 Precision-Recall 曲线下的面积，用于衡量检测精度； t_p 指单帧图像的推理时间；

2.3 消融试验

为方便试验及记号，对主干网络改进命名为 B (Backbone)、颈部融合网络改进命名为 N (Neck)、注意力机制改进命名为 A (Attention)。由于焦粉检测场景中硬件资源受限，选用 RTDETR-r18 版本作为基础模型。具体的试验参数为：训练轮次均为 500，优化器为 AdamW，学习率为 0.000 1，批次大小为 2，输入图像尺寸为 2048×2 048，动量参数为 0.9，权重衰减为 0.000 1。训练过程中使用 4 个并行计算单元，未加载预训练权重，损失函数采用 FocalPower-IoU。模型评估在测试集上进行，使用相应的测试指标进行性能验证。

2.3.1 模块消融试验

为了评估不同模块对模型性能的影响，试验设计了 6 组对照试验，分别为 Baseline、Baseline+B、Baseline+N、Baseline+A、Baseline+B+N、Baseline+B+A 以及 Baseline+B+N+A。控制除模块外，其余试验参数均一致，不同的模块间消融结果见表 1。

表 1 不同模块消融试验检测指标对比

Table 1 Comparison of ablation test indicators of different modules

Model	mAP ₅₀ /%	mAP ₅₀₋₉₅ /%	R/%	P/%	F1-score/%	FPS/(frame/s)	GFLOPs
Baseline	0.725 4	0.542 1	0.6519	0.7635	0.703 3	10.98	48.8
Baseline+B	0.847 4	0.630 5	0.7828	0.8329	0.807 0	16.19	59.4
Baseline+A	0.877 4	0.672 4	0.815 3	0.8641	0.839 0	20.52	57.8
Baseline+N	0.833 3	0.661 1	0.7556	0.8428	0.796 8	10.47	51.1
Baseline B+N	0.851 2	0.694 5	0.7801	0.8621	0.819 1	15.09	56.9
Baseline B+A	0.853 3	0.612 5	0.7899	0.8416	0.815 0	17.13	60.3
Baseline B+N+A	0.945 5	0.803 5	0.8971	0.9442	0.920 0	11.87	88.8

为了清晰呈现各模块的消融效果，图 7 展示了不同消融组合在训练过程中 mAP₅₀ 精度随迭代次数的变化对比。




图 7 消融试验训练迭代精度对比

Fig. 7 Comparison of training iteration accuracy of the experiment

通过表 1 及图 7 可以看出，各模块的消融实验对模型精度具有不同程度的提升。相比基准模型，经过单一模块或组合模块处理后，模型精度均有所提高，但不同组合间仍存在差异。使用全部模块时，模型性能显著优于其他组合，证明了模块设计的有效性。

2.3.2 损失函数消融试验

为评估不同损失函数的效果，在 Baseline+B+N+A 模型基础上，分别采用损失函数 GIoU 及 FocalPowerIoU 作为损失函数进行对照试验，训练策略及参数均一致。试验结果见表 2。

表 2 损失函数改进检测精度对比

Table 2 Comparison of detection accuracy by improving loss function

IOU	mAP ₅₀ /%	mAP ₅₀₋₉₅ /%	R/%	P/%	F1-score/%
GIoU	0.869	0.716	0.797	0.891	0.841
FocalPowerIoU	0.945	0.803	0.896	0.944	0.920

2.4 对比试验

为验证模型改进的有效性，依据计算速度、预测精度选取常见目标检测网络进行对比，控制训练策略及训练参数的一致性，以验证各个模型相较于本文提出的模型的优劣。具体模型及试验结果见表 3。

表 3 主流检测模型精度对比

Table 3 Comparison of accuracy of mainstream detection models

Model	mAP ₅₀ /%	mAP ₅₀₋₉₅ /%	R/%	P/%	F1-score/%	FPS/(frame/s)	GFLOPs
SSD	0.219	0.103	0.218	0.126	0.159	79	15.02
Faster R-CNN	0.347	0.235	0.388	0.412	0.399	41	134.49
RetinaNet	0.295	0.202	0.223	0.296	0.254	42	127.21
YOLOv5	0.823	0.618	0.785	0.764	0.790	99	7.10
YOLOv8	0.856	0.657	0.801	0.816	0.810	101	8.10
YOLOv10	0.812	0.606	0.767	0.757	0.760	82	6.50
YOLOv11	0.821	0.621	0.766	0.781	0.773	44	6.30
YOLOv12	0.451	0.227	0.525	0.475	0.499	45	6.22
DETR	0.286	0.148	0.204	0.876	0.330	52	57.10
RT-DETR	0.739	0.661	0.755	0.843	0.797	10	51.10
Deformable-DETR	0.286	0.139	0.180	0.286	0.224	14	220.65

为了清晰呈现对照实验结果，图 8 展示了不同模型在精度与推理时间上的对比情况。




图 8 精度推理速度对比散点图


Fig. 8 Accuracy inference speed comparison scatter plot

在本研究中，选取了 SSD^[26]、Faster R-CNN^[27]、RetinaNet^[28]、YOLOv5^[29]、YOLOv8^[30]、YOLOv10^[31]、YOLOv11^[32]、YOLOv12^[33]、DETR^[34]、RT-DETR、Deformable-DETR 共 11 种主流目标检测模型进行对比评估。从检测精度来看，ESGE-RTDETR 显示出显著优势，其 mAP_{50} 高达 0.945、 mAP_{50-95} 达 0.803、F1-score 达 0.920，均为所有模型中最高值，这表明其对焦粉等小目标的识别能力最强，尤其适合对粒度检测精度要求严苛的应用场景。

2.5 试验可视化

2.5.1 热力图可视化

为进一步验证改进对模型的有效性，采用 Grad-CAM（Gradient-weighted Class Activation Mapping）技术，对同一图像经过不同的模块进行处理后的热力图进行绘制，可清晰反映模型的检测注意力分布。结果如图 9 所示。



(a、e) 初始热力图; (b、f) 主干特征提取热力图; (c、g) 注意力筛选后热力图; (d、h) 特征融合后热力图;

图 9 局部及全局检测热力图

Fig. 9 Local and global detection heatmaps

图 9 为根据热力值的可视化结果。其中，第 1 行为局部热力图，第 2 行为全局热力图。在局部热力图中，图 9 (a) ~ (d) 采用置信度 0.6 限定检测目标框，将目标限定在检测框中进行热力计算，通过检

测结果可以看出，模型在初始阶段对焦粉的关注较为分散；经过主干网络及注意力机制处理后，关注点逐渐集中在边缘信息；在特征融合后，对焦粉中部区域的关注进一步减弱，而对边缘的关注显著增强，从而提升检测效果。在全局热力图中，图 9（e）~（h）为不限制检测框进行全局热力显示，蓝色区域（电子版显示）表示未被关注的部分。随着模型处理的逐步深入，关注范围不断扩大，并逐渐集中于焦粉目标区域。

2.5.2 图像增强及检测可视化

由于现场生产环境复杂，存在大量粉尘，并且在皮带上运动的焦粉受到光照不均的影响使得原始采集图像存在与背景融合度高的问题，这为焦粉的检测带来了挑战，因此，采用图像增强的方法对焦粉特征进行放大，以提高检测的精准性。通过试验，分别采用拉普拉斯算子图像锐化增强、伽马校正（Gamma）增强图像特征以及自适应直方图均衡化处理图像。对比发现，采用自适应直方图均衡化（CLAHE）对采集待推理图像进行图像增强效果最好。图像增强后采用本文检测算法检测结果组图如图 10 所示。




图 10 不同图像增强算法处理及检测效果

Fig. 10 Processing and detection effects of different image enhancement algorithms

图 10 中展示了采用伽马校正、拉普拉斯锐化及自适应直方图均衡化 3 种方法对原始采集数据进行增强及检测的结果。伽马校正优化改善了整体亮度及对比度，但在光照不均匀区域其增强效果不稳定^[35]；拉普拉斯锐化增强边缘信息，突出了焦粉的边缘轮廓^[36]，但受到噪声影响增强效果一般；自适应直方图均衡化通过局部对比度增强，显著改善了图像的局部细节^[37-38]，缓解背景融合度高干扰，目标边界清晰。使用 ESGE-RTDETR 对比检测效果，原始图像检测 F1 Score 为 0.818 5、伽马校正为 0.819 6、拉普拉斯锐化为 0.623 0、自适应直方图均衡化为 0.859 6，这表明自适应直方图均衡化有效提升了焦粉的精准度和召回率。

2.6 实际生产部署效果验证

为验证所提出 ESGE-RTDETR 模型在实际工业场景中的检测性能与部署适应性, 本文将模型部署于某大型钢铁企业的烧结车间焦粉粒度在线检测系统中, 开展工业现场验证测试。系统配置包括 2500 万像素工业相机 (4216×4 504 分辨率)、显卡配置 RTX 3060 (TensorRT 推理)、双侧 LED 补光、实时图像采集与处理模块等。在连续 3 日的运行测试中, 在传输皮带停止时通过漏筛获取实际焦粉粒径所占比例, 并在此时进行图像采集并处理, 完成实际粒径及所占比例标定。模型部署后, 由于现场对实时性要求较低, 采集间隔为 30 s, 平均推理时间为 62 ms/张 (约为 16 帧/s), 满足生产线“≥1 帧/s”的实时性要求。利用现场的 200 组数据, 将检测结果划分为 5 个区间, 分别统计人工标注数量与模型推理输出数量, 并据此计算检测准确率。最终 5 个区间平均检测准确率为 89.5%, 具体数据见表 4, 均优于企业设定的评估标准 (准确率不低于 85%)。相较于原人工每小时抽检方式, 系统可实现连续在线检测; 系统具备 24 h 稳定运行能力, 设备功率消耗约为 14.7 W, 满足车间环境对低功率消耗的要求, 具备良好的工业落地价值。

表 4 现场粒径分布所占比例及准确率

Table 4 On-site particle size distribution ratio and accuracy					
Particle size interval/mm	Number of manual annotations	Manual annotation Proportion/%	Number of model inferences	Model inference Proportion/%	Detection Accuracy/%
<0.5	5 612	7.03	4 910	6.79	87.5
[0.5, 1)	5 625	7.05	4 985	6.89	88.6
[1, 3)	41 780	52.33	38 050	52.67	91.0
[3-5]	13 640	17.09	12 460	17.26	91.3
>5	13 199	16.53	11 772	16.40	89.1
合计	79 856	100.0	72 177	100.0	—

3 结语

为进一步提高焦粉粒度的检测精度, 本文提出了基于边缘多尺度特征融合并结合稀疏注意力机制的检测模型 ESGE-RTDETR, 在 RT-DETR 基础上引入多尺度边缘特征提取结构以及 CNN-Transformer 混合主干网络与稀疏注意力机制, 提升了模型对复杂焦粉图像的检测能力。同时, 模型训练采用数据增强策略提高了模型的工程适应性。在实际生产过程中, 采用先进行图像增强再进行模型检测的整体流程, 进一步提高检测精度。在焦粉工业图像数据集上, ESGE-RTDETR 模型实现了 94.4%的检测准确率和 89.6%的召回率, mAP₅₀ 为 94.5%, 推理速度为 18 帧/s, 较原始 RT-DETR 模型分别提升 10.1 个百分点、14.1 个百分点、20.6 个百分点, 推理速度提升了 1.8 倍, 达到了工业焦粉检测对精度和实时性的综合要求。基于此, 对研究过程中遇到的问题进行了梳理, 并结合已有研究成果, 总结了相应的解决思路:

- 1) 针对焦粉检测场景, 由于各焦粉块边缘特征具有较强的表征性, 将边缘感知机制嵌入检测网络将有效提升模型对焦粉目标的感知能力及定位准确性。
- 2) 工业检测场景中普遍存在目标高密度堆叠的问题。引入稀疏注意力机制, 可以在不显著增加计算开销的同时, 有效提升对小目标及堆叠目标的检测性能。
- 3) 本文更多的是基于边缘信息进行检测识别, 所以若存在极端密集堆叠或严重遮挡样本场景, 则检测存在较高误检率, 下一步研究将聚焦在如何进一步提升极端场景下的检测性能上, 进一步提高焦粉检测准确性及稳定性。

参考文献:

[1] 欧大明, 孙骐, 沈红标, 等. 焦粉粒度对铁矿石烧结过程的影响[J]. 钢铁, 2008, 43 (10): 8. (OU D M, SUN Q, SHEN H B, et al. Effect of coke size on iron ore sintering[J]. Iron and Steel, 2008, 43 (10): 8.)

- [2] 樊君, 赵俊学, 陈元平, 等. 焦粉粒度对海鑫烧结固体燃料的影响[C]//第八届(2011)中国钢铁年会. 北京: 中国金属学会, 2011: 2819.
(FAN J, ZHAO J X, CHEN Y P, et al. Effect of coke breeze size on solid fuel consumption in Haixin sintering process[C]//The 8th (2011) China Steel Annual Conference. Beijing: The Chinese Society for Metals, 2011: 2819.)
- [3] 周明顺, 赵东明, 李建军, 等. 焦粉粒度分布对铁矿石烧结指标的影响[J]. 中国冶金, 2018, 28(2): 11. (ZHOU M S, ZHAO D M, LI J J, et al. Effects of size distribution of coke breeze on sintering process[J]. China Metallurgy, 2018, 28(2): 11.)
- [4] 刘建波, 张俊杰, 裴元东, 等. 焦粉粒级分布对烧结过程及烧结矿质量的影响[J]. 安徽工业大学学报(自然科学版), 2019, 36(4): 309.
(LIU J B, ZHANG J J, PEI Y D, et al. Effect of size distribution of coke powder on sintering process and sinter quality[J]. Journal of Anhui University of Technology (Natural Science), 2019, 36(4): 309.)
- [5] 董铭江, 王雅琳, 谭栩杰, 等. 基于自适应多尺度形态学的烧结焦粉粒度图像分割方法[C]//第35届中国过程控制会议. 三亚: 中国自动化学会过程控制专业委员会, 2024: 1404. (DONG M J, WANG Y L, TAN X J, et al. Image segmentation method of sintering coke breeze size based on adaptive multi-scale morphology[C]//The 35th China Process Control Conference. Sanya: Process Control Professional Committee of the Chinese Society of Automation, 2024: 1404.)
- [6] 袁君奇, 王雅琳, 谭栩杰. 基于图像处理的烧结燃料粒度检测方法研究[J]. 中国计量, 2024(4): 113. (YUAN J Q, WANG Y L, TAN X J. Study on granularity detection method of sintering fuel based on image processing[J]. China Metrology, 2024(4): 113.)
- [7] 李福民, 侯炬才, 刘颂, 等. 基于计算机视觉和 Re-Net 网络的烧结混合料粒度识别模型[J]. 钢铁研究学报, 2023, 35(11): 1347. (LI F M, HOU J C, LIU S, et al. Particle size identification model of sintering mixture based on computer vision and Re-Net network[J]. Journal of Iron and Steel Research, 2023, 35(11): 1347.)
- [8] 刘计尊. 钢铁物料粒度智能检测方法研究[D]. 秦皇岛: 燕山大学, 2023. (LIU J Z. Study on intelligent detection method of steel material granularity[D]. Qinhuangdao: Yanshan University, 2023.)
- [9] TARIQ M F, JAVED M A. Small object detection with YOLO: a performance analysis across model versions and hardware[DB/OL]. (2025-04-14) [2025-08-13]. <https://arxiv.org/abs/2504.09900>.
- [10] KELES M C, SALMANOGLU B, GÜZEL M S, et al. Evaluation of YOLO models with sliced inference for small object detection[DB/OL]. (2022-03-09) [2025-08-13]. <https://arxiv.org/abs/2203.04799>.
- [11] ZHU X, SU W, LU L, et al. Deformable DETR: deformable transformers for end-to-end object detection[DB/OL]. (2020-10-08) [2025-08-13]. <https://arxiv.org/abs/2010.04159>.
- [12] ZHAO Y A, LV W Y, XU S L, et al. DETRs beat YOLOs on real-time object detection[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 16965.
- [13] WANG X, XI B, XU H, et al. AgeDETR: attention-guided efficient DETR for space target detection[J]. Remote Sensing, 2024, 16(18): 3452.
- [14] CHEN J C, QIAN Y M, FURUKAWA Y S T. HEAT: holistic edge attention transformer for structured reconstruction[C]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, LA, USA: IEEE, 2022: 3856.
- [15] QIN X B, ZHANG Z C, HUANG C Y, et al. U2-net: going deeper with nested u-structure for salient object detection[J]. Pattern Recognition, 2020, 106: 107404.
- [16] 刘一民, 文姗姗, 梁叶, 等. 基于图像处理的生球团特征检测模型[J]. 钢铁, 2025, 60(6): 36. (LIU Y M, WEN S S, LIANG Y, et al. Detection model of green pellet characteristics based on image processing [J]. Iron and Steel, 2025, 60(6): 36.)
- [17] HOWARD A G, ZHU M, CHEN B, et al. MobileNets: efficient convolutional neural networks for mobile vision applications[DB/OL]. (2017-04-17) [2025-08-13]. <https://arxiv.org/abs/1704.04861>.
- [18] LI Y H, CHEN Y T, WANG N Y, et al. Scale-aware trident networks for object detection[C]//2019 IEEE/CVF International Conference on Computer Vision (ICCV). Seoul, Korea (South): IEEE, 2019: 6053.
- [19] TAN M X, PANG R M, LE Q V. EfficientDet: scalable and efficient object detection[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2020: 10778.
- [20] YANG Z Q, GUAN Q, ZHAO K E, et al. Multi-branch auxiliary fusion YOLO with re-parameterization heterogeneous convolutional for accurate object detection[C]//Chinese Conference on Pattern Recognition and Computer Vision. Singapore: Springer Nature Singapore, 2025: 492.
- [21] RAHMAN M M, MUNIR M, MARCULESCU R. EMCAD: efficient multi-scale convolutional attention decoding for medical image segmentation[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 11769.
- [22] SUN P Z, ZHANG R F, JIANG Y, et al. Sparse R-CNN: end-to-end object detection with learnable proposals[C]//2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville, TN, USA: IEEE, 2021: 14449.

- [23]SU L, MA X, ZHU X, et al. Can we get rid of handcrafted feature extractors? SparseViT: nonsemantics-centered, parameter-efficient image manipulation localization through spare-coding transformer[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2025, 39 (7): 7024.
- [24] LIU C, WANG K G, LI Q, et al. Powerful-IoU: more straightforward and faster bounding box regression loss with a nonmonotonic focusing mechanism[J]. Neural Networks, 2024, 170: 276.
- [25] ZHANG H, ZHANG S. Focaler-IoU: more focused intersection over union loss[DB/OL]. (2024-01-19) [2025-08-13].
<https://arxiv.org/abs/2401.10525>.
- [26] LIU W, ANGUELOV D, ERHAN D, et al. SSD: single shot MultiBox detector[C]//Computer Vision – ECCV 2016. Cham: Springer International Publishing, 2016: 21.
- [27] GIRSHICK R. Fast R-CNN[C]//2015 IEEE International Conference on Computer Vision (ICCV). Santiago, Chile: IEEE, 2015: 1440.
- [28] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//2017 IEEE International Conference on Computer Vision (ICCV). Venice, Italy: IEEE, 2017: 2999.
- [29] JOCHER G, CHAURASIA A, QIU J. YOLOv5: a family of object detection architectures and models [DB/OL]. (2020-06-25) [2025-09-08].
<https://github.com/ultralytics/yolov5>.
- [30] VARGHESE R, M. S. YOLOv8: a novel object detection algorithm with enhanced performance and robustness[C]//2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS). Chennai, India: IEEE, 2024: 1.
- [31] WANG A, CHEN H, LIU L, et al. YOLOv10: real-time end-to-end object detection[J]. Advances in Neural Information Processing Systems, 2024, 37: 107984.
- [32] ULTRALYTICS. YOLOv11 [DB/OL]. (2024-10-12) [2025-09-08]. <https://github.com/ultralytics/ultralytics>.
- [33] TIAN Y, YE Q, DOERMANN D. YOLOv12: attention-centric real-time object detectors[DB/OL]. (2025-02-18) [2025-08-13].
<https://arxiv.org/abs/2502.12524>.
- [34] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]//Computer Vision – ECCV 2020. Cham: Springer International Publishing, 2020: 213.
- [35] 蔡美芳, 万里勇. 基于自适应 Gamma 校正的红外图像增强算法[J]. 光学技术, 2022, 48 (4): 486. (CAI M F, WAN L Y. Infrared image enhancement algorithm based on adaptive gamma correction[J]. Optical Technique, 2022, 48 (4): 486.)
- [36]王明印, 韦群, 何国林, 等. 基于拉普拉斯图像锐化算法研究[C]//中国电子学会第十六届信息论学术年会. 北京: 中国电子学会信息论分会, 2009: 476. (WANG M Y, WEI Q, HE G L, et al. Research on image sharpening algorithm based on Laplacian[C]//The 16th Annual Conference on Information Theory of the Chinese Electronics Society. Beijing: China Electronics Society Information Theory Branch, 2009: 476.)
- [37] SHARMA R, KAMRA A. A review on CLAHE based enhancement techniques[C]//2023 6th International Conference on Contemporary Computing and Informatics (IC3I). Gautam Buddha Nagar, India: IEEE, 2023: 321.
- [38]聂丰英, 万里勇. 等分直方图均衡和高频强化的低光照图像增强[J/OL]. 计算机科学与探索: 1. (2025-04-22) [2025-08-13].
<https://link.cnki.net/urlid/11.5602.tp.20250422.1104.002>. (NIE F Y, WAN L Y. Low-light image enhancement based on equalized histogram and high-frequency enhancement[J]. Computer Science and Exploration: 1. (2025-04-22) [2025-08-13].
<https://link.cnki.net/urlid/11.5602.tp.20250422.1104.002>.)