

高嵩, 杨景峰, 许德龙. 基于改进 YOLO v10 的牛只种类与行为识别 [J]. 华南农业大学学报, 2025, 46(6): 832-842.
GAO Song, YANG Jingfeng, XU Delong. Cattle species and behavior identification based on improved YOLO v10[J]. Journal of South China Agricultural University, 2025, 46(6): 832-842.

基于改进 YOLO v10 的牛只种类与行为识别

高 嵩¹, 杨景峰¹, 许德龙²

(1 内蒙古民族大学 动物科技学院, 内蒙古 通辽 028000; 2 内蒙古师范大学 计算机科学技术学院, 内蒙古 呼和浩特 010000)

摘要:【目的】实现精准养殖中牛只活动状态的实时监控, 助力养殖户及时识别牛只异常行为, 并为牛只的饲料分配、疾病监测及繁殖管理提供支持。【方法】本研究将 YOLO v10 模型改进为 LDCM-YOLO v10n, 并基于此对牛只种类及行为进行检测。具体改进如下: 首先, 在 YOLO v10 的 Backbone 端采用 C2f-LSKA 结构, 以增强模型的特征提取能力; 其次, 引入 DySample 上采样算子, 旨在有效捕捉图像的细微变化与密集语义信息, 规避传统上采样方法中存在的图像模糊及感受野受限问题; 同时, 将 YOLO v10 中的 PSA 替换为 CloFormer 注意力机制, 从而更精准地区分牛只特征与背景噪声, 并提升小目标识别精度; 此外, 加入多尺度空洞注意力机制 (Multi-scale dilated attention mechanism, MSDA), 以增强感受野范围内各尺度的聚合语义信息, 同时有效减少自注意力机制的冗余; 最后, 采用 Inner-IoU 损失函数, 解决普通 IoU 损失函数无法根据目标尺度灵活调整损失计算的问题。【结果】在牛只行为数据集上, LDCM-YOLO v10n 模型的 mAP@0.50 较 YOLO v3、YOLO v5、YOLO v6、YOLO v8n、YOLO v9 及 YOLO v10n 模型分别提升 15.4、10.7、12.0、8.4、7.9 和 5.1 个百分点; 在牛只种类数据集上, LDCM-YOLO v10n 模型的 mAP@0.50 较上述模型分别提升 32.4、11.9、10.4、9.5、9.0 和 6.4 个百分点。【结论】LDCM-YOLO v10n 模型在牛只行为与种类检测中表现优异, 为精准养殖提供了强有力的技术支撑。

关键词: 卷积神经网络; 牛; 图像识别; YOLO v10 模型; 人工智能

中图分类号: TP183; S818.9

文献标志码: A

文章编号: 1001-411X(2025)06-0832-11

Cattle species and behavior identification based on improved YOLO v10

GAO Song¹, YANG Jingfeng¹, XU Delong²

(1 College of Animal Science and Technology, Inner Mongolia Minzu University, Tongliao 028000, China; 2 College of Computer Science and Technology, Inner Mongolia Normal University, Hohhot 010000, China)

Abstract: 【Objective】To achieve real-time monitoring of cattle activity status in precision breeding, help farmers promptly identify cattle abnormal behaviors, and provide support for cattle feed allocation, disease monitoring, and breeding management. 【Method】This study modified the YOLO v10 model into LDCM-YOLO v10n, and based on this, conducted detection on cattle species and behaviors. The specific improvements were as follows: First, the C2f-LSKA structure was adopted in the Backbone of YOLO v10 to enhance the

收稿日期: 2025-03-20 网络首发时间: 2025-09-09 10:25:50

首发网址: <https://link.cnki.net/urlid/44.1110.s.20250908.1621.004>

作者简介: 高 嵩, E-mail: 2764026974@qq.com; 通信作者: 杨景峰, 主要从事肉牛养殖模式研究, E-mail: yangjf@imn.edu.cn

基金项目: 内蒙古自治区科技计划 (2022YFSJ0001); 内蒙古自治区自然科学基金 (2023ZD16)

feature extraction capability of the model. Second, the DySample upsampling operator was introduced to effectively capture subtle changes in images and dense semantic information, avoiding the problems of image blurring and limited receptive field in traditional upsampling methods. Meanwhile, the PSA of YOLO v10 was replaced with the CloFormer attention mechanism to better distinguish cattle features from background noise and accurately identify small targets. In addition, the multi-scale dilated attention mechanism (MSDA) was added to enhance the aggregated semantic information at various scales within the receptive field and effectively reduce the redundancy of the self-attention mechanism. Finally, the Inner-IoU loss function was used to address the issue that the ordinary IoU loss function could not flexibly adjust loss calculation according to the target scale.

【Result】 On the cattle behavior dataset, the mAP@0.50 of the LDCM-YOLO v10n model increased by 15.4, 10.7, 12.0, 8.4, 7.9 and 5.1 percentage points compared with YOLO v3, YOLO v5, YOLO v6, YOLO v8n, YOLO v9 and YOLO v10n model, respectively. Meanwhile, on the cattle species dataset, the mAP@0.50 of the LDCM-YOLO v10n model increased by 32.4, 11.9, 10.4, 9.5, 9.0 and 6.4 percentage points compared with the aforementioned models, respectively. **【Conclusion】** The LDCM-YOLO v10n model demonstrates excellent performance in cattle behavior and species detection, providing a strong technical support for precision breeding.

Key words: Convolutional neural network; Cattle; Image recognition; YOLO v10 model; Artificial intelligence

近年来,畜牧业在我国农业经济中的重要性不断增强,已成为农业的支柱产业之一^[1]。在此趋势下,精准化养殖模式逐步取代了传统的小规模分散养殖,这不仅标志着我国畜牧业生产方式的重大转型,也反映了产业组织结构的优化升级^[2]。与此同时,科技正以前所未有的速度发展,尤其是计算机技术和互联网技术的深度融合,已在全球经济中形成了一个高度互联的网络体系^[3]。“互联网+”作为一种创新的发展模式,对生产与生活方式产生了深刻的影响,并在推动传统产业的转型升级中扮演了关键角色^[4]。因此,将互联网技术与畜牧业相融合,具有广泛的研究前景。

动物的行为模式与其生理健康状况及周围环境因素之间存在紧密的联系。因此,运用行为分析技术来评估动物福利状态已成为一种简便且有效的常规方法^[5]。牛养殖业是畜牧业领域的一个重要组成部分,对牛实现精准养殖的核心在于对其个体进行详尽的信息收集和行​​为特征的智能化监测。但是,利用信息技术对牛群体进行持续的自动化监控,是精准养殖过程中需要重点突破的技术难题之一。

传统的动物行为检测及动物识别方法主要依赖人工观察,易引起应激反应,并且存在主观性强、效率低下、数据采集不连续和难以实时监控等缺点^[6-7]。深度学习技术因可捕捉、提取数据中复杂且层次化的自动特征^[8]、灵活调整架构和参数配置^[9]、从原始数据直接映射到最终结果^[10]等优点,适用于动物行为检测和动物识别。

在动物行为检测研究中,王少华等^[11]提出了一种基于 YOLO v3 的奶牛发情识别方法,在 YOLO v3 模型的特征提取网络中引入 DenseBlock 结构^[12],提升模型在复杂环境中的识别精度和速度,从而满足实时准确识别奶牛发情行为的需求。曹天一等^[13]提出了一种基于 YOLO v5s 的养殖场景下的牛识别方法,通过对 YOLO v5s 模型结构进行适配,优化 Backbone 网络的特征提取能力、改进 Head 网络的检测效果,提高了模型对牛行为的检测精度。袁宇翔等^[14]提出了一种基于 YOLO v7 的奶牛行为识别方法,通过将 BConv、MP、CAT 和 RAP 等模块融入其头部层,提高了 YOLO v7 网络头部层的整体性能,实现了对奶牛进食、躺卧、站立和行走等行为的高精度识别。付辰伏等^[15]提出了一种基于 YOLO v8 的牛只行为识别和跟踪方法,改进了 YOLO v8 网络中的 C2f 模块,将 FasterNet Block 嵌入其中,形成新的 C2f-faster 结构,显著提升了牛只行为识别的准确率和多目标跟踪的稳定性。

动物种类识别检测任务中,冯子懿^[16]提出一种基于改进 YOLO v7 的牛只种类识别与行为检测方法,通过在 YOLO v7 的 Head 部融入自注意力机制和优化损失函数,显著提升了模型的检测精度与效率。李章辉^[17]提出了一种基于深度学习的动物种类与身份识别方法,通过将 SC 注意力机制嵌入 GoogLeNet 模型中,提升了动物种类识别的准确率和模型鲁棒性。田小路等^[18]提出了基于卷积神经网络 (Convolutional neural network, CNN) 的宠物狗种类识别方法,利用 CNN 的卷积层自动对图像进

行特征提取, 识别准确率远高于传统方法。Xie 等^[19]提出了一种基于 YOLO v5 算法的空中热成像中大型哺乳动物种类识别的方法, 通过调整卷积层和全连接层的结构, 显著提升了无人机热成像图像中大型哺乳动物种类识别的精确度与处理效能。

这些研究充分说明 YOLO 算法适用于动物行为检测以及动物种类识别检测。因此本研究采用 YOLO 系列中的 YOLO v10 算法, 通过替换特征提取模块, 融合注意力机制, 调整上采样方式, 引入多尺度空洞注意力机制^[20](Multi-scale dilated attention mechanism, MSDA) 以及更改损失函数, 以期提升模型对牛只行为和种类识别的准确率。

1 材料与方法

1.1 数据采集

研究所用图片采集自内蒙古自治区通辽市科尔沁左翼后旗新牛畜牧科技有限公司第六牧场。采集设备为 Iphone15pro, 分辨率为 2556 像素×1179 像素, 共筛选 10000 多张照片, 其中, 用于牛只行为检测照片 7000 多张, 用于牛只种类识别照片 3000 多张, 图片在 2024 年 5 月和 12 月不同时间段采集, 包含牛只 583 头, 涵盖晴天、阴天、雪天、牛舍内、牛舍外等多种环境。随后对这些照片进行处理, 通过几何变换 (通过翻转改变图像方向, 裁剪调整内容范围, 旋转适应不同姿态, 平移模拟目标位置变化等)、颜色变换 (通过改变图像的亮度值, 改变图像中不同颜色或灰度之间的差异程度, 改变图像中颜色的鲜艳程度等)、噪声添加 (通过在图像中添加符合高斯分布的随机噪声或者在图像中随机将一些像素点的值设置为最大值或最小值等) 等方

法进行数据增强, 最终将总图片扩展为 14210 张, 其中牛只行为图片 9210 张, 牛只种类图片 5000 张。在行为检测任务中, 除了选取牛只放牧、行走、卧躺、站立等日常行为外, 还加入了发情 (爬跨) 行为, 其中放牧 2132 张, 行走 1852 张, 卧躺 2254 张, 站立 1947 张, 发情 1025 张。将牛只行为图片按数量 8:1:1 划分为训练集、测试集和验证集, 分别为 7368、921 和 921 张。

在种类识别任务中, 依据毛色、花纹等特性将牛只分为荷兰斯坦牛、安格斯牛、海福特牛、西门塔尔牛与娟山牛 5 类, 其中, 海福特牛最多, 1274 张, 其次是西门塔尔牛, 1028 张, 荷兰斯坦牛 935 张, 安格斯牛 920 张, 娟山牛 843 张。同样将牛只种类图片按照数量 8:1:1 划分为训练集、测试集和验证集, 分别为 4000、500 和 500 张。

1.2 数据预处理

本研究将采集到的牛只行为和种类识别图片保存为 jpg 格式, 并使用 Make-sense 软件对其进行标注, 标注的原则为目标框必须框住整个目标物体, 不能有遗漏和重叠; 目标框应与目标物体尽可能接近, 但不能与目标物体重合; 目标框的宽度和高度应为正数, 不能为 0 或负数。标注完成后, 导出与目标数据集对应的标注集文件。

1.3 YOLO v10

目前, YOLO v10^[21] 是 YOLO 系列的最新研究成果。如图 1 所示, YOLO v10 由主干网络 (Backbone)、颈部 (Neck)、头部 (Head) 和特殊模块组成, Backbone 采用增强版的 CSPNet, 通过 3×3 卷积核提取特征, 并引入残差连接和 SCDowm 模块进行空间和通道下采样。SPPF 模块对特征图进行多尺度




图 1 YOLO v10 结构图

Fig. 1 YOLO v10 structure diagram

池化拼接^[22],而 PSA 模块则以较小的计算成本融入全局学习能力。Neck 部分采用自下而上和自上而下的特征融合,通过上采样模块扩大特征图尺寸,并利用 Concat 模块融合低级和高级语义信息。Head 端检测器由卷积层和全连接层负责目标定位、分类识别和边界框预测,并采用轻量级分类 Head 以提升效率。针对牛只的目标与行为检测,研究选取了 YOLO v10 模型,相比于先前的 YOLO v3、YOLO v5、YOLO v6、YOLO v8n、YOLO v9 模型,YOLO v10 在平衡计算效率与检测精度方面取得了显著的进步。具体而言,YOLO v10 在保持与 YOLO 系列模型相似或更优的平均精度 (Average precision, AP) 的同时,大幅减少了模型参数数量和每秒浮点运算次数 (Floating point operations per second, FLOPS),从而实现了更优的计算效率-精度平衡。本试验采用的 YOLO v10n 是 YOLO v10 系列中的一个轻量级版本,专为资源受限的环境设计,可在保持一定精度的前提下,尽可能减小模型尺寸和计算量。相较于 YOLO v10 的其他版本,YOLO v10n 更加注重模型的轻量化和在资源受限设备上的高效运行。

1.3.1 特征提取 C2f-LSKA 在牛舍中,牛只的活动空间有限,且背景复杂,牛只之间的遮挡现象较为普遍。此外,在恶劣天气条件下,摄像设备的镜头容易附着水滴或尘土,同时手持设备的晃动可能导致画面模糊^[23]。这些因素可能会降低图像质量,从而导致卷积神经网络在提取图像特征时引入冗余信息和噪声,进而影响牛只行为和种类识别的准确性。

Yolo v10 模型中 C2f 结构如图 2 所示,其不足是很难消除引入的冗余特征,且计算复杂程度高。Zhang 等^[24]、Gao 等^[25]和 Chen 等^[26]分别利用逐点卷积 (Pointwise convolution, PWConv)、混合深度卷积 (Mixed depthwise convolution, MDC)、部分卷积 (Part convolution, PConv) 来提取空间特征,均存在感受野受限、特征融合不足等缺点,同时在减少 FLOPs 的过程中,会引入更多的内存访问操作。Lau 等^[27]提出了一个大可分离注意力 (Large separable kernel attention, LSKA) 卷积,将 depthwise 卷积层的 2D 卷积核分解为串联的 1D 卷积核。每个 LSKA 都有 2 个 DW_Conv 层,后面连接 2 个 DW_D_Conv 层和 1 个 Conv 层,结构如图 3 所示,它们通过一系列的深度可分离卷积和逐点卷积操作,实现了对输入特征图的高效特征提取和自适应加权。基于 LSKA 构造的视觉注意网络 (Visual




图 2 C2f 结构示意图

Fig. 2 C2f structure diagram




图 3 LSKA 结构图

Fig. 3 LSKA structure diagram

attention network, VAN) 显著降低了计算复杂性、减少了内存足迹 (Footprints),在目标识别、目标检测等任务中表现出优异的性能。

本研究对 YOLO v10 中的 C2f 模块进行了改进,将 LSKA 模块嵌入 C2f 模块,形成新的结构 C2f-LSKA,具体来说,是将 C2f 中的紧凑反转块 (Compact inverted block, CIB) 模块替换为 LSKA 模块,这种结合方式充分利用了 C2f 的特征融合能力和 LSKA 的高效特征提取能力,为模型提供了更丰富的特征表示,有助于提高检测精度和鲁棒性,其结构如图 4 所示。

1.3.2 DySample 上采样 在 YOLO v10 架构中,上采样层主要采用最近邻插值法 (Nearest neighbor interpolation, NNI)。该方法仅依赖最近邻像素的值,难以有效捕捉图像中的细微变化和丰富的语义信息,从而导致图像出现一定程度的失真现象。特别是在对图像进行放大操作时,图像容易模糊化,且其感受野相对较小。基于此本文提出一种超轻量





图 4 C2f-LSKA 结构图

Fig. 4 C2f-LSKA structure diagram

级且高效的动态上采样算子^[28], 其核心思想是将上采样过程重新定义为点采样 (Point sampling), 通过学习输入特征图中的采样点坐标来实现上采样。

DySample 的流程如图 5 所示, 首先, 使用一个 1×1 卷积层处理输入特征图, 生成每个采样点的偏移量。这些偏移量表示采样点相对于原始位置的移动方向和距离。为了防止偏移量过大导致采样点超出特征图的有效范围, DySample 还引入了动态范围因子, 动态范围因子通过另一个 1×1 卷积层生成, 并经过 Sigmoid 激活函数将其值限制在 $[0, 1]$ 范围内, 再乘以一个缩放因子, 从而对偏移量进行约束, 确保采样点的移动在合理范围内。随后, DySample 利用 Grid sample 函数进行特征重组。具体来说就是生成一个网格, 来表示原始特征图中每个像素的位置。然后, 根据偏移量调整这些位置, 生成最终的采样点坐标。这些坐标被归一化到 $[-1, 1]$ 范围内, 以适配 Grid sample 函数的要求。Grid sample 函数通过双线性插值, 根据偏移后的采样点坐标从输入特征图中获取像素值, 从而生成上采样后的高分辨率特征图。



H 、 W 是特征图的垂直维度尺寸和水平维度尺寸, C 是隐含在特征图中的通道维度, W_s 是对 W 的缩放因子, x 、 x' 是变换前、后的采样位置, $2g$ 表示采样步长, H_s 为球谐权重。

H and W are the height and width of the feature map, C is the channel dimension implied in the feature map, W_s is the scaling factor of W , x and x' are the sampling positions before and after the transformation, $2g$ represents the sampling step, and H_s is the spherical harmonic weight.


图 5 DySample 流程图

Fig. 5 DySample flowchart

1.3.3 CloFormer 注意力机制 在牛目标检测和种类识别任务中, 牛的背景可能非常复杂 (如野外、养殖场等), YOLO v10 中的 PSA 注意力模块虽然能够捕获全局信息, 但在复杂背景中, 它可能无法有效区分牛的特征与背景噪声, 从而影响检测和识别的准确性。并且牛的个体较小, 在图像中占据比例较低, PSA 可能无法精准定位和识别这些小目标。基于此我们引入了如图 6 所示的 CloFormer 注意力机制^[29]。

CloFormer 注意力机制引入了 AttnConv 模块, 该模块结合了卷积操作的共享权重和注意力机制的上下文感知权重。这种设计使得引入 CloFormer 的模型能够高效地捕捉局部信息, 同时相比传统的卷积操作, AttnConv 能够更好地处理图像中不同位置之间的关系。在 SPFF 后将 PSA 换成 CloFormer

注意力机制, 能够更好地区分牛的特征与背景噪声, 并能够精准识别小目标。同时 CloFormer 注意力机制与 DySample 相结合, 有效支持了模型对低分辨率特征图的加权关注, 其通过在低分辨率阶段对关键信息进行聚焦, 避免了高分辨率特征图中的复杂计算, 从而显著降低了计算复杂度。同时, 这种设计能够更精准地定位目标对象 (如牛只), 进一步提升模型的整体运行效率。CloFormer 主要由 3 个阶段组成, 分别是 Conv Stem、Clo Block 和 ConvFFN。Conv Stem 作为模型的输入模块通过卷积操作对输入图像进行预处理, 提取初始的特征表示, 为后续的特征提取模块提供基础。随后利用 Clo Block 对特征进行局部和全局信息的融合, 分为局部分支和全局分支。局部分支使用 AttnConv 模块, 结合了卷积的共享权重和注意力机制的上下文



H 、 W 是特征图的垂直维度尺寸和水平维度尺寸, $N_1 \sim N_4$ 代表对各阶段中模块的重复次数, s 为步长。

H and W are the height and width of the feature map, $N_1 \sim N_4$ represent the number of repetitions for module in corresponding stages, s represents stride.


图6 CloFormer 注意力机制

Fig. 6 CloFormer attention mechanism

感知权重,能够高效地捕捉高频局部信息;全局分支通过池化操作对关键信息进行下采样,然后执行标准的注意力操作,提取低频全局信息。接下来利用 ConvFFN 模块增强特征的局部感知能力和整体表达能力,并通过多阶段的 Clo Block 和 ConvFFN 逐步提取分层特征,最后使用全局平均化和全连接层得到最终的预测结果。如图 6 所示, CloFormer 注意力机制在单个阶段内并行 2 条路径: Local 支路先用 3×3 DW_Conv(步长为 1) 提取局部空间特征,经 Tanh 门控、批归一化 (Batch normalization, BN) 与可选池化后,由 1×1 FC 恢复通道; Global 支路先经 LayerNorm 与 1×1 FC 降维,再经 CELU、 3×3 DW_Conv 处理后拆分为查询 (Q)、键 (K) 和值 (V),在通道维度执行 softmax 注意力并加重权,随后升维还原。两路特征逐元素相加融合,必要时通过步长为 2 的 DW_Conv 或池化完成下采样,输出进入下一阶段。

1.3.4 MSDA YOLO v10 模型接收输入图像,通过 Backbone 提取多层次特征,生成不同尺度的特征图,并采用上采样和拼接操作融合这些特征图,增强对不同尺寸目标的检测能力。随后,融合后的特征图再经过 Head 进行目标检测、分类,得到最终结果。然而在牛舍场景下进行牛只种类识别与行为检测任务时,由于不同种类牛特征不显著及牛多种类型的行为相似,不便于区分,所以检测需要更高精度,但 YOLO v10 并不能很好地解决这一挑战。

因此引入 MSDA 来提高检测精度, MSDA 结构如图 7 所示。MSDA 采用多头设计并能够模拟小范围内局部和稀疏的图像块交互。它首先将输入特征图通过线性变换生成 Q 、 K 和 V ,然后将这些特征送入由多个并行头组成的多头注意力结构中。每个头利用不同扩张率 (r) 的滑动窗口空洞注意力对特征进行处理,以捕获不同尺度的信息。处理后的特征在各头之间被拼接 (Concat) 起来,形成综合多尺度特征表示。最后,这个拼接后的特征通过一个线性层进一步处理,以完成特征融合并为后续的任务 (如分类或检测) 提供增强特征表示。该方法能够关注感受野内不同尺度的聚合语义信息,并有效减少自注意力机制中的冗余,提升目标检测精度,



Q 、 K 、 V 分别代表查询、键和值; r 表示扩张率。

Q 、 K and V represent query, key and value respectively. r indicates dilation rate.

图7 MSDA 结构图

Fig. 7 MSDA structure diagram

同时避免复杂操作和额外计算开销。

1.3.5 Inner-IoU 损失函数 YOLO v10 采用 IoU 作为边框回归损失函数,但其对小物体的检测不够敏感并缺乏对不同类别或框尺度变化的适应性,在复杂场景下可能会降低检测精度。因此,本文采用 Inner-IoU^[30] 作为损失函数,通过引入尺度因子(ratio)来调整辅助边框的尺度,并在不同数据集和检测器中计算损失。通过精准的定位和灵活的损失计算,Inner-IoU 在牛只行为检测和种类识别中显著提高了检测精度、加速了模型收敛。其公式如下所示:

$$\text{IoU}^{\text{inner}} = \frac{\text{inter}}{\text{union}}, \quad (1)$$

$$\text{inter} = \left[\min(b_l^{\text{gt}}, b_l) - \max(b_l^{\text{gt}}, b_l) \right] \times \left[\min(b_b^{\text{gt}}, b_b) - \max(b_b^{\text{gt}}, b_b) \right], \quad (2)$$

$$\text{union} = w^{\text{gt}} h^{\text{gt}} (\text{ratio})^2 + wh(\text{ratio})^2 - \text{inter}, \quad (3)$$

式(3)定义了交并比(IoU),它是交集面积(inter)与并集面积(union)的比值。IoU是一个衡量2个边框重叠程度的指标,取值为[0, 1],值越接近1,表示2个边框的重叠程度越大。式(4)计算了2个边框的交集面积,其中 b_l^{gt} 和 b_r^{gt} 分别是真实边框的左、右边界, b_l 和 b_r 是预测边框的左、右边界。同样 b_t^{gt} 和 b_b^{gt} 分别是真实边框的上、下边界, b_t 和 b_b 是预测边框的上、下边界。式(5)表示2个边框的并集面积,其中, w^{gt} 和 h^{gt} 分别是

真实边框的宽度和高度, w 和 h 是预测边框的宽度和高度。ratio 是一个尺度因子,用于调整边框的大小。

2 结果与分析

2.1 试验平台与评价指标

试验在 Windows 10 系统上进行,使用 AutoDL 算力云平台,编程语言为 Python 3.8,深度学习框架为 PyTorch 1.10, Cuda 版本为 11.3。硬件配置包括 Intel Xeon Gold 6430 处理器、80 GB 内存和 RTX 4090D 显卡。试验使用牛只行为检测与种类识别数据集,将改进的 YOLO v10n 模型(LDCM-YOLO v10n)(图 8)与 YOLO v3、YOLO v5、YOLO v6、YOLO v8n、YOLOv9 和 YOLO v10 等 6 个目标检测模型进行比较,设置输入图像尺寸为 640 像素×640 像素,批量大小为 32,学习率设为 0.01,模型训练 100 轮,确保训练收敛后,再对数据集进行评估。在牛只行为检测与种类识别任务中,采用查准率(Precision, P)、查全率(Recall, R)和平均精度均值(Mean average precision, mAP)作为评估指标。其中, mAP 分别在 IoU 阈值为 0.50(mAP@0.50)和 0.95(mAP@0.95)时评价模型的精确度。对于 P 、 R 和 mAP 而言,数值越高表示检测结果越精确。

2.2 缩放因子的选择

本研究对动态范围的缩放因子选择进行了消融试验,在牛只行为检测与种类识别数据集上,以 LDCM-YOLO v10n 模型为基础,测试了不同缩放因子 0.1、0.3、0.5、0.7、1.0 对模型性能的影响,结果




图 8 LDCM-YOLO v10n 模型结构图

Fig. 8 LDCM-YOLO v10n model structure diagram

如表 1 所示。由表 1 可知,缩放因子为 0.5 时,模型性能最好。我们分析,缩放因子在 0.5 时能够在保证采样点偏移量合理范围的前提下,较好地捕捉图像中的细微变化和丰富语义信息,使上采样后的图像具有较高的质量,从而提升模型在牛只行为检测和种类识别任务中的性能。如果缩放因子过小,比如 0.1 和 0.3,那么动态范围因子对偏移量的约束会过于严格,可能会限制模型对图像中细微变化的捕

捉能力,导致采样点的偏移无法充分适应图像中的复杂特征,影响模型对图像的上采样效果和特征提取能力。而如果缩放因子过大,比如 0.7 和 1.0,那么动态范围因子对偏移量的约束能力就会减弱,无法有效抑制偏移量的增长,进而导致采样点超出特征图的有效范围,从而引发采样错误和图像失真等问题。

表 1 LDCM-YOLO v10n 缩放因子消融试验
Table 1 LDCM-YOLO v10n model scaling factor ablation experiments

%

缩放因子 Scaling factor	牛只种类 Cattle species			牛只行为 Cattle behavior		
	<i>P</i>	<i>R</i>	mAP@0.50	<i>P</i>	<i>R</i>	mAP@0.50
0.1	89.1	86.2	95.4	90.5	90.1	94.1
0.3	89.5	86.9	95.8	91.1	90.7	94.6
0.5	90.4	87.5	96.3	91.6	91.2	95.2
0.7	89.9	87.1	96.1	91.3	90.5	94.5
1.0	89.3	86.0	95.2	90.7	90.3	93.9

2.3 牛只行为识别试验

本方法使用牛只行为数据集,分别训练了 YOLO v3、YOLO v5、YOLO v6、YOLO v8n、YOLO v9、YOLO v10 和 LDCM-YOLO v10n 模型,结果如表 2 所示,相比于 YOLO v3、YOLO v5、YOLO v6、YOLO v8n、YOLOv9 模型,YOLO v10 的 *P* 提升了 17.0、10.4、7.1、6.5、1.2 个百分点,*R* 提升了 12.8、7.1、6.9、4.7、0.9 个百分点,mAP@0.50 提升了 10.3、5.6、6.9、3.3、2.6 个百分点,mAP@0.95 提升了 15.7、11.2、9.5、11.2、5.3 个百分点。这说明 YOLO v10 模型性能更强,更适合做牛只行为检测的基线模型。LDCM-YOLO v10n 模型的 *P* 为 91.6%,*R* 为 91.2%,mAP@0.50 为 95.2%,mAP@0.95 为 80.2%,比其他 6 个模型性能更优。

表 2 不同模型对牛只行为识别的试验结果
Table 2 Experimental results of different models for cattle behavior recognition

%

模型 Model	<i>P</i>	<i>R</i>	mAP@0.50	mAP@0.95
YOLO v3	70.4	69.3	79.8	58.9
YOLO v5	77.0	75.0	84.5	63.4
YOLO v6	80.3	75.2	83.2	65.3
YOLO v8n	80.9	77.4	86.8	63.6
YOLO v9	86.2	81.2	87.3	69.5
YOLO v10n	87.4	82.1	90.1	74.6
LDCM-YOLO v10n	91.6	91.2	95.2	80.2

为验证 LDCM-YOLO v10n 模型的有效性,本文对牛只行为的 mAP@0.50 进行分析,设计了 C2f-LSKA、DySample、CloFormer、MSDA 等改进方法的消融试验。结果(表 3)显示,YOLO v10n 模型在牛只行为识别任务中展现了较为优异的分类性能,尤其在识别站立、躺卧和跑动行为时,其 mAP@0.50 分别达到了 96.2%、93.1% 和 97.1%。然而,在识别放牧以及发情行为时,模型的精度相对较低,分别为 75.7% 和 88.5%。深入分析发现,牛只的躺卧行为表现为四肢及身体完全接触地面,其特征表现较为显著且独特,因此在识别过程中具有较高的准确率。相比之下,站立、跑动、发情和放牧等行为均以四肢着地为基础姿态,行为特征在视觉表现上较为相似,站立行为主要表现为牛的四肢直立,头部姿态相对稳定,而跑动行为则伴随着四肢的快速交替运动,身体姿态较为动态。发情行为通常伴随着牛的头部频繁摆动、身体姿态的频繁变化以及与其他牛只的互动,其特征较为复杂且不固定。放牧行为则表现为牛在一定区域内自由活动,行为特征介于跑动和站立之间,具有一定的动态性和随机性。由于站立和发情行为在头部姿态和身体动作上存在一定的相似性,尤其是在头部的摆动频率和幅度上,模型在识别时容易将两者混淆。此外,跑动和放牧行为虽然在动态性方面有明显差异,但由于两者均涉及四肢的运动,且缺乏显著的区别特征,因此也容易导致识别精度下降。相比之

下, 躺卧行为由于其独特的身体姿态和稳定的特征表现, 在模型识别中具有较高的准确率。

后续试验中, 通过引入不同的模块, 模型的性

能得到了逐步提升, 特别是在对行为特征进行更细致的分析和处理后, 模型在识别发情和放牧行为时的性能提升较为明显。

表 3 不同模型在牛只行为识别消融试验中的 mAP@0.50

Table 3 The mAP@0.50 of different models in ablation experiments on cattle behavior recognition

%

模型 Model	放牧 Graze	发情 Rut	跑动 Run	躺卧 Lie-down	站立 Stand	均值 Average
YOLO v10n	75.7	88.5	97.1	93.1	96.2	90.1
YOLO v10n+C2f-LSDA	86.3	88.3	96.6	94.0	96.1	92.2
YOLO v10n+DySample	83.6	89.9	97.3	94.6	96.1	92.3
YOLO v10n+CloFormer+MSDA	88.8	89.4	97.7	96.2	97.6	93.9
YOLO v10n+Inner-IoU	88.9	92.0	97.9	95.2	97.1	94.2
LDCM-YOLO v10n	90.0	91.8	98.1	97.6	98.7	95.2

如表 3 所示, YOLO v10+C2f-LSKA 的 mAP@0.50 相较于 YOLO v10 提升了 2.1 个百分点, 在 YOLO v10 中加入 DySample 后 mAP@0.50 提升了 2.2 个百分点, 同时加入 CloFormer 和 MSDA 后 mAP@0.50 提升了 3.8 个百分点。结合之前的模块, 引入 Inner-IoU 损失函数, 构建 LDCM-YOLO v10n 模型后, 牛只行为 mAP@0.50 达到了 95.2%。综上所述 LDCM-YOLO v10n 模型在牛只行为识别中表现出色。

2.4 牛只种类识别试验

本方法使用牛只种类数据集, 分别训练了上述模型和 LDCM-YOLO v10n 模型, 通过试验对比牛只种类识别的 P 、 R 、mAP@0.50 和 mAP@0.95 来评估模型的性能, 结果如表 4 所示, 相比于 YOLO v3、YOLO v5、YOLO v6、YOLO v8n、YOLO v9 模型, YOLO v10 模型的 P 提升了 37.6、7.1、10.4、4.9、4.2 个百分点, R 提升了 13.5、8.3、6.8、3.1、2.2 个百分点, mAP@0.50 提升了 26.0、5.5、4.0、3.1、2.6 个百分点, mAP@0.95 提升了 27.7、13.5、6.8、11.0、5.1 个百分点。这说明 YOLO v10 模型性能更强, 适合做牛只行为检测的基线模型。LDCM-YOLO v10n 模型的 P 为 90.4%, R 为 87.5%, mAP@0.50 为 96.3%, mAP@0.95 为 81.0%, 比其他模型性能更优。

YOLO v10n 模型在牛只种类识别任务中展现了较为优异的分类性能 (表 5), 尤其在识别荷斯坦牛、娟姗牛和安格斯牛时, 其 mAP@0.50 分别达到了 96.4%、92.9% 和 95.4%。然而, 在识别海福特及西门塔尔时, 模型的 mAP@0.50 相对较低, 仅为 83.9% 和 81.2%。深入分析发现, 荷斯坦牛、海福特牛和安格斯牛的特征表现较为独特, 因此在种类识

表 4 不同模型对牛只种类识别的试验结果

Table 4 Experimental results of different models for cattle breed recognition

%

模型 Model	P	R	mAP@0.50	mAP@0.95
YOLO v3	49.8	70.8	63.9	46.9
YOLO v5	80.3	76.0	84.4	61.1
YOLO v6	77.0	77.5	85.9	67.8
YOLO v8n	82.5	81.2	86.8	63.6
YOLO v9	83.2	82.1	87.3	69.5
YOLO v10n	87.4	84.3	89.9	74.6
LDCM-YOLO v10n	90.4	87.5	96.3	81.0

别过程中具有较高的准确率。荷斯坦牛具有黑白花毛色和较大的体型, 娟姗牛体型较为丰满, 乳头较大且乳区明显, 而安格斯牛则以其全黑的毛色和紧凑的体型在视觉上具有独特性, 这些特征使得模型能够较为容易地将它们与其他牛种区分开来。

相比之下, 西门塔尔牛和海福特牛的外观特征较为相似, 导致模型在区分时存在一定困难。西门塔尔牛体型大, 肌肉线条明显, 毛色多为黄白花; 海福特牛体型中等, 肌肉发达, 毛色多为红白花。由于西门塔尔牛和海福特牛在毛色和肌肉线条上存在一定的相似性, 尤其是在四肢和肩部的肌肉表现上, 模型在识别时容易将两者混淆。在后续试验中, 特别是在对牛的毛色、体型和乳区等特征进行更细致地分析和处理后, 模型在区分西门塔尔牛和海福特牛时的性能提升较为明显。荷斯坦牛、娟姗牛和安格斯牛由于其独有的特征表现, 始终保持着较高的识别准确率。

如表 5 所示, 相较于 YOLO v10, YOLO

v10+C2f-LSKA 的 $mAP@0.50$ 提升了 0.8 个百分点,在 YOLO v10 中加入 DySample 后 $mAP@0.50$ 提升了 2.2 个百分点,同时加入 CloFormer 和 MSDA 后,平均精度 $mAP@0.50$ 提升了 3.0 个百分

点,结合之前的模块,在引入 Inner-IoU 损失函数,构建 LDCM-YOLO v10n 模型后,牛只种类识别 $mAP@0.50$ 达到了 96.7%。综上所述 LDCM-YOLO v10n 模型在牛只种类识别中表现出色。

表 5 不同模型在牛只种类识别消融试验中的 $mAP@0.50$

Table 5 The $mAP@0.50$ of different models in ablation experiments on cattle breed recognition

%

模型 Model	西门塔尔 Simmental	娟姗 Jersey	荷斯坦 Holstein	海福特 Hereford	安格斯 Angus	均值 Average
YOLO v10n	81.2	92.9	96.4	83.9	95.4	89.9
YOLO v10n+C2f-LSKA	84.7	81.5	96.9	94.2	96.4	90.7
YOLO v10n+DySample	83.9	91.6	96.6	93.1	95.7	92.1
YOLO v10n+CloFormer+MSDA	88.3	86.8	97.8	94.8	96.8	92.9
YOLO v10n+Inner-IoU	87.3	96.2	97.4	95.0	96.6	94.5
LDCM-YOLO v10n	92.8	96.6	98.9	96.7	98.5	96.7

3 讨论与结论

本研究提出了一种基于 YOLO v10 的改进牛只行为与牛只种类检测模型 LDCM-YOLO v10n。与 Wang 等^[21]、Ruengrote 等^[31]、Tu 等^[32]提出的模型相比,LDCM-YOLO v10n 针对特定的牛只行为检测和种类识别任务进行优化,将 YOLO v10 中的 C2f 模块改进为 C2f-LSKA 模块,减少了卷积神经网络提取图像特征时引入的冗余信息和噪声;将 Upsample 模块换成 DySample 算子,解决了 Upsample 模块难以有效捕捉图像中细微变化和丰富语义信息的问题;将 PSA 注意力模块改进为 CloFormer 注意力机制,使创新模型能够更好地区分牛的特征与背景噪声,并能够精准识别小目标;加入 MSDA,解决了 YOLO v10n 模型在进行牛只种类识别与行为检测任务时,由于不同种类牛特征不明显及牛多种相似的行为引起的不利于区分的问题;将损失函数改进为 Inner-IoU 损失函数,明显提高了检测精度、加速了模型收敛。试验结果表明,LDCM-YOLO v10n 在牛只行为检测任务中 $mAP@0.50$ 为 95.2%,相比于 YOLO v3、YOLO v5、YOLO v6、YOLO v8n、YOLO v9、YOLO v10n 模型分别提高了 15.4、10.7、12.0、8.4、7.9、5.1 个百分点。LDCM-YOLO v10n 在牛只种类检测任务中 $mAP@0.50$ 达到了 96.3%,相比于 YOLO v3、YOLO v5、YOLO v6、YOLO v8n、YOLO v9、YOLO v10n 模型分别提高了 32.4、11.9、10.4、9.5、9.0、6.4 个百分点。试验结果证明,LDCM-YOLO v10n 模型可以很好地解决规模化养殖中出现的问

题,较高的 mAP ,研究为后续精准化养殖提供了强有力的技术支持。

参考文献:

- [1] 韩磊,刘长全.中国畜牧业经济形势分析及对策研究[J].中国畜牧杂志,2021,57(2): 224-230.
- [2] 冯晓敏.浅谈传统散养与标准化规模养殖[J].吉林农业,2015(6): 89.
- [3] 匡文波,方圆.网络空间命运共同体理念下的全球互联网治理体系变革[J].武汉大学学报(哲学社会科学版),2023,76(5): 38-46.
- [4] 董超.“互联网+”对我国传统制造业绩效的影响研究[J].科技创业月刊,2021,34(11): 73-75.
- [5] 齐琳,包军,李剑虹.动物行为学研究在动物福利养殖中的应用[J].中国动物检疫,2009,26(9): 68-69.
- [6] 吴赛赛,吴建寨,程国栋,等.基于姿态估计的动物行为识别研究进展[J].中国农业大学学报,2023,28(6): 22-35.
- [7] LI G Z. Advancements, challenges, and future prospects in vision-driven animal behavior recognition technology [C]//Proceedings of the 2024 International Conference on Artificial Intelligence and Communication (ICAIC 2024). Dordrecht: Atlantis Press International BV, 2024: 522-532.
- [8] SHAHEEN F, VERMA B, ASAFUDDOULA M. Impact of automatic feature extraction in deep learning architecture[C]//2016 International Conference on Digital Image Computing: Techniques and Applications (DICTA). Gold Coast, QLD, Australia: IEEE, 2016: 1-8.
- [9] GULZAR Y, ÜNAL Z, AYOUB S, et al. Adaptability of deep learning: Datasets and strategies in fruit classification[J]. BIO Web of Conferences, 2024, 85: 01020. doi: 10.1051/bioconf/20248501020.
- [10] ZHANG K C. Incorporating deep learning model development with an end-to-end data pipeline[J]. IEEE Ac-

- cess, 2024, 12: 127522-127531.
- [11] 王少华, 何东健. 基于改进 YOLO v3 模型的奶牛发情行为识别研究[J]. 农业机械学报, 2021, 52(7): 141-150.
- [12] HUANG G, LIU Z, VAN DER MAATEN L, et al. Densely connected convolutional networks[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, HI: IEEE, 2017: 2261-2269.
- [13] 曹天一, 王月明, 李宝山, 等. 基于 YOLOv5 养殖场景下牛的行为识别[J]. 家畜生态学报, 2024, 45(9): 46-50.
- [14] 袁宇翔, 罗维平. 基于 YOLOv7 的奶牛行为识别方法研究[J]. 农业与技术, 2024, 44(11): 39-43.
- [15] 付辰伏, 任力生, 王芳. 基于改进 YOLO v8 的牛只行为识别与跟踪方法[J]. 农业机械学报, 2024, 55(5): 290-301.
- [16] 冯子懿. 基于改进 yolo 算法的牛只种类识别与行为检测[D]. 长春: 长春工业大学, 2024.
- [17] 李章辉. 基于深度学习的动物种类与身份识别研究[D]. 贵阳: 贵州大学, 2024.
- [18] 田小路, 张莉敏. 基于卷积神经网络的宠物狗种类识别[J]. 信息技术与信息化, 2019(8): 21-22.
- [19] XIE Y H, JIANG J Z, BAO H, et al. Recognition of big mammal species in airborne thermal imaging based on YOLO v5 algorithm[J]. Integrative Zoology, 2023, 18(2): 333-352.
- [20] JIAO J Y, TANG Y M, LIN K Y, et al. DilateFormer: Multi-scale dilated transformer for visual recognition[J]. IEEE Transactions on Multimedia, 2023, 25: 8906-8919. doi: 10.1109/TMM.2023.3243616.
- [21] WANG A, CHEN H, LIU L, et al. YOLOv10: Real-time end-to-end object detection[EB/OL]. arXiv: 2405.14458 (2024-10-30)[2025-02-01]. <https://doi.org/10.48550/arXiv.2405.14458>.
- [22] MISHRA N K, SINGH P, GUPTA A, et al. PP-CNN: Probabilistic pooling CNN for enhanced image classification[J]. Neural Computing and Applications, 2025, 37(6): 4345-4361.
- [23] 李忠, 欧阳斌, 邱少华, 等. 镜头表面附着雨滴的检测和去除方法综述[J]. 国防科技大学学报, 2023, 45(3): 146-160.
- [24] ZHANG P F, LO E, LU B T. High performance depthwise and pointwise convolutions on mobile devices[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(4): 6795-6802.
- [25] GAO H M, YANG Y, LI C M, et al. Multiscale residual network with mixed depthwise convolution for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(4): 3396-3408.
- [26] CHEN J R, KAO S H, HE H, et al. Run, don't walk: Chasing higher FLOPS for faster neural networks [C]//2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, BC, Canada: IEEE, 2023: 12021-12031.
- [27] LAU K W, PO L M, REHMAN Y A U. Large separable kernel attention: Rethinking the large kernel attention design in CNN[J]. Expert Systems with Applications, 2024, 236: 121352. doi: 10.1016/j.eswa.2023.121352.
- [28] LIU W Z, LU H, FU H T, et al. Learning to upsample by learning to sample[C]//2023 IEEE/CVF International Conference on Computer Vision (ICCV). Paris, France: IEEE, 2023: 6004-6014.
- [29] FAN Q, HUANG H, GUAN J, et al. Rethinking local perception in lightweight vision transformer[EB/OL]. arXiv: 2303.17803(2023-06-01)[2025-02-01]. <https://doi.org/10.48550/arXiv.2303.17803>.
- [30] ZHANG H, XU C, ZHANG S. Inner-IoU: More effective intersection over union loss with auxiliary bounding box[EB/OL]. arXiv: 2311.02877(2023-11-14)[2025-02-01]. <https://doi.org/10.48550/arXiv.2311.02877>.
- [31] RUENGROTE S, KASETRAVETIN K, SRISOM P, et al. Design of deep learning techniques for PCBs defect detecting system based on YOLOv10[J]. Engineering, Technology & Applied Science Research, 2024, 14(6): 18741-18749.
- [32] TU W, YU H, WU Z J, et al. YOLOv10-UDFishNet: Detection of diseased *Takifugu rubripes* juveniles in turbid underwater environments[J]. Aquaculture International, 2025, 33(2): 125. doi: 10.1007/s10499-024-01798-5.

【责任编辑 霍 欢】