

doi: 10.3969/j.issn.1673-3142.2025.09.003

基于改进 YOLOv7 的苹果目标检测算法研究

杨帆, 周杰, 吴昊荣, 罗瑶, 汪旭, 廖佳豪

(成都大学, 四川 成都 610106)

摘要: 针对自然场景下苹果果实检测模型适应性不足和高计算复杂度的问题, 在 YOLOv7 基础上进行改进, 提出了一种兼顾精度与推理速度的 ESS-YOLO 模型。首先, 使用改进的 SPPFCSPC 模块替换传统 YOLOv7 中的 SPPCSPC 模块, 降低模型的计算量以及参数量; 其次, 引入 ECA 注意力机制模块, 增强模型的鲁棒性和泛化能力; 最后, 使用 Siou 损失函数, 加快模型的收敛速度。实验结果表明, ESS-YOLO 精确率、召回率和平均精度分别达到 92.3%、93.9% 和 99.4%, 较于基准模型 YOLOv7, 精确率提高了 1.1%, 召回率提高了 0.8%, 平均精度提高了 1.8%, 其参数量和浮点计算量分别降低了 0.12 M 和 2.3 G, 推理速度提升了 18%。ESS-YOLO 模型展现出优异的适应性与鲁棒性, 可为促进苹果智能采摘应用提供技术参考。

关键词: 苹果; YOLOv7; 目标检测; 注意力机制

中图分类号: S225; TP183; TP391.41 **文献标识码:** A **文章编号:** 1673-3142(2025)09-0013-06

引用格式: 杨帆, 周杰, 吴昊荣, 罗瑶, 汪旭, 廖佳豪. 基于改进 YOLOv7 的苹果目标检测算法研究 [J]. 农业装备与车辆工程, 2025, 63(9): 13-18.

Research on apple object detection algorithm based on improved YOLOv7

YANG Fan, ZHOU Jie, WU Haorong, LUO Yao, WANG Xu, LIAO Jiahao

(Chengdu University, Chengdu 610106, Sichuan, China)

Abstract: In response to the problems of insufficient adaptability and high computational complexity of apple fruit detection models in natural scenes, improvements was made based on YOLOv7, and an ESS-YOLO model that balanced accuracy and inference speed was proposed. Firstly, the improved SPPFCSPC module was used to replace the traditional SPPCSPC module in YOLOv7, thereby reducing the computational load and parameter quantity of the model. Secondly, the ECA attention mechanism module was introduced to enhance the robustness and generalization ability of the model. Finally, the Siou loss function was adopted to accelerate the convergence speed of the model. Experimental results show that the precision, recall, and average precision of ESS-YOLO reach 92.3%, 93.9%, and 99.4% respectively. Compared with the benchmark model YOLOv7, the precision was increased by 1.1%, the recall was increased by 0.8%, and the average precision was increased by 1.8%. Meanwhile, its parameter quantity and floating-point computation were reduced by 0.12 M and 2.3 G respectively, and the inference speed FPS was improved by 18%. The ESS-YOLO model demonstrated excellent adaptability and robustness, which could provide technical references for promoting the application of intelligent apple picking.

Key words: apple; YOLOv7; target detection; attention mechanism

0 引言

苹果树是中国第一大落叶果树, 其种植面积与产量均居全球首位, 年产量达 3.52×10^7 t, 占世界总产量的 54.7%^[1]。苹果产量的提升对采摘效率提出了挑战, 但目前中国苹果采摘仍以人工为主, 效率低、成本高^[1]。因此, 研发智能化的采摘机器人具有重要的发展前景。在智能化苹果采摘系统的开发中, 如何突破复杂环境因素的干扰实现果实精准识别是亟待解决的关键技术难题^[2]。在自然复杂场景

下, 传统检测方法易受光线变化、枝叶遮挡及背景噪声干扰, 导致检测性能显著下降, 难以满足实际应用需求^[4]。人工智能行业的快速发展推动了以深度学习为核心的新型目标检测方法(如 R-CNN 系列、SSD、YOLO 系列)在农业生产中的应用^[5]。相较于传统方法, 基于卷积神经网络(Convolutional Neural Networks, CNN)的技术能够自动学习并提取目标的高级语义特征, 在复杂背景环境(如光线变化、遮挡、噪声)下表现出更强的适应性和更高的检测精度

基金项目: 四川省大学生创业训练计划项目“视觉检测工业应用系统研究”(S202411079012X)

收稿日期: 2025-07-31

作者简介: 杨帆(2005-), 女, 研究方向: 通信工程。E-mail: 1193326004@qq.com

通信作者: 吴昊荣(1989-), 博士, 副教授, 研究方向: 机器视觉。E-mail: xxli1987@163.com

与鲁棒性^[6]。周晖等^[7]基于 YOLOv8 模型设计了一种复杂环境下轻量化苹果目标检测算法 YOLOv8n-Apple, 通过引入 VanillaNet 主干网络、C2fGhost 模块和 WIoU 损失函数, 实现了对苹果目标检测算法的轻量化; 黄铭杰等^[8]提出了一种改进的 YOLOv11 模型, 通过添加 C2f_SimAM 注意力模块和可分离卷积 CMUNeXt 模块, 实现了荔枝果实品种精准识别; 陈思等^[9]以 YOLOv8 为基础模型, 通过引入 GSConv 和 VoV-GSCSP 模块, 并嵌入简化注意力机制 (Simplified Attention Mechanism, SimAM) 注意力机制, 实现了对绿橙的精准识别。师翊等^[10]针对苹果幼果识别, 将迁移学习方法与 YOLOv8 相结合, 提出了一种改进 YOLOv8n 模型的苹果幼果识别方法。

上述研究虽在果品识别算法优化方面取得显著进展, 但多数基于理想化环境参数设置。为此, 本研究以 YOLOv7 为基准模型, 提出了一种苹果检测模型 ESS-YOLO。使用改进的空间金字塔池化跨阶段部分通道 (Spatial Pyramid Pooling Cross Stage Partial Channel, SPPFCSPC) 模块替换传统 YOLOv7 中的 SPPCSPC 模块, 提升模型在移动设备上的推理效率; 引入 ECA (Efficient Channel Attention, ECA) 注意力机制模块, 增强模型的鲁棒性和泛化能力; 使用 SIoU 损失函数, 加快模型的收敛速度。

1 材料与方法

1.1 实验数据

本研究采用公共数据集, 有关详细信息请参阅链接: <https://opendatalab.com/>, 数据集中图像分辨率为 $3\,024 \times 4\,032$, 格式为 JPG。该数据集涵盖了在不同光照和距离条件下的苹果果实, 包括枝叶遮挡、果实重叠、单个果实以及多个果实的情况, 能够充分反映自然环境的复杂性, 苹果样本如图 1 所示。




图 1 苹果果实图像

Fig.1 Image of apple fruit

(a) 单果实 (b) 多果实 (c) 阴天 (d) 晴天

(e) 树叶遮挡 (f) 枝干遮挡 (g) 果实重叠 (h) 远距离

此外, 通过使用 LabelImg 软件对图像中的苹果进行人工标注, 标注过程中将边界框类别指定为 “Apple”, 并导出为 YOLO 格式的标签文件。

1.2 YOLOv7 网络模型

YOLOv7 核心设计目标是实现高效的特征提取和多尺度目标检测^[11]。YOLOv7 的网络结构主要由输入模块 (Input)、骨干网络 (Backbone) 和头部网络 (Head) 3 部分组成。输入模块采用了 Mosaic 数据增强技术, 通过对 4 张图像进行随机裁剪、缩放和拼接, 生成包含多尺度目标的训练图像, 显著提升了模型对小目标和遮挡目标的检测能力。骨干网络基于 E-ELAN (Extended Efficient Layer Aggregation Network) 模块设计, 通过多分支结构融合不同层次的特征, 增强了网络对多尺度目标的感知能力。头部网络则采用了路径聚合网络 (Path Aggregation Network, PANet) 结构, 通过自上而下和自下而上的特征融合路径, 将不同尺度的特征图进行整合, 进一步提升了模型的特征表达能力。此外, YOLOv7 还引入 SPPCSPC 模块, 通过空间金字塔池化和跨阶段局部连接结构, 网络架构如图 2 所示。




图 2 YOLOv7 网络架构

Fig.2 The network architecture of YOLOv7

1.3 ESS-YOLO 算法

YOLOv7 算法经过系统性的优化, 性能有所提升, 但在复杂果园环境和不均匀光照条件下, 仍难以有效检测遮挡、密集或远距离的苹果目标。此外, 模型的体积尺寸偏大, 特征提取能力相对不足, 训练过程中产生的部分冗余参数也不利于提升模型整体效率。基于此, 本研究提出高效苹果目标检测算法 ESS-YOLO, 对 YOLOv7 模型结构进行优化: 首先, 采用改进的 SPPFCSPC 模块替换原始 SPPCSPC 模块, 以降低模型复杂度 (减少计算量与参数量), 提升移动设备推理速度; 其次, 融入 ECA 通道注意力机

制, 强化模型特征提取能力, 增强其在非均匀光照等复杂果园环境下的鲁棒性; 最后, 应用 SIoU 损失函数替换原始损失函数, 加快模型训练收敛过程。其网络架构如图 3 所示。




图 3 ESS-YOLO 算法流程

Fig.3 Flowchart of the ESS-YOLO algorithm

1.3.1 SPPFCSPC 模块

SPPFCSPC 模块是 YOLOv7 的关键组件, 通过融合空间金字塔池化 (SPP) 与跨阶段局部网络 (CSP) 提升模型感受野和特征表达能力^[12]。然而, 其并行池化结构在增强性能的同时, 也显著增加了参数量并降低了模型收敛速度。为优化效率, 本研究借鉴 SPP-Fast 思想, 对 SPPFCSPC 进行改进: 将并行的最大池化层重构为串行结构, 形成 SPPFCSPC 模块, 结构如图 4 所示。




图 4 SPPFCSPC 模块

Fig.4 SPPFCSPC module

该模块核心在于结合“Fast”空间金字塔池化 (SPPF) 与 CSP 架构: 利用串联的小尺寸 (如 5×5) 步长 1 最大池化层, 等效实现大感受野 (如 13×13) 效果, 显著降低计算复杂度与参数量; 同时, CSP 结构通过特征图分流处理与合并, 进一步减轻计算负担并促进梯度流动。SPPFCSPC 在保持甚至增强多尺度特征提取能力 (对遮挡、远距离目标检测至关重要) 的基础上, 大幅提升了模型效率, 尤其适用于移动端等资源受限场景的部署。

1.3.2 ECA 注意力机制模块

在果园环境中, 苹果呈现出密集分布并受到果

实遮挡等多种干扰, 增加了苹果检测任务的复杂性。为优化模型性能, 更有效地聚焦于目标特征中的关键细节, 在模型中引入 ECA 注意力机制。ECA 注意力机制是一种轻量级通道注意力机制, 通过全局平均池化压缩空间信息后, 采用 1×1 卷积替代全连接层进行跨通道交互, 避免传统方法 (如 SENet) 的维度压缩问题^[13]。其核心创新在于自适应动态卷积核 (根据通道数自动调整卷积核大小) 与局部交互策略, 在几乎不增加计算负载 (如 ResNet50 仅增 80 参数) 的前提下, 显著提升模型的特征选择能力与鲁棒性, ECA 注意力机制结构如图 5 所示。




图 5 ECA 注意力机制

Fig.5 ECA attention mechanism

1.3.3 SIoU 损失函数

目标检测是计算机视觉中的核心问题之一, 其有效性很大程度上取决于所使用的损失函数。传统的目标检测损失函数通常基于边界框回归指标的聚合, 例如预测框和地面实况框之间的距离、重叠区域和纵横比 (例如, GIoU、CIoU、IIoU 等)。然而, 现有方法往往忽视了地面实况与预测框之间的方向不匹配问题, 导致预测框在训练过程中漂移, 导致收敛缓慢, 模型性能不佳^[14]。为了解决这个问题, Gevorgyan 提出了一个 SIoU 损失函数。SIoU 损失函数结构示意图如图 6 所示。




图 6 SIoU 损失函数

Fig.6 SIoU loss function

该方法重新定义了目标检测任务中的损失函数, 该函数由角度损失、距离损失、形状损失和 IoU 损失 4 个部分组成。具体来说, 角度损失考虑

了地面实况和预测框的向量之间的角度,距离损失考虑了地面实况和预测框之间的距离,形状损失考虑了地面实况和预测框之间的形状差异,IoU 损失计算预测框和地面实况框之间的并集交集,以评估预测框的准确性。通过引入这 4 个损失函数,可以提高目标检测模型的准确性和鲁棒性,同时避免过拟合问题。

由图 6 可知, α ——预测框和真实框中心点连线与水平方向的夹角; β ——预测框和真实框中心点连线与垂直方向的夹角; C_{w1} 、 C_{h1} ——预测框和真实框中心点的宽度和高度; C_{w2} 、 C_{h2} ——包含地面实况框和预测框的边界框的宽度和高度; σ ——预测框和地面实况框之间的中心点距离; w^{gt} 、 h^{gt} 、 w 、 h ——地面实况框和预测框的宽度和高度。

SIoU 损耗函数中角度损失函数 Λ 计算公式为

$$\Lambda = 1 - 2\sin^2(\arcsin(\frac{C_h}{\sigma}) - \frac{\pi}{4}) = \cos(2(\arcsin(\frac{C_h}{\sigma}) - \frac{\pi}{4})) \quad (1)$$

$$\sigma = \sqrt{(b_{C_x}^{gt} - b_{C_x})^2 + (b_{C_y}^{gt} - b_{C_y})^2} \quad (2)$$

SIoU 损耗函数 $LOSS_{IoU}$ 的最终定义如式 (3) 所示,可由式 (4) —式 (8) 得出。

$$LOSS_{IoU} = 1 - IoU + \frac{\Delta + \Omega}{2} \quad (3)$$

$$\rho_x = \left(\frac{b_{C_x}^{gt} - b_{C_x}}{C_{w2}} \right)^2, \rho_y = \left(\frac{b_{C_y}^{gt} - b_{C_y}}{C_{h2}} \right)^2, \gamma = 2 - \Lambda \quad (4)$$

$$\omega_w = \frac{|w - w^{gt}|}{\max(w, w^{gt})}, \omega_h = \frac{|h - h^{gt}|}{\max(h, h^{gt})} \quad (5)$$

$$\Omega = \sum_{t=w, h} (1 - e^{-\omega_t})^\theta \quad (6)$$

$$\Delta = \sum_{t=x, y} (1 - e^{-\gamma \rho_t}) = 2 - e^{-\gamma \rho_x} - e^{-\gamma \rho_y} \quad (7)$$

$$IoU = \frac{|B \cap B^{gt}|}{|B \cup B^{gt}|} \quad (8)$$

式中: C_h ——预测框和真实框中心点的高度; $b_{C_x}^{gt}$ 、 $b_{C_y}^{gt}$ ——地面实况框的中心点坐标; b_{C_x} 、 b_{C_y} ——预测框的中心点坐标; Δ ——距离损失函数; C_{w2} ——地面实况框和预测框的边界框的宽度; C_{h2} ——地面实况框和预测框的边界框的高度; Ω ——形状损失函数 θ , 为常量,取值范围为区间 [2,6]; ρ_x ——预测框和真实框中心点宽度差与最小外接框宽度比值的平方; ρ_y ——预测框和真实框中心点高度差与最小外接框高度比值的平方; γ ——调节系数; ω_w ——预测框与真实框的宽度差绝对值与两者最大宽度比值; ω_h ——预测框与真实框的高度差绝对值与两者最大高度比值。

2 实验

2.1 实验条件

本实验是在 64 位 Windows11 家庭版操作系统下运行用于服务器端的深度学习框架部署,处理器为 AMD Ryzen 7 5800H with Radeon Graphics 3.20 GHz, 16 GB 内存,显示适配器为 NVIDIA GeForce RTX 3050 Ti,用于加速深度学习模型的训练和推理,使用软件为 Python3.8,支持数据处理、模型开发和脚本编写以及 PyCharm 2021.3.1,用于构建和训练深度学习模型。PyTorch2.9,提供灵活的动态计算图和丰富的神经网络模块。表 1 为训练策略的参数设置。

表 1 训练参数

Tab.1 Training parameters

参数	数值
图片尺寸 /px	640 × 640
批量大小	16
多线程	16
动量	0.937
初始学习率 /%	0.01
加速器	SGD
轮次数	300

2.2 评价指标

本研究选择精确率 (P)、召回率 (R)、平均精度均值 (mAP)、每秒帧率 (FPS)、算法占用内存大小 (Params) 和浮点计算量 (GFLOPs) 对所提模型进行有效评价,计算公式为

$$P = \frac{TP}{TP + FP} \quad (9)$$

$$R = \frac{TP}{TP + FN} \quad (10)$$

式中: TP ——被目标检测模型正确判断为苹果的样本; FP ——其他对象被目标检测模型判断为苹果的样本; FN ——目标检测模型未识别的苹果样本。

$$mAP = \frac{\sum_{i=1}^{N_c} AP_i}{N_c} \quad (11)$$

式中: N_c ——目标数据集中所有对象的个数; mAP ——IoU 权重为 0.5 时柑橘目标的平均检测精度; AP_i ——第 i 类的平均精度,其能够综合考虑准确率和召回率 2 个方面的影响。

2.3 消融实验

消融实验是一种通过逐步移除或替换模型中的特定组件来系统性评估各模块对系统整体性能贡献度的实验方法^[15]。本实验以 YOLOv7 作为基准模型,对所加模块以单独加入和多个模块进行不同组合加入的方式进行分析,消融实验结果如表 2 所示。

表 2 消融实验
Tab.2 Ablation experiments

模块	SPPFCSPC	ECA	SIoU	$P/\%$	$mAP@0.5/\%$	Params/M	GFLOPs/G	FPS
YOLOv7	×	×	×	91.2	97.6	3.01	8.1	60.67
	√	×	×	91.6	96.9	2.53	5.8	63.34
	×	√	×	92.2	98.1	3.1	8.1	65.89
	×	×	√	91.6	98.7	3.01	8.1	64.76
	√	√	×	91.8	97.7	2.89	5.8	68.78
	√	√	√	92.3	99.4	2.89	5.8	71.86

由表 2 可知, 当引入 SPPFCSPC 模块时, 模型的精确率 P 提升了 0.4%, 参数量和浮点数分别降低了 0.48 M 和 2.3 G。嵌入 ECA 注意力机制时, 模型的准确率 P 和平均精度值 $mAP@0.5$ 分别提升了 1.0% 和 0.5%。通过优化对苹果目标的回归效率, SIoU 损失函数使模型的准确率 P 和平均精度值 $mAP@0.5$ 分别提升了 0.4% 和 1.1%。在同时使用 SPPFCSPC 模块和 ECA 模块时, 不仅提升了模型的精度, 还使模型的参数量和 GFLOPs 大幅度下降, 实现了模型的轻量化。当集成 3 个改进模块后, 模型的综合检测性能达到最佳, ESS-YOLO 模型准确率 P 达到 92.3%, 平均精度值达到 99.4%。实验验证了改进的 3 个模块在提升模型多个指标上的有效性, 并成功减少了参数量、节约了计算资源、降低了耗时。

2.4 改进后 ESS-YOLO 对比实验

为评估 ESS-YOLO 模型在果园环境下对苹果检测的优越性, 在同一环境和训练策略下, 将 ESS-YOLO 模型与 YOLOv7 模型在苹果数据集上进行对比试验, 数据如表 3 所示。根据数据分析, 相较于 YOLO7 模型, ESS-YOLO 模型在苹果果实识别上实现了性能提升: 精确率 P 提高了 1.1%, 召回率 R 提高了 0.8%, $mAP@0.5$ 提高了 1.8%, 同时, 通过模型架构优化, ESS-YOLO 模型的 Params 和 GFLOPs 分别降低了 0.12 M 和 2.3 G, 推理速度 FPS 提升了 18%。这使得 ESS-YOLO 模型减少了对计算资源与存储空间的需求, 加快了检测速度, 有力保障了果园环境下苹果检测的高效性。

表 3 模型改进前后性能对比

Tab.3 Performance comparison before and after model improvement

模型	$P/\%$	$R/\%$	$mAP@0.5/\%$	Params/M	GFLOPs/G	FPS
YOLOv7	91.2	93.1	97.6	3.01	8.1	60.67
ESS-YOLOv7	92.3	93.9	99.4	2.89	5.8	71.86

图 7 展示了 YOLOv7 模型与 ESS-YOLO 模型在不同场景下对苹果的识别表现, 图中白色框为模型漏检的苹果目标。在枝干遮挡和密集目标时, 2 种

模型均表现出良好的检测性能。然而, YOLOv7 算法在树叶遮挡和密集目标时存在漏检现象。这是由于 YOLOv7 标准卷积核在极端光照下难以自适应调整感受野, 同时 YOLOv7 中 SPPCSPC 等模块在压缩特征时容易忽略光照不均匀区域的局部差异性, 导致其在果园环境下难以有效区分果实与背景。相较于 YOLOv7 模型, ESS-YOLO 显著降低了目标漏检率, 并在多场景测试中展现出更高的检测精度。其在果园环境下对苹果目标的鲁棒识别能力, 验证了该模型优越的泛化性能。




图 7 不同模型下的识别效果

Fig.7 Recognition effects under different models

3 结论

本研究针对自然场景下苹果果实检测模型适应性不足和高计算复杂度的问题, 在 YOLOv7 基础上提出了一种兼顾精度与推理速度的 ESS-YOLO 模型。主要结论如下:

(1) 在改进算法上: 首先, 使用改进的 SPPFCSPC 模块替换传统 YOLOv7 中的 SPPCSPC 模块, 降低模型的计算量以及参数量, 提升模型在移动设备上的推理效率; 其次, 引入 ECA 注意力机制模块, 增强模型的鲁棒性和泛化能力; 最后, 使用 SIoU 损失函数, 加快模型的收敛速度;

(2) ESS-YOLO 在复杂环境下对苹果识别的性能表现优异,其精确率、召回率和平均精度分别达到 92.3%、93.9% 和 99.4%。在果园环境苹果数据集上,较于基准模型 YOLOv7,其参数量和浮点计算量分别降低了 0.12 M 和 2.3 G,推理速度提升了 18%,更利于在移动设备上部署,为复杂环境下的苹果采摘识别提供了有效的技术支持;

(3) 尽管 ESS-YOLO 模型表现出优势性能,但其泛化能力仍有提升空间。当前训练数据集主要包含成熟期(表皮呈红色)的苹果图像,缺乏未成熟期(深绿色)苹果样本,样本多样性不足可能导致模型在识别不同颜色和成熟度苹果时性能受限。因此,后续研究计划收集并引入涵盖不同生长期(特别是未成熟期)的苹果图像,构建更具多样性的数据集,以提升模型在不同生长阶段苹果检测中的泛化性能和实际适应性。

参考文献

- [1] 陈青,殷程凯,郭自良,等. 苹果采摘机器人关键技术研究现状与发展趋势[J]. 农业工程学报,2023,39(4):1-15.
- [2] 曹旭东,路敦民. 苹果采摘末端执行器设计及分析[J]. 林业机械与木工设备,2024,52(9):97-101,109.
- [3] 王得志,王延鑫,汪小崑,等. 农业机器人中的管理与采摘技术:现状、挑战与未来发展[J]. 智能化农业装备学报(中英文),2025,6(2):1-23.
- [4] 宋怀波,尚钰莹,何东健. 果实目标深度学习识别技术研究进展[J]. 农业机械学报,2023,54(1):1-19.
- [5] 史孝杰,张紫璇,伦智民,等. 果实目标识别检测算法研究进展[J]. 农业装备与车辆工程,2025,63(5):1-7.
- [6] 牛晓婷. 基于卷积神经网络的低照度图像增强算法研究[D]. 大连:大连交通大学,2025.
- [7] 周晖,杨洁,赵祥飞. YOLOv8 轻量化的果园复杂环境下苹果检测算法[J]. 科学技术与工程,2025,25(6):2274-2283.
- [8] 黄铭杰,蔡伟强,张子健,等. 基于改进 YOLO11 的荔枝果实品种实时精准识别算法[J]. 农业工程学报,2025,41(11):156-164.
- [9] 陈思,李俊菡,孔德肖,等. 基于 YOLOv8n 绿橙检测算法研究[J]. 中国农机化学报,2025,46(7):145-152.
- [10] 师翊,王应宽,王菲,等. 基于改进 YOLOv8n 的苹果幼果识别[J]. 农业工程学报,2025,41(8):204-210.
- [11] 金涛,李昭蒂. 基于改进 YOLOv7 的无人机图像小目标检测算法[J]. 实验室研究与探索,2025,44(7):118-124,143.
- [12] 周平,殷勇,杨岚,等. 基于改进 YOLOv7 的荔枝叶片病害监测模型[J]. 农业工程,2025,15(4):21-27.
- [13] 徐江鹏,王传安. 基于轻量化改进 YOLOv7-Tiny 算法的苹果检测与分类[J]. 江苏农业科学,2024,52(23):221-229.
- [14] 高贤君,刘振宇,许磊,等. 基于 CutMix 数据增强与多约束损失函数的 YOLOv7 盾构隧道渗漏水检测[J]. 测绘通报,2024(7):105-110.
- [15] 任晶晶,郭中原,鞠剑平. 基于双层优化元学习的域自适应红枣缺陷检测[J]. 中国农机化学报,2025,46(7):104-110.