

山东农业科学
Shandong Agricultural Sciences
ISSN 1001-4942,CN 37-1148/S

《山东农业科学》网络首发论文

题目：基于改进实时检测 Transformer 的轻量级番茄果实检测算法
作者：卢承方，崔艳荣，胡蓉华，王浩宇，陈鹏翔
收稿日期：2024-11-01
网络首发日期：2025-11-13
引用格式：卢承方，崔艳荣，胡蓉华，王浩宇，陈鹏翔. 基于改进实时检测 Transformer 的轻量级番茄果实检测算法[J/OL]. 山东农业科学.
<https://link.cnki.net/urlid/37.1148.S.20251113.0859.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于改进实时检测 Transformer 的轻量级番茄果实检测算法

卢承方¹, 崔艳荣¹, 胡蓉华¹, 王浩宇¹, 陈鹏翔²

(1. 长江大学计算机科学学院, 湖北 荆州 434000; 2. 华南理工大学软件学院, 广东 广州 510006)

摘要: 针对复杂环境下番茄果实目标多、外形各异、分布密集等特点, 同时为解决 Transformer 架构巨大运算量导致的模型部署困难的问题, 提出一种改进实时检测 Transformer (Real-Time Detection Transformer, RT-DETR) 的番茄果实检测模型 SPC-DETR。首先, 实地拍摄采集多尺度的复杂环境番茄果实图片, 并从公开数据集中筛选符合复杂环境的番茄果实图片作为补充, 进行标注及数据增强后构建了一个包含 3 398 张图片的番茄果实数据集。其次, 以 RT-DETR-R18 为基线模型, 进行如下改进: 选用计算复杂度低且检测精度较高的 StarNet 作为主干特征提取基准网络, 并引入倒置残差移动块 iRMB, 构建 iR-StarNet 作为主干网络, 在轻量化主干的同时进一步提高模型对番茄果实的特征提取能力; 设计一种改进的并行空洞卷积结构块 EMA-PDC, 该模块基于融合跨空间学习的高效多尺度注意力机制, 可在减少计算量的同时扩大模型感受野, 提升模型多尺度表示的准确性; 使用 DEA-Net 提出的内容引导注意力融合方案 CGA-Fusion 改进颈部网络, 进一步提高模型表征能力。实验结果表明, SPC-DETR 的准确率、召回率和平均精度均值 (mAP50) 分别为 88.0%、83.7% 和 90.2%, 分别比基线模型 RT-DETR-R18 提高 1.5、0.8、0.4 个百分点, 模型权重大小、参数量、浮点运算量分别为 25.2 MB、13.1 M、34.6 GFLOPs, 分别比 RT-DETR-R18 降低 34.72%、35.64%、41.30%, 综合表现优于目前大部分主流的 YOLO 系列模型和 DETR 系列模型。本研究结果可为提升智能采摘机器人识别检测复杂环境下番茄果实的准确率提供技术参考。

关键词: 番茄果实识别; Transformer; RT-DETR; 轻量化; 目标实时检测; 深度学习

A Lightweight Tomato Fruit Detection Algorithm Based on Improved Real-Time Transformer

Lu Chengfang¹, Cui Yanrong¹, Hu Ronghua¹, Wang Haoyu¹, Chen Pengxiang²

(1. School of Computer Science, Yangtze University, Jingzhou 434000, China;

2. School of Software Engineering, South China University of Technology, Guangzhou 510006, China)

Abstract Detecting tomato fruits in complex environments presents significant challenges, including a high density of targets, varying shapes, and diverse distributions. To address these challenges while solving the deployment difficulties caused by the massive computational requirements of Transformer architectures, we propose an enhanced version of the real-time detection Transformer (RT-DETR), termed SPC-DETR. Firstly, a custom tomato fruit dataset specifically designed for complex environments was created. This dataset was supplemented by selecting relevant images of tomato fruits from publicly available datasets that depict similar complex environmental conditions. Each of these images was meticulously annotated and subjected to various data augmentation techniques to enhance diversity and robustness. As a result, the final dataset consists of 3,398 carefully labeled images, providing a solid foundation for effective tomato fruit detection in challenging scenarios. Secondly, several novel lightweight architectures were compared to select the feature extraction network, including EfficientViT, MobileNetv4, EfficientFormerV2, RepViT, and StarNet. StarNet was ultimately chosen as the benchmark network due to its balance of low computational complexity and high detection accuracy, making it suitable for deployment on resource-constrained devices. Furthermore, an inverted residual mobile block (iRMB) was introduced to further enhance StarNet, improving its feature extraction capabilities while maintaining a lightweight backbone design. To further improve the detection performance, we design an improved parallel dilated convolution block (EMA-PDC) based on an efficient multi-scale attention mechanism with cross-space learning. This design reduced computational load while expanding the model's receptive field, thereby improving the accuracy in multi-scale representation. In the design of the neck network, inspiration was drawn from CGA-Fusion, a content-guided attention fusion scheme proposed by DEA-Net. The incorporation of this mechanism further improved the model's representational ability, particularly in detecting tomato fruits with diverse morphologies in complex environments. Experimental results show that SPC-DETR achieves precision, recall, and average precision of 88.0%, 83.7% and 90.2% respectively, outperforming most mainstream YOLO and DETR models. Compared to the baseline model RT-DETR-R18, SPC-DETR reduces the number of parameters, floating-point operations, and model weights by 35.8%, 41.5%, and 34.7%, respectively, while maintaining high detection accuracy. These findings provide a

收稿日期: 2024-11-01

基金项目: 国家自然科学基金面上项目 (62077018); 湖北省自然科学基金项目 (2023AFB082)

作者简介: 卢承方 (2001—), 男, 硕士研究生, 主要研究方向为深度学习与目标检测。E-mail: 2023710700@yangtzeu.edu.cn

通信作者: 崔艳荣 (1968—), 女, 博士, 教授, 主要从事人工智能、信息处理研究。E-mail: cyanr@yangtzeu.edu.cn

valuable technical reference for effective tomato fruit detection in complex environments.

Keywords: Tomato Fruit Recognition; Transformer; RT-DETR; Lightweighting; Target detection; Deep learning

我国是全球番茄栽培面积最广、产量最高的国家之一^[1]。番茄产业对提高农民收入、促进农村经济发展以及推动农业产业化和结构调整具有重要作用。随着我国现代农业向自动化和智能化发展,温室环境下的番茄果实智能识别技术显得尤为关键,但目前这一技术还面临诸多挑战,尤其番茄在不同条件下外部特征差异大、样本不均衡、光照多变以及茎叶遮挡等复杂因素,使其识别比户外开放环境或简单背景下的物体识别更为困难,成为当前番茄采摘设备所用目标检测算法面临的主要难题。

目前基于深度学习的目标检测技术已在农业领域得到广泛应用,在番茄果实检测方面也取得一定研究进展,主要使用一阶段(以 R-CNN^[2]、Fast R-CNN^[3]为代表)和二阶段(以 YOLO 系列^[4]为代表)目标检测算法构建番茄检测算法。张文静等^[5]提出一种基于 Faster R-CNN 的番茄检测方法,正确识别率达到 95.2%,推理速度为 245 ms。龙洁花等^[6]利用跨阶段局部网络对 Mask R-CNN 进行改进,提升了番茄的识别率。Gao 等^[7]提出一种基于 YOLO v5 的温室番茄识别方法,采用 K-means 聚类算法获取更适合的锚点,通过改进空间金字塔池化增强多尺度特征提取,最后优化非最大值抑制,将平均精度提升至 97.3%,改进后的平均检测时间为 57 ms。成伟等^[8]提出了一个基于 YOLO v3 的改进模型,使用基于广义交并比 G-IoU 的位置损失函数,改善了果实目标的识别精度,相比原模型在番茄红果和绿果的估产精度上提高 2.7%。苗荣慧等^[9]提出一种基于改进 YOLO v7 的轻量化樱桃番茄成熟度检测模型,通过引入 MobileNetV3 作为骨干网络以及在特征融合网络中加入全局注意力机制提高网络的表征能力,将精确率提升至 98.6%,单幅图像平均检测时间为 82 ms。何斌等^[10]提出一种基于改进 YOLO v5 的夜间温室番茄果实快速识别模型,通过引入基于交并比(IoU)的 CIoU 目标位置损失函数,将识别精度提高 1.6 个百分点。张俊宁等^[11]利用卷积注意力模块改进 YOLOv5s 的骨干网络,将其对温室番茄的识别准确率提升 1.5 个百分点。李名博等^[12]提出一种基于 YOLOX-L-TN 的番茄果实识别模型,通过设计含有残差结构块的 TN 模块改进主干网络,将平均识别精度提升 4.81 个百分点,模型权重为 219.41 MB。Appe 等^[13]提出一种改进 YOLO v5 的番茄检测算法,通过引入卷积注意力模块 CBAM (Convolutional Block Attention Module) 并采用 DIOU-NMS 方法减少错误抑制,将平均识别精度提升至 88.1%。代国威等^[14]提出一种基于 YOLOv5 的温室番茄检测模型,通过引入八度卷积和 CBAM 注意力机制增强特征提取能力,采用天气增强技术增加数据集多样性,将模型的平均识别精度提升至 94.6%。

上述番茄果实检测算法虽解决了检测过程中面临的部分问题,一定程度上提升了检测精度,但仍存在一些不足:

①多数研究采用 YOLO 系列模型作为基线模型,而该系列模型普遍依赖于非极大值抑制方法(Non-Maximum Suppression, NMS)来处理检测框间的重叠问题,过于依赖人为设定的阈值,难以实现真正意义上的端到端的检测流程;②相关研究采用引入注意力机制的方法虽提升了检测精度,但同时也增加了一定的参数量和计算复杂度,如何减少由此带来的额外开销和复杂度有待进一步研究;③部分研究模型仅针对单一尺度或简单背景下的番茄果实进行研究,无法满足实际复杂生产环境的检测需求。针对这些问题,本研究基于不依赖于 NMS 且适用于复杂环境下多尺度番茄果实识别任务的 Transformer 的端到端实时物体检测模型 RT-DETR (Real-Time Detection Transformer)^[15],提出一种改进的轻量级番茄果实检测算法 SPC-DETR,通过增强模型的动态信息建模能力以及对于不同尺寸、姿态和复杂环境番茄果实的适应能力,使模型能够更精准地捕捉番茄特征的关键信息,从而提升番茄果实实时检测的准确性。

1 材料与方法

1.1 数据集制作

本研究使用自制番茄果实数据集进行实验。数据集中图像的主要部分来源于湖北省荆州市番茄连栋温室实地拍摄;另有少部分来源于 Larxel 在 Kaggle 平台上开源的 Tomato Detection 数据集,从中筛选出符合复杂环境条件下的小目标番茄图片数据作为补充。实地拍摄所用设备为 2 420 万像素、等效焦距 28 mm、光圈范围 F2.8-F16 的 RICOH GR III 相机,像素级精度为 2 mm;选择顺光、逆光、单果、多果、果实重叠以及枝叶遮挡等多种条件下的结果期番茄果实进行拍摄,以确保数据集涵盖多种典型复杂场景;拍摄时分远景与近景,分别距离果实 450~600 mm 和 150~300 mm,确保数据集符合多尺度数据研究预期。初始数据集中共有 2 098 张图片,其中实地拍摄的图片有 1 873 张,剩余 225 张来源于 Tomato Detection 数据集。按照 7:2:1 的比例进行数据集的随机划分,其中 1 470 张图片作为训练集,417 张图片作为测试集,211 张图片作为验证集。为提高模型泛化能力,减少过拟合情况,在训练集中进行离线数据增强操作,随机采用随机剪裁、亮度变化、增加噪声、镜像翻转与旋转(图 1),将训练集图片扩充至 2 770 张。

所有图像分为红色成熟番茄和绿色未成熟番茄两个类别,采用 LabelImg 进行人工标注,以番茄果实的最小外接矩形为标准标定真实框体,将果实红色着色面积低于 20%的目标标注为绿色未成熟番茄(GreenTomato),将红色着色面积超过 80%的标注为红色成熟番茄(RedTomato),而红色着色面积在 20%~80%范围内属于转色阶段的番茄虽尚未完全成熟,但考虑到后续的运输和储存需求,也标记为红色成熟番茄。不同数据集各类别标注框体数量见表 1。




图 1 数据增强处理示例

表 1 不同数据集各类别标注框体数量统计

数据集类别（图片数量/张）	红色成熟番茄标注框体数量/个			绿色未成熟番茄标注框体数量/个		
	训练集	测试集	验证集	训练集	测试集	验证集
实地拍摄数据集（1 873）	5 076	1 284	591	2 595	736	334
筛选的开源数据集（225）	823	211	117	149	41	18
数据增强后的训练集（2 770）	9 329	1 495	708	5 041	777	352

1.2 轻量级复杂环境番茄检测算法 SPC-DETR 的建立

1.2.1 基线模型 RT-DETR

RT-DETR 的结构主要包括主干网络（BackBone）、颈部网络（Neck）以及带辅助预测头的变换解码器（Transformer Decoder）。相较于 YOLO 系列方法，RT-DETR 摒弃手动设计锚框和 NMS 后处理步骤，除主干网络仍采用卷积神经网络（Conventional Neutral Network, CNN）外，其余均由 Transformer^[16]处理。RT-DETR 在 Neck 部分设计一个高效混合编码器（Efficient Hybrid Encoder），由基于注意力的尺度内特征交互模块（Attention-based Intra-scale Feature Interaction, AIFI）和基于 CNN 的跨尺度特征融合模块（CNN-based Cross-scale Feature-fusion Module, CCFM）组成，其中，AIFI 仅在特征内部进行尺度特征交互，以降低计算负担；CCFM 则通过卷积层组成的融合块（Fusion Block）嵌入特征融合路径，将相邻特征融合为新特征，并通过逐元素加法融合输出，转换多尺度特征为图像特征序列。在 Decoder 部分引入一种改进的感知查询选择机制 IoU-Aware，通过筛选出与真实边界框 IoU 值较高的图像特征，来初始化解码器的对象查询。检测头仍沿用 DINO^[17]的检测头，通过迭代优化对象查询，生成边界框和置信度分数。

RT-DETR 官方提供包括 ResNet、HGNet 等不同主干网络的模型，本研究针对复杂环境下番茄果实检测任务中低计算开销和高检测精度的实际需求，选取以 ResNet-18 为主干网络的 RT-DETR-R18 作为基线模型并对其进行轻量化和精度提升改进。RT-DETR-R18 的网络架构如图 2 所示。




图 2 RT-DETR-R18 模型架构

1.2.2 SPC-DETR 整体网络结构

在对比不同轻量化网络架构的基础上，本研究选用 StarNet 并引入 iRMB 块替换其 StarBlock 内部第一个深度优先

卷积（Depth-Wise Convolution, DWConv），构建了一种轻量级的特征提取网络 iR-StarNet，并用其替换 RT-DETR-R18 的主干网络，以提高模型对多尺度目标的适应性及应对复杂场景的能力，用于提取复杂环境下的番茄果实图像特征信息；设计融合高效多尺度注意力（Efficient Multi-Scale Attention, EMA）的并行空洞卷积注意力模块 EMA-PDC，将其引入 CCFM 层的 Fusion Block，以提高模型捕获番茄果实细微特征的能力；采用 DEA-Net 思想中的基于内容引导注意力特征融合方案 CGAFusion^[18]，以提高模型动态特征融合能力。最终得到改进后的番茄果实检测模型 SPC-DETR，其整体网络架构如图 3 所示。




图 3 改进后的 SPC-DETR 模型的网络架构

1.2.3 构建 iR-StarNet 特征提取网络

为实现在边缘设备中部署番茄果实检测算法，降低检测模型的复杂度，保障检测的实时性，本研究引入 Ma 等^[19]提出的 StarNet 网络作为基础网络并对其存在的局限性进行改进。StarNet 网络中 StarBlock 的核心优势在于双分支并行全连接后引入并重新定义的星形操作，其有效缓解了 Monarch Mixer^[20]、Mamba^[21]和 FocalNet^[22]等传统深度神经网络在处理高维数据时面临的计算复杂度和特征提取效率问题，并且星形操作通过类似于核函数的处理方式将输入数据直接映射到高维非线性特征空间，不仅保留了低维数据的结构信息，还能在高维空间中捕捉到更多、更复杂的特征，从而在不显著增加计算量的前提下有效提升网络的特征提取能力和计算效率。虽然 StarBlock 模块的星形操作提高了计算效率，但其特征提取部分的 DWConv 仅在每个通道内部进行卷积操作，导致通道间信息交互不足，使得模型在处理高维数据时可能无法充分利用各通道间的特征，进而限制了捕捉复杂全局上下文信息的能力，在面对复杂场景下的番茄目标细粒度特征提取时表现不佳。针对该问题，本研究引入倒置残差移动块 iRMB 替换 StarBlock 中的首个 DWConv，构建新的模块 iR-StarBlock，其结构如图 4b 所示。

iRMB 通过对 MobileNet-v2^[23]的反向残差块（Inverted Residual Block, IRB）进行扩展，提出一种结构如图 4(a)所示的元移动块（Meta-Moblie Block, MMB），并在此基础上对其内部的高效算子 F 进行实例化设计，通过改进扩展窗口多头自注意力（Expanded Window MHSA, EW-MHSA）和卷积运算实现高效的特征提取和信息流^[24]，在计算资源有限的场景中提供高效性能。iRMB 模块采用 EW-MHSA 用于学习检测目标的长距离特征交互，模拟 Transformer 的动态全局建模能力，并结合 Conv_Local 模块用于学习检测目标的局部特征交互。为降低计算复杂度，EW-MHSA 将未扩展的输入特征 $F \in R^{C \times W \times H}$ 作为查询键 F_{qk} ，从而将注意力矩阵的计算复杂度从原来的 $O(C^2 \cdot H \cdot W)$ 降低为 $O(C \cdot H \cdot W)$ ，同时将扩展后的特征 $F_e \in R^{\lambda C \times W \times H}$ 经过卷积和 SiLU 激活函数后的输出特征作为值 F_v ，降低计算开销的同时保持特征表达能力，最后使用 Upsample 操作变换 F_v 得到 $F_e \in R^{B \times \lambda C \times H \times W}$ 。 F_e 通过 Conv_Local 模块提取局部空间特征，随后经过 Dropout、 1×1 卷积、DropPath、深度可分离卷积、批量归一化和 SiLU 激活等操作，最终通过残差连接与输入特征融合，有效捕捉目标的细粒度局部信息。利用 iRMB 的全局-局部互补设计思想可以有效提升模型对多尺度番茄目标的特征提取能力。




图 4 MMB 模块与改进的 iR-StarBlock 结构

本研究通过上述改进构建了新的主干网络 **iR-StarNet**，并用其替换基线模型所使用的主干网络 **ResNet-18**。与原主干网络 **ResNet-18** 相比，**iR-StarNet** 实现了提取和保持番茄果实特征与多样性的同时减少网络整体参数量并提升计算效率，而且在引入 **iRMB** 后，能够同时兼顾 **Transformer** 的动态全局建模能力和 **CNN** 的静态局部信息融合能力，有效提高模型对多尺度目标的适应性与应对复杂场景的能力。

1.2.4 设计 EMA-PDC 模块

在复杂环境下的番茄识别任务中，网络模型特征融合的效率 and 感受野的大小是决定模型性能的关键因素。原模型颈部网络中高效混合编码器的 **RepC3** 模块采用直接元素加法融合策略，在处理复杂和高维特征信息时由于不能充分挖掘并利用各分支特征信息，对模型的整体识别能力产生不利影响，尤其是在面临多尺度番茄目标识别场景时，因 **RepC3** 感受野受限和对细微特征表达能力不足，导致模型识别能力不佳。为此，本研究设计一种融合 **EMA** 的并行空洞卷积结构 **EMA-PDC**，其整体结构如图 5 所示。




图 5 EMA-PDC 模块的结构

每个 **PDC** 模块有三个并行的空洞卷积通道，分别采用具有不同膨胀系数的卷积核对输入特征进行并行处理，三个通道的膨胀系数分别设置为 1、2 和 3。膨胀系数决定了卷积核在滑动过程中相邻采样点的间隔，值为 1 表示使用传统的标准卷积，值大于 1 则表示通过在卷积核的权重之间插入零元素来扩大感受野，从而有效地模拟更大的卷积核而不增加参数量，这能有效替代池化采样方案^[25]。不同膨胀系数的空洞卷积如图 6 所示，可以看出，膨胀系数为 1 的空洞卷积，即标准卷积，感受野为 3×3 ；而膨胀系数为 2 和 3 的空洞卷积，感受野分别扩展为 5×5 和 7×7 。通过在同一特征图上应用多个不同膨胀系数的卷积核，网络能够捕获不同尺度的上下文信息，从而提高特征的丰富度，增强其多尺度表示的准确性。




图 6 不同膨胀系数的空洞卷积可视化

尽管三个不同膨胀系数的并行空洞卷积通道能够捕捉不同尺度的信息，但空洞卷积在采样时存在间隔，导致相邻像素之间的信息交互受限，仍然有无法有效处理长距离信息间关系的可能性，从而导致捕获的信息缺乏相关性，产生对复杂环境下多尺度目标番茄识别效果不佳的问题。为进一步提升这种结构捕获远程依赖关系和细粒度信息的能力，本研究在三个并行空洞卷积支路后均接入一个 EMA 模块。

EMA 模块采用多尺度并行子网络，避免使用常规卷积方式进行降维，在保持通道信息完整性同时实现跨维度特征交互，通过跨空间信息聚合的学习方法完成对长短期依赖关系的有效建模，同时融合不同尺度的上下文信息，增强模型对关键区域特征的关注能力，从而获得更丰富的聚维特征。其整体结构如图 7 所示。在 EMA 中，对于给定的输入特征，通过三个并行分支提取注意力权重：空间注意力分支通过水平方向（X AvgPool）和垂直方向（Y AvgPool）的平均池化操作分别捕捉空间上的长短期依赖关系，这两个池化后的特征被拼接（Concat）后通过一个 1×1 卷积层进行融合和维度调整，随后经过 Sigmoid 函数生成空间注意力权重并与输入特征进行重加权（Re-weight）操作；局部特征分支通过一个 3×3 卷积层捕获局部跨通道特征以扩大特征空间，随后经过 Sigmoid 函数生成局部注意力权重并与输入特征进行重加权（Re-weight）操作。在跨空间信息聚合（cross-spatial learning）阶段，输入特征被送入两个并行路径：路径一经过组归一化（GroupNorm）和平均池化（AvePool）后通过 Softmax 函数进行归一化处理得到一组权重系数，路径二经过平均池化（AvePool）后通过 Softmax 函数进行归一化处理得到另一组权重系数，随后这两组权重系数通过矩阵点积（Matmul）进行融合，生成融合了空间信息与通道信息的注意力特征表示，此融合结果与一个中间特征相加，再经过 Sigmoid 函数捕捉像素级的成对关系，最终通过重加权（Re-weight）操作输出模块的最终特征表示，从而实现高效的跨空间信息聚合




图 7 EMA 结构

经过三个 EMA 模块处理后的特征图在通道维度上被合并，并通过降维操作减少模型的复杂性，同时保留最重要的信息，得到最终输出。这一系列的融合和降维步骤能够提升模型的表征能力和计算效率，同时减少一定量的信息冗余并优化特征表达。

综合来看，引入 EMA-PDC 模块的优势在于其采用的并行空洞卷积结构允许网络在不增加参数量或不降低分辨率的情况下进一步增大感受野，同时引入的 EMA 注意力机制进一步加强网络对全局上下文信息的捕捉能力，增强对细粒度特征的判别能力，能更有效地应对遮挡、密集小目标等复杂因素的影响，从而更加准确定位番茄果实对象。而且相比 CBAM^[26]、ECA^[27]等注意力机制，引入 EMA 对整体参数量与计算量的增加极少。

1.2.5 基于内容引导注意力特征融合方案 CGA-Fusion 进一步改进 Neck 网络

原模型 Neck 网络中的混合编码器能够融合不同尺度的特征，在一定程度上提升对中小尺度番茄目标的检测能力。

但其融合方式是静态的，即在整个处理过程中特征的融合策略是预先设定的，无法充分适应图像中不同区域的特征差异，并且无法根据不同输入图像的具体内容动态调整特征权重。因此，本研究在三个 EMA-PDC 模块后引入 CGA-Fusion 来进一步改进 Neck 网络，通过将编码器部分输出的特征输入到 CGA 模块实现特征的自适应融合，更好地理解 and 处理图像中的复杂特征分布问题。通过这种动态特征融合方法，模型能够更精准地捕捉复杂环境下的番茄关键特征信息，从而提升检测精度和鲁棒性。CGA-Fusion 方案如图 8 所示。




图 8 CGA-Fusion 方案

从编码器输出的低层特征 (Low-level Features) 和高层特征 (High-Level Features) 经加权求和后作为 CGA 模块的输入特征 $Input \in R^{C \times H \times W}$ ，在 CGA 中通过通道注意力和空间注意力操作得到 O_c 和 O_s ，具体操作结果如式 (5) 和式 (6) 所示，输出的特征再按式 (7) 进行加权求和，得到 $O_{add} \in R^{C \times H \times W}$ ，

$$O_c = \text{Conv}(\text{ReLU}(0, \text{Conv}(X_{GAP}^c))) \quad (5)$$

$$O_s = \text{Conv}([X_{GAP}^s, X_{GMP}^s]) \quad (6)$$

$$O_{add} = O_c + O_s \quad (7)$$

式中， O_c 和 O_s 分别为通道注意力和空间注意力操作输出特征；ReLU 是非线性激活函数； X_{GAP}^c 是跨空间维度的全局平均池化特征； X_{GAP}^s 是跨通道维度的全局平均池化特征； X_{GMP}^s 是跨通道维度的全局最大池化特征； X_{GMP}^s 是加权求和处理后的最终结果输出； O_{add} 是双注意力操作加权求和处理后的最终输出结果。为了得到更精细的输出结果 $Output$ ，将 O_{add} 进行张量拼接，采用 ShuffleNet^[28] 设计思想对其每个通道进行通道混洗操作，以交替方式重新排列，再经过核尺寸为 7 的分组卷积来保留空间域上的权重共享特性，同时引入通道域的分组处理机制，以学习到更丰富的特征表示。经过 CGA 处理后的特征输出与高低层特征加权融合后，再通过 1×1 卷积进行通道调整，完成最终特征输出。

1.3 模型评价方法与试验设置

1.3.1 模型评价指标

本研究采用浮点运算量 (FLOPs) 作为检测模型检测速度的评价指标，用模型权重大小 (Model Size)、参数量 (Params) 作为模型复杂度评估指标，用精确率 (Precision, P)、召回率 (Recall, R)、50% IoU 阈值下的全类平均精度 (mAP50) 作为模型性能评估指标。

1.3.2 实验环境与参数设置

实验使用的服务器具体配置见表 2，软件环境包括 Python 3.10、深度学习框架 PyTorch 2.1.0、CUDA 版本 12.1。在实验超参数设置方面，选择 AdamW 优化器来最小化损失函数并调整模型参数，权重衰减率设置为 0.0001，学习率初始化为 0.0001，批量大小 Batch Size 设置为 4，每张图片输入大小统一缩放为 640×640 像素，并设置训练轮次 (Epoch) 为 150，早停轮次 (Early Stop) 为 20。参考跨域迁移学习思想，利用微软的开源 COCO 2017 数据集^[29]进行训练，使用训练得到的预训练权重作为初始化权重用于自建番茄数据集训练。通过比较使用和未使用迁移学习的损失曲线 (图 9) 发现，进行迁移学习后的算法损失值下降更快，收敛速度更快、更稳定，表明使用迁移学习可以帮助模型在训练时更快找到有效的学习路径并调整相应权重。另外，损失曲线整体变化趋势也显示算法拟合情况正常，证明了自建番茄数据集的有效性。因此，借助迁移学习思想，利用在大型通用数据集上预训练模型所习得的通用视觉特征 (如边缘、纹理等底层视觉信息)，能够有效改善自建番茄数据集样本规模有限、数据分布单一的问题，帮助模型在检测任务中更快收敛至更优解，同时提升模型的泛化能力，实现对番茄相关特征的精准学习与目标识别。




图 9 损失曲线
表 2 服务器配置

配置名称	具体信息
操作系统	Ubuntu 22.04
中央处理器	16 vCPU Intel(R) Xeon(R) Gold 6430
图像处理器	RTX 4090(24GB *1)
随机存储器	120G

2 结果与分析

2.1 SPC-DETR 模型对不同类别番茄果实的检测结果对比

从表 3 中可以看出,SPC-DETR 模型对红色成熟番茄果实的检测结果较好,精确率、召回率和 mAP50 分别为 91.3%、89.3%和 94.6%;对绿色未成熟番茄果实的检测结果相对较差,精确率、召回率和 mAP50 分别为 84.6%、78.0 和 85.8%,导致此种情况的原因一个可能是绿色未成熟番茄果实易与果茎和果梗混淆,产生误检和漏检;另一个可能是绿色果实数据量较红色果实少,模型未能得到充分学习及优化,泛化性较弱。

表 3 SPC-DETR 模型在不同类别番茄检测结果对比

数据类别	精确率/%	召回率/%	mAP50/%
红色成熟番茄果实	91.3	89.3	94.6
绿色未成熟番茄果实	84.6	78.0	85.8
全类别均值	88.0	83.7	90.2

2.2 不同主干网络对模型性能的影响

分别选用基线模型的 ResNet-18 以及近年来较有代表性的轻量化网络 EfficientViT、MobileNetv4、RepViT 作为主干网络与本研究设计的 iR-StarNet 进行对比实验,从检测结果(表 4)可以看出,在全类别番茄检测任务中,使用本研究构建的主干网络 iR-StarNet 时,模型权重大小、参数量和浮点运算量较使用 ResNet-18 分别降低 34.72%、35.64%和 41.30%,精确率、召回率和 mAP50 分别上升 1.5、0.8 和 0.4 个百分点;EfficientViT 在浮点运算量和模型权重上具备一定优势,但精确率、召回率及 mAP50 均不如 iR-StarNet;RepViT 各项评估指标均落后于 iR-StarNet;MobileNetv4 在模型权重、参数量和精确率上较 iR-StarNet 稍具优势,但在召回率和 mAP50 上的表现仍不及 iR-StarNet。表明 iR-StarNet 在检测效果上表现更优,能够更好地满足复杂环境下番茄果实识别的高精度要求,并且适合于设备资源有限的部署需求,在性能与部署资源占用间实现了较好的平衡。

表 4 使用不同主干网络的模型性能对比

主干网络	模型权重大小/MB	参数量/M	浮点运算量 /GFLOPs	精确率/%	召回率/%	mAP50/%
ResNet-18	38.6	20.2	58.6	86.0	83.4	88.5
EfficientViT	21.7	11.0	27.2	86.7	80.3	86.4
MobileNetv4	22.3	11.6	40.9	87.7	82.5	88.2
RepViT	27.4	13.4	36.3	88.1	79.2	85.5
iR-StarNet	25.2	13.0	34.4	87.5	84.2	88.9

注:准确率、召回率、mAP50 均取红色成熟番茄与绿色未成熟番茄的全类别均值。

2.3 消融实验

2.3.1 iRMB 不同添加位置和数量实验

为验证倒置残差移动块 iRMB 在 StarNet 上替换 DWConv 的数量和位置对模型性能的影响,在仅替换主干网络为 StarNet 的基础上,进一步用 iRMB 替换图 4b 中 StarBlock 网络的位置 1 和位置 2,进行消融实验,结果(表 5)显示,

在位置 1 和位置 2 同时使用 iRMB 时，精确率和 mAP50 均最高，较未添加时分别提高 1.9 和 0.5 个百分点，但同时也导致模型权重大小、参数量和浮点运算量上升程度较大，分别上升 14.83%、15.57%、18.87%。仅在位置 1 使用 iRMB，虽然相比两个位置都添加时精确率和 mAP50 略低，分别仅降 1.7、0.1 个百分点，召回率一致，但模型权重大小、参数量、浮点运算量明显降低 7.01%、7.80%、8.99%。仅在位置 2 使用 iRMB 的准确率与未添加时一致，但召回率和 mAP50 分别下降 0.7 和 0.6 个百分点，这可能是因为该位置接收到的特征已经过多层处理，逐渐精简成高层语义信息，缺乏足够的上下文支撑，导致 iRMB 无法充分发挥其特征提取能力。综合来看，仅在位置 1 使用 iRMB 的特征提取效果最佳，可能是因为特征输入初期信息流最为丰富，iRMB 内部的扩展改进多头注意力机制可以捕获全局特征，因而能以最小的网络复杂度代价获得最佳的改进效果。

表 5 iRMB 改进主干网络位置消融试验

实验 编号	位置 1	位置 2	模型权重 大小/MB	参数量/M	浮点运算量 /GFLOPs	精确率/%	召回率/%	mAP50/%
1			23.6	12.2	31.8	86.0	84.2	88.5
2	√		25.2	13.0	34.4	86.2	83.6	88.9
3		√	25.2	13.0	34.4	86.0	83.5	87.9
4	√	√	27.1	14.1	37.8	87.9	83.6	89.0

注：“√”表示使用 iRMB；实验编号 1 为未替换 iRMB 仅实现 StarNet 改进的模型。

2.3.2 本研究所提改进点的消融实验

为探究本研究提出的改进方法对于模型性能的提升效果，进行消融实验，结果见表 6。可以看出，与基线模型 RT-DETR-R18 相比，使用改进的 iR-StarNset 替换主干网络后，模型的权重大小、参数量大幅降低，提升了计算和存储效率，精确率、召回率、mAP50 分别提升 0.2、0.9、0.4 个百分点。之后在颈部网络的 CCFM 部分设计 EMA-PDC 模块对 RepC3 进行替换，模型进一步轻量化，但检测精度（mAP50）相比原模型上升 1.0 个百分点。在上述改进基础上再引入基于内容引导注意力融合方案 CGA-Fusion 改进颈部网络，模型的计算量和参数量未有明显增加，但模型性能进一步优化，最后结合迁移学习使模型性能达到最佳，对比基线模型 RT-DETR-R18，精确率、召回率、mAP50 分别提高 2.0、0.3、1.7 个百分点，而参数量、浮点运算量、模型权重大小分别降低 35.15%、40.96%、34.72%，表明 SPC-DETR 在保持高检测效率的同时实现了模型的轻量化。

表 6 SPC-DETR 模型改进点的消融实验结果对比

实验 编号	iR-StarNet	EMA-PDC	CGA-Fusion	迁移学习	模型权重大小/MB	参数量/M	浮点运算量/G	精确率/%	召回率/%	mAP50/%
1					38.6	20.2	58.6	86.0	83.4	88.5
2	√				25.2	13.0	58.6	86.2	84.3	88.9
3	√	√			24.9	12.7	34.4	87.6	83.6	89.5
4	√	√	√		25.2	13.1	34.6	87.9	83.6	89.8
5	√	√	√	√	25.2	13.1	34.6	88.0	83.7	90.2

注：“√”表示进行该项改进。

2.4 不同模型对比试验

为比较 SPC-DETR 与主流检测模型在自建番茄数据集上的检测效果，选择 YOLOv5m、YOLOv6s、YOLOv7、YOLOv8m、YOLOv9c、YOLOv10m、YOLOv11m、Deformable DETR-R50 和 DINO-4scale-R50 共 8 种目前主流检测模型，在保证实验条件一致的前提下，与 SPC-DETR 进行对比试验，结果如表 7 所示。可知，SPC-DETR 的精确率、模型权重大小、浮点运算量、参数量均优于 YOLO 系列模型，召回率较优，mAP50 相较 YOLOv5m、YOLOv6s、YOLOv7、YOLOv8m、YOLOv10m 和 YOLOv11m 分别高出 2.85%、4.52%、3.44%、2.50%、0.89%和 1.23%；虽然 SPC-DETR 的 mAP50 低于 YOLOv9c 1.2 个百分点，但权重大小、参数量、计算量方面远低于该对比模型，准确率高 0.8 个百分点。在 DETR 系列模型中，SPC-DETR 的精确率最高，mAP 仅略低于 DINO-4scale-R50（降 1.8 个百分点），召回率略低于 Deformable DETR-R50 和 DINO-4scale-R50（分别降 0.7、1.4 个百分点），但模型权重大小、参数量、浮点运算量最低，降幅分别达 34.72%~95.41%、35.64%~72.84%、41.30%~86.00%。综合来看，本研究提出的改进模型 SPC-DETR 可以在较低的计算资源下获得接近最优的检测性能，实现了检测性能与资源占用之间的平衡，这可为 Transformer 架构的目标检测器在实际生产中应用提供有效参考。

表 7 SPC-DETR 模型与其他模型检测结果对比

模型名称	模型权重大小/MB	参数量/M	浮点运算量 /GFLOPs	精确率/%	召回率/%	mAP50/%
YOLOv5m	40.3	21.2	47.9	84.6	82.8	87.7
YOLOv6s	32.9	18.5	44.0	86.7	81.8	86.3
YOLOv7	74.8	36.9	104.7	85.5	82.0	87.2
YOLOv8m	49.6	25.9	78.9	86.9	82.3	88.0
YOLOv9c	49.2	25.3	102.8	87.2	84.6	91.4
YOLOv10m	31.9	15.4	59.1	86.4	83.8	89.4
YOLOv11m	38.7	20.0	67.7	87.1	84.6	89.1
Deformable DETR-R50	473.5	40.1	172.0	83.1	84.4	89.8
DINO-4scale-R50	549.4	47.5	245.0	87.8	85.1	92.0
RT-DETR-R18	38.6	20.1	58.6	87.0	83.4	88.5
SPC-DETR	25.2	12.9	34.3	88.0	83.7	90.2

2.5 SPC-DETR 与 RT-DETR-R18 模型对番茄果实检测结果对比

图 10 展示了原模型 RT-DETR-R18 和改进模型 SPC-DETR 在测试集上的推理结果，不同类型果实采用不同颜色的矩形框进行标识并在框边展示对应置信度分数。可知原模型在番茄果实多尺度变化、暗光场景中适应性较差，出现目标漏检问题，如：在多尺度目标场景 1 中漏检下部位置一个红色番茄果实，在多尺度目标场景 2 中漏检下部位置四个番茄果实，在暗光场景 1 中漏检左下部和上部位置两个红色和 1 个绿色番茄果实，在暗光场景 2 中漏检一个绿色番茄果实；而 SPC-DETR 模型在番茄果实多尺度和低光照场景中漏检情况少，且置信度有一定提升，均取得较好的识别效果。




图 10 改进模型与原模型在测试集上的检测结果可视化

目标检测热力图可用于呈现图像中信息对于预测结果的贡献，热力分数越高（颜色越红）的地方表示在输入图像中该区域对网络的响应程度越高^[30]。为评估改进后的 SPC-DETR 模型较原模型检测性能的提高水平，采用梯度加权类激活映射 Grad-CAM（gradient-weighted class activation mapping）方法^[31]对模型检测结果进行热力图可视化，图 11 为 RT-DETR-R18 和 SPC-DETR 模型在测试集中对部分复杂环境下番茄果实图像检测的热力图，图中从蓝色到红色的加深表示模型对图片关注度的增加。可以看出，RT-DETR-R18 的热力分数较低，且在关注果实时焦点较为分散，大都接近番茄果实边缘区域，无法有效捕捉到整体信息，而 SPC-DETR 模型的检测焦点则更加集中和准确，更贴近真实果实区域，证明改进后的 SPC-DETR 模型可以有效捕捉番茄果实特征。




图 11 改进模型与原模型检测番茄果实的热力图可视化

2.6 模型的跨数据集泛化性试验结果分析

为验证本研究提出的改进方法的泛化性，选用 Kaggle 的公开数据集 Olive Fruit 对 SPC-DETR 和基线模型 RT-DETR-R18 模型进行对比实验，该数据集中的橄榄果均较为密集且遮挡情况较多，与本研究番茄果实分布相似。结果（表 8）显示，与 RT-DETR-R18 相比，SPC-DETR 在参数量、浮点运算量、模型权重大小分别减少 35.64%、41.30% 和 34.72% 的情况下精确率、召回率、mAP50 分别提升 0.8、1.1、1.2 个百分点，说明 SPC-DETR 的泛化性更好。由图 12 的综合性能雷达图可以看出，SPC-DETR 模型所占图形区域更加饱满，表明改进后的模型较基线模型在 Olive Fruit 数据集上更接近理想状态。

表 8 SPC-DETR 与 RT-DETR-R18 模型的泛化性实验结果对比

数据集	模型名称	精确率/%	召回率/%	mAP50/%
Kaggle 的 Olive Fruit	RT-DETR-R18	90.6	80.8	86.7
	SPC-DETR	91.4	81.9	87.9




图 12 跨数据集改进模型与原模型的综合性能雷达图

3 结论

针对复杂环境下番茄果实识别高准确率和边缘部署低资源占用等要求，本研究提出一种基于 RT-DETR 改进的轻量级算法 SPC-DETR，得到如下结论：

(1) 选取 RT-DETR-R18 作为基线模型，对其进行改进。首先，以轻量级网络 StarNet 为基础框架，通过引入 iRMB 替换 StarBlock 模块中的首个 DWConv，构建得到 iR-StarNet，用其替换原主干网络，在轻量化主干网络的同时增强了模型对番茄特征的提取能力；其次，设计一种融合高效多尺度注意力的并行空洞卷积注意力模块 EMA-PDC，并用其替代 CCFM 中用于特征融合的 RepC3，能够使模型有效学习番茄果实的长距离特征交互及多尺度目标的局部特征交互，

不仅有效降低了计算量,还进一步提升了特征提取的准确性,增强了模型的识别能力;最后,采用基于内容引导注意力的特征融合方案 CGA-Fusion 对颈部网络进行改进,进一步增强模型在复杂背景下的特征表示能力。

(2)消融实验结果验证了各项改进措施的有效性,均对提升模型性能产生积极影响。对比基线模型 RT-DETR-R18, SPC-DETR 在保持召回率几乎不变的情况下, mAP50 提高 1.7 个百分点,参数量、浮点运算量和模型权重分别减少 35.64%、41.30%和 34.72%,实现了轻量化与高精度的有效平衡。与 YOLO 系列、DETR 系列主流检测模型的对比实验结果也表明, SPC-DETR 在精确率、模型权重、计算量和参数量等方面均优于多数 YOLO 系列和 DETR 系列模型,召回率较优, mAP50 达到 90.2%,展现出较强的综合性能优势。另外,本研究在 Kaggle 开源的橄榄果检测数据集 Olive Fruit 上进行泛化性试验,试验表明 SPC-DETR 对于橄榄果的检测性能也能拥有较高的提升,证明本研究方法对于其他同属密集遮挡且属多尺度类别检测具有较好的泛化性能。

(3)对复杂场景下的番茄果实检测结果证明, SPC-DETR 模型在不同光照和遮挡条件下能够有效地检测出番茄果实。未来的研究将侧重于将该模型集成到智能番茄采摘机器人中进行实际应用验证,并在真实的番茄种植环境中部署评估和改进模型,以推进复杂环境下的番茄识别实地应用研究。

参 考 文 献 (文献 24 文中未引用)

- [1] 唐林. 基于电阻抗的开花期番茄叶片含水率检测仪研发[D]. 杨凌: 西北农林科技大学, 2023.
- [2] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]// Proceedings of the 2014 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2014: 580-587.
- [3] Girshick R. Fast R-CNN[C]//2015 IEEE International Conference on Computer Vision (ICCV). IEEE, 2015: 1440-1448.
- [4] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: unified, real-time object detection[C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2016: 779-788.
- [5] 张文静, 赵性祥, 丁睿柔, 等. 基于 Faster R-CNN 算法的番茄识别检测方法[J]. 山东农业大学学报(自然科学版), 2021, 52(4): 624-630.
- [6] 龙洁花, 赵春江, 林森, 等. 改进 Mask R-CNN 的温室环境下不同成熟度番茄果实分割方法[J]. 农业工程学报, 2021, 37(18): 100-108.
- [7] Gao G H, Wang S Y, Shuai C Y, et al. Recognition and detection of greenhouse tomatoes in complex environment[J]. International Information and Engineering Technology Association, 2022, 39: 291-298.
- [8] 成伟, 张文爱, 冯青春, 等. 基于改进 YOLOv3 的温室番茄果实识别估产方法[J]. 中国农机化学报, 2021, 42(4): 176-182.
- [9] 苗荣慧, 李志伟, 武锦龙. 基于改进 YOLO v7 的轻量化樱桃番茄成熟度检测方法[J]. 农业机械学报, 2023, 54(10): 225-233.
- [10] 何斌, 张亦博, 龚健林, 等. 基于改进 YOLO v5 的夜间温室番茄果实快速识别[J]. 农业机械学报, 2022, 53(5): 201-208.
- [11] 张俊宁, 毕泽洋, 闫英, 等. 基于注意力机制与改进 YOLO 的温室番茄快速识别[J]. 农业机械学报, 2023, 54(5): 236-243.
- [12] 李名博, 刘玉乐, 穆志民, 等. 基于 YOLOX-L-TN 模型的番茄果实识别[J]. 中国农业科技导报, 2024, 26(4): 97-105.
- [13] Appe S N, Arulselvi G, Balaji G N. CAM-YOLO: tomato detection and classification based on improved YOLO v5 using combining attention mechanism[J]. PeerJ Computer Science, 2023, 9: e1463.
- [14] 代国威, 樊景超, 胡林. 采用天气增强与八度卷积改进 YOLOv5 的番茄检测模型构建[J]. 山东农业科学, 2022, 54(11): 138-149.
- [15] Zhao Y A, Lv W Y, Xu S L, et al. DETRs beat YOLOs on real-time object detection[C]//Proceedings of the 2014 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2024: 16965-16974.
- [16] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc., 2017: 6000-6010.
- [17] Zhang H, Li F, Liu S L, et al. DINO: DETR with improved DeNoising anchor boxes for end-to-end object detection[C]//The Eleventh International Conference on Learning Representations. 2023
- [18] Chen Z X, He Z W, Lu Z M. DEA-Net: Single image dehazing based on detail-enhanced convolution and content-guided attention[J]. IEEE Transactions on Image Processing, 2024, 33: 1002-1015.
- [19] Ma X, Dai X Y, Bai Y, et al. Rewrite the Stars[C]//Proceedings of the 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2024: 5694-5703.
- [20] Fu D Y, Arora S, Grogan J, et al. MONARCH MIXER: a simple sub-quadratic GEMM-based architecture[C]//Proceedings of the 37th International Conference on Neural Information Processing Systems, 2024, 36: 77546-77603.
- [21] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[DB/OL]. arXiv: 2312.00752 [cs.LG], 2023. <https://doi.org/10.48550/arXiv.2312.00752>.
- [22] Yang J W, Li C Y, Dai X Y, et al. Focal modulation networks[C]//Proceedings of the 36th International Conference on Neural Information Processing Systems. 2022: 4203-4217.
- [23] Sandler M, Howard A, Zhu M L, et al. Mobilenetv2: inverted residuals and linear bottlenecks[C]//Proceedings of the 2018 IEEE Conference on Computer Vision and Pattern Recognition. 2018: 4510-4520.
- [24] Zhang J N, Li X T, Li J, et al. Rethinking mobile block for efficient attention-based models[C]//Proceedings of the 2023 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2023: 1389-1400.
- [25] 张丽珍, 李延天, 李志坚, 等. 基于混合空洞卷积和注意力多尺度网络的残饵密度估计[J]. 农业工程学报, 2024, 40(14): 137-145.
- [26] Woo S, Park J, Lee J Y, et al. CBAM: Convolutional block attention module[C]//Computer Vision – ECCV 2018. ECCV 2018. Lecture Notes in Computer Science, vol11211. Cham.: Springer, 2018: 3-19.

-
- [27] Wang Q L, Wu B G, Zhu P F, Et al. ECA-Net: efficient channel attention for deep convolutional neural networks[C]//Proceedings of the 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. IEEE, 2020: 11534-11542.
- [28] Zhang X Y, Zhou X Y, Lin M X, et al. Shufflenet: an extremely efficient convolutional neural network for mobile devices[C]//Proceedings of the 2018 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2018: 6848-6856.
- [29] Lin T Y, Maire M, Belongie S, et al. Microsoft COCO: Common objects in context[C]//Computer Vision—ECCV 2014. ECCV 2014. Lecture Notes in Computer Science, vol8693. Cham.: Springer, 2014: 740-755.
- [30] 苗荣慧, 李港澳, 黄宗宝, 等. 基于 YOLO v7-ST-ASFF 的复杂果园环境下苹果成熟度检测方法[J]. 农业机械学报, 2024, 55(6): 219-228.
- [31] Selvaraju R R, Cogswell M, Das A, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the 2017 IEEE International Conference on Computer Vision. IEEE, 2017: 618-626.

