



广东技术师范大学
Guangdong Polytechnic Normal University

硕士学位论文

基于改进小目标实时检测 Transformer 的 研究与应用

Research and Application of an Improved Real-time Transformer
for Small Target Detection

作	者	王苏皖
导	师 姓 名 职 称	肖政宏教授
专	业 学 位 类 别	电子信息
领	域	计算机技术
所	在 学 院	计算机科学学院
学	生 类 别	全日制 ☒ 非全日制 ☐
论	文 提 交 日 期	2025 年 06 月



广东技术师范大学
Guangdong Polytechnic Normal University

Research and Application of an Improved Real-time Transformer
for Small Target Detection

By

Wang Suwan

A Thesis Submitted to
Guangdong Polytechnic Normal University
in Partial Fulfillment of the Requirements
for the Master's Degree

June, 2025

中 图 分 类 号 TP391
U D C 004.9

学 校 代 码 10588
密 级 公开



广东技术师范大学
Guangdong Polytechnic Normal University

硕士学位论文

基于改进小目标实时检测 Transformer 的 研究与应用

Research and Application of an Improved Real-time Transformer
for Small Target Detection

作 者	王苏皖	导师姓名职称	肖政宏教授
申 请 学 位	电子信息	所 在 学 院	计算机科学学院
专 业 学 位 类 别	电子信息	领 域	计算机技术
答 辩 委 员 会 主 席	周继鹏教授	评 阅 人	匿名评阅

2025 年 06 月

摘要

无人机图像小目标检测在军事侦察、环境监测等多领域具有重要战略意义，已成为计算机视觉领域的研究热点。然而，实际应用中，小目标因尺寸微小易受复杂背景、噪声及光照变化干扰，导致特征提取与融合困难；同时，高分辨率和动态场景带来的计算复杂度激增，对检测算法的实时性与准确性提出严苛要求。现有深度学习目标检测方法在小目标处理上存在特征提取不足、多尺度融合效率低及模型复杂度高的问题。为此，本文提出基于改进 RT-DRTR 的小目标检测方法，通过优化特征提取与多尺度融合机制，提升检测精度与鲁棒性，具体研究成果如下：

（1）提出了跨阶段并行与自适应下采样联合特征提取网络。设计轻量化的跨阶段并行特征提取 RepCSPNet 块，在降低计算复杂度的同时，增强小目标特征提取能力；为解决传统下采样手段于小目标特征提取时产生细节信息损失的问题，引入自适应下采样模块 ADown，可依据图像内容动态选择下采样方式，有效避免小目标细节丢失。在 VisDrone2019 数据集上，该方法实现精确率 62.2%、mAP50%达 47.9%，兼顾实时性与轻量化，每秒帧率 86.6f，模型参数量仅 32MB。

（2）构建了一种融合动态尺度序列特征融合以及特征聚合模块的多尺度融合方法。将动态尺度序列特征融合 DySSFF 模块与 GLSA 特征聚合模块相结合的方式，前者动态处理尺度序列特征，提升多尺度特征融合效果，后者促使模型聚焦关键区域抑制背景噪声；同时基于 Focaler-CIoU 改进 CIoU 损失函数，该模型强化了物体的定位功能，显著提高了微小物体的检测效果。与当前主流的检测算法相比，对比实验结果表明，改进后的 DG-RA-RTDETR 模型相较于原始的 RTDETR-R18 模型，在 mAP 50/%指标上提升了 2.5%，在 mAP 50:95/%指标上提升了 0.9%。同时，模型计算复杂度方面，参数规模（Param/MB）和计算量（GFLOPs/G）均出现下降。

（3）完成了一种无人机图像检测平台的设计与实现。基于 PyQt5 技术实现了无人机图像检测平台，该平台具有友好的用户界面和丰富的功能。用户可以选择预训练好的配置文件、输入源（图片、视频、文件夹、摄像头），进行无人机图像目标检测，并查看检测结果和详细的日志信息。平台的实现为改进后的模型在实际应用中的部署提供了便利。

关键词：无人机图像；小目标检测；实时检测 Transformer；尺度序列特征融合

分类号：TP391

Abstract

The detection of small targets in unmanned aerial vehicle (UAV) images holds significant strategic importance in multiple fields such as military reconnaissance and environmental monitoring, and has become a research hotspot in the field of computer vision. However, in practical applications, due to their small size, small targets are vulnerable to interference from complex backgrounds, noise, and changes in lighting, leading to difficulties in feature extraction and fusion. At the same time, the sharp increase in computational complexity brought about by high resolution and dynamic scenes poses stringent requirements for the real-time performance and accuracy of detection algorithms. Existing deep learning-based target detection methods have problems such as insufficient feature extraction, low multi-scale fusion efficiency, and high model complexity when dealing with small targets. To address this, this paper proposes a small target detection method based on the improved RT-DRTR. By optimizing the feature extraction and multi-scale fusion mechanisms, the detection accuracy and robustness are enhanced. The specific research achievements are as follows:

(1) A joint feature extraction network with cross-stage parallelism and adaptive downsampling is proposed. A lightweight cross-stage parallel feature extraction RepCSPNet block is designed, which not only reduces the computational complexity but also enhances the ability to extract features of small targets. To solve the problem of detail information loss caused by traditional downsampling methods during the feature extraction of small targets, an adaptive downsampling module ADown is introduced. It can dynamically select the downsampling method according to the image content, effectively avoiding the loss of details of small targets. On the VisDrone2019 dataset, this method achieves a precision of 62.2% and an mAP50% of 47.9%. Taking into account real-time performance and light weight, it has a frame rate of 86.6 frames per second and the number of model parameters is only 32MB.

(2) A multi-scale fusion method that integrates dynamic scale sequence feature fusion and a feature aggregation module is constructed. The dynamic scale sequence feature fusion (DySSFF) module is combined with the GLSA feature aggregation module. The former dynamically processes the features of the scale sequence to enhance the effect of multi-scale feature fusion, and the latter enables the model to focus on key areas and suppress background noise. At the same time, based on Focaler-CIoU, the CIoU loss function is improved. This model strengthens the positioning function of objects and significantly improves the detection

effect of tiny objects. Compared with the current mainstream detection algorithms, the comparative experimental results show that, compared with the original RTDETR-R18 model, the improved DG-RA-RTDETR model has increased by 2.5% in the mAP 50/% index and by 0.9% in the mAP 50:95/% index. Meanwhile, in terms of the computational complexity of the model, both the parameter scale (Param/MB) and the computational amount (GFLOPs/G) have decreased.

(3) The design and implementation of a UAV image detection platform have been completed. Utilizing PyQt5 technology, the drone image detection platform features a user-friendly interface and a comprehensive set of functionalities. Users have the option to select pre-trained configuration files and input sources (such as images, videos, directories, or camera feeds) to perform drone image object detection and view the detection results along with detailed log information. The realization of this platform facilitates the deployment of the improved model in practical applications.

Key words: UAV images; Small object detection; Real-Time detection transformer; Scale sequence feature fusion

Classification: TP391

目 录

1.绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	3
1.2.1 目标检测技术发展现状.....	3
1.2.2 无人机航拍图像检测技术发展现状.....	6
1.3 论文的主要研究内容.....	7
1.4 论文的组织结构.....	8
2.相关理论与技术背景	10
2.1 卷积神经网络介绍.....	10
2.1.1 卷积神经网络的发展历程.....	10
2.1.2 卷积神经网络的基本原理.....	11
2.1.3 基于卷积神经的目标检测方法.....	14
2.2 Transformer 介绍.....	16
2.2.1 编码器-解码器架构的视觉适配	16
2.2.2 自注意力机制与序列建模.....	17
2.2.3 Transformer 在目标检测中的范式迁移与优化路径.....	18
2.3 Transformer 在目标检测中的应用.....	19
2.3.1 DETR(Detection Transformer)	19
2.3.2 RTDETR(Real-Time Detection Transformer)	20
2.3.3 其他经典 Transformer 检测模型.....	21
3.基于跨阶段 RepCSPNet 和 ADown 模块优化特征提取结构	23
3.1 原始特征提取结构存在的问题与分析	23
3.2 原始 RTDETR-R18 特征提取结构介绍	24
3.3 基于跨阶段 RepCSPNet 和 ADown 模块优化特征提取结构	26
3.3.1 基于跨阶段 RepCSPNet 优化特征提取结构	26
3.3.2 基于 ADwon 优化特征提取下采样机制.....	29
3.3.3 优化后 RA-RTDETR 特征提取网络整体结构	32
3.3.4 优化后特征提取模型算法流程.....	33
3.4 实验相关介绍.....	34
3.4.1 实验数据集介绍.....	34
3.4.2 实验评价指标介绍.....	36
3.5 实验结果与实验分析.....	37
3.5.1 实验环境参数介绍.....	38
3.5.2 消融实验.....	40

3.5.3 对比实验.....	42
3.5.4 可视化展示.....	43
3.6 本章总结.....	47
4.基于动态尺度序列特征融合 DySSFF 和 GLSA 特征聚合优化...	48
4.1 原始特征融合结构存在的问题与分析	48
4.2 基于动态尺度序列特征 DySSFF 和 GLSA 特征聚合优化特征融合	49
4.2.1 基于动态尺度序列 DySSFF 特征融合.....	49
4.2.2 基于 GLSA 特征聚合	50
4.2.3 改进后网络整体结构.....	51
4.3 损失函数改进.....	52
4.3.1 IOU 介绍.....	52
4.3.2 基于 Focaler-CIoU 改进 CIoU 损失函数	53
4.4 实验结果与实验分析.....	54
4.4.1 消融实验.....	55
4.4.2 对比实验.....	56
4.4.3 可视化展示.....	58
4.5 本章总结.....	61
5.基于 PyQt5 实现无人机图像检测平台的设计与实现.....	62
5.1 平台需求分析.....	62
5.2 平台总体设计.....	63
5.2.1 平台架构设计.....	63
5.2.2 平台流程设计.....	64
5.3 平台功能模块与实现.....	65
5.3.1 平台功能模块.....	65
5.3.2 交通管理场景的应用与实现.....	70
6.总结与展望.....	72
6.1 本文总结.....	72
6.2 展望.....	73
参考文献.....	75

1.绪论

1.1 研究背景与意义

随着无人机技术的飞速进步，无人机所获取的航拍图像已应用于多个领域，包括侦察、交通监管、生态保护以及农业耕作等重要范畴均有涉及。无人机航拍图像因其视角独特、覆盖范围广泛以及实时传输能力，已成为现代监控和数据采集的重要手段。然而，航拍图像的复杂性及其带来的数据挑战，也使得目标检测任务面临着显著的技术难题，尤其是对于小目标的检测。在无人机航拍图像中，目标物体的尺寸可能较小且分辨率较低，同时背景复杂，目标与背景的差异性较小，这给传统的目标检测算法带来了严峻考验^[1]。尤其是在小目标检测任务中，传统算法往往难以从图像中提取到足够有效的特征，导致检测精度的下降和错误的定位。因此，提升无人机航拍图像中小目标检测的精度和效率，不仅是一个重要的技术难题，更是一个具有重要实践意义的研究方向。

目标检测在计算机视觉领域中占据着基础性与核心性的地位，作为该领域的关键任务之一，其主要目的在于从图像或视频数据中精准地识别出所有具有研究价值或应用意义的目标对象，进而精准判定这些目标于图像或者视频里的确切位置。目标检测的核心任务包括两个方面^[2]：首先，需从复杂的图像背景中准确地检测出目标对象，这要求算法具备强大的特征提取与识别能力，能够有效区分目标与非目标区域；其次，需对检测出的目标实施精准定位，也就是明确目标在图像坐标系里边界框的具体位置。该步骤对目标识别、分析等后续处理的精确性具有至关重要的影响。

在目标检测研究领域，小目标检测的重要性日益凸显，特别是在无人机图像处理与分析方面。无人机所摄图像往往具备高分辨率及宽广视角，然而，小目标因尺寸细小、特征模糊，且易与复杂背景或其它物体相互遮挡，导致其检测与识别难度较大^[3]。小目标检测属于目标检测领域内关键的研究分支，长期以来是阻碍技术进一步突破的难点所在。小目标具有尺寸微小、细节信息稀缺、在图像中占比低等特点，在背景中往往容易被忽略或与背景混淆，这使得小目标在目标检测中常常难以被准确检测到。由于这些目标的特征信息较为模糊，且易受到背景干扰，漏检、误检等问题屡见不鲜^[4]。因此，如何有效提升小目标的检测准确性，尤其是在复杂背景和密集目标环境下，已成为当前目标检测领域的一个亟待解决的核心问题。

近些年来，深度学习，特别是卷积神经网络（CNN）^[5]在目标检测范畴收获了突出成果。以深度学习为依托的目标检测算法，已成为各界研究员共同关注的研究热点。基于特定网络架构的目标识别技术已在众多领域得到广泛应用，并在各个行业中扮演着举

足轻重的角色。其应用涵盖了从安全监控中对可疑人员和物品的实时监控，到自动驾驶中对道路标志、行人及车辆的精准识别，再到医学影像分析中的病变组织检测等多个关键领域。这些应用不仅极大地推动了各行业的智能化发展，也为社会的整体科技进步提供了强大的技术支撑。目标检测作为人工智能技术体系里的关键构成要素，于现实场景中得到极为广泛的应用。这一技术的普及，不但显著提高了诸多行业的运行效率，还切实优化了人们的生活品质，具备极为深远的社会影响以及实用价值。

常见的物体识别算法包括 Faster R-CNN^[6]、YOLO^[7]、SSD^[8]等。在这些算法中，Faster R-CNN 等经典算法因其较高的识别精度，于众多场景中被广泛运用^[6]。Faster R-CNN 采用区域生成网络^[9]来生成候选框，并与深度学习网络相结合完成特征学习的，最终达成精准的目标检测效果。然而，这类算法在实时性方面较为逊色，计算复杂度较高，不适合对计算资源要求较高的无人机实时处理任务；YOLO（You Only Look Once）系列算法，依靠其快速的检测性能以及良好的实时性特点，在目标检测领域彰显出强劲且极具潜力的应用前景^[10]。特别是 YOLOv5^[10]、YOLOv8^[10]等版本，凭借其优化的网络结构和高效的计算方式，广泛应用于多种检测场景。然而，尽管 YOLO 系列算法在一定程度上解决了小目标检测的问题，但其仍然存在计算量大、模型体积较大以及检测精度不足等挑战^[11]。此外，YOLO 模型在多目标检测和复杂背景的场景下仍然表现出一定的局限性；SSD 采用融合多尺度特征的方式来开展目标检测工作^[12]，这种方式在提升检测精度的同时，还有效地提升了计算效率。

针对无人机航拍图像中小目标的特殊需求，如何在保证检测精度的基础上提升计算效率，已成为当前研究中的重点之一^[11]。与常规的目标检测任务相比，无人机所拍摄航拍图像中的小目标呈现出分辨率较低、背景状况复杂以及目标形态丰富多样等特征。在这样的情况下，传统的目标检测手段通常无法获得令人满意的检测成效。因此，研究新型的小目标检测算法，不仅有助于推动无人机技术的应用，还能为实时监控、灾害救援等任务提供更高效的技术支持。鉴于上述情况，研究人员纷纷提出了各式各样的优化策略，以此来提升对小目标的检测精准度。RTDETR（Real-Time Detection Transformer）是近年来提出的一种基于 Transformer 的目标检测方法^[13]。与传统的基于卷积的方法不同，RTDETR 结合了自注意力模型的优势，能够在目标检测任务中充分利用全局信息，从而提升物体识别的准确性和稳定性。RTDETR 采用了自注意力机制（Self-Attention）^[14]，它能够处理图像中不同区域之间的长距离依赖关系，从而提高检测效果。与传统目标检测方法相比，RTDETR 在处理复杂场景时，能够有效地捕捉目标之间的关系，特别是在进行稠密目标任务和微小目标时，具有更好的性能。此外，RTDETR 还具备较高的计算

效率，能够实现实时目标检测，适用于视频监控、无人驾驶、无人机图像分析等应用场景。

RTDETR 凭借其基于 Transformer 架构的设计，能够高效地捕捉图像中的全局信息，从而在多数情况下优于传统的卷积神经网络（CNN）模型。这一优势使得 RTDETR 在处理大多数常见的目标检测任务时，能够展现出卓越的性能。然而，尽管其在多种常见场景下表现出色，在小目标检测任务中，RTDETR 的表现仍然存在一定的局限性^[15]。具体而言，尽管该模型在大多数检测任务中具有良好的适应性，但在面对小尺寸目标时，其检测准确性和鲁棒性仍有待进一步提升，亟需在该领域进行更为深入的改进与优化。

尽管目前已经有多种优化算法在小尺寸物体识别方面取得了一些成果，但仍有许多难题尚待攻克。首先，如何进一步提升目标检测的精度，尤其是在极其复杂的背景和低分辨率条件下，仍是一个重要的研究课题。其次，如何通过优化算法的计算效率，使得检测算法在资源受限的无人机平台上能够高效运行，依然是实现实际应用的关键。未来的研究将可能集中在更加轻量化的深度学习模型、更加高效的特征提取方法、以及新的注意力机制和多尺度融合策略的应用上。

1.2 国内外研究现状

物体检测作为图像视觉领域内的核心任务，其目标在于能够自动地从图像或者视频资料中，识别出目标物体的所属类别，并确定该物体在图像里的具体位置。它不仅需要识别图像中的目标物体，还需要精确地标定目标的边界框坐标。伴随深度学习方法的快速进步，物体识别领域已实现从早期传统方法向基于深度学习方法的转变。特别是卷积神经网络（CNN）以及 Transformer^[16]架构的应用，让目标检测在精度和效率方面都有了大幅提升。然而，随着目标尺寸的变化、密集目标的出现及背景的复杂性，目标检测面临许多挑战，特别是小目标的检测仍然是一个亟待解决的问题。

1.2.1 目标检测技术发展现状

在目标检测技术的发展历程中，传统方法主要依托于手工提取的特征以及经典的机器学习算法来实现目标的识别与定位。此类方式一般借助颜色、纹理、边缘这类低级视觉特性，通过构建特征向量用以刻画图像中的目标物体。在诸多传统目标检测算法当中，基于 Haar 特征的 AdaBoost 分类器^[17]以及基于 HOG（方向梯度直方图）特征的 SVM（支持向量机）^[18]分类器尤为引人注目。这些算法在处理简单场景时能够取得较为理想的效果，但在面对复杂场景、噪声干扰、物体变形等挑战时，其检测精度和鲁棒性则显得力

不从心。

以基于 Haar 特征及 AdaBoost 构建的级联分类器^[17]来说,其于目标检测领域意义重大,在 Viola-Jones 人脸检测方法^[19]中有着极为广泛的运用。将 Haar-like 特征与强弱分类器的架构精妙融合,达成了在图像内对目标物体的快速检测。然而,其局限性在于特征选择和模型训练过程高度依赖于手工设计,这使得算法在面对复杂场景中的多样化目标时,适应性较差。尤其是在小目标和密集目标检测方面,传统方法往往难以满足高精度检测的要求,在实际应用场景里,该方法极有可能出现漏检目标以及误检的状况,难以全方位满足现实复杂多样的需求。

自卷积神经网络(CNN)于图像分类领域取得显著成效后,以深度学习为基础的目标检测技术逐步成为研究与实际应用的核心发展方向。深度学习方法的核心优势在于其能够通过数据驱动的方式自动提取图像中的高级特征,从而显著提升目标检测的精度与鲁棒性。相较于传统依靠人工提取特征的方式,深度学习方法在捕捉图像内复杂语义信息方面优势显著。特别是在大规模数据集作为支撑时,深度学习方法的检测性能有了极为明显的提高。

早期的深度学习目标检测方法,例如 R-CNN (Region-based Convolutional Neural Network)^[21],通过引入区域提议机制(Region Proposal)^[20],通过把卷积神经网络跟区域提议算法相融合,目标检测的精准度得以大幅提升。随后, Fast R-CNN^[22]和 Faster R-CNN^[5]相继提出,分别通过优化候选区域生成算法及引入区域提议网络(RPN)来解决传统 R-CNN 方法中存在的计算冗余问题,与此同时,识别速度和准确率均得到了显著提高。Faster R-CNN 的出现,让区域提议与目标检测环节可通过端到端的方式进行训练,极大程度地优化了计算效率。

随着 YOLO (You Only Look Once)^[7]和 SSD (Single Shot MultiBox Detector)^[8]等方法的出现,在目标检测领域,技术发展趋势逐步朝着单阶段端到端的检测架构转变。YOLO 算法采用了与众不同的方法,将物体识别任务转化为回归,这一举措极大幅度提升了实时检测的速率与效能,成功构建起端到端的训练体系。SSD 算法则另有所长,它借助多尺度特征图开展多尺度检测工作,显著增强了对不同尺度目标的检测性能。上述算法均依托全卷积网络(Fully Convolutional Network)^[23],借由端到端的训练流程,在目标检测任务中,显著优化了检测速度与整体效率,特别契合对实时性要求严苛的各类应用场景。

近段时间,Transformer 架构于自然语言处理(NLP)范畴收获了重大进展。该架构所具备的自注意力机制,让模型得以高效抓取全局信息,显著提升了处理复杂任务的能

力^[24]。鉴于自注意力机制在处理序列数据方面的出色表现，促使学者们探索其在图像识别领域的应用，特别是在目标检测任务中进行探索应用。在目标检测场景下，Transformer 架构一般以编码器-解码器的形式得以运用。其中，编码器环节利用自注意力机制对输入图像的特征数据进行处理，从而生成富含大量上下文信息的特征表达。解码器则通过这些编码信息生成最终的预测结果。Transformer 具备独特优势，它可同时对不同尺度、不同位置的特征开展处理工作。这一特性使得目标检测精度得到有效提升，尤其是在面对复杂场景与小目标时，Transformer 能够更为出色地整合不同层级的信息。基于 Transformer 的目标检测方法因此开始受到广泛关注，其中 DETR (Detection Transformer)^[25]和 RTDETR 等模型成为该领域的代表性成果。

目标检测任务的关键在于精准确定图像内物体的位置，同时为各个物体赋予相应的类别标签。传统目标检测方法通常通过先验框生成和非极大值抑制 (NMS)^[25]来完成这一任务。然而，这些方法在多物体检测、背景复杂以及小目标检测等任务中存在一定的局限性。Transformer 在目标检测中的应用，通过其端到端的训练和不依赖于先验框的特性，显著提升了模型的简洁性和鲁棒性。DETR 模型把检测任务创新性地转变为序列到序列的问题模式，借助 Transformer 架构中的自注意力机制，对全局信息予以有效捕捉，能够在较少的超参数调节下取得良好的检测精度。DETR 的一个显著特点是，其模型不依赖于传统的区域提议网络 (RPN)，而是通过端到端的学习实现目标的检测和定位。此方法对检测流程予以简化，使得模型在训练效率以及检测性能方面均得到提升。

尽管 DETR 在众多场景中彰显出强劲实力，然而于小目标检测这一领域，它依旧存在短板。由于自注意力机制的全局特性，DETR 在处理小目标时容易丢失细节信息，导致检测精度下降。为了提升小目标的检测能力，研究者们提出了改进版的 Transformer 检测模型，如 RTDETR。RTDETR 在 DETR 的基础上进行了优化，通过改进解码器架构和引入多尺度特征融合，增强了模型对小型物体的辨识能力。通过细化的多尺度表征处理，RTDETR 能够更好地识别和定位尺寸较小的目标，提升了其在复杂场景中的表现。

在目标检测领域，Transformer 架构的应用不断拓展，除了 DETR 和 RTDETR，其他基于 Transformer 的算法也在持续演进。Deformable DETR^[26]通过引入可变形注意力机制，实现了在不同位置和尺度上的灵活特征采样，有效降低了运算开销，提高了识别效率和精度。该机制不但提升了模型的运行效率，还增强了模型对图像中小物体的检测。此外，Deformable DETR 还利用多尺度特征和不同层级的编码，进一步提升了小物体检测的精度。Conditional DETR^[27]则通过条件卷积和动态卷积，优化了模型的训练和推理过程。这些技术赋能模型，使其可依据输入图像特征对卷积核进行动态调节。一方面，

增强了模型的适应性，提升了检测精度；另一方面，削减了计算成本，提高了模型在实际应用场景中的可行性。这些基于 Transformer 的算法在不同方面对 DETR 进行了改进，进一步提升了目标检测的性能。

尽管深度学习技术在物体识别效果方面取得了长足进步，但在一些复杂场景下，诸如小目标检测、密集目标环境以及目标重叠等问题依然存在挑战，体现出检测精度不高，并且漏检、误检问题相当显著。如何在这些复杂场景下进一步优化深度学习模型的性能，尤其是如何提升小目标的检测能力，已成为当前目标检测领域的重要研究热点。

1.2.2 无人机航拍图像检测技术发展现状

无人机所拍摄的航拍图像展现出鲜明特性，像分辨率较高、小目标数量众多、背景繁杂等。鉴于这些特性，研究人员研发出各式各样的改进算法。RGDiNet^[28]结合了 RGB 航拍图像和点云数据，通过融合深度信息提高了目标检测的精度。YOLOv5-mamba^[29]通过引入双向密集反馈网络和自适应门控特征融合网络，显著提升了小目标的检测性能。此外，有研究通过将注意力机制与空间金字塔池化（SPP）技术^[30]纳入模型，进一步增强了模型对小目标的感知敏锐度与抗干扰能力。

无人机获取的航拍图像存在显著的目标尺度变化问题，这无疑给目标检测算法带来更为严苛的挑战。针对该难题，研究人员开发出众多多尺度检测策略。YOLOv7 通过引入多检测头和 CBAM 卷积注意力模块^[31]，有效提取不同尺度的特征。Xue 和 An 等^[32]人提出的 YOLOv7-drone 算法，通过多尺度特征融合和注意力机制，完成了轻量级无人机图像的目标检测工作，呈现出高精度与低计算量优势。引入具备自适应性的特征融合模块，配合多尺度特征金字塔网络架构，有效提升了模型针对不同尺寸物体的辨识能力，拓宽了模型对复杂尺度变化场景的适应范畴。Zhang 等学者运用经改良优化的 YOLOv8s 算法，切实提升了无人机图像中小目标的检测效果^[33]。具体而言，他们设计了新型 ODE 模块，通过多尺度特征融合和自适应特征提取，有效提升了对复杂背景中小目标的检测精度^[33]。此外，Changfeng Feng 等人^[34]提出了一种基于混合变换器的检测方法，通过多尺度融合和对抗性去噪技术，进一步提高了检测精度。在 Transformer 检测技术方面，肖振久等人提出了一种自适应前景聚焦的检测方法，通过动态聚焦头优化特征交互与集成，显著强化了对不同尺度目标的识别效能^[35]。此外，Tan 等研究者指出凭借自适应特征融合机制的不同尺度检测手段，借助自适应特征提取组件以及特征加权融合网络，有力地削减了图像内的冗余背景信息，提升了小目标检测的精准度^[36]。

实时检测构成了无人机航拍图像目标检测领域的一项核心需求。为契合此需求，研

究人员构建了多种轻量化模型。Efficient YOLOv7-Drone^[37]通过取消 P5 检测头和优化 CBS 模块，显著降低了计算负担，同时保持了较高的检测精度。MFP-YOLO 通过重新设计特征提取和融合机制，实现了高精度和低资源消耗^[38]。这些轻量化模型具备广泛适用性，既能在高性能计算平台上高效运作，也能够资源受限的设备中流畅运行。另一项重要的研究是由 Wu 等人提出的 YOLOv5_mamba 算法，该算法通过引入双向密集反馈网络 and 自适应门控特征融合，极大程度上强化了对小目标的检测成效^[29]。同时，Wang 和 Zhang 等人^[38]提出的 MFP-YOLO 算法，通过多尺度特征融合和注意力机制，达成了轻量级的航拍图像的目标检测，其突出优势在于检测精度高且计算量较低。

虽然现阶段的检测算法于航拍图像领域已收获颇为显著的成果，然而依旧面临着一些难题，且在不少方面仍有优化提升的余地。未来的研究方向包括：①进一步提升目标检测的精度，特别是在复杂背景和低分辨率条件下，仍然是当前计算机视觉领域面临的一个重要且挑战性的研究课题；②随着目标检测技术应用场景的不断拓展，如何提高算法的计算效率，特别是在资源有限的无人机平台上高效运行，已然成为推动目标检测技术落地实际应用的又一核心要点。

无人机航拍图像目标检测算法的演变，历经了由传统方式向深度学习方式的转变，且在近段时间内取得了相当突出的进展。通过引入多尺度特征融合、注意力机制、自适应特征提取等技术，不断提升了模型的检测性能和实时性。未来的研究将继续探索更高效、更鲁棒的算法，以应对无人机航拍图像中的各种挑战。

1.3 论文的主要研究内容

本文研究基于改进 RT-DRTR 的小目标检测方法，旨在通过引入 Transformer 架构优化深度学习神经网络，特别是在小目标检测方面，提升检测精度和鲁棒性。通过对现有小目标检测方法的分析和改进，本文深入探究了一种创新的网络，巧妙地融合了深度学习模型与 Transformer 架构，构建更加高效、精准的检测框架。具体研究内容如下：

(1) 提出了一种跨阶段并行特征提取和自适应下采样模块的联合特征提取网络。本文针对无人机 (UAV) 硬件资源有限，部署在其上的检测模型必须满足低参数量、计算复杂度低、运行延迟短以及准确率高的目标。然而，原始的 RTDETR 检测算法在追求高准确率的同时，往往面临计算复杂度高、浮点运算量大和模型延迟高等问题。针对这些问题，本文构造了一种轻量级别的跨阶段并行特征提取网络 (RepCSPNet)，旨在减少计算复杂度并增强模型在无人机图像中提取小目标特征的能力。为了进一步提升在无人机图像中的小目标检测性能，提出了结合 RepCSPNet 块和 ADown (Adaptive

Downsampling) 的联合特征提取网络。这一创新结合有效解决了传统下采样方法在处理小目标时导致的细节信息丢失问题。ADown 模块通过自适应机制, 能够动态选择合适的下采样方式, 确保图像中关键信息的最大保留。

(2) 构建了一种融合动态尺度序列特征融合以及特征聚合模块的多尺度融合方法。本文针对原始的 RTDETR 在多尺度特征融合方面采用了 CCFM 模块^[39]忽视了尺度序列信息的重要性, 即不同尺度下目标表示的差异性, 以及传统损失函数在处理小目标以及复杂场景时, 无法精准度量预测目标与真实目标间的差异, 进而影响检测精度。特别是在实际应用中, 无人机图像往往存在噪声、遮挡、低分辨率等问题, 这些挑战对检测精度提出了更高的要求。为了解决传统 CCFM 模块的不足, 本文提出了动态尺度序列特征融合模块 DySSFF 模块, 该模块能够动态地处理尺度序列特征, 以此达成更为高效且强劲的多尺度特征融合效果。在编码器部分, 本文除了引入了 DySSFF 模块以改善模型对多尺度特征的融合能力, 还结合 GLSA 特征聚合模块, 引导模型更好地聚焦图像中的关键区域, 减少背景噪声干扰, 增强模型的鲁棒性。同时, 基于 Focaler - CIoU 对 CIoU 损失函数加以改进, 极大地增强了模型的目标定位能力, 尤其在小目标和高密度目标检测方面。这一方案有效避免了传统的跨尺度特征融合方法存在的不足, 进一步提高了小目标和高密度目标的检测性能。

(3) 设计了无人机图像检测平台。基于 PyQt5 技术搭建无人机图像检测平台, 让改进后的 DG-RA-RTDETR 模型预训练权重, 在实际检测中得到应用, 充分体现改进后模型的优越性能。

1.4 论文的组织结构

本文由六个章节构成, 具体的全文组织架构如下所示:

第一章, 绪论。本章首先论述了航拍图像中微小物体识别的相关背景及其重要性, 随后对目标检测领域的国内外研究进展进行了综述, 对当下小目标检测方法的发展现状以及面临的挑战进行了深度剖析。基于此, 本论文明确了研究工作, 并对论文框架进行了组织。

第二章: 相关理论与技术背景。本章全面阐述深度学习与基于 Transformer 结构的小目标检测有关的理论依据及要点。对特征提取中所采用的技术, 卷积神经网络展开介绍。之后, 探讨目标检测的基本框架, 特别是单阶段与双阶段方法在小目标检测中的表现。然后, 将对 Transformer 架构的理论基础进行简要介绍, 重点分析其自注意力机制如何有效捕捉全局信息, 以及这一机制在目标检测任务中的应用价值。随后, 对目标检

测范畴内几种极具典型性的 Transformer 结构展开深度探究，剖析它们的运行机制。最后，针对小目标检测面临的难题，对基于 Transformer 技术路径的效果展开评估，给后续研究筑牢理论根基。

第三章：优化 RTDETR 骨干网络特征提取结构。首先，在骨干网络中引入轻量化的跨阶段并行特征提取网络（RepCSPNet 块），通过跨阶段网络结构和重参数化卷积，减轻计算负担，强化获取小目标特征的技术。其次，RepCSPNet 块有效减少了计算复杂度，结合 ADown（Adaptive Downsampling）的联合特征提取网络在保证高效特征提取的同时，优化了模型在有限硬件资源下的性能。该方法显著提升了无人机图像中小目标的检测能力，且实验数据表明，优化后的识别模型能够在降低延迟和计算开销的同时，保持较高的检测精度。

第四章：基于动态尺度序列特征融合和 GLSA 特征聚合优化 RTDETR。基于原始 RTDETR 的多尺度特征融合，本文提出了 DySSFF（Dynamic Scale Sequence Feature Fusion）模块，以解决传统 CCFM 模块忽略尺度序列信息的问题，提升了模型在不同尺度特征交融中的表现。首先，DySSFF 模块能动态处理尺度序列特征，实现高效融合。然后，结合 GLSA 特征聚合模块，帮助模型更好聚焦关键区域，减少背景干扰，增强鲁棒性。实验结果表明，该方法显著提升了小目标和高密度目标的检测性能。与此同时，本文还对损失函数进行了优化。通过引入 Focaler-CIoU 对 CIoU 损失函数进行改进，该改进策略进一步强化了模型的小目标定位能力。

第五章：改进算法设计与应用。本文针对所提出的改进型 RTDETR 算法开展实现工作，并基于真实应用情况对该算法的改进效果进行系统性验证，以评估其在实际环境中的效果。

第六章：总结与展望。本文对现有的研究工作进行了回顾，同时对未来发展进行了预测，旨在推动研究迈向更高层次，为社会进步拓展更广阔空间。

2. 相关理论与技术背景

本章意在系统化地剖析卷积神经网络（CNN）以及依托 Transformer 架构的目标检测技术所关联的理论根基与具体技术实现要点。首先，对特征提取网络中主要采取的卷积神经网络反战历程，原理与基于卷积神经网络的目标检测技术进行介绍；然后，将对 Transformer 架构的理论基础进行简要介绍，重点分析其自注意力机制如何有效捕捉全局信息，以及这一机制在目标检测任务中的应用价值。随后，深入探讨几种在目标检测领域具有代表性的 Transformer 模型及其工作原理，包括但不限于 DETR（Detection Transformer）和 RTDETR（Real-Time Detection Transformer）。经采用 Transformer 架构的集成设计，此类模型在目标检测领域实现了检测精度与处理效率的显著增强。

进一步地，本章将介绍目标检测的基本框架，详细分析单阶段与双阶段目标检测方法的核心差异及其在小目标检测中的表现。通过对比这两种方法的优缺点，揭示它们在处理小目标时的挑战与机遇。最终，本研究将核心关注点锚定于小目标检测这一关键议题，系统梳理当前基于 Transformer 架构的目标检测技术在该细分领域的应用实践现状，深入剖析其技术优势与现存局限，旨在为后续研究构建坚实的理论支撑体系，并为未来研究方向提供可参考的路径指引。

2.1 卷积神经网络介绍

卷积神经网络（Convolutional Neural Networks，简称 CNNs）作为深度学习领域的核心架构之一，其结构主要由卷积层、池化层以及全连接层，这三大模块组成^[5]。在网络的训练进程中，各模块分别承担着独特的功能角色^[40]。

2.1.1 卷积神经网络的发展历程

卷积神经网络（CNN），在许多领域广泛应用。自 20 世纪 90 年代初 LeNet 问世，其历经多阶段发展，网络结构与算法不断创新。LeNet^[41]由 LeCun 团队于 1996 年正式提出，并在 MNIST 数据集表现出色。该模型架构包含两个卷积运算层、两个下采样层以及全连接网络层，通过将卷积特征提取与下采样降维机制有机结合，成功构建了卷积神经网络（CNN）的基础性框架体系，有效验证了其在处理图像数据任务中的高效特性，为后续相关研究提供了重要的理论支撑与实践范例。2012 年，AlexNet^[42]在 ImageNet^[43]竞赛取得突破，采用更深网络结构，引入 ReLU^[44]激活函数解决梯度消失问题，借助 GPU 加速训练，提升效率与准确性，标志深度学习进入主流，推动视觉任务研究发展。2014

年，VGGNet^[45]通过堆叠 3×3 小卷积核替代大卷积核，以更深网络结构提升特征提取能力，虽计算量大，但在特征提取方面为 CNN 架构设计提供深刻启示。2015 年，ResNet^[46]引入残差连接，利用“跨越连接”跳过一些层，如图 2-1 所示，针对深层网络中普遍存在的梯度消失难题，残差模块通过创新机制有效缓解该问题，使得超深层次网络结构具备可训练性且训练效果显著提升，进而演变为深度神经网络架构中的标准组件，实现了网络性能的大幅跃升，该技术架构已在计算机视觉领域实现深度使用，被系统化应用于图像分类、目标检测及语义分割等多元视觉处理任务场景中。

2017 年，为解决卷积神经网络在移动和嵌入式设备部署时计算量大的难题，Google 提出 MobileNet^[47]，采用深度可分离卷积^[48]，通过将标准卷积操作解构为深度卷积与逐点卷积的级联方式，该技术方案实现了计算复杂度与参数规模的大幅削减，在确保模型预测精度的前提下，为轻量化神经网络架构设计提供了创新性思路，有力推动了深度学习模型在移动计算平台及嵌入式系统中的规模化部署进程。




图 2-1 残差连接结构

Fig.2-1 Residual Connections structure

卷积神经网络（CNN）的技术演进轨迹，深刻印证了其在目标检测任务中的核心价值地位与架构迭代进程。从 LeNet 到 ResNet、MobileNet，各阶段创新提升了网络性能与计算效率，有助于理解现有模型优劣，该研究为后续目标检测技术的创新发展提供了坚实的理论基石，系统性地揭示了深度学习技术迭代升级的过程。

2.1.2 卷积神经网络的基本原理

卷积网络作为计算机视觉中的主要网络框架，在图像理解任务中呈现出广阔的潜力，特别是在目标检测细分领域表现卓越。该网络架构由卷积运算层、下采样层及全连接映射层构成，各层级模块在特征空间构建与信息融合处理过程中发挥着不可替代的意义。卷积层通过实施卷积操作机制，系统性地解析图像空间结构，从而精准捕获图像中的局

部特征信息；池化层则通过下采样减少图像的维度，保留主要特征，减轻计算负担；全连接层通过整合前序网络提取的深层特征表示，构建特征向量空间以执行分类与回归任务，最终实现目标对象的精准定位与语义识别。该分层特征处理架构使卷积神经网络在目标检测任务中展现出显著优势。

（1）卷积层

卷积运算层作为卷积神经网络（CNN）架构的核心构成单元，承担着从输入数据中执行特征提取的关键功能。该机制通过实施多个可训练的滤波（卷积核）与输入数据间进行卷积操作，进而生成体现输入特性的特征映射图（Feature Map）^[49]。这些卷积核在空间维度（如图像数据）或在时序轴（如时序数据）上移动，计算特定范围与卷积核的内积，生成对应的特征值。

卷积运算层由若干可训练的卷积滤波器构建而成，各滤波器单元独立执行对输入数据的局部特征提取任务^[49]。常见的卷积核大小包括 3x3、5x5 或 7x7 等。各卷积滤波器单元均配备独立的偏置参数，用于调整输出结果。卷积层通过执行卷积核与输入数据的特定范围的内积操作，生成特征映射图，随后利用激活函数对该特征图实施非线性映射，以提升模型对复杂模式的表征能力。具体来说，滤波模板在数据上移动，每次计算模板与特定范围的内积，从而得到一个特征图中的元素。卷积滤波器在整个输入数据域内采用共享权重机制，此设计显著缩减了模型参数规模，有效抑制了过拟合风险。同时，神经元与输入数据的局部空间区域建立稀疏连接，该架构特性使卷积层能够精准捕获数据中的局部特征模式。

当输入数据的形态参数为 I ，卷积滤波器的形态参数为 K ，且输出特征图的形态参数为 O 时，可通过特定公式（2-1）表达卷积层的数学映射关系：

$$O = f(I * K + b) \quad (2-1)$$

在此公式中，输入数据以 I 表示，卷积滤波器的权重参数矩阵记作 K ，偏置参数定义为 b ，激活变换函数用 f 表示， $*$ 表示卷积操作。该计算流程通过卷积核对输入数据实施空间/时间维度的结构化扫描，实现特征的多尺度空间分布解析，从而为后续网络层构建具备更高语义抽象级别的特征表示。

（2）下采样层

下采样层是卷积网络中的关键组件，其主要功能是通过减少特征图的空间维度来降低计算复杂度，同时提升模型的鲁棒性^[49]。池化层常用于降低特征映射的分辨率，从而减少运算负荷，同时保留关键的特征信息。典型空间降维操作涵盖最大值采样池化、平

均值滤波池化及概率随机采样池化，图 2-2 展示了其具体操作。最大池化在特征映射上使用固定大小的区域进行移动，并选取每个区域内的最大激活值作为输出^[50]。以 2×2 的区域和 2 的步幅为例，可从 4×4 的特征映射中提取主要特征，生成 2×2 的输出特征图。平均池化操作与最大池化操作相似，其输出为区域内所有数值的平均数，使用相同的窗口大小和步长，也得到 2×2 的输出特征图^[50]。随机池化与前两者不同，它通过在窗口内随机选择一个值作为输出，生成的输出特征图也为 2×2 ，且选取的值基于给定的概率矩阵^[50]。它不仅能够减少特征图的大小，还能缓解卷积层对位置的敏感性，使得模型更具位移不变性，能够处理输入图像的微小变化。




图 2-2 几种常见的池化操作

Fig.2-2 Several common pooling operations

通过降低特征图的维度，池化层能够有效减轻计算负担，并在一定程度上防止过拟合，尤其是当模型的参数量较大时^[50]。池化操作帮助精简非必要数据，同时维持图像中的核心信息，尤其是在最大池化中，通常会保留最显著的特征，例如边缘或角点。与最大池化不同，平均池化通过计算每个窗口的平均值，适合保留图像的整体信息，使得特征图更加平滑，适用于不同的任务需求。

池化层通常设置在卷积层后面，在进行特征提取之后，通过池化操作进一步减少特征图的尺寸，从而实现更高效的特征学习。池化层的工作原理是滑动固定大小的窗口，计算每个窗口的统计值，并输出新的特征图。这一过程不仅降低了计算量，也有助于提升模型对细节变化的容错能力。

(3) 全连接层

全连接层（FC 层）作为深度学习架构中的典型层类型，其核心特征表现为每个神经

元均与前一层神经元建立全域连接关系，能够有效整合前一层提取的特征，并进行最终的决策或分类^[51]。通常，在特征网络的输出端，全连接层负责将特征图转化为特征向量。该过程采用线性变换，将特征图与参数矩阵进行运算并添加常数项，然后通过非线性函数进行映射。

全连接层在深度神经网络中发挥着特征汇聚、降维以及分类输出的功能^[51]。该层能够将部分特征综合为整体特征，提升模型的鲁棒性与分类能力；同时，通过将高维特征图压缩为一维向量，简化了计算过程并减少特征位置对分类结果的影响；在模型的最后，通常利用全连接层利用 Softmax 函数输出最终的分类概率。

全连接层的特性体现在：每个节点与前一层所有节点相连，导致参数数量庞大，计算开销较高。此外，全连接层虽然能够获取整体信息，但也使得模型对输入图像的尺寸较为敏感。尽管全连接层的参数量大且计算复杂度高，但它在整合特征并提供全局特征表示方面的优势使其在许多深度学习任务中不可或缺。

2.1.3 基于卷积神经的目标检测方法

基于深度卷积架构的目标识别技术主要分为双阶段与单阶段两类，二者在检测精度与计算效率之间形成显著差异，适用于不同的应用场景。双阶段方法通过分阶段优化实现高精度检测，而单阶段方法则以端到端回归为核心满足实时性需求，两类方法在算法演进中持续推动目标检测技术的边界扩展。

（1）双阶段目标检测

双阶段目标检测方法的核心思想是将目标识别过程通常分为两步：首先产生提议区域，然后对这些区域进行类别判断和位置精炼^[52]。首先，通过生成候选区域来缩小搜索范围，减少计算量，提高检测效率。选择性搜索（Selective Search）是早期 R-CNN 方法使用的区域提议方法，通过合并图像中的相似区域生成候选框，尽管生成结果具备优质特性，然而其计算资源消耗相对显著。接着，利用深度卷积架构对每个提议区域进行特征分析，以判断其是否包含目标并确定位置。这种方法通过将检测任务拆解为更细致的两个步骤，从而能够在候选区域中准确定位目标。双阶段方法的优点在于其高精度，尤其是在复杂场景下，能有效减少误检与漏检现象。双阶段方法在精度上具有优势，尤其在复杂背景和遮挡情况下表现更好。

R-CNN 系列（包括 Fast R-CNN 和 Faster R-CNN）是双阶段目标识别领域的重要里程碑。R-CNN 采用区域选择策略生成提议区域，利用卷积网络进行特征分析，并通过 SVM^[53] 进行分类。尽管 R-CNN 提升了目标识别的准确性，但计算开销大。为提高效

率，Fast R-CNN 通过共享卷积特征减少冗余计算，并采用兴趣区域标准化操作将形状各异的提议框整合为统一尺寸的输出，从而提升了速度和精度^[54]。然而，Fast R-CNN 仍依赖选择性搜索，计算过程较为复杂。

为减少选择性搜索的计算开销，Faster R-CNN 引入了区域建议网络，与深度卷积架构共用特征提取层，直接生成候选区域。RPN 通过滑动窗口预测多个候选区域的得分和边界框偏移量，实现了端到端的训练。这一创新减少了区域提议的时间开销，提高了检测速度。尽管 Faster R-CNN 在精度和效率上表现优越，但其计算过程仍较为复杂，计算开销较大。

（2）单阶段目标检测

单阶段目标识别技术是一种直接从图像到结果的检测流程，通过直接预测目标边界，通过一次性计算得到目标的类别与位置^[55]。该方法将目标识别流程整合为一个统一的回归任务，能够在保持较好精度的同时，显著提升计算效率，满足实时性的需求。这一特点使得该方法在计算效率上相较于双阶段方法具有显著优势。传统的双阶段方法需要通过选择性搜索或区域提议网络（RPN）生成多个候选框，并对每个框进行分类和回归处理，过程繁琐且计算开销较大。而单阶段方法则通过将目标检测任务简化为回归问题，实现了在一次前向传播中同时预测目标的位置和类别，减少了计算时间和复杂度。

YOLO（You Only Look Once）作为单阶段目标检测领域的标志性方法体系，创新性地目标检测任务重构为基于回归的优化求解问题，通过网络直接预测目标的边界框和类别^[56]。最初的 YOLO 版本由于其较低的精度限制了应用，但随着 YOLOv2 和 YOLOv3 等后续版本的优化，检测精度和速度有了显著提高。YOLO 方法将图像切分为多个单元格，并在每个单元格内预测边界框，能够实现高效的实时检测，特别适用于对检测速度有严格要求的应用场景^[56]。SSD 方法通过在不同层次的特征图谱上进行目标识别，增强了小尺度目标的检测性能^[57]。通过不同尺度的卷积特征图，SSD 能够捕捉到图像中不同尺寸目标的特征，从而有效提高了检测精度，尤其在复杂场景中表现更佳。

单阶段目标检测方法的核心优势在于其高效性和适用性，尤其是在需要快速响应的实时目标检测任务中。由于省略了候选区域生成的步骤，单阶段方法能够在较短的时间内输出检测结果。然而，尽管单阶段方法在计算效率上具有显著优势，但在一些复杂场景中，其检测精度可能逊色于双阶段方法。例如，面对较多的背景干扰或目标间距较小的情况时，单阶段方法的检测精度可能无法与精细的候选区域生成和分类的双阶段方法相匹敌。因此，尽管单阶段方法具备较高的实时性，其在某些复杂任务中的表现可能受到限制。

2.2 Transformer 介绍

2.2.1 编码器-解码器架构的视觉适配

在深度学习领域，Transformer 架构凭借其强大的序列处理能力和并行计算优势，在自然语言处理任务中取得了巨大成功。随着研究的深入，其在计算机视觉领域也展现出了广阔的应用前景。Transformer 架构的核心组件包含编码模块（Encoder）与解码模块（Decoder）^[58]，其模块化设计结构如图 2-3 所示。

编码器部分由相同的编码层堆叠而成。编码模块的层级结构中，每个编码单元均内嵌两个功能子模块：多头自注意力处理机制与前馈神经网络单元^[58]。多头自注意力机制允许模型在处理序列时，从不同的表示子空间中捕捉序列元素以便更好地捕捉序列间的相关性，进而提升模型对序列语境信息的感知能力。前馈神经网络模块针对自注意力处理单元的输出特征实施非线性映射操作，实现特征维度的深度提取与增强。在处理输入序列时，编码模块将输入数据转化为一系列的特征向量，这些向量包含了序列中各个元素的上下文信息。




图 2-3 Transformer 编码器-解码器架构图

Fig.2-3 Architecture diagram of the transformer Encoder-Decoder

解码模块采用层级堆叠架构，由多个功能等效的解码单元层级组合而成。每个解码单元内嵌三个核心处理子模块：多头自注意力处理机制、跨模态交互注意力模块（对应原 Encoder-Decoder Attention）以及前馈神经网络处理单元^[58]。其中，编码-解码注意力

机制用于将编码模块输出的特征表示与解码器当前的输入进行交互，从而使解码器能够关注到编码器中与当前解码步骤相关的信息。解码模块的核心功能在于：基于编码器生成的特征表示，通过序列化生成机制逐步构建目标序列。

将 Transformer 的编码器-解码器架构应用于视觉任务时，需要进行一些适配工作，以适应图像数据的特点。由于图像是二维数据，与自然语言处理中的一维序列不同，因此需要将图像分割成多个固定大小的图像块（Patches），并将每个图像块转换为一维向量表示，这个过程称为图像嵌入（Image Embedding）。经由该技术路径，可实现将图像数据重构为适配 Transformer 模型处理的序列化表达形态。在自然语言处理中，序列元素的顺序信息对于理解语义至关重要。同样，在图像中，各个图像块的位置信息也对目标检测和识别有重要影响。因此，在输入 Transformer 之前，需要为每个图像块添加位置编码（Position Encoding），以保留图像块的位置信息。

针对图像数据的非序列特性，研究者提出了二维空间位置编码（2D Positional Encoding）的视觉适配方案^[59]。相较于自然语言处理中采用的一维序列位置编码，视觉 Transformer 通过双坐标正弦函数构建空间感知特征如公式（2-2），（2-3）：

$$PE_{(x,y,2i)} = \sin\left(\frac{x}{10000^{2i/d}}\right) + \sin\left(\frac{y}{10000^{2i/d}}\right) \quad (2-2)$$

$$PE_{(x,y,2i+1)} = \sin\left(\frac{x}{10000^{2i/d}}\right) + \sin\left(\frac{y}{10000^{2i/d}}\right) \quad (2-3)$$

在无人机图像小目标检测任务中，将 Transformer 的编码器-解码器架构进行视觉适配后，能够有效处理图像中的复杂信息和小目标特征。通过多头自注意力机制，模型可以更好地捕捉小目标与周围环境的上下文关系，提高小目标的检测精度。同时，多尺度特征提取和定制的解码策略也有助于模型在不同尺度和复杂背景下准确检测小目标。

2.2.2 自注意力机制与序列建模

在深度学习领域，传统的循环神经网络（RNN）和卷积神经网络（CNN）在处理长序列数据时，逐渐暴露出效率和性能方面的瓶颈^[58]。为了突破这些局限，Vaswani 等学者在 2017 年的开创性研究中，首次提出了 Transformer 架构^[58]。该架构的核心亮点在于引入了自注意力机制，将其作为序列建模的基础运算单元，这一创新为解决长序列数据处理难题提供了新的思路。

自注意力机制通过构建元素间的动态权重矩阵，有效捕捉远距离依赖。与传统的循环神经网络相比，它在并行处理和长距离依赖捕捉方面具有优势。该机制的核心是计算

输入中任意元素间的相关度，从而显式地建立全局上下文依赖关系。

针对输入数据 $X \in R^{n \times d}$ ， n 表示序列的长度， d 表示特征维度，自注意力方法采用三个可学习的线性变换矩阵 W^Q 、 W^K 、 W^V ，通过特定的映射方式将输入数据转化为查询矩阵、键矩阵和值矩阵^[16]，该转换过程可用数学表达式（2-4）描述：

$$Q = XW^Q, K = XW^K, V = XW^V \quad (2-4)$$

之后，通过计算查询矩阵与键矩阵的点积，再进行尺度缩放和 softmax 归一化处理，得到注意力权重矩阵 A ，如公式（2-5）：

$$A = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \quad (2-5)$$

其中 d_k 表示键向量的维度。最终，对权重矩阵和值矩阵执行矩阵乘法操作，即可得到该机制的输出，如公式（2-6）：

$$\text{Attention}(Q, K, V) = AV \quad (2-6)$$

这种基于点积的注意力计算方式，不仅能够动态建模序列元素之间的依赖关系，还具备良好的可并行性，该结构优化了计算效能。同时，通过引入多注意力头机制，模型可以从不同层面提取数据的多样化特征，从而增强了模型的特征提取能力。

在无人机航拍图像目标检测领域，基于 Transformer 架构的全局注意力机制在应对密集小目标检测挑战时，展现出独特的理论优势。传统的卷积神经网络受限于局部感受野的逐层特征传递模式，而自注意力机制通过构建像素级全连接关系（进行 n^2 级别交互计算），打破了空间距离对特征聚合的限制。在无人机图像分析中，这种全局上下文建模能力具有两方面的实际价值：一方面，对于因分辨率低而导致特征信息匮乏的小目标，通过跨区域语义关联增强目标与背景的区分度；另一方面，针对密集场景下目标相互遮挡造成的特征混淆问题，利用长程依赖关系实现被遮挡目标的间接特征补偿。

2.2.3 Transformer 在目标检测中的范式迁移与优化路径

将 Transformer 架构应用于目标检测领域，需要克服视觉数据建模和检测范式适配这两个关键技术难题，核心挑战主要集中在空间特征序列化建模和动态目标表征学习两个方面。DETR (Detection Transformer) 模型首次实现了端到端的 Transformer 检测框架，通过一系列创新完成了范式迁移。

为了解决图像到序列的转换问题，DETR 采用 CNN 骨干网络（如 ResNet-50）提取二维特征图 $F \in R^{H \times W \times C}$ ，然后通过空间维度扁平化操作将其重构为序列化特征 $F' \in$

$\mathbb{R}^{(H \times W) \times C}$ 。在这个过程中，既保留了局部语义信息，又通过位置编码注入了空间坐标先验，使 Transformer 编码器能够建立像素级全局关联。然而，在处理无人机高分辨率图像（例如 4000×3000 像素）时，会产生 $H \times W > 10^4$ 的超长序列，导致自注意力计算复杂度急剧增加至 $O((HW)^2)$ ，带来显著的计算和存储开销。

解码器引入了 N 个可学习的位置嵌入向量（Object Queries）来建立目标假设空间，其数学表示为 $Q \in \mathbb{R}^{N \times d}$ 。每个查询向量通过交叉注意力（Cross-Attention）机制与编码器特征进行迭代交互，逐步聚焦潜在目标区域，如公式（2-7）：

$$\text{CrossAttention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-7)$$

其中 $K, V \in \mathbb{R}^{(H \times W) \times d}$ 为编码器输出特征。传统均匀初始化查询向量在密集小目标场景中易导致注意力弥散问题。为此，RTDETR 提出动态查询更新策略，通过前帧检测结果引导查询向量初始化，使模型在无人机视频流中实现高达 83.6% 的检测跟踪精度^[13]。

在预测结果与真实标注的匹配方面，采用匈牙利算法进行最优二分图匹配^[59]，其损失函数定义为（2-8）：

$$\mathcal{L} = \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \lambda_{\text{box}} \mathcal{L}_{\text{box}} + \lambda_{\text{giou}} \mathcal{L}_{\text{giou}} \quad (2-8)$$

其中分类损失 $\mathcal{L}_{\text{cls}}$ 采用 Focal Loss，回归损失 $\mathcal{L}_{\text{box}}$ 为 L1 范数， $\mathcal{L}_{\text{giou}}$ 为广义交并比损失。虽然该机制摒弃了锚框与非极大值抑制（NMS）等手工设计组件，但在无人机密集场景中仍存在正负样本匹配失衡的问题。

2.3 Transformer 在目标检测中的应用

2.3.1 DETR（Detection Transformer）

DETR 作为首个将 Transformer 架构引入目标检测的模型，通过集合预测范式重新定义了检测任务。其架构由卷积神经网络（CNN）特征提取器、Transformer 编码器-解码器以及端到端训练机制构成。CNN 骨干网络（如 ResNet）首先提取输入图像的多层次特征，随后将特征图展平为序列输入 Transformer 编码器。编码器通过多头自注意力机制建模全局空间依赖关系，捕获跨区域的语义关联性。解码模块采用一系列可训练的目标查询嵌入与编码特征进行交互，通过交叉注意力机制逐步生成目标的类别标签与边界框坐标。

与传统检测模型不同，DETR 完全摒弃了人工设计的锚框和非极大值抑制（NMS）

后处理步骤，实现了从输入到输出的端到端训练流程。然而，在无人机图像的小目标检测场景中，DETR 表现出明显局限性。编码器输入特征图的高下采样率（32 倍）导致微小目标的纹理细节严重丢失。此外，该机制的计算量随输入尺寸二次增长，对于 1024×1024 规格的航拍影像，难以达到实时处理的要求。

研究指出，DETR 的性能瓶颈源于其注意力机制的设计特性^[59]。在密集小目标场景中，全局自注意力倾向于分散到背景区域，导致目标特征响应被稀释。同时，固定尺寸的对象查询向量无法适应目标尺度的剧烈变化，进一步加剧了漏检问题。这些缺陷表明，标准 Transformer 架构在直接迁移至无人机检测任务时存在显著的适配性挑战。

2.3.2 RTDETR (Real-Time Detection Transformer)

RTDETR 作为应对 DETR 模型在实时性及小目标检测场景局限而研发的改进方案，通过对模型架构的深度重构与训练策略的精细优化，实现了检测效率与精度的双重跃升。该模型舍弃传统检测算法中的非极大值抑制（NMS）步骤，采用端到端训练范式，在 VisDrone 无人机数据集环境下，达成了 45FPS 的实时推理速度，小目标检测精度（AP_S）提升至 24.3%，相较于原始 DETR 提高了 56%^[13]。其核心创新点在于引入混合编码器、动态稀疏注意力机制，并结合多尺度特征融合策略，有效化解了无人机图像中密集小目标的特征提取难题与计算效率瓶颈。

RTDETR 的编码器采用独特的双路径混合设计模式。其中一条路径专门用于处理高分辨率细节特征，借助轻量化卷积层，直接获取下采样率为 8 倍的高分辨率特征图，以此完整保留微小目标的边缘与纹理等关键信息，为后续精准检测微小目标奠定基础。另一条语义路径则运用 Transformer 编码器，对下采样 32 倍的低分辨率特征实施全局上下文建模，让模型能够充分把握图像的整体语义与目标间的上下文关联。这两条路径所生成的特征，借助通道注意力机制实现动态融合。具体而言，融合权重由可学习参数矩阵依据图像特征动态调整，确保在不同场景下，不同尺度的特征信息能够得到有效整合，提升特征的丰富度与有效性。

在多尺度特征融合环节，RTDETR 提出跨尺度特征融合模块（CCFM），CCFM 模块致力于解决不同尺度特征间的有效融合问题，为提升模型在多尺度目标场景下的识别效能，特别是针对密集分布的小型目标的检测精度，优化算法架构实现性能增强，结构如图 2-4 所示。在无人机图像中，目标尺度变化范围大，从远处的微小目标到近处的较大目标均有涉及，CCFM 模块通过特定机制，能够将不同层级、不同分辨率的特征进行合理整合。它首先对来自不同路径、不同尺度的特征进行初步处理，使其在维度和特征

表达上具备可融合性。在融合过程中，采用类似残差连接的方式，保留原始特征中的关键信息，避免在融合时造成信息丢失。同时，模块内还融入了注意力机制，这里的注意力机制并非简单的通道注意力，而是综合考量空间位置与通道信息的注意力机制。




图 2-4 跨尺度特征融合模块 CCFM 结构

Fig.2-4 The structure of the cross-scale feature fusion module CCFM

解码器部分，RTDETR 提出局部-全局协同注意力机制。该机制将特征图细分为 8×8 的区域，并在这些区域内独立计算注意力权重，从而将计算复杂度由传统的二次方级别降低到一次方级别，极大提升计算效率。

为进一步提升模型鲁棒性，RTDETR 在训练策略方面进行了多方面优化。在学习率调度上，采用渐进式地学习策略。在训练的早期阶段，采用较小的学习率 ($1e-4$) 对骨干网络参数进行微调，此阶段着重让模型适应数据特征，稳定基础参数。随着训练推进，逐步将学习率增大至 $5e-5$ ，用于优化解码器参数，以提升模型对目标检测结果的生成能力^[13]。

2.3.3 其他经典 Transformer 检测模型

在 Transformer 检测框架的演进过程中，研究者提出了多种改进架构以应对不同场景的挑战。Deformable DETR 采用了一种改进的注意力机制，有效降低了计算成本^[26]。与传统的自注意力机制相比，该机制仅对稀疏采样点进行注意力权重计算，采样点位置通过可学习的偏移量动态调整。这种设计使得计算复杂度从 $O(n^2)$ 降至 $O(nk)$ (k 为采样点数，默认 $k = 4$)，在 COCO 数据集上将小目标检测精度 (AP_S) 提升至 23.4%，推理速度达到 28FPS^[26]。

CondDETR 则通过动态条件卷积 (Dynamic Conditional Convolution) 重构特征提取过程^[27]。该技术根据输入图像内容动态生成卷积核参数，使模型能够自适应调整感受野大小与特征响应强度。例如，在处理无人机拍摄的交通监控图像时，模型对远处车辆

(20×20 像素以下)的卷积核自动缩小感受野以捕捉细节纹理,而对近处行人则扩大感受野以整合上下文信息。

此外, Sparse DETR 通过渐进式特征蒸馏策略优化特征表示^[61]。其核心思想是通过级联的 Transformer 层逐步提炼关键特征,抑制冗余背景噪声。在 VisDrone 密集小目标数据集上的测试显示,该模型使目标召回率提升 14.6%,误检率降低 22.3%^[61]。工业实践中,无人机巡检系统采用 Sparse DETR 进行光伏板热斑检测,成功将检测分辨率从传统方法的 256×256 提升至 1024×1024 ^[61]。这些改进模型通过注意力机制重构、动态参数调整等策略,在保持 Transformer 全局建模优势的同时,显著提升了计算效率与场景适应性。

3. 基于跨阶段 RepCSPNet 和 ADown 模块优化特征提取结构

3.1 原始特征提取结构存在的问题与分析

卷积神经网络作为图像特征提取的核心架构，在图像分类、目标检测等视觉任务领域展现出广泛的适用性与卓越性能。其优势在于通过卷积操作提取局部特征，并利用权重共享显著降低了参数数量，从而提升了运算效能。CNN 能够自动从数据中学习特征，并且具有平移不变性，使得它在处理图像时具有较强的鲁棒性。然而，CNN 也存在局限，如无法有效捕捉全局上下文信息以及处理长程依赖的问题，这限制了其在复杂场景中的表现。

结合 ResNet 的 RTDETR 该模型采用了 Transformer 架构，并通过残差连接显著减轻了模型训练的难度，从而提取了更加丰富的图像特征，弥补 CNN 在长程依赖建模上的不足。Transformer 架构借助自注意力处理机制，可有效整合图像的全局语义关联，从而提升目标检测任务的识别精度。尽管 ResNet 能够提供高质量的特征图，但 Transformer 的引入也带来了较高的计算开销和复杂的模型结构，尤其是在处理高分辨率图像时，推理速度较慢且对计算资源要求较高。因此，RTDETR 在实现高精度目标检测的同时，也需要在计算资源与推理效率之间进行平衡。

在目标检测领域，尤其是在无人机（UAV）图像中的小目标检测任务中，特征提取的精确性和效率是决定模型性能的关键因素。RTDETR 是一种基于深度神经网络的视觉识别算法，在许多需要精确识别的任务中取得了显著成绩。然而，原始 RTDETR 模型中使用的 ResNet-18（ResNet-r18）骨干特征提取网络，在处理小目标时存在一些局限性，主要表现在特征提取能力不足以及计算复杂度较高两个方面。

一方面，ResNet-18 的架构相对较深，如表 3-1 所示，包含多个层次和较大的网络宽度，这使得其在处理图像中的小目标时会面临一些挑战。特别是在深层特征图的分辨率逐渐降低时，信息的丢失和特征的模糊变得更加严重，这极大地影响了小目标的检测精度。尽管 ResNet-18 在大多数标准目标检测任务中表现较好，但其在捕捉和保留细小目标的关键特征时存在一定的不足。这种残差结构在理论上有助于提升网络性能，但实际应用中未能有效地保持小目标特征的细节，导致检测精度有所下降。

另一方面，ResNet-18 特征提取网络结构的计算复杂度较高，浮点运算量（FLOPs）相对较大，这对于计算资源有限的无人机平台来说，是一个不容忽视的负担，需要改进特征提取网络结构达到实际要求。该问题使得模型的实时性能受到限制，难以满足对快速处理的需求。

表 3-1 不同 ResNet 网络结构

Tab.3-1 Different ResNet network structures

层名	输出尺寸	r18	r34	r50	r101	r152
Conv1	112×112	7×7,64, stride 2				
Conv2_x	56×56	3×3, 最大池化, stride 2				
Conv3_x	28×28	4 层 BasicBlock	4 层 BasicBlock	4 层 Bottleneck	4 层 Bottleneck	4 层 Bottleneck
Conv4_x	14×14					
Conv5_x	7×7					
	1×1	平均池化（均值聚合策略），全连接，激活变换函数				
FLOPs		1.8×10 ⁹	3.6×10 ⁹	3.8×10 ⁹	7.6×10 ⁹	11.3×10 ⁹

为了应对这些挑战,本文提出了一种基于跨阶段并行特征提取网络(RepCSPNet 块)的改进方案。RepCSPNet 块通过引入重参数化卷积和跨阶段的结合,有效降低了计算复杂度,从而减轻了计算负担,同时仍然保留了高效的特征提取能力。具体来说,RepCSPNet 块在骨干网络中增加了一种轻量化的跨阶段并行特征提取方法,这一方法能够增强小目标特征的提取能力,并优化模型性能,特别是在无人机图像检测任务中的表现。通过这一改进,模型不仅减少了计算复杂度,还在有限硬件资源的条件下提升了处理速度和精度。

3.2 原始 RTDETR-R18 特征提取结构介绍

RT-DETR 的架构主要由三大组件构成:主干网络、混合编码器以及 Transformer 解码器。主干网络一般使用 ResNet 或 HGNet-v2 的传统卷积网络结构,来从图像中获取特征,为后续检测任务奠定基础。编码器层主要负责处理多尺度特征,鉴于主干网络输出的特征图尺度各异,编码器层能够有效整合并转换这些多尺度特征,为解码器构建更为完备且多元的特征信息输入体系。为将编码器提取的特征转换为最终的检测结果(包括目标类别和边界框坐标),RTDETR 融入了解码器层,使模型能够直接从编码器输出的特征被直接用于生成最终的检测结果,无需进行非极大值抑制等后续处理。这种一体化检测方法简化了流程,提高了效率。为适应不同应用场景的需求,RTDETR 提供了多个

模型选项，如 R18、R34、R50 和 R101，允许根据需要在检测精度和计算效率之间做出权衡。其中，ResNet-18 作为轻量级模型，因其小巧的体积和较快的推理速度，在资源受限的边缘计算设备，特别是无人机等移动平台上，展现出了显著优势。RTDETR-R18 的网络架构如图 3-1 所示。网络架构结合了 ResNet18 作为主干网络和高效的混合编码器（Efficient Hybrid Encoder）。ResNet18 作为模型的核心部分，通过几个关键模块实现特征提取。高效混合编码器通过多个专门设计的模块对特征进行进一步处理。RepC3 模块由重复卷积块和 3x3 卷积组成，能够深入提取和整合特征。CCFM 是一个特征融合模块，用于在多个尺度上融合特征。Conv1x1 卷积层则帮助调整通道数或进行特征融合，优化特征的表示。最后，通过 Concat 操作将来自不同路径的特征拼接在一起，为后续处理做好准备。




图 3-1 RTDETR-R18 的网络架构

Fig.3-1 The network architecture of RTDETR-R18

RTDETR-R18 在无人机图像中的小目标检测面临一些挑战，主要由于其骨干网络 ResNet-18 的局限性。作为较浅的网络，ResNet-18 相比深层网络，其特征提取能力较弱。在无人机图像中，小目标通常尺寸较小，且可能与复杂背景相似。浅层网络难以捕捉这些细节特征，导致检测效果不佳。由于目标占据的区域有限且与背景差异微弱，网络可能无法有效提取关键特征，从而导致漏检或精度下降。

另外, RTDETR-R18 的下采样过程也对小目标检测产生影响。虽然 ResNet-18 结构简单、计算量小, 但其下采样速度较快, 导致在特征提取过程中丢失大量空间信息。鉴于小型物体在图像中所占的面积有限且细节模糊, 快速下采样会使这些微小目标的特征无法准确保留。即便 Transformer 通过全局建模整合上下文信息, 网络仍可能错失这些细小目标, 从而影响检测效果。

为进一步优化 RTDETR-R18 在边缘计算设备(包括无人机)上的性能, 更好地应对现实场景中硬件资源有限、环境复杂等挑战, 对网络架构进行了针对性改进。这些改进旨在减少模型参数数量、提升推理速度、增强模型对复杂环境的适应性, 同时尽可能减少对检测精度的牺牲。通过这些优化措施, RTDETR-R18 在保持较高检测精度的同时, 大幅降低了运算复杂性和模型响应时间, 从而更适用于资源有限的终端设备上的应用。这些改进不仅提升了模型的性能, 还增强了其在实际应用中的可行性和可靠性。

3.3 基于跨阶段 RepCSPNet 和 ADown 模块优化特征提取结构

3.3.1 基于跨阶段 RepCSPNet 优化特征提取结构

无人机(UAV)平台通常面临硬件资源有限的情况, 因此部署的检测模型需要在保证高精度的同时, 满足低参数量、低计算复杂度、低延迟等性能要求。然而, 像 RT-DETR 这样的检测算法, 在追求高精度的同时, 往往会遇到计算复杂度过高、浮点运算量大、推理延迟较长等问题。这些困难主要由无人机平台的硬件资源限制, 如处理器性能、内存和功耗等方面引起。为应对这些挑战, 传统的深度学习方法, 如深度卷积神经网络(CNN)和部分卷积网络(Pconv)^[62], 通常通过减少网络层数、使用较小的卷积核或采用轻量级网络架构来降低计算量和参数量。尽管这些方法在一定程度上减轻了计算负担, 但在提升推理速度和检测精度方面仍需进一步优化, 以适应资源受限的无人机平台上的实时检测需求。

在深度学习领域, 模型在硬件资源受限的环境中常面临性能瓶颈, 难以同时兼顾高效运行与高检测精度。为攻克这一难题, 王剑尧等人创新性地提出了跨阶段局部网络(CSPNet)^[63]。CSPNet 的设计理念独树一帜, 其核心在于借助跨阶段局部连接对网络结构进行深度优化, 以此大幅提升模型的运行效率。从图 3-2(a)展示的 CSPNet 架构设计中可以清晰看到, 它将特征图巧妙地划分为两个部分分别处理。其中一部分进行常规的卷积操作, 用于提取关键特征; 另一部分则直接传递至下一阶段, 避免了不必要的重复计算。这种独特的设计方式能够有效削减计算过程中的冗余信息, 显著降低计算复杂

度，同时减少内存消耗，使模型在有限资源下也能高效运转。

本文进一步拓展了 CSPNet 跨阶段的思想，在 RepCSPNet（图 3-2(b)）中引入了重参数块 RepNBottleneck（具体结构如图 3-2(c)所示）。RepNBottleneck 块的引入具有重要意义，它能够对梯度反向传播过程起到优化作用。在模型的训练中，梯度消失问题一直是影响其效能的原因之一，而 RepNBottleneck 块的加入，可以有效缓解这一问题，确保梯度在整个网络中的传递更加顺畅，从而使模型在训练时能够更快速、稳定地收敛，为增强模型效能，可着重优化其检测精准度并提升综合性能表现。




图 3-2 CSPNet Block , RepCSPNet Block and RepNBottleneck Block 各个结构

Fig.3-2 The structures of CSPNet Block, RepCSPNet Block and RepNBottleneck Block

本文在 CSPNet 跨阶段思想的基础上做了进一步拓展，在 RepCSPNet 的块中巧妙地融入了重参数化卷积（RepConv）技术（详细结构如图 3-2(c)所示）。RepConv 技术的融入，进一步优化了计算资源的分配与利用，使计算负担和内存消耗得以显著降低，与此同时，模型的推理效率也得到了明显提升。RepConv 的基本原理是，在模型训练阶段，借助多分支卷积层对特征进行处理，每个分支负责提取不同维度或特性的特征，从而丰富特征表达；而在推理阶段，将这些多分支的卷积参数进行合并，重参数化到主分支中。这一策略能够有效地降低模型的计算复杂度，避免了重复计算所产生的冗余，不仅显著减少了内存占用，还大幅加快了推理速度。通过这种设计，RepConv 在不降低检测精度的前提下，能够充分挖掘硬件资源的潜力，确保模型实现高效运行，尤其在资源受限的环境中，发挥着至关重要的作用，为深度学习模型在实际应用中的高效部署提供了有力支持。

卷积层通过滑动窗口对输入图像进行卷积操作以提取特征，生成特征映射。批量归一化层对卷积层输出的特征映射进行规范化，使其均值趋于 0，方差趋于 1，这有助于

提升模型训练的效率，并降低数值不稳定的风险。卷积层和批量归一化层的结合在许多经典的神经网络架构中发挥了基础而重要的作用，是实现高效学习和准确预测的关键组成部分。传统的卷积结构通常由卷积单元（Conv）和批量归一化单元（BN）组成，分别用公式（3-1），（3-2）表示：

$$\text{Conv}(X) = W(X) + b \quad (3-1)$$

其中， $\text{Conv}(X)$ 表示对输入数据 X 进行卷积操作， $W(X)$ 为卷积核（权重）作用于输入 X 的结果， b 为偏置项，且为可学习的参数。

$$\text{BN}(X) = \gamma * \frac{X - \text{mean}}{\sqrt{\text{var}}} + \beta \quad (3-2)$$

其中， $\text{BN}(X)$ 为批量归一化后的数据， γ 和 β 为可学习的参数，控制尺度和偏移； mean 和 var 分别为当前批次数据 X 在每个特征方向上的均值和离散程度（方差）。

相比之下，与传统的卷积结构不同，RepConv 将卷积操作与批量归一化（BN）紧密结合在一起，形成了一种更高效的处理方式。在 RepConv 中，卷积层与批量归一化层并不分开执行，而是在单一的计算过程中完成。通过这种融合策略，RepConv 不仅减少了中间步骤的计算开销，还降低了内存消耗，从而提高了整体的计算效率。此外，这种整合使得模型在训练和推理时能够更加高效地利用硬件资源，避免了重复计算，从而提升了推理速度并优化了模型的性能。通过将这两种操作合并，RepConv 实现了更简洁且高效的卷积处理，显著减少了传统方法中的冗余计算。RepConv 将卷积操作和批量归一化整合为一体，如（3-3）所示：

$$\text{BN}(\text{Conv}(x)) = \gamma * \frac{\text{Conv}(x) - \text{mean}}{\sqrt{\text{var}}} + \beta \quad (3-3)$$

将公式（3-1）代入公式（3-3）后，得到：

$$\begin{aligned} \text{BN}(\text{Conv}(x)) &= \gamma * \frac{W(x) + b - \text{mean}}{\sqrt{\text{var}}} + \beta \\ &= \frac{\gamma * W(x)}{\sqrt{\text{var}}} + \left(\frac{\gamma * (b - \text{mean})}{\sqrt{\text{var}}} + \beta \right) \end{aligned} \quad (3-4)$$

通过简化公式（3-4），可以得出融合卷积权重和偏置的形式，这种融合形式显著降低了运算和存储成本，加快了运行速度。

基于跨阶段 RepCSPNet 优化特征提取结构改进后的网络总体结构如图 3-3，主要涵盖 Backbone（主干网络）、Efficient Hybrid Encoder（高效混合编码器）以及后续处理模块。Backbone 作为整个网络的基础部分，由多个 RepCSPNet Block 依次相连构成。它承担着对输入图像数据进行初步特征提取的关键任务。在 RepCSPNet Block 内部，创新性地采用了重参数化等先进技术。重参数化技术能够在不增加模型计算复杂度的前提下，

优化特征提取的流程，使网络能够更高效地学习和提取图像中的关键特征，从而显著提升特征提取的效率。该网络结构借助跨阶段的 RepCSPNet 对特征提取进行优化，对特征提取过程进行全面优化。在 Efficient Hybrid Encoder（高效混合编码器）中，通过跨阶段的信息交互与整合，能够实现多尺度特征的有效融合。不同尺度的特征包含着图像中不同层次和范围的信息，有效融合这些特征可以使模型更好地捕捉目标的细节和全局信息。




图 3-3 基于跨阶段 RepCSPNet 优化后的网络结构

Fig.3-3 The network structure optimized based on the cross-stage RepCSPNet

3.3.2 基于 ADwon 优化特征提取下采样机制

在图像处理和深度学习领域，卷积神经网络（CNN）里的特征提取至关重要。传统特征提取方法常借助下采样操作，例如运用池化层或者调整卷积层步幅，以此来缩小图像的空间尺寸。这一操作益处明显，既能够显著降低计算复杂度，又能大幅减少内存消耗，有助于提升模型运行效率。但这类常规下采样方法有个明显短板，在处理图像时易导致细节信息丢失。尤其是处理小目标图像或高分辨率图像时，信息丢失情况会加剧，进而对后续图像分析和处理结果产生负面影响。

常见的下采样操作，如最大值下采样，通常选取一个局部范围内的最大值作为输出，其原理如图 3-4 所示，忽略其他信息。这种选择性的信息压缩方式虽然能够快速降低空间维度，但它不具备保留原始细节的能力。随着网络层数的增加，图像的分辨率逐步降低，使得小物体和细节部分变得更加模糊，甚至无法在后续的网络层中进行有效的检测和识别。这在许多计算机视觉任务中，尤其是在小目标检测方面，成为了一个难以克服的问题。因此，虽然传统的下采样方法能有效地减少计算量，但它们对特征信息的选择性压缩，尤其是对图像中的小目标和精细特征的忽视，常常导致性能上的下降，尤其是在需要高精度的小目标识别任务中。




图 3-4 最大池化操作过程

Fig.3-4 The operation process of the maximum pooling

为了克服传统下采样方法带来的信息丢失问题，ADown (Adaptive Downsampling) 作为一种新兴的特征提取方法应运而生。与固定的池化方法不同，ADown 采用了一种自适应的下采样机制，使得在进行空间降维时，可以根据输入图像局部区域的特征分布和重要性动态地调整下采样的程度，ADown 具体结构如图 3-5 所示。这种方式能更有效地保留图像中的关键信息，尤其是在小物体或细节丰富的区域。该模块的结构主要包括输入、平均池化、分支处理、卷积和特征融合几个步骤。输入的特征图经过平均池化降低空间分辨率后，分为两个分支。一个分支继续进行线性操作，另一个分支进行最大池化。两个分支分别经过卷积、批归一化和 SiLU 激活函数处理，最后通过拼接 (Concat) 操作将它们的输出特征融合，生成最终的特征图。

ADown 模块进行下采样操作，其设计目标是通过高效的方式对特征图进行下采样，并且最大限度地减少对模型性能的负面影响。ADown 模块的优势表现在多个方面，首先，它采用了轻量化设计，减少了模型中的参数量，从而降低了整体的计算复杂度。这样的设计不仅优化了模型的运行效率，还尤其在计算资源有限的情况下，能够显著提升

模型的推理速度和响应能力。




图 3-5 ADown 具体结构

Fig.3-5 The specific structure of ADown

ADown 模块在降低特征图的空间分辨率时，特别注重保留关键的图像信息，这确保了下采样过程中尽可能不丢失对任务至关重要的特征。这种做法帮助模型在进行后续处理时，仍能保持较高的准确性，尤其是在目标检测等任务中，能够保证对细节信息的敏感性。另一方面，ADown 模块具有一定的可学习能力，可以根据不同的数据特征和应用场景进行自适应调整。这一特点使得模块能够在不同任务中优化其表现，从而提升整体的模型效果，不论是对于小物体的检测还是复杂场景的理解，都能够做到精细调节。

在无人机拍摄的图像中，特别是在进行小目标检测时，传统下采样方法往往会因其信息压缩方式不够灵活而导致检测性能的下降。无人机图像往往具有复杂的背景和多样的场景，小目标往往处于低对比度、远距离或者背景较为复杂的位置。在计算机视觉领域中，小目标的精准检测已然演变为一项亟待攻克的关键性难题。传统的下采样方法在处理这些图像时，往往由于分辨率过低而无法准确地提取小目标的特征。

ADown 方法在这种情况下显示出了显著的优势。通过自适应调整下采样操作，ADown 能够在图像的关键区域保留更多的细节，从而有效避免了传统下采样方式在小目标检测中的信息丢失。例如，在无人机拍摄的遥远或低对比度小物体的区域，ADown 能够保留更多精细的特征，确保这些小目标在网络的后续层中仍然具备较高的辨识度。这种能力使得 ADown 在无人机图像中的小目标检测任务中，表现出更高的准确性和鲁棒性。此外，ADown 还能够优化整个网络的计算效率。与传统的池化方法相比，ADown 能根据图像的实际需求动态调整特征图的空间分辨率，避免了过度压缩无关区域的特征，

同时确保小目标和重要区域的特征能够得到充分的保留。这种自适应性使得 ADown 不仅能够提高小目标的检测精度，还能在保证计算量相对较低的情况下，实现更高效的目标检测。

3.3.3 优化后 RA-RTDETR 特征提取网络整体结构

为了提升 RTDETR 模型在无人机图像中对小目标的检测效果，本文提出了基于跨阶段并行特征提取网络（RepCSPNet 块）来替代传统的 ResNet-r18 骨干特征提取网络。RepCSPNet 块通过结合重参数化卷积与残差结构，在降低计算复杂度的同时有效减轻了计算负担。这种结构不仅减少了计算资源的消耗，还保持了高效的特征提取能力，使得模型在处理高分辨率图像时，可以更准确地捕捉到关键的细微特征，进而增强了对小型物体的识别能力。

针对传统下采样方法在特征提取过程中可能导致的图像信息丢失问题，我们引入了 ADown 特征提取下采样机制。该机制通过在降低特征图空间分辨率的同时，精心保留了图像中的关键信息，特别是那些对任务至关重要的细节。通过这种改进，ADown 有效避免了下采样过程中重要特征的丢失，从而保障了特征提取的完整性和准确性，增强模型对小目标的辨识精准度。具体优化后的 RA-RTDETR 网络结构图如图 3-6 所示。




图 3-6 优化后 RA-RTDETR 特征提取网络总体结构图

Fig.3-6 Overall structure diagram of the optimized feature extraction network of RA-RTDETR

特征提取两种模块协同过程，RepCSPNet 块首先对输入的无人机图像进行初步特征提取，利用轻量化结构快速生成包含丰富语义信息的特征图。随后，ADown 模块根据特

征图中目标分布与结构信息，自适应调整下采样参数，确保在分辨率降低过程中，小目标的关键特征被完整保留并传递至后续网络层。这种协同机制使得联合特征提取网络既能保持高效的计算效率，又能实现对小目标细节特征的精准捕捉，有效增强了模型对无人机图像中小目标的辨识精准度，为后续多尺度特征融合与目标检测任务提供高质量的特征输入。

3.3.4 优化后特征提取模型算法流程

具体优化结构的算法流程为一开始输入图像首先通过多个 RepCSPNet Block 进行特征提取。每个 RepCSPNet Block 包含两个 3×3 卷积层 (Conv 3×3)，用于提取局部特征。特征图经过 RepCSPNet Block 后，通过 ADown 模块进行下采样，逐步减少特征图的分辨率，同时增加通道数。ADown 模块在每个 RepCSPNet Block 之后应用，逐步降低特征图的分辨率。下采样后的特征图继续通过 RepCSPNet Block 进行特征提取，进一步增强特征表示能力。最后一个 RepCSPNet Block 的输出通过 1×1 卷积层 (Conv 1×1) 进行通道数调整，然后进入 AIFI 模块。AIFI 模块通过注意力机制进一步增强特征表示能力。

CCFM 模块接收来自 Backbone 的特征图，通过多个 1×1 卷积层 (Conv 1×1) 和 3×3 卷积层 (Conv 3×3) 进行特征融合。特征图通过 RepC3 模块进行进一步的特征增强，RepC3 模块包含一个 RepConv 层和一个 3×3 卷积层。不同尺度的特征图通过 Concat 操作进行拼接，形成更丰富的特征表示。最后，融合后的特征图通过 1×1 卷积层进行通道数调整，输出最终的特征图。最终的特征图通过解码器部分进行进一步处理，生成检测结果。

模型训练过程如下所示：

(1) 输入无人机图像数据：实验的初始阶段获取了由 10209 张静态图像构成的 VisDrone 数据集，将 6471 张图像送到优化后的模型中进行训练，确定将 2042 幅图像配置为验证样本集，1696 幅图像划归测试样本集。

(2) 网络前向传播：输入无人机图像，通过 Backbone 中的多个 RepCSPNet Block 和 ADown 模块进行特征提取和下采样。特征图逐步减少分辨率，同时增加通道数，最终输出高维特征图。高维特征图通过 Efficient Hybrid Encoder 中的 CCFM 模块进行跨尺度特征融合。特征图通过 1×1 卷积层和 3×3 卷积层进行处理，通过 RepC3 模块增强特征表示能力。不同尺度的特征图通过 Concat 操作进行拼接，形成更丰富的特征表示。融合后的特征图通过解码器部分进行进一步处理，生成分割结果。解码器部分通过 Query Selection 模块和 Decoder Head 模块，生成最终的检测图。

(3) 网络反向传播：通过对比生成的检测图与真实的标签图，计算损失函数值。使

用 mIOU 和 Dice 系数作为评估指标, 计算预测结果与真实标签之间的差距。运用反向传播机制, 依据损失函数评估值对网络权重参数实施迭代更新。优化策略通过动态调节网络参数配置, 逐步缩小预测输出与真实标注之间的误差范围。经过大约 300 轮的训练, 网络的损失函数值逐渐趋于平缓, 模型达到收敛状态。待训练流程结束后, 系统将输出最终的神经网络权重参数配置。

(4) 测试与评估: 将测试集中的无人机图像输入训练好的模型, 生成预测检测图。将测试集中的无人机图像输入训练好的模型, 生成预测检测图。通过对比预测检测图与真实的标签图, 计算精确率 (Precision) 和召回率 (Recall) 等指标。针对无人机图像检测任务, 对模型性能展开系统性评估。通过实施多模型性能对比实验, 实证检验所提模型方案的优越性能。

3.4 实验相关介绍

3.4.1 实验数据集介绍

在目标检测算法的研究领域, 从无人机视角全面评估算法性能是一项极具现实意义且充满挑战的任务。为了达成这一目标, 本实验选用了 VisDrone2019^[64]数据集。由天津大学相关实验室主导构建, 联合多个科研机构共同发布的数据集。它的出现为基于无人机的视觉任务研究提供了一个大规模、标准化的基准测试平台, 在无人机视觉研究领域具有重要的地位和广泛的应用。

VisDrone2019 数据集为目标检测算法的效能评估设置了极具挑战性的测试场景。于真实无人机作业场景下, 目标对象的几何形态、空间分布及动态状态均呈现高度复杂化特征。该数据集中存在大量小目标, 这些小目标在图像中所占像素比例小, 特征信息有限, 使得算法难以准确捕捉和识别其特征。同时, 密集目标的存在也是一个棘手的问题, 多个目标紧密排列, 相互之间的特征容易混淆, 增加了目标分割和分类的难度。此外, 部分目标还存在被遮挡的情况, 被遮挡的目标只有部分特征可见, 算法需要从有限的可见信息中推断出完整的目标信息, 这对算法的特征推理和上下文理解能力提出了很高的要求。

该数据集包含了 10209 张静态图像, 为了科学地评估算法性能, 这些图像被合理地划分为三个不同的子集。训练集是算法学习的基础, 其中包含了 6471 张图像。在训练过程中, 模型通过对这些图像的学习, 不断调整自身的参数, 以适应不同目标的特征和分布规律。验证集则起到了监控和调整模型的作用, 它包含 548 张图像。

在模型学习阶段，验证集有助于实时监测模型表现，揭示潜在问题，例如泛化能力不足或学习能力欠缺等，基于评估分析结论，对模型架构参数实施动态优化，旨在提升其跨场景适应性能。测试集是最终评估模型性能的关键，它包含 1610 张图像。通过在测试集上的表现，可以客观地衡量模型在实际应用中的性能，检验模型是否能够准确地检测和识别目标。

VisDrone2019 数据集涵盖了 10 个主要的目标类别，如图 3-7 所示，这些类别基本涵盖了无人机在实际应用中常见的目标类型。行人（pedestrian）是最常见的目标之一，在城市监控、交通管理等场景中具有重要的研究价值。人群（people）则是多个行人的集合，其特征和行为模式与单个行人有所不同，需要算法具备更强的分析能力。于交通目标类别体系中，涵盖如两轮骑行工具自行车（bicycle）、四轮载客车辆汽车（car）、厢式运输载体面包车（van）、重型货运工具卡车（truck）及公共通勤公交车（bus）等多元对象。于特定地域环境与特定应用情境中，人力驱动三轮车辆（tricycle）及其加装遮阳装置的变型车款（awning-mounted tricycle）呈现出较高的出现概率，其独特的形态和用途也为目标检测带来了一定的挑战。摩托车（motor）则具有速度快、灵活性高的特点，对算法的实时性和准确性提出了更高的要求。每个类别的实例数量分布情况如图 3-7 所示，不同类别的实例数量差异反映了实际场景中目标出现的频率和分布规律。这种丰富的类别和多样的数量分布使得该数据集能够更好地模拟真实的无人机视觉场景，有助于训练出更具通用性、准确性和鲁棒性的目标检测模型，为适配多元应用场景中的无人机目标识别任务需求。通过对该数据集的深入研究和应用，可以不断推动目标检测算法在无人机领域的发展和创新。




图 3-7 各类目标对象在 VisDrone2019 数据集分布态势

Fig.3-7 The distribution patterns of various target objects in the VisDrone2019 dataset

3.4.2 实验评价指标介绍

在目标检测领域，准确且全面地评估模型性能是衡量模型优劣的关键所在。一个性能卓越的目标检测模型不仅要能够精准地识别目标，还需在效率、资源利用等多方面展现出优势。为了科学、系统地评估所提出模型在特定任务中的表现，本研究系统性选取四项核心评估维度，具体涵盖：分类精度量化指标精确率（Precision）、目标检索完备性指标召回率（Recall）、多类别综合性能评估指标平均精度均值（mean average precision, mAP）以及神经网络结构复杂度量参数模型参数量。这四个指标从不同的维度出发，对模型的性能和效率进行了全方位、深层次的综合考量，为模型的评估提供了全面且细致的信息，有助于我们深入了解模型的优势与不足，从而为模型的优化和改进提供有力依据。

精确率在目标检测评估中扮演着至关重要的角色，它主要衡量的是在该指标衡量了被判定为正样本的结果中，真正正样本所占的比例，它是评估模型效能的关键指标之一。其计算公式为（3-5）：

$$P = \frac{N_{TP}}{N_{TP} + N_{FP}} \quad (3-5)$$

其中， N_{TP} 代表被模型正确分类为目标样本的数量，也就是真正例的数量。这部分样本是模型准确识别出的目标，是模型检测能力的直接体现。例如，在无人机图像小目标检测任务中， N_{TP} 就是模型准确检测到的目标数量。而 N_{FP} 表示被模型错误分类为目标的样本数量，即假正例的数量。这些样本实际上并不是目标，但模型却将其误判为目标，属于误检情况。精确率越高，说明模型在预测为正样本时，其预测结果的可靠性越强。在实际应用场景中，如智能安防监控系统，高精确率意味着系统在发出警报时，真正存在异常目标的概率较大，能够有效减少误报情况，避免不必要的资源浪费和干扰。在无人机图像小目标检测中，如果精确率较高，意味着模型在检测到的目标中，真正是目标的比例较大，误检的情况较少，这对于提高检测的可靠性和效率具有重要意义。

召回率同样是评估目标检测模型性能的核心指标之一，它用于评估在所有实际的正样本中，被模型正确预测为正样本的比例。召回率体现了模型对正样本的捕捉能力，反映了模型是否能够全面地检测到所有实际存在的目标。其计算公式为（3-6）：

$$R = \frac{N_{TP}}{N_{TP} + N_{FN}} \quad (3-6)$$

其中 N_{FN} 表示被模型错误分类为背景的样本数量，即假负例的数量。这些样本实际

上是目标，但模型却未能将其检测出来，属于漏检情况。目标检索完备性指标召回率数值攀升，表征模型对实际存在目标的识别覆盖范围扩大，遗漏检测现象相应缩减。在实际应用中，召回率的重要性不言而喻。例如，在无人机对特定区域内目标的搜索任务中，较高的召回率可以确保更多的目标被检测到，避免重要目标的遗漏。在自然灾害救援场景中，无人机需要快速、全面地搜索受灾区域内的幸存者，此时高召回率的目标检测模型能够更有效地发现幸存者，为救援工作争取宝贵的时间。

平均精度均值是衡量模型在所有类别上整体性能的关键指标，它综合考虑了模型在各个类别上的表现，能够更全面地反映模型的性能。在目标检测任务中，往往涉及多种不同类别的目标，每个类别的目标具有不同的特征和分布情况。mAP 指标通过对每个类别的平均精度（AP）进行综合计算，为我们提供了一个全面评估模型性能的量化标准。其具体计算公式为（3-7）：

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (3-7)$$

其中，N 表示类别的数量， AP_i 表示第 i 个类别的平均精度。平均精度均值能够有效地评估模型在处理多种类别目标时的综合能力。例如，在 VisDrone2019 数据集包含多种目标类别的情况下，mAP 可以准确地衡量模型对不同类型目标的检测性能。一个高 mAP 值的模型意味着它在各个类别上都具有较好的检测效果，能够在复杂的目标检测任务中表现出色。通过对 mAP 的分析，我们可以了解模型在不同类别目标上的优势和不足，为进一步优化模型提供有针对性的方向。

模型参数量指的是模型中可学习参数的总数，它是衡量模型复杂度和计算资源需求的一个重要指标。在深度学习模型中，参数是模型学习和表示数据特征的关键因素。模型参数量的大小直接影响到模型的训练和推理速度，以及对硬件资源的要求。较小的模型参数量意味着模型更加轻量化，具有以下显著优势。在训练过程中，轻量化模型所需的计算资源和时间更少，能够更快地收敛，提高训练效率。在推理阶段，轻量化模型可以在资源受限的设备上，如无人机搭载的计算设备、移动终端等，更高效地运行，减少响应时间，满足实时性要求。随着评估指标值的动态增长，可观察到模型对真实目标对象的识别覆盖率呈现显著提升态势，同时目标遗漏检测事件的发生频次呈现逐步降低趋势。在实际应用中，如无人机目标检测系统，需要在保证检测性能的前提下，尽可能降低模型的参数量，以提高系统的运行效率和稳定性。

3.5 实验结果与实验分析

为切实验证基于跨阶段 RepCSPNet 和 ADown 模块对 RTDETR 特征提取结构所做优化的成效，本部分精心设计并开展了一系列实验。接下来，我们会先详细介绍实验所涉及的环境参数，确保实验条件的清晰透明。随后，通过消融实验深入探究各个优化模块对整体性能的具体贡献，剖析其内在作用机制。同时，进行对比实验，将优化后的模型与其他相关模型进行全面比较，突出优化后模型在各方面展现出的优势。此外，还会采用可视化展示的方式，以直观的形式呈现优化前后模型表现的明显差异。通过这一系列实验操作，从多个维度、多个层面为优化方案的性能提供科学、可靠的评估依据。

3.5.1 实验环境参数介绍

在本实验中，为了保证实验的顺利进行并确保数据处理与模型训练的高效性，采用了高性能计算系统。该系统配置了英特尔 (Intel) Core(TM) i9-10920X 处理器，具有 32GB 的内存，该处理器拥有 16 核和 24 个线程，其默认频率为 3.50GHz，并支持最高可达 3.19GHz 的加速频率。这一强大的处理能力为实验提供了卓越的计算性能。此外，为了配合高效的处理能力，系统还配备了 NVIDIA GeForce GTX 3080 显卡，具备 10GB 独立显存，可以高效地支持深度学习中的大规模矩阵运算和并行处理任务。

在深度学习模型的开发方面，采用了 Pytorch 1.8.1 平台，作为一种流行的开源深度学习框架，Pytorch 以其适应性和可延伸性著称，已成为计算机视觉、自然语言处理等领域的首选工具。同时，结合 Torchvision 0.16.1，这一库为计算机视觉任务提供了丰富的图像处理函数和预训练模型，有效支持模型的快速搭建和实验验证。为了确保深度学习任务能够顺利进行，本实验选择了 Python 3.8.1 版本，以保证与 Pytorch 以及相关库的兼容性，并优化计算效率，确保在训练与推理过程中能够充分利用硬件资源。

为了保证模型训练的公平性与结果的可比性，在进行消融实验与对比实验时，未采用预训练权重。通过这一设置，可以确保每次实验结果均仅反映模型结构本身的能力，避免了外部因素（如预训练权重的影响）对模型性能的干扰。这一做法在一定程度上提高了实验的严谨性，并为后续的分析 and 讨论提供了更加纯粹的数据支持。

为确保实验配置与参数的清晰传达，所有实验所用的硬件与软件配置均详细列示于表格 3-2 中。具体参数介绍如下：

（1）训练轮数（epochs）选择：训练轮次（epochs）指的是模型针对训练数据集完成全部遍历迭代的次数。通常情况下，增加训练轮次有助于提升模型的预测精度，然而这也会导致计算负担加重以及训练耗时延长。在模型训练进程中，每一轮迭代结束后均

会对模型参数权重进行更新操作，直至损失函数值趋于稳定。依据本实验的观测结果，当训练轮次达到约 300 次时，模型呈现出良好的收敛特性。本实验将训练轮次参数设定为 300 轮，旨在保障模型能够充分提取特征信息并获得理想的图像分割性能。

(2) 批次大小 (batch size) 选择：批次大小决定了每次模型训练时输入的样本数量。较大的 batch size 有助于提高模型的训练精度，但也需要更多的计算资源，特别是 GPU 显存。在本实验中，由于使用的是 Nvidia GeForce GTX 显卡，经过调整后，batch size 选择为 4，这样能够在合理的计算资源下保持训练过程的高效性，同时避免显存过度占用。

(3) 并行工作数 (workers) 选择：训练过程中，数据加载是一个关键环节，通过设置合适的工作线程数 (workers)，可以提升数据加载的速度，进而减少训练过程中的瓶颈。通常来说，增加 workers 数量可以提升训练效率，但也要考虑计算机硬件的具体配置。在本实验中，选择了 4 个工作线程，以优化数据预处理和加载过程，确保训练过程的流畅性。

(4) 输入图像尺寸 (imgsize) 选择：输入图像的尺寸直接影响到模型的特征提取能力和计算资源的消耗。图像尺寸过大会增加计算和显存的压力，而尺寸过小则可能导致特征信息的丢失，影响模型的分割精度。在本实验中，经过调试和对比，最终选择了 640×640 的输入尺寸，既能有效保留图像中的关键信息，又能在硬件限制下进行高效计算。

(5) 优化器选择 (optimizer)：优化器在深度学习中负责调整网络权重，使模型逐步接近最优解。AdamW 优化器是一种常见且表现优良的优化器，相比传统的 SGD 优化器，AdamW 能够更好地处理稀疏梯度问题，并且在较复杂的任务中展现出较高的收敛速度和性能。因此，本实验中选择了 AdamW 优化器，以保证网络模型的训练稳定性和收敛效果。

(6) 优化器选择 (optimizer)：优化器在深度学习中负责调整网络权重，使模型逐步接近最优解。AdamW 优化器是一种常见且表现优良的优化器，相比传统的 SGD 优化器，AdamW 能够更好地处理稀疏梯度问题，并且在较复杂的任务中展现出较高的收敛速度和性能。因此，本实验中选择了 AdamW 优化器，以保证网络模型的训练稳定性和收敛效果。

(7) 最终学习率 (lrf) 选择：最终学习率是指在训练过程中逐渐衰减到的学习率，用于避免模型在接近最优解时过度波动。选择合适的最终学习率能够帮助模型在训练后期保持稳定的收敛状态。在本次实验中，设置最终学习率为 1.0，以保证网络在训练的

后期仍能保持有效的学习能力，并避免早期的过拟合现象。

（8）动量（momentum）选择：动量是用于优化梯度下降方法的一种技术，它通过在更新权重时引入过去梯度的影响，帮助模型加速收敛并减少振荡。在本实验中，动量设置为 0.9，这是一个常用的设置值，能够有效加速训练过程，同时避免过早陷入局部最优解。

表格 3-2 包含了相关细节，便于实验结果的复现与对比分析。通过精心的硬件配置与合理的软件环境搭建，本实验为后续深度学习模型的开发与优化提供了坚实的基础，经严谨规范实验流程，并采用统一评估基准体系，有效保障了实验数据精确度及不同实验组间的结果可对照性。

表 3-2 实验参数设置

Tab.3-2 Experimental parameter settings

Parameters	Settings
epochs	300
batch	4
workers	4
imgsize	640
optimizer	AdamW
lr0 (initial learning rate)	0.0001
lrf (final learning rate)	1.0
momentum	0.9

3.5.2 消融实验

为深入探究不同优化策略对特征提取网络性能的具体影响，本文精心设计了四组模型配置开展消融实验。实验以原始 RTDETR 模型作为基准模型 A，在此基础上循序渐进地引入不同优化改进，以全面评估各策略的有效性。

首先构建了改进模型 A+B，它借助跨阶段 RepCSPNet 对 RTDETR 的特征提取结构进行优化，以此提升特征提取的效率与质量。随后，得到改进模型 A+C，其基于 ADown 对 RTDETR 的特征提取下采样机制进行优化，有效规避传统下采样操作中细节信息丢失的问题，增强对小目标和高分辨率图像的特征提取能力。最后，将两种策略相结合，构建出改进模型 A+B+C，即 RA-RTDETR，同时采用跨阶段 RepCSPNet 和 ADown 模块优化特征提取结构，发挥两者协同优势，进一步提升网络性能。通过这一系列在验证集

上的消融实验，实验结果如表 3-3 所示，可清晰洞察每个优化策略及其组合对特征提取网络性能提升的贡献，为网络的后续优化和实际应用提供坚实依据。

表 3-3 消融实验结果

Tab.3-3 Results of the ablation experiment

方法	P/%	R/%	mAP50/%	Param/MB	GFLOPs/G
A	61.1	46.6	47.4	40.5	58.2
A+B	62.0	46.9	47.8	36.5	33
A+C	61.9	46.7	47.5	34.2	35.4
A+B+C	62.2	47.1	47.9	32	36.5

为了全面且定量地评估模型 A、A+B、A+C 和 A+B+C 的改进效果，本文选取了五项关键指标作为评估标准。分类精度量化指标精确率（P）用于评估模型预测结果与真实标签的匹配精准度；召回率（R）体现模型识别所有正样本的能力；mAP50 作为多类别目标识别效能的综合评估基准，用于量化模型在跨类别分类场景下的全局性能水平；模型权重文件大小（Param）用于评估模型的复杂度和存储需求；每秒浮点运算次数（GFLOPs）则直接反映计算资源的消耗情况。

与原始模型 A 相比，基于跨阶段 RepCSPNet 改进的模型 A+B 优势明显。精确率提升 0.9 个百分点，源于 RepCSPNet 优化后的特征提取流程，避免信息冗余与丢失，增强目标识别准确性；mAP50 提高 0.4 个百分点，体现其在多类别分类任务中性能提升。同时，模型权重减少 4MB，浮点运算次数降低 25.2G，轻量化设计有效降低模型复杂度与计算成本，利于资源受限环境部署。采用 ADown 优化的模型 A+C 也成果显著。精确率提升 0.8 个百分点，ADown 自适应下采样保留关键特征，使目标识别更准。模型权重减少 6.3MB，浮点运算次数降低 22.8G，优化资源利用，减轻计算负担。

结合两种策略的模型 A+B+C 性能更优。精确率达 62.2%，mAP50 为 47.9%，跨阶段 RepCSPNet 与 ADown 协同，前者优化结构提升信息整合，后者保障下采样信息留存，共同提升检测精度与综合性能。模型权重降至 32MB，浮点运算次数为 36.5G，实现性能与资源消耗的良好平衡。

消融研究实证表明，所提出的优化策略对模型性能具有显著提升作用。跨阶段 RepCSPNet 和 ADown 模块通过优化特征提取结构与下采样机制，分别从不同层面提升了模型性能，减少了模型参数，降低了计算资源消耗，为网络的后续优化和实际应用奠定了坚实基础。

3.5.3 对比实验

为了进一步验证改进后的 RTDETR 的性能,本节开展了对比实验,将其与十种当前先进的目标检测算法^[13],包括 SSD、Faster R-CNN、Yolov5m、Yolov5l、Yolov7、Yolov8s、Yolov8m、Yolov8l、Deformable DETR 以及原始的 RTDETR-R18 在具有挑战性的 VisDrone 2019 无人机图像检测数据集上进行比较,实验结果如表 3-4 所示。该数据集以其复杂多变的场景以及高密度的目标分布而闻名。

在本次对比实验进程中,针对多个目标检测模型,从多个关键性能维度展开了系统性评估。这些维度涵盖了 mAP 50%、mAP 50:95%、FPS (每秒帧率)、Param (模型参数量) 以及 GFLOPs (每秒浮点运算次数),旨在深度剖析不同模型的性能特性,同时着重凸显本章经改进后的模型所具备的独特优势。

表 3-4 对比实验

Tab.3-4 Results of the comparative experiment

模型	mAP 50/%	mAP 50:95/%	FPS/f	Param/MB	GFLOPs/G
SSD	24.2	10.7	65.3	26.3	62.7
Faster R-CNN	33.2	17.0	15.0	137.1	370.2
Yolo v5m	37.6	19.8	124.0	21.2	49.0
Yolo v5l	40.4	25.3	89.0	46.15	109.1
YoLo v7	46.1	24.0	36.0	37.2	103.3
Yolo v8s	39.2	23.4	120.2	11.2	28.6
Yolo v8m	42.7	26.6	82.4	25.9	78.7
Yolo v8l	48.5	29.7	34	43.7	165.2
Deformable DETR	43.1	27.1	14.0	40	196
RTDETR-R18	47.4	29.5	54.1	40.5	58.2
Ours	47.9	29.9	86.6	32	36.5

在与多种先进算法的对比实验中,改进后的模型展现出卓越性能。在平均精度均值 (mAP) 指标方面,跨阶段 RepCSPNet 优化特征提取整体结构,极大提升信息整合效率,而 ADown 模块保障下采样时关键信息留存,二者协同作用,让模型在复杂的 VisDrone 2019 数据集中,能精准捕捉目标特征。这使得 mAP50%指标上,改进模型以

47.9%的精度超越 Deformable DETR 等模型,在 mAP 50:95%指标上,以 29.9%反超 Yolo v8l。

帧率(FPS)层面,改进模型虽因跨阶段 RepCSPNet 优化网络结构,减少冗余计算层级,搭配 ADown 模块提升特征信息留存,帧率达到 86.6FPS,远超 Faster R-CNN、Deformable DETR 以及 Yolo v7,优化后的算法架构可高效适配实际场景中的实时响应需求。

在模型参数量(Param)和每秒浮点运算次数(GFLOPs)上,跨阶段 RepCSPNet 和 ADown 模块协同实现轻量化。通过精简网络结构、采用高效计算方式,模型权重降至 32MB,GFLOPs 降至 36.5G,相比原始 RTDETR-R18 及 Faster R-CNN 等大幅优化,在减少计算资源消耗的同时,显著提升检测精度,达成性能与资源消耗的理想平衡,在实际无人机图像检测场景中优势突出。

改进后的模型在检测精度、推理速度以及模型轻量化这三个关键方面达成了较为理想的平衡。在维持较高检测精度的基础上,不仅提升了推理速度,还降低了模型复杂度以及计算资源的消耗,充分展现出在实际应用场景中的巨大潜力与独特优势。

3.5.4 可视化展示

在目标检测的探索进程中,可视化剖析是深度洞察模型性能的有效途径。本部分运用 HiResCAM^[65]作为可视化的方法,借助经过 300 轮训练的预训练权重对无人机图像开展检测工作,以此来对比不同模型的检测表现。

在图 3-8 中,我们将重点关注图 3-8 (b)和图 3-8 (c)。图 3-8 (c)中,红框圈出的部分特定标识出了原始模型(图 3-8 (b))检测精度较低的区域。这些区域之所以检测精度较低,存在多种复杂的原因。目标特征不够突出是一个重要因素。在实际的图像中,有些目标可能由于自身的特性,如颜色、形状与背景相似度较高,或者目标本身尺寸较小,导致其特征信息在图像中不明显。例如,在一幅包含众多建筑物的城市航拍图像中,一些小型的车辆目标可能由于其尺寸相对于整个图像来说非常小,并且颜色与周围的道路、建筑颜色相近,使得模型难以从复杂的背景中提取到这些目标的有效特征,从而导致检测精度下降。


存在遮挡状况也会对模型的检测精度产生严重影响。当目标物体被其他物体部分或完全遮挡时,模型只能获取到目标的部分特征信息。这就使得模型难以根据这些不完整的特征来准确判断目标的类别和位置。比如,在一个停车场的图像中,一辆汽车可能被旁边的另一辆车部分遮挡,模型只能看到被遮挡汽车的部分车身,无法获取到其完整的

轮廓和特征，从而增加了检测的难度，导致检测精度降低。


复杂的背景环境也是导致模型检测精度下降的重要原因之一。复杂背景中可能包含大量的干扰信息，这些信息会与目标特征相互混淆，使得模型难以准确区分目标和背景。例如，在一幅自然风景图像中，目标可能是隐藏在草丛中的野生动物，而草丛的纹理、颜色等信息会与野生动物的特征相互交织，给模型的检测带来很大的挑战。



(a) 原始图像



(b) 原始 RTDETR-R18 模型检测热力图



(c) 改进后 RA-RTDETR 模型检测热力图

图 3-8 不同模型检测热力图对比

Fig.3-8 Comparison of detection heatmaps of different models

通过仔细对比图 3-8 (b) 和图 3-8 (c)，我们能够清晰地发现改进后的 RA-RTDETR 模型在检测精度方面要明显优于原始的 RTDETR 模型。在图 3-8 (c) 中，改进后的模型所生成的热力图在目标区域的颜色更加均匀且集中，这表明模型能够更准确地聚焦于目

标物体，对目标的定位更加精准。而在图 3-8（b）中，原始模型的热力图在目标区域存在颜色分散、模糊的情况，甚至在一些应该是目标的区域颜色较浅，这说明原始模型对目标的检测不够准确，检测过程中可能出现目标遗漏或错误识别现象。


改进后的 RA-RTDETR 模型之所以能够在检测精度上取得显著提升，得益于对原始模型进行的一系列优化措施。这些优化措施针对原始模型在处理复杂情况时的不足进行了改进，从而增强了模型对各种复杂场景的适应能力。例如，改进后的模型可能采用了更先进的特征提取算法，能够从图像中提取到更丰富、更具代表性的目标特征。同时，模型可能还引入了一些注意力机制，使得模型能够更加聚焦于目标区域，减少背景干扰信息的影响。此外，在模型的训练阶段，可能使用了更合适的代价函数和优化策略，进一步提升了模型的适应能力和推广能力，从而使得模型在面对各种复杂情况时都能够保持较高的检测精度。

通过对图 3-8 中不同模型检测热力图的对比分析，我们可以直观地看到改进后的 RA-RTDETR 模型在检测精度方面相较于原始的 RTDETR 模型有了显著的提升。不仅实证了所提优化策略的显著效能，更为后续目标识别算法的迭代升级构筑了坚实的理论支撑框架。在接下来的第四章研究中，继续深入探索更加有效的优化方法，不断提高目标检测模型的性能，以满足实际应用中的各种需求。

在目标检测研究中，模型的性能评估至关重要。为了更为全面且精准地衡量修改后模型在实际场景中的检测效能，图 3-9 直观地展示了修改前后模型的具体检测结果。这些结果，让我们得以深入且细致地洞察不同模型在实际目标检测任务中的真实表现。

从这些具体的检测结果里，我们能够捕捉到诸多关键信息。其中，对图 3-9 中各个检测框的细致分析是评估模型性能的关键环节。我们着重关注检测框的位置、大小以及它们与真实目标的匹配程度。检测框的位置反映了模型对目标位置的判断，精准的位置意味着模型能够准确地定位目标；检测框的大小则与目标的实际尺寸相关，合适的大小表明模型对目标的尺度把握准确；而检测框与真实目标的匹配程度，更是直接体现了模型在目标定位和分类方面的准确性。

通过这样的分析，我们能够清晰地验证改进后的 RA-RTDETR 模型在目标定位和分类准确性上实现了显著提升。具体而言，改进后的模型所生成的检测框往往与真实目标具有更高的重叠度。这一特征意味着模型能够更精确地贴合目标的实际轮廓，准确地识别出目标的范围。例如，在处理不规则形状的目标时，改进后的模型能够生成与目标形状高度契合的检测框，而不是像原始模型那样出现较大的偏差。



(a) 原始图像



(b) 原始 RTDETR-R18 模型检测结果图



(c) 改进 RA-RTDETR 模型检测热力图

图 3-9 不同模型检测结果图对比

Fig.3-9 Comparison of detection results of different models

同时，改进后的模型在减少误检和漏检方面表现出色。误检是指模型将非目标物体错误地识别为目标，这会给后续的处理带来不必要的干扰；漏检则是指模型未能识别出实际存在的目标，这会导致重要信息的丢失。改进后的 RA-RTDETR 模型通过优化算法和特征提取方式，有效地降低了这两种情况的发生概率。以图 3-9 为例，图 3-9（c）中右下角的 bicycle 在图 3-9（b）中并未被检测出来，这一明显的对比清晰地展示了改进后模型在检测能力上的增强。图 3-9 所呈现的修改前后模型的具体检测结果为我们提供了丰富而有价值的信息。通过对这些结果的深入分析，我们不仅验证了改进后的 RA - RTDETR 模型在目标定位和分类准确性上的提升，还能够了解模型在不同类型目标上

的检测效果差异,为进一步优化模型提供了明确的方向和有价值的参考依据。这将有助于我们不断改进目标检测模型,使其在实际应用中发挥出更好的性能。

3.6 本章总结

本章围绕基于跨阶段 RepCSPNet 和 ADown 模块对 RTDETR 特征提取结构进行优化展开,旨在解决原始特征提取结构存在的问题,提升模型在目标检测任务中的性能。在优化特征提取结构方面,采取了多方面的改进措施。一方面,引入跨阶段 RepCSPNet 对特征提取结构进行优化。这种跨阶段的设计能够增强特征的融合与传递,使模型在不同层次上更有效地提取目标特征,丰富了特征信息的多样性和代表性。另一方面,利用 ADown 模块对特征提取下采样机制进行改进。ADown 模块优化了下采样过程,减少了信息的丢失,更好地保留了目标的细节特征,提升了模型对不同尺度目标的感知能力。基于这两方面的优化,构建了优化后 RA-RTDETR 特征提取网络的整体结构,并梳理出优化后特征提取模型的算法流程,为提升特征提取效能的合理性与效率性,本研究构建了优化实验体系,通过系统性实验验证了改进策略的有效性。在实验环境参数介绍部分,明确了实验所使用的软硬件环境、数据集等信息,确保实验的可重复性和结果的可靠性。消融实验分别验证了跨阶段 RepCSPNet 和 ADown 模块对模型性能的提升作用。结果表明,这两个模块单独使用时都能在一定程度上改善模型性能,而当二者结合使用时,效果更为显著。对比实验将优化后的模型与其他先进的目标检测模型在多个关键性能指标上进行对比,如 mAP 50%、mAP 50:95%、FPS、Param 和 GFLOPs 等。实验结果显示,优化后的模型在检测精度、推理速度和模型轻量化等方面都展现出明显优势。可视化展示环节,采用特定的可视化方法直观呈现了优化前后模型的检测效果差异。通过热力图和具体检测结果,我们可以清晰地看到优化后的模型能够更准确地定位目标,减少误检和漏检情况,进一步证明了优化措施的有效性。

4. 基于动态尺度序列特征融合 DySSFF 和 GLSA 特征聚合优化

4.1 原始特征融合结构存在的问题与分析

在无人机图像的实际应用中，小目标检测一直是颇具挑战性的课题。无人机作业过程中采集的图像，普遍存在噪声干扰、目标易被遮挡以及分辨率较低等问题。这些问题极大地增加了小目标检测的难度，因为小目标在图像中所占像素极少，特征不够明显，再加上复杂的外界因素，精准识别和定位小目标就成了一项艰巨的任务。

传统的 CCFM 模块在处理无人机图像小目标检测时，弊端十分显著。它往往没有意识到尺度序列信息的重要性，也就是不同尺度下物体的表现存在差异。在无人机拍摄的图像里，小目标可能会出现在不同尺度的特征图中。大尺度特征图能够展示小目标更多的细节，但噪声和遮挡可能会让这些特征变得模糊不清；小尺度特征图涵盖了更广泛的场景信息，却会使小目标的特征更加抽象和难以辨认。由于 CCFM 模块在进行多尺度特征融合时，没有充分考虑这种尺度序列信息，就无法有效地整合不同尺度特征图中与小目标相关的信息。这一缺陷严重制约了模型在无人机图像小目标检测时的多尺度特征融合效果，导致模型很难准确地识别和定位小目标。

在无人机图像中的小目标检测任务中，原始的 RTDETR 方法通过 CCFM 模块^[26]进行了多尺度特征融合。CCFM 模块通过对来自不同尺度的特征图进行整合，试图实现多层次、多尺度的目标检测。然而，尽管该模块能够在一定程度上提升模型的表现，但在其实际应用中暴露出了一些不足之处，尤其是在处理尺度序列特征时的局限性。

传统的 CCFM 模块在进行多尺度特征融合时，通常采用静态的融合策略。这意味着，尽管在不同尺度下物体的特征会发生变化，传统模块并没有考虑这些变化对物体表示的影响。具体来说，物体在不同尺度下的外观特征、纹理信息及形态结构可能有所不同，因此统一的融合方式无法有效地捕捉这些差异性。这种静态的融合方式可能导致在处理不同尺度特征时，模型未能准确地调整权重或选择合适的融合策略，从而影响了多尺度特征融合的效果和准确性。在面对模糊图像或小目标时，也可能表现出一定的不足。由于无人机图像在拍摄过程中可能存在模糊现象，尤其是在远距离拍摄时，小目标的细节信息往往较为模糊。而现有的 CCFM 模块在进行特征融合时，没有针对图像的模糊性进行适应性调整，导致在细节信息缺失的情况下，图像的结构性特征被过度强调，从而影响了小目标的精准检测。尤其是当低分辨率的特征图与高分辨率的特征图融合时，细节信息往往难以得到充分保留，进一步加剧了小目标检测的困难。

此外，传统的 CCFM 模块在跨尺度特征融合过程中，也缺乏对尺度序列信息的动态

适应能力。不同尺度下的目标具有不同的尺寸和形状，且每个尺度的特征图包含的信息差异较大。在这种情况下，如果不考虑尺度序列特征之间的相互关系，可能会导致多尺度融合的效果不佳，尤其是在复杂场景或小目标密集的图像中。尺度序列信息在一定程度上决定了目标的层次化表示，而传统的静态特征融合方法未能充分挖掘这种层次结构的信息，限制了目标检测的表现。原始的 RTDETR 方法通过 CCFM 模块进行的特征融合存在一定的局限性，主要体现在对尺度序列信息的忽视以及在多尺度特征融合过程中缺乏动态调整机制。为了提升小目标检测的精度和鲁棒性，需要在原有框架的基础上，提出更加灵活且能够适应不同尺度特征差异的特征融合方法。

4.2 基于动态尺度序列特征 DySSFF 和 GLSA 特征聚合优化特征融合

4.2.1 基于动态尺度序列 DySSFF 特征融合

为了有效解决无人机图像小目标检测的难题，本文提出了 DySSFF（Dynamic Scale Sequence Feature Fusion）模块。该模块拥有动态处理尺度序列特征的能力，能够根据无人机图像中不同尺度特征图的特点，自动调整特征融合的方式和权重。对于大尺度特征图，DySSFF 模块会重点处理细节信息，减少噪声和遮挡的影响；对于小尺度特征图，它会专注于提取和整合抽象的语义信息。通过这种动态的融合机制，DySSFF 模块能够更高效地捕捉无人机图像中小目标在不同尺度下的特征，实现更加稳健、精确的多尺度特征融合。这样一来，即使面对噪声、遮挡、低分辨率等复杂情况，模型也能显著提高无人机图像中小目标检测的精度和稳定性。




图 4-1 DySSFF 的动态融合图

Fig.4-1 The dynamic fusion diagram of DySSFF

在特征融合阶段，DySSFF 摒弃了传统的静态融合策略，而采用了一种动态融合的方法，如图 4-1 所示。该方法能够根据当前输入数据的特征，自适应地调整不同尺度特

征之间的融合权重与融合方式。这种动态调整的方式使得融合过程更加细致、精准，能够有效提升多尺度特征融合的效果。通过这种方法，DySSFF 不仅能够多尺度特征的融合过程中保留更多的信息，还能够一定程度上克服尺度差异导致的特征丢失问题，进而增强目标识别任务的精准度与抗干扰能力。原始的尺度序列特征融合方法能够较好地整合深层特征图中的高维信息与浅层特征图中的细节信息。然而，在无人机拍摄的图片中，由于图像可能出现模糊的现象，导致细节信息的丢失，而图像的结构性特征则得以保留。在这种情况下，传统的尺度序列特征融合方法可能无法有效地处理这些图像中的模糊信息。为了解决这一问题，本文提出的 DySSFF 模块在融合过程中能够动态地调整尺度序列特征的处理方式，从而更好地应对图像模糊带来的影响。具体而言，输入到 SSFF 模块的缩放图像可以通过公式(4-1)获得：

$$F_{\sigma}(w, h) = G_{\sigma}(w, h) \times f(w, h) \quad (4-1)$$

其中， $f(w, h)$ 是具有宽度 w 和高度 h 的二维输入图像； $F_{\sigma}(w, h)$ 是通过一系列卷积平滑操作生成的图像，使用的是二维高斯滤波器 $G_{\sigma}(w, h)$ ，其中 σ 是二维高斯滤波器标准差的缩放参数。此公式表示了通过高斯卷积滤波处理后的图像，能够在一定程度上平滑图像的细节，同时保留图像的结构信息，从而为后续的多尺度特征融合提供了有效的特征表示。

4.2.2 基于 GLSA 特征聚合

尽管无人机图像检测技术取得了显著的进展，但在面对复杂多变的自然场景和高密度目标时，仍然面临着诸多挑战。尤其是在存在丰富背景信息、遮挡以及目标尺度和朝向各异的情况下，精确且高效的检测仍然是一个难题。背景噪声和目标的多样性使得传统检测方法难以有效分辨目标物体与干扰信息，影响了模型的检测精度和效率。




图 4-2 GLSA 特征聚合结构图

Fig.4-2 The structural diagram of GLSA feature aggregation

为了解决这些问题并提升无人机图像检测性能,本文引入了全局局部空间注意力机制(GLSA),如图4-2所示。GLSA机制的核心在于其能够同时捕捉图像中的全局上下文信息和局部细节特征,并通过空间注意力对这些信息进行加权处理,进而提升模型对核心区域的聚焦能力,同时有效削弱非目标背景的噪声影响。通过这种方式,GLSA机制能够更精准地识别出目标区域,并在处理复杂场景时提高模型的鲁棒性和准确度。其结构如图4-2所示。

在GLSA机制中,初始的特征序列被并行输入到基于全局注意力的空间聚合模块(GASA)和基于局部窗口的空间注意力模块(LWSA)。在这两个模块中,模型对整个特征图执行空间注意力操作,以识别图像中对检测任务至关重要的区域。这一操作有助于模型聚焦于潜在目标物体所在的区域,同时减少背景噪声的干扰。具体来说,全局空间注意力模块(GASA)通过计算全局上下文信息,对整个图像的特征进行加权,从而突出显示具有重要检测价值的区域。相对的,局部空间注意力模块(LWSA)则通过局部窗口的方式,专注于图像中的局部区域,能够更加细致地捕捉到图像中的精细空间关系。局部注意力机制的引入,使得模型在处理具有复杂结构和细节的目标时,能够有效识别出更小的目标区域以及细微的目标特征。经过全局和局部空间注意力处理后,得到的特征图会在通道级特征调制模块中进行融合,这一模块通过融合不同层次的注意力信息,使得最终特征图能够综合考虑全局和局部信息。融合后的特征图随后会被传送到基于深度注意力的不确定性层,该层结合多层感知机(MLP)进一步优化和精炼特征,最终输出用于目标检测的高质量特征。

该机制的设计有效地平衡了全局信息和局部细节的捕捉,增强了模型对关键目标区域的感知能力,同时抑制了背景噪声的干扰,提升了目标检测的精度和鲁棒性。通过这一创新的空间注意力机制,GLSA能够在复杂且多变的无人机图像环境中显著提高检测效果,尤其是在处理不同尺度、不同朝向的目标时表现突出。

4.2.3 改进后网络整体结构

原始的RTDETR方法通过CCFM模块进行特征融合,在特征融合时忽视了尺度序列信息的重要性,导致特征融合未能反映目标的层次结构特性。另一方面,CCFM模块采用静态融合方式,无法根据不同尺度目标的灵活调整权重或融合策略,影响了检测的鲁棒性与精度。本章提出了动态多尺度序列特征融合DySSFF模块,该模块能够动态处理尺度序列特征,从而实现更高效、更鲁棒的多尺度特征融合。

同时,还提出了一种更加灵活的特征聚合方法——全局局部空间注意力机制

(GLSA)。GLSA 通过结合全局与局部注意力，动态调整模型对不同区域的关注权重，提升对小目标的检测精度。全局注意力机制增强了跨尺度与跨区域的长程依赖建模，而局部注意力机制则强调关键区域，减少背景噪声影响。通过这种融合方式，模型能够更好地应对多尺度目标的多样性，提升了小目标检测的精度与鲁棒性。结合本章的改进点，优化后的 DG-RA-RTDETR 模型如图 4-3 所示。




图 4-3 DG-RA-RTDETR 的网络结构

Fig.4-3 The network structure of DG-RA-RTDETR

4.3 损失函数改进

4.3.1 IOU 介绍

在目标检测任务场景下，IoU (Intersection over Union, 交并比) 作为核心评估参数，用于量化预测边界框与实际标注框的空间重叠度。该指标反映了检测模型的预测结果与实际目标之间的契合度，因此在评估目标检测算法性能时具有重要意义。

IoU 的计算方法通过衡量预测框与真实框之间的重叠部分占总并集部分的比例来进行量化。IoU 值计算逻辑为：将预测边界框与真实标注框的重叠区域面积，作为分子；以其联合覆盖区域面积作为分母，执行除法运算所得结果。设定 P 为预测框， G 为真实框，IoU 的计算公式可以表示为 (4-2)：

$$IoU = \frac{|P \cap G|}{|P \cup G|} \quad (4-2)$$

公式中，预测边界框与真实标注框在空间维度上的重叠区域面积用 $|P \cap G|$ 表示，预测框与真实框的并集面积用 $|P \cup G|$ 表示，如图 4-4 所示。这个公式反映了预测框与真实

框在空间上的重叠程度。IoU 值的取值范围在 0 和 1 之间。当 IoU 值接近 1 时，说明预测框和真实框的重叠程度非常高，表示检测结果的准确性较高；相反，当 IoU 值接近 0 时，表示预测框与真实框几乎没有重叠，检测结果的准确性较低。因此，IoU 值成为了目标检测中广泛应用的性能评估指标。

然而，IoU 虽然是一个有效的指标，但在一些情况下也存在一定的局限性。比如，在目标大小差异较大的情况下，IoU 可能对较小目标的评估不够敏感。此外，IoU 对目标检测中可能存在的部分遮挡或目标错位的情况也不够友好，因此，在实际应用中，除了 IoU，往往还会结合其他评估指标，如精确度（Precision）、召回率（Recall）以及平均精度均值（mAP）等，为系统衡量目标识别系统的综合效能。

4.3.2 基于 Focaler-CIoU 改进 CIoU 损失函数

现有 RTDETR 采用的损失函数包含分类损失（Focal Loss）、回归损失（CIoU Loss）和对齐损失。Focal Loss 用于解决正负样本不平衡问题，通过降低易分类样本的权重，使模型更关注难分类样本；CIoU Loss 则在 IoU 的基础上考虑了预测框和真实框的中心点距离、长宽比等信息，提高了目标定位的准确性；对齐损失增强了分类得分和回归质量之间的一致性。然而，在无人机图像小目标检测场景下，CIoU 损失函数未能充分考虑小目标作为困难样本的特殊性。在无人机图像中，一般的检测目标可视为简单样本，而极小目标由于其尺度小、特征微弱，难以精准定位，可看作困难样本。CIoU 损失函数在处理小目标检测时，容易受到大量简单样本的影响，导致对困难样本的关注不足，从而影响小目标的检测精度。

本文提出将 RTDETR 中的回归损失（CIoU Loss）改进为 Focaler-CIoU 损失函数，进一步聚焦小目标检测的边界框回归。在无人机图像中，小目标由于其尺度小，在特征提取和定位过程中容易被忽略。Focaler-CIoU 损失函数通过增大小目标的权重，使模型在训练过程中更加关注小目标的边框回归，从而提高小目标的检测精度。CIoU 损失函数在处理大量简单样本时，容易使模型偏向于简单样本的学习，而忽视困难样本。Focaler-CIoU 损失函数根据目标尺度动态调整样本权重，能够有效平衡简单样本和困难样本在模型训练中的作用，为防止模型在训练阶段过度适配简单样本特征，需着重增强其对复杂场景的迁移适应能力。由于小目标的特征不明显，其定位难度较大。Focaler-CIoU 损失函数在 CIoU Loss 的基础上，进一步聚焦小目标的边框回归，考虑了小目标的特殊性，通过优化预测框的定位策略，可更精准地校准其空间位置与尺度参数，进而提升微小目标的空间定位精度。

改进后的 Focaler-CIoU 损失函数，是在传统 CIoU Loss 算法框架上实施优化升级的产物。对于简单样本占主导的检测任务，在边框回归过程聚焦简单样本有助于提升检测效果；但在无人机图像小目标检测中，困难样本占比较高，因此需要聚焦困难样本的边框回归。Focaler-CIoU 引入了一个聚焦因子，根据目标的尺度和检测难度动态调整每个样本的权重。对于小目标（困难样本），增大其在损失计算中的权重，使其在模型训练过程中得到更多的关注；对于大目标（简单样本），适当降低其权重。

设预测框为 B_p ，真实框为 B_g ，CIoU Loss 的计算公式为（4-3）：

$$L_{CIoU} = 1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2} + \alpha v \quad (4-3)$$

在该公式中，IoU 表征交集与并集的比值参数，预测边界框与真实标注框中心点的欧氏距离平方通过 $\rho^2(b, b^{gt})$ 进行量化，同时涵盖两者的最小外接矩形的空间对角线长度用 c 表示， α 作为权重调节因子， v 则用于评估长宽比例的匹配程度。

Focaler-CIoU 损失函数在 L_{CIoU} 的基础上引入聚焦因子 F 如（4-4）所示：

$$L_{Focaler-CIoU} = F \times L_{CIoU} \quad (4-4)$$

聚焦因子 F 根据目标尺度 s 计算如（4-5）所示：

$$F = \begin{cases} \beta, & s < s_{th} \\ 1, & s \geq s_{th} \end{cases} \quad (4-5)$$

其中 s_{th} 是尺度阈值， $\beta > 1$ 是一个超参数，用于增大小目标的权重。

Focaler-CIoU 并非简单组合两个损失函数，而是对 CIoU 损失函数加以改进，引入聚焦因子，在处理不同尺度目标样本，尤其是无人机图像小目标检测这类困难样本占比高的场景时优势显著。传统单个损失函数在目标检测中存在诸多局限。在小目标检测方面，其通常对所有样本平等对待或受大量简单样本主导，易忽略小目标。同时，难以平衡不同尺度样本的学习，模型会倾向于简单样本，对困难样本学习不足。而且传统定位损失函数未针对小目标特殊性优化，在复杂场景下缺乏对小目标的特殊处理机制，导致小目标检测性能不佳。

改进后的 Focaler-CIoU 能根据目标尺度动态调整样本权重，平衡不同尺度样本在训练中的作用，提高模型泛化能力。此外，它在 CIoU 损失基础上进一步优化小目标边框回归，提高小目标定位准确性，还增强了模型在复杂场景下对小目标特征的学习能力，提升检测稳定性。在实际的无人机图像检测中，无论是复杂的城市环境、有云层遮挡还是光影复杂的情况，Focaler-CIoU 都能帮助模型更精准地检测和定位小目标。

4.4 实验结果与实验分析

4.4.1 消融实验

本节主要开展消融实验以深入探究改进后的 RTDETR 模型的性能表现。为保证实验的连贯性和可比性，实验参数与第三章保持一致。特别地，本节所有实验均将原有的 CIoU 损失函数替换为 Focaler-CIoU 损失函数，期望通过这种改进进一步提升模型在目标检测任务中的性能。

本次实验采用 VisDrone2019 数据集作为实验评估基准。该数据集具有场景复杂、目标多样等特点，能为模型的性能评估提供极具挑战性的测试环境。为了准确验证动态

多尺度序列特征融合 DySSFF 模块以及特征聚合方法——全局局部空间注意力机制（GLSA）这两种改进策略给 RTDETR 算法带来的性能提升，我们精心设计了消融实验。

从表 4-1 消融实验数据可以看出各模型的作用。原始 RTDETR 是基准，RA-RTDETR 换用 Focaler-CIoU 损失函数后，精确率从 61.1%升至 62.2%，召回率从 46.6%涨至 47.1%，mAP50%从 47.4%提到 47.9%。因 Focaler-CIoU 采用聚焦机制，加重小目标难样本的权重，优化训练，提升整体检测性能。

DySSFF 动态处理尺度序列特征，在 Focaler-CIoU 基础上，自适应调整不同尺度目标特征融合策略，提升检测精度与召回率。RA-RTDETR 加入 DySSFF 模块，精确率达 62.7%，召回率 47.2%，mAP50%为 48.5%。单独加 GLSA 模块时，精确率 62.6%，召回率降至 46.9%，但 mAP50%大幅提升到 49.2%。GLSA 利用全局局部空间注意力，引导模型关注目标关键区域，复杂场景下准确定位目标，提升多尺度检测准确性。

表 4-1 消融实验结果

Tab.4-1 Results of the ablation experiment					
方法	P/%	R/%	mAP50/%	Param/MB	GFLOPs/G
RTDETR-R18	61.1	46.6	47.4	40.5	58.2
RA-RTDETR (未更改损失函数)	62.2	47.1	47.9	32	36.5
RA-RTDETR (更改损失函数)	62.5	47.3	48.2	32.4	37.3
DySSFF+ RA-RTDETR	62.7	47.2	48.5	32.5	39.7
GLSA+ RA-RTDETR	62.6	46.9	49.2	34.2	40.1
DG-RA-RTDETR	63.4	47.5	49.9	35.2	41.4

整体而言, DG-RA-RTDETR (结合 DySSFF 与 GLSA) 表现最佳。相较于基础版 RTDETR 模型, 其目标识别精确度提升 2.3 个百分点, 目标捕获能力增强 0.9 个百分点, 在 50%交并比阈值下的平均精度指标提升 2.5 个百分点。Focaler-CIoU 优化训练, DySSFF 与 GLSA 协同, 从特征融合和关注层面提升模型在精确性、召回率及多尺度检测等方面的性能, 为复杂场景应用助力。

4.4.2 对比实验

在目标检测领域, 模型性能的提升始终是研究的重点。为了更全面、深入地验证改进后的 DG-RA-RTDETR 模型的性能, 本节专门开展了对比实验。我们将改进后的 DG-RA-RTDETR 模型与十种当前先进的目标检测算法^[13], 包括 SSD、Faster R-CNN、Yolov5m、Yolov5l、Yolov7、Yolov8s、Yolov8m、Yolov8l、Deformable DETR 以及原始的 RTDETR-R18, 一同置于极具挑战性的 VisDrone 2019 无人机图像检测数据集上进行评估。VisDrone 2019 数据集以其场景复杂多变、目标分布高度密集而著称, 这为模型的性能测试提供了一个贴近真实应用的复杂环境, 能够有效检验模型在复杂场景下的泛化能力和检测准确性。

表 4-2 对比实验

Tab.4-2 Results of the comparative experiment

模型	mAP 50/%	mAP 50:95/%	FPS/f	Param/MB	GFLOPs/G
SSD	24.2	10.7	65.3	26.3	62.7
Faster R-CNN	33.2	17.0	15.0	137.1	370.2
Yolo v5m	37.6	19.8	124.0	21.2	49.0
Yolo v5l	40.4	25.3	89.0	46.15	109.1
YoLo v7	46.1	24.0	36.0	37.2	103.3
Yolo v8s	39.2	23.4	120.2	11.2	28.6
Yolo v8m	42.7	26.6	82.4	25.9	78.7
Yolo v8l	48.5	29.7	34	43.7	165.2
Deformable DETR	43.1	27.1	14.0	40	196
RTDETR-R18	47.4	29.5	54.1	40.5	58.2
DG-RA-RTDETR	49.9	30.4	93.57	35.2	41.4

在本次对比实验中, 我们从多个关键性能维度对各个目标检测模型进行了系统、全

面的评估。这些性能维度主要包括 mAP 50%、mAP 50:95%、FPS（每秒帧率）、Param（模型参数量）以及 GFLOPs（每秒浮点运算次数）。通过对这些维度的分析，我们旨在深入剖析不同模型的性能特点，同时突出改进后的 DG-RA-RTDETR 模型相较于其他模型所具备的独特优势，结果如表 4-2 所示。

改进后的 DG-RA-RTDETR 模型依靠优化设计与先进算法，以 49.9%的精度领先。这一优势源于模型采用了动态尺度序列特征融合 DySSFF 模块以及全局局部空间注意力机制 GLSA 模块，二者协同作用，在特征提取阶段，DySSFF 模块能够动态、精准地融合不同尺度下目标的特征信息，为后续的目标定位与识别提供了更丰富、准确的特征表达；GLSA 模块则引导模型关注目标关键区域，强化了对目标特征的捕捉能力，从而在 IoU 阈值为 0.5 时，显著提升了目标定位准确性，超越 Yolo v8l 及 Deformable DETR（43.1%）、Yolo v8m（42.7%）等众多模型。

改进模型在多尺度特征处理上的创新。面对不同 IoU 阈值，模型可依据 DySSFF 模块自适应调整特征融合策略，结合 GLSA 模块对全局和局部特征的精准聚焦，使模型在不同 IoU 条件下均能维持高检测精度，展现出更强的适应性与稳定性。

DG-RA-RTDETR 模型帧率为 93.57FPS。改进模型通过跨阶段 RepCSPNet 优化网络结构，精简计算层级，减少了不必要的计算量；ADown 模块则在不损失过多信息的前提下，提升了计算效率，二者结合，使得模型在保证较高检测精度的同时，拥有良好实时处理能力，超越 Faster R - CNN（15.0 FPS）、Deformable DETR（14.0 FPS）、Yolo v8l（34FPS）等模型，在多数实际应用场景中，该系统也能够达到实时响应的标准要求。

通过模型参数规模（Param）与每秒浮点计算效能（GFLOPs）两项核心指标，可有效量化分析模型架构复杂度及计算资源占用水平。Yolo v8s 轻量化表现佳，参数量 11.2MB，GFLOPs 为 28.6G。DG-RA-RTDETR 模型同样出色，参数量控制在 35.2MB，GFLOPs 降至 41.4G。跨阶段 RepCSPNet 与 ADown 模块协同实现网络结构精简，采用高效计算方式，相比原始 RTDETR-R18（40.5MB，58.2G）及 Faster R-CNN（137.1MB，370.2G）、Yolo v8l（43.7MB，165.2G）等有显著优化，在资源受限设备上也能高效运行。

通过本次对比实验可以看出，改进后的 DG-RA-RTDETR 模型在多个关键性能维度上都表现出色。在检测精度方面，无论是 mAP 50%还是 mAP 50:95%，都超越了众多对比模型；在推理速度方面，能够满足大多数实际应用的实时性需求；在模型轻量化方面，也取得了显著的优化成果。这些优势使得改进后的 DG-RA-RTDETR 模型在目标检测领域具有更高的应用价值和发展潜力。

4.4.3 可视化展示

在目标检测研究中，可视化分析是直观评估模型性能的重要手段。本部分采用 HiResCAM 作为可视化方法，利用经过 300 轮训练的预训练权重对无人机图像进行检测，以对比不同模型的检测效果。

热力图运用色彩的明暗变化，直观展示模型对图像各区域的关注度差异。颜色越深的区域，表明模型在该区域投入的注意力越多，也就意味着模型认为该区域更有可能存在目标。对于目标检测任务而言，检测精度是衡量模型性能的关键指标之一。它直接关系到模型能否准确地识别出图像中的目标物体，以及能否对目标进行精确的定位。因此，通过对比不同模型生成的热力图，我们可以直观地观察到它们在检测精度上的差异。


图 4-4 展示了不同模型检测的热力图对比情况。在图 4-4 (d) 中，红色边界框特别标注出了原始 RTDETR-R18 模型和第三章改进后 RA-RTDETR 模型检测精度较低的区域。这些区域可能由于目标特征不明显、存在遮挡或者处于复杂背景等因素，导致模型难以准确识别目标。而在图 4-4 (b)，4-4 (c) 中，红色框显示了这些精度较低的区域。这一对比结果进一步清晰地表明，改进后的 DG-RA-RTDETR 模型在检测精度方面优于第三章改进后 RA-RTDETR 模型，更显著优于原始 RTDETR-R18 模型。改进后的 DG-RA-RTDETR 模型通过优化网络特征提取结构、采用更有效的多尺度特征融合方法和调整损失函数，增强了对复杂区域目标的识别能力，从而减少了检测精度较低的区域。




(a) 原始图像



(b) 原始 RTDETR-R18 模型检测热力图



(c) 改进 RA-RTDETR 模型检测热力图




(d) 改进 DG-RA-RTDETR 模型检测热力图

图 4-4 不同模型检测热力图对比

Fig.4-4 Comparison of detection heatmaps of different models

此外，图 4-5 呈现了不同模型的具体检测结果。这些具体结果能够让我们更详细地观察不同模型在实际目标检测中的表现。通过对图 4-5 中各个检测框的位置、大小以及与真实目标的匹配程度进行分析，可以进一步验证改进后的 DG-RA-RTDETR 模型在目标定位和分类准确性上的提升。特别地，在检测检测精度数值和漏检上，明显优于原始 RTDETR-R18。例如，图 4-5 (d) 右下角 bicycle 的检测，原始 RTDETR-R18 并未检测，而改进后的 DG-RA-RTDETR 模型和第三章改进的 RA-RTDETR 模型均检出。同时，改进后的 DG-RA-RTDETR 模型在检测精度数值上优于第三章改进的 RA-RTDETR 模型。例如，改进后的模型可能生成的检测框与真实目标的重叠度更高，误检和漏检的情况更少。同时，从具体检测结果中还可以分析出模型在不同类型目标（如不同大小、形状、姿态的目标）上的检测效果差异，为了进一步提升模型的性能，提供有价值的参考依据。

通过热力图对比和具体检测结果展示，充分证明了改进后的 RTDETR 模型在检测精度上的优势。可视化分析不仅为模型性能评估提供了直观的依据，也为后续模型的改进和优化指明了方向。未来的研究可以基于这些可视化结果，深入分析模型的不足之处，针对性地进行改进，以进一步提高模型在无人机图像目标检测任务中的性能。



(a) 原始图像



(b) 原始 RTDETR-R18 模型检测结果图



(c) 改进后 RA-RTDETR 模型检测结果图



(d) 改进后 DG-RA-RTDETR 模型检测结果图

图 4-5 不同模型检测结果图对比

Fig.4-5 Comparison of detection results of different models

4.5 本章总结

本章聚焦于基于动态尺度序列特征融合 DySSFF 和 GLSA 特征聚合对目标检测模型进行优化，以提升其在复杂场景下，尤其是无人机图像小目标检测中的性能。首先对原始特征融合结构进行了深入分析，明确指出其存在的问题。这些问题在处理复杂场景和小目标时会限制模型的性能，为后续的改进提供了方向。提出基于动态尺度序列的 DySSFF 特征融合方法。该方法能够根据目标的尺度动态调整特征融合的方式，有效捕捉不同尺度下目标的特征信息，从而提升模型对不同尺度目标的检测能力。引入 GLSA 特征聚合方法，通过全局和局部空间注意力机制，增强模型对目标特征的关注和提取能力，优化模型对目标关键特征的聚焦能力，从而提升检测的精确度。将 DySSFF 特征融合和 GLSA 特征聚合相结合，构建了改进后 DG-RA-RTDETR 的网络整体结构。基于 CIoU 损失函数，我们提出了改进的 Focaler-CIoU 损失函数。该损失函数引入了聚焦因子，根据目标尺度区分简单样本和困难样本，增大困难样本（小目标）在损失计算中的权重，使模型更加关注小目标的边框回归，从而提高小目标的检测精度。设计了消融实验，验证了 DySSFF 模块和 GLSA 模块对模型性能的提升作用。我们在 VisDrone 2019 数据集上，将改进后的模型与多种前沿目标检测算法进行了对比实验。通过热力图对比和具体检测结果展示，直观地证明了改进后的模型在检测精度上优于原始模型，能够更准确地识别目标。本章通过对特征融合结构和损失函数的改进，以及一系列实验验证，证明了所提出的改进方法能够有效提升目标检测模型在复杂场景下的性能，特别是在无人机图像中的微小物体检测，该方法展现出显著的优越性。未来的研究可以进一步优化这些方法，探索更适合实际应用的模型结构和训练策略。

5. 基于 PyQt5 实现无人机图像检测平台的设计与实现

为了更加全面地评估改进模型的性能,本章将在第4章优化后的整体模型结构及训练得到的模型参数基础上,结合实际应用场景,进行静态图像、视频以及本地摄像头实时检测等多种应用测试。通过这些实际应用测试,将更直观地展示所改进模型在现实环境中的适应性与应用价值,从而更加充分地验证该模型在实际生活中的有效性与可行性。

5.1 平台需求分析

本平台功能设计紧密围绕无人机图像检测流程展开。在检测准备阶段,用户需能便捷选择预训练配置文件,此文件存储着模型运行的核心参数,如模型架构细节、检测目标类别等信息,其准确性直接关乎检测结果的可靠性。同时,平台要提供丰富输入源选项,涵盖单张图片、图片文件夹、视频文件以及摄像头实时图像流。单张图片检测适用于对特定图像的精准分析;文件夹检测便于批量处理大量无人机采集的图像;视频检测可追踪目标在动态场景中的变化;摄像头实时检测则用于即时监控场景。

检测过程中,“开始检测”按钮触发后,平台迅速依据选定配置文件与输入源,调用优化后的检测算法,如融合了多种先进模块的 DG-RA-RTDETR 模型,对图像进行深度分析。“停止检测”按钮则赋予用户随时中断检测的控制权,例如在检测出现异常或无需继续时可及时停止。检测完成后,平台将检测结果以直观形式呈现,在图像上精确标注目标,详细展示目标类别与置信度分数,辅助用户判断检测结果的可靠性。并且,平台提供结果保存功能,用户可自定义保存路径,存储检测结果图像与相关日志信息,日志涵盖从配置文件加载到结果保存全过程的关键信息,便于后续回溯与分析。

基于 PyQt5^[66]构建的用户界面,以操作便捷性为首要设计原则。界面设计清晰明了,各功能模块布局合理。各类功能按钮,如配置文件选择按钮、输入源选择按钮、检测控制按钮等,设计醒目且易于点击,用户无需复杂摸索即可快速上手操作。例如,配置文件选择按钮置于界面顶部显眼位置,点击后弹出文件选择对话框,方便用户定位所需配置文件;输入源选择以下拉菜单或图标形式呈现,直观展示多种输入选项。

在信息展示方面,界面清晰呈现原始输入图像与检测结果图像,两者对比展示便于用户直观查看检测前后变化。标注信息采用醒目的颜色与字体,在图像上突出显示目标类别与置信度分数,确保用户远距离也能清晰识别。检测过程日志信息在专门区域有序罗列,按时间顺序记录配置文件加载路径、图像读取详情、检测耗时、结果保存路径以及检测到的目标统计数量等,以简洁明了的表格或列表形式呈现,用户可随时查阅,全

面掌握检测过程。

5.2 平台总体设计

5.2.1 平台架构设计

基于 PyQt5 的无人机图像检测平台采用分层架构设计,这种设计能够有效提高系统的可维护性和可扩展性。该系统架构由三个主要层级构成:负责与用户交互的界面层、处理业务规则的逻辑层,以及执行数据操作的加工层。用户界面层是用户与平台交互的窗口,负责接收用户的操作指令,并将处理结果展示给用户;业务逻辑层作为中间层,起到协调和调度的作用,将用户界面层的请求转化为具体的数据处理任务,数据处理层的结果将被传输至用户界面层以供展示;数据处理层则专注于核心的图像检测任务,运用先进的检测模型对输入的无人机图像数据进行分析 and 处理。各层之间相互独立又相互协作,通过清晰的接口进行数据传递和交互,确保平台的高效稳定运行。

用户界面层基于 PyQt5 框架构建,以简洁直观、操作便捷为设计原则。其主要目的是为用户提供一个友好的交互环境,使用户能够轻松地完成图像检测的相关操作。在文件与配置选择方面,平台提供文件选择对话框,方便用户选择预训练配置文件,这些配置文件包含了模型运行所需的关键参数,如模型结构、目标类别等。同时,用户可以通过多样化的输入源选择控件,如下拉菜单和按钮,选择单张图片、图片文件夹、视频文件或摄像头作为检测数据的输入源。检测控制部分设置了“开始检测”和“停止检测”按钮,用户点击“开始检测”按钮即可触发业务逻辑层的检测流程,而“停止检测”按钮则可随时中断检测任务。结果展示与保存组件以可视化窗口的形式呈现原始输入图像和检测结果图像,在检测结果图像上清晰标注出检测到的目标类别和置信度分数。此外,用户还可以设置保存路径,将检测结果图像和相关日志信息保存到本地。

业务逻辑层是平台的核心协调部分,负责将用户界面层的操作请求转化为具体的业务流程,并与数据处理层进行数据交互。在配置文件解析环节,该层读取用户选择的预训练配置文件,对其中的参数信息进行详细解析,并将解析后的参数传递给数据处理层的检测模型,确保模型按照正确的参数设置运行。输入源数据加载根据用户选择的输入源类型,采用不同的加载方式。对于图片和视频文件,直接读取其数据;对于图片文件夹,遍历其中的所有图像文件;对于摄像头,则建立实时图像采集连接。加载完成后,将数据传递给检测任务调度模块。检测任务调度模块负责启动和停止检测任务,当接收到用户点击“开始检测”按钮的信号时,调用数据处理层的检测模型对输入数据进行

检测，并实时监控检测进度。若接收到“停止检测”信号，则立即中断检测任务。结果数据整理模块收集数据处理层返回的检测结果数据，包括目标类别、位置坐标、置信度分数等，将其整理成适合在用户界面层展示的格式，并与原始输入图像进行关联。同时，生成详细的检测日志信息，如检测时间、使用的配置文件、输入源信息以及检测到的目标统计等，最后将整理好的数据传递给用户界面层进行展示和保存。

数据处理层是平台进行图像检测的核心部分，采用了经过优化改进的 DG-RA-RTDETR 模型。该模型融合了跨阶段 RepCSPNet、ADown 模块、DySSFF 模块以及 GLSA 模块等先进技术，能够在复杂的无人机图像场景中准确检测各类目标，该方法的检测精度和实时性较高。在检测开始前，需要对输入的图像数据进行预处理。首先进行图像尺寸调整，将图像统一缩放至模型输入要求的尺寸，以保证数据的一致性；然后进行归一化处理，将图像像素值归一化到特定范围，提高模型的训练和检测效果；最后根据模型要求进行通道转换，确保图像数据符合模型的输入格式。检测完成后，对模型输出的结果进行后处理。采用非极大值抑制（NMS）技术剔除冗余的检测框，从而仅保留置信度最高的目标检测结果；进行目标类别映射，将模型输出的类别索引转换为实际的目标类别名称；根据实际应用需求对置信度分数进行阈值过滤或校准，提高检测结果的可靠性。

平台各层之间通过特定的交互机制实现数据传递和任务协作。用户界面层与业务逻辑层之间采用信号与槽机制进行交互。当用户在界面上进行操作，如点击“开始检测”按钮时，会发出一个特定的信号，业务逻辑层中的相应模块接收到该信号后，会触发相应的业务流程。业务逻辑层与数据处理层之间通过函数调用的方式进行交互。业务逻辑层将解析后的配置文件参数和加载的输入数据传递给数据处理层的检测模型，调用模型的检测函数进行图像检测。数据处理层完成检测后，将结果返回给业务逻辑层。业务逻辑层对结果进行整理和处理后，再将其传递给用户界面层进行展示和保存。这种交互机制使得各层之间的职责明确，数据传递清晰，保证了平台的高效运行和功能的正常实现。

5.2.2 平台流程设计

图 5-1 展示了基于改进后 DG-RA-RTDETR 模型，运用 PyQt5 技术实现的无人机图像检测平台的操作流程。在使用该平台时，首先需要选择配置文件。配置文件对模型的运行至关重要，它包含了模型运行所需的各种参数和设置。选择配置文件后，系统会对其进行加载，并判断是否加载成功。如果配置文件加载成功，流程继续；若加载失败，系统会提示加载失败信息，并要求重新选择配置文件。




图 5-1 基于 PyQt5 技术实现无人机图像检测平台操作流程

Fig.5-1 Flowchart of the operation of the drone image detection platform based on PyQt5 technology

成功加载配置文件后，下一步是选择输入源，可选的输入源包括图片、文件夹、视频或者摄像头。这种多样化的输入源设置，使平台能够适应不同的检测需求，既可以对已有的静态图片、视频进行检测，也能够通过摄像头实现实时检测。确定输入源后，点击开始检测按钮，改进后的 DG-RA-RTDETR 模型便会对输入内容进行目标检测。该模型基于 PyQt5 技术集成到平台中，凭借优化的网络特征提取结构、高效的多尺度特征融合方法以及调整后的损失函数，能够更精准地识别无人机图像中的目标。

模型完成目标检测后，会生成检测结果。此时，用户需要设置保存路径，用于存储检测结果图片以及相关的统计信息，例如检测到的目标数量、类别等。完成保存操作后，整个检测流程结束。通过这样一套完整且清晰的流程，基于 PyQt5 技术实现的无人机图像检测平台，结合改进后的 DG-RA-RTDETR 模型，为用户提供了一个方便、高效的无人机图像目标检测工具。

5.3 平台功能模块与实现

5.3.1 平台功能模块

基于 PyQt5 技术开发的无人机图像检测系统，涵盖了以下几个关键功能模块：

- (1) 平台显示界面模块



图 5-2 平台显示界面模块

Fig.5-2 Platform display interface module

图 5-2 展示的 DG-RA-RTDETR-VisDrone 系统平台显示界面，界面上方排列着一系列按钮，充当用户与系统交互的主要入口。“选择配置文件”按钮用于选取模型运行所需的配置文件，这是系统准确运行的基础；“打开图片”“打开文件夹”“打开视频”“打开摄像头”按钮，分别对应不同的输入源选择，支持 JPG、PNG 格式的图片，MP4 和 AVI 格式的视频，以及摄像头实时画面输入，极大地拓展了检测的适用场景；“开始检测”和“停止检测”按钮用于控制检测流程的启动与暂停；“设置保存路径”按钮方便用户指定检测结果的存储位置；“退出”按钮则用于结束系统操作。此外，还有一个下拉菜单选项，当前显示为 “NoTrack”，其具体功能与检测跟踪模式相关。

在界面右侧预留了较大的空白区域，该区域用于显示检测结果、相关统计信息以及模型运行的反馈内容等，尽管当前为空白状态，但在实际检测过程中，它将发挥重要的信息展示作用，为用户提供直观的检测结果呈现，类似于检测框模块在其他系统中展示检测结果和分类的功能。用户通过点击上述相应按钮，根据自身需求选择合适的输入源和操作指令，即可借助改进后的 DG-RA-RTDETR 模型，完成对无人机图像或视频的目标检测任务。整个界面设计简洁明了，各模块功能明确，便于用户快速上手操作。

(2) 选择配置文件模块




图 5-3 选择配置文件模块

Fig.5-3 Configuration file selection module

在 DG-RA-RTDETR-VisDrone 系统平台中，“选择配置文件”是关键操作步骤之一。如图 5-3 所示，用户点击界面左上角标注为“选择配置文件”的按钮后，会弹出一个文件浏览窗口，该窗口呈现出类似资源管理器的界面，用户可以在其中浏览计算机中的文件目录。在该窗口中，列出了不同的文件夹和文件，其中包括多个以.yaml 为后缀的源文件，例如 rtdestr.yaml、yolov5s.yaml 等。这些配置文件对于模型的运行至关重要，它们包含了模型运行所需的参数和设置信息。用户可根据实际需求，在文件浏览窗口中选择合适的配置文件，然后点击“打开”按钮。所选配置文件的相关信息会被传递给系统后台，用于后续 DG-RA-RTDETR 模型的初始化和运行配置，以确保模型能够按照设定的参数准确地对无人机图像或视频进行目标检测。整个操作流程清晰直观，方便用户进行配置文件的选取与设置。

(3) 打开功能模块

图 5-4 包含四个关键的打开功能模块，为用户提供了多样化的检测输入选择。“打开图片”按钮，允许用户导入特定格式的静态图像用于目标检测。系统支持常见的 JPG 和 PNG 格式图片，用户点击该按钮后，会弹出文件选择窗口，从中选取所需图片，即可将其输入到改进后的 DG-RA-RTDETR 模型中进行分析。



图 5-4 打开功能模块

Fig.5-4 Open function module

“打开文件夹”按钮则适用于批量检测场景。当用户需要对一个文件夹内的多张图片进行检测时，点击此按钮，在弹出的文件夹选择窗口中选定目标文件夹，系统会自动遍历该文件夹内符合格式要求的图片，并依次进行检测，提高了检测效率，减少了重复操作。

“打开视频”按钮专为处理视频文件检测而设。系统兼容 MP4 和 AVI 两种主流视频格式，用户点击后选择对应的视频文件，系统会对视频进行逐帧分析。通过对每一帧画面中的目标进行检测和跟踪，实现对视频内容的全面目标检测，为用户提供视频中目标的动态信息。

“打开摄像头”按钮为实时检测功能的入口。点击该按钮后，系统会调用计算机连接的摄像头设备，获取实时视频流，并将其作为输入源，利用 DG-RA-RTDETR 模型实时检测摄像头视野内的目标。这种实时检测功能在诸如安防监控、现场巡检等场景中具有重要应用价值，可及时发现异常目标并做出响应。

这四个打开功能模块相互配合，满足了用户在不同场景下的检测需求，使系统具有较高的灵活性和实用性。

（4）开始检测功能模块

图 5-5 以图片检测为例，用户的操作流程和结果呈现如下：




图 5-5 开始检测功能模块

Fig.5-5 Start Detection Function Module

首先，用户通过点击“选择配置文件”按钮，选取合适的配置文件，为检测任务设定基础参数。接着点击“打开图片”按钮，在弹出的文件选择窗口中挑选需要检测的图片，将其导入系统。准备工作完成后，点击“开始检测”按钮，系统即调用改进后的 DG-RA-RTDETR 模型对所选图片进行目标检测。模型基于先进的特征提取和目标识别算法，对图片中的各类目标进行分析和定位。

检测完成后，系统会在界面中输出检测结果。如图所示，左侧区域会显示两张图片，左边是原始输入图片，右边则是带有检测标识的结果图片。在结果图片中，不同类别的目标被不同颜色的框标注出来，并且每个框旁都标有目标类别及对应的置信度分数，如“car 0.93”表明检测到的汽车目标，其置信度为 0.93。

与此同时，界面右侧专门的区域会输出详细的日志信息。这些日志信息包括配置文件的加载路径及状态、图片的读取路径、检测耗时、检测结果图片的保存路径以及各类目标的统计数量。这些信息为用户全面了解检测过程和结果提供了丰富的数据支持，有助于用户评估模型的检测效果和性能表现。若在检测过程中用户想要停止操作，点击“停止检测”按钮即可。此外，用户还可通过“设置保存路径”按钮自定义检测结果图片及相关信息的存储位置，方便后续查看和管理。

5.3.2 交通管理场景的应用与实现

在完成无人机图像检测平台的设计与实现后,为充分验证其在实际场景中的有效性与可靠性,本节结合多领域应用案例展开详细分析,评估平台性能。在基于 PyQt5 实现的 DG-RA-RTDETR-VisDrone 系统平台中,图 5-6 所示视频检测功能,是交通管理场景中重要组成部分。



图 5-6 交通管理场景下检测平台结果展示

Fig.5-6 Result display of the detection platform in the traffic management scenario

在城市交通管理实际应用中,将平台部署于交通巡逻无人机,对城市主干道及交叉路口进行监测。在早晚高峰时段,面对密集的车流与人流,平台需同时处理大量动态目标。若要进行视频检测,首先需在系统界面上方点击“选择配置文件”按钮,从本地计算机中选取适合视频检测任务的配置文件,该配置文件包含了模型运行所需的各类参数,对检测准确性和效率至关重要。随后点击“打开视频”按钮,在弹出的文件选择窗口中,用户可选择符合系统要求的 MP4 或 AVI 格式视频文件导入系统。准备工作就绪后,点击“开始检测”按钮,系统即启动改进后的 DG-RA-RTDETR 模型,对视频逐帧进行目标检测。若在检测过程中,用户希望停止操作,可点击“停止检测”按钮。检测完成后,用户还能通过“设置保存路径”按钮,指定检测结果的存储位置,方便后续查看和分析。

在系统界面中,检测结果的展示清晰直观。界面左侧区域会同时显示原始视频帧图像以及带有检测标识的结果帧图像。在结果帧图像上,不同类别的目标被不同颜色的矩形框精准标注,并且每个框旁都明确标有目标类别及对应的置信度分数。例如,“car 0.90”

表示检测到的汽车目标，其置信度为 0.90，反映了模型对该目标检测结果的可靠程度。

此外，平台的可视化界面可直观呈现交通流量分布与违规事件位置，协助交警部门更高效地进行交通疏导与执法工作，用户对平台的稳定性和检测准确性给予高度评价。

界面右侧则输出详细的日志信息，为用户深入了解检测过程和结果提供丰富的数据支持。日志信息包含各类目标的统计数量，清晰地展示了视频中各目标的出现频次。同时，还记录了当前处理的帧数与总帧数，方便用户了解检测进度。另外，每帧检测所耗费的时间以及帧率等信息也会呈现，这些数据有助于用户评估模型的检测效率和性能表现。

通过该系统平台的视频检测功能，基于 PyQt5 良好的界面交互性和 DG-RA-RTDETR 模型强大的目标检测能力，能够高效、准确地对无人机拍摄的视频进行分析处理，为诸如交通监控、安防巡逻等实际应用场景提供有力的支持。

6. 总结与展望

6.1 本文总结

本文聚焦于基于改进 RT-DETR 的小目标检测方法研究，核心目标是通过引入 Transformer 架构来优化深度学习神经网络，着重提升小目标检测的精度和鲁棒性。研究过程综合考虑了无人机硬件资源有限的实际情况，以及现有目标检测算法在小目标和多尺度特征处理上的不足，从特征提取、特征融合和平台实现等多个方面展开深入探索。在目标检测领域，随着无人机应用场景的不断拓展，对无人机航拍图像中的小目标进行准确检测变得愈发重要。然而，现有的目标检测技术在处理无人机图像时面临诸多挑战，如计算复杂度高、小目标特征提取困难、多尺度特征融合不足等问题。因此，本文的研究对于提升无人机图像小目标检测的性能具有重要的现实意义，本文主要贡献如下：

（1）特征提取结构优化。针对原始 RTDETR 检测算法在无人机应用中计算复杂度高、浮点运算量大和模型延迟高的问题，提出了轻量化的跨阶段并行特征提取网络（RepCSPNet 块），有效减少了计算复杂度，增强了模型在无人机图像中提取小目标特征的能力。引入 ADown（Adaptive Downsampling）模块，与 RepCSPNet 块相结合，构建联合特征提取网络。ADown 模块通过自适应机制动态选择下采样方式，解决了传统下采样方法导致的小目标细节信息丢失问题，提高了小目标特征提取的准确性。

（2）多尺度特征融合与聚合改进，损失函数优化与实验验证分析。针对原始 RTDETR 的 CCFM 模块在多尺度特征融合方面忽视尺度序列信息的问题，提出了动态尺度序列特征融合模块 DySSFF。该模块能够动态处理尺度序列特征，实现更高效的多尺度特征融合。在编码器部分引入 GLSA 特征聚合模块，引导模型聚焦图像关键区域，减少背景噪声干扰，增强模型的鲁棒性，进一步提高了小目标和高密度目标的检测性能。为了提高目标检测的准确性，对损失函数进行了改进。基于 Focaler-CIoU 改进 CIoU 损失函数，增强了模型对目标定位的准确性。使用 VisDrone2019 数据集进行实验，通过精确率、召回率、平均精度均值（mAP）和模型参数量等指标对模型性能进行评估。消融实验和对比实验结果表明，改进后的模型在小目标检测和多尺度目标检测方面均有显著提升。可视化展示（如热力图、检测结果图等）直观地显示了改进后模型在目标定位和分类准确性上的优势，验证了改进策略的有效性。

（3）检测平台的实现。基于 PyQt5 技术实现了无人机图像检测平台，该平台具有友好的用户界面和丰富的功能。用户可以方便地选择配置文件、输入源（图片、视频、文件夹、摄像头），进行目标检测，并查看检测结果和详细的日志信息。平台的实现为

改进后的模型在实际应用中的部署提供了便利。

本文通过对 RTDETR 模型在特征提取、特征融合、损失函数等方面的改进，显著提升了无人机图像小目标检测的精度和鲁棒性。同时，基于 PyQt5 实现的检测平台为模型的实际应用提供了一个可操作的工具。未来的研究可以进一步探索更高效特征提取和融合方法，以及在更多实际场景中验证模型的性能，推动目标检测技术在无人机领域的发展。

6.2 展望

本文在基于改进 RT-DRTR 的小目标检测方法研究上取得了一定的成果，显著提升了无人机图像小目标检测的精度和鲁棒性，并开发了基于 PyQt5 的检测平台。然而，目标检测领域发展迅速，仍有诸多方向值得深入探索和拓展，以下是对未来研究的展望：

（1）模型性能优化。尽管本文提出的 RepCSPNet 块、ADown 模块、DySSFF 模块和 GLSA 特征聚合模块在特征提取和融合方面取得了良好效果，但未来可进一步探索更高效特征处理方式。例如，研究新型的卷积结构或注意力机制，以增强模型对小目标特征的捕捉能力，同时减少计算量和模型参数量，提高模型在资源受限设备上的运行效率。当前模型在不同场景下的适应性仍有提升空间。未来可以研究自适应模型调整策略，使模型能够根据输入图像的特点（如分辨率、光照条件、目标密度等）自动调整自身的参数和结构，以实现更优的检测性能。

（2）多模态融合检测。目前的研究主要集中在视觉图像上，未来可以考虑引入其他模态的信息，如红外、激光雷达等，实现多模态融合检测。不同模态的信息具有互补性，融合后可以提供更丰富的目标特征，从而提高目标检测的准确性和鲁棒性，特别是在复杂环境下的小目标检测。探索有效的多模态融合方法是关键。需要研究如何将不同模态的数据进行合理的融合，以充分发挥各模态的优势。例如，可以采用深度学习架构将不同模态的特征进行融合，或者研究基于决策级的融合方法，提高模型的综合判断能力。

（3）实际应用拓展。虽然本文的研究主要针对无人机图像小目标检测，但可以将改进后的模型和检测平台应用到更多实际场景中，如智能交通、安防监控、农业监测等。在不同的应用场景中验证模型的性能，发现并解决实际问题，进一步完善模型和平台。在实际应用中，对目标检测的实时性和可靠性要求较高。未来需要进一步优化模型和算法，提高检测的实时性，确保在短时间内输出准确的检测结果。同时，研究有效的容错机制和误差校正方法，提高模型的可靠性，以满足实际应用的需求。

总之，目标检测领域充满了机遇和挑战。未来的研究将围绕模型性能优化、多模态

融合检测、实际应用拓展和平台功能扩展等方面展开，不断推动目标检测技术的发展，为更多领域的应用提供支持。

参考文献

- [1] Deng L ,Zhang C ,Mao W , et al.UAV-assisted bridge alignment measurement using enhanced small target detection and adaptive ellipse fitting[J].Automation in Construction,2025,176106258-106258.
- [2] 张兵,柳钦火,李晓明,等.遥感科学的内涵与基础性问题[J].遥感学报,2025,29(01):1-48.
- [3] 王林,刘景亮,王无为.基于空洞卷积融合 Transformer 的无人机图像小目标检测方法[J].计算机应用, 2024, 44(11):3595-3602.
- [4] 罗俊海, 杨阳. 基于数据融合的目标检测方法综述[J]. 控制与决策, 2020, 35(1): 1-15.
- [5] Imani M .Attention based multi-level and multi-scale convolutional network for PolSAR image classification[J].Advances in Space Research,2025,75(11):7971-7986.
- [6] Yang B ,Wei Y ,Shi J , et al.Diagnosis of array antennas based on near-field data using Faster R-CNN[J].Materials & Design,2025,254114033-114033.
- [7] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
- [8] Del Signore A, Hendriks A J, Lenders H J R, et al. Development and application of the SSD approach in scientific case studies for ecological risk assessment[J]. Environmental Toxicology and Chemistry, 2016, 35(9): 2149-2161.
- [9] Peng S .Multi-object extraction technology for complex background based on faster regions-CNN algorithm in the context of artificial intelligence[J].Service Oriented Computing and Applications,2024,19(1):1-13.
- [10] Vijayakumar A , Vairavasundaram S .YOLO-based Object Detection Models: A Review and its Applications[J].Multimedia Tools and Applications, 2024, 83(35):83535-83574.
- [11] Wei W ,Yu C ,Jiafeng H , et al.A review of small object detection based on deep learning[J].Neural Computing and Applications,2024,36(12):6283-6303.
- [12] Kumar N ,Singh P .Small and dim target detection in infrared imagery: A review, current techniques and future directions[J].Neurocomputing,2025,630129640-129640.
- [13] 胡佳乐,周敏,申飞. 面向无人机小目标的 RTDETR 改进检测算法[J]. 计算机工程与应用,2024,60(20):198-206.

- [14] Feng H , Li Q , Wang W ,et al.Security of target recognition for UAV forestry remote sensing based on multi-source data fusion transformer framework[J].Information Fusion, 2024, 112(000):14.
- [15] 吴斌斌, 张礼华, 刘军伟, 等. 基于改进的 EP-RTDETR 小目标 PCB 表面缺陷检测[J]. 制造技术与机床, 2025 (3): 139-148.
- [16] Lin M , Wu G , Liu K ,et al.Review of Detection Methods for Typical Faults in Transformer Bushings*[J].Electrical Insulation Magazine, IEEE, 2024, 40(2):12.
- [17] Deng Y , Deng D .Research on Vehicle Detection Algorithm Based on Embedded ARM[J].Applied Mathematics and Nonlinear Sciences, 2024, 9(1).
- [18] Alsahwa B , Maussang F , Garelo R ,et al.Marine life airborne observation using HOG and SVM classifier[C]//Oceans.IEEE, 2016:1-5.
- [19] Hefenbrock D, Oberg J, Thanh N T N, et al. Accelerating Viola-Jones face detection to FPGA-level using GPUs[C]//2010 18th IEEE Annual International Symposium on Field-Programmable Custom Computing Machines. IEEE, 2010: 11-18.
- [20] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE transactions on pattern analysis and machine intelligence, 2016, 39(6): 1137-1149.
- [21] Bharati P, Pramanik A. Deep learning techniques—R-CNN to mask R-CNN: a survey[J]. Computational Intelligence in Pattern Recognition: Proceedings of CIPR 2019, 2020: 657-668.
- [22] Girshick R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
- [23] Tian J, Wang C, Cao J, et al. Fully convolutional network-based fast uav detection in pulse doppler radar[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-12.
- [24] Parnami A, Singh R, Joshi T. Pruning attention heads of transformer models using a* search: A novel approach to compress big nlp architectures[J]. arXiv preprint arXiv:2110.15225, 2021.
- [25] Liu C, Cong S. DETR with hybrid attention encoder for object detection[C]//2024 4th International Conference on Electronic Information Engineering and Computer (EIECT). IEEE, 2024: 356-360.

- [26] 江志鹏,王自全,张永生,等. 基于改进 Deformable DETR 的无人机视频流车辆目标检测算法[J]. 计算机工程与科学,2024,46(1):91-101.
- [27] Nicolini M ,Saitto E ,Franco J E R , et al.Fine-tuning of conditional Transformers improves in silico enzyme prediction and generation.[J].Computational and structural biotechnology journal,2025,271318-1334.
- [28] Jongwon K ,Jeongho C .RGDiNet: Efficient Onboard Object Detection with Faster R-CNN for Air-to-Ground Surveillance[J].Sensors,2021,21(5):1677-1677.
- [29] Wu S ,Lu X ,Guo C .YOLOv5mamba: unmanned aerial vehicle object detection based on bidirectional dense feedback network and adaptive gate feature fusion[J].Scientific Reports,2024,14(1):22396-22396.
- [30] 王国刚,李泽欣,董志豪. 基于注意力机制和多空间金字塔池化的实时目标检测算法[J]. 计算机测量与控制,2024,32(2):56-64.
- [31] Li Y, Zheng P, Yu M, et al. Small-modulus worms surface defect detection method based on YOLOv7[J]. Measurement Science and Technology, 2024, 35(5): 055005.
- [32] 薛珊, 安宏宇, 吕琼莹, 等. 复杂背景下基于 YOLOv7-tiny 的图像目标检测算法[J]. Infrared and Laser Engineering, 2024, 53(1): 20230472-20230472.
- [33] 张瑞芳, 杜伊婷, 程小辉. 无人机视角下小目标检测算法[J]. Laser & Optoelectronics Progress, 2025, 62(4): 0437002-0437002-9.
- [34] Feng C, Wang C, Zhang D, et al. Enhancing Dense Small Object Detection in UAV Images Based on Hybrid Transformer[J]. Computers, Materials & Continua, 2024, 78(3).
- [35] 肖振久, 赵昊泽, 张莉莉, 等. 基于自适应聚焦 CRIoU 损失的目标检测算法[J]. Chinese Journal of Liquid Crystals and Displays, 2023, 38(11): 1468-1480.
- [36] Tan S, Duan Z, Pu L. Multi-scale object detection in UAV images based on adaptive feature fusion[J]. Plos one, 2024, 19(3): e0300120.
- [37] Fu X, Wei G, Yuan X, et al. Efficient YOLOv7-drone: an enhanced object detection approach for drone aerial imagery[J]. Drones, 2023, 7(10): 616.
- [38] Wang J, Zhang F, Zhang Y, et al. Lightweight object detection algorithm for uav aerial imagery[J]. Sensors, 2023, 23(13): 5786.
- [39] 姜贤翔,司占军,王晓喆. 改进 RT-DETR 的无人机图像目标检测算法[J]. 计算机工程与应用,2025,61(1):98-108.

- [40] 徐维真,李锐,胡伟,等. 基于卷积神经网络的渤海海浪波高场预报模型构建与训练方法研究[J]. 海洋通报,2025,44(1):1-14.
- [41] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [42] Shanthi T, Sabeenian R S. Modified Alexnet architecture for classification of diabetic retinopathy images[J]. Computers & Electrical Engineering, 2019, 76: 56-64.
- [43] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]//2009 IEEE conference on computer vision and pattern recognition. Ieee, 2009: 248-255.
- [44] Daubechies I, DeVore R, Foucart S, et al. Nonlinear approximation and (deep) ReLU networks[J]. Constructive Approximation, 2022, 55(1): 127-172.
- [45] Zhang X. The AlexNet, LeNet-5 and VGG NET applied to CIFAR-10[C]//2021 2nd International Conference on Big Data & Artificial Intelligence & Software Engineering (ICBASE). IEEE, 2021: 414-419.
- [46] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [47] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
- [48] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.
- [49] Pinaya W H L, Vieira S, Garcia-Dias R, et al. Convolutional neural networks[M]//Machine learning. Academic Press, 2020: 173-191.
- [50] 刘万军, 梁雪剑, 曲海成. 不同池化模型的卷积神经网络学习性能研究[J]. 中国图象图形学报, 2016, 21(9): 1178-1190.
- [51] Nakahara H, Fujii T, Sato S. A fully connected layer elimination for a binarized convolutional neural network on an FPGA[C]//2017 27th international conference on field programmable logic and applications (FPL). IEEE, 2017: 1-4.
- [52] 赵永强, 饶元, 董世鹏, 等. 深度学习目标检测方法综述[J]. 中国图象图形学报, 2020, 25(4): 629-654.

- [53] 黄景涛, 马龙华, 钱积新. 一种用于多分类问题的改进支持向量机[J]. 浙江大学学报: 工学版, 2004, 38(12): 1633-1636.
- [54] Qin Y, He S, Zhao Y, et al. RoI pooling based fast multi-domain convolutional neural networks for visual tracking[C]//2016 2nd International conference on artificial intelligence and industrial engineering (AIIE 2016). Atlantis Press, 2016: 198-202.
- [55] 李科岑, 王晓强, 林浩, 等. 深度学习中的单阶段小目标检测方法综述[J]. 计算机科学与探索, 2022, 16(1): 41-58.
- [56] BADGUJAR C.M., POULOSE A., GAN H.. Agricultural object detection with You Only Look Once (YOLO) Algorithm: A bibliometric and systematic literature review[J]. Computers and Electronics in Agriculture, 2024, 2231-18.
- [57] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [58] Yang J. Piezoelectric transformer structural modeling-A review[J]. IEEE transactions on ultrasonics, ferroelectrics, and frequency control, 2007, 54(6): 1154-1170.
- [59] Dufter P, Schmitt M, Schütze H. Position information in transformers: An overview[J]. Computational Linguistics, 2022, 48(3): 733-763.
- [60] 柳毅, 佟明安. 匈牙利算法在多目标分配中的应用[J]. 火力与指挥控制, 2002, 27(4): 34-37.
- [61] Roh B, Shin J W, Shin W, et al. Sparse detr: Efficient end-to-end object detection with learnable sparsity[J]. arXiv preprint arXiv:2111.14330, 2021.
- [62] Park S, Yeo Y J, Shin Y G. PConv: simple yet effective convolutional layer for generative adversarial network[J]. Neural Computing and Applications, 2022, 34(9): 7113-7124.
- [63] Ju C, Guan C. Tensor-cspnet: A novel geometric deep learning framework for motor imagery classification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 34(12): 10955-10969.
- [64] DAWEI DU, PENGFEI ZHU, LONGYIN WEN, et al. VisDrone-DET2019: The Vision Meets Drone Object Detection in Image Challenge Results[C]//2019 IEEE/CVF International Conference on Computer Vision Workshop: ICCVW 2019, Seoul, South Korea, 27-28 October 2019, [v.1].:Institute of Electrical and Electronics Engineers, 2019:213-226.

- [65] Draelos R L, Carin L. Use HiResCAM instead of Grad-CAM for faithful explanations of convolutional neural networks[J]. arXiv preprint arXiv:2011.08891, 2020.
- [66] YUNKAI YANG, QIJIA YANG, WEIFENG LIU, et al. Design of integrated interactive system for pre-diagnosis of breast cancer pathological images based on CNN and PyQt5[J]. Multimedia systems,2024,30(2):95.1-95.14.

学位论文数据集表

关键词*	无人机图像；小目标检测；实时检测 Transformer；尺度序列特征融合
密级*	公开
中图分类号*	TP391
UDC	004.9
论文资助	
学位授予单位名称*	广东技术师范大学
学位授予单位代码*	10588
学位类别*	电子信息
学位级别*	硕士
论文题名*	基于改进小目标实时检测 Transformer 的研究与应用
并列题名	
论文语种*	中文
作者姓名*	王苏皖
学号*	2112203033
培养单位名称*	广东技术师范大学
培养单位代码*	10588
培养单位地址	广东省广州市天河区中山大道西 293 号
邮编	510630
学科专业*	计算机技术
研究方向*	计算机视觉目标检测
学制*	3 年
学位授予年*	2025 年
论文提交日期*	2025 年 6 月 21 日
导师姓名*	肖政宏
导师职称*	教授
评阅人	匿名评阅
答辩委员会主席*	周继鹏教授
答辩委员会成员	黄根华，张越，魏纵横
电子版论文提交格式	文本（√） 图像（） 视频（） 音频（） 多媒体（） 其他（） 推荐格式：word/pdf
论文总页数*	83

注：“*”为必填数据，为 22 项。