



玉米科学
Journal of Maize Sciences
ISSN 1005-0906, CN 22-1201/S

《玉米科学》网络首发论文

题目：基于改进的 RT-DETR 玉米叶片病害轻量化检测方法
作者：肖春霖，范永胜，桑彬彬
网络首发日期：2025-11-05
引用格式：肖春霖，范永胜，桑彬彬. 基于改进的 RT-DETR 玉米叶片病害轻量化检测方法[J/OL]. 玉米科学. <https://link.cnki.net/urlid/22.1201.S.20251105.1537.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于改进的 RT-DETR 玉米叶片病害轻量化检测方法

肖春霖¹, 范永胜¹, 桑彬彬²

(1.重庆师范大学计算机与信息科学学院, 重庆 401331; 2.重庆师范大学国家应用数学中心, 重庆 401331)

摘要: 针对玉米叶片病害表现多样, 且受光线、拍摄角度、遮挡等场景干扰易导致漏检误检, 同时为降低对移动端与嵌入式设备的算力需求, 本研究基于 RT-DETR 提出一种轻量化玉米叶片病害识别方法。其实现过程: 首先, 设计了新的主干网络 FasterRepNCSPNet, 该网络通过优化特征提取结构来提升多尺度病害表征精度, 降低计算成本并增强模型鲁棒性, 减少误判漏检的风险; 其次, 将跨尺度特征融合的 RepC3 模块替换为 RepNCSPELAN4-FB 模块, 强化多分辨率特征交互能力, 优化不同尺寸玉米叶片病斑的检测效果; 然后, 引入 Focaler - MPDIoU 回归损失函数, 改善检测边框回归效果, 从而提升推理结果的精准度; 最后, 采用层自适应稀疏化剪枝策略压缩模型规模, 在不损失精度的同时进一步压缩模型的大小。实验结果表明, 与原 RT-DETR-R18 模型相比, 新方法的准确率、召回率和平均精度均值分别提升 4.4、3.8、3.2 个百分点, 参数量、计算量、模型大小分别下降 61.53%、65.91%、60.5%, 实现了检测精度的提升与模型的轻量化目标, 具备较强的实际应用价值。

关键词: 玉米叶片病害; 目标检测; RT-DETR; 模型剪枝; 轻量化

中图分类号: S435.131; TP391.41 文献标志码: A

A Lightweight Detection Method for Corn Leaf Diseases Based on Improved RT-DETR

XIAO Chun-lin¹, FAN Yong-sheng¹, SANG Bin-bin²

(1.School of Computer and Information Science, Chongqing Normal University, Chongqing 401331, China;

2. National Center for Applied Mathematics, Chongqing Normal University, Chongqing 401331, China)

Abstract: Aiming at the diversity of corn leaf disease manifestations, which are affected by scene interferences such as light, occlusion, and fracture, resulting in missed detections and false detections. Meanwhile, considering the requirement for lightweight deployment of models in agricultural production detection equipment, this study proposes a lightweight corn leaf disease recognition method based on RT - DETR. The implementation process is as follows: First, a new backbone network, FasterRepNCSPNet, is designed. This network improves the representation accuracy of multi - scale diseases by optimizing the feature extraction structure, reduces the computational cost, and enhances the model's robustness, thereby reducing the risk of misjudgment and missed detection. Second, the RepC3 module for cross - scale feature fusion is replaced with the RepNCSPELAN4 - FB module to strengthen the multi - resolution feature interaction ability and optimize the detection effect of corn leaf disease spots of different sizes. Then, the Focaler - MPDIoU regression loss function is introduced to improve the regression effect of the detection bounding box, thus enhancing the accuracy of the inference results. Finally, a layer - adaptive sparsification pruning strategy is adopted to compress the model scale, further reducing the model size without losing accuracy. The experimental results show that, compared with the original RT - DETR - R18 model, the accuracy, recall rate, and mean average precision (mAP) of the new method are increased by 4.4, 3.8, and 3.2 percentage points, respectively. Meanwhile, the number of parameters, computational load, and model size are reduced by 61.53%, 65.91%, and 60.5%, respectively. It achieves the goals of improving detection accuracy and lightweighting the model and has strong practical application value.

Keywords: Corn Leaf Diseases; Object Detection; RT - DETR; Model Pruning; Lightweight

玉米是我国主要的粮食作物, 其种植面积和产量长期稳居三大谷物之首。玉米生产在保障国家粮食安全、推动畜牧业发展, 以及拓展工业应用等方面, 具有极为关键

的战略价值^[1]。然而, 在玉米种植和生长过程中, 叶片极易遭受多种病害侵袭, 这些侵袭给玉米的产量和质量都带来了严重的影响^[2]。其南方锈病、灰斑病和大斑病是玉米生长中最为常见的三种叶片病害^[3], 极大地威胁着玉米的健康生长。因此, 及时发现并有效防治这些病害

基金项目: 国家自然科学基金项目 (62306054); 重庆市自然科学基金面上项目 (CSTB2023NSCQ-MSX1010); 重庆市教委科学技术研究项目 (KJZD-K202400507)

作者简介: 肖春霖 (1998-), 长期聚焦计算机视觉、深度学习领域研究, 致力于探索人工智能技术在农业工程场景中的融合应用, 旨在以智能技术赋能农业生产升级。Email: 1392090773@qq.com

范永胜为本文通信作者。

迫在眉睫。目前，玉米叶片病害识别仍然主要依靠人工观察，因此存在主观性强、工作量大等问题，容易导致误判与漏判，致使错过最佳防治时机。所以，怎样实现玉米叶片病害快速、准确识别的研究具有重要的意义^[4]。

近年来，随着计算机视觉技术和深度学习的蓬勃发展，传统农业正向智能化转型^[5]。这为玉米集中培育提供了方向，而基于计算机视觉的病害监测在精准农业中具有重要意义^[6]。以 YOLO 系列模型为代表的 One-stage 目标检测技术因其单阶段检测特点，具有高效性和准确性，广泛应用于玉米叶片病害识别领域。众多学者基于 YOLO 系列模型提出改进方案，旨在提升检测精度与效率。具体如下：徐会杰等^[7]在 YOLOv3 中引入 K-means++ 聚类算法，优化锚定的规模与数量，并改进焦点损失计算，但是检测速度较慢；刘家俊等^[8]运用 YOLOv5 模型检测识别玉米叶片病虫害，但检测精度欠佳；施杰^[9]等以 EfficientViT 重构 YOLOv8 主干网络，引入 GhostConv 等模块，提出轻量化的 YOLOv8-EGCW 模型，大幅削减参数量和模型大小，显著提升检测精度，不过对玉米叶片表型病害的研究仅聚焦于锈病；党珊珊等^[10]在 YOLOv10 中引入 CBAM 注意力机制，虽提升了精度，但以增加模型复杂度为代价。

尽管上述学者在基于 YOLO 目标检测模型的优化和轻量化方面取得了显著成果，但在玉米叶片病害检测领域仍面临以下挑战：（1）由于玉米叶片病害在初期阶段呈现特征尺度微小和视觉对比度低的特性，且受复杂背景干扰，导致 YOLO 模型在早期病害检测时存在精度不足的问题；（2）玉米叶片病害几何形态丰富多变，现有 YOLO 模型难以适配目标变形，进而也会造成检测精度不足；（3）YOLO 系列模型依赖卷积神经网络，在捕捉长距离和全局语义信息方面能力较弱，用于复杂背景下的玉米叶片病害检测时，因难以整合全局信息判别病害，易引发漏检与误检；（4）高精度模型往往伴随着高计算量，难以在嵌入式设备上实现高效部署。

与传统基于 YOLO 的目标检测方法相比，以 DETR^[11]这类基于 Transformer 架构的检测方法在全局感知、细节捕获和序列建模方面更优，可在不同尺度与层次上对整幅图像进行精细分析，有助于精准定位和识别目标。然而，因其参数量庞大、计算过程复杂，难以在资源受限的设备上部署。为解决这一难题，Zhao 等^[12]提出了 RT-DETR。它是首个基于 Transformer 的实时端到端目标检测器，在保留自注意力机制的同时，通过削减多余的特征提取层，并去除非极大值抑制后处理，有效降低了计算开销，能够在复杂背景下快速定位较大目标。但由于特征金字塔构建不够完善，浅层细节提取能力欠佳，导致其对小目标与微弱特征的检测精度较低，容易出现漏检和误检的情况，这在一定程度上限制了它在对精度

要求较高场景中的应用。

基于以上问题，为实现玉米叶片病害检测的轻量化与高精度目标，我们以 RT-DETR-R18 为基础模型，构建兼具轻量化与高精度的病害检测方法 FRA-DETR（Faster RepNCSPNet ADown-DETR）。

1 材料与方法

1.1 数据集建立

玉米生长环境复杂多样，为保障病害检测模型的准确性，本研究通过多源数据构建试验数据集，整合了开源 PlantDoc^[13]、PlantVillage^[14]数据集及 Kaggle 等公开平台数据。由于数据集来源广泛，图片格式与分辨率差异较大，为确保试验严谨规范，先剔除重复和无效图片，再对数据集进行归一化处理。最终数据集包含大斑病、南方锈病、灰斑病 3 种常见玉米叶片病害。部分病害叶片示例如图 1 所示。



图 1 3 种病害玉米叶片示例图

Fig.1 Example Diagrams of Corn Leaves with 3 Types of Diseases

利用 LabelImg 软件对数据集中的图片开展手动标注工作，标注内容涵盖大斑病、南方锈病和灰斑病。标注结果以 VOC 格式的 XML 文件保存，每个文件详细记录病害类别及其在图像中的位置信息。随后，对数据集进行随机划分，形成训练集、验证集和测试集，其比例约为 8:1:1。

表 1 玉米病害数据集分布
Table 1 Distribution of Corn Disease Dataset

分类 Type	图像数/张 Number of images			总数/张 Total images
	大斑病 NCLB	南方锈病 Southern rust	灰斑病 Gray leaf spot	
训练集	1243	3654	742	5639
验证集	148	498	83	729
测试集	153	454	77	684
总数/张	1544	4606	902	7052

图 3 数据增强处理方式

Fig 3 Data augmentation processing methods





图 2 目标相对整幅图的高、宽比例分布情况

Fig 2 Distribution of the height and width ratios of the target relative to the entire image

如表 1 和图 2 展示了玉米叶片病害目标框相对于整幅图的高宽比例，颜色深浅反映了训练集中目标相对于整幅图的高、宽比例分布情况。从分布图可见，宽比例处于 0.1 - 0.5、高比例处于 0.2 - 0.8 区间的目标数量明显较多，说明数据集中存在大量中小目标，这无疑增加了目标检测任务的复杂性与难度。

为全面模拟现实中物体的多样形态与环境变化，让模型接触更丰富场景，选用 Albumentations^[15]在线数据增强方式。在模型训练的每次迭代中，抽取 1 个样本后，先将图像尺寸统一调整为 640×640 像素，随即对其实施多种随机变换，如翻转、裁剪、旋转等，以此模拟现实中物体的多样形态与环境变化，拓宽模型的场景认知，增强泛化能力，防范过拟合现象。同时，引入高斯模糊、亮度变化等噪声与变动因素，赋予模型更强的抗干扰能力，使其面对图像质量波动、光照变化等复杂环境时，仍能稳定检测目标，提升模型的鲁棒性。数据处理流程如图 3 所示。



1.2 FRA-DETR 玉米叶片病害目标检测模型

为了解决 RT-DETR-R18 存在漏检和误检以及在边缘设备上部署时资源消耗过大的弊端，本文基于 RT-DETR 提出了改进模型 FRA-DETR,该模型由主干网络、高效混合编码器和带有辅助预测头的解码器三部分组成。首先将图像输入至由 FasterRepNCSPNet 构成的骨干网络进行特征提取，生成 S3、S4、S5 三层有效特征。随后，具备丰富语义信息的高层特征 S5 经序列化处理与位置编码后，输入至基于注意力机制的内因特征交互模块 (AIFI)。在此模块中，自注意力机制可分析每个特征元素与其他元素间的相关性权重，并根据这些权重对特征进行加权求和，从而实现特征的交互与增强。该过程能帮助模型更充分地捕捉物体的上下文信息与全局特征，有效提升模型在目标检测与识别任务中的性能。


在解码器阶段，S5 经处理后生成特征 F5；解码器采用多层结构设计，包含 N 层解码单元，每层由多头注意力机制（注意力头数设为 H）与前馈网络构成。随后，特征 F5 与骨干网络输出的 S4、S3 共同输入至跨尺度特征融合模块，该模块首先对不同层级的特征进行深度融合，再通过 IoU 感知机制筛选候选特征、执行解码操作，最终实现类别与回归任务的差异对齐。

模型结构如图 4 所示,具体基于 RT-DETR-R18 改进包括：1) 设计了一种新的网络结构 FasterRepNCSPNet 代替原 ResNet18^[16]主干网络；2) 将跨尺度特征融合中的 RepC3 模块替换为 RepNCSPELAN4-FB 模块；3) 结合 Focaler-IoU^[17]和 MPDIoU^[18]引入一种回归损失函数 Focaler-MPDIoU 替换原 GIOU；4) 为了降低对移动端、嵌入式设备计算能力的需求，实施基于幅度的层自适应稀疏度的剪枝。

1.2.1 FasterRepNCSPNet

ResNet18 采用常规卷积、跨步卷积及传统最大池化下采样进行特征提取。其中，常规卷积块的固定层级结构在提取玉米叶片病害的细微斑点、纹理变化等复杂纹理及多尺度病斑特征时能力不足，难以充分挖掘图像深层信息。跨步卷积和传统最大池化下采样在降低分辨率时易导致病害边缘等关键细节丢失，影响后续特征融合和检测精度。尽管 ResNet18 通过残差连接抑制了参数量增长，但特征提取环节仍存在冗余计算，导致浮点运算量较高，所以网络结构和参数需进一步压缩优化。

为此采用轻量化网络 FasterRepNCSPNet 替代 ResNet18 网络，其结构如图 4 左侧所示，FasterRepNCSPNet 网络由卷积层 (Conv)、RepNCSPELAN4-FB 和 ADown 层组成。



注：Conv 为卷积；Concat 为特征连接模块；3*3 为卷积核的大小；s2 为步长为 2；Upsample 是上采样；S3、S4、S5 是主干网络提取出的多尺度特征图，从大到小排列；

Note: Conv is convolution, Concat is the feature connection module, 3*3 are the sizes of convolution kernels, s2 means the stride is 2, Upsample is upsampling, and S3, S4, S5 are multi-scale feature maps extracted by the backbone network arranged from largest to smallest.

图 4 FRA-DETR 结构图
Fig 4 Structure Diagram of FRA - DETR

1) RepNCSPNELAN4-FB 模块


本文将 FasterNet^[19]中的 FasterBlock 引入特征提取模块 RepNCSPNELAN4^[20]，设计了融合型模块 RepNCSPNELAN4-FB。FasterNet 作为一种高效神经网络架构，通过部分卷积 (Partial Convolution, PConv) 技术显著降低冗余计算和内存访问开销。PConv 的核心创新在于采用通道选择性计算机制，仅对输入特征图的部分通道执行卷积操作，从而大幅减少计算量。对于具有连续分布特性的特征图数据，PConv 通过通道选择策略（如首通道或尾通道连续采样）构建代表性特征子集，并保持输入输出通道数一致。基于上述设计，PConv 的浮点运算量 (Fa) 和内存访问成本 (Mc) 可分别由式 (1) 和式 (2) 表示：

$$Fa = 2 \times h \times w \times k^2 \times c_p^2 \quad (1)$$

$$Mc = h \times w \times 2c_n + k^2 \times c_n^2 \approx h \times w \times 2c_n \quad (2)$$

其中，h 和 w 分别代表输出特征图的高度与宽度尺寸， c_p 为参与部分卷积 (PConv) 运算的通道数，k 为卷积核大小， c_n 为参与计算的通道数，定义通道比例系

数 $r = c_p / c$ (c 为总通道数)，由式(1)和(2)可以看出，对于典型设置 $r = 1/4$ (仅取 $1/4$ 部分通道进行卷积)，PConv 的 FLOPs 浮点运算量 (Fa) 仅为传统卷积的 $1/16$ ，内存访问量 (Mc) 也降低到传统卷积的 $1/4$ 。这种计算上的优化，不仅减轻了模型的负担，还提高了运算效率。因此 RepNCSPNELAN4-FB 在特征提取过程中具备更低的计算开销。RepNCSPNELAN4-FB 模块具体结构如图 5 所示，RepNCSPNELAN4-FB 模块通过 1×1 、 3×3 卷积进行组合，并与部分卷积 (Pconv)、CSP 结构及残差连接等有机融合。首先，利用多分支并行结构，对病害图像的细微纹理、全局轮廓等不同尺度特征，进行针对性提取与强化；随后，通过特征拼接操作，将分支处理后的信息聚合，实现多尺度病害特征的有效整合，从而提升检测精度；同时，在架构设计中，通过 1×1 卷积降维、部分卷积 (Pconv) 减少冗余计算等策略，压缩模型计算量。在面对大规模玉米叶片病害数据集时，可有效降低算力资源消耗，使模型在实际应用场景中，实现算法性能与工程实用性的平衡。



注：k 为卷积核的大小；s 为步长；
Note: k is the size of the convolution kernel; s is the stride.

图 5 RepNCSPELAN4-FB 结构图
Fig 5 Diagram of the RepNCSPELAN4-FB Structure

2) ADown 模块

在 RT-DETR-R18 的特征提取过程中，下采样策略主要依赖跨步卷积与最大池化（MaxPool）操作。其中，跨步卷积的直接降维机制因固有的信息压缩特性，易导致玉米叶片病害图像中细微斑斑纹理、边缘轮廓等关键细节特征的丢失，进而影响模型对早期病害的检测敏感度。而最大池化通过选取局部区域最大值作为输出，虽能有效降低数据维度并减少计算负荷，却可能过滤掉病斑边缘低对比度的颜色渐变信息或非显著纹理特征，造成特征表征的片面性。

针对上述问题，本文引入 YOLOv9^[21]中提出的 ADown 模块，替代原有部分下采样环节。该模块通过多路径特征融合设计，在实现空间分辨率降低的同时，能够更完整地保留病害图像中的细微结构信息与多尺度特征，从而在提升检测精度的同时兼顾模型轻量化需求。ADown 模块的具体结构如图 6 所示。




图 6 ADown 结构
Fig 6 Structure of ADown

特征图沿通道维度被均匀划分为两个部分，各部分通道数减半，以此有效降低后续计算复杂度。第一条路径为显著性特征增强路径，子特征图首先经历最大池化操作，该操作通过提取局部区域的最大值，凸显关键显著特征，规避细微干扰对整体特征判断的影响，同时剔除冗余信息。紧接其后，采用 1×1 卷积灵活调控通道维度，强化模型对病斑与健康组织边界等具有分类判别力信息的聚焦。此过程在降低计算复杂度的同时，保留了图像的关键显著特征。第二条路径为细粒度特征学习路径，采用步长为 2 的 3×3 卷积对子特征图进行空间下采样。其中， 3×3 卷积核能够捕获较为宽泛的空间信息，步长 2 实现降维以缩减计算量，同时留存病斑的局部结构特征。通过对输入特征图的通道分割及双路径处理，ADown 模块显著优化了各路径的计算量。相较于传统下采样策略，通道分割与池化策略大幅削减了卷积操作的参数量，进而有效降低模型的计算开销。假设输入特征图的尺寸为 $h \times w \times c$ （其中 h 为特征图的高度， w 为特征图的宽度， c 为特征图的通道数），设 ADown 模块的参数量 Pa_1 、计算复杂度 Fa_1 ，步长为 2 的 3×3 跨步卷积模块的参数量 Pa_2 和计算复杂度 Fa_2 ，可以通过数学公式分别表示为：

$$\begin{cases} Pa_1 = \frac{5}{2}c^2 \\ Fa_1 = \frac{5}{8}c^2 \times h \times w \end{cases} \quad (3)$$

$$\begin{cases} Pa_2 = 9c^2 \\ Fa_2 = \frac{9}{4}c^2 \times h \times w \end{cases} \quad (4)$$

根据式（3）和式（4）的分析结果，传统步长为 2

的下采样卷积操作的参数量和计算复杂度分别为 ADown 模块的 3.6 倍。ADown 模块在实际应用中展现出显著优势,在特征下采样过程中,它能够在保持高精度的同时,提高计算效率,降低资源消耗。在需要多尺度特征处理的任务中,ADown 模块为模型提供了强大的下采样能力。

1.2.2 Focaler-MPDIoU 损失函数

RT - DETR 采用 GIoU 损失函数。尽管 GIoU 充分考量了边界框间的包含关系与空间分布特性,然而其对边界框角点距离的优化缺乏直接性。对于玉米叶片病害这类形状复杂的场景而言,其难以迅速且精准地调整预测框位置,进而可能引发定位偏差,在病斑重叠或边界模糊时更为显著。此外,GIoU 主要聚焦于边界框的几何关系,并未针对样本不均衡问题设计相应优化机制。在样本不均衡的场景下,模型训练过程易受样本量较大类别的主导,对样本量较少的病害检测效果欠佳,难以契合玉米叶片病害检测中对各类病害进行均衡检测的实际需求。为克服这些局限性,本文提出一种融合动态加权与几何优化的 Focaler-MPDIoU 损失函数,结合 Focaler-IoU 和 MPDIoU 两者的思想,以提升边界回归精度并增强目标检测性能。

Focaler 机制构建了基于 IoU 的动态加权策略,根据样本的回归难度,自适应地为困难样本分配更高的权重,从而增强困难样本在损失计算中的贡献;相反,对于较易学习的样本,赋予较低的权重,减少模型对常见目标的过拟合风险,其函数定义如下:

$$IoU^{focaler} = \begin{cases} 0, & IoU < d \\ \frac{IoU - d}{u - d}, & d \leq IoU \leq u \\ 1, & IoU > u \end{cases} \quad (5)$$

式中: IoU 表示原始 IoU 值, d 表示困难样本下界阈值, u 表示容易样本上界阈值, $d, u \in [0, 1]$ 。通过调整 d 和 u 的值,可以使 $IoU^{focaler}$ 聚焦于不同的回归样本,损失函数公式为:

$$L_{Focaler-IoU} = 1 - IoU^{focaler} \quad (6)$$

MPDIoU 损失函数基于点的最小距离,综合考虑了现有损失函数中的多个因素,如重叠或非重叠区域、中心点距离以及宽度和高度的偏差等,简化了计算过程,更加准确地衡量边界框之间的匹配程度,提升模型在复杂任务中的定位能力。其损失函数定义如下:

$$MPDIoU = \frac{A \cap B}{A \cup B} - \frac{d_1^2}{w^2 + h^2} - \frac{d_2^2}{w^2 + h^2} \quad (7)$$

$$d_1^2 = (x_1^B - x_1^A)^2 + (y_1^B - y_1^A)^2 \quad (8)$$

$$d_2^2 = (x_2^B - x_2^A)^2 + (y_2^B - y_2^A)^2 \quad (9)$$

式中: A 和 B 分别代表真实框和预测框的面积, d_1 、 d_2 表示图形 A 、 B 左上角点之间和右下角点之间的欧氏距离。 w 和 h 分别为图片的宽度和高度。

(x_1^A, y_1^A) 、 (x_2^A, y_2^A) 表示图形 A 的左上和右下点坐标, (x_1^B, y_1^B) 、 (x_2^B, y_2^B) 表示图形 B 的左上和右下点坐标。




图 7 Focaler-MPDIoU 边框处理图

Fig 7 Bounding Box Processing Diagram of Focaler-MPDIoU

Focaler-MPDIoU 损失函数结合 MPDIoU 的边界框几何优化与 Focaler 机制的困难样本关注,图 7 为 Focaler-MPDIoU 边框处理过程。边界框与其他物体或背景的重叠较小,容易分类和回归的样本为简单样本,反之为困难样本。在训练过程中优化边界框回归目标的对齐度,同时自适应调整样本权重,增强对困难样本的关注。Focaler-MPDIoU 损失函数的完整表达式如下:

$$L_{Focaler-MPDIoU} = L_{MPDIoU} + IoU - IoU^{focaler} \quad (10)$$

Focaler-MPDIoU 不仅充分考虑样本难度的差异,而且融入了边界框位置匹配因素,因而对于小目标、密集目标以及复杂背景具有更好的适应性。

1.2.3 模型剪枝

为了在轻量化模型的同时简化剪枝过程,避免广泛的超参数调整对人力物力的损耗。引入了一种基于幅度的层自适应稀疏度的剪枝算法(Layer-adaptive sparsity for the Magnitude-based Pruning, LAMP)对改进后的模型进行剪枝。LAMP 分数没有任何需要调整的超参数,计算开销很小,可以通过基本张量运算轻松实现,且效果优于目前大多数剪枝算法。这一方法不需要复杂的操作,只需要调整加速比,具体公式如下所示:

$$score(u; W) := \frac{(W[u])^2}{\sum_{v \geq u} (W[v])^2} \quad (11)$$

$$(W[u])^2 > (W[v])^2 \Rightarrow score(u; W) > score(v; W) \quad (12)$$

式中: W 表示权重,分子部分 $(W[v])^2$ 表示目标连接的权重幅度的平方,分母部分 $\sum_{v \geq u} (W[v])^2$ 则表示在同一层中所有剩余连接的权重幅度平方之和。权重按照给定的索引映射按升序排序。根据式(11)可知权重项越大,与之对应的 LAMP 评分则越大。LAMP 剪枝的主要流程如图 8 所示,其流程形式化表述如公式(13)所示。




图 8 LAMP 剪枝流程图
Fig 8 Flow Chart of LAMP Pruning

$$\begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ \vdots \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ \vdots \end{bmatrix} \Rightarrow \begin{bmatrix} \frac{u_1^2}{u_1^2} & \frac{v_1^2}{v_1^2} \\ \frac{u_2^2}{u_1^2 + u_2^2} & \frac{v_2^2}{v_1^2 + v_2^2} \\ \frac{u_3^2}{u_1^2 + u_2^2 + u_3^2} & \frac{v_3^2}{v_1^2 + v_2^2 + v_3^2} \\ \vdots & \vdots \end{bmatrix} \Rightarrow \begin{bmatrix} \frac{u_1^2}{u_1^2} & \frac{v_1^2}{v_1^2} \\ \frac{u_2^2}{u_1^2 + u_2^2} & \Phi \\ \Phi & \Phi \\ \vdots & \vdots \end{bmatrix} \quad (13)$$

权重大小 LAMP 得分 自适应动态剪枝

本模型中 LAMP 剪枝作用于骨干网络的 Conv(3×3,s2)卷积层、RepNCSPeLan4-FB 模块、ADown 下采样模块，高效混合编码器的 Conv(1×1)卷积层、Conv(3×3,s2)卷积层、RepNCSPeLan4-FB 模块等冗余特征层；而 AIFI（注意力特征交互模块）、Upsample（尺度对齐模块）、Concat（特征拼接模块）以及 Decoder（解码器模块）未被剪枝——其中 AIFI 保障跨尺度特征的注意力交互，Upsample 实现特征尺度对齐，Concat 完成多尺度特征拼接，Decoder 是目标检测输出的核心结构，这些模块对模型的特征表达、结构完整性与检测性能起关键支撑作用，剪枝会破坏功能逻辑，因此保留以平衡轻量化与性能。

当剪枝幅度较小时，由于复杂度降低、过拟合的减轻等原因，模型的精度可能有所提升；但是当剪枝幅度过大时，由于重要特征的丢失、网络容量的降低、泛化能力受到破坏等问题，会导致模型精度大幅下降。所以为了平衡模型大小和精度，需要仔细选择剪枝幅度，并在剪枝后进行适当的微调，以恢复模型的性能。

2 实验与分析

2.1 试验平台与参数设置

本文所有实验均在 64 位 Windows 11 操作系统下开展，配置了 Python3.9.7、CUDA11.3 及 Pytorch1.12.1 环境，于 NVIDIA GeForce RTX 4060 Ti 16GB 显卡上进行训练。实验中将图片输入尺寸统一规范为 640 pixel×640 pixel，以此提升训练效率；设置批次为 4，确保 GPU 资源得以充分利用。初始学习率设定为 0.0001，优化器选用 AdamW，初始训练轮数 epoch 为 200，剪枝后的微调训练轮数同样设定为 200。

2.2 评估指标

目标检测领域的核心评价指标体系通常采用精确率精确率（Precision, P）、召回率（Recall, R）、mAP₅₀ 及 mAP_{50:95} 四项指标。其中，精确率反映模型预测正样本的准确程度，即预测为正的样本中实际为正的比例；召回率衡量模型对真正样本的捕捉能力，即实际正样本被正确检出的比例。mAP₅₀ 设定预测框与真实框的交并比（IoU）阈值为 0.5，计算所有类别平均精度（Average Precision, AP）的均值；mAP_{50:95} 则将 IoU 阈值从 0.5 至 0.95 以 0.05 为间隔遍历，综合评估模型在不同检测精度要求下的平均表现。

在轻量化指标方面，研究引入浮点计算次数（GFLOPs）量化模型的计算复杂度，参数量（parameters）表征模型结构的复杂程度，模型大小（Model Size）直观反映存储需求。

2.3 同轻量化特征提取主干网络对比试验

本文在 RT-DETR-R18 的基础模型上，遵循单一变量原则，仅替换主干网络并对训练结果进行对比，结果如表 2 所示，从表 2 数据可知，本文所设计的 FasterRepNCSPNet 在召回率、平均精度及参数量等维度，相较于 EfficientViT^[22]、ConvNext-V2^[23]、EfficientFormerv2^[24]、RepViT^[25]、FastNet、MobileNetV2^[26]、Ghostnetv2^[27] 等网络展现出显著优势。其平均精度均值较这些网络分别提升 4.6、1.6、0.7、3.8、0.7、3.7、4.2 个百分点。部分轻量化主干网络虽计算量低于本文方法，但其特征提取能力欠佳，无法满足实际部署要求。

表 2 同轻量化特征提取主干网络对比
Table 2 Comparison with Lightweight Feature Extraction Backbone Networks

主干网络 Backbone networks	R/%	mAP ₅₀ /%	GFLOPs	Parameters/10 ⁶
EfficientViT	61.0	65.9	27.2	10.71
ConvNeXt-V2	63.4	68.9	31.9	12.3
EfficientFormerv2	62.5	69.8	29.5	11.8
RepViT	60.8	66.7	36.3	13.3
FastNet	64.9	69.8	28.5	10.81
MobileNetV2	58.4	66.8	25.3	9.35
Ghostnetv2	59.5	66.3	25.9	12.38
FasterRepNCSPNet	66.1	70.5	27.5	9.271

2.4 IoU 对比实验

为验证 Focaler - MPDIoU 损失函数的有效性，将其与其他主流定位损失函数在玉米叶片病害数据集上开展对比实验。鉴于定位损失函数不影响模型参数量与计算量，故选取 P、R、mAP₅₀、mAP_{50:95} 四项指标进行比较。由表 3 实验结果可知，本文所采用组合的损失函数相较其他各类损失函数，在召回率、mAP₅₀ 和 mAP_{50:95} 指标上表现更优。这充分表明，本文所采用的损失函数对玉米叶片病害检测任务场景具有更好的适配性。

表 3 IoU 对比实验
Table 3 IoU Comparison Experiments

损失函数 Loss function	P/%	R/%	mAP ₅₀ /%	mAP _{50:90} /%
Inner-Iou	64.9	66.6	69.9	52.7
MPDIoU	70.5	65.3	70.7	53.3
Focaler-IoU	69.2	67.2	71.5	54.4
Inner-MPDIoU	73.1	63.5	70.5	53.9
Focaler-MPDIoU	67.9	68.6	71.8	54.7

2.5 LAMP 剪枝的 speed_up 选取

为了降低对移动端、嵌入式设备计算能力的需求，对改进后的模型进行 LAMP 剪枝。为探究不同剪枝幅度下模型的性能表现，筛选出实际应用场景中综合性能最优的剪枝模型，现对不同浮点计算速率倍数（定义为： $\text{speed_up} = \text{剪枝前模型计算量} / \text{剪枝后模型计算量}$ ，其中 $\text{speed_up} = 1.0$ 表示未剪枝的原始模型）提升下的模型剪枝效果进行对比，具体结果如表 4 所示

表 4 LAMP 剪枝 speed_up 对比实验
Table 4 Speed-up Comparison Experiments of LAMP Pruning

speed_up	Parameters/ 10^6	GFLOPs	mAP ₅₀ /%	ModelSize/MB
1.0	8.98	26.3	71.8	17.5
1.1	8.47	22.5	70.6	16.7
1.2	8.15	21.6	71.6	16.1
1.3	7.65	19.5	71.7	15.2
1.4	7.37	18.7	71.3	14.7
1.5	6.83	15.8	69.8	13.6
1.6	6.73	15.5	67.3	13.4

当模型的速率提升较小时，伴随 speed_up 的增加，模型精度得到了提升，这说明本文所采用的 LAMP 剪枝方法有效的去除了模型中的冗余部分。当 speed_up 大于 1.3 时，模型精度开始降低，重要特征可能丢失、泛化能力受到破坏，造成精度下降。故综合模型大小和精度指标，选择 $\text{speed_up}=1.3$ 的剪枝模型。

2.6 剪枝前后通道数对比

当 speed_up 设置为 1.3 时，修剪通道数量排名前 20 的层修剪前后对比如图 9 所示，从中可以直观地看出该剪枝策略有效地去除了模型中的冗余部分。




图 9 修剪通道数量排名前 20 的层修剪前后对比图
Fig 9 Comparison Chart of the Top 20 Layers by Pruned Channel Count Before and After Pruning

2.7 模型改进前后各类别病害检测性能对比

根据表 5 可知，改进后的模型展现出显著的性能提

升。整体精确率提升了 4.4 个百分点；召回率提高了 3.8 个百分点；平均精度均值提高了 3.2 个百分点。此外，各类病害对应的精确率、召回率及平均精度均值指标均实现了不同程度的提升。结合图 10 与图 11 中模型改进前后的混淆矩阵对比可知，改进后的模型展现出更优的综合性能。具体来看，灰斑病、南方锈病、大斑病三类病害的正确识别数量显著增加，漏检数量明显减少；同时，三类病害之间的交叉误判有所降低，但三类病害与背景的交叉误判出现一定程度的增多。

表 5 模型改进前后各类别病害检测性能对比
Table 5 Performance Comparison of Various Disease Categories Before and After Model Improvement

类别 Category	P ₁ / %	P ₂ /%	R ₁ /%	R ₂ /%	mAP ₁ @50/%	mAP ₂ @50/%
全部	69.5	73.9	61.7	65.5	68.5	71.7
灰斑病	63.2	65.4	40.8	48.3	46.1	53.2
南方锈病	68.7	72.6	67.4	70.7	76.7	78.4
大斑病	76.6	83.7	76.9	77.5	82.7	83.5




图 10 模型改进前的混淆矩阵
Fig 10 Confusion matrix before model improvement




图 11 模型改进后的混淆矩阵
Fig 11 Confusion matrix after model improvement

2.8 消融实验

为科学验证各改进策略对模型性能的提升效果，本研究以 RT-DETR-R18 作为基础模型（Baseline），针对性实施四项优化策略：A，将 RepC3 模块升级为 RepNCSPeLan4-FB 模块；B，采用 FasterRepNCSPNet 替代原 RestNet18 主干网络；C，以 Focaler-MPDIoU

损失函数替换 GIoU; D, 运用 LAMP 算法进行模型剪枝。通过消融实验验证各策略的有效性, 实验结果如表 6 所示。

表 6 消融实验结果
Table 6 Results of Ablation Experiments

Model	Parameters /10 ⁶	GFLOP s	mAP ₅₀ / %	ModelSize/ MB
Baseline	19.88	57.2	68.5	38.5
Baseline+A	18.45	49.9	69.5	35.5
Baseline+A+B	8.98	26.3	71.1	17.5
Baseline+A+B+C	8.98	26.3	71.8	17.5
Baseline+A+B+C+D	7.65	19.5	71.7	15.2

引入 RepNCSPELAN4-FB 模块, 平均精度均值显著提升, 参数量与计算量小幅下降。在此基础上, 用 FasterRepNCSPNet 替换主干网络, 平均精度均值进一步提高, 参数量与计算量大幅降低。接着, 引入 Focaler-MPDIoU 优化回归损失函数。最后, 进行模型

表 7 不同算法在测试集实验结果对比表
Table 7 Comparison Experiments of Different Algorithms on the Test Set

Model	Parameters/10 ⁶	GFLOPs	P/%	R/%	mAP ₅₀ /%	mAP _{50:90} /%	ModelSize/MB
RT-DETR-R18	19.88	57.2	69.5	61.7	68.5	52.0	38.5
YOLOv3-tiny ^[28]	12.12	18.9	60.5	64.7	65.1	41.8	24.4
YOLOv5m	25.04	64.0	63.3	63.4	69.4	51.4	48.1
YOLOv6s ^[29]	16.29	44.0	64.9	65.3	69.9	51.9	31.2
YOLOv8s	11.12	28.4	69.7	63.5	70.4	52.0	21.4
YOLOv10m ^[30]	16.45	63.4	64.8	58.9	65.9	48.5	33.5
Ours	7.65	19.5	73.9	65.5	71.7	0.54.2	15.2




图 12 模型训练指标对比图

Fig 12 Comparison Diagram of Model Training Indicators

剪枝, 在保证精度的同时, 进一步减小模型规模。

2.9 检测模型对比试验


在完成模型结构改进与剪枝优化后, 本文构建了最终的 FRA-DETR 模型。为直观验证该改进模型在玉米叶片病害目标检测场景中的有效性与优越性, 现将其与当前主流目标检测模型置于相同实验平台开展训练对比, 具体效果对比如图 12 所示。从图中可以看出本文提出的 FRA-DETR 模型在收敛速度上较对比模型呈现出显著优势, 整体性能表现突出, 且曲线平滑度更优。为进一步量化性能提升幅度, 将各模型最优权重在测试集进行验证, 结果如表 7 所示。数据表明, 本文提出的改进模型显著优于其他对比算法, 在核心指标上呈现多维度优势。其轻量化特性与高效性能的结合, 充分印证了所提改进方法在该场景下的有效性与优越性。

2.10 模型检测效果




为直观呈现改进效果, 从玉米叶片病害数据集测试集中选取典型检测结果, 对 RT-DETR-R18、YOLOv3-tiny、YOLOv5m、YOLOv6s、YOLOv8s、YOLOv10m 及 FRA-DETR 等模型的检测效果进行对比(见图 13), 图中采用不同颜色预测框对 3 类病害加以区分, 同时标注对应置信度值; 特别地, 对于所有对比模型均能检测到的目标, 本文所提出的模型对其输出的预测置信度, 明显高于其他对比模型的预测结果。

具体来看, 图 13 (a) 显示, 针对不同尺度的大斑病目标, 其他模型存在漏检或误检问题, 而 FRA-DETR 能准确检测全尺寸目标; 图 13 (b) 中, 叶片遮挡场景下仅 FRA-DETR 完整识别所有南方锈病目标, 其余模型均有漏检; 图 13 (c) 显示, YOLOv3-tiny、YOLOv6s、YOLOv10m 在光照不均时出现漏检灰斑病目标, FRA-DETR 凭借稳定的特征学习保持检测效果;



RT-DETR
-R18




YOLOv3
-tiny





YOLOv5m



YOLOv6s



YOLOv8s






图 13 不同模型检测效果图
Fig 13 Detection Effect Diagrams of Different Models

3 结论与讨论

针对玉米叶片病害表现形式多样，且易受光线、拍摄角度、遮挡等场景干扰导致漏检、误检问题，同时为降低对移动端与嵌入式设备的算力需求，本研究基于 RT-DETR 提出一种轻量化玉米叶片病害识别方法。具体而言，设计 FasterRepNCSPNet 替换原 RestNet18 主干网络，在提升特征提取精度以减少误漏判的同时，提高参数利用效率；将跨尺度特征融合中的 RepC3 模块替换为 RepNCSPeLAN4-FB 模块，增强模型多尺度特征处理能力，优化不同规模病害区域检测效果；结合 Focaler-IoU 与 MPDIoU 构建 Focaler-MPDIoU 损失函数，替代原 GIOU，通过考虑样本难易分布，优化边界框回归；借助基于幅度的层自适应稀疏度剪枝，精简模型非关键部分，降低对硬件资源的需求。实验验证结果显示，FRA-DETR 模型在实际玉米叶片病害目标检测任务中，检测准确性显著提升，且参数量、计算量及存储空间大幅减小，为玉米叶片病害检测提供了切实可行的技术方案。

尽管本研究在玉米叶片病害检测中取得了阶段性成果，但仍存在病害种类局限等不足。未来将扩展病害种类，并融合多模态数据，推动技术向更实用、更全面的方向发展。同时，针对骨干网络的进一步优化，后续研究可探索基于 Transformer 的架构（如 Swin

Transformer），利用其全局特征建模能力，对比其在玉米叶片病害检测任务中对小目标、模糊病害区域的识别潜力，为模型性能突破提供新方向；在应用场景落地方面，本模型的轻量化与高效性可面向田间实时监测（如搭载于移动端设备的现场巡检）、无人机图像分析（大范围玉米田的病害筛查）等实际场景，通过嵌入式设备部署实现病害的快速精准识别，为农业智能化植保决策提供技术支撑。

[参 考 文 献]

- [1] 崔涛, 樊晨龙, 张东兴, 等. 玉米机械化收获技术研究进展分析[J]. 农业机械学报, 2019, 50(12):1-13.
CUI T, FAN C L, ZHANG D X, et al. Research progress of maize mechanized harvesting technology[J]. Transactions of the Chinese Society for Agricultural Machinery, 2019, 50(12): 1-3. (in Chinese)
- [2] 王月先, 董淑华, 雷秀丽. 高产玉米种植技术及病虫害强化防治措施[J]. 世界热带农业信息, 2024, (04):53-55.
WANG Y X, DONG S H, LEI X L. High-yield corn cultivation techniques and enhanced prevention and control measures for diseases and pests[J]. World Tropical Agriculture Information, 2024, (04):53-55. (in Chinese)
- [3] 吴清近. 玉米病害防治与种植技术应用[J]. 河北农业, 2025, (01):92-93.

- WU Q J. Corn disease control and application of planting techniques[J]. Hebei Nongye, 2025, (01): 92-93. (in Chinese)
- [4] 邓朋飞, 官铮, 王宇阳, 等. 基于迁移学习和模型压缩的玉米病害识别方法[J]. 计算机科学, 2022, 49(S2): 444-449.
- DENG P F, GUAN Z, WANG Y Y, et al. A maize disease identification method based on transfer learning and model compression[J]. Computer Science, 2022, 49(S2): 444-449. (in Chinese)
- [5] 黄成龙, 柯宇曦, 华向东, 等. 边缘计算在智慧农业中的应用现状与展望[J]. 农业工程学报, 2022, 38(16): 224-234.
- HUANG C L, KE Y X, HUA X D, et al. Application status and prospects of edge computing in smart agriculture[J]. Transactions of the Chinese Society of Agricultural Engineering, 2022, 38(16): 224-234. (in Chinese)
- [6] 岑海燕, 朱月明, 孙大伟, 等. 深度学习在植物表型研究中的应用现状与展望[J]. 农业工程学报, 2020, 36(09): 1-16.
- CEN H Y, ZHU Y M, SUN D W, et al. Application status and prospects of deep learning in plant phenotyping research[J]. Transactions of the Chinese Society of Agricultural Engineering, 2020, 36(09): 1-16. (in Chinese)
- [7] 徐会杰, 黄仪龙, 刘曼. 基于改进 YOLOv3 模型的玉米叶片病虫害检测与识别研究[J]. 南京农业大学学报, 2022, 45(06): 1276-1285.
- XU H J, HUANG Y L, LIU M. Research on detection and identification of corn leaf diseases and pests based on an improved YOLOv3 model[J]. Journal of Nanjing Agricultural University, 2022, 45(06): 1276-1285. (in Chinese)
- [8] 刘家俊, 苏润琦, 吴麒, 等. 基于 YOLO 模型的玉米叶片病虫害检测与识别研究[J]. 化学工程与装备, 2023, (06): 31-34. DOI:10.19566/j.cnki.cn35-1285/tq.2023.06.026.
- LIU J J, SU R Q, WU Q, et al. Research on detection and identification of corn leaf diseases and pests based on YOLO model[J]. Chemical Engineering & Equipment, 2023, (06): 31-34. DOI:10.19566/j.cnki.cn35-1285/tq.2023.06.026. (in Chinese)
- [9] 施杰, 熊凯祥, 李志, 等. 基于轻量化改进 YOLOv8 模型和边缘计算的玉米病虫害检测系统[J]. 江苏农业学报, 2025, 41(02): 313-322.
- SHI J, XIONG K X, LI Z, et al. A corn disease and pest detection system based on lightweight improved YOLOv8 model and edge computing[J]. Jiangsu Journal of Agricultural Science, 2025, 41(02): 313-322. (in Chinese)
- [10] 党珊珊, 白明宇, 路扬, 等. 基于改进 YOLOv10n 的玉米叶片病虫害检测研究[J]. 内蒙古民族大学学报(自然科学版), 2025, , 40(02) :
- 69-76. DOI:10.14045/j.cnki.15-1220.2025.02.010.
- DANG S S, BAI M Y, LU Y, et al. Research on corn leaf disease detection based on an improved YOLOv10n model[J]. Journal of Inner Mongolia Minzu University (Natural Science Edition), 2025, 40(02): 69-76. DOI:10.14045/j.cnki.15-1220.2025.02.010. (in Chinese)
- [11] CARION N, MASSA F, SYNNAEVE G, et al. End-to-end object detection with transformers[C]//European conference on computer vision. Cham: Springer International Publishing, 2020: 213-229.
- [12] ZHAO Y, LV W, XU S, et al. Detrs beat yolos on real-time object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 16965-16974.
- [13] SINGH D, JAIN N, JAIN P, et al. Plantdoc: a dataset for visual plant disease detection[M]//Proceedings of the 7th ACM IKDD CoDS and 25th COMAD. 2020: 249-253.
- [14] GEETHARAMANI G, PANDIAN A. Identification of plant leaf diseases using a nine-layer deep convolutional neural network[J]. Computers & Electrical Engineering, 2019, 76: 323-338.
- [15] BUSLAEV A, IGLOVNIKOV V I, KHVEDCHENVA E, et al. Alumentations: fast and flexible image augmentations[J]. Information, 2020, 11(2): 125.
- [16] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [17] ZHANG H, ZHANG S. Focaler-iou: more focused intersection over union loss[J]. arXiv preprint arXiv:2401.10525, 2024.
- [18] MA S, XU Y. Mpdious: a loss for efficient and accurate bounding box regression[J]. arXiv preprint arXiv:2307.07662, 2023.
- [19] CHEN J, KAO S, HE H, et al. Run, don't walk: chasing higher FLOPS for faster neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 12021-12031.
- [20] WANG C Y, YE H I H, LIAO H Y M. Yolov9: learning what you want to learn using programmable gradient information[EB/ OL]. (2024-02-21) [2024-04-24]. <https://arxiv.org/abs/2402.13616>.
- [21] WANG C Y, YE H I H, MARK L H Y. Yolov9: learning what you want to learn using programmable gradient information[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2024: 1-21.

- [22] CAI H, LI J, HU M, et al. EfficientViT: lightweight multi-scale attention for on-device semantic segmentation[J]. arXiv preprint arXiv:2205.14756, 2023, 2.
- [23] WOO S, DEBNATH S, HU R, et al. Convnext v2: co-designing and scaling convnets with masked autoencoders[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 16133-16142.
- [24] LI Y, YUAN G, WEN Y, et al. Efficientformer: vision transformers at mobilenet speed[J]. Advances in Neural Information Processing Systems, 2022, 35: 12934-12949.
- [25] WANG A, CHEN H, LIN Z, et al. Repvit: revisiting mobile cnn from vit perspective[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 15909-15920.
- [26] SANDLER M, HOWARD A, ZHU M, et al. Mobilenetv2: inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.
- [27] TANG Y, HAN K, GUO J, et al. GhostNetV2: enhance cheap operation with long-range attention (Supplementary Material)[J].
- [28] REDMOR J, FARHADI A. Yolov3: an incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.
- [29] LI C, LI L, JIANG H, et al. YOLOv6: a single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.
- [30] WANG A, CHEN H, LIU L, et al. Yolov10: real-time end-to-end object detection[J]. Advances in Neural Information Processing Systems, 2024, 37: 107984-108011.