

DOI: 10.3969/j.issn.1671-7775.2025.06.012

基于新的 F-YOLO 深度网络的城市植被覆盖检测

徐 昇, 吴 迪

(南京林业大学 信息科学技术学院, 江苏 南京 210037)

摘要: 针对传统基于遥感影像处理的植被分析中人工干预较多导致的效率低、精度差、更新速度慢、耗费资源等问题, 基于 YOLO 网络结构, 提出一种新的全卷积 F-YOLO (fully convolutional YOLO) 结构网络模型对植被覆盖进行研究. 通过修改损失函数来提升图像中目标检测的精度, 并输出像素级的目标检测结果, 完成像素级分类任务. 通过设计出自动端到端的像素分割算法, 统计城市植被的覆盖度. 选取南京市紫金山附近区域为研究对象, 采用提出的 F-YOLO 对图片进行卷积和池化操作, 从而得到特征图; 再通过上采样将高度抽象的特征图还原成原图像大小; 然后进行逐像素分析, 判断此像素是否属于目标植被; 最后进行植被的分割与覆盖度计算. 试验结果表明算法植被分割像素精确率达到 94.76%, 植被覆盖度计算结果的精确度为 96.72%. 在目标检测任务中, 文中方法召回率为 97.33%, 像素精确率为 96.34%, F_1 值为 96.83%, 都显著优于 SSD 与 Faster-RCNN; 在像素级分割任务中, 该方法 94.76% 的像素精确率明显高于 FCN-16、U-Net 及 FCN-32, 验证了其具有综合性能优势.

关键词: 植被检测; 高分辨率遥感图像; 深度学习; YOLO; 全卷积网络

中图分类号: TP391 **文献标志码:** A **文章编号:** 1671-7775(2025)06-0705-09

引文格式: 徐 昇, 吴 迪. 基于新的 F-YOLO 深度网络的城市植被覆盖检测[J]. 江苏大学学报(自然科学版), 2025, 46(6): 705-713.

Urban vegetation coverage detection based on
novel F-YOLO deep network

XU Sheng, WU Di

(College of Information Science and Technology, Nanjing Forestry University, Nanjing, Jiangsu 210037, China)

Abstract: Traditional vegetation analysis based on remote sensing imagery is often characterized by substantial manual intervention with low efficiency, suboptimal accuracy, slow updates and high resource consumption. To address these limitations, the novel fully convolutional YOLO (F-YOLO) network architecture was proposed. Derived from the YOLO framework, the target detection accuracy was improved by modifying the loss function to deliver pixel-level classification outcomes. The automated end-to-end pixel segmentation algorithm was designed to quantify the urban vegetation coverage. The Zijin Mountain area in Nanjing was selected as the study region. The images were processed through convolutional and pooling operations by the proposed F-YOLO to extract feature maps. These highly abstract features were subsequently upsampled to original dimensions through bilinear interpolation and

收稿日期: 2023-03-27

基金项目: 国家自然科学基金青年科学基金资助项目(62102184); 中国博士后科学基金资助项目(2019M661852); 江苏省自然科学基金青年科学基金资助项目(BK20200784); 江苏省高等学校大学生创新创业训练计划项目(202210298042Z)

作者简介: 徐 昇(1988—), 男, 江苏宿迁人, 博士, 副教授(xusheng@njfu.edu.cn), 主要从事遥感图像处理 and 计算机视觉的研究.

吴 迪(1999—), 女, 江苏扬州人, 学士(共同一作, wudi1227@njfu.edu.cn), 主要从事图像处理 and 计算机视觉的研究.

followed by per-pixel vegetation classification for segmentation and coverage calculation. The experimental results show that by the proposed method, the vegetation segmentation accuracy of 94.76% is achieved with the vegetation coverage estimation precision of 96.72%. For object detection, the recall rate of 97.33%, the precision of 96.34% and the F_1 -score of 96.83 are significantly higher than those of SSD and Faster R-CNN. In terms of pixel-level segmentation, the accuracy of 94.76% also outperforms those of FCN-16, U-Net and FCN-32, which confirms the overall superior performance of the proposed approach.

Key words: vegetation detection; high-resolution remote sensing imagery; deep learning; YOLO; fully convolutional network

植被是覆盖于地表的植物群落总称,包括森林、草地、作物、灌木等,是生态系统的重要组成部分,与气候、土壤、地形、水资源等环境要素息息相关。城市植被是城市生态系统的重要组成部分,是自然和人文多种因素影响的结果。及时准确地对城市植被资源进行调查和探测、推进城市植被资源信息化提取与管理,有助于了解城市植被状况,对于生态、社会和经济有着重要的意义^[1]。遥感图像具有客观、准确、实时的特点,能够清晰地显示各种地表覆盖物的特征和分布,真实准确地反映地面状况。对于遥感图像进行分类是获取植被信息的重要方法。早期的植被遥感分类需要进行野外现场调查,耗费大量人力物力,并不适用于大规模作业。植被遥感分类早期主要采取目视解译的方法,但解释的准确性通常取决于图像的质量和处理者的经验,难度大、时效性差。

随着遥感图像应用技术的发展,出现了许多自动化植被检测技术。传统的图像分割方法有阈值分割法、区域分割法、遗传理论分割法、基于边缘的检测算法等。而在植被分割方面又有基于光谱特征的植被提取方法、基于纹理特征的植被提取方法和综合光谱与纹理特征的植被提取方法。但传统图像分割方法需要人工设计特征,依赖经验和数据本身特性,因此多数情况下无法提取到图像的本质特征。而深度学习作为数据驱动的特征学习方法,属于端到端的方法,通过大量数据训练,可以获得图像本质特征。

文中基于 YOLO(you only look once)网络结构^[2]和全卷积神经网络算法,拟设计一种新的植被提取方法,通过像素级的植被分割来估算场景中植被覆盖度,提高城市植被信息化程度。文中的主要思路如下:实际遥感图像中的植被分布较为复杂,存在区域遮挡等原因造成的目标缺失,文中在设计损失函数时,添加基于目标区域识别的置信度来对目标区域的内接圆部分计算损失函数,提升小区域的检测精度;在网络输出目标检测框后,给出初步定位结果,减少计算复杂度,通过融合全卷积网络来获得目标框内的像素

级的分类结果,并对植被覆盖度进行估算。

1 相关工作

植被覆盖度(fractional vegetation cover, *FVC*)通常定义为植被在地面的垂直投影面积占统计区总面积的百分比^[3]。植被覆盖度的测算一直以来都是困扰人们的一个难题,因为存在城市的面积大、范围广、植被数量过多等诸多因素,使得整个测算过程烦琐且结果精确度较低。

目前地面监测的方法大致分为3种,即目估、仪器和经验模型。目估法是通过人眼直接分辨植被覆盖度或利用照片、网络等参考资料来进行估算。该方法简单易行,但相对主观武断,误差较大,其精确度与测试人员的经验有很大关系。仪器法是通过光学传感器获取光穿过植被冠层的情况估算植被覆盖度。这种方法在当前已经成功运用于植被覆盖度的测量中。此前,Decagon公司就开发过用来测算植被覆盖度的相机,这种相机可以通过检测图片中的植被,进而计算所有植被的像素与整个图片像素的比例,即该区域的植被覆盖度估值。经验模型方法就是建立植被覆盖度的经验模型,并根据相关数据对植被覆盖度进行估算。该模型有较可靠的准确度,但其使用受到地理位置的限制。这些传统的方法都具有一定的可行性,但随着时代的发展与进步,无法适应当下城市植被覆盖度动态监测的要求,严重影响了我我国城市绿化管理和城市环境的改善。遥感具有数据采集范围广泛、能够持续监测目标区域的优点,目前已广泛用于多种研究领域,可获取不同尺度上的植被覆盖及其变化信息,已成为估算植被覆盖度的主要技术手段。相比地面监测方法,遥感具有更高的精度,更适用于对城市绿化的有效管理^[4]。

在采用遥感图像技术来统计覆盖度时,关键难点就是图像中目标的检测、定位和分割。目前图像分割的方法可分为2个大类,即传统图像分割法和基

于深度学习的分割方法.传统图像分割方法包括基于阈值、边缘、区域、聚类及特定理论等图像分割方法.

基于阈值的图像分割常用算法有直方图双峰法、Otsu 法、自适应法、迭代法等.基于边缘检测的图像分割算法对图像边缘进行检测,即检测图像中灰度值发生跳变的地方,将其视为一片区域的边缘,从而完成分割.常用的边缘检测微分算子有 Roberts、Sobel、Prewitt、LoG、Canny 等^[5].基于区域的图像分割算法从一个或多个特定像素开始,比较起始像素和周围像素,将具有相似属性的像素合并到一个区域中,最后获得整个区域完成对目标的提取.常用的方法是区域增长法和拆分合并法.基于聚类的图像分割方法是在同一区域内收集具有相似特征的像素,然后迭代聚类结果直到收敛,最后将所有像素分为几个不同的类别以实现图像区域的划分.随着图像分割任务的要求和复杂性的增加,图像分割方法不断改进,并且出现了许多基于特定理论的分割方法,例如基于遗传理论的分割方法、基于小波变换的分割方法^[6]和基于支持向量机的分割方法等.

传统图像分割方法在植被分割方面又有基于光谱特性的植被提取方法、基于纹理特征的植被提取方法和综合多特征的植被提取方法.植被的光谱具有明显的区别于其他地面物体的特征.由于植被的内部细胞结构和叶绿素的影响,其对电磁波的吸收和反射与其他地面物体明显不同.这种差异可以用作植被提取的重要特征.纹理是物体表面的自然特征,这是一个常见且难以描述的特征.物体图像的纹理通常不显示区域的均匀性,而是部分重复并具有一定的排列规律.纹理分析的基本思想是提取纹理图像中一些易于与其他物质区分开来的特征作为纹理基元,使用纹理基元检查,以找到相同的结构.纹理特征

提取方法的难点在于多特征、多尺度的应用^[7].单个纹理特征无法描述地面对象的特征.如何有效地利用多种特征来描述纹理结构是当前研究的重点.当前用于纹理特征分析的提取方法包括不变纹理特征提取、彩色纹理特征提取和三维纹理特征提取.

地面物体以某些光谱、纹理和形状特征的组合形式出现在图像中.基于光谱特征的识别方法无法解决异物同谱的问题,导致识别和分类不准确.单纯使用纹理特征提取,也不能解决所有类型的识别问题.因此,多特征分割方法已成为当前的研究趋势.基于深度学习的图像分割常用模型有 FCN^[8]、Seg-Net^[9]、GAN^[10]、U-Net 等.区别于传统的机器学习在计算机视觉领域通过人工设计特征,基于深度学习的图像分割法通过支持向量机算法、条件随机场算法、K 近邻算法等对图像特征进行分类以实现目标识别,无需人工设计特征,而是利用反向传播算法在大量数据上自动学习图像特征,相比于人工设计特征更能反映图像的本质特征.

文中基于 YOLO 网络结构,提出一种新的全卷积 F-YOLO (fully convolutional YOLO) 结构网络模型.通过在高分辨率遥感图像上对植被进行识别,对某区域内植被的覆盖度进行估算.文中的研究创新点是通过优化损失函数来提高目标识别精度,同时采用全卷积网络结构来获得像素级的分割结果,最后根据检测出的所有区域大小与整个图像的大小,计算出植被的覆盖度.

2 F-YOLO 模型构建

2.1 模型结构

图 1 为 F-YOLO 中检测部分网络结构图.




图 1 F-YOLO 中检测部分网络结构图

由图1可见,算法网络基于YOLO结构^[11],包含大、中、小3种尺寸,得到特征图的平面尺寸分别是在输入网络图像的基础上扩大了32倍、16倍和8倍.在这个网络结构图中存在两个拼接,通过构建特征金字塔,形成自下而上与自上而下的两条通道.左边自下而上的通道是指普通CNN特征自下而上逐层浓缩表达特征的过程.而右边自上而下的通道将底层的强位置信息与高层的强语义信息相融合,从而对定位和分类进行了综合的提高.

网络结构如图1所示,共有3种尺寸的输出,52×52、26×26、13×13像素是根据特定的网络结构所得出的特征图平面尺寸.而后面的255为通道数,是由网格所对应的先验框数目和类别数目决定的.在网络输出结束后需要有一个解码的过程,将输出的结果进行解码,解码公式为

$$\begin{cases} b_x = (\text{sigmoid}(t_x) + c_x) \times \text{stride}, \\ b_y = (\text{sigmoid}(t_y) + c_y) \times \text{stride}, \end{cases} \quad (1)$$

$$\begin{cases} b_w = p_w e^{t_w} \times \text{stride}, \\ b_h = p_h e^{t_h} \times \text{stride}, \end{cases} \quad (2)$$

$$\begin{cases} \text{conf} = \text{sigmoid}(\text{raw_conf}), \\ \text{prob} = \text{sigmoid}(\text{raw_prob}), \end{cases} \quad (3)$$

式中: b_x 、 b_y 、 b_h 、 b_w 分别为预测框的中心横、纵坐标与高、宽; p_h 和 p_w 分别为先验框的高、宽; t_x 和 t_y 分别为物体中心距离网格左上角位置的横、纵预测偏移量; t_w 和 t_h 分别为物体相对于先验框的宽、高预测偏移量; c_x 和 c_y 分别为网格左上角的横、纵坐标;而 stride 为最后特征图的缩放比例.通过解码得到网络预测的结果,问题是这些预测结果是在之前进行填充后的图片上得出的,与实际图片还有一定的差距.因此,需通过后处理将这些预测结果映射回原图片中,此外还需筛选出类别置信度小于阈值的预测框.在最后一步,进行非极大值抑制,否则会在一个目标物体上出现重叠框体的现象.然后计算框体IoU(intersection over union)值,试验中当IoU值大于设定的阈值时,该框体对应的权重将被置为0.非极大值抑制(non-maximum suppression, NMS)的核心机制是基于IoU阈值过滤重叠预测框,由于顺序处理的原因,运算效率较为低下,通过使用NMS的变体来对其进行改进加速.

2.2 优化损失函数

算法在目标框坐标回归过程中采用均方误差损失函数,在类别和置信度上使用了交叉熵作为损失函数.图像送入神经网络后,将其划分为一个 $S \times S$ 的网格.每个网格生成 N 个候选框,每个候选框最终

通过网络得到相应的边界框.结果得到 $S \times S \times N$ 个边界框,然后使用损失函数确定具体的边界框,计算误差并更新权重.网络的损失函数公式为

$$\begin{cases} \text{LOSS} = A + B + C + D + E, \\ A = \lambda_{\text{coord}} \sum_{i=0}^{s^2} \sum_{j=0}^N I_{ij}^{\text{obj}} [(x_i - \hat{x}_i^j)^2 + (y_i - \hat{y}_i^j)^2], \\ B = \lambda_{\text{coord}} \sum_{i=0}^{s^2} \sum_{j=0}^N I_{ij}^{\text{obj}} [(\sqrt{w_i} - \sqrt{\hat{w}_i^j})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i^j})^2], \\ C = \sum_{i=0}^{s^2} \sum_{j=0}^N I_{ij}^{\text{obj}} [\hat{C}_i^j \log C_i^j + (1 - \hat{C}_i^j) \log(1 - C_i^j)], \\ D = \lambda_{\text{noobj}} \sum_{i=0}^{s^2} \sum_{j=0}^N I_{ij}^{\text{noobj}} [\hat{C}_i^j \log C_i^j + (1 - \hat{C}_i^j) \log(1 - C_i^j)], \\ E = \sum_{i=0}^{s^2} \lambda_c \cdot I_{ij}^{\text{obj}} \sum_{c \in \text{class}} [\hat{P}_i^j \log P_i^j + (1 - \hat{P}_i^j) \log(1 - P_i^j)], \end{cases} \quad (4)$$

式中: λ_{coord} 为坐标损失权重; (x_i, y_i) 为真实中心坐标; $(\hat{x}_i^j, \hat{y}_i^j)$ 为预测中心坐标; w_i^j 和 h_i^j 为真实框的宽高; $\hat{w}_i^j$ 和 $\hat{h}_i^j$ 为输出的边界框宽、高; $\hat{C}_i^j$ 和 C_i^j 分别为真实置信度和预测置信度; λ_{noobj} 为背景损失权重; $\hat{P}_i^j$ 和 P_i^j 分别为真实类别概率和预测类别概率; I_{ij}^{obj} 为指示函数,当第 i 个网格的第 j 个先验框不负责预测任何目标(即背景)时,其值为1,否则为0;参数 I_{ij}^{obj} 表示第 i 个网格的第 j 先验框是否负责这个目标物体,如果负责 $I_{ij}^{\text{obj}} = 1$,否则为0;参数置信度 $\hat{C}_i^j$ 表示真实值, $\hat{C}_i^j$ 的取值是由网格的边界框是否负责预测对象而确定的,负责 $\hat{C}_i^j = 1$,否则为0; A 为目标物体的中心坐标的误差,在训练过程中回归的是中心坐标的偏移量,每个网格都有 N 个候选框,在训练过程中只取重叠度最大的候选框才能负责当前网格的回归; B 为目标物体的宽高坐标差,在训练过程中并不是直接回归目标物体的宽高坐标,而是利用网格本身满足条件的最佳anchor去回归宽高坐标误差的; C 和 D 为目标物体置信度的误差,在训练过程中,不管网格中是否有负责某个目标物体,都会计算置信度误差,但只有少部分空间包含了目标物体,因此需要添加权重对不包含目标物体的置信度损失进行约束; E 为目标物体的分类误差,只有当第 i 个网格的第 j 个候选框负责某个真

实目标物体,这个候选框产生的边界框才会去计算分类损失精度.与经典的 YOLO 模型不同的是,在 E 中,添加了系数 λ_c ,用来处理遮挡或者较小区域的植被识别.在传统 YOLO 模型中,检测框内如果植被区域较少,很容易被识别为非目标,这里通过添加系数,来对框内区域进行计算,其值依赖于框内目标物体的置信度,即误差 C .置信度越大,考虑区域内的像素点越多,当置信度很小时,仅仅考虑中心点附近的区域作为检测目标,因此 λ_c 计算式中 r 表示的是矩形框的内接圆区域的像素点,而下式表示的就是在原有 $LOSS$ 值上增加置信度的惩罚值:

$$\lambda_c = \frac{1}{N} \sum_{i^2+j^2 < r^2} I_{ij} C,$$

(5)

式中: C 为公式(4)中的误差 C ,即负责检测物体的边界框的置信度误差,当 C 越大, λ_c 越大,误差 E 也越大,从而对小物体更加友好.

2.3 语义分割模型

为了获得像素级的分类,文中提出一种新的 F-YOLO 网络.基于 FCN-8 模型,将带有语义的彩色分割图像转化成 $nClasses \times W \times H$ 的标签,标签由 0 和 1 组成,一个通道代表一个类别,不同通道的同一位置上仅有一个 1,表示此像素的正确分类.图 2 为 F-YOLO 中语义分割部分模型示意图.




图 2 F-YOLO 中语义分割部分模型示意图

由图 2 可见,网络由 VGG16 中的卷积池化层加上多层融合的上采样层组成.该设计通过跨层特征融合将浅层细节信息与深层语义信息结合,显著提升了小目标植被的分割精度.因此,将图 2 中网络结构接入上述 YOLO 模型,这样来获得语义分割结果.网络保留了 VGG16 中的卷积和池化层,用于提取图像特征,并将全连接层替换为卷积层,使输出保持二维数据形式,再对特征图进行上采样,还原成原图像大小,逐像素分析像素的类别.VGG16 由 5 个结构重复的卷积池化块、3 个全连接层和 softmax 输出层组成,所有卷积层的卷积核大小都为 3×3 像素,卷积步长为 1 像素,在边缘填充像素以保持卷积后图像大小不发生变化,池化层都选择 2×2 像素的 max pooling,将输入缩小 50%,激活函数都为 ReLU,舍弃小于 0 的值.试验证明 VGG 模型使用连续多个小的卷积核可以替代 1 个大的卷积核,并且通过增加通道数来表示更丰富的图像特征.若减小输入的宽、高,就需要增加通道数以保持不损失过多的信息.网络复制了 VGG16 中的卷积池化层,经过 VGG16 中 5 个 block 的卷积池化操作,此时特征图大小为原图像的 $1/32$;第 5 个 block 的输出经过两层卷积后,其特征图被上采样 2 倍,得到大小为原图

像 $1/16$ 的特征图,融合第 4 个 block 的输出;再进行上采样放大 2 倍,得到大小为原图像 $1/8$ 的特征图,融合第 3 个 block 的输出;最后上采样放大 8 倍,还原成原始图像大小;接下来在各通道的同一位置上使用 softmax 函数,将输入映射为 0 和 1 之间的实数,并量纲一化保证和为 1;各通道同一位置上的值即代表此像素的各通道所表示类别的概率值,取通道概率最大值的类别作为此像素预测结果.

F-YOLO 中的目标分割层通过卷积运算、池化下采样、非线性激活等一系列操作,从输入带分割图像中的原始特征信息提取出高级的图像语义信息,在最后的全连接层将提取到的高级特征映射成一维向量,向量中包含了每个类别的预测概率.对于图像分类任务来说,由于只需要得到整张图像的分类,像素点的空间信息对分类结果不会有影响.但如果进行像素级别的分类,得到每个像素点的类别,空间信息就十分重要.卷积神经网络中的全连接层会使模型丢失二维空间信息.因此,在 F-YOLO 中的语义分割层将 CNN 中紧跟在卷积和池化层后的全连接层换成 1×1 卷积层,得到多通道的二维下采样的特征图,保留了特征图的二维空间信息,同时使得网络可以接收任意大小的输入,输出同样大小的

分割图.其次通过上采样将特征图还原成原始图像大小,各通道对应位置数值为此像素在各类别上的预测概率,概率的最大值所在通道对应类别为此像素预测类别,从而实现像素级分类.

3 试验结果与分析

3.1 数据集获取

试验研究对象是南京市紫金山区域的植被,对

获得的遥感正射图像进行分割处理,每张图片的分辨率为 500×500 像素,共分割出 1 500 张遥感图像作为数据集,部分输入数据如图 3 所示.

针对本次研究的遥感图像,使用 labellmg 工具逐个标注出图像中的植被位置.标注样例数据如图 4 所示,标注过程中统一采用矩形边界框标识植被区域,该策略主要基于 YOLO 架构的矩形检测机制原生兼容性,较多边形标注提升 3~5 倍的效率优势,以及植被覆盖度大致统计而非精细轮廓的核心需求.



图3 部分输入数据



图4 标注样例数据

训练过程中,训练集、测试集和验证集比例是 7 : 2 : 1;在神经网络训练过程中,通过监测 *LOSS* 值来确定最优学习参数。*LOSS* 值会逐渐下降至收敛,此时输出最后参数。

3.2 评价指标

选用准确率 *P*、召回率 *R*、*F* 值对算法进行评价。*P* 显示的是预测为正的样本中有多少是真正的正样本。*R* 显示的是样本中的正例有多少被预测正确了。

F 是在 *P* 和 *R* 出现矛盾时,综合考虑二者,用于评价的一个指标。*P*、*R*、*F* 的表达式分别为

$$P=\frac{TP}{TP+FP}, R=\frac{TP}{TP+FN}, F=\frac{2PR}{P+R}, \quad (6)$$

式中:*TP* 表示实际属于植被,并且正确识别为植被的数量;*FN* 表示实际属于植被,但没有被正确识别为植被的数量;*FP* 表示实际不属于植被,但被识别为植被的数量。通过测试,部分图像的识别情况如图 5 所示。



图 5 部分图像的识别情况

图 5 展示了不同区域地段的植被检测情况,可以看出对于植被的识别较为精准,能够完整地识别出某一区域内的树木。对于乔木、灌木等多种类型的植被都有较高的检测精度。对于有建筑物遮挡的植被,其识别结果的精度也较高。但对于光线较暗、植被本身颜色较深等情况,可能会存在一定的误差。研究为计算区域植被覆盖度提供了很好的依据。精度评估中,实际植被数目 3 685 棵,监测到的植被 3 598 棵,*TP* 值为 3 502,*FP* 为 96,*FN* 为 133。

文中选择了 SSD 和 Faster-RCNN 作为对比算法。SSD 属于单步模型算法,它利用多层网络特征,每一个卷积层都会输出不同大小感受野的特征图。在这些不同尺度的特征图上,进行目标位置和类别的训练和预测,从而达到多尺度检测的目的。该算法在准确度和速度上都有较好的表现。Faster-RCNN 是从 RCNN 算法发展而来的,先通过 CNN 得到特征图,再利用 RPN 网络对特征图上的特征进行检测,输出候选框,最后对候选框进行分类与回归。Faster-RCNN 作为二阶网络,针对高精度、多尺度以及小物

体问题具有优势。表 1 为不同方法下的植被检测结果对比。

表 1 不同方法植被检测结果对比				
方法	主干网络	<i>R</i> /%	<i>P</i> /%	<i>F</i> /%
文中方法	Darknet-53	97.33	96.34	96.83
SSD	VGG-16	88.25	89.11	88.68
Faster-RCNN	VGG-16	90.52	90.67	90.46

由表 1 可见,对植被区域 ROI 进行测试,文中方法得到 *R*、*P*、*F* 的值分别为 97.33%、96.34% 和 96.83%。虽然检测结果仍存在一定的识别误差,但算法整体检测精度已经达到了 96% 以上。相比于传统的植被检测方法,文中方法具有成本更低、准确率更高、时间复杂度更低、鲁棒性更好等优点,可以更加灵活地用于城市植被覆盖度的研究中。文中方法将 CNN 中紧跟在卷积和池化层后的全连接层换成 1×1 卷积层,得到了多通道的二维下采样的特征图,避免了模型丢失二维空间信息,可以接收任意尺度的输入图像,提高了鲁棒性;采用神经网络直接预

估所要检测的目标位置和类别,降低了成本;在网络输出目标检测框后,给出初步定位结果,减少了计算复杂度;修改了损失函数,添加基于目标区域识别的置信度来对目标区域的内接圆部分计算损失函数,提升小区域的检测精度;实现了像素级的分类,因此准确率更高.本网络结构是端到端的检测网络,逐像素回归,其回归的几何精度为1像素.而输入图片分辨率越高,产生的预测框也就越多,从而提升精度.相比于SSD和Faster-RCNN,文中方法在准确率和识别速度上都体现了较好的性能,测试精度较高.

试验结果同时显示,文中的网络结构对于遥感图像中细小地物的检测精度高于经典YOLO模型.经典YOLO模型中惩罚小框因子的存在使得被遮挡的地物难以被识别,文中的损失函数对此进行优化,增强对细小地物特征的捕获能力,从而提升检测精度,如图5中不同尺度下的车辆与灌木.

对于像素级试验结果的评估,文中对比了FCN-32和FCN-16.FCN-32将在第5个block后的两层卷积层的输出、大小为原图像的1/32的热力图上直接进行32倍上采样,恢复原图像大小;FCN-16针对第5个block后的两层卷积层的输出,上采样放大两倍,融合第4个block的输出,大小为原图像的1/16,进行16倍上采样恢复原图像大小.优化过程中使用Adam优化器,在学习率为 10^{-4} 时,精确度在82%左右徘徊,于是调整学习率至 10^{-5} ,精确度提升到93%.试验对比结果如表2所示.

表2 试验对比结果

模型	像素精确率/%
文中方法	94.76
FCN-16	93.15
U-Net	91.75
FCN-32	83.86

由表2可见,文中方法像素精确率达到94.76%,优于其他模型,具有较好的分割像素精确率.模型检测结果和真实值对比如图6所示,左、中、右分别是真实图像、标注信息和文中模型检测结果.

最后,以植被覆盖度FVC对算法进行评价,其计算式为

$$FVC = \frac{\sum_{i=1}^n l_k w_k}{LW}, \quad (7)$$

式中: n 为该图中回归框的总数; L 为图像的长; W

为图像的宽; l_k 为第 k 个回归框的长; w_k 为第 k 个回归框的宽.统计得到南京紫金山植被覆盖度约为7.83%.




图6 模型检测结果和真实值对比

表3 为不同方法试验结果对比.

表3 不同方法试验结果对比

方法	植被覆盖度/%	精确度/%
文中方法	7.83	96.72
目估法	6.54	85.62
仪器法	7.12	92.34

从表3中可以直观地看出,文中方法在植被覆盖度测算的精确度上有着较好的表现.主要因为提出的网络可以自动地提取图像特征和提高植被检测的精度.而采用传统的目估法和仪器法所得到的试验结果,相比于文中方法其精确度都较低.

4 结 论

1) 将文中提出的改进F-YOLO模型与FCN-32、FCN-16和U-Net模型的试验结果进行对比,结果表明改进的模型在紫金山植被数据集上的成绩要优于其他模型,达到了94.76%的像素精确率,而植被覆盖度测算的像素精确率达到96.72%.

2) 虽然精度有所提升,研究仍存在局限:分割结果精细度不足,上采样导致模糊和平滑;模型缺乏空间一致性,未充分考虑像素间关系并忽略空间规整步骤(如条件随机场);试验数据主要依赖高质量图像,对低光照、低清晰度环境及高分辨率下小目

标的识别鲁棒性不足;基于 YOLO 规则检测框的计算方式与现实不规则植被形态存在误差.未来工作将考虑后端引入条件随机场优化空间一致性,扩展数据集覆盖多样环境,并探索不规则植被覆盖度的精确计算方法.

参考文献 (References)

[1] 张淑梅. 郑州城市森林景观肌理演化过程与调控路径[D]. 郑州: 河南农业大学, 2021.

[2] 余翔, 庞志濠. 融合 FEB 的 YOLOX 遥感图像目标检测算法[J]. 重庆邮电大学学报(自然科学版), 2024, 36(2): 319-327.

YU X, PANG Z H. YOLOX remote sensing image object detection algorithm based on FEB [J]. Journal of Chongqing University of Posts and Telecommunications (Natural Science Edition), 2024, 36(2): 319-327. (in Chinese)

[3] YU X L, GUO X L. Extracting fractional vegetation cover from digital photographs: a comparison of in situ, SamplePoint, and image classification methods[J]. Sensors, 2021, 21(21): 7310.

[4] KAMILARIS A, PRENAFETA-BOLDÚ F X. Deep learning in agriculture: a survey[J]. Computers and Electronics in Agriculture, 2018, 147: 70-90.

[5] DONG W, PENG D L, LIU X, et al. Eight direction improved sobel algorithm based on morphological processing in 5G smart grid[C] // Proceedings of the 2021 2nd International Conference on Computing, Networks and Internet of Things. New York: ACM, DOI: 10.1145/3468691.3468721.

[6] 谷昱良, 羿旭明. 基于小波变换的权重自适应图像分割模型[J]. 图学学报, 2020, 41(5): 733-739.

GU Y L, YI X M. Adaptive weights image segmentation

model based on wavelet transform[J]. Journal of Graphics, 2020, 41(5): 733-739. (in Chinese)

[7] 刘春娟, 辛钰强, 吴小所, 等. 基于多尺度特征融合的遥感图像变化检测网络[J]. 四川大学学报(自然科学版), 2024, 61(6): 121-131.

LIU C J, XIN Y Q, WU X S, et al. Remote sensing image change detection network based on multi-scale dense fusion[J]. Journal of Sichuan University (Natural Science Edition), 2024, 61(6): 121-131. (in Chinese)

[8] CHEN G Z, TAN X L, GUO B B, et al. SDFCNv2: an improved FCN framework for remote sensing images semantic segmentation [J]. Remote Sensing, 2021, 13(23): 4902.

[9] BADRINARAYANAN V, KENDALL A, CIPOLLA R. SegNet: a deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(12): 2481-2495.

[10] JOZDANI S, CHEN D M, POULIOT D, et al. A review and meta-analysis of generative adversarial networks and their applications in remote sensing [J]. International Journal of Applied Earth Observation and Geoinformation, 2022, 108: 102734.

[11] 李国进, 黄晓洁, 李修华. 基于改进 YOLOv3 的树上成熟芒果检测方法[J]. 沈阳农业大学学报, 2021, 52(1): 70-78.

LI G J, HUANG X J, LI X H. Detection method of tree-ripe mango based on improved YOLOv3 [J]. Journal of Shenyang Agricultural University, 2021, 52(1): 70-78. (in Chinese)

(责任编辑 梁家峰)