

基于注意力增强 YOLO 的苹果茎检测方法研究

肖尧¹, 朱素杰¹, 吴强²

(1. 河南科技职业大学 信息工程学院, 河南 周口 466000; 2. 安徽建筑大学 电子与信息工程学院, 合肥 230088)

摘要: 针对水果采摘后果茎去除消耗人力多而影响果实品质和市场价值的问题, 开发精准、高效的果实与茎自动化检测技术势在必行。为此, 创新性地提出了基于注意力机制增强(Attention Mechanism Enhanced)的 YOLO 模型 AME-YOLO, 通过引入幽灵瓶颈结构和全局注意力机制对 YOLO 模型进行改进, 专门用于苹果茎检测。幽灵瓶颈的运用显著降低了模型参数量且提高了计算效率, 而全局注意力机制则增强了特征提取能力。试验结果表明: AME-YOLO 模型在各项指标上表现优异。其中, 平均精度 mAP@50 为 0.956, mAP@50-95 为 0.782, 同时保持 120 f/s 的实时处理速度。该模型为农业自动化提供了具有实际应用价值的解决方案, 并将有效推动水果智能采收技术的发展。

关键词: 苹果茎检测; YOLO 模型; 全局注意力机制; 幽灵瓶颈

中图分类号: S126; TP399

文献标志码: A

文章编号: 1003-188X(0000)00-0000-00

肖尧, 朱素杰, 吴强. 基于注意力增强 YOLO 的苹果茎检测方法研究[J]. 农机化研究

XIAO Yao, ZHU Sujie, WU Qiang. Research on apple stem detection method based on attention enhanced YOLO[J]. Journal of agricultural mechanization research

0 引言

近年来, 农业机械化技术不断发展, 显著提升了作物的采收效率, 并降低了作业成本^[1]。作为全球重要经济作物之一, 苹果采收后去除茎秆时如何精准识别果实与茎秆连接部位对于保持果实新鲜度和减少采后损伤至关重要^[2,3]。目前, 茎秆分离工序仍高度依赖人工, 在采收旺季需要投入大量劳动力, 实现该环节的自动化亟需计算机视觉与深度学习技术相结合的高精度检测方案。

计算机视觉领域的研究表明: 传统检测方法^[4-10]虽能有效定位果实轮廓, 但对茎秆等微小区域的识别仍存在明显不足。一般采集的苹果图像中, 茎秆区域的像素占比远低于果实, 需要更高精度的识别算法。为此, 基于深度学习的检测模型应运而生, 为解决此难题提供了更精细的解决方案。现有国外技术(如多模态融合方法^[11]和双阶段 CNN 模型^[12-13])虽然在精度上取得了一定进展, 但是存在处理速度瓶颈。

以 Mask R-CNN^[14]为例, 尽管其在复杂环境下能达到 91.4% 的检测准确率^[13], 但单帧处理耗时 1.18 s, 难以满足实时作业需求。多模态方案^[11]通过融合 RGB 与近红外(NIR)图像提升了精度, 但存在模态对齐耗时长、设备成本高等问题, 且需要额外照明设备,

在实际农业场景的应用价值受到限制。

国内研究偏重于对现有 YOLO 模型进行改进^[15-20]。随着 YOLO 架构的发展, 最新的版本已迭代到 YOLOv11 和 YOLOv12。YOLOv11 引入更轻量的 RepViT 骨干网络与改进的任务解耦头, 有效提升小目标检测精度与推理效率。YOLOv12 在此基础上加入动态卷积与稀疏激活策略, 进一步减少计算开销, 同时提出置信度引导的损失重加权方法, 优化训练效果。

本研究提出了一种名为 AME-YOLO 的优化模型, 通过引入 3 项关键技术, 在目标检测任务中有效实现了性能与效率的平衡。首先, 模型引入 Ghost 瓶颈模块^[21], 通过简化卷积操作生成冗余特征, 显著减少参数量, 在保持特征表达能力的同时大幅提升计算效能; 其次, 整合全局注意力机制(Global Attention Mechanism, GAM)^[22], 通过跨通道与空间维度的注意力加权, 增强对关键区域的特征响应, 从而显著提升复杂背景下农作物茎秆区域的识别精度; 最后, 为验证模型在实际场景中的性能, 研究团队自建了高质量 Apple Stem Detection(AS-Det)数据集, 涵盖多角度、多光照和遮挡条件下的苹果茎秆图像。试验结果表明, AME-YOLO 在保持高精度的同时, 在 NVIDIA GeForce RTX 3070 平台上可实现 48 f/s 的实时处理速度, 能够有效满足农业实际应用中对高效、精准检测的需求。

1 原理

1.1 整体架构

图 1 为所提出方法的完整处理流程。步骤①: 系

收稿日期: 2025-08-04

基金项目: 安徽省重点研究与开发计划项目(202004a07020050)

作者简介: 肖尧(1985-), 男, 河南周口人, 讲师, (E-mail) xiaoyao1985xx@126.com。

统接收不同环境条件下采集的苹果 RGB 图像作为输入。步骤②: 考虑到原始图像尺寸存在差异, 系统会进行尺寸归一化处理, 将所有输入统一调整为 640×640 像素的标准尺寸。步骤③: 经过预处理的图像输入到 AME-YOLO 模型进行苹果果实与茎秆的检测识别。步骤④: 模型输出的检测结果会生成对应的二值掩码。步骤⑤~⑥: 分离出检测目标的边界和区域信息。




图 1 所提出方法的流程图
Fig. 1 Flowchart of the proposed method

1.2 AME-YOLO 模型

AME-YOLO 以 YOLOv8 为基础框架, 通过引入幽灵瓶颈(Ghost Bottleneck) 和 GAM 优化检测性能, 在保证实时性的同时提升精度, 速度和准确度较高。

AME-YOLO 的整体架构采用模块化设计, 各层参数(包括卷积核尺寸、步长和填充方式) 在试验中详细列出, 如图 2 所示。Ghost Bottleneck 通过减少冗余计算提升推理效率, 而 GAM 则增强模型对茎秆等细小目标的特征提取能力, 从而优化检测效果。




图 2 AME-YOLO 模型架构
Fig. 2 Architecture of the AME-YOLO model

AME-YOLO 的核心主干基于 YOLOv8 框架, 并创新性地集成了幽灵瓶颈模块, 以显著降低计算复杂度并提升运算效率。幽灵瓶颈作为一种轻量化技术, 通过优化传统卷积操作, 在减少参数数量的同时保留关键特征信息, 从而确保模型在实时应用中的高效表现。该主干网络采用多尺度特征提取策略, 通过卷积层与

幽灵瓶颈的协同作用, 在不同分辨率下高效捕获图像的关键特征, 实现计算资源的最优分配。

AME-YOLO 的颈部设计融合了跨阶段部分瓶颈(CSP) 与双重卷积模块: 1 个高效的 C2f 块和 1 个 GAM 模块。这种组合架构专门用于捕获图像的全局上下文特征。GAM 模块通过自适应权重分配, 使模型能够聚焦于关键视觉区域, 显著提升对复杂目标(如苹果果实) 和微小目标(如苹果茎) 的检测能力。该颈部结构通过上采样和特征拼接技术, 有效整合了来自主干网络的多尺度特征, 不仅增强了模型的表征能力, 还显著提高了目标检测的定位精度。特别是对于茎秆等细小目标的识别, 这种设计能够更好地保留空间细节信息, 从而优化最终的检测效果。

AME-YOLO 的头部结构专门用于生成精确的检测结果, 能够清晰区分果实与茎秆的边界轮廓。该检测头采用多类别预测机制, 不仅可以准确识别苹果主体, 还能精细检测出茎秆区域, 实现不同类别目标的精准区分。该头部结构具有强大的多尺度处理能力, 既能处理苹果这类较大目标, 又能精确捕捉茎秆等细小目标, 显著提升了模型在复杂农业场景应用中的实用性和可靠性。通过优化特征融合策略, 检测头确保了各类物体边界的完整性, 特别适合完成果实与茎秆这类尺寸差异显著的目标检测任务。

1.3 幽灵瓶颈

AME-YOLO 模型中的幽灵瓶颈模块通过巧妙地融合幽灵模块、SE(挤压激励) 层和深度可分离卷积(DW-Conv), 实现了计算效率的最大化提升, 如图 3 所示。




图 3 幽灵瓶颈(Ghost Bottleneck) 模块架构
Fig. 3 Architecture of the Ghost Bottleneck module

该模块采用双路径并行处理机制, 具体如下: 首先, 主路径通过幽灵模块提取核心特征; 然后, SE 层基于跨步条件对关键通道信息进行选择性增强, 由第 2 个幽灵模块补充生成高级特征; 最后, 快捷路径根据输入、输出维度匹配情况, 智能选择恒等映射或 DW-Conv 结合 1×1 卷积的调整策略。通过双路径特征的

有机融合,该模块在显著降低计算开销的同时,仍能保持高效的特征表达能力,从而为 AME-YOLO 实现实时、高性能处理提供了关键支撑。

1.4 全局注意力机制

AME-YOLO 模型中的 GAM 模块通过同时处理特征图的通道和空间维度信息,显著提升了模型的特征提取能力,如图 4 所示。该模块采用双分支结构设计,通过通道注意力分支和空间注意力分支的协同工作,分别对输入特征进行动态权重调整。通道注意力分支分析各特征通道的重要性并重新分配权重,而空间注意力分支则聚焦于特征图的关键空间区域。这种双重注意力机制使模型能够自适应地强化最具判别性的特征,有效提升对苹果和茎秆等目标的识别精度,从而优化整体检测效果。




图 4 全局注意力机制架构

Fig. 4 Architecture of the Global Attention Mechanism

通道注意力机制通过动态评估各特征通道的重要性来增强模型的特征选择能力。首先,该机制对输入特征图 X 进行全局平均池化 (GAP) 操作,将空间维度信息压缩为通道描述向量;然后,该向量经过两个全连接层处理采用 Sigmoid 激活函数生成各通道的权重系数。这种设计使得模型能够自适应地强化重要特征通道并抑制冗余信息,实现了对特征通道的智能加权,有效提升了模型的特征表达能力。其完整的数学表达式为

$$A_c = \zeta(W_2 \cdot \tau(W_1 \text{GAP}(X))) \quad (1)$$

式中: W_1 和 W_2 分别为卷积层的权值, τ 和 ζ 分别为 Sigmoid 线性单元 (SiLU) 激活函数和 Sigmoid 函数,计算出的通道注意力图 A_c 决定了输入特征图中每个通道的重要性。

将 A_c 乘以输入特征图 X ,最终得到反映通道重要性的特征图 X_c 为

$$X_c = X A_c \quad (2)$$

在应用通道注意之后, GAM 应用空间注意来确定每个空间位置的重要性。输入特征映射 X_c 经过两个卷积层,然后应用 Sigmoid 函数计算每个空间位置的重要性 A_s 。

$$A_s = \zeta(W_4 \cdot \tau(W_3 X_c)) \quad (3)$$

式中: W_3 、 W_4 为卷积层的权重,空间注意力图 A_s 为每个空间位置的重要性。

将 A_s 乘以 X_c ,最终得到反映空间位置重要性的特征图 X_s 为

$$X_s = X_c A_s \quad (4)$$

GAM 模块通过同时聚焦特征图的通道维度和空

间位置,显著提升了模型对关键目标的识别能力和细节特征的捕捉精度。这种双重注意力机制使网络能够智能地强化输入特征中最具判别性的区域,从而在复杂场景中实现更准确的物体检测和更精准的细节检测。通过动态调整通道权重和空间关注点, GAM 有效增强了模型对苹果茎秆等细小结构的表征能力,大幅提升了整体检测性能。

2 试验

2.1 试验数据集

本研究构建的 AS-Det 数据库整合了公开水果数据集的标注数据与自主采集的样本。数据采集采用 Intel RealsenseTM D405 相机,该设备具备 $87^\circ \times 58^\circ$ 视场角,工作距离 7 ~ 50cm,最高支持 1 280 × 720 分辨率。

试验设计了开放桌面环境(多角度拍摄桌上苹果)、封闭暗室(精确控制光照条件避免干扰)和配备转盘的透明亚克力箱(实现苹果 360° 旋转拍摄) 3 种典型场景,如图 5 所示。这 3 种配置分别模拟了自然光照、实验室控制和动态旋转条件下的数据采集环境。




图 5 采集数据的 3 种试验配置

Fig. 5 Three experimental configurations for data collection

AS-Det 数据库的具体构成如表 1 所示。该数据库按照 7 : 2 : 1 的比例划分为训练集、测试集和验证集,分别用于模型训练、性能测试和最终验证。为提升模型泛化能力并防止过拟合,研究采用了包括 Dropout、马赛克增强、图像翻转和像素位移等多种数据增强技术。这些方法通过在训练过程中引入多样性数据,有效增强了模型对未见过数据的适应能力,从而显著提高了系统的鲁棒性。

表 1 AS-Det 数据库具体划分

Table 1 Detailed division of the AS-Det database

设定	训练	验证	测试
开放式桌面	196	28	56
封闭黑暗室	83	11	23
透明箱子带转盘	182	26	52
开放数据库	421	61	121
总计	882	126	252

2.2 AME-YOLO 模型的训练

AME-YOLO 模型基于 AS-Det 数据集进行训练与验证,采用 500 个 Epoch 的训练周期并设置早停机制(当验证损失连续 100 个 Epoch 未改善时终止训练),有效防止了过拟合现象。训练过程中配置了 0.937 的动量参数、0.000 5 的权重衰减和 0.01 的初始学习率。

2.3 AME-YOLO 模型的消融试验

为了评估所提出的模块对 YOLOv8 性能的贡献,本文进行了消融研究。在一致的试验条件下,对这些模型进行了苹果和茎分割的训练和评估,并使用精度、召回率、mAP@50 和 mAP@50-95 来测量性能。模块消融定量对比的结果如表 2 所示。

表 2 模块消融定量对比
Table 2 Quantitative comparison of module ablation

方法	类别	准确率	召回率	mAP@50	mAP@50-95	处理速度/(f/s)	Param/M
YOLOv8	全部	0.942	0.886	0.935	0.757	114.9	43
	苹果	0.998	1.000	0.995	0.990		
	茎秆	0.886	0.771	0.875	0.523		
YOLOv8 + Ghost	全部	0.969	0.869	0.941	0.761	122.7	32
	苹果	0.999	1.000	0.995	0.985		
	茎秆	0.939	0.737	0.888	0.536		
YOLOv8 + GAM	全部	0.900	0.948	0.954	0.772	110.5	47
	苹果	0.998	1.000	0.995	0.989		
	茎秆	0.803	0.897	0.913	0.555		
YOLOv8 + GAM + Ghost (AME-YOLO)	全部	0.943	0.932	0.956	0.782	120.2	36
	苹果	0.999	1.000	0.995	0.989		
	茎秆	0.888	0.864	0.916	0.574		

基线 YOLOv8 模型的总体 mAP@50 为 0.935, mAP@50-90 为 0.757。虽然该模型在苹果分割方面表现良好,但其在茎秆分割方面的性能相对较差,可能是由于对象大小和遮挡等问题所导致的。将 Ghost 瓶颈纳入 YOLOv8,将总体 mAP@50 提高到 0.941, mAP@50-95 提高到 0.761。值得注意的是,茎秆分割的精度从 0.886 显著提高至 0.939,展示了 Ghost 瓶颈提高计算效率的能力,同时提高了复杂特征的分割精度。将 GAM 模块添加到 YOLOv8,显著提高了召回率和 mAP@50-95,表明 GAM 模块捕获全局上下文信息的能力特别有利于茎秆分割。Ghost+GAM+AME-YOLO 组合整体表现最好, mAP@50 为 0.956, mAP@50-95 为 0.782。该模型保持了苹果分割的高准确率和召回率,同时显著提高了茎秆分割准确率和召回率之间的平衡性。

由参数数量和运行效率可以看出:在原始 YOLOv8 模型基础上,只加入 Ghost 瓶颈模块,实现了最高的参数精简和 122.7 f/s 的处理速度;只加入 GAM 模块,虽然增加了模型参数量,达到最高 47 M,但是模型精

度上升。综合来看,本文的 AME-YOLO(同时引入 Ghost 和 GAM 模块)达到了最均衡的参数数量 36 M 和 120.2 f/s 的处理速度,同时获得了较高的分割精度。

2.4 AME-YOLO 模型的测试

AME-YOLO 模型的评估采用精度 P(Precision)、召回率 R(Recall)、mAP@50 和 mAP@50-95 等 4 个核心指标,分别从不同维度衡量模型在目标检测任务中的性能表现。其中,P 值反映模型预测结果的可靠性,计算公式为 $P = TP / (TP + FP)$,体现模型在避免误检方面的能力;R 值则表征模型发现目标的能力,计算公式为 $R = TP / (TP + FN)$,评估模型对数据集中真实目标的覆盖程度。在目标检测领域,mAP(mean Average Precision)是最具代表性的综合性能指标:mAP@50 基于 0.5 的交并比(IoU)阈值计算平均精度,主要评估预测框与真实标注在宽松标准下的匹配质量;而更具挑战性的 mAP@50-95 指标则通过 0.5~0.95 范围内(步长 0.05)的 10 个 IoU 阈值进行综合评估,不仅检验模型在精确定位方面的能力,还能反映模型在不同匹配严格度下的稳定性和鲁棒性。值

得注意的是, $mAP@50-95$ 对边界框的定位精度要求更高, 能更全面地评估模型在实际应用场景中的表现。试验结果表明: 通过这种多维度的评估方案, 可以更准确地评价模型在不同应用场景下的优缺点。

本研究通过对比试验验证了 AME-YOLO 模型的优越性能, 将其与 Mask R-CNN^[14]、YOLACT^[23]、YOLOv8^[24] 和 YOLOv11^[25] 等当前主流方法进行了全面比较, 如表 3 所示。在检测精度、检测质量和推理速度的综合评估中, AME-YOLO 展现出显著优势。特

别值得注意的是, 该模型在保持最快推理速度的同时, 在大多数评估指标上均超越其他方法。虽然现有方法在苹果主体检测方面表现良好, 但在茎秆这类细小目标的检测上存在明显不足。AME-YOLO 以 0.674 的 $mAP@50-95$ 分数在边界框检测中领先, 显著优于 YOLOv8(0.597) 和 YOLOv11(0.664), 充分证明了其在细小目标检测方面的独特优势。这一结果验证了 AME-YOLO 模型在处理农业场景中典型的大小目标共存问题时具有更强的适应性和精确性。

表 3 本文方法和其他主流方法的检测结果定量对比

Table 3 Quantitative comparison of detection results between the proposed method and other mainstream methods							
方法	类别	P	R	$mAP@50$	$mAP@50-95$	处理速度/(f/s)	Param/M
Mask R-CNN ^[14]	全部	0.820	0.959	0.942	0.762	49.5	63
	苹果	1.000	1.000	0.990	0.970		
	茎秆	0.640	0.917	0.893	0.553		
YOLACT ^[23]	全部	0.876	0.897	0.913	0.536	51.9	53
	苹果	0.990	1.000	0.988	0.731		
	茎秆	0.762	0.793	0.827	0.341		
YOLOv8 ^[24]	全部	0.940	0.890	0.949	0.795	114.9	43
	苹果	0.998	1.000	0.995	0.992		
	茎秆	0.881	0.780	0.903	0.597		
YOLOv11 ^[25]	全部	0.921	0.939	0.995	0.827	111.4	40
	苹果	0.997	1.000	0.995	0.990		
	茎秆	0.845	0.878	0.921	0.664		
AME-YOLO	全部	0.943	0.932	0.960	0.833	120.2	36
	苹果	0.999	1.000	0.995	0.991		
	茎秆	0.888	0.864	0.924	0.674		

AME-YOLO 展现出卓越的实时处理能力, 处理速度达到 120.2 f/s, 较 YOLOv8(114.9 f/s) 和 YOLOv11(111.4 f/s) 分别提升 4.6% 和 7.32%。相比之下, Mask R-CNN(49.5 f/s) 基于迭代处理的架构在速度上明显落后, 难以满足实时应用需求。在检测精度方面, AME-YOLO 对苹果主体准确率为 0.999、召回率为 1.0, 近乎完美, 同时在茎秆检测上也表现出色(精度为 0.888, $mAP@50-95$ 为 0.674)。尽管 YOLOv11 在整体边界框检测上 $mAP@50-95$ 为 0.827, 但其在小目标检测任务上的表现仍不及 AME-YOLO。这种差距主要源于 YOLOv11 采用的 Transformer 模块和自适应空间融合机制带来的计算负担, 虽然增强了上下文理解能力, 却导致推理时间增加, 并在处理茎秆等

细粒度结构时面临模型容量限制。此外, YOLOv11 在较小目标类别上出现的召回率下降现象, 也反映出其在有限样本类别上的泛化能力存在不足。

AME-YOLO 通过巧妙地整合 GAM 模块与幽灵瓶颈结构, 在检测精度与处理速度之间实现了最佳平衡。这种设计既增强了全局特征提取能力, 又显著降低了计算复杂度, 使模型能够同时高效处理不同尺度的目标, 成为实时应用场景的理想选择。AME-YOLO 的检测效果明显优于其他先进方法, 不仅能准确识别整个茎秆区域(避免将人手误判为茎秆), 而且在水果主体检测上也表现出卓越的鲁棒性, 更接近人工标注的苹果和茎秆的分割真值。本文方法与其他主流方法在数据集上的检测效果定性对比如图 6 所示。试

验数据与可视化结果共同证实: AME-YOLO 不仅在小目标检测精度上领先现有方法,而且保持了出色的实时性能,为农业场景下的目标检测任务提供了可靠的技术方案。




图 6 本文方法与其他主流方法在数据集上的检测效果定性对比

Fig. 6 Qualitative comparison of detection effects between the proposed method and other mainstream methods on the dataset

3 结 论

本研究提出的 AME-YOLO 模型创新性地融合幽灵瓶颈和全局注意力模块,基于 YOLOv8 架构实现了果实与茎秆的高效检测,为自动化采收机器人提供了可靠的技术方案。该研究通过算法优化和架构创新,在农业自动化检测领域取得显著突破,具有重要的理论价值和应用前景。

1) 在性能方面,AME-YOLO 模型在计算效率和检测精度上实现双提升,在 GPU 平台达到 120.2 f/s 的实时处理速度,并在 mAP@50 和 mAP@50-95 指标上表现优异。该模型特别擅长茎秆等细小目标的检测,相比现有模型具备更快的响应速度和更高的检测精度,充分满足农业自动化场景的实时性需求。

2) 在应用价值方面,该模型为采收机器人的去茎操作提供了可靠的解决方案,同时其技术框架可拓展至其他农业智能化场景,如作物监测、病虫害识别等。这一创新不仅推动了水果采收环节的自动化进程,而且为智慧农业的发展提供了新的技术支撑。

3) 在未来发展方面,AME-YOLO 模型具备广阔的优化空间。后续研究将重点发展三维图像检测能力,实现对果实形态、尺寸和空间位置的精确建模,并进一步提升模型在多变光照、复杂背景和遮挡环境下的适应能力。这些改进方向将显著增强模型在复杂农业场景中的实用性和鲁棒性,推动农业智能化技术的深入应用。

参考文献:

[1] ZIV C, FALLIK E. Postharvest storage techniques and quality evaluation of fruits and vegetables for reducing food loss [J]. *Agronomy*, 2021, 11(6): 1133.

[2] YU J F, ZHANG Z, MHAMED M, et al. Apple's in-field grading and sorting technology: a review [M]//Towards Unmanned Apple Orchard Production Cycle. Singapore: Springer Nature Singapore, 2023: 81-104.

[3] VALENZUELA J L. Advances in postharvest preservation and quality of fruits and vegetables [J]. *Foods*, 2023, 12(9): 1830.

[4] STAJNKO D, LAKOTA M, HO EVAR M. Estimation of number and diameter of apple fruits in an orchard during the growing season by thermal imaging [J]. *Computers and electronics in agriculture*, 2004, 42(1): 31-42.

[5] ZHAO J, TOW J, KATUPITIYA J. On-tree fruit recognition using texture properties and color data [C]//2005 IEEE/RSJ International Conference on Intelligent Robots and Systems. IEEE, 2005: 263-268.

[6] COHEN O, LINKER R, NAOR A. Estimation of the number of apples in color images recorded in orchards [M]//Computer and Computing Technologies in Agriculture IV. Berlin/Heidelberg: Springer, 2011: 630-642.

[7] LINKER R, COHEN O, NAOR A. Determination of the number of green apples in RGB images recorded in orchards [J]. *Computers and electronics in agriculture*, 2012, 81: 45-57.

[8] KURTULMUS F, LEE W S, VARDAR A. Green citrus detection using 'eigenfruit', color and circular Gabor texture features under natural outdoor conditions [J]. *Computers and electronics in agriculture*, 2011, 78(2): 140-149.

[9] ZHOU R, DAMEROW L, SUN Y R, et al. Using colour features of cv. 'Gala' apple fruits in an orchard in image processing to predict yield [J]. *Precision agriculture*, 2012, 13(5): 568-580.

[10] CHAIVIVATRAKUL S, DAILEY M N. Texture-based fruit detection [J]. *Precision agriculture*, 2014, 15(6): 662-683.

[11] LIU C, FENG Q C, SUN Y H, et al. YOLACTFusion: an instance segmentation method for RGB-NIR multimodal image fusion based on an attention mechanism [J]. *Computers and electronics in agriculture*, 2023, 213: 108186.

[12] HUSSAIN M, HE L, SCHUPP J, et al. Green fruit segmentation and orientation estimation for robotic green fruit thinning of apples [J]. *Computers and electronics in agriculture*, 2023, 207: 107734.

[13] LÓPEZ-BARRIOS J D, ESCOBEDO CABELLO J A, GÓMEZ-ESPINOSA A, et al. Green sweet pepper fruit and peduncle detection using mask R-CNN in greenhouses [J]. *Applied sciences*, 2023, 13(10): 6296.

[14] HE K M, GKIOXARI G, DOLLAR P, et al. Mask R-CNN [C]//2017 IEEE International Conference on Computer Vision (ICCV). IEEE, 2017: 2980-2988.

[15] 胡仕林, 陈伟, 张境锋, 等. 基于改进 YOLO v5 的苹果采摘机器人目标检测方法 [J]. *农机化研究*, 2024, 46

- (6): 48–55.
- [16] 张境锋, 陈伟, 魏庆宇, 等. 基于 Des-YOLO v4 的复杂环境下苹果检测方法 [J]. 农机化研究, 2023, 45(5): 20–25.
- [17] 温彬彬, 张华, 孟祥龙. 基于改进 YOLO v5 的轻量化苹果检测方法 [J]. 江苏农业科学, 2024, 52(12): 217–223.
- [18] 马保建, 邱媛媛, 陈棒棒, 等. 基于改进 YOLO v8n 轻量化模型的苹果识别方法 [J]. 石河子大学学报(自然科学版), 2025, 43(2): 143–151.
- [19] 曾林涛, 马嘉昕, 丁羽, 等. 基于改进 YOLO v8 的苹果叶部病害检测方法 [J]. 江苏农业科学, 2025, 53(5): 147–156.
- [20] 高昂, 吴昆, 宋月鹏, 等. 基于 LT-YOLO 检测与机器视觉的苹果激光疏花试验台参数优化与试验 [J]. 农业机械学报, 2025, 56(2): 393–401.
- [21] Han K, Wang Y, Tian Q, et al. Ghostnet: More Features from Cheap Operations [C] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 1580–1589.
- [22] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [J]. Advances in neural information processing systems, 2017, 30.
- [23] BOLYA D, ZHOU C, XIAO F Y, et al. YOLACT: real-time instance segmentation [C] // 2019 IEEE/CVF International Conference on Computer Vision (ICCV). IEEE, 2019: 9156–9165.
- [24] YASEEN M. What is YOLOv8: An in-depth exploration of the internal features of the next-generation object detector. [J]. arXiv preprint arXiv: 2408.15857, 2024.
- [25] KHANAM R, HUSSAIN M. YOLOv11: An overview of the key architectural enhancements [J]. arXiv preprint arXiv: 2410.17725, 2024.

Research on Apple Stem Detection Method Based on Attention Enhanced YOLO

Xiao Yao¹, Zhu Sujie¹, Wu Qiang²

(1. School of Information Engineering, Henan University of Science and Technology, Zhoukou 466000, China; 2. School of Electronic and Information Engineering, Anhui Jianzhu University, Hefei 230088, China)

Abstract: Aiming at the problem that stem removal consumed a lot of manpower and affected fruit quality and market value after fruit picking, it was imperative to develop accurate and efficient automatic detection technology for fruit and stem. To this end, a YOLO model AME-YOLO based on Attention Mechanism Enhanced was innovatively proposed. The YOLO model was improved by introducing the ghost bottleneck structure and the global attention mechanism, which was specially used for apple stem detection. The use of the ghost bottleneck significantly reduced the number of model parameters and improved the computational efficiency, while the global attention mechanism enhanced the feature extraction capability. The experimental results showed that AME-YOLO performed well in various indicators. Among them, the average accuracy mAP@50 was 0.956, mAP@50–95 was 0.782, while maintaining a real-time processing speed of 120 f/s. This model provided a solution with practical application value for agricultural automation, and will effectively promote the development of fruit intelligent harvesting technology.

Key words: apple stem detection; YOLO model; global attention; Ghost Bottleneck