



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: 改进 RTDETR 的葡萄叶病害实时检测算法
作者: 王启明, 于千城, 杨文跃, 穆洪锐, 李易臻
网络首发日期: 2025-10-24
引用格式: 王启明, 于千城, 杨文跃, 穆洪锐, 李易臻. 改进 RTDETR 的葡萄叶病害实时检测算法[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20251023.1840.013>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

改进 RTDETR 的葡萄叶病害实时检测算法

王启明¹, 于千城^{1,2}, 杨文跃^{1,3}, 穆洪锐¹, 李易臻¹

- 1.北方民族大学 计算机科学与工程学院, 银川 750021
- 2.图形图像国家民委重点实验室, 银川 750021
- 3.宁夏工商职业技术学院 信息网络中心, 银川 750021

摘要: 葡萄叶病害的实时检测对保障葡萄产业可持续发展至关重要, 针对现有检测模型在复杂田间场景下存在的计算冗余、实时性不足及小目标漏检等问题, 提出了一种基于 RTDETR 的病害检测模型 PVSA-RTDETR。首先采用极简骨干网络 PVNet 替换 HGNetV2, 增强病斑边缘的特征提取能力, 降低计算量; 其次, 引入 SPPELAN(Spatial Pyramid Pooling Efficient Local Aggregation Network)构建了新的特征交互模块, 提升模型对不规则病斑的适应性; 然后基于 ASF(Attentional Scale Sequence Fusion YOLO)重新设计了基准模型的颈部网络, 增强模型对病斑多样性的表征能力; 最后引入 Inner_CIoU 损失函数, 加速边界框回归的过程, 提高模型的泛化能力。实验表明, 改进模型在自建葡萄叶病害数据集上 mAP@0.5 为 89.4%, 其中黑腐病检测精确率为 90.3%, 推理速度达到 204.1FPS, 较基线模型提升约 1.5 倍。该模型在保持精度的同时实现了计算效率与实时性的动态平衡, 为智慧农业场景下的实时病害监测系统提供了可行的方案。

关键词: 葡萄叶病害; RTDETR; 实时目标检测; SPPELAN; ASF
文献标志码:A **中图分类号:**TP391 **doi:** 10.3778/j.issn.1002-8331.2504-0440

An Improved RTDETR Algorithm for Real-Time Detection of Grape Leaf Diseases

WANG Qiming¹, YU Qiancheng^{1,2}, YANG Wenyue^{1,3}, MU Hongrui¹, LI Yizhen¹

1. School of Computing Science and Engineering, North Minzu University, Yinchuan 750021, China
2. The Key Laboratory of Images & Graphics Intelligent Processing of State Ethnic Affairs Commission, Yinchuan 750021, China
3. Information Network Center, Ningxia Vocational Technical College of Industry and Commerce, Yinchuan 750021, China

Abstract: Real-time detection of grape leaf diseases is crucial for the sustainable development of the grape industry. To address issues such as computational redundancy, insufficient real-time performance, and small target detection failures in existing detection models under complex field conditions, a novel disease detection model, PVSA-RTDETR, based on RT-DETR, is proposed. The HGNetV2 backbone is replaced with the minimalist backbone PVNet

基金项目: 宁夏重点研发计划(重点)项目(2023BDE02001); 宁夏自然科学基金项目(2023AAC03818); 宁夏重点研发计划(引才专项)项目(2022YCZX0013); 北方民族大学 2022 年校级科研平台《数字化农业赋能宁夏乡村振兴创新团队》(2022PT_S10); 银川市校企联合创新项目(2022XQZD009)。

作者简介: 王启明(1998—), 男, 硕士研究生, CCF 学生会员, 研究方向为深度学习、机器学习, E-mail: 530636132@qq.com; 于千城(1976—), 通信作者, 男, 博士, 副教授, 研究方向为机器学习、社交网络分析, E-mail: 1999019@nmu.edu.cn; 杨文跃(1989—), 男, 硕士研究生, 助教, 研究方向为大语言模型检索增强生成、机器学习, E-mail: 835839959@qq.com; 穆洪锐(1999-), 男, 硕士研究生, 研究方向为 Graph Transformers、图表示学习, E-mail: 1426829582@qq.com; 李易臻(1999—), 男, 硕士研究生, 研究方向为大语言模型、深度学习, E-mail: 1092754099@qq.com。

to enhance feature extraction of lesion edges while reducing computational complexity. Additionally, SPPELAN (Spatial Pyramid Pooling Efficient Local Aggregation Network) is introduced as a new feature interaction module to improve the model's adaptability to irregular lesions. The neck network of the baseline model is redesigned based on ASF (Attentional Scale Sequence Fusion YOLO) to enhance the representation of lesion diversity. Furthermore, the Inner_CIoU loss function is incorporated to accelerate the bounding box regression process and improve the model's generalization ability. Experimental results demonstrate that the improved model achieves an mAP@0.5 of 89.4% on a self-constructed grape leaf disease dataset, with the detection precision for black rot reaching 90.3%. The inference speed is 204.1 FPS, approximately 1.5 times faster than the baseline model. The proposed model achieves a dynamic balance between accuracy, computational efficiency, and real-time performance, providing a feasible solution for real-time disease monitoring systems in smart agriculture.

Key words: grape leaf disease; RTDETR; real-time target detection; SPPELAN; ASF

葡萄作为一种重要的经济作物,其生长周期阶段难免会遭受到病害的侵扰,这使得葡萄的产量和品质严重受损,带来不小的经济损失,根据国际葡萄与葡萄酒组织(OIV)发布的报告显示,2023 年全球葡萄总产量为 74.7 百万吨,其中因自然灾害、病害等因素产量损失达 4.4 百万吨;2024 年真菌病害的爆发导致法国葡萄酒年产量骤降 23.5%,创 1957 年以来的最低产量。在这种背景下如何及时、准确地检测和识别葡萄叶病害就显得尤为重要,而具有实时性检测的方法无疑成为解决这一难题的关键因素,一方面为及时制定防治措施提供了依据,从而有效控制病害的扩散,减少对葡萄产量和品质的影响;另一方面,大幅提高了病害监测的效率,节省了人力和时间成本。

对于规模较小的酒庄而言,病害的检测方法通常依赖于人的经验,这个过程不仅耗时耗力,还会受到主观因素的影响,进而影响检测效率和准确性,但随着智慧农业的快速兴起,基于图像处理和机器学习的检测方法在目标识别方面收到了广泛的欢迎。其中,Sun 等人^[1]提出了一种轻量级 YOLOv8 模型 YOLO-FMDI 用于番茄病虫害的检测,实验结果显示,该模型较原始 YOLOv8n,参数、GFLOPs 和模型尺寸分别减少 18.2%、6.1%和 15.9%,mAP50 提升 1.2%。Chen 等人^[2]提出了轻量级葡萄叶病害检测方法 YOLOv8-ACCW,在自建数据集上,mAP50 和 mAP50-95 分别达 92.8%和 73.8%,较原算法分别提升 3.1%和 5.6%,参数规模仅 2.8MB,计算成本 7.5G。Ishengoma 等人^[3]提出了一种基于 CNN 特征提取器和随机森林分类器的葡萄叶片病害检测集成模型,实验表明,改进后模型的准确性、精确度和灵敏度提升了 5.6%,验证了在有限数据集下提升病害模式识别的有效性。Chen 等

人^[4]提出了基于通道注意力机制和轻量级上采样算子的作物病害检测算法,改进模型精度达 90.0%,召回率 91.4%,mAP@.50 和 mAP50-95 分别为 92.1%和 64%,参数数量和计算负载分别减少 23.9%和 31.2%,性能优于 YOLOv5、YOLOv7 等主流方法。Liu 等人^[5]对 YOLOX-Tiny 模型进行了改进,提出了一种新的葡萄检测模型 YOLOX-RA,实验结果表明,YOLOX-RA 模型的 mAP 达到了 88.75%,检测速度为 84.88FPS,模型大小为 17.53MB。Prathiksha BJ 等人^[6]提出使用基于 CNN 的 VGG-19 模型进行葡萄叶片病害早期准确鉴定,实验结果表明,该模型在严格评估标准下准确率达 98%,在葡萄叶片病害分类任务中展现出良好性能。Wang 等人^[7]提出了一种基于注意力机制的芒果病虫害检测轻量级 YOLOv8 模型 GAS-YOLOv8,经公开数据集验证,该模型害虫检测准确率从 97.1%提升至 98.6%,病害检测准确率从 91.4%提升至 91.7%,模型参数减少 33%。Yuan 等人^[8]提出了一种增强型深度学习模型 ESA-ResNet34 用于作物病虫害检测,实验结果显示,该模型准确率、精度和 F1 分数分别达到 87.09%、87.14%和 86.91%,在 AI Challenger 2018 数据集上性能优于 AlexNet、VGG16 等多个基准模型。Guo 等^[9]在 Faster R-CNN、YOLOx 和 SSD 模型中分别引入 SE、ECA 和 CBAM 注意力机制,实验表明 YOLOx+ECA 模型以最小参数增量 34.87MB,达到最高检测准确率 99.6%,而 SSD+SE 模型在保持较高准确率的同时实现了最优实时性。蔡易南等人^[10]提出基于改进 YOLOv5n 的葡萄叶病虫害检测模型轻量化方法,与传统 YOLOv5n 相比,改进后的模型 mAP 提高 0.2 个百分点,权重、参数数量、计算量分别减少 58%、67%、57%,有效满足移动端和嵌入式设备的部署要求。

以上的病害检测方法大多数都是基于YOLO系列算法的改进,虽然在模型轻量化(权重文件体积小、参数量低)与检测精度之间取得了较好的平衡,但也存在一些问题,如YOLO系列算法依赖NMS(非极大值抑制)后处理机制来消除冗余的检测框,这个过程需要对候选框进行排序与阈值筛选,从而导致计算资源消耗随目标密度而增长,尤其是在叶片病斑密集重叠的场景下,NMS显著抑制了检测速度,成为制约实时检测系统部署的障碍。

本文针对如何在提升检测速度的同时保持较高检测精度的问题,提出了一种基于改进RTDETR的葡萄叶病害检测方法,借助RTDETR消除NMS对检测速度的影响,并通过改进提升模型的推理速度,从而实现检测速度的提升,同时兼顾检测精度,满足实际应用的需求。该方法首先彻底摒弃了基准模型的骨干网络,提出了一种融合VanillaNet和部分卷积的骨干网络PVNet,使模型的参数量和计算量显著降低;其次,引入SPPELAN重构了特征交互模块,使模型更好的把握多尺度的特征;然后,基于ASF重新设计了RTDETR的颈部网络,提升模型对病斑多样性的表征能力;最后引入Inner_CIoU损失函数替换RTDETR中的CIoU损失函数,加速了边界框回归的过程,提高了模型的泛化能力,并将改进后的模型统一命名为PVSA-RTDETR。

1 材料与方法

1.1 数据来源

本文以葡萄叶片的黑腐病、黑麻疹以及叶斑病作

为主要的研究对象^[11],病害样本如图1所示。实验周期覆盖2024年12月至2025年4月,图片资源来源于PlantVillage开源病害图像库,共收集13201张葡萄叶病害图像,为保障数据质量,从中筛选了6238张使用Labelimg标注工具进行精细标注,构建了符合VOC标准的结构化标注数据集,并将数据集按8:1:1比例划分为训练集4990张、验证集623张和测试集625张,确保各病害类别在不同子集间的分布均衡性,图2展示了标签的数量、大小以及中心点的位置,样本分布情况如表1所示,其中黑麻疹占比32.3%,黑腐病占比33.2%,叶斑病占比34.1%。




图1 葡萄叶病害样本

Fig.1 Grape Leaf Disease Samples

1.2 模型选择

RTDETR是由百度开发的一种端到端对象检测器^[12],提供了实时检测的性能,同时也保持了较高的准确率,在识别物体时能够直接生成边界框的位置和类别信息,无需依赖传统的NMS去除冗余框,有效的减少了计算复杂度,提高了推理速度。




图2 标签分布情况图

Fig.2 Label Distribution Diagram

表 1 葡萄叶病害的图像数量

病害类型	图像总数	训练集	验证集	测试集
黑麻疹	2038	1660	206	172
黑腐病	2072	1621	226	225
叶斑病	2128	1709	191	228

在 RTDETR 检测模型中, 提供了多种骨干网络, 如 ResNet、HGNetv2 等。本文选择的基础模型是以 HGNetv2 作为骨干网络的 RTDETR-L 模型, 与其他骨干网络模型相比, HGNetv2 具有高效的特征提取能力和可缩放的结构特点, 使得 RTDETR 模型在保持一定

计算效率的同时, 能够实现较高的检测精度, 这种特性较适合应用于葡萄叶病害检测这类对实时性和准确性要求较高的场景。该模型首先接收一张葡萄叶的输入图像, 该图像由骨干网络先进行处理, 接着通过不同的步长将三种不同尺度的高级特征(S3、S4 和 S5)提取到颈部网络, 随后特征 S5 进入基于注意力的尺度内特征交互(AIFI)模块进行编码, 之后进入基于 CNN 的跨尺度特征融合模块(CCFM)进行多尺度特征交互, 最后这些特征被传递到解码器检测网络中^[13], 模型结构如图 3 所示。




图 3 RTDETR-L 结构图

Fig.3 RTDETR-L Structural Diagram

本研究在 RTDETR-L 算法上进行改进, 提出了一种新的 PVSA-RTDETR 模型, 具体工作如下, 首先完全摒弃基础模型中的骨干网络部分, 将改进的后 PVNet 作为新的骨干网络, 解决计算复杂度较高的问题; 其次, 引入 SPPELAN 重构了特征交互模块, 提

升模型对多尺度目标的检测能力; 然后, 基于 ASF 重新设计了 RTDETR 的颈部网络, 提升模型对病斑多样性的检测精度; 最后引入 Inner_CIoU 损失函数替换 RTDETR 中的 CIoU 损失函数, 加速了边界框回归的过程, 改进后的模型结构如图 4 所示。




图 4 PVSA-RTDETR 结构图

Fig.4 PVSA-RTDETR Structural Diagram

1.3 改进骨干网络

RTDETR 的原始骨干网络包含 HGStem 与多阶段 HGBlock 堆叠结构, 通过 DWConv(Depthwise Separable Convolution)^[14]实现高效特征下采样与通道维度调整, 然而其复杂的层级设计与参数冗余限制了在资源受限设备的部署效率。为了解决计算复杂度等问题, Wang 等人^[15]提出了一种将部分卷积与残差块融合形成的 PConv_Block 模块替代了传统骨干网络中的 Basic_Block 结构, 显著减轻了计算负载。本文为了解决计算复杂度等问题, 选择以 VanillaNet^[16]做为基础网络, 该网络是一种面向环境资源受限设计的极简深度神经网络, 其核心思想通过深度训练策略与系列激活函数的协同创新, 在摒弃残差连接、自注意力等复杂结构的同时, 实现与深度模型相当的性能。为克服浅层网络非线性表达能力不足的缺陷, VanillaNet 引入动态训练机制, 训练初期将单层卷积拆分为两层并插入可调激活函数(公式 1), 逐步将非线性计算融合至权重中, 确保推理时恢复为单层高效结构; 同时设计系列激活函数, 通过邻域加权捕获局部上下文信息, 增强病斑边缘与复杂背景的区分能力, 数学表达式如公式(3)所示。

$$A'(x) = (1 - \lambda)A(x) + \lambda x \quad (1)$$

$$\lambda = \frac{e}{E} \quad (2)$$

其中 $A(x)$ 是激活函数(可以是 ReLU 和 Tanh), λ 随训

练轮次从 1 线性衰减至 0, e 表示当前 $epoch$, E 表示深度训练 $epoch$ 的数量。

$$A_s(x_{h,w,c}) = \sum_{i,j \in \{-n,n\}} a_{i,j,c} \cdot \text{ReLU}(x_{i+h,j+w,c} + b_c) \quad (3)$$

式(3)中, $x \in R^{H \times W \times C}$, 表示输入特征图的位置值, 其中 h, w 和 c 表示高度、宽度和通道数, i, j 表示邻域内相对于中心位置的偏移量, $a_{i,j,c}$ 表示邻域权重参数, b_c 表示通道偏置项。

借鉴 Wang 等人的思想, 本文基于 VanillaNet 创新性的设计了新的骨干网络 PVNet, 将 RTDETR 模型中的 Backbone 部分完全摒弃, 以 PVNet 为主组成新的骨干网络, 旨在提高计算效率的同时保持高效的特征提取。具体而言, PVNet 网络采用严格的线性堆叠架构, 核心模块由 Stem 模块和 Stage 模块构成, 在 Stage 模块中, 基于 PConv(Partial Convolution)^[17]重新设计了该模块, 利用其特性将 VanillaNet 与 PConv 进行了融合, 使模型在处理特征图时更好的关注有效信息, 从而增强模型对关键特征的识别能力, 并将修改后的网络称为 PVNet, 图 5 展示了 PVNet 的结构图, 输入图像通过 4×4 卷积快速下采样至 160×160 分辨率, 随后经 1×1 卷积调整通道至 64, 并通过动态激活函数(activation)调整特征响应, 增强对病斑边缘的敏感性, 随后再经过多个 Stage 模块将通道数变化为: $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$ 。




图5 PVNet 结构图

Fig.5 PVNet Structural Diagram

PConv 的设计原理是通过选择性通道处理机制, 仅在局部通道上执行空间特征提取, 而其余通道直接传递原始数据, 如图 6 所示, 这样既减少了参数计算量, 又避免了传统的 DWConv 和 GConv(Group Convolution)^[18]因过度压缩通道导致的特征表达能力下降的问题。假设输入和输出通道数相同, 当选取 $1/4$ 通道进行卷积时(即 $\frac{c_p}{c} = \frac{1}{4}$), 其理论 FLOPs(浮点计算次数)

仅为标准卷积的 $1/16$, 计算公式如式(4), 内存访问量(公式 5)降低至普通卷积的 $1/4$ 。

$$h \times w \times k^2 \times c_p^2 \quad (4)$$

$$h \times w \times 2c_p + k^2 \times c_p^2 \approx h \times w \times 2c_p \quad (5)$$

式中 h, w 分别代表特征图的高宽, k 表示卷积核的大小, c_p 表示选取用于卷积的通道数。




图6 部分卷积示例图

Fig.6 Partial Convolution Example Diagram

1.4 基于 SPPELAN 的特征交互模块

SPPELAN 通过融合空间金字塔池化(SPP)^[19]的尺寸不变性优势与高效层聚合网络(ELAN)^[20]的特征增强能力,构建了一种兼顾全局语义与局部细节的特征融合模块。如图7所示,该模块的核心由三个并行分支组成,每个分支均采用核尺寸为 5×5 、步长1、填充2的MaxPool2d层进行多层次池化处理,特征重组阶段通过拼接(concat)操作融合多分支输出,最终通过 1×1 卷积调整通道维度,形成具有自适应权重的多尺度特征表达。




图7 SPPELAN 结构图

Fig.7 SPPELAN Structural Diagram

本文针对葡萄叶病害检测中存在的复杂背景和规则病斑等问题,利用 SPPELAN 模块的优势(融合多层次池化与高效特征聚合),将 RTDETR 中的 AIFI 模块进行了替换。具体而言,通过 SPPELAN 的并行多分支结构,在每个分支上应用不同扩张率的MaxPool2d操作,实现多层次池化,这种设计能够渐进式地扩大感受野,使模型同时捕获像素级的病斑边缘、纹理等细节特征,以及病斑整体形态和与背景信息关联的特征,有效解决了传统方法对葡萄叶大小不一、病斑形态各异适应性不足等问题;其次,跨层级残差连接融合骨干网络种不同分辨率的特征图,充分利用浅层特征的高分辨率优势,对深层特征因多次下

采样损失的叶片边缘、微小病斑或遮挡区域等细节信息进行了有效补偿,从而显著提升了模型在叶片形态多变、部分遮挡等复杂田间场景下的识别鲁棒性,如图8所示。相较于 AIFI 模块,SPPELAN 模块基于局部操作和结构化特征融合的设计,在保持强大特征表达能力的同时,显著降低了模型的计算复杂度和内存需求,为资源受限的田间边缘设备实现实时病害检测提供了更可行的技术方案。




图8 空间金字塔池化结构图

Fig.8 Spatial Pyramid Pooling Structure Diagram

1.5 颈部网络的改进

针对小目标和密集目标的分割任务,传统方法及YOLO系列模型在处理医学图像中的微小细胞或农业场景中的早期病斑等复杂目标时存在显著局限性,主要表现为多尺度特征表达能力不足、密集目标边界模糊以及复杂背景干扰等问题。在此背景下,Ming Kang等人^[21]提出了一种名为ASF-YOLO的模型,该模型的技术核心在于多尺度特征融合与注意力机制的协同优化,通过引入SSFF(Scale Sequence Feature Fusion)模块强化网络的多尺度特征提取能力,利用TFE(Triple Feature Encoder)模块实现多尺度特征图的融合,丰富病斑细节信息,并进一步引入CPAM(Channel and Position Attention Mechanism)来整合SSFF和TFE模块,实现自适应通道权重分配与空间位置聚焦,有效抑制了复杂背景的干扰,增强了目标区域的表征能力,SSFF、TFE以及CPAM的结构如图9所示。

为了解决小目标特征信息丢失等问题,胡佳乐等人通过结合动态上采样模块(Dysample)^[22]和SSFF,实现了更有效的多尺度特征整合,丰富了语义关系^[23]。本文基于胡等人的思想,为了解决病害检测任务中小目标漏检等问题,结合ASF-YOLO重新设计了

RTDETR 的颈部网络,通过 SSFF 模块对小目标形态变化的多尺度特征融合能力,实现对不同葡萄叶病斑形态特征的捕获;CPAM 模块则通过注意力机制,动

态筛选关键通道特征并精准定位病斑相关的空间位置,有效提升模型对叶片纹理、光照等田间复杂环境下干扰的鲁棒性,为精准农业中的防治提供了技术支撑。




图9 SSFF+TFE+CPAM 结构图

Fig.9 SSFF+TFE+CPAM Structure Diagram

1.6 Inner-IoU 损失函数

在 RTDETR 中,通过引入 CIoU(Complete Intersection over Union)损失函数显著优化了边界框回归的精度与效率,CIoU 损失函数的计算如公式(6-8)所示。相较于传统的 IoU,CIoU 从几何特征的重叠区域、中心点距离、长宽比相似性联合优化边界框回归,有效解决了目标尺度变化与形状适配问题,但 CIoU 在处理复杂背景下的样本不平衡问题时仍存在局限性,如样本优化策略单一、梯度动态调节不足等。为了解决这些问题,本文引入了 Inner-CIoU^[24]损失函数,通过可调节的缩放因子(ratio)动态生成多尺度辅助边界框,加速回归过程,针对高 IoU 样本,采用缩小比例(ratio<1)的辅助框聚焦目标核心区域;对于低 IoU 样本,采用放大比例(ratio>1)的辅助框扩展有效回归范围,Inner-CIoU 的计算如公式(9-12)所示。

$$\mathcal{L}_{CIoU} = 1 - IoU + \frac{\rho^2(b, b^{gt})}{c^2} + \alpha v \quad (6)$$

$$\alpha = \frac{v}{(1 - IoU) + v} \quad (7)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h} \right)^2 \quad (8)$$

其中 IoU 表示预测框与真实框的交并比, b_{gt} 和 b 分别为真实框与预测框的中心点坐标, ρ 为两中心点间的欧氏距离, c 为包含两框的最小闭包区域的对角线长

度, α 为动态权重系数, v 用于衡量两框长宽比的一致性。

$$inter = \left(\min(b_r^{gt}, b_r) - \max(b_l^{gt}, b_l) \right) \cdot \left(\min(b_t^{gt}, b_t) - \max(b_b^{gt}, b_b) \right) \quad (9)$$

$$union = (w^{gt} \cdot h^{gt}) \cdot ratio^2 + (w \cdot h) \cdot ratio^2 - inter \quad (10)$$

$$IoU_{inner} = \frac{inter}{union} \quad (11)$$

$$\mathcal{L}_{inner-CIoU} = \mathcal{L}_{CIoU} + IoU - IoU_{inner} \quad (12)$$

其中, b_r^{gt} 、 b_l^{gt} 、 b_t^{gt} 、 b_b^{gt} 分别表示真实框的右、左、上、下边界坐标, b_r 、 b_l 、 b_t 、 b_b 分别表示预测框的右、左、上、下边界坐标, w^{gt} 、 h^{gt} 分别表示真实框的宽度和高度, w 、 h 则表示预测框的宽度和高度。

1.7 评价指标

本文选取了准确率(P)、召回率(R)、平均精度(AP)、平均精度均值(mAP)、每秒帧数(FPS)、权重文件的大小以及计算量来衡量改进后模型的性能。

准确率是指模型正确检测到的病害区域数量与模型检测到的总病害区域数量的比值,如公式(13)所示。其中真正例(TP)指模型正确预测为正类的样本数量,真负例(TN)表示模型正确预测为负类的样本数量,假正例(FP)是模型错误地将负类样本判为正类的情况,假负例(FN)则是模型未能识别出实际为正类的样本。

$$Precision = \frac{TP}{TP+FP} \quad (13)$$

召回率是指模型正确识别的病害区域占实际病害区域总量的比例,体现模型对真实阳性样本的覆盖能力,如公式(14)所示。该值越高,表明模型对病害目标的漏检风险越低,检测全面性越强。

$$Recall = \frac{TP}{TP+FN} \quad (14)$$

平均精度是通过将精度-召回率曲线进行积分得到的结果,反映模型在不同置信度阈值下的综合判别能力,如公式(15)所示。 AP 值越高,表明模型在分类准确性与目标召回能力之间的平衡性越优。

$$AP = \int_0^1 P(R) dR \quad (15)$$

平均精度均值是对多类别检测任务中各病害类别的 AP 值进行算术平均,量化模型在复杂场景下的整体性能,如公式(16)所示。 mAP 值越高,说明模型对不同病害类型的泛化检测能力越强。

$$mAP = \frac{1}{n} \sum_{i=1}^n AP_i \quad (16)$$

每秒帧数是指模型在单位时间内可处理的图像数量,与实时性相关,如公式(17-18)所示, FPS 值越高,表明系统响应速度越快,能够更好地满足实际应用中的实时性需求。公式(18)中的 pre 表示预处理时间($preprocess$), inf 表示推理时间($inference$), $post$ 表示后处理时间($postprocess$),单位都是毫秒(ms)。

$$FPS = \frac{1000ms}{AllTime} \quad (17)$$

$$AllTime = pre + inf + post \quad (18)$$

2 实验与结果分析

2.1 试验配置

本次实验在 Ubuntu22.04 系统上开展,硬件方面,处理器为 Intel (R) Xeon (R) Platinum 8352V CPU @ 2.10GHz,内存达 90GB,存储包含 30GB 系统盘与 50GB 数据盘,保证了数据处理和模型训练的流畅运行,软件环境为 Python 3.10、PyTorch 2.1.0、CUDA 12.1。在实验过程中,设置了一些关键的实验参数,例如学习率、批次大小、训练轮数等,初始学习率为 0.0001,最终学习率为 0.001,批次大小的设置为 16,训练轮数的设置为 150,优化器为 Adamw。

2.2 对比试验分析

2.2.1 骨干网络对比实验

为了验证不同骨干网络对检测性能的影响,本文对 MobileNetV4^[25]、MobileNetV3^[26]、StarNet^[27]、Revc01^[28]、RepVit^[29]、RMT^[30]和 PVNet 七种骨干网络的检测性能进行了对比分析,结果如表 2 所示。实验表明,PVNet 在检测精度、参数量与计算量的平衡性上均表现出显著优势,其 $mAP@0.5$ 达到 89.5%,在精确率方面相较于 MobileNetV4、MobileNetV3 等对比模型分别提升了 2.0%、6.6%、6.4%、7.1%、3.6%、4.0%。具体到病害类别,PVNet 在黑腐病检测中表现尤为突出(P 达 89.7%),较其它模型提升 6.0%-11.4%,同时其参数量和计算量显著低于 Revcol 和 RMT。

表 2 不同骨干网络的实验对比

Table 2 Comparison of Experiments with Different Backbone Networks

骨干网络 Backbone	精确率% Precision			平均精度均值% mAP@0.5	参数量/MB Params	计算量/G GFLOPs	每秒帧数/帧 FPS
	黑麻疹 Black Measles	黑腐病 Black Rot	叶斑病 Leaf Spot				
MobileNetV4	85.5	83.7	83.0	89.3	20.4	73.0	217.4
MobileNetV3	83.8	79.5	75.1	87.6	18.6	57.2	231.6
StarNet	83.2	79.6	76.2	87.3	18.0	57.7	142.9
Revc01	83.7	78.3	75.0	87.1	47.7	130.7	56.5
RepVit	82.5	82.6	82.4	87.2	22.4	70.3	90.9
RMT	84.3	83.5	78.5	88.3	30.4	94.6	30.8
PVNet	85.5	89.7	83.0	89.5	18.2	59.9	208.3

2.2.2 空间金字塔池化对比实验

在相同位置引入 SimSPPF^[31]、SPPCSPC^[32]和 FocalModulation^[33]模块进行对比实验,以验证 SPPELAN 模块对模型检测性能的影响。实验结果表明,

引入 SPPELAN 模块的基准模型在检测精度上取得了最佳性能,SPPELAN 模块使得模型在 $mAP50$ 上达到了 89.8%,相较于 AIFI 模块、SimSPPF 模块、SPPCSPC 模块以及 FocalModulation 模块分别提高了 1.2%、1.4%、2.5%和 1.2%,在精确率方面三类病害的检测值也分别

达到 87.1%、85.1%、84.4%，具体的实验结果如表 3 所示。

表 3 空间金字塔池化实验对比

Table 3 Comparison of Spatial Pyramid Pooling Experiments

金字塔池化 SPP	精确率% Precision			平均精度均值% mAP@0.5	参数量/MB Params	计算量/G GFLOPs
	黑麻疹 Black Measles	黑腐病 Black Rot	叶斑病 Leaf Spot			
AIFI	84.6	78.1	81.3	88.6	32.0	103.4
SimSPPF	84.7	80.8	79.0	88.4	32.0	103.6
SPPCSPC	84.4	79.0	73.5	87.3	58.1	124.6
FocalModulation	85.4	79.3	77.8	88.6	31.5	103.2
SPPELAN	87.1	85.1	84.4	89.8	32.5	104.1

2.2.3 模型损耗对比

为评估 PVSA-RTDETR 相较于基准模型的性能优化效果，本文对分类损失曲线展开了对比分析。如图 10 所示，基准模型 RTDETR(红色曲线)与改进模型 PVSA-RTDETR(蓝色曲线)在训练集和验证集上的损

失动态存在显著差异，实验表明：改进模型在训练阶段呈现出更稳定的收敛过程，其损失值在后期明显优于基准模型，反映了目标类别判别能力的提升；同时，验证集上的分类损失曲线也明显低于 RTDETR，说明 PVSA-RTDETR 模型具有良好的泛化能力。




图 10 分类损失曲线对比图

Fig.10 Comparison Chart of Classification Loss Curves

2.2.4 消融实验

本文进行了 8 组消融实验来验证改进模块对模型的影响，实验结果如表 4 所示。仅加入 PVNet 网络时，mAP@0.5 提升了 0.9 个百分点，相比于基准模型增加 1.02%，精确率提升了 4.8 个百分点，相比于基准模型增加 5.90%，其中最显著的是，模型的权重文件大小和计算量较基准模型大幅降低 42.10%；仅加入 SPPELAN 模块时，mAP@0.5 和精确率较基准模型分别提升 1.20%

和 4.20%；仅加入 ASF 模块时，mAP@0.5 和精确率较基准模型分别提升 0.90%和 5.50%；仅改进损失函数模块时，mAP@0.5 和精确率较基准模型分别提升 0.20%和 1.80%；当同时加入 PVNet 和 SPPELAN 时，mAP@0.5 和精确率相对于基准模型分别增加 0.68%和 4.80%；当同时加入 PVNet、SPPELAN 和 ASF 三个模块时，mAP@0.5 和精确率相对于基准模型分别增加 0.80%和 5.90%；当同时加入所有的改进模块后，mAP@0.5、精

确率和召回率相对于基准模型分别增加 0.90%、5.30% 模型的权重文件大小相比于基准模型大幅降低了 和 4.45%，此外在保持较高检测精度和召回率的同时， 49.70%，有效证明了改进方法的可行性。

表 4 消融实验的性能评估
Table 4 Performance Evaluation of Ablation Experiments

PVNet	SPPELAN	ASF	Inner_CIoU	平均精度均值%	精确率%	召回率%	权重文件大	计算量/G
				mAP@0.5	Precision	Recall	小/MB	GFLOPs
-	-	-	-	88.6	81.3	80.9	66.2	103.4
✓	-	-	-	89.5	86.1	83.2	38.3	59.9
-	✓	-	-	89.8	85.5	82.8	67.2	104.1
-	-	✓	-	89.5	86.8	82.2	61.5	109.5
-	-	-	✓	88.8	83.1	82.0	66.2	103.4
✓	✓	-	-	89.2	85.2	82.2	39.3	60.5
✓	✓	✓	-	89.3	86.1	83.9	33.3	60.7
✓	✓	✓	✓	89.4	85.6	84.5	33.3	60.7

尽管同时使用所有改进模块时精确率略有浮动， 侧为基准模型的曲线，可以清晰的看到改进后的模型 但通过对比 F1-Score 曲线表明了模型改进的有效性， 在大部分置信度区间内，各类别和综合的 F1 曲线位 如图 11 所示，图中左侧为 PVSA-RTDETR 的曲线,右 置高于基准模型。




图 11 F1-Score 曲线对比图
Fig.11 Comparison Chart of F1-Score Curves

2. 2. 5 模型效果分析

在测试集上选取三类有代表性的不同病害进行验证，图 12 展示了 RTDETR 与 PVSA-RTDETR 在置信度等相同条件下的检测效果，可以看到改进后的模型

在检测精度和漏检方面有了较大的提升，尤其在相对复杂的背景下(图 12 右侧)，PVSA-RTDETR 的检测效果远超基准模型，同时为了证明改进后模型的泛化能力，在原有 6238 张病害样本的基础上新增 62 张全新

的样本，并将扩充后的数据集按 7：2：1 划分为训练集、测试集和验证集，显著增加测试集的数量，充分验证改进后模型的泛化能力，表 5 对比了增加测试集

比例后基准模型与改进模型的性能指标，可以观察到改进后模型的性能指标依然优于基准模型。




图 12 模型检测结果对比图
Fig.12 Comparison Chart of Model Detection Results

表 5 测试集比例增加后的模型性能比较

Table 5 Comparison of Model Performance After Increasing the Proportion of Test Set

模型 Model	平均精度均值% mAP@0.5	精确率% Precision	召回率% Recall	每秒帧数/帧 FPS
RTDETR	89.4	82.4	81.3	60.2
PVSA-RTDETR	90.8	86.4	84.1	166.7

由于原有数据集中的样本过于单一，因此为了更好的证明模型在特殊场景下的性能表现，在原有数据集的基础上选取各类病害约 1500 张样本，通过变换样本的亮度、饱和度、增强对比度和添加噪声等方式模拟强光、阴影和雨雾等特殊场景下的病害样本，最终，

将病害样本扩充到 9300 张组成了一个全新的数据集，处理后的样本如图 13 所示；在新样本上，改进模型表现出了更好的性能指标，如表 6 所示，mAP@0.5、精确率和召回率都达到了百分之九十以上。



图 13 处理后的病害样本

Fig.13 Processed Disease Samples

表 6 特殊样本上的验证结果

Table 6 Verification Results on Special Samples

病害类型 Disease Types	平均精度均值% mAP@0.5	精确率% Precision	召回率% Recall
黑麻疹 Black Measles	95.4	91.2	91.3
黑腐病 Black Rot	95.9	93.6	92.0
叶斑病 Leaf Spot	95.0	91.0	87.6
总体 All	95.4	91.9	90.3

图 14 展示了 PVSA-RTDETR 在特殊样本上的检测效果，从图中可以观察到改进后的模型在特殊场景下也表现出了良好的检测性能。此外，考虑到在实际应用场景中硬件环境有所差别，因此在低功耗设备上部署了改进后的模型来进行性能的测试，测试结果如表 7 所示，测试用到的数据集是未经特殊处理的图像

样本，即原始样本，从表中可以观察到，在低功耗的设备上改进后模型的检测性能仍然优于基准模型，尤其在检测速度方面。综上所述，充分验证了模型改进的有效性，为智慧农业病害监测系统提供了精度与效率协同进化的可行性方案，具有重要的工程应用价值。

表 7 模型在低功耗设备上的检查性能对比

Table 7 Comparison of Inspection Performance of the Model on Low-Power-Consumption Devices

设备 Device	模型 Model	平均精度均值% mAP@0.5	精确率% Precision	召回率% Recall	推理速度/ms Inference
NVIDIA GeForce GTX 1050	RTDETR	88.9	82.0	81.2	104.6
	PVSA-RTDETR	89.3	84.8	84.9	65.5

2.2.6 不同模型的对比

为进一步验证 PVSA-RTDETR 模型的性能，与 YOLO11^[34]、RTDETR-Mamba-L^[35]等模型进行了对比，从表 8 可以看出，在 mAP@0.5 方面，PVSA-RTDETR 模型以 89.4%的精度高于其它对比模型，特别在黑腐病的检测上，PVSA-RTDETR 模型的精确率比 YOLOv8L、YOLOv9C 等模型分别高 7.2%、26.1%、

38%、27.1%、30.2%和 2.7%。模型轻量化方面，PVSA-RTDETR 模型的权重文件仅为 33.3MB，显著低于同级别的主流模型。在实时性方面的表现尤为突出，PVSA-RTDETR 模型的推理速度达 204.1FPS，比其它模型高出约 2.7 倍-8.1 倍。综上所述，改进后的模型在实时高精度检测场景中具有显著的应用价值，适合在资源受限的设备上部署。



图 14 改进模型在特殊样本上的检测效果图

Fig.14 Detection Results of the Improved Model on Special Samples

表 8 不同模型实验对比

Table 8 Comparison of Experiments with Different Models

模型 Model	精确率% Precision			平均精度均值% mAP@0.5	参数量 /MB Params	计算量/G GFLOPs	每秒帧数 /帧 FPS	权重文件 大小/MB
	黑麻疹 Black Measles	黑腐病 Black Rot	叶斑病 Leaf Spot					
YOLOV8L	85.9	83.1	63.4	80.4	43.6	164.8	67.6	87.7
YOLOV9C	84.4	64.2	83.6	83.2	25.3	102.3	73.5	51.6
YOLOV10L	74.2	52.3	57.6	72.2	25.7	126.3	55.6	52.2
YOLO11L	86.4	63.2	80.6	83.8	25.3	86.6	76.3	51.2
YOLOV12L	86.3	60.1	61.2	80.3	26.3	88.6	55.2	53.5
RTDETR-Mamba-L	80.1	87.6	82.4	88.3	32.4	76.4	25.1	65.1
RTDETR-L	84.6	78.1	81.3	88.6	32.0	103.4	137.0	66.2
PVSA-RTDETR	83.6	90.3	82.8	89.4	15.7	60.7	204.1	33.3

3 结束语

本文提出一种基于改进 RTDETR 的葡萄叶病害实时检测模型 PVSA-RTDETR，通过多维度协同优化解决了复杂田间场景下模型实时性不足、小目标漏检率高等问题。采用极简骨干网络 PVNet 替换基准模型的 HGNetv2，在参数量降低 43%的同时增强病斑边缘特征提取能力；其次，基于 SPPELAN 重新设计了特征交互模块，通过多层级上下文感知机制将 mAP@0.5 提升至 89.4%；此外，基于 ASF-YOLO 重构了 RTDETR 的颈部网络，最终将计算量压缩至 60.7GFLOPs，较基线减少 41%，FPS 达到 204.1，远超 YOLO 系列算法的检测速度；最后结合 Inner_CIoU 损失函数，加速了边界框回归的过程，提高了模型的泛化能力。与现有

的主流模型相比，PVSA-RTDETR 在检测精度和速度上均表现出色，具有较高的实用性和可扩展性。

参考文献：

[1] SUN H, NICHOLAUS I T, FU R, et al. YOLO-FMDI: a lightweight YOLOv8 focusing on a multi-scale feature diffusion interaction neck for tomato pest and disease detection[J]. Electronics, 2024, 13(15): 2974.

[2] CHEN Z, FENG J, YANG Z, et al. YOLOv8-ACCW: lightweight grape leaf disease detection method based on improved YOLOv8[J]. IEEE Access, 2024.

[3] ISHENGOMA F S, LYIMO N N. Ensemble model for grape leaf disease detection using CNN feature extractors

- and random forest classifier[J]. Heliyon, 2024, 10(12).
- [4] CHEN W, ZHENG L, XIONG J. Algorithm for crop disease detection based on channel attention mechanism and lightweight up-sampling operator[J]. IEEE Access, 2024.
- [5] LIU B, ZHANG Y, WANG J, et al. An improved lightweight network based on deep learning for grape recognition in unstructured environments[J]. Information Processing in Agriculture, 2024, 11(2):202-216.
- [6] PRATHIKSHA B J, KUMAR V, KRISHNAMOORTHY M, et al. Early accurate identification of grape leaf disease detection using CNN based VGG-19 model[C]//2024 International Conference on Cognitive Robotics and Intelligent Systems (ICC-ROBINS). IEEE, 2024: 263-269.
- [7] WANG J, WANG J. A lightweight YOLOv8 based on attention mechanism for mango pest and disease detection[J]. Journal of real-time image processing, 2024, 21(4): 136.
- [8] YUAN Y, SUN J, ZHANG Q. An enhanced deep learning model for effective crop pest and disease detection[J]. Journal of Imaging, 2024, 10(11): 279.
- [9] GUO W, FENG Q, LI X, et al. Grape leaf disease detection based on attention mechanisms[J]. International Journal of Agricultural and Biological Engineering, 2022, 15(5): 205-212.
- [10] 蔡易南, 肖小玲. 基于改进 YOLO v5n 的葡萄叶病虫害检测模型轻量化方法[J]. 江苏农业科学, 2024, 52(07): 198-205. DOI:10.15889/j.issn.1002-1302.2024.07.027.
- CAI Y N, XIAO X L. Lightweight method of grape leaf diseases and insect pests detection model based on improved YOLOv5n[J]. Jiangsu Agricultural Sciences, 2024, 52(7):198-205
- [11] 蔺瑶, 曾晏林, 刘金涛, 等. 基于 EBP-YOLOv8 的葡萄叶病害检测与识别方法研究[J]. 山东农业大学学报(自然科学版), 2024, 55(03):322-334.
- LIN Y, ZENG Y L, LIU J T, et al. Detection and identification method of grape leaf diseases based on EBP-YOLOv8[J]. Journal of Shandong Agricultural University (Natural Science Edition), 2024, 55(03):322-334. DOI : 10.3969/j.issn.1000-2324.2024.03.004.
- [12] ZHAO Y, LV W, XU S, et al. Detsr beat yolos on real-time object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 16965-16974.
- [13] FU Z, YIN L, CUI C, et al. A lightweight MHDI-DETR model for detecting grape leaf diseases[J]. Frontiers in Plant Science, 2024, 15: 1499911.
- [14] CHOLLET F. Xception: deep learning with depthwise separable convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.
- [15] WANG S, JIANG H, YANG J, et al. Lightweight tomato ripeness detection algorithm based on the improved RT-DETR[J]. Frontiers in Plant Science, 2024, 15: 1415297.
- [16] CHEN H, WANG Y, GUO J, et al. Vanillanet: the power of minimalism in deep learning[J]. Advances in Neural Information Processing Systems, 2023, 36: 7050-7064.
- [17] CHEN J, KAO S, HE H, et al. Run, don't walk: chasing higher FLOPS for faster neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 12021-12031.
- [18] XIE S, GIRSHICK R, DOLLÁR P, et al. Aggregated residual transformations for deep neural networks[C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1492-1500.
- [19] HE K, ZHANG X, REN S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.
- [20] WANG C Y, YEH I H, MARK LIAO H Y. Yolov9: learning what you want to learn using programmable gradient information[C]//European conference on computer vision. Cham: Springer Nature Switzerland, 2024: 1-21.
- [21] KANG M, TING C M, TING F F, et al. ASF-YOLO: a novel YOLO model with attentional scale sequence fusion for cell instance segmentation[J]. Image and Vision Computing,

- 2024, 147: 105057.
- [22] LIU W, LU H, FU H, et al. Learning to upsample by learning to sample[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 6027-6037.
- [23] 胡佳乐,周敏,申飞.面向无人机小目标的 RTDETR 改进检测算法[J].计算机工程与应用,2024,60(20):198-206.
- HU J L, ZHOU M, SHEN F. Improved detection algorithm of RTDETR for UAV small target[J]. Computer Engineering and Applications, 2024, 60(20): 198-206.
- [24] ZHANG H, XU C, ZHANG S. Inner-iou: more effective intersection over union loss with auxiliary bounding box[J]. arXiv preprint arXiv:2311.02877, 2023.
- [25] QIN D, LEICHNER C, DELAKIS M, et al. MobileNetV4: universal models for the mobile ecosystem[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 78-96.
- [26] HOWARD A, SANDLER M, CHU G, et al. Searching for mobilenetv3[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 1314-1324.
- [27] MA X, DAI X, BAI Y, et al. Rewrite the stars[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 5694-5703.
- [28] CAI Y, ZHOU Y, HAN Q, et al. Reversible column networks[J]. arXiv preprint arXiv:2212.11696, 2022.
- [29] WANG A, CHEN H, LIN Z, et al. Repvit: revisiting mobile cnn from vit perspective[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 15909-15920.
- [30] FAN Q, HUANG H, CHEN M, et al. Rmt: Retentive networks meet vision transformers[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 5641-5651.
- [31] LI C, LI L, JIANG H, et al. YOLOv6: a single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.
- [32] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 7464-7475.
- [33] YANG J, LI C, DAI X, et al. Focal modulation networks[J]. Advances in Neural Information Processing Systems, 2022, 35: 4203-4217.
- [34] KHANAM R, HUSSAIN M. Yolov11: an overview of the key architectural enhancements[J]. arXiv preprint arXiv: 2410.17725, 2024.
- [35] WANG Z, LI C, XU H, et al. Mamba YOLO: a simple baseline for object detection with state space model[C]// Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(8): 8205-8213.