



计算机科学

Computer Science

ISSN 1002-137X, CN 50-1075/TP

《计算机科学》网络首发论文

题目：改进 YOLOv11n 的无人机航拍图像小目标检测模型
作者：王井阳，薛为民，黄敏，武少广
网络首发日期：2025-11-20
引用格式：王井阳，薛为民，黄敏，武少广. 改进 YOLOv11n 的无人机航拍图像小目标检测模型[J/OL]. 计算机科学.
<https://link.cnki.net/urlid/50.1075.TP.20251119.1814.019>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

改进 YOLOv11n 的无人机航拍图像小目标检测模型

王井阳 薛为民 黄敏 武少广

河北科技大学信息科学与工程学院 河北 石家庄 050018
(ever211@163.com)

摘要 随着目标检测算法和无人机技术的持续革新，无人机航拍图像中小目标的检测已成为研究热点问题。无人机航拍图像具有小目标占比高、分布密集和环境复杂等问题。针对这些问题，本文提出了一种改进 YOLOv11n 的无人机航拍图像小目标检测模型 MPI-YOLO。首先，在其 Backbone 中使用多尺度特征聚合模块 (MSFAM) 替换前 2 个 C3k2 模块，以增强对小目标信息的特征提取能力。其次，针对无人机图像中小目标占比高的问题，新增了 P2 小目标检测层，使得尺寸微小的目标能够被更好的检测到。最后，提出了改进的双向密集特征金字塔网络 (IBDFPN)，通过扩展金字塔网络的层级范围并引入跳跃连接来增强浅层和深层特征的跨层交互，实现了高效的多尺度信息融合。在 VisDrone2019 数据集上，开展了消融实验和对比实验，消融实验验证了各改进策略的有效性，对比实验结果表明 MPI-YOLO 对小目标检测的准确率均优于其它对比模型，相较于基准模型 YOLOv11n 在 mAP50 上提升了 9.1 个百分点。在 UAVDT 数据集和 Tinyperson 数据集上进行了泛化实验，验证了其具有良好的泛化能力。

关键词： 小目标检测；无人机航拍图像；特征金字塔网络；多尺度特征融合；双向特征融合

中图法分类号 TP391

An Improved YOLOv11n Model for Small Target Detection in UAV Aerial Images

WANG Jingyang, XUE Weimin, HUANG Min and WU Shaoguang

School of Information Science and Engineering, Hebei University of Science and Technology, Shijiazhuang 050018, China

Abstract With the continuous innovation of target detection algorithms and Unmanned Aerial Vehicle (UAV) technology, detecting small targets in UAV aerial images has become a hot research topic. UAV aerial images have problems such as a high proportion of small targets, dense distribution, and complex environments. To address these issues, this paper proposes an improved UAV aerial image small target detection model MPI-YOLO based on YOLOv11n. Firstly, the Multi-Scale Feature Aggregation Module (MSFAM) replaces the first two C3k2 modules in the Backbone of YOLOv11n to enhance the feature extraction ability for small target information. Secondly, to solve the problem of a high proportion of small targets in UAV images, a new P2 small target detection layer is added, so that small targets can be better detected. Finally, an Improved Bidirectional Dense Feature Pyramid Network (IBDFPN) is proposed, which extends the level range of the pyramid network and introduces skip connections to enhance the cross-layer interactions between shallow and deep features, achieving efficient multi-scale information fusion. The VisDrone2019 dataset is utilized for ablation experiments and comparative experiments. The ablation experiments verify the effectiveness of each improved strategy. The comparative experimental results show that MPI-YOLO's accuracy in detecting small targets is better than that of other comparative models. Compared with the benchmark model YOLOv11n, the mAP50 has increased by 9.1 percentage points. Generalization experiments are conducted on the UAVDT dataset and Tinyperson dataset, verifying its good generalization ability.

Key words Small target detection, UAV aerial images, Feature pyramid network, Multi-scale feature fusion, Bidirectional feature fusion

基金项目：国防科技重点实验室基金项目 (6142205240201)

This work was supported by the Key Laboratories for National Defense Science and Technology (6142205240201).

通信作者：武少广 (wushaoguang@hebust.edu.cn)

1 引言

近年来,随着目标检测和无人机(Unmanned Aerial Vehicle, UAV)技术的快速发展,利用无人机平台进行目标检测是计算机视觉领域中极具挑战性与前景的前沿课题。部署了目标检测算法的无人机在森林火灾预警^[1]、智能交通^[2]、输电线路检测^[3]、农作物病虫害检测^[4]、人员搜救^[5]和军事行动^[6]等领域得到广泛应用。然而,不同于自然场景中的图像,无人机航拍图像通常具有目标尺度变化大、小目标占比高、环境复杂等特点。一方面,由于无人机飞行高度离地面较高且拍摄视野宽广,其拍摄的图像中往往包含大量微小目标,且呈现密集分布状态。另一方面,无人机俯视拍摄时,目标与相机的物距差异会导致图像中近处目标成像尺寸较大,远处目标成像尺寸较小,进而造成目标尺度的显著变化。上述两个挑战使得为自然场景设计的检测模型难以直接应用于无人机航拍图像目标检测场景。

当前无人机航拍图像目标检测领域的研究方法可归纳为传统人工特征提取方法与深度学习方法两大类。传统人工特征提取方法基于目标颜色、纹理、轮廓等特征人工设计特征提取器,通过滑动窗口进行特征提取后,采用分类器完成目标分类与定位^[7-8]。然而,传统方法依赖人工经验设计特征描述符,其通用性和泛化能力不足,在环境多变的无人机航拍图像目标检测场景中,该方法难以精准完成目标检测任务。近年来,随着深度学习技术的迅猛发展,基于深度学习的目标检测方法凭借其强大的特征提取和自适应学习能力,显著提升了检测性能,逐渐取代了传统的手动特征提取方法。

根据不同的检测策略,基于深度学习的目标检测方法可分为两大类:两阶段目标检测方法和单阶段目标检测方法。(1) R-CNN (Region-

Convolutional Neural Network) 是一种经典的两阶段的目标检测方法,它分为两个主要步骤:

第一步是利用区域提取技术在图像中提取一组可能包含目标物体的候选区域;第二步是对这些区域进行 CNN 特征提取和分类识别以及使用回归算法精确定位目标物体的位置。随后相继出现如 Faster R-CNN^[9]、Mask R-CNN^[10]和 Cascade R-CNN^[11]等两阶段的目标检测方法。尽管两阶段方法可以实现较高的检测精度,但检测速度较慢。(2) 基于回归的单阶段目标检测方法,如单发多框检测器(Single Shot MultiBox Detector, SSD)^[12]、YOLO 系列^[13]、RetinaNet^[14]和 DETR 系列^[15]。单阶段方法可以直接对图像中的目标进行分类和检测,并进行边界框回归,无需生成候选区域,从而在保持较高检测精度的同时,具有较快的速度。

由于无人机航拍图像通常具有小目标占比高、目标分布密集、环境复杂以及目标尺度差异较大等问题,这些方法直接应用于无人机航拍图像目标检测任务时效果并不理想。Mu 等^[16]通过在 YOLOv5 中加入小目标检测层、跨通道融合模块和多级特征融合模块,使得模型更加关注小目标的重要特征,但该模型参数量较大。Zhu 等^[17]提出了一种通过改进 Transformer 预测头的 YOLOv5 无人机航拍图像目标检测模型 TPH-YOLOv5,该模型有效解决了无人机图像中目标尺度变化较大的问题。然而,其计算复杂度较高,导致检测速度有所下降。Zhou 等^[18]提出多尺度目标检测器,设计坐标和全局信息聚合模块来捕获更丰富的上下文信息,并引入特征融合模块来提高模型多尺度特征的表示能力,但其推理时间长,对小目标检测效果较差。Peng 等^[19]提出了一种基于高效卷积和多尺度特征融合的小型目标检测器 PS-YOLO,来解决小目标的信息丢失问题,但该模型对训练数

据依赖性强,增加了检测时间。赵子杰等^[20]通过在 YOLOv11n 网络中引入双线性自注意力机制以及改进检测头设计了 CBAM-YOLO, 提高了对小目标的检测性能。周葳楠等^[21]提出了一种增强弱特征表达的一阶段轻量级小目标检测算法 SA-YOLO, 以应对复杂背景下小目标特征被背景噪声淹没的问题, 但其增加了计算开销, 影响了实时性。

两阶段目标检测算法在检测精度方面有一定优势, 但网络训练时间长、推理速度慢。而单阶段目标检测算法模型结构简单, 实时性较强, 但检测精度较低。目前, 大多数研究仍围绕 YOLOv8 或以下版本展开优化, 而 YOLOv11 作为该系列的较新版本, 在保持高精度检测的同时, 通过结构改进和算法优化, 有效降低了参数数量和推理成本, 为提升小目标检测性能提供了新的研究方向。为解决无人机航拍图像小目标占比高、目标特征不清晰、目标尺度变化大以及环境复杂多变等问题, 本文提出了一种改进 YOLOv11n 的无人机航拍图

像小目标检测模型 MPI-YOLO。首先, 在 Backbone 中引入了多尺度特征聚合模块(Multi-Scale Feature Aggregation Module, MSFAM), 并用其替换前 2 个 C3k2 模块, 以增强 Backbone 对小目标信息的特征提取能力; 然后, 新增了 P2 检测层, 使其能够精确检测和定位小目标, 同时有效地融合多尺度信息; 最后, 提出了改进的双向密集特征金字塔网络(Improved Bidirectional Dense Feature Pyramid Network, IBDFPN), 通过引入 BIFPN2 和 BIFPN3 来构建多层级特征金字塔结构并引入跨层跳跃连接机制, 将浅层特征图蕴含的细粒度空间信息与深层特征图的语义表征进行高效融合, 从而实现了跨尺度信息的高效交互与融合。IBDFPN 通过扩展特征表达的尺度范围, 增强了模型对多尺度目标的特征表征能力, 为后续检测任务提供了更丰富的多层次特征信息。

2 MPI-YOLO 模型

本文提出的改进 YOLOv11n 的小目标检测模型 MPI-YOLO 整体结构如图 1 所示。




图 1 MPI-YOLO 网络结构

Fig.1 The network structure of MPI-YOLO

MPI-YOLO 是在 YOLOv11n 的基础上, 首先在 Backbone 中使用 MSFAM 模块替换前 2 个 C3k2 模块, 通过并行多分支卷积与特征重组机制, 强化网络对微小目标的差异化特征提取能力; 然后新增了一个分辨率为 160×160 的小目标检测层 P2, 通过扩展高分辨率特征层检测分支, 显著提升对微小目标的定位敏感度; 最后提出了 IBDFPN, 深度融合浅层细粒度特征与深层语义特征, 构建多层次特征表征空间, 提升了多尺度目标检测的鲁棒性。

2.1 使用 MSFAM 替换 C3k2

无人机航拍图像中普遍存在目标尺度微小、空间分布密集的特点。传统 CNN 因固定感受野的限制, 难以有效捕获多粒度特征表征, 导致小目标漏检率较高。为解决这一问题并增强网络对微小目标的感知能力, 本文使用 MSFAM 来替换 YOLOv11n 中的 Backbone 前 2 个 C3k2 模块。通过

在多分支结构中采用不同尺度的卷积操作^[22], MSFAM 能够提取不同感受野大小的目标特征信息, 帮助网络更好地理解特征图中像素间的关系, 从而提升检测精度。此外, MSFAM 还能避免特征图下采样过程中的信息丢失。图 2 展示了 MSFAM 的详细结构, 其包含四个特征提取分支。主分支由核大小为 1×1 、 3×3 和 5×5 的卷积模块组成, 每个卷积模块由卷积层、批量归一化和 SiLU 激活函数三部分构成。使用 SiLU 激活函数, 在不同数据分布下能自适应调整输出, 引入非线性因素, 增强模型对复杂特征的学习能力。相较于传统的 ReLU 等激活函数, SiLU 在一些任务中能使模型训练更稳定, 收敛速度更快, 提高特征表达能力。批量归一化操作, 可对输入数据进行归一化处理, 使数据分布更稳定。这有助于缓解梯度消失或爆炸问题, 加快模型收敛速度, 在一定程度上增强模型的泛化能力, 减少模型对超参数的敏感性。




图 2 MSFAM 结构

Fig.2 Structure of MSFAM

MSFAM 的工作过程如下: 首先将尺寸为 $H \times W \times C$ 的输入特征图分为主分支和残差分支。主分支使用 1×1 卷积操作且保持特征图尺寸不变, 随后进一步分为三个卷积子分支。第一个子分支依次使用 3×3 卷积模块和 1×1 卷积模块; 第二个子分支依次使用 5×5 卷积模块和 1×1 卷积模块; 第三个子分支仅使用 1×1 卷积模块提取

特征。三个子分支输出经过沿通道维度拼接和 1×1 卷积降维至原始通道数 ($H \times W \times C$)。这种结构有助于缓解深度网络训练中的梯度消失或爆炸问题, 使信息能更顺畅地在网络中传递, 同时也有利于模型学习恒等映射, 更容易训练深层网络。残差分支仅使用单个 1×1 卷积模块, 输出特征图尺寸同样为 $H \times W \times C$ 。由于网络深度较深, 在特征

提取的过程当中, 不可避免的会有一些信息丢失, 主分支和残差分支的输出特征图沿通道维度拼接得到尺寸为 $H \times W \times 2C$ 的特征图。残差连接通过在网络中添加跳跃连接, 缓解了深层神经网络中的梯度消失问题, 使梯度能够直接从深层传播到浅层, 从而让网络更容易训练、支持更深的架构, 并提高训练稳定性, 达到增强特征提取的效果。最后, 采用 1×1 卷积模块进行降维, 最终得到与输入尺寸一致的 $H \times W \times C$ 特征图作为 MSFAM 的输出。将不同路径提取的特征进行融合, 这能整合不同尺度、不同感受野下提取的特征信息, 为后续处理提供更丰富、全面的特征表示, 提高了目标检测的准确性。

2.2 新增 P2 小目标检测层

针对无人机航拍图像中微小目标易漏检、定

位精度低的问题, 本文在 YOLOv11n 原始三个检测层 (P3、P4 和 P5) 基础上, 新增 P2 高分辨率检测层。添加 P2 检测层后的特征融合网络结构如图 3 所示。添加新的检测层级时, 需要确保特征在不同分辨率之间有正确的融合路径。模型最终使用四个检测层 (对应 P2、P3、P4 和 P5), 设计目的是确保 P2 检测头能够有效利用来自更深层的语义信息, 同时保持其高分辨率特性, 从而提高对小目标的检测能力; P2 层直接接入 Backbone 的浅层输出, 保留 $1/4$ 输入尺寸的高分辨率特征图 ($H \times W = 160 \times 160$)。这些目标原本因尺寸微小容易被忽视或误分类, 现在受益于 P2 层的高灵敏度, 能被更好地检测到, 从而提高了小目标检测的整体准确率。




图 3 添加 P2 检测层后的特征融合网络结构

Fig.3 Structure of feature fusion network with the added P2 detection layer

2.3 提出了 IBDFPN

在卷积神经网络中, 浅层特征图通常具有较高的空间分辨率, 包含物体边缘、纹理和色彩等细节信息; 深层特征图虽然空间分辨率较低, 但蕴含丰富的语义信息 (如物体形态、结构及类别属性)。因此, 目标检测网络普遍采用特征融合策略以提升多尺度目标检测性能^[23]。特征金字塔网

络 (Feature Pyramid Network, FPN) 作为跨尺度特征融合的经典范式, 通过构建自上而下的横向连接结构, 实现浅层细节特征与深层语义特征的高效融合, 提升了多尺度目标检测能力^[24]。

针对无人机航拍图像中目标尺度变化大、分布密集等特点, Jiang 等^[25]提出双向密集特征金字塔网络 (Bidirectional Dense Feature

Pyramid Network, BDFPN), 其对传统特征金字塔网络进行改进。C1-C4 表示主干网络输出的不同层级的特征图, C1 是最浅层, C4 是最深层, 随着层级增加空间分辨率不断降低, 语义增强。C1-C4 通过卷积、上采样和跳跃连接操作, 对不同层级间双向传递和融合特征。自顶向下通过上采样融合高层语义信息和浅层细节信息, 自底向上通过卷积操作进一步融合特征, 让各层级特征都能充分利用不同层级的信息。但 BDFPN 对数据质量要求高, 数据中的噪声可能会在多次卷积和特征融合操作后, 对模型的学习产生误导, 导致模型性能下降。本文在此基础上提出了 IBDFPN, 其结构如图 4 所示。




图4 IBDFPN 结构

Fig.4 Structure of IBDFPN

相较于 BDFPN, IBDFPN 对不同层级特征之间的跳跃连接进行了重新规划, 使得特征融合的路径和方式更加灵活。该网络突出浅层特征优势, P2'' 特征图保留了较多图像细节信息, 使该层特征提前进入检测头, 能更突出浅层特征在目标检测中的作用, 对于小目标检测有更好效果; 更深的 P4 层意味着网络中更多的层次来对特征进行提炼, 随着网络层数的增加, P4 层的感受野会相应增大, 使得不同类别的目标之间的特征差异更加明显, 提升对较大目标和远距离目标的检测能力, 提高特征的区分度和鲁棒性, 更好地支持多尺度特征融合, 有效应对复杂场景下的目标检测挑战。

IBDFPN 通过 BiFPN2 和 BiFPN3 进行层级扩展和跨层连接优化实现航拍场景下的高效多尺度特征融合。BiFPN2 和 BiFPN3 分别用于处理 2 个和 3 个输入特征的融合。BiFPN2 通过可学习的权重参数自适应地确定每个特征的重要性。在特征融合之前, 首先需要解决不同输入特征可能具有不同空间尺寸的问题, 模块使用第一个输入特征的尺寸作为参考标准, 对所有输入特征进行空间对齐。当特征图尺寸大于目标尺寸, 则应用最大池化操作进行下采样; 当特征图尺寸小于目标尺寸, 则使用最近邻插值方法进行上采样。这确保了所有特征在融合前具有一致的空间尺寸。对于权重的处理, BiFPN2 模块引入了可学习的权重参数, 并采用快速的归一化方法计算最终权重:

$$\omega'_i = \frac{\omega_i}{\sum_{j=1}^2 \omega_j + \varepsilon} \quad (1)$$

其中 ω_i 表示第 i 个特征图的原始可学习权重, ω'_i 表示第 i 个特征图的归一化后的权重, ε 是一个很小的常数 (在实现中取 0.0001), 用于确保数值稳定性。这种归一化方式计算简单高效, 避免了 softmax 等复杂操作的计算负担。在特征融合阶段, 将归一化权重应用于相应的对齐特征, 然后沿指定维度 (默认是通道维度) 进行拼接:

$$Y = \text{Concat}(\omega'_1 \cdot X'_1, \omega'_2 \cdot X'_2) \quad (2)$$

BiFPN3 模块是对 BiFPN2 的扩展, 用于处理 3 个输入特征的情况。其基本原理与 BiFPN2 相似, 但处理的是 3 个输入特征。这两种特征融合模块相比传统方法具有的优势如下:

(1) 通过引入可学习的权重参数, 模型能够动态调整不同特征的重要性, 实现自适应的特征

融合过程。

(2) 使用拼接而非简单相加操作保留了原始特征的维度信息, 增强了模型的特征表示能力。

(3) 灵活的特征对齐机制使模块可以处理来自不同层级、不同尺度的特征图, 适用于各种复杂的网络结构。

在实际应用中, BiFPN2 适合处理双层特征融合的场景, 计算效率较高; 而 BiFPN3 在需要融合 3 个不同层级特征时提供了更丰富的特征表达能力。图 4 中 $P3''$ 、 $P4''$ 是经过 BiFPN3 拼接后形成的特征图, 其余为经过 BiFPN2 拼接后形成的特征图。

以图 4 中的 $P3$ 层为例, 特征信息融合过程如下: 经过多尺度特征信息融合后, $P3'''$ 作为 IBDFPN 的输出以及检测层的输入, 将用于无人机航拍图像的目标检测。

$$P3' = \text{Conv} \left(\frac{\omega_3^1 \times C_3 + \omega_4^1 \times \text{Upsample}(P4')}{\omega_3^1 + \omega_4^1 + \xi} \right) \quad (3)$$

$$P3'' = \text{Conv} \left(\frac{\omega_3^3 \times C_2 + \omega_3^2 \times P3' + \omega_2^1 \times \text{Conv}(P2'')}{\omega_2^1 + \omega_3^2 + \omega_3^3 + \xi} \right) \quad (4)$$

$$P3''' = \text{Conv} \left(\frac{\omega_3^5 \times P3' + \omega_3^4 \times \text{Conv}(P3'')}{\omega_3^4 + \omega_3^5 + \xi} \right) \quad (5)$$

$\omega_i^j \leq 1$ 表示不同的可学习权重, $\xi = 0.0001$ 用于避免数值不稳定, $\text{Conv}(\bullet)$ 表示卷积操作, Upsample 指的是上采样操作。

IBDFPN 主要创新点如下:

(1) 跨尺度特征金字塔结构扩展。在传统 FPN 基础上构建多级特征交互路径, 通过自顶向

下与自底向上双向信息流, 实现浅层细粒度特征与深层语义特征的深度聚合;

(2) 密集跳跃连接机制。引入跨层级捷径连接, 在特征上采样与下采样过程中保留原始特征图的完整性, 避免信息稀释。

3 实验

3.1 实验设置

本文实验环境所使用的操作系统为 Ubuntu20.04, CPU 为 Intel(R)Core(TM) i7-14700HX, GPU 为 NVIDIA RTX3090Ti 显卡, 编程语言是 Python3.9.7, 使用 CUDA 11.8 和 PyTorch 1.8.1 作为深度学习框架。在模型训练期间, 训练轮数为 300, 训练图像大小设置为 640×640 , 批次大小为 8。为确保实验结果的可比性, 所有实验均在相同的实验环境下进行。

3.2 实验数据集

VisDrone2019 数据集^[26]是由 AISKEYEY 团队采集, 专为无人机视觉目标检测设计。该数据集包含 8629 张静态图像, 划分为训练集 6471 张、验证集 548 张和测试集 1610 张, 共约 260 万个标注边界框, 涵盖了行人、自行车、摩托车、汽车和公共汽车等 10 个目标类别。

3.3 消融实验

为验证 MSFAM 中残差分支的具体贡献, 将 YOLOv11n+MSFAM (无残差分支) 模型与 YOLOv11n+MSFAM (有残差分支) 模型在 Visdrone2019 数据集下进行实验, 实验结果如表 1 所示。实验结果表明: 相较于 YOLOv11n+MSFAM (无残差分支) 模型, YOLOv11n+MSFAM (有残差分支) 模型的 mAP50 和 mAP50-95 分别提高了 1.2 和 2.6 个百分点, 其检测性能更优。

表 1 VisDrone2019 数据集下 YOLOv11n+MSFAM (无残差分支) 与 YOLOv11n+MSFAM (有残差分支) 的对比结果

Table 1 Comparative results between YOLOv11n+MSFAM (without residual branch) and YOLOv11n+MSFAM (with residual branch)

on VisDrone2019 dataset							
模型	Precision	Recall	mAP50 /%	mAP50-95 /%	Params /M	GLOPS /G	FPS

YOLOv11n+MSFAM(无残差分支)	0.47	0.36	36.7	21.9	3.31	22.4	80.3
YOLOv11n+MSFAM(有残差分支)	0.49	0.37	37.9	24.5	3.32	22.4	80.6

为验证 IBDFPN 的改进效果,将基线模型集成 BDFPN (YOLOv11n+BDFPN) 的对照模型与基线模型集成 IBDFPN (YOLOv11n+IBDFPN) 的新模型在 VisDrone2019 数据集下进行实验,实验结果如表 2 所示。实验结果表明,相较于 YOLOv11n+BDFPN 模型,YOLOv11n+IBDFPN 的 mAP50 和 mAP50-95 分别提高了 3.5 和 2.6 个百分点,其检测性能更优。

为验证本文提出 MPI-YOLO 模型中各个改进策略的有效性,选择在 VisDrone2019 数据集上进行消融实验,采用 YOLOv11n 模型作为基线 (Baseline),分别加入 MSFAM 模块、P2 检测层和 IBDFPN 模块三个改进策略对网络模型预测结果

进行比较,实验结果如表 3 所示。从表 3 消融实验结果可以得出,与基线模型相比,加入 MSFAM 后,其 mAP50 和 mAP50-95 分别提高了 5.4 和 5.6 个百分点;加入 P2 检测层后,其 mAP50 和 mAP50-95 分别提高了 3.6 和 2.6 个百分点。将 IBDFPN 加入基线模型后,其 mAP50 和 mAP50-95 分别提高了 5.3 和 3.8 个百分点。融合三个改进策略的模型与基线模型相比,其 mAP50 和 mAP50-95 分别提高了 9.1 和 6.3 个百分点。上述实验结果验证了本文提出的三个改进策略在无人机航拍图像目标检测中的有效性。

表 2 VisDrone2019 数据集下 YOLOv11n+BDFPN 与 YOLOv11n+IBDFPN 的对比结果

Table 2 Comparison results of YOLOv11n+BDFPN and YOLOv11n+IBDFPN on the VisDrone2019 dataset

模型	Precision	Recall	mAP50 /%	mAP50-95 /%	Params /M	GLOPS /G	FPS
YOLOv11n+BDFPN	0.44	0.36	34.3	20.1	3.11	7.4	69.8
YOLOv11n+IBDFPN	0.49	0.37	37.8	22.7	3.16	11.5	68.9

表 3 VisDrone2019 数据集上消融实验的对比结果

Table 3 Comparison results of ablation experiments on the VisDrone2019 dataset

Baseline	MSFAM	P2	IBDFPN	Precision	Recall	mAP50 /%	mAP50-95 /%	Params /M	GLOPS /G	FPS
√				0.43	0.33	32.5	18.9	2.58	6.3	87.6
√	√			0.49	0.37	37.9	24.5	3.32	22.4	80.6
√			√	0.49	0.37	37.8	22.7	3.16	11.5	68.9
√		√		0.47	0.35	36.1	21.5	2.74	11.3	59.5
√	√		√	0.49	0.38	38.5	24.6	3.81	23.3	70.3
√		√	√	0.50	0.38	39.1	24.8	3.45	20.1	62.3
√	√	√	√	0.52	0.40	41.6	25.2	3.89	27.6	59.0

为进一步分析各改进策略在特征提取中的效果,通过可视化对比展示了实施该策略前后热力图的差异,如图 5 所示:(a)Baseline 对应的热力图;(b)为 Baseline+MSFAM 对应的热力图;(c)

为 Baseline+MSFAM+IBDFPN 对应的热力图,(d)为 Baseline+MSFAM+P2+IBDFPN (即 MPI-YOLO)对应的热力图,对比结果表明,本文提出的网络模型能够更准确地区分小目标物体与背景信息。




图5 不同模型热力图效果对比

Fig.5 Comparison of heatmap effects across different models

3.4 对比实验

本文所提出的 MPI-YOLO 模型与其他目标检测

模型在 VisDrone2019 验证集上的对比实验结果如表 4 所示。

表 4 不同目标检测方法在 VisDrone2019 数据集上的对比结果

Table 4 Comparison results of different target detection methods on the VisDrone2019 dataset

模型	Precision	Recall	mAP50 /%	mAP50-95 /%	Params /M	GLOPS /G	FPS
Faster R-CNN	0.346	0.368	36.3	20.6	41.0	207.0	—
SSD	0.211	0.358	24.0	11.9	12.3	63.2	—
YOLOv5s	0.504	0.380	38.8	23.2	9.1	23.8	—
YOLOv5m	0.490	0.370	37.0	20.9	20.9	48.0	109.9
YOLOv8s	0.506	0.381	39.6	23.6	11.2	28.5	160.5
YOLOv10n	0.442	0.342	34.2	19.8	2.26	6.5	—
YOLOv11n	0.430	0.330	32.5	18.9	2.6	6.3	87.6
YOLOv11s	0.509	0.382	39.0	23.4	94.0	21.3	—
CBAM-YOLO ^[20]	0.348	0.338	38.9	30.6	3.76	12.4	124.6
YOLO-HV ^[27]	0.480	0.388	38.1	19.9	38.5	111.9	—
MPI-YOLO	0.521	0.400	41.6	24.8	3.89	27.6	59.0

本文提出的 MPI-YOLO 模型在 Precision、Recall 和 mAP50 评价指标上均优于其他对比模型。该模型在保持计算量和参数量相对较小的同时,检测精度最高,综合性能表现最优,具有一定的鲁棒性和实用性。

3.5 可视化

为直观展示 MPI-YOLO 模型的性能优势,在 VisDrone2019 数据集中选择四种典型无人机拍摄图像场景,与现有模型 YOLOv5s、YOLOv8s 和 YOLOv11n 进行可视化对比分析,红色框代表漏检情况,黄色框代表误检情况,如图 6 所示。在小规模

密集人群中,准确检测出操场上的目标人员。对于远处小尺寸车辆的检测,MPI-YOLO 模型显著优于其他模型。在低光照条件下,能够有效识别更多车辆。上述结果表明,MPI-YOLO 通过多模块协同优化,在

复杂背景、密集分布、尺度变化及低光照等多元场景中均展现出更强的检测鲁棒性,在处理各种复杂检测场景中具有明显优势。




图6 VisDrone2019 数据集中的四种典型无人机捕获图像场景在不同模型下的视觉检测结果

Fig.6 Visual detection results of four typical UAV-captured image scenarios in the VisDrone2019 dataset under different models

3.6 泛化实验

为了验证本文提出的 MPI-YOLO 模型的泛化能力,选择在无人机航拍密集小目标数据集 UAVDT 数据集^[28]和 Tinyperson^[29]数据集上进行泛化实验。UAVDT 数据集是由南京理工大学和香港科技大学联合创建,涵盖广场、高速公路等多种场景,背景丰富且复杂,具有变化尺度大、背景复杂多样等特点。该数据集包含训练集 24778 张图像,测试集 15598 张图像,总标注数超过 80000 个。Tinyperson 数据集是针对低分辨率小目标检测而设计的,主要用于检测低分辨率的海上和陆地两类人类目标,总计包含 1610 张图像和 72651 个标注对象。在实验设置中,将 1610 张图像按照 8:1:1 的比例划分为训练集 1288 张图像,验证集 161 张图像和测试集 161 张图像进行实验。

表 5 列出了 MPI-YOLO 与其他目标检测模型在 UAVDT 数据集上的对比实验结果,结果表明 MPI-

YOLO 综合性能最优。相比 YOLOv11n, MPI-YOLO 的 mAP50 提高了 6.3 个百分点;相比 YOLOv8s, mAP50 提升了 3.8 个百分点。验证了 MPI-YOLO 模型的泛化性能良好。

表 5 不同目标检测方法在 UAVDT 数据集上的对比结果

方法	mAP50 %	mAP50-95 %
YOLOv8s	32.8	20.1
GLSAN ^[30]	30.5	19.0
ClusDet ^[31]	26.5	13.7
DMNet ^[31]	24.6	14.7
GDFNet ^[32]	26.1	15.4
SODNet ^[32]	29.9	17.1
DSHNet ^[32]	30.4	17.8
CDMNet ^[33]	35.5	20.7
YOLOv11n	30.3	17.9
MPI-YOLO	36.6	22.5

表 6 列出了 MPI-YOLO 与其他目标检测模型在 Tiny person 数据集上的对比实验结果, 结果表明 MPI-YOLO 综合性能最优。相比 YOLOv11n, MPI-YOLO 的 mAP50 提高了 5.3 个百分点; 相比 YOLOv8s, mAP50 提升了 3.1 个百分点。验证了 MPI-YOLO 模型的泛化性能良好。

表 6 不同目标检测方法在 Tiny person 数据集上的对比结果

the Tiny person dataset		
方法	mAP50 /%	mAP50-95 /%
YOLOv8s	30.6	16.8
GLSAN ^[30]	28.5	15.2
ClusDet ^[31]	20.7	11.2
DMNet ^[31]	19.2	9.3
GDFNet ^[32]	23.1	10.2
SODNet ^[32]	24.8	12.5
DSHNet ^[32]	27.2	12.7
CDMNet ^[33]	32.5	15.1
YOLOv11n	28.4	13.5
MPI-YOLO	33.7	17.4

结束语

在无人机视觉领域, 针对航拍图像小目标检测难题, 本文提出了改进 YOLOv11n 的小目标检测模型 MPI-YOLO。通过在 Backbone 引入 MSFAM 替换前 2 个 C3k2 模块, 实现了跨分支多尺度卷积操作下的丰富特征信息提取; 新增 P2 检测层则显著增强了模型对微小目标的检测能力; 提出的 IBDFPN 有效促进了浅层细粒度特征与深层语义特征的高效融合。消融实验验证了各改进策略的有效性, 对比实验表明 MPI-YOLO 模型在复杂场景下的检测性能优于其他对比模型, 能够有效提高检测准确率。

然而, 该模型在计算资源占用与推理效率方面仍存在优化空间。后续研究将聚焦于轻量化技术路径, 通过模型结构优化、剪枝策略及高效特征表示学习等技术, 在保持检测精度的同时进一步提升计

算效率, 为智能遥感分析、无人系统自主决策等领域提供更优解决方案。

参考文献

- [1] ZHANG L, WANG M, FU Y, et al. A forest fire recognition method using UAV images based on transfer learning[J]. *Forests*, 2022, 13(7): 975.
- [2] JIANG C, REN H, YE X, et al. Object detection from UAV thermal infrared images and videos using YOLO models[J]. *International Journal of Applied Earth Observation and Geoinformation*, 2022, 112: 102912.
- [3] BAO W, REN Y, WANG N, et al. Detection of abnormal vibration dampers on transmission lines in UAV remote sensing images with PMA-YOLO[J]. *Remote Sensing*, 2021, 13(20): 4134.
- [4] CHEN C, ZHENG Z, XU T, et al. YOLO-based UAV technology: A review of the research and its applications[J]. *Drones*, 2023, 7(3): 190.
- [5] WU X, LI W, HONG D, et al. Deep learning for Unmanned Aerial Vehicle-based object detection and tracking: A survey[J]. *IEEE Geoscience and Remote Sensing Magazine*, 2022, 10(1): 91–124.
- [6] BOUGUETTAYA A, ZARZOUR H, KECHIDA A, et al. Vehicle detection from UAV imagery with deep learning: A review[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2022, 33(11): 6047–6067.
- [7] CHENG H Y, WENG C C, CHEN Y Y. Vehicle detection in aerial surveillance using dynamic Bayesian networks[J]. *IEEE Transactions on Image Processing*, 2012, 21(4): 2152–2159.
- [8] MORANDUZZO T, MELGANI F, BAZI Y, et al. A fast object detector based on high-order gradients and Gaussian process regression for UAV images[J]. *International Journal of Remote Sensing*, 2015, 36(10): 2713–2733.
- [9] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2017, 39(6): 1137–1149.
- [10] HE K, GKIOXARI G, DOLLAR P, et al. Mask R-CNN[C]. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. New York, USA: IEEE, 2017: 2980–2988.
- [11] CAI Z, VASCONCELOS N. Cascade R-CNN: Delving into high quality object detection[C]. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. New York, USA: IEEE, 2018: 6154–6162.

- [12] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single shot multibox detector [C]. Lecture Notes in Computer Science, vol. 9905. Berlin, Germany: Springer, 2016: 21–37.
- [13] REDMON J, FARHADI A. YOLOv3: An incremental improvement [OL]. arXiv, 2018. <https://arxiv.org/abs/1804.02767>
- [14] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection [C]. Proceedings of the IEEE International Conference on Computer Vision (ICCV). New York, USA: IEEE, 2017: 2980–2988.
- [15] ZHU X, SU W, LU L. Deformable DETR: Deformable transformers for end-to-end object detection [EB/OL]. arXiv, 2021. <https://arxiv.org/abs/2010.04159>
- [16] MU A, WANG H, MENG W, et al. Small target detection in drone aerial images based on feature fusion [J]. Signal, Image and Video Processing, 2024, 18(1): 585–598.
- [17] ZHU X, LYU S, WANG X, et al. TPH-YOLOv5: Improved YOLOv5 based on transformer prediction head for object detection on drone-captured scenarios [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCV Workshops). New York, USA: IEEE, 2021: 2778–2788.
- [18] ZHOU L, LIU Z, ZHAO H, et al. A multi-scale object detector based on coordinate and global information aggregation for UAV aerial images [J]. Remote Sensing, 2023, 15(10): 2567–2580.
- [19] PENG S, FAN X, TIAN S. PS-YOLO: A small object detector based on efficient convolution and multi-scale feature fusion [J]. Multimedia Systems, 2024, 30(5): 241.
- [20] ZHAO Z J, WANG Y, TANG R Q, et al. Based on improved YOLOv11 for UAV target detection algorithm [J/OL]. Journal of Computer Applications, 2025,; <https://link.cnki.net/urlid/51.1307.tp.20250427.1138.002>. (in Chinese)
- 赵子杰, 王毅, 唐瑞卿, 等. 基于改进 YOLOv11 的无人机目标检测算法 [J/OL]. 计算机应用, 2025, <https://link.cnki.net/urlid/51.1307.tp.20250427.1138.002>.
- [21] ZHOU W N, WU Z H, ZHANG Z D, et al. Lightweight small target detection method based on weak feature enhancement [J]. Control and Decision, 2024, 39(2): 381–390. (in Chinese)
- 周葭楠, 吴治海, 张正道, 等. 基于弱特征增强的轻量化小目标检测方法 [J]. 控制与决策, 2024, 39(2): 381–390.
- [22] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions [C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). New York, USA: IEEE, 2015: 1–9.
- [23] JIANG L, YUAN B, WANG Y, et al. MA-YOLO: A method for detecting surface defects of aluminum profiles with attention guidance [J]. IEEE Access, 2023, 11: 71269–71286.
- [24] Li S, TONG Q, LIU X, et al. MA2-FPN for tiny object detection from remote sensing images [C]. Proceedings of the 15th International Congress on Image Signal Processing, Biomedicine Engineering and Informatics (CISP-BMEI). Piscataway, NJ: IEEE, 2022: 1–8.
- [25] JIANG L, YUAN B, DU J, et al. MFSODNet: Multiscale feature fusion small object detection network for UAV aerial images [J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 5015214.
- [26] DU D, ZHU P, WEN L, et al. VisDrone-DET2019: The vision meets drone object detection in image challenge results [C]. Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops. Piscataway, NJ: IEEE, 2019: 213–226.
- [27] XU S, ZHANG M, Chen J, et al. YOLO-HyperVision: A vision transformer backbone-based enhancement of YOLOv5 for detection of dynamic traffic information [J]. Egyptian Informatics Journal, 2024, 27: 100523.
- [28] YU H, LI G, ZHANG W, et al. The unmanned aerial vehicle benchmark: object detection, tracking and baseline [C]. Proceedings of the European Conference on Computer Vision (ECCV). Berlin, Germany: Springer, 2018: 370–386.
- [29] YU X, GONG Y, JIANG N, et al. Scale match for tiny person detection [C]. IEEE Winter Conference on Applications of Computer Vision. Snowmass Village, 2020: 1257–1265.
- [30] DENG S, LI S, XIE K, et al. A global-local self-adaptive network for drone-view object detection [J]. IEEE Transactions on Image Processing, 2021, 30: 1556–1569.
- [31] ZHANG Y, WU C, GUO W, et al. CFANet: efficient detection of UAV image based on cross-layer feature aggregation [J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 5608911.
- [32] ZHAO Q, LIU B, LYU S, et al. TPH-YOLOv5++: boosting object detection on drone-captured scenarios with cross-layer asymmetric transformer [J]. Remote Sensing, 2023, 15(6): 1687.

- [33] DUAN C, WEI Z, ZHANG C, et al. Coarse-grained density map guided object detection in aerial images[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops. Piscataway, NJ: IEEE, 2021: 2789–2798.

全部作者的中文简介:

王井阳, 出生于 1971 年, 硕士, 教授, 硕士研究生导师, CCF 高级会员 (51341S), 主要研究方向为人工智能、计算机视觉、深度学习。

薛为民, 出生于 2001 年, 硕士研究生, 主要研究方向为人工智能、计算机视觉。

黄敏, 出生于 1979 年, 博士, 教授, 硕士研究生导师, CCF 会员 (E2172M), 主要研究方向为人工智能、计算机视觉。

武少广, 出生于 1987 年, 硕士, 讲师, 主要研究方向为深度学习、人工智能。



WANG Jingyang, born in 1971, master, professor, master supervisor, is a member of CCF(51341S). His main research interests include artificial intelligence, computer vision, and deep learning.



WU Shaoguang, born in 1987, master, lecturer. His main research interests include deep learning and artificial intelligence.