



电光与控制
Electronics Optics & Control
ISSN 1671-637X, CN 41-1227/TN

《电光与控制》网络首发论文

题目: 航拍视角下小尺度车辆精确检测方法
作者: 林树铭, 冯桑, 谭俊楠
收稿日期: 2024-12-12
网络首发日期: 2025-11-05
引用格式: 林树铭, 冯桑, 谭俊楠. 航拍视角下小尺度车辆精确检测方法[J/OL]. 电光与控制. <https://link.cnki.net/urlid/41.1227.tn.20251104.1805.002>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

航拍视角下小尺度车辆精确检测方法

林树铭, 冯桑, 谭俊楠

(广东工业大学 机电工程学院, 广州 510000)

摘要：针对航拍视角下的车辆目标存在多尺度、目标小、背景复杂等问题，提出了一种基于多通道协同特征融合的 YOLOv8 改进模型 ZZQ-YOLO。首先，通过引入 LSKA 机制对主干网络的金字塔池化处理进行改造，提高模型在复杂背景下对关键信息的关注度。其次，应用一种新的多通道协同特征融合金字塔网络 MCFFPN 来增强不同分辨率、不同特征映射下的特征信息聚合，进一步提高颈部网络中小目标层对特征信息的提取。最后，使用 Focaler-MPDIoU Loss 损失函数，改善边框尺寸差异以及难易样本数量不均衡对梯度的不利影响，加快网络收敛速度。实验表明，改进模型 ZZQ-YOLO 较基线模型在 VisDrone2019 数据集的验证集 Val 与测试集 Test 上的平均精度 (mAP@0.5) 分别提升了 4.5%、3.6%，证明了模型改进的有效性。

关键词：目标检测; YOLOv8; 航拍视角; 特征融合; 损失函数

中图分类号：TP391.4 **文献标志码：**A

Accurate small-scale vehicle detection method from the perspective of aerial photography

LIN Shuming, FENG Sang, TAN Junnan

(College of Mechanical and Electrical Engineering, Guangdong University of Technology, Guangzhou 510000, China)

Abstract: To address challenges such as multi-scale targets, small object sizes, and complex backgrounds in aerial vehicle de-tECTION, an improved YOLOv8 model, named ZZQ-YOLO, is proposed based on multi-channel collaborative feature fusion. Firstly, LSKA mechanism is introduced to modify the pyramid pooling of the backbone network, enhancing the model's focus on critical information in complex backgrounds. Secondly, a novel Multi-Channel Collaborative Feature Fusion Pyramid Network structure is implemented to strengthen the aggregation of feature information across different resolutions and feature mappings, particularly improving feature extraction in the small-object layers of the neck network. Furthermore, the Focaler-MPDIoU Loss function is utilized to mitigate the adverse effects of bounding box size differences and uneven distribution of hard/easy samples on gradient calculations, expediting network convergence. Experimental results demonstrate that the ZZQ-YOLO model outperforms the baseline model, achieving an average precision (mAP@0.5) improvement of 4.5% on the VisDrone2019 Validation set and 3.6%, which validates the effectiveness of the proposed model en-hancements.

Key words: Target detection; YOLOv8; Aerial view; Feature fusion; Loss function

收稿日期：2024-12-12

修回日期：2025-01-12

基金项目：广东省研究生教育创新计划项目(粤教研函[2023]3号)

作者简介：林树铭(2000-), 男, 广东汕头人, 硕士生。

通讯作者：冯桑(1973-), 男, 海南琼海人, 博士, 副教授, 硕导。

0 引言

无人机在军事、民用和商业等领域的应用日益普及^[1]。航拍车辆检测任务，为交通管理、应急响应及城镇规划等领域提供了重要的数据支撑和治理效能提升。

目前，航拍车辆检测模型主要分为两类：基于图像处理和特征提取的传统目标检测方法，以及基于深度学习的目标检测方法。传统方法（如HOG特征、Haar特征等）通过手工设计特征并利用分类器进行车辆检测^[2-4]，但面临特征设计复杂、难以适应复杂场景等问题。随着深度学习的广泛应用，目标检测技术取得了显著进步，涌现出如R-CNN^[5]、Fast R-CNN^[6]、YOLO^[7-9]和SSD^[10]等经典模型。然而，两阶段检测模型虽在准确性上表现优异，但速度较慢。因此，单阶段检测模型成为无人机目标检测研究的主流。

尽管大中型目标检测已取得显著成果，小目标检测仍面临挑战。针对小目标检测，研究者们提出了多种改进方法，Fan等人利用深度大核卷积增强浅层特征的感受野，并利用点卷积混合通道位置，结合损失函数等方式来集中小目标更关键的特征信息^[11]。Li等人基于Bi-PAN-FPN的思想改善YOLOv8s的颈部网络，采用GhostblockV2结构替代部分C2f模块，提高模型的整体检测性能^[12]。孙佳宇等人提出了一种动态样本的注意力尺度序列融合框架AFD，使用轻量化动态点采样融合不同尺度的特征图来增强网络提取多尺度信息的能力，提高模型对关键信息的关注度^[13]。谌海云等人针对小目

标特征丢失的问题，设计了混合注意力卷积的小目标检测层，有效地提升了小目标检测的准确性，但同时也大幅增加了计算复杂度^[14]。

上述作者的研究往往在追求模型轻量化的过程中，面临检测精度的下降，或者在增强特征融合等优化提升方面导致模型的计算参数量和复杂度显著上升，使得改进后的模型难以在无人机等计算资源有限的嵌入式设备上实现高准确性、低计算量之间的平衡。

因此，针对航拍视角下小尺度车辆的目标检测方法进行研究，提出一种基于YOLOv8n的无人机车辆检测模型ZZQ-YOLO。主要工作如下：

（1）通过引入大型可分离核注意力机制^[15]改进主干网络中的SPPF模块，对原始特征进行加权处理，增强检测对象的相关特征来减少复杂背景对车辆检测的干扰。

（2）提出一种新的多通道协同特征融合金字塔网络结构替换原模型颈部网络，使用多个连接结构融合不同分辨率、不同特征映射的特征，增强输出层的表示能力和梯度传播。

（3）在模型中引入Focaler-MPDIoU^[16,17]，改善边框尺寸差异以及难易样本数量不均衡对梯度的不利影响，使模型更多地关注高质量样本，从而优化训练过程。

1 ZZQ-YOLO 目标检测模型

本次研究所提出的ZZQ-YOLO目标检测模型，整体网络结构如图1所示。




图1 ZZQ-YOLO 网络结构
Fig1 Structure of ZZQ-YOLO network

1.1 SPPF-LSKA 模块

针对航拍视角下，车辆等目标占据像素比例小、背景复杂的问题，在YOLOv8的金字塔池化处理模块（Scale-Process Pyramid Pooling, SPPF）中引入大型可分离核注意力机制（Local-Global Spatial Attention, LSKA）。

LSKA通过将一个大核卷积分解为多级子操作实现高效计算和上下文建模。如图2（a）所示，首先，大核卷积被分解为深度卷积、深度扩张卷积和通道卷积。其中，深度卷积和深度扩张卷积分别用于捕获局部和扩展的空间上下文信息，而通道卷积负责特征通道之间的交互与融合。而后，为降低计算复杂度，LSKA将2D卷积核继续分解为1D的水平（横向）卷积核和垂直（纵向）卷积核，并将分解后的卷积核依次串联以构建高效的卷积操作。




图2 LSKA 注意力结构

Fig2 The structure of LSKA attention

在上述卷积操作的基础上，注意力图的生成与特征加权过程紧密结合。该过程如下式所示：

$$Y_1 = \sum_H \sum_W W_{1 \times (2d-1)} * F \quad (1)$$

$$Y_2 = \sum_H \sum_W W_{(2d-1) \times 1} * Y_1 \quad (2)$$

$$D_1 = \sum_H \sum_W W_{1 \times \left\lfloor \frac{k}{d} \right\rfloor} * Y_2 \quad (3)$$

$$D_2 = \sum_H \sum_W W_{\left\lfloor \frac{k}{d} \right\rfloor \times 1} * D_1 \quad (4)$$

$$A = W_{1 \times 1} * D_2 \quad (5)$$

$$\bar{F} = A \otimes F \quad (6)$$

其中 F 表示输入特征图， $\bar{F}$ 表示输出特征图， D 、 Y 表示中间特征， H 、 W 分别表示其高度和

宽度, $*$ 表示卷积操作, k 表示最大感受野, d 表示扩张率, $\otimes$ 表示逐元素乘积。

1.2 多通道协同特征融合金字塔网络

小目标检测精度一直是YOLO系列亟待解决的难题,其主要原因在于深层网络在提取高级特征时,逐渐丢失浅层网络捕捉的细节信息。

为此,设计了多通道协同特征融合金字塔网络 (Multi-Channel Collaborative Feature Fusion Pyramid Network, MCFFPN)。其中,浅层特征融合结构(Shallow Feature Fusion Architecture, SFFA)通过双向连接保持浅层主干信息,有效提升小目标检测能力;深层特征融合结构(Deep Feature Fusion Architecture, DFFA)通过多向连接整合不同分辨率与特征映射的信息,进一步增强输出层的表达能力与梯度传播效率。两者在功能上逐步递进,构成从浅层到深层特征提取与融合的完整框架。MCFFPN整体结构如图3(a)所示。

1.2.1 浅层、深层特征融合结构

SFFA主要针对主干网络中的浅层空间信息,这些信息对小目标检测至关重要,但因其较为初级且易受干扰,直接利用可能影响后续检测的稳定性。因此, SFFA通过双向连接,将浅层特征作为辅助分支融入深层网络,以实现深浅结合,从而保留丰富的定位细节并提升网络的空间表征能力。具体结构如下图3(b)所示,其中 P_n 、 P'_n 、 P''_n 表示主干网络的特征层在颈部网络的两条路径, V7DS模块和 EUCB模块分别为更加高效的下采样模块和上采样模块, Fusion为特征融合方式。

针对特征融合方式,本文对比了三种常见方案,如图3(c)所示。串联融合和加权融合操作简

单,但无法动态调整特征权重,可能导致信息冗余或关键特征被稀释。为此,本文采用自适应特征融合,通过引入自注意力机制或动态权重学习,灵活调节特征权重,更高效地捕获多尺度、多层次的语义与位置信息^[18]。自适应融合公式如式(7)

$$O = \sum_i \frac{w_i}{e + \sum_j w_j} I_i \quad (7)$$

O 为输出值, I 为输入值, e 为极小值学习率,用于约束数值的震荡, w_i 和 w_j 表示不同权重学习参数。以 P'_4 为例,浅层特征融合机制如式(8)所示。

$$P'_4 = \text{Conv} \left(\frac{w_1 \cdot R(P_3) + w_2 \cdot \text{Conv}(P_4) + w_3 \cdot \text{Conv}(R(P'_5))}{w_1 + w_2 + w_3 + e} \right) \quad (8)$$

其中 P_3 、 P_4 、 P'_4 、 P'_5 分别为 P3、P4 层的输入特征, P4、P5 层的中间特征, Conv 为可分离卷积, R 为上采样或下采样。

DFFA 在 SFFA 的基础上进一步增强深层特征的表达能力,重点提升对中型目标的检测性能。具体而言, DFFA 利用多向跨层信息聚合机制,将来自不同分辨率的浅层特征与前一层的深层特征进行整合。

具体如图3(g)所示,以 P'_4 的输入为例,由跨浅层高分辨率 P'_5 、浅层低分辨率层 P'_3 、浅层同分辨率层 P'_4 和前一层的 P''_3 的信息聚合而成。最终 P'_4 可以同时合并来自4个不同层的信息,从而显著提升模型检测中型目标的性能,深层特征融合机制如式(9)所示。

$$P'_4 = \text{Conv} \left(\frac{w_1 \cdot P'_4 + w_2 \cdot R(P'_3) + w_3 \cdot R(P'_5) + w_4 \cdot R(P''_3)}{w_1 + w_2 + w_3 + w_4 + e} \right) \quad (9)$$




图3 MCFFPN结构

Fig3 The structure of MCFFPN

1.2.2 高效上下采样模块

在目标检测任务中，下采样和上采样模块对特征提取与融合至关重要。为更好地保留关键特征信息，分别对下采样和上采样模块进行了优化。

针对下采样，采用了YOLOv7中设计的更先进下采样模块(YOLOv7 Downsampling, V7DS)^[19]，其结构如图3(d)所示。V7DS包含两个分支：第一个分支通过最大池化层下采样后，再经卷积调整通道数；第二个分支先通过卷积调整输入特征图的通道数，随后再使用步长为2的卷积完成下采样以捕获更多空间上下文信息。最终，两分支结果合并生成空间分辨率减半的特征图。

相比YOLOv8原来结构中简单使用两个步长为2的卷积进行下采样，V7DS模块结合了最大池化和卷积操作，能够更好地保留局部显著特征，同时捕获更大的感受野，显著提升了多尺度下采样过程对小目标的保留能力。

而上采样使用EUCB模块，其用于逐步将低分辨率特征图放大至目标分辨率，以恢复高尺度层的空间信息^[20]，其工作流程如图3(e)所示。首先，对输入特征图进行2倍上采样；随后，使用深度可分离卷积(Depthwise Separable Convolution, DWC)在通道内进行卷积操作，再通过逐点卷积(Pointwise Convolution, PWC)整合通道信息，得到的特征图经过批量归一化和Leaky-ReLU激活

处理。最后，激活后的特征图通过卷积层进一步整合和压缩通道信息。

该上采样模块能够有效压缩和提取关键特征，为后续网络层提供更精细的输入，同时增强对高尺度层空间信息的利用。

1.2.3 多尺度特征提取模块

上述SFFA和DFFA分别针对浅层和深层特征进行融合与优化，有效提升了模型对小目标和中型目标的检测性能。然而，为进一步增强模型对多尺度目标的表达能力，本文引入了一种基于异构核选择机制的多尺度卷积模块(Multi-scale Convolution Block, MSCB)^[20]，以补充对多尺度、多分辨率上下文信息的捕获。

MSCB整体结构如图4(a)所示，主要包括特征通道扩展、多尺度卷积模块(MSDC)、以及特征融合与残差连接三部分。其中，MSDC模块是MSCB的核心，如图4(b)所示。MSDC通过多尺度并行卷积实现不同尺度特征的独立提取：输入特征被分为不同通道组，并分别采用不同感受野的深度卷积核(例如，P3层使用1×1、3×3和5×5卷积核)进行处理。这种设计允许各分支专注于不同尺度的特征，从而捕获更加丰富的空间语义信息，同时避免通道间的特征干扰，保留细粒度结构信息。




图4 MSCB 模块

Fig4 Multi-scale Convolution Block

随后,MSDC通过通道混洗(Channel Shuffle)

[21]技术对各分支的特征进行重组与融合,充分发挥了多尺度卷积的表达优势。

1.3 损失函数 Focaler-MPDIoU

损失函数是目标检测模型的重要组成部分。

YOLOv8初始模型的损失函数由VFL Loss、CIoU Loss和DFL Loss[22]三者加权组合而成。其中,CIoU损失函数综合考虑了预测框与真实框的中心点距离、纵横比一致性以及重叠面积,但在处理边框尺寸差异和样本不均衡问题上仍存在局限性[23]。为此,本文引入了MPDIoU损失函数和Focaler-IoU损失函数进行优化。

MPDIoU通过直接优化预测框与真实框左上角和右下角的距离,更精确地捕捉边框尺寸差异与回归精度,解决CIoU在面对不同大小但具有相同长宽比的矩形框时难以准确评估边界匹配情况。

MPDIoU以及损失函数 L_{MPDIoU} 计算公式为:

$$\begin{cases} d_1^2 = (x_1 - x_1^{gt})^2 + (y_1 - y_1^{gt})^2 \\ d_2^2 = (x_2 - x_2^{gt})^2 + (y_2 - y_2^{gt})^2 \end{cases} \quad (10)$$

$$MPDIoU = IoU - \frac{d_1^2}{w_{gt}^2 + h_{gt}^2} - \frac{d_2^2}{w_{gt}^2 + h_{gt}^2} \quad (11)$$

$$L_{MPDIoU} = 1 - IoU + \frac{d_1^2}{w_{gt}^2 + h_{gt}^2} + \frac{d_2^2}{w_{gt}^2 + h_{gt}^2} \quad (12)$$

式中: (x_1^{gt}, y_1^{gt}) 和 (x_1, y_1) 分别表示真实框和预测框左上角坐标, (x_2^{gt}, y_2^{gt}) 和 (x_2, y_2) 分别表示真实框和预测框的右下角坐标, (x_1^I, y_1^I) 和 (x_2^I, y_2^I) 分别表示真实框和预测框交集的左上角和右下角坐标, d_1 、 d_2 分别是预测边界框的左上角

点到真实边界框左上角点与右下角点的欧氏距离。

针对航拍数据集中目标种类繁多、样本分布不均的问题。引进了一种基于Focal Loss思想的Focaler-IoU损失函数,通过线性区间映射重构IoU损失,使得模型在IoU值较高的区间内(即高质量样本)产生更大的梯度,从而引导模型更多地关注这些样本,并学习到更精确的定位信息。公式如下:

$$IoU_{Focaler} = \begin{cases} 0, & IoU < d \\ \frac{IoU - d}{u - d}, & d \leq IoU \leq u \\ 1, & IoU > u \end{cases} \quad (13)$$

$$L_{Focaler-IoU} = 1 - IoU_{Focaler} \quad (14)$$

最终,将MPDIoU和Focaler-IoU整合为Focal-MPDIoU,既能更精确地匹配预测框和真实框,又能有效解决样本不平衡问题。Focal-MPDIoU损失函数计算公式如式(15)所示。

$$L_{Focaler-MPDIoU} = L_{MPDIoU} + IoU - IoU_{Focaler} \quad (15)$$

2 实验结果与可视化分析

2.1 数据集

本文选用公开数据集VisDrone2019[24]作为实验验证对象。该数据集是目前主流的小目标检测对象之一,由不同型号的无人机在中国14个城市拍摄的,图像标签类别包括行人、卡车、自行车等10个种类,涵盖不同的光照条件和天气情况。包含了6471张训练集、548张验证集、1610张测试集图像。

2.2 实验环境及评价指标

本实验平台采用Windows11作为操作系统,CPU为AMD Ryzen7 7950X3D; 64GB运行内存; GPU为Nvidia GeForce RTX4070Ti Super, 16GB。pytorch的框架版本为2.2.0+cu121, python版本为3.9.7, Batch size设置为16, 图像大小设置为640×640, 迭代次数设置为200。网络未使用预训练模型的权重且所有实验使用一致的超参数训练验证。

采用精确率(P)、召回率(R)、平均精确率均值(mAP)、参数量(Para)、浮点运算次数(GFLOPs)和帧率(FPS)作为实验的评价指标,以此来衡量改进的有效性。

2.3 消融实验

2.3.1 不同特征融合网络的性能比较

为了验证颈部网络MCFFPN的有效性,在VisDrone2019验证集Val上比较了AFPN、BIFPN、HSFPN和MCFFPN应用于相同基准模型的结果,如

表1所示。与基准模型相比，AFPN不仅 $mAP@0.5$ 下降0.9%，计算复杂度还有所上升，而HSFPN与BIFPN两个经典的特征提取网络虽然在参数及计算复杂度上取得一定程度的优势，但识别的准确性仍比不上本文所提出的MCFFPN。

MCFFPN能够灵活控制深层网络的抽象语义信息与浅层网络的精细空间信息，更好地融合了不同层之间的数据流，在最高检测精度达到了32.9%的同时，参数量也减少到2.1M。

表1 不同特征融合网络对比实验

Table 1 Comparison experiment of different feature fusion net-works

Model	mAP@0.5/%	mAP@0.5:0.95/%	Para/M	GFLOPs
PA-FPN	32.1	18.5	3.0	8.1
AFPN	31.2	16.8	2.6	8.6
HSFPN	32.3	18.6	2.0	7.0
BIFPN	32.5	18.8	2.0	7.1
MCFFPN	32.9	19.0	2.1	7.1

2.3.2 不同融合方式性能对比

在MCFFPN中的SFFA和DFFA结构中支持加权融合、串联融合和自适应融合三种特征融合方式。为了验证本文使用自适应融合的性能优越性，与另外两种融合方式进行了实验对比。

实验结果如表2所示，自适应融合方式在保持较低计算开销和参数量的同时，显著提升了检测精度。表3展示了三种融合方式的可视化效果。相比于串联融合和加权融合，自适应融合能够灵活调整特征权重，使得SFFA和DFFA输出的特征图中目标的关键特征更加突出和清晰，进一步验证了其在特征表达能力上的优越性。


表2 不同融合方式对比实验

Table 2 Comparison experiment of different fusion Methods

Fusion	mAP@0.5/%	mAP@0.5:0.95/%	Para/M	GFLOPs
加权融合	32.8	18.9	2.1	7.1
串联融合	32.7	18.8	2.1	7.0
自适应融合	32.9	19.0	2.1	7.1

表3 不同融合方式效果可视化

Table 3 Visualization of the Effects of Various Fusion methods



2.3.3 不同损失函数的性能比较

为评估Focaler-MPDIoU损失函数的有效性，本研究在VisDrone2019验证集Val上开展了实验。实验中，将Focaler-MPDIoU损失函数应用于基准模型，并与CIoU、WIoU、GIoU、EIoU、SIoU、MPDIoU以及Focaler-IoU等典型损失函数进行了对比分析。

表4 不同损失函数的性能比较

Table 4 Performance comparison of different loss functions

Model	P/%	R/%	mAP@0.5/%	mAP@0.5:0.95/%
CIoU	42.8	32.1	32.1	18.5
WIoU	39.7	28.7	29.2	16.2
GIoU	41.3	31.5	31.2	17.1
EIoU	43.2	32.5	32.9	18.8
SIoU	43.3	31.8	32.7	18.7
MPDIoU	44.6	33.6	33.6	19.2
Focaler-IoU	44.2	32.9	33.1	18.9
Focaler-MPDIoU	45.3	33.7	34.2	19.4

如表4所示，当将CIoU损失替换为Focaler-IoU和MPDIoU损失时，在检测精度 $mAP@0.5$ 指标上，两者均优于其他传统的IoU损失函数。进一步地，将Focaler-IoU与MPDIoU结合形成的Focaler-MPDIoU损失函数，在经过多次实验并优化权重因子($d=0.1$, $u=0.95$)后，实现了最佳性能，检测精度提升了2.1%，显著高于其他IoU损失函数。

2.3.4 总体消融实验

为证明所提出的改进点对基线模型检测效果提升的有效性，以单独加入和多个模块进行不同组合加入的方式进行消融实验。针对VisDrone2019验证集Val中检测目标较为集中，遮挡状况少，而测试集Test中的检测目标遮挡状态多，导致模型训练后，在验证集Val和测试集Test上的实验结果差距过大的

问题。本文以Val集和Test集共同作为最后实验验证结果的分析。

如表5所示，通过系列实验验证了各改进模块的有效性。最终，三种改进结合后的ZZQ-YOLO模型在Val和Test集上的精确度分别提升至46.4%和

40.2%，mAP@0.5和mAP@0.5:0.95分别提升至36.6%、30.0%和21.6%、16.3%，参数量减少0.2M。

实验结果表明，多个模块组合使用能进一步提升准确率，且FPS为95.9仍然满足实时性检测的需求。

表 5 消融实验

Table 5 Ablation experiment

SPPF-LSKA	MCFFPN	Focaler-MPDIoU	Precision/%		Recall/%		mAP@0.5/%		mAP@0.5:0.95%		FPS	Para/M	GFLOPs
			Val	Test	Val	Test	Val	Test	Val	Test			
√	√	√	42.8	37.6	32.1	28.5	32.1	26.4	18.5	14.7	115.5	3.0	8.1
			44.3	39.0	33.3	29.2	33.5	27.1	19.5	15.0	122.4	3.2	8.3
			42.9	37.8	33.2	29.3	32.9	26.8	19.0	14.9	99.6	2.1	7.1
√	√	√	45.3	38.2	33.7	31.0	34.2	27.5	19.4	15.5	115.6	3.0	8.1
			44.5	40.2	35.8	31.1	35.8	28.9	20.9	16.1	96.2	2.8	9.5
√	√	√	46.4	40.2	36.6	31.5	36.6	30.0	21.6	16.3	95.9	2.8	9.5

2.4 对比实验

为进一步验证改造模型的检测性能，本文选用目前最新目标检测SOTA模型YOLOv11n、经典的目标检测模型以及优秀的改进模型UAV-YOLOv8^[12]、BDAD-YOLO^[13]，在Visdrone2019小目标检测数据集上进行对比，其实验结果如表6所示。

表 6 对比实验

Table 6 Comparisons experiment

Model	mAP@0.5/%		mAP@0.5:0.95/%		Para/M	GFLOPs	FPS
	Val	Test	Val	Test			
YOLOv5n	22.2	18.3	10.8	8.6	1.8	4.2	129.4
YOLOv5s	29.8	25.1	15.8	12.7	7.0	15.8	108.5
YOLOv7-Tiny	32.9	27.2	16.4	13.2	6.0	13.1	157.3
YOLOv8n	32.1	26.7	18.5	14.8	3.0	8.1	115.5
YOLOv8s	38.6	31.9	24.2	19.6	11.1	28.7	102.7
YOLOv10n	31.9	26.2	18.5	14.3	2.7	8.4	112.3
YOLOv11n	32.2	26.4	18.7	14.5	2.5	6.5	118.6
文献[12]	33.4	26.7	19.3	14.7	3.6	11.8	94.8
文献[13]	36.1	29.8	20.7	16.3	3.2	10.8	-
ZZQ-YOLO	36.6	30.0	21.6	16.3	2.8	9.5	95.9

首先，在精度上相较于其他模型，ZZQ-YOLO在精确率、mAP@0.5与mAP@0.5:0.95上具有更好的性能体现。在验证集Val上分别达到了46.4%、36.6%、21.6%，在测试集Test上分别达到了40.2%、30.0%、16.3%。在参数上，相较于基线模型减少了0.2M。对比与本文同数据集下的最新检测模型BDAD-YOLO和UAV-YOLOv8模型参数量少了0.4M和0.8M，在mAP@0.5以及mAP@0.5:0.95上ZZQ-YOLO也更具优势。

与轻量级的YOLOv5n、YOLOv10n、YOLOv11n检测模型相比，模型ZZQ-YOLO在验证集Val上的mAP@0.5指标上分别提高了14.4%、4.7%、4.4%。

与整体规模更大的YOLOv5s、YOLOv7-Tiny、YOLOv8s相比，ZZQ-YOLO在验证集Val和测试集Test上相较于YOLOv5s、YOLOv7-Tiny有更好的性

能体现。在验证集Val和测试集Test上检测效果落后于YOLOv8s，但模型大小以及计算复杂度远低于它。

实验结果表明，与其他单阶段目标检测模型比较，ZZQ-YOLO模型以较低的计算参数量实现了较高的检测精度，且帧率仍然满足实时性检测的需求，更适用于航拍视角下的小目标检测任务。

2.5 可视化结果与分析

为直观展示改进模型在复杂背景下目标检测的能力，本研究采用Grad-CAM^[25]技术生成热力图，以可视化方式揭示模型对目标特征的关注程度。热力图红色的区域代表关注度更高。且为了清晰区分基线模型与改进模型在目标检测性能上的差异，我们采用黄色框标注原模型漏检而改进模型成功检测出的车辆目标。如表7所示，

在VisDrone2019数据集的静态目标检测场景中（场景一、二），改进模型展现了显著的检测效果。场景一中，针对YOLOv8n在处理被树木遮挡的车辆及多辆车密集排列导致的漏检问题，改进模型实现了更准确的检测。场景二中，改进模型ZZQ-YOLO在应对建筑阴影覆盖的车辆检测时，同样表现出更高的检测精度。







在动态目标检测场景（场景三）中，改进模型针对多车辆行驶过程中的连续遮挡以及自行车等小体积车辆被围栏遮挡导致的漏检情况，实现了显著的目标识别改进。

特别在夜间低光照环境（场景四下），改进模型ZZQ-YOLO成功检测出原模型未能识别的车辆目

标，体现了在低光照环境下的检测优势。下的目标检测问题中具有显著优势。同时，对于行至
至此，证实了改进模型ZZQ-YOLO在复杂背景人等难识别小目标的检测效果亦得到显著提升。

表 7 改进效果可视化。

Table 7 Visualizing Improvement Effects

场景	一	二	三	四
模型输入图像				
YOLOv8n				
ZZQ-YOLO				

3 结束语

本次工作针对航拍视角下的车辆目标尺度变化大、目标小、背景遮挡等导致目标检测不精确问题，对基线模型中的特征融合、特征提取、损失计算等方面提出改进。在主干网络，采用改进后的SPPF-LSKA模块来融合上下文信息，使模型更聚焦于检测对象相关特征，减少背景环境的干扰。在颈部网络，采用新的特征融合结构MCFFPN将不同分辨率、不同特征映射的信息进行融合解决多尺度问题。最后，使用Focaler-MPDIoU Loss损失函数，改善边框尺寸差异以及难易样本数量不均衡对梯度的不利影响，以加快网络收敛速度。实验结果表明，改进模型较基线模型在VisDrone2019数据集的验证集Val与测试集Test上的平均精度(mAP@0.5)分别提升了4.5%、3.6%，并且参数量减少了0.2M，所提方法能够较好地完成航拍图像中的车辆目标检测任务，为交通管理、安防监控、应急响应处理以及城镇规划等任务提供良好的解决方案。

参考文献

[1] 吴盘龙,黄樊品,何山,等,无人机系统控制研究综述[J]. 电光与控制,2024,31(10):1-9.

[2] TUERMER S, KURZ F, REINARTZ P, et al. Airborne Vehicle Detection in Dense Urban Areas Using HoG Features and Disparity Maps[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2013, 6(6): 2327-2337.

[3] 李星, 郭晓松, 郭君斌. 基于HOG特征和SVM的前向车辆识别方法[J]. 计算机科学, 2013, 40(S2): 329-332.

[4] 关晓斌, 李战明. 基于SIFT和HOG特征融合的视频车辆检测算法[J]. 计算机与数字工程, 2021, 49(6): 1113-1117.

[5] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2014: 580-587

[6] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.

[7] Zhao Z Q, Zheng P, Xu S, et al. Object detection with deep learning: A review[J]. IEEE transactions on neural networks and learning systems, 2019, 30(11): 3212-3232.

[8] Wang A, Chen H, Liu L, et al. Yolov10: Real-time end-to-end object detection[J]. arXiv preprint arXiv: 2405.14458, 2024.

[9] Khanam R, Hussain M. YOLOv11: An Overview of the Key Architectural Enhancements[J]. arXiv preprint arXiv:2410.17725, 2024.

[10] LYU Z, JIN H, ZHEN T, et al. Small Object Recognition Algorithm of Grain Pests Based on SSD Feature Fusion[J]. IEEE Access, 2021, 9: 43202-43213.

[11] FAN X, HU Z, ZHAO Y, et al. A Small-Ship Object Detection Method for Satellite Remote Sensing Data[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 11886-11898.

[12] Li Y, Fan Q, Huang H, et al. A modified YOLOv8 detection network for UAV aerial image recognition[J]. Drones, 2023, 7(5): 304.

[13] 孙佳宇,徐民俊,张俊鹏,等.优化改进YOLOv8无人机视角下目标检测算法[J].计算机工程与应用,2025,61(01):109-120.

- [14] 湛海云,肖章勇,郭勇,等,基于改进 YOLOv8s的无人机航拍目标检测算法[J],电光与控制,2024,31(12):55-63,
- [15] Lau K W, Po L M, Rehman Y A U. Large separable kernel attention: Rethinking the large kernel attention design in cnn[J]. Expert Systems with Applications, 2024, 236: 121352.
- [16] Ma S, Xu Y. Mpdious: a loss for efficient and accurate bounding box regression[J]. arXiv preprint arXiv:2307.07662, 2023.
- [17] Zhang H, Zhang S. Focaler-IoU: More Focused Intersection over Union Loss[J]. arXiv preprint arXiv:2401.10525, 2024.
- [18] CHEN J, MAI H, LUO L, et al. Effective Feature Fusion Network in BIFPN for Small Object Detection[C]//2021 IEEE International Conference on Image Processing (ICIP). 2021: 699-703
- [19] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable Bag-of-Freebies Sets New State-of-the-Art for Real-Time Object Detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 7464-7475
- [20] RAHMAN M M, MUNIR M, MARCULESCU R. EMCAD: Efficient Multi-scale Convolutional Attention on Decoding for Medical Image Segmentation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 11769-11779
- [21] ZHANG X, ZHOU X, LIN M, et al. ShuffleNet: An Extremely Efficient Convolutional Neural Network for Mobile Devices[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 6848-6856
- [22] HUANG P, TIAN S, SU Y, et al. IA-CIOU: An Improved IOU Bounding Box Loss Function for SAR Ship Target Detection Methods[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 10569-10582.
- [23] Zheng Z, Wang P, Liu W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(07): 12993-13000.
- [24] DU D, ZHU P, WEN L, et al. VisDrone-DET2019: The Vision Meets Drone Object Detection in Image Challenge Results[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops. 2019: 0-0
- [25] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization[J]. International Journal of Computer Vision, 2020, 128(2): 336-359.