

doi: 10.11707/j.1001-7488.LYKX20240446

融合多尺度注意力特征的林业外来害虫检测方法*

张长春^{1,2,3} 杨兴昌¹ 王国骅¹ 王冰婧⁴ 李诗杰¹ 陈方舟¹
葛永泰¹ 石 娟⁵ 张军国^{1,2,3}

(1. 北京林业大学工学院 北京 100083; 2. 林木资源高效利用全国重点实验室 北京 100083; 3. 北京林业大学生物多样性智慧监测研究中心 北京 100083; 4. 北京林业大学信息学院 北京 100083; 5. 北京林业大学林学院 北京 100083)

摘 要: 【目的】针对林业外来害虫因目标尺度多样、栖息环境复杂、易受遮挡等因素导致的现有检测算法识别准确率低、鲁棒性差的问题,提出一种融合多尺度注意力特征的林业外来害虫检测方法(MAF-YOLO),通过增强模型对不同尺度特别是小尺度目标的特征提取能力,并优化边界框回归策略,从而显著提升在复杂自然环境下对外来害虫的检测精度和泛化能力。【方法】该方法以 YOLOv5s 为基线架构,其核心改进包括:1) 在颈部网络中嵌入坐标注意力机制,以强化对目标区域关键特征的捕获能力并抑制背景噪声干扰;2) 增设 160 像素×160 像素的小目标检测头,构建多层级检测结构,以提升对微小目标的检测灵敏度;3) 采用 Focal-EIoU 损失函数替代原始 CIoU 损失函数,缓解正负样本及难易样本不平衡的问题,优化目标的定位精度;4) 引入域适应训练策略,通过在大规模通用数据集上预训练,增强模型对不同场景的泛化能力。【结果】在包含 15 类潜在入侵和已入侵的林业外来害虫图像数据集上,训练和评估提出的模型,改进后的 YOLOv5s 模型精确率和召回率较原始 YOLOv5s 模型分别提升 3.6% 和 4.4%;与 SSD、YOLOv7、YOLOv8 模型相比,改进模型的平均识别精度分别提高 2.2%、1.1% 和 0.3%;结合域适应后模型精确率达 77.9%,较原模型提升 2.1%。【结论】本研究实现了林业外来害虫的精准识别,增强了模型的准确性与鲁棒性,为有效监测林业外来害虫提供了理论依据和技术支持。

关键词: 林业外来害虫; YOLOv5s; 坐标注意力; 域适应; 图像检测

中图分类号: S763.30 文献标识码: A 文章编号: 1001-7488(2025)10-0154-10

A Detection Method of Alien Forest Pests with Integrating Multi-scale Attention Features

Zhang Changchun^{1,2,3} Yang Xingchang¹ Wang Guohua¹ Wang Bingjing⁴ Li Shijie¹ Chen Fangzhou¹ Ge Yongtai¹
Shi Juan⁵ Zhang Junguo^{1,2,3}

(1. School of Technology, Beijing Forestry University Beijing 100083; 2. State Key Laboratory of Efficient Production of Forest Resources Beijing 100083; 3. Research Center for Biodiversity Intelligent Monitoring, Beijing Forestry University Beijing 100083; 4. School of Information Science and Technology, Beijing Forestry University Beijing 100083; 5. School of Forestry, Beijing Forestry University Beijing 100083)

Abstract: 【Objective】To address the challenges of low identification accuracy and insufficient robustness in existing detection algorithms for alien forest pests, which stem from factors such as diverse target scales, complex habitats, and frequent occlusions, this paper proposes a detection method integrating multi-scale attention features, termed MAF-YOLO. The method aims to significantly enhance the detection accuracy and generalization capability for alien pests in complex natural environments by strengthening the model's feature extraction capability for targets of varying scales, particularly small-scale ones, and optimize the bounding box regression strategy. 【Method】The proposed method was based on the YOLOv5s baseline architecture, and its core modifications included: 1) A coordinate attention (CA) mechanism was embedded into the neck network to enhance the capture of key target features and suppress background noise. 2) A small target detection head with 160×160 pixel was added to construct a multi-level detection structure, thereby improving detection sensitivity for minute objects. 3) The Focal-EIoU loss function was employed to replace the original CIoU loss, in order to mitigate the imbalance between positive/negative and easy/hard samples, and refine object localization accuracy. 4) A domain adaptation training strategy was introduced to improve the model's generalization across diverse scenarios by pre-training on a large-scale general-purpose dataset. 【Result】The proposed

收稿日期: 2024-07-16; 修回日期: 2025-05-23。

基金项目: 中央高校基本科研业务费专项资金(QNTD202510); 中央高校优秀青年团队项目(QNTD202304); 北京市级大学生创新训练项目(S202310022154)。

* 石娟、张军国为通信作者。E-mail: shi_juan@263.net; zhangjunguo@bjfu.edu.cn。本文为“智慧林草驱动新质生产力”专题征稿论文。

model was trained and evaluated on an image dataset comprising 15 categories of potential and existing invasive forest pests. The improved YOLOv5s model, MAF-YOLO, demonstrated an increase in precision and recall by 3.6% and 4.4%, respectively, compared to the original YOLOv5s. In comparison with the SSD, YOLOv7, and YOLOv8 models, the average precision of the improved model was higher by 2.2%, 1.1%, and 0.3%, respectively. Furthermore, with the integration of domain adaptation, the model's precision reached 77.9%, representing a 2.1% improvement over the baseline model under the same strategy. 【Conclusion】 This study achieves precise recognition of invasive alien forest pests, enhances the model's accuracy and robustness, and provides theoretical and technical support for effective monitoring of alien forest pest.

Key words: alien forest pest; YOLOv5s; coordinate attention; domain adaptation; image detection

林业外来害虫会对生态系统平衡构成显著威胁,已成为制约森林生态系统健康和可持续发展的关键因素,其造成的经济损失不可忽视,对林业外来害虫的智能监测和管理是保护森林资源和维护生态平衡的重要任务。然而,我国林业外来害虫智能监测面临林间环境复杂、害虫尺度多样等带来的检测困难,探究一种基于深度学习的高精度害虫检测方法显得尤为重要。

近年来,在深度学习技术驱动下,目标检测算法在害虫检测领域取得显著进展。孙丽萍等(2022)将 Focal Loss 引入 YOLO 网络,通过调节聚焦参数,在平衡正负样本比例的同时,显著提升了模型对难分样本的识别能力。孙海燕等(2022)采用 MobileNetV3 替换 YOLO 主干网络,并在 PANet 中集成注意力机制,有效改善了漏检、误检问题,为实现林业害虫的准确识别提供了技术参考。杨红云等(2022)提出了一种基于卷积神经网络的水稻(*Oryza sativa*)害虫识别方法,该方法在模型收敛速度和识别准确率方面具有显著优势。Wang 等(2020)设计出一种轻量化的 CPAFNet(compound pyramid attention fusion network)深度害虫分类网络,害虫检测准确率达 92.63%,高于 ResNet50(He et al., 2016)和 VGG16(Simonyan et al., 2015)等传统深度学习模型。Yulita 等(2024)采用 SqueezeNet 和 Multi-Layer Perceptron 模型对农场中的害虫进行检测,也具有较高的准确率。宫妍等(2024)针对玉米(*Zea mays*)作物害虫检测中存在的问题,提出基于 YOLOv7 的 SPD-YOLOv7 算法,该算法引入 SPD-Conv 模块减少细节信息丢失,将 ELAN-W 模块与 CBAM(convolutional block attention module)注意力机制结合以更好地学习害虫特征,改进后的模型准确率达 98.38%。Chu 等(2023)针对粮仓害虫检测问题,设计了一种基于 YOLOv5s 的多尺度粮仓害虫识别模型,平均准确率达 98.2%,能较好地适应复杂粮仓环境下害虫的检测。王中天等(2024)提出一种融合 MAE(masked autoencoder)和 YOLOX 算法的 MRA-

YOLOX 模型,在自构建的 TDBFP 害虫数据集上的检测精度达 88.2%。上述技术为林业领域的研究与应用提供了重要借鉴,然而将其直接移植到林区特殊环境中,仍存在显著的适配局限性。

当前林业外来害虫检测方法面临如下问题:首先,目标尺度多样性导致小个体害虫的检测准确率较低;其次,复杂林间环境下采集到的害虫数据存在分布差异进而影响模型适应性。鉴于此,本研究提出一种融合多尺度注意力特征的林业外来害虫检测方法(multi-scale attention features, MAF-YOLO),利用坐标注意力机制将位置信息融入通道注意力,强化对林业害虫感兴趣对象的表达。该模型首先提出 160 像素×160 像素检测头策略,挖掘不同层次特征图信息,然后采用 Focal-EIoU 函数替代原模型的 CIoU 边框损失函数,使回归过程更聚焦高质量锚框;同时,运用域适应思想将训练得到的最佳权重作为自建数据集训练的初始权重。本研究将这些改进策略和域适应技术应用于林业外来害虫图像检测领域,以期增强模型检测的准确性与鲁棒性,为林业外来害虫的有效监测提供理论依据和技术支持。

1 材料与方法

1.1 林业外来害虫数据集

采用系统抽样方法,通过检索国家动物标本资源库、中国生物志库、Insect Images 等权威数据库,以及 iNaturalist、InsectNet 等专业生物多样性平台,获取 15 类潜在入侵和已入侵的林业外来害虫图像样本,包括圆木蠹象(*Pissodes rotundatus*)、松六星吉丁(*Chrysobothris solieri*)、长林小蠹(*Hylurgus ligniperda*)、美国白蛾(*Hyphantria cunea*)、美松齿小蠹(*Ips pini*)、黑腹尼虎天牛(*Neoclytus acuminatus*)、桉天牛(*Phoracantha semipunctata*)、条带木蠹象(*Pissodes castaneus*)、耐猛木蠹象(*P. nemorensis*)、云杉木蠹象(*P. piceae*)、松树木蠹象(*P. pini*)、菲利普木蠹象(*P. piniphilus*)、欧洲榆小蠹(*Scolytus multistriatus*)、松树蜂(*Sirex noctilio*)

和暗褐断眼天牛(*Tetropium fuscum*)。采用布尔逻辑运算符组合物种学名、中文名及形态特征等关键词进行精确检索,确保数据来源的科学性和可靠性。

为确保数据集质量,排除重复、模糊或特征不明显的样本,最终获得有效图像 2 112 张,涵盖 15 种林

业外来害虫(含潜在入侵和已入侵)。为提高模型泛化能力,采用多维度数据增强策略(图 1),包括:1) 几何变换,如水平翻转、镜像旋转;2) 色彩空间变换,如亮度调整、对比度调节;3) 添加噪声;4) 模糊处理和锐化。



图 1 8 种图像预处理策略

Fig. 1 Eight image preprocessing strategies

1.2 研究方法

为解决林业外来害虫目标尺度多样、所处自然环境复杂导致识别准确率低的问题,本研究提出一种融合多尺度注意力特征的林业外来害虫检测方法(MAF-YOLO),模型结构见图 2。首先,采用 YOLOv5s 作为基线网络,引入坐标注意力机制,通过将位置信息嵌入到通道注意力中,有效增强模型对林业害虫感兴趣目标的特征表示能力,从而显著提升目标的定位精度和分类准确性。其次,提出 160 像素×160 像素检测头策略,用于提高模型对多尺度害虫目标的检测精度。最后,为有效缓解样本前后背景不平衡和目标定位不准确的问题,采用 Focal-EIoU 损失函数替代原模型的 CIoU 边框损失函数,有效缓解锚框质量不平衡对边界框优化的不利影响。此外,基于域适应思想,本研究将 COCO128 数据集作为源域、IP102 数据集作为辅助域进行模型训练,并将所得最佳权重作为自建数据集训练的初始权重,进一步优化模型的泛化性能。

1.2.1 融合坐标注意力机制 鉴于林业外来害虫所处自然环境复杂多变,且多种害虫具备保护色机制,为有效提升模型的检测性能,本研究在模型的 Neck 网络中引入坐标注意力(coordinate attention, CA)机制(Hou et al., 2021),这不仅能使模型敏锐感知图像中不同局部信息的重要程度,而且具有增强模型关键特征表征能力的显著优势,可有效抑制无关信息,进而提升模型的泛化能力。具体实现过程如下:

1) 全局平均池化:对输入特征图在高度和宽度

方向分别进行全局平均池化操作,得到 2 个维度上的特征图:

$$z_{hc}(h) = \frac{1}{W} \sum_{i=0}^W |x_c(h, i)|; \quad (1)$$

$$z_{wc}(w) = \frac{1}{H} \sum_{j=0}^H |x_c(j, w)|. \quad (2)$$

式中: $x_c(h, i)$ 、 $x_c(j, w)$ 表示输入特征图 x 中的第 c 个通道在高度方向和宽度方向上的像素值; W 和 H 分别表示输入特征图的宽度和高度; $z_{hc}(h)$ 表示在高度方向上对第 c 个通道编码后得到的高度特征图; $z_{wc}(w)$ 则表示在宽度方向上对第 c 个通道编码后得到的宽度特征图。

2) 编码特征图:利用全局平均池化得到的 2 个特征图,分别沿高度和宽度方向进行编码,从而编码每个通道在高度和宽度方向上的重要性。

3) 拼接与降维:将编码后的特征图在空间维度上进行拼接操作,并通过共享的 1×1 卷积层进行降维,以减少计算复杂度:

$$f = \delta(F_1([z_h, z_w])). \quad (3)$$

式中: δ 表示非线性激活函数; F_1 表示卷积变换函数; $[z_h, z_w]$ 表示沿着空间维度的拼接操作,将高度和宽度方向的特征图拼接起来。

4) 注意力权重计算:对降维后的特征图进行卷积操作,得到在高度和宽度方向上的注意力权重,并通过 Sigmoid 函数进行归一化处理:

$$g_h = \sigma(F_h(f_h)); \quad (4)$$




图2 MAF-YOLO 模型结构

Fig. 2 Architecture of the MAF-YOLO model

CA: 坐标注意力 Coordinate attention; BottleNeck: 瓶颈层 Bottleneck layer; CBS: 卷积、归一化层和 SiLU 激活函数 Convolution, batch normalization, and Sigmoid Linear Unit activation function; BN: 批归一化 Batch normalization; Maxpooling: 最大池化 Maximum pooling; Concat: 张量拼接 Tensor concatenation; SPPF: 空间金字塔池化 Spatial pyramid pooling; Upsampling: 上采样 Upsampling.

$$g_w = \sigma(F_w(f_w)). \quad (5)$$

式中: g_h 和 g_w 分别表示在高度和宽度方向上得到的注意力权重; f 表示中间特征图; F 为卷积变换函数。

5) 乘法加权计算: 利用得到的注意力权重与输入特征图进行乘法加权计算, 得到在高度和宽度方向上带有注意力权重的特征图:

$$y_c(i, j) = x_c(i, j) \times g_{hc}(i) \times g_{wc}(j). \quad (6)$$

式中: $x_c(i, j)$ 和 $y_c(i, j)$ 分别表示输入及输出特征图中第 c 个通道在高度方向 i 和宽度方向 j 上的像素值; $g_{hc}(i)$ 与 $g_{wc}(j)$ 则分别用于加权输入特征图中第 c 个通道在高度方向 i 和宽度方向 j 上的像素值。

1.2.2 优化目标检测头 林业害虫在自然环境中呈现出多尺度特性, 包含的特征信息较少, 分辨率较低且细节不明显, 导致模型在检测过程中的精度降低, 检测效果不理想(Zhang *et al.*, 2022)。由于 YOLOv5s 模型的下采样倍数较大, 其深层特征图在提取小尺度目标特征信息时存在困难, 且检测效果不佳。因此, 本研究考虑在 YOLOv5s 模型中增设小目标检测层, 以提升模型对林业害虫的检测精度。具体地, 设置输入分辨率为 640 像素×640 像素, YOLOv5s 原始模型仅具有 3 个目标检测头, 分别是 20 像素×20 像素

(大目标)、40 像素×40 像素(中目标)、80 像素×80 像素(小目标)。为增强小目标检测能力, 本研究在原有 80 像素×80 像素检测头的基础上, 新增 160 像素×160 像素检测头。改进后的模型通过整合 4 个不同尺度的预测层(160 像素×160 像素、80 像素×80 像素、40 像素×40 像素和 20 像素×20 像素), 构建了 4 头检测机制, 从而充分利用底层特征高分辨率和深层特征高语义信息提高检测精度, 且未显著增加网络复杂度。

1.2.3 改进损失函数 YOLOv5s 模型采用 CIoU 损失函数计算边界框回归损失, CIoU 损失函数在目标检测任务中应用广泛, 其主要通过优化目标检测框的尺寸和位置提升检测性能, 但对于林业害虫检测中存在的小尺度目标其检测性能受限。因此, 本研究将 CIoU 损失函数替换为 Focal-EIoU 损失函数。对于林业害虫检测场景中因环境因素而难以区分的害虫与背景区域, Focal-EIoU 损失函数中的 Focal Loss 部分能够在正样本范围内, 根据检测框的 IoU 值调整权重。对于 IoU 值较高(代表检测框质量较好)的正样本, 赋予更大权重, 促使模型更专注于学习这些高质量正样本区域的特征, 以此提升模型在林业害虫检

测中的性能表现。EIoU 部分通过引入框之间的位置偏差约束目标检测框的位置和尺寸,提高检测精度,其具体计算公式如下。

1) 计算 IoU 损失:

$$L_{\text{IoU}} = 1 - \text{IoU}(A, B); \quad (7)$$

$$\text{IoU}(A, B) = \frac{\text{Area}(A \cap B)}{\text{Area}(A \cup B)}. \quad (8)$$

式中: $\text{Area}(A \cap B)$ 表示检测框 A 和 B 的交集面积; $\text{Area}(A \cup B)$ 则表示两框的并集面积。

2) 计算位置偏差 (displacement) 损失 L_d :

$$L_d = \frac{(x_{b_1} - x_{a_1})^2}{(w_a + w_b)^2} + \frac{(y_{b_1} - y_{a_1})^2}{(h_a + h_b)^2}. \quad (9)$$

3) 计算纵横比 (aspect ratio) 损失 L_a :

$$L_a = \frac{w_a}{h_a} - \frac{w_b}{h_b}. \quad (10)$$

式中: (x_{a_1}, y_{a_1}) 、 (x_{b_1}, y_{b_1}) 、 w_a 、 h_a 、 w_b 、 h_b 分别表示 A 框和 B 框的左上角坐标、宽度和高度。

4) 3 部分相加得到 EIoU 损失函数:

$$L_{\text{EIoU}} = L_{\text{IoU}} + L_d + L_a. \quad (11)$$

5) 利用 Focal Loss 对 EIoU 进行加权处理:

$$L_{\text{Focal Loss}} = \text{IoU}^\gamma \times L_{\text{EIoU}}. \quad (12)$$

式中: γ 是一个超参数,用于控制 IoU 的权重, IoU 越大,损失的权重越大,对回归目标为高 IoU 的样本施加更大的惩罚,以促进回归目标更加精确的定位,本试验中 γ 取值为 2。

1.2.4 联合域适应策略 自建数据集规模有限,且目标害虫类群在形态学上呈现显著的多态性和复杂性,导致外部特征信息的有效提取难度较高;若直接采用该数据集进行模型训练,难以获得理想识别效果。为此,本研究引入域适应方法,其核心要义是将从一个任务中获取的知识或经验迁移应用到另一个相关任务中(张长春等, 2024),本研究域适应优化过程如下。

1) 源域训练: 选用 COCO128 数据集对改进的 YOLOv5s 模型进行源域训练。在此过程中,模型通过对 COCO128 数据集中多样化图像内容的学习,能够提取并掌握广泛且复杂的特征表示,为后续模型性能的提升提供参考。

2) 辅助域训练: 采用 IP102 数据集作为辅助域对模型进行进一步训练。IP102 数据集包含 102 类害虫的 75 000 余张图像样本和 19 000 余条标注数据样本,本研究选用其中 18 982 条标注数据进行训练,这些数据能够帮助模型学习到更广泛和通用的害虫识别特征。

3) 目标域优化: 以自建数据集作为目标域对模型进行优化调整,使其达到最佳性能,最终生成适用

于林业外来害虫检测的模型。

2 试验设置

2.1 数据集划分和评估指标

为获得稳健的试验结果且保证性能的可比性,本研究按 9:1 将原数据集划分为训练集和测试集,则训练集和测试集分别为 1 899 张和 213 张图像。其中,经数据增强后,训练集扩充至 2 811 张图像。此外,为验证本研究模型针对林业外来害虫图像的检测效果,采用精确率 (precision)、召回率 (recall)、平均精度均值 mAP (mean average precision) 以及准确率 (accuracy) 作为定量评价标准。

2.2 实施细节

本研究的硬件环境操作系统是 64 位 Windows 11, CPU: Intel Core i7-12700H, 内存为 16 GB, GPU: Nvidia GeForce RTX 3060, 显存为 8 GB。储存为 1 T 固态硬盘; 软件环境为 Python 3.8、Pytorch 2.2.0、CUDA12.0, 编译环境是 PyCharm Community Edition 2023.2。本研究选择 SGD 优化器作为优化算法, 初始学习率设置为 0.01, 权重衰减系数为 0.000 5, 动量参数为 0.937, 批处理大小为 16, 每个试验都进行了总共 150 次 epoch 的训练。

3 结果与分析

3.1 不同图像检测模型性能对比

为全面评估 MAF-YOLO 模型的性能表现, 本研究选取当前主流的目标检测模型(包括 YOLOv4、YOLOv7、YOLOv8 和 SSD)进行对比试验。试验在统一的硬件环境与参数配置下进行, 由表 1 可知, MAF-YOLO 模型在关键性能指标上均展现出显著优势。与 SSD、YOLOv4、YOLOv5s 和 YOLOv7 相比, 在精确率、召回率和平均精度均值 3 个指标上均取得更优表现。与当前最优的 YOLOv8 模型相比, 虽然精确率略低 0.6%, 但召回率提升 2.2%, 同时平均精度均值也实现了更优表现。这些试验结果均证明, MAF-YOLO 模型在综合性能上优于传统目标检测模型, 具有更好的实际应用价值。

3.2 域适应效果分析

本研究采用对照试验设计, 以 YOLOv5s 模型和 MAF-YOLO 模型作为基准网络, 分别构建含域适应模块和不含域适应模块的对比试验。由表 2 可知, 域适应组的主要性能指标均显著优于无域适应组。具体而言: 1) 对于 YOLOv5s 模型, 域适应策略使其精确率和召回率分别提升 1.5% 和 0.8%; 2) MAF-YOLO

表 1 不同图像检测模型性能对比

Tab. 1 Performance comparison of different image detection models

模型 Models	精确率 Precision	召回率 Recall	平均精度均值 mAP@0.5	平均精度均值 mAP@0.5:0.95
SSD	61.3	59.4	60.8	43.4
YOLOv4	71.5	76.3	75.2	62.5
YOLOv7	74.9	80.2	81.7	66.7
YOLOv8	76.4	81.2	82.5	67.3
YOLOv5s	74.3	79.1	79.2	64.9
MAF-YOLO	75.8	83.4	80.3	66.5

模型在引入域适应后, 精确率达到 77.9%, 较未使用域适应时提升 2.1%; 召回率提升至 84.5%, 增加 1.1%; 3) 在平均精度均值(mAP@0.5)指标上, 域适应后的模型达到 83.5%, 较未使用域适应时提升 0.7%。上述结果表明, 域适应策略有效提升了模型的综合性能, 在各项评价指标上均表现出显著优势。

3.3 检测结果可视化

为验证 MAF-YOLO 模型在实际应用场景中的检

表 2 域适应效果对比

Tab. 2 Comparison of domain adaptation effect

试验组 Experimental group	模型 Models	精确率 Precision	召回率 Recall	平均精度均值 mAP@0.5	平均精度均值 mAP@0.5:0.95
无域适应 Without domain adaptation	YOLOv5s	74.3	79.1	79.2	64.9
	MAF-YOLO	75.8	83.4	82.8	67.5
有域适应 With domain adaptation	YOLOv5s	76.8	79.9	80.0	66.0
	MAF-YOLO	77.9	84.5	83.5	69.8

测性能, 本研究从自建数据集中随机选取具有代表性的林业害虫图像进行测试分析, 结果见图 3。MAF-YOLO 模型在目标识别准确率和定位精度方面均显著优于 YOLOv5s 模型。以图 3 第 3 列检测结果为例, 原始 YOLOv5s 模型仅能识别单个昆虫目标(精确率: 30.2%), 而改进后的 YOLOv5s 模型成功检测到 2 个害虫个体, 其精确率分别达 49.3% 和 49.7%, 不仅提高了多目标检测能力, 还显著提升了检测结果的可靠性。




图 3 不同模型在典型样本上的检测效果可视化

Fig. 3 Visualization of detection performance for different models on typical samples

a: 原始图像 Original images; b: 基线模型 YOLOv5s 的检测结果 Detection results from the baseline YOLOv5s model; c: 本研究 MAF-YOLO 模型的检测结果 Detection results from our MAF-YOLO model.

3.4 模型召回率和平均精度均值分析

模型训练过程的性能曲线见图 4。首先, 在召回率方面, 随着训练轮次(epoch)增加, 本研究提出的 MAF-YOLO 模型与对比方法的召回率均呈收敛趋势。值得注意的是, MAF-YOLO 模型的召回率曲线始终维持在较高水平, 且其收敛速度较对比模型提升 15%~20%。其次, 在平均精度均值方面, 训练初期各模型的 mAP 均呈快速上升趋势, 随后增长速率逐渐减缓。当训练轮次达到 120 轮时, MAF-YOLO 模型与 YOLOv7、YOLOv8 模型的 mAP 均趋于稳定, 表明模型检测精度已达稳定状态。最后, 定量分析显示 MAF-YOLO 模型的最终 mAP 稳定在 0.82 左右, 相较

于 YOLOv5s、YOLOv7 和 YOLOv8 模型分别提升 3.0%、1.1% 和 0.3%, 这一结果证明了 MAF-YOLO 方法的有效性。

3.5 模型检测效果定量分析

由表 3 可知, MAF-YOLO 模型在整体性能上显著优于 YOLOv5s 和 YOLOv4 模型, 但在部分物种的识别准确率上略低于 YOLOv8 和 YOLOv7 模型。所有测试模型对圆木蠹象、条带木蠹象、耐猛木蠹象、云杉木蠹象、松树木蠹象以及菲利普木蠹象这 6 种害虫的识别准确率均显著低于其他类。MAF-YOLO 模型对美国白蛾的识别准确率最高, 达到 97.2%; 而对菲利普木蠹象的识别准确率最低, 仅为 34.4%。通




图 4 模型召回率与 mAP 变化曲线

Fig. 4 Recall and mAP curves during model training

a: 召回率变化曲线 Model recall curve; b: 平均精度均值变化曲线 Model mean average precision change curve.

过数据集分析发现,美国白蛾样本量大且具有显著的外观特征,因此各模型对该物种均表现出较好的识别效果。相比之下,木蠹象属害虫由于样本收集难度大、种内形态变异度高,加之种间相似性显著,导致模型难以建立有效的判别特征,从而影响识别准确率。

3.6 消融试验性能分析

为系统评估各改进模块对模型性能的贡献度,本研究以 YOLOv5s 为基线模型,在保持超参数一致性的前提下,采用控制变量法进行消融试验。由表 4 可知,各改进模块均对模型性能产生正向影响。其中,坐标注意力机制的引入效果最为显著,使模型精确率提升 0.6 个 %,召回率提高 2.1%。这一改进主要得益于坐标注意力模块增强了模型对害虫关键形态特征的定位能力。其次,160 像素×160 像素小目标检

测头的加入使模型在小尺度目标检测方面取得明显进步,精确率提升 0.5%,召回率提高 1.2%。这表明,多尺度特征融合策略能够有效缓解传统 YOLOv5s 在下采样过程中造成的小目标特征丢失问题。当同时集成坐标注意力模块、小目标检测头和 Focal-EIoU 损失函数时,模型综合性能达到最优:精确率提升 1.5%,召回率提高 4.3%,平均精度均值也有较为显著的提升。这一结果证实各改进模块间的协同效应,其通过增强特征提取能力、优化多尺度检测性能和改善边界框回归精度,显著提升了模型在复杂林业场景下的害虫识别效果。

3.7 模型检测目标的特征可视化结果分析

林业外来害虫样本特征可视化结果见图 5。通过可视化分析可知,MAF-YOLO 模型在特征提取能力方面较 YOLOv5s 模型有显著提升。这主要归因于

表 3 不同模型对 15 类害虫识别效果

Tab. 3 Identification effectiveness of 15 types of pests by different models

物种 Species	模型准确率 Model accuracy (%)				
	MAF-YOLO	YOLOv5s	YOLOv8	YOLOv7	YOLOv4
圆木蠹象 <i>Pissodes rotundatus</i>	60.5	56.3	61.4	61.7	54.5
松六星吉 <i>Chrysobothris solieri</i>	94.5	90.2	96.0	95.2	87.6
长林小蠹 <i>Hylurgus ligniperda</i>	90.8	88.6	90.7	91.1	86.3
美国白蛾 <i>Hyphantria cunea</i>	97.2	96.3	98.9	97.5	94.4
条带木蠹象 <i>Pissodes castaneus</i>	40.6	34.5	38.6	37.9	34.8
黑腹尼虎天牛 <i>Neoclytus acuminatus</i>	87.4	84.4	87.0	86.3	83.3
桉天牛 <i>Phoracantha semipunctata</i>	91.2	88.3	91.9	90.8	86.9
美松齿小蠹 <i>Ips pini</i>	82.5	80.0	81.7	80.9	79.1
耐猛木蠹象 <i>Pissodes nemorensis</i>	44.3	39.6	42.5	41.6	38.3
云杉木蠹象 <i>Pissodes piceae</i>	42.7	37.9	41.3	39.8	37.5
松树木蠹象 <i>Pissodes pini</i>	51.8	48.5	51.0	52.2	47.3
菲利普木蠹象 <i>Pissodes piniphilus</i>	34.4	30.2	32.6	31.9	29.0
欧洲榆小蠹 <i>Scolytus multistriatus</i>	75.7	72.8	75.4	74.5	70.2
松树蜂 <i>Sirex noctilio</i>	88.9	86.8	90.1	89.2	85.7
暗褐断眼天牛 <i>Tetropium fuscum</i>	90.1	88.2	91.2	90.0	86.8

表 4 消融试验结果^①
Tab. 4 Results of ablation study

%

YOLOv5s基线网络 YOLOv5s baseline network	坐标注意力 Coordinate attention	小目标检测头 Small target detection head	Focal-EIoU损失函数 Focal-EIoU loss function	精确率 Precision	召回率 Recall	平均精度均值 mAP@0.5	平均精度均值 mAP@.5:95
√	√	—	—	74.9	81.2	79.5	66.3
√	—	√	—	74.8	80.3	79.7	65.9
√	—	—	√	74.4	81.7	79.3	65.1
√	√	√	—	75.7	82.0	80.0	66.7
√	√	—	√	75.1	82.3	79.9	66.0
√	—	—	—	74.3	79.1	79.2	64.9
√	√	√	√	75.8	83.4	80.3	66.5

① √表示使用该模块，—表示未使用。√ indicates that the module is used, — indicates that the module is not used.

通道注意力机制的引入,该机制通过自适应权重分配增强了模型对目标有效特征的提取能力,同时有效抑制了背景噪声等无效特征的干扰。在图 5 第 4 列样本中,原始模型的特征响应区域过度分散,错误地包含了大量周围杂草的背景特征,而改进模型则能够将特征响应集中在对目标害虫的识别上,背景

特征响应度降低。此外,在第 1 列样本中,原始模型的特征响应区域仅局限于害虫背部局部区域,而改进模型的特征响应区域能够完整覆盖整个虫体。这些可视化结果充分证实 MAF-YOLO 方法能够显著提升模型的特征提取能力,增强模型对目标区域的关注度。




图 5 YOLOv5s 与 MAF-YOLO 模型的特征可视化对比

Fig. 5 Comparison of feature visualization heatmaps between YOLOv5s and MAF-YOLO.

a: 原始输入图像 Original input images; b: 基线模型 YOLOv5s 的注意力区域 Attention regions from the baseline YOLOv5s model; c: MAF-YOLO 模型的注意力区域 Attention regions from the proposed MAF-YOLO model.

4 讨论

林业害虫对森林资源可持续发展和生态安全构成重大威胁,不仅严重影响林业生产效益,更危及生态屏障建设质量。传统化学防治手段存在环境污染和抗药性风险,常规检测方法受限于人工识别效率与主观判断误差,难以满足现代精准防控需求(崔晓辰等, 2024)。基于深度学习的 YOLO 网络在害虫智能识别领域表现出显著优势(王泰华等, 2024; 郭嘉璇等, 2024),但针对林业害虫检测中普遍存在自然场景复杂性、目标多尺度性等关键问题仍需进一步优化(谢婉滢等, 2024)。

本研究以 15 类林业外来害虫(含潜在入侵和已入侵)为研究对象,提出融合多尺度注意力特征的检测模型 MAF-YOLO,其创新性主要体现在以下方面。首先,在特征增强模块中创新性地融合坐标注意力

机制。该机制通过将二维位置编码嵌入通道注意力层,建立空间位置与通道特征的动态关联,能够更精准定位害虫形态特征,与引入 CA 模块以提升模型对图像感兴趣区域的敏感程度的思路相似(王俊岭等, 2024),但本研究进一步优化了其在多尺度特征融合上的应用策略。其次,针对多尺度检测难题构建了 160 像素×160 像素检测头协同的多层级特征融合架构。通过改进特征金字塔网络结构,实现浅层细节特征与深层语义特征的有效聚合,使小目标检测召回率提升。通过加权双向特征融合技术可以丰富各级特征图的语义信息,也证明了精细化特征融合对提升虫害平均检测精度的有效性(何颖等, 2022)。最后,采用 Focal-EIoU 混合损失函数替代标准 CIoU,其中 EIoU 项通过解耦宽高坐标优化边界框回归, Focal Loss 项设置动态权重系数强化困难样本学习,

最终提升了模型的平均识别精度,与引入 MPDIoU 以提升收敛速度和定位准确率的改进一致(陈万志等, 2025),但 Focal-EIoU 在应对样本不平衡问题上展现出更大潜力。

MAF-YOLO 在林业害虫检测性能上表现出显著优势,模型在测试集上保持 80.3% 的检测精度,较基线模型提升 1.1%。对比试验显示,虽然模型对松六星吉丁虫和美国白蛾的检测精度较 YOLOv8 低 1.5% 和 0.7%,但在木蠹象属害虫识别方面表现优异。此外,本研究虽以 YOLOv5s 为基准架构开展优化,但改进方案中的核心组件采用模块化设计,具备即插即用的兼容特性,这与轻量化网络设计的发展趋势相契合(匡敏球等, 2025;周志飞等, 2024)。

5 结论

本研究提出的融合多尺度注意力特征的林业外来害虫检测方法(MAF-YOLO),提升了在目标尺度多样和复杂自然环境下害虫的检测性能。通过坐标注意力机制、160 像素×160 像素检测头以及 Focal-EIoU 边框函数作为优化策略构建融合多尺度注意力特征的林业外来害虫检测模型,并利用域适应思想,进一步提升了模型的检测性能。与现有基线方法相比,所提方法在多个评价指标上均取得了明显提升,验证了其在林业外来害虫检测任务中的优越性。本研究认为采用域适应思想微调模型 MAF-YOLO,使得模型能够挖掘物种的不变特征以减轻复杂环境导致的分布差异,显著提高了模型对林业外来害虫的识别性能。

参 考 文 献

- 陈万志,袁 航. 2025. 改进 YOLOv8n 的林业害虫检测方法. 北京林业大学学报, 47(2): 119–131.
- (Chen W Z, Yuan H. 2025. Forestry pest detection method based on improved YOLOv8n. Journal of Beijing Forestry University, 47(2): 119–131. [in Chinese])
- 崔晓辰,雷一东. 2024. 基于深度学习的林业害虫智能化检测方法研究进展. 世界林业研究, 37(4): 53–57.
- (Cui X C, Lei Y D. 2024. Research progress in deep-learning-based intelligent forest pest detection methods. World Forestry Research, 37(4): 53–57. [in Chinese])
- 宫 妍,翟俊杰,王 凯,等. 2024. 基于改进 YOLOv7 的玉米作物害虫检测研究. 计算机测量与控制, 32(9): 58–65.
- (Gong Y, Zhai J J, Wang K, et al. 2024. Study on corn crop pest detection based on improved YOLOv7. Computer Measurement & Control, 32(9): 58–65. [in Chinese])
- 郭嘉璇,王蓉芳,南江华,等. 2024. 融入全局相应归一化注意力机制的 YOLOv5 农作物害虫识别模型. 农业工程学报, 40(8): 159–170.
- (Guo J X, Wang R F, Nan J H, et al. 2024. YOLOv5 model integrated with GRN attention mechanism for insect pest recognition. Transactions of the Chinese Society of Agricultural Engineering, 40(8): 159–170. [in Chinese])
- 何 颖,陈丁号,彭 琳. 2022. 基于改进 YOLOv5 模型的经济林木害虫目标检测算法研究. 中国农机化学报, 43(4): 106–115.
- (He Y, Chen D H, Peng L. 2022. Research on object detection algorithm of economic forestry pests based on improved YOLOv5. Journal of Chinese Agricultural Mechanization, 43(4): 106–115 [in Chinese])
- 匡敏球,李 旭,陈 楠,等. 2025. 基于改进 YOLOv8n 的轻量化辣椒花目标检测方法. 农业工程学报, 41(12): 198–207.
- (Kuang M Q, Li X, Chen S, et al. 2025. Lightweight chili flower target detection method based on improved YOLOv8n. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 41(12): 198–207. [in Chinese])
- 孙海燕,陈云博,封丁惟,等. 2022. 基于注意力模型和轻量化 YOLOv4 的林业害虫检测方法. 计算机应用, 42(11): 3580–3587.
- (Sun H Y, Chen Y B, Feng D W, et al. 2022. Forest pest detection method based on attention model and lightweight YOLOv4. Journal of Computer Applications, 42(11): 3580–3587. [in Chinese])
- 孙丽萍,谭少亨,周宏威,等. 2022. 基于 YOLOv5 的林业有害生物检测与识别. 森林工程, 38(5): 104–109.
- (Sun L P, Tan S H, Zhou H W, et al. 2022. Forestry pests detection and identification based on YOLOv5. Forest Engineering, 38(5): 104–109. [in Chinese])
- 王俊岭,王晨晨,熊玉华. 2024. 基于 YOLOv5l-1m 的排水管道缺陷检测方法 & 效果分析. 科学技术与工程, 24(18): 7833–7842.
- (Wang J L, Wang C C, Xiong Y H. 2024. Detection and effectiveness of drainage pipeline defects based on YOLOv5l-1m. Science Technology and Engineering, 24(18): 7833–7842. [in Chinese])
- 王泰华,郭亚州,张家乐,等. 2024. 基于改进 YOLO v5s 的水稻害虫识别研究. 农业机械学报, 55(11): 39–48.
- (Wang T H, Guo Y Z, Zhang J L, et al. 2024. Research on rice pest identification based on improved YOLOv5s. Transactions of the Chinese Society for Agricultural Machinery, 55(11): 39–48. [in Chinese])
- 王中天,邹颖波,吴昌霖,等. 2024. 超越单一感知的农田害虫检测算法 MRA-YOLOX. 计算机工程与应用, 60(16): 206–216.
- (Wang Z T, Zou Y B, Wu C L, et al. 2024. MRA-YOLOX for pest detection in farmland beyond single perception. Computer Engineering and Applications, 60(16): 206–216. [in Chinese])
- 谢婉滢,刘文萍,王 晗. 2024. 无人机松林图像早期松材线虫病害检测. 林业科学, 60(9): 124–133.
- (Xie W Y, Liu W P, Wang H. 2024. UAV images of pine forests for early detection of pine wood nematode infestation. Scientia Silvae Sinicae, 60(9): 124–133. [in Chinese])
- 杨红云,肖小梅,黄 琼,等. 2022. 基于卷积神经网络和迁移学习的水稻害虫识别. 激光与光电子学进展, 59(16): 333–340.
- (Yang H Y, Xiao X M, Huang Q, et al. 2022. Rice pest identification based on convolutional neural network and transfer learning. Progress in Laser and Optoelectronics, 59(16): 333–340. [in Chinese])
- 张长春,李大方,张军国. 2024. 基于 Wasserstein 距离和相关对齐迁移学

- 习的野生动物图像识别方法. 林业科学, 60(8): 25–32.
- (Zhang C C, Li D F, Zhang J G. 2024. Wildlife images recognition method based on Wasserstein distance and correlation alignment transfer learning. *Scientia Silvae Sinicae*, 60(8): 25–32. [in Chinese])
- 周志飞, 李 华, 冯毅雄, 等. 2024. 轻量化深度卷积神经网络设计研究进展. 计算机工程与应用, 60(22): 1–17.
- (Zhou Z F, Li H, Feng Y X, *et al.* 2024. Research progress on designing lightweight deep convolutional neural networks. *Computer Engineering and Applications*, 60(22): 1–17. [in Chinese])
- Chu J, Li Y, Feng H, *et al.* 2023. Research on multi-scale pest detection and identification method in granary based on improved YOLOv5. *Agriculture*, 13(2): 364.
- He K, Zhang X, Ren S, *et al.* 2016. Deep residual learning for image recognition. *IEEE Conference on Computer Vision and Pattern Recognition*, 770–778.
- Hou Q, Zhou D, Feng J. 2021. Coordinate attention for efficient mobile network design. *IEEE Conference on Computer Vision and Pattern Recognition*, 13708–13717.
- Simonyan K, Zisserman A. 2015. Very deep convolutional networks for large-scale image recognition. *International Conference on Learning Representations*, 1234–1256.
- Wang J, Li Y, Feng H, *et al.* 2020. Common pests image recognition based on deep convolutional neural network. *Computers and Electronics in Agriculture*, 179: 105834.
- Yulita I, Prabuwo A, Ardiansyah F, *et al.* 2024. Pest detection in agricultural farms using squeezeNet and multi-layer perceptron model. *International Journal of Advanced Computer Science and Applications*, 15(6): 802–808.
- Zhang Y, Ren W, Zhang Z, *et al.* 2022. Focal and efficient IOU loss for accurate bounding box regression. *IEEE Conference Computer Vision and Pattern Recognition*, 247–256.
- (责任编辑 王艳娜)