



计算机工程与应用  
Computer Engineering and Applications  
ISSN 1002-8331, CN 11-2127/TP

## 《计算机工程与应用》网络首发论文

题目: 轻量化 YOLO 动态多尺度注意力钢材缺陷检测  
作者: 张小龙, 贾渊, 黄杰  
网络首发日期: 2025-10-28  
引用格式: 张小龙, 贾渊, 黄杰. 轻量化 YOLO 动态多尺度注意力钢材缺陷检测[J/OL]. 计算机工程与应用. <https://link.cnki.net/urlid/11.2127.TP.20251027.1624.003>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

## 轻量化 YOLO 动态多尺度注意力钢材缺陷检测

张小龙, 贾渊, 黄杰

西南科技大学 计算机科学与技术学院, 四川 绵阳 621010

**摘要:** 目前传统轻量级钢材表面缺陷检测技术在精确率(P)和平均精度(mAP)上存在不足, 而大参数模型又无法满足企业实时检测需要。如何在轻量模型基础上实现精确率和平均精度有效提升成为钢材检测重难点。针对以上问题并基于 YOLOv11 改进设计出 MFC-YOLO 模型。通过对骨干网络中传统 Conv 进行改进设计出多分支池化重采样卷积(MPRConv)模块, 通过对传统卷积模式中引入多维度局部池化分支实现对局部区域显著缺陷特征和隐秘瑕疵以及局部背景信息的有效捕获; 设计改进高效多尺度注意力模块(S-EMA)取代骨干网中的 C2PSA 模块, 提升对多尺度缺陷特征的专注度; 通过对颈部下采样空间到深度的卷积 (SPDConv)实现对细粒度缺陷特征的保留; 设计高效特征权重聚合模块(EFWA)代替颈部特征拼接(Concat)操作, 通过可学习权重实现不同层级缺陷特征的有效融合, 减小了后续 C3k2 模块需要处理的通道数量; 提出 SMPD-IoU 边框损失函数替代原始边框损失, 引入中心距离和斜角差计算提升边界框回归精度。在公开钢材表面缺陷数据集 NEU-DET 上的实验结果表明, MFC-YOLO 算法在 mAP@50 上相比原始 YOLOv11 基准模型提升 5.5%达到 81.1%, 在精度上提升 4.7%。

**关键词:** 钢材缺陷检测; 多维特征融合; YOLOv11

文献标志码: A 中图分类号: TP391 doi: 10.3778/j.issn.1002-8331.2505-0052

### Lightweight YOLO with Dynamic Multi-Scale Attention for Steel Defect Detection

ZHANG Xiaolong, JIA Yuan, HUANG Jie

College of Computer Science and Technology, Southwest University of Science and Technology, Mianyang, Sichuan 621010, China

**Abstract:** Traditional lightweight steel surface defect detection techniques currently suffer from limitations in precision (P) and mean average precision (mAP), while large-parameter models fail to meet the real-time detection requirements of industrial applications. Achieving improvements in precision and mAP based on lightweight models remains a significant challenge in steel surface inspection. To address these issues, we propose the MFC-YOLO model, an enhanced version of YOLOv11. In this model, we introduce a novel Multi-modal Pooling Resampling Convolution (MPRConv) module to replace standard convolutions in the backbone. This module incorporates multi-dimensional local pooling branches to effectively capture prominent defect features, subtle flaws, and local background information. An improved Efficient Multi-scale Attention (S-EMA) module is designed to replace the C2PSA module in the backbone, thereby improving focus on multi-scale defect features. We further propose an Efficient Feature Weight Aggregation (EFWA) module to replace the Concat operation in the neck. By introducing learnable weights, EFWA enables effective fusion of features from different levels while reducing the number of channels required by subsequent C3k2

**基金项目:** 四川省自然科学基金(NO.2023NSFSC1417); 博士基金 (NO.22zx7174)。

**作者简介:** 张小龙(2000-), 男, 硕士研究生, CCF 学生会会员, 研究方向为计算机视觉, E-mail: zhangxl2129@163.com; 贾渊(1973-), 男, 博士, 教授, CCF 普通会员, 研究方向为计算机视觉、智能图像处理及应用; 黄杰(2001-), 男, 硕士研究生, CCF 学生会会员, 研究方向为缺陷检测。

modules. Additionally, a new bounding box loss function, SMPD-IoU, is proposed to replace the original Complete IoU that takes into account the distance between centers and the angle deviation, which incorporates center distance and aspect ratio deviation to improve bounding box regression accuracy. Experimental results on the public NEU-DET steel surface defect dataset demonstrate that MFC-YOLO achieved 5.5% improvement in mAP@50 over the original YOLOv11, reaching 81.1% and 4.7% improvement in Precision.

**Key words:** steel surface defect detection; multi-dimensional feature fusion; YOLOv11

钢材表面缺陷检测作为钢产品的生产质量保障, 钢材产业的特殊性要求钢材表面缺陷检测需具备实时性。然而, 钢材表面存在种类繁多、尺度不一、形态复杂且相互干扰的多类型缺陷, 如裂纹、麻点、氧化皮等, 这为自动化检测系统带来了极大的挑战<sup>[1]</sup>。如何提升轻量级模型在复杂钢材表面缺陷检测的精确率(P)和平均精度(mAP)成为学者们广泛研究的命题。

随着深度学习的快速发展, 单阶段目标检测算法因其结构简洁、推理速度快等优势, 在工业视觉领域获得广泛应用。王宁等在对单阶段目标检测算法的系统性综述中指出, YOLO 系列作为代表性架构, 凭借优异的检测速度与模型压缩能力, 已成为轻量化检测任务的重要技术路径, 尤其适合部署于工业实时检测场景<sup>[2]</sup>。杨思念等在 PCB 缺陷检测综述中也强调, 轻量化模型、多尺度特征提取和融合、注意力机制与边框回归策略, 是提升工业缺陷检测性能的关键方向之一<sup>[3]</sup>。

针对钢材表面缺陷的检测任务, 国内学者近年来也提出了多种改进方案。例如, 王韵琳等<sup>[4]</sup>针对小目标和多尺度缺陷检测难题, 在 YOLOX-s 算法中融合了坐标注意力和多尺度上下文敏感模块, 在不增加模型复杂度的前提下, 显著提升了多类型缺陷的检测效果; 张政超等<sup>[5]</sup>针对工业场景的资源限制, 在 YOLOv5 的基础上, 通过引入 ShuffleNetv2 和 CARAFE 等轻量化模块, 实现了模型的大幅压缩和检测速度的提升; 刘毅等<sup>[6]</sup>则着重于提高检测精度, 在 YOLOX 框架中融入改进的 SE 注意力机制和 ASFF 模块, 增强了模型的特征提取与融合能力; 杨本臣等<sup>[7]</sup>提出一种基于 YOLOv8n 的多尺度融合轻量化检测算法, 引入 RepHGnetv2 主干与 ADown 下采样, 并采用 SlideLoss 优化样本不平衡问题; 李宗祐等<sup>[8]</sup>在综述中总结了近年来金属材料表面缺陷检测的主流方法与趋势, 指出轻量化与多尺度响应是工业应用的核心需求。

在国际研究方面, Wu 等<sup>[9]</sup>通过多分支合并与轻量卷积设计轻量 YOLO 结构, 提升速度的同时降低精度对尺度差异的适应性; Ren 等<sup>[10]</sup>集成 ECA 注意力、

SimSPPF 模块与 SIoU 损失提升检测准确度, 但整体结构偏向微调, 缺乏结构重构创新; Mo<sup>[11]</sup>等人提出的 SGT-YOLO 模型, 通过引入 SE-ENv2 主干网络和 GC-Neck, 解决了 PCB 缺陷检测中模型复杂和小缺陷漏检的问题, 在实现轻量化的同时, 显著提升了检测精度, 但该模型移除了 P4 和 P5 检测头, 导致模型对大尺寸、特征明显的缺陷检测能力有所下降; Ma 等<sup>[12]</sup>设计 MPDIoU 综合多项回归误差计算, 优化定位精度, 但未结合语义特征表达整体提升检测性能; 章曙光等<sup>[13]</sup>改进 Tiny-YOLOv3, 引入 CBAM 注意力和锚框优化, 对小目标识别有效, 但浅层特征表达弱, 且多尺度融合设计较为简单。

综上, 尽管已有方法在不同层面有所突破, 但在“高精度+轻量化+多尺度响应”的统一优化方面仍存在显著空缺, 尤其在面对钢材表面多类缺陷与复杂背景干扰时。当下 YOLO 系列算法模型如 YOLOv6、v8、v10、v11<sup>[14-17]</sup>等展现了不同程度的钢材表面缺陷检测适配性, 其中 YOLOv11<sup>[18]</sup>在有效降低参数和计算量的前提下, 展现出明显强势的精确率(P)和平均精度(mAP)。因此基于 YOLOv11 进行模型改进具有一定优势。

与上述方法相比, 本文在保证轻量化的同时, 采用多分支特征池化与多路径注意力机制协同优化, 实现了更高的检测精度与更优的实时性平衡。MFC-YOLO 模型在多方面进行了针对性的结构创新 MFC-YOLO: 1) 在骨干网络中将传统卷积替换为多分支池化重采样卷积(MPRConv)模块, 通过增设多个局部池化分支, 不仅能够捕捉显著缺陷区域的特征, 还能兼顾隐蔽瑕疵与周围背景信息, 从而提升了对不同类型缺陷的响应能力; 2) 设计改进后的 S-EMA 模块取代原有的 C2PSA, 在对不同尺度缺陷特征进行聚焦时更为精准, 提升模型对多类钢材表面缺陷的识别效果; 3) 在颈部网络中引入 SPDConv 操作, 将下采样过程中的空间信息有效映射到深度通道, 最大限度地保留了细粒度缺陷特征, 避免了传统下采样带来的信息损失; 4) 设计了一个轻量级的特征权重聚合模块替代简

MPRConv 提供多视角特征, S-EMA 提取多尺度注意, EFWA 聚合多层语义, SMPD-IoU 融合多类型损失, 四者协同作用提升复杂背景下对不同缺陷的检测能力。MFC-YOLO 模型在实际钢材缺陷检测中

## 1 MFC-YOLO 整体实现

MFC-YOLO 网络模型结构如图 1 所示。改进部分通过红色虚线框进行标记。




图 1 MFC-YOLO 网络模型结构

Fig.1 MFC-YOLO network model structure

## 2 改进的 YOLOv11 网络结构

### 2.1 多分支池化重采样卷积 (MPRConv)

在钢材表面缺陷检测任务中,缺陷类型繁多,表现形式复杂,既包含如划痕、裂纹等具有明显边缘特征的显性缺陷,也包含如氧化、斑点、细微划伤等边界模糊、纹理变化微弱的隐性缺陷。同时,钢材表面具有较强的背景纹理干扰,如反光、高光等,这些因素导致传统卷积<sup>[19]</sup>操作在特征提取阶段容易陷入对显性特征的过拟合,而忽略对隐性特征与背景干扰之间差异性的辨别,影响模型对复杂缺陷的感知能力。

针对以上问题, 本文提出多分支池化重采样卷积 (MPRConv)。如图 2 所示。该模块采用多分支特征提

取策略,通过对相邻 4 个像素的最大池化(maxPool)、最小池化(minPool)与平均池化(avgPool) 分别提取显性结构边缘、隐性低对比特征与背景平均纹理响应,从而捕获钢材表面缺陷在强弱对比、局部变化与背景过渡层面的多重特性<sup>[20]</sup>。再与原始卷积得到的输出特征进行深度融合。

三种池化方式分别对应感知域中不同特征表达形式的响应上限、响应下限与响应平均值: 1) 最大池化增强高对比度区域响应, 适用于捕捉裂纹、划痕等突变性强的显性缺陷; 2) 最小池化在低响应区域保留细微纹理变化, 有助于建模轻微磨损、氧化痕迹等隐性缺陷; 3) 平均池化提供稳定的背景响应特性, 有助于模型从复杂背景中分离干扰信息。通过上述三类特征



的并行提取,MPRConv 在特征空间中形成了一种“对比增强+细节保持+背景平均”的多层次响应表征机制,为后续模块提供更具判别性的特征基础。

如图 2 所示:输入特征尺寸设为 $(C1, W, H)$ 分别表示输入特征矩阵的通道数、长和宽。局部显隐性特征和平均背景特征分别通过卷积核大小为  $2 \times 2$  步长为 2 的最大池化、最小池化和平均池化操作获得。将池化得到的 3 个尺寸为  $(C1, W/2, H/2)$  池化特征分量,输入特征经过卷积核大小为  $3 \times 3$  步长为 2 的 Conv2d 操作得到的尺寸为  $(C1, W/2, H/2)$  的混合输出特征,将 4 个特征分量进行通道方向拼接操作,再经过卷积核大小

为  $1 \times 1$  的卷积操作将通道数压缩为  $C2$ ,再经过归一化和 SiLU 函数激活操作得到尺寸为 $(C2, W/2, H/2)$ 的输出特征。

通过引入多分支局部池化操作,MPRConv 不仅提升了模型对显性结构的响应强度,还增强了对细粒度隐性缺陷与复杂背景之间边界模糊区域的识别能力,有效缓解了传统卷积在复杂纹理干扰场景下特征表达能力不足的问题。该模块作为本文提出网络的重要组成部分,为整体缺陷识别性能的提升提供了坚实的支撑。




图 2 MPRConv 结构图。

Fig.2 MPRConv structure diagram

## 2.2 改进高效多尺度注意力模块(S-EMA)

EMA 采用分组策略,并使用跨空间学习技术来捕获短期和长期依赖关系<sup>[21]</sup>。为提升模型对复杂钢材表面缺陷的感知与判别能力,本文在原始 EMA 模块基础上进行了结构性优化。该模块采用分组策略,并使用跨空间学习机制捕获局部与全局的多尺度依赖关系,通过多路径注意力融合策略实现了对不同类型缺陷的精准建模,同时控制计算复杂度和参数冗余。

如图 3 所示,改进后的高效多尺度注意力模块(S-EMA)首先将输入特征图沿通道维度划分为若干子组(本实验 group=4),每组特征尺寸为 $(C/4 \times W \times H)$ 。分组策略显著降低了注意力建模的计算复杂度,同时通过划分多尺度通道块增强了网络对不同尺寸和形态缺陷的响应能力。在每组内部,S-EMA 采用横向和纵向的自适应池化操作分别提取水平和垂直方向特征,随后进行特征拼接、 $1 \times 1$  卷积与特征再分离操作,融合双向结构信息,生成空间注意力映射。相比于仅关注空间注意力的 C2PSA 设计,该操作为网络提供了明确的方向性特征提取,有助于对裂纹和划痕等细长缺陷进行更精细的刻画。为了强化语义层级信息的建模,模块还引入通道注意机制:分别对各分组特征进行全

局最大池化和平均池化,输出两种信号经两次卷积核大小为  $1 \times 1$  卷积(用以压缩和恢复通道)+ReLU 和 Sigmoid 激活后生成通道注意向量,该向量与其互补向量  $1 - \text{channel\_attention}$  分别作为门控权重,作用于空间注意增强分支与残差分支,实现互补式通道重标定,这种互补门控设计不仅突出了高响应通道的重要性,还能够抑制背景噪声通道,使得空间注意图在复杂表面环境下保持稳定聚焦。通道注意力与空间注意特征融合得到经感知增强的特征表示。此机制在不丢失关键信息的前提下突出不同通道的重要性,避免对低对比度缺陷(如麻点、夹杂物等)信息的过度抑制,从而提升模型的召回率和类别区分度。同时,为了增强对边缘特征突出的缺陷(如压入氧化皮和斑点)的检测能力,S-EMA 采用固定大小为  $3 \times 3$  拉普拉斯核的 EdgeConv 结构,该操作无需额外训练的方式检测边缘梯度变化,与 Canny 等传统边缘检测不同,EdgeConv 作为轻量卷积模块可在端到端框架下与语义特征协同优化,保证边缘与区域注意力的一致性。提取出的边缘特征与空间注意特征拼接后经  $1 \times 1$  卷积融合,显著提高了缺陷轮廓对比度与定位精度。最终,S-EMA 融合了方向性特征、显性与隐性语义信息以及边缘响应

三条注意力路径,具备对钢材表面典型缺陷(整体与局部结构)的全面感知能力。这种多路径融合机理本质上通过空间方向、语义分组与边缘约束三个互补维度构建了跨尺度一致性:空间分组保证不同大小缺陷均被建模,语义引导提升低对比度缺陷的显著性,边缘约束强化了轮廓边界。相对于 YOLOv11 原骨干中的 C2PSA 模块, S-EMA 在结构上引入了多尺度分组和多通路注意力机制,在计算量基本不变的前提下显著提升了对多样化缺陷的检测表现,特别是在识别高纵横比裂纹和低对比度斑点等多尺度问题上更具优势。

S-EMA 通过多组通道分组、双向结构注意、语义引导及边缘引导多路径融合,在不同空间尺度与语义维度上形成互补,从而具备跨尺度特征对齐与增强能力。在不同缺陷尺寸与对比度条件下, S-EMA 可根据局部响应动态调整注意力聚焦区域,互补门控机制使得注意力能够在真实缺陷区域收敛并抑制复杂背景干扰。在可视化实验中, S-EMA 的注意力热力图较改进之前的 EMA 展现出更集中于缺陷区域的聚焦效果,进一步证明了其在复杂背景下的鲁棒性。进而实现复杂钢材缺陷的自适应检测。




图3 EMA 结构图。

Fig.3 EMA structure diagram

## 2.3 高效特征权重聚合模块(EFWA)

借鉴高效通道注意力(ECA)<sup>[22]</sup>机制的设计思路,设计出高效特征权重聚合模块(EFWA),如图4所示。对  $n$  个尺寸为  $(C, W, H)$  的输入特征设计可学习权重向量自适应优化各输入特征权重,再经归一化处理得到输入特征的权重构成,各输入特征经过加权和得到尺寸为  $(C, W, H)$  的输出特征。通过该方式实现对不同维度输入特征的高效融合。该方式相比 Concat 特征拼接方式只需要引入少量计算量的同时,大幅减少了输出特征的通道维度,减少后续的 C3k2 模块计算压力,相比传统的 Concat 拼接, EFWA 在减少冗余计算的同时保留关键语义特征,单张图像推理时间降低了 0.7 ms。钢材表面缺陷特征不同层级所专注缺陷类型不同,通过该方式融合不同层级的缺陷特征提升混合钢材表面缺陷的检测能力。

EFWA 模块在轻量结构下通过通道加权的方式聚

合来自不同尺度的语义信息,不同层级特征的权重由网络端到端学习获得,从而避免了固定融合策略对某类特征的过度依赖,提升对特征层间信息重要性的动态建模能力,实现多尺度特征融合自适应性。




图4 EFWA 结构图。

Fig.4 EFWA structure diagram

## 2.4 空间深度转换卷积 (SPDConv)

由于高效特征权重聚合模块(EFWA)的输入特征需本层输入特征以及低层特征输入,低层特征需要先进行下采样将特征尺寸压缩到高层尺寸,而传统的压缩方法会造成低分辨率和细小钢材表面缺陷丢失从而降低检测精度。为实现钢材缺陷特征的无损压缩同时提升处理速度,采用空间深度转换卷积 (SPDConv)

[23,24,25]代替传统步长卷积进行下采样。

如图5所示,该算法是将输入特征尺寸为 $(C1, H, W)$ 按照相邻4个空间像素进行位置分离重组,得到4个尺寸为 $(C1, H/2, W/2)$ 特征分量,再将4个特征分量进行通道方向上的堆叠处理后得到特征尺寸为




图5 SPDCConv. 结构图.

Fig.5 SPDCConv structure diagram

## 2.5 基于最小距离的新型边界框相似度比较度量(SMPD-IoU)

在目标检测任务中,边界框回归的精度直接影响缺陷定位的准确性。由于钢材缺陷在形态上常呈现出细长不规则(如裂纹、划痕)、边缘锯齿(如氧化皮)以及低对比模糊区域(如麻点、色斑)的复杂结构,传统IoU<sup>[27]</sup>及其变体(如GIoU、DIoU、CIoU)<sup>[28,29,30]</sup>难以全面刻画预测框与真实框之间的几何一致性特征,易在微小偏移情况下出现损失震荡或惩罚不足的问题。为此,本文提出最小点距离IoU(MPD-IoU),通过引入对角顶点距离偏差度量<sup>[31,32]</sup>,优化边界框回归过程,尤其适用于工业场景中的复杂缺陷检测。

钢材缺陷常呈现长条形、锯齿状边缘或低对比度模糊边界,传统IoU度量易因微小偏移导致损失值跳变,而CIoU的纵横比惩罚项对不规则形状敏感度不足。MPD-IoU通过最小化预测框与真实框对角线顶点距离差异,强制模型学习边界框的几何对齐特性,增强对缺陷形状的适应性。

然而,尽管MPD-IoU在解决“单向边界对齐”问题方面具有优势,但在以下两个方面仍存在显著不足:  
(1)缺乏对目标中心位置偏移的直接约束,对非对角方向的整体偏移不敏感,容易造成边界框整体位置偏

( $4C1, H/4, W/4$ )特征向量,再经过 $1 \times 1$ 卷积核压缩通道尺寸为 $C2$ ,最后再进行归一化处理和SiLU<sup>[26]</sup>激活操作得到尺寸为 $(C2, H/4, W/4)$ 的输出特征。该模式与多分支池化重采样卷积(MPRConv)的处理流程相似,但4个特征分量的获取却存在本质上的不同。

离但仍获得较高的相似度评估;(2)未考虑缺陷主方向上的角度一致性,无法有效区分形态方向不匹配的候选框,尤其在钢材缺陷方向分布稳定(如裂纹、压痕)的情况下限制其判别能力。

本文在原始MPD-IoU度量基础上,提出增强型最小点距离IoU(SMPD-IoU),通过联合考虑对角线顶点偏差、中心点距离和对角偏差三重几何对齐因素,强化对缺陷实际形态的建模能力,提升边界框回归的鲁棒性与对细粒度位移的敏感性。




图6 MPD-IoU 结构图.

Fig.6 MPD-IoU structure diagram

如图6所示:设预测框 $B_p = (x_1^p, y_1^p, x_2^p, y_2^p)$ 和真



实框 $B_g = (x_1^g, y_1^g, x_2^g, y_2^g)$ 传统 IoU 的计算公式如下, 边框损失为预测框和真实框交集的面积比上两者并集的面积。

$$IoU = \frac{|B_p \cap B_g|}{|B_p \cup B_g|} \quad (1)$$

为衡量预测框与真实框左上角和右下角在对角线方向上的对齐程度。设计计算对角线顶点距离偏差项。计算如下:

$$\begin{aligned} d_1 &= \left( (x_1^p - x_1^g) - (y_1^p - y_1^g) \right)^2 \\ d_2 &= \left( (x_2^p - x_2^g) - (y_2^p - y_2^g) \right)^2 \end{aligned} \quad (2)$$

归一化惩罚项计算过程如下。通过 $d_1, d_2$ 约束对角线顶点对齐, 提升对长条形缺陷(如裂纹)的定位精度。其中 $c_w, c_h$ 为最小包围框的宽高, 用于消除尺度敏感性。归一化项 $c_w^2 + c_h^2$ 减少尺度变化对损失值的影响, 适应多尺度缺陷。

$$\mathcal{L}_{MPD} = \frac{d_1 + d_2}{c_w^2 + c_h^2 + \epsilon} \quad (3)$$

中心点距离项的计算首先需要定义预测框与真实框中心点坐标为

$$\begin{aligned} C_1 &= \left( \frac{x_1^p + x_2^p}{2}, \frac{y_1^p + y_2^p}{2} \right) = (x_c^p, y_c^p) \\ C_2 &= \left( \frac{x_1^g + x_2^g}{2}, \frac{y_1^g + y_2^g}{2} \right) = (x_c^g, y_c^g) \end{aligned} \quad (4)$$

则归一化中心点距离损失为:

$$\mathcal{L}_{center} = \frac{(x_c^p - x_c^g)^2 + (y_c^p - y_c^g)^2}{c_w^2 + c_h^2 + \epsilon} \quad (5)$$

该项能够精确惩罚边界框在二维平面上的偏移行为, 增强模型对中小缺陷(如麻点、压痕)在中心偏移下的鲁棒性。

方向角偏差项为预测框对角线与真实框对角线夹角偏差, 预测框和真实框对角向量可以表示如下:

$$\begin{aligned} \vec{v}_p &= (x_2^p - x_1^p, y_2^p - y_1^p) \\ \vec{v}_g &= (x_2^g - x_1^g, y_2^g - y_1^g) \end{aligned} \quad (6)$$

方向角偏差项用以保证划痕类长条类缺陷方向一

致性, 可以表示为如下:

$$\mathcal{L}_{angle} = 1 - \cos(\theta) = 1 - \frac{\vec{v}_p \cdot \vec{v}_g}{|\vec{v}_p| \cdot |\vec{v}_g| + \epsilon} \quad (7)$$

最终得到 SMPD-IoU 损失函数:

$$\mathcal{L}_{SMPD-IoU} = 1 - IoU + \mathcal{L}_{MPD} + \mathcal{L}_{center} + \mathcal{L}_{angle} \quad (8)$$

该度量方式全面融合了边界对齐、中心一致与方

向趋势等几何属性, 能够更好地适应钢材缺陷在实际检测中表现出的位置敏感、形状细长、方向倾斜及模糊扩散等多维特性, 显著提升模型在裂纹、划痕、氧化皮、压入类等典型缺陷上的定位精度与鲁棒性。

## 3 实验与分析

### 3.1 实验环境

实验环境涉及软件环境、硬件环境以及实验参数。

硬件方面采用 GPU(NVIDIA GeForce RTX 4070), CPU(Intel(R)Core(TM)I5-13600KF), RAM(32G); 软件方面采用操作系统(Windows 11 专业版), Python(3.8.20), Pytorch(2.4.1), CUDA(12.7.33); 训练参数方面采取 batch(32), worker(32), SGD 优化器, 初始学习率 0.01, 最终学习率 0.2, 动量 0.937, 权重衰减  $5e-4$ 。评价指标包括 Precision、Recall、mAP@50、mAP@50-90、Params/M、GFLOPs、F1、Speed (per img /ms)。

### 3.2 可视化实验结果分析

基于 NEU-DET 公共数据集进行分析检测实验, 从检测结果和热力图两方面进行可视化分析。检测结果如图 7 所示: 通过检测框对比可以发现, MFC-YOLO 模型能够检测出更多缺陷, 相比 YOLOv11 以及 YOLOv8 模型具有更好的检测效果, 检测框置信度更高。






图7 钢材缺陷检测效果对比图

Fig.7 Comparison of steel defect detection results

为验证模型对图像不同区域的专注度,通过梯度加权类激活映射(Grad-CAM)<sup>[33]</sup>方法和 NEU-DET 数据集进行热力图分析。如图 8 所示:自上到下分别表示 6 种不同的缺陷类型 Rolled-in Scale、Pitted Surface、Patches、Scratches、Inclusion、Crazing,其中 ours(S-EMA + SMPD-IoU)表示在 MPRConv、SPDConv、EFWA 模块的基础上还增加了 S-EMA 和 SMPD-IoU 的算法模型检测效果。改进后的 ours(S-EMA + SMPD-

IoU)相比改进前的 ours(EMA + MPD-IoU)算法模型,模型更专注于目标缺陷区域且有效减少了对背景区域和图像边缘区域的专注。其中, Rolled-in Scale 和 Crazing 这类对比度较低且边界模糊的缺陷,在 S-EMA + SMPD-IoU 模型下热力图聚焦明显更集中于缺陷主体,而 EMA + MPD-IoU 往往仍存在一定的背景误激活。相比基准模型 YOLOv11, MFC-YOLO 在钢材表面缺陷上取得更为显著的专注效果。




图8 模型热力图对比

Fig.8 Model heat map comparison

### 3.3 对比实验

对比评估 MFC-YOLO 模型和主流 YOLO 模型在 NEU-DET<sup>[34]</sup>公共数据集上的检测表现,该数据集包含了六种常见钢材表面缺陷:Cracking (Cr)、Inclusion (In)、Patches (Pa)、Pitted Surface (Ps)、Rolled-in Scale (RS)、Scratches (Sc)。

各模型整体检测性能表现如表 1 所示:模型在保存增加少量参数量和计算量前提下, Precision 和 mAP@50 上相比其它主流 YOLO 模型取得明显优势,相比基准模型 YOLOv11-n 在精确率(P)上提升 4.7%达到 77.5%, mAP@50 提升 5.5%达到 81.1%。对比参数量和计算量超过 MFC-YOLO 三倍的 YOLOv11-s 模型,在 Precision 和 mAP@50 上也取得明显优势。



表 1 对比实验结果表

| Table 1 Comparative experimental results |              |              |              |              |             |            |
|------------------------------------------|--------------|--------------|--------------|--------------|-------------|------------|
| 模型                                       | Precision    | Recall       | mAP@50       | mAP@50-90    | Parms/M     | GFLOPs     |
| Faster R-CNN                             | 0.623        | 0.707        | 0.769        | 0.435        | 43.72       | 81.7       |
| SSD                                      | 0.669        | 0.658        | 0.749        | 0.417        | 9.63        | 53.7       |
| YOLOX                                    | 0.716        | 0.680        | 0.748        | 0.422        | 8.50        | 24.5       |
| YOLOv6-n                                 | 0.779        | 0.678        | 0.774        | 0.449        | 4.16        | 11.5       |
| YOLOv6-s                                 | 0.758        | 0.721        | 0.780        | 0.452        | 15.98       | 42.8       |
| YOLOv8-n                                 | 0.679        | 0.729        | 0.762        | 0.454        | 2.69        | 6.8        |
| YOLOv8-s                                 | <b>0.800</b> | 0.649        | 0.781        | 0.458        | 9.83        | 23.4       |
| YOLOv10-n                                | 0.701        | 0.665        | 0.726        | 0.419        | 3.79        | 14.2       |
| YOLOv10-s                                | 0.710        | 0.718        | 0.746        | 0.439        | 8.04        | 24.5       |
| YOLOv11-n                                | 0.728        | 0.706        | 0.756        | 0.453        | <b>2.58</b> | <b>6.3</b> |
| YOLOv11-s                                | 0.749        | 0.725        | 0.771        | 0.462        | 9.41        | 21.3       |
| Ours                                     | 0.775        | <b>0.747</b> | <b>0.811</b> | <b>0.494</b> | 3.16        | 7.0        |

NEU-DET 数据集中钢材表面缺陷类型复杂多样, 分析模型在各类缺陷类型平均准确率(mAP@50), 进一步研究模型对 MFC-YOLO 模型对特定缺陷类型的提升。分析结果如表 2 所示: 对比模型各缺陷类型

AP@50 可以发现, MFC-YOLO 模型对于夹杂物(In)、麻面(Ps)和轧入氧化皮(Rs)取得最佳检测表现。整体 mAP@50 达到最优。

表 2 各类缺陷检测效果图

| Table 2 Renderings of various defect detections |       |              |              |              |              |              |              |
|-------------------------------------------------|-------|--------------|--------------|--------------|--------------|--------------|--------------|
| 模型                                              | Cr    | In           | Pa           | Ps           | Rs           | Sc           | mAP@50       |
|                                                 | AP@50 | AP@50        | AP@50        | AP@50        | AP@50        | AP@50        |              |
| Faster R-CNN                                    | 0.529 | 0.761        | 0.898        | 0.797        | 0.700        | 0.931        | 0.769        |
| SSD                                             | 0.549 | 0.776        | <b>0.909</b> | 0.863        | 0.663        | 0.737        | 0.749        |
| YOLOX                                           | 0.451 | 0.783        | 0.893        | 0.766        | 0.654        | <b>0.942</b> | 0.748        |
| YOLOv6-n                                        | 0.488 | 0.822        | 0.869        | 0.903        | 0.729        | 0.834        | 0.774        |
| YOLOv6-s                                        | 0.518 | 0.855        | 0.898        | 0.856        | 0.665        | 0.888        | 0.780        |
| YOLOv8-n                                        | 0.446 | 0.862        | 0.899        | 0.862        | 0.626        | 0.875        | 0.762        |
| YOLOv8-s                                        | 0.475 | 0.886        | 0.900        | 0.879        | 0.685        | 0.860        | 0.781        |
| YOLOv10-n                                       | 0.461 | 0.813        | 0.871        | 0.772        | 0.619        | 0.822        | 0.726        |
| YOLOv10-s                                       | 0.476 | 0.816        | 0.876        | 0.829        | 0.647        | 0.829        | 0.746        |
| YOLOv11-n                                       | 0.455 | 0.841        | 0.904        | 0.825        | 0.619        | 0.889        | 0.756        |
| YOLOv11-s                                       | 0.445 | 0.888        | 0.915        | 0.845        | 0.650        | 0.885        | 0.771        |
| ours                                            | 0.513 | <b>0.889</b> | 0.899        | <b>0.929</b> | <b>0.743</b> | 0.891        | <b>0.811</b> |

### 3.4 消融实验

为观察 MFC-YOLO 模型各项改进对模型整体性能的影响, 采用 NEU-DET 数据集进行消融实验设计。通过该实验对比多分支池化重采样卷积(MPRConv)、改进高效多尺度注意力模块(S-EMA)、高效特征权重聚合模块(EFWA)、空间深度转换卷积(SPDCConv)、改进基于最小点距离的新型边界框相似度比较度量(SMPD-IoU)五处改进对模型产生的影响。

表 3 所示为 MFC-YOLO 中五处改进点的消融实验, 通过逐项改进并观察对比实验结果, 分析实验结果可以发现: 实验 1-3 作为 MRPCConv 的子实验, 通过逐步加入最小、平均、最大池化进行实验, 实验结果表明, 逐步加入的池化分支对 mAP50 和 F1 有一定提升, 且模型参数量和速度几乎不受影响; 实验 4 在网络颈部采取 SPDCConv 代替传统下采样操作后, 平

均精度 mAP@50 提升 1.9%且消耗参数量更少。这是由于 SPDCConv 在不破坏原有特征信息的前提下实现特征尺寸由空间到通道维度上的转移导致; 实验 5 引入 EFWA 替换输出头部的通道拼接操作, 该操作在不增加计算量的情况下, 相比实验 4 原本的 Concat 通道拼接操作在 Precision 提升 3.9%, 在单张图像处理时间减少 0.7ms, 借助于输出通道数得到有效压缩, 减少后续 C3k2 计算量, 进而有效提升处理速度; 实验 6 将改进的 S-EMA 代替原网络主干头部 C2PSA 注意力模块, 相比实验 5 采取的 C2PSA 模块在 Precision、mAP@50-90 分别显著提升 4.6%、5.1%, 该模型实现全局和局部缺陷的双重专注同时针对不同缺陷类型强化各类型缺陷注意力, 模型准确率和平均精度得到进一步提升, 虽然 S-EMA 模块在结构上更复杂, 但带

来的精度提升在工业应用中可显著减少误检与漏检，整体收益远大于 1.4 ms 的推理延迟；在最终实验中，SMPD-IoU 综合了中心点、边角及角度差信息，使回

归过程更符合缺陷边界的真实几何形态，从而提升了定位精度。相比于原本的 C-IoU 在单张图片处理时间上减少了 0.8,模型速度进一步提升。

表 3 消融实验配置统计表

| Table 3 |          | Ablation experiment configuration statistics table |          |         |      |       |          |
|---------|----------|----------------------------------------------------|----------|---------|------|-------|----------|
| 实验编号    | MPRConv  |                                                    |          | SPDConv | EFWA | S-EMA | SMPD-IoU |
|         | Min Pool | Mean Pool                                          | Max Pool |         |      |       |          |
| 实验 1    | ✓        |                                                    |          |         |      |       |          |
| 实验 2    | ✓        | ✓                                                  |          |         |      |       |          |
| 实验 3    | ✓        | ✓                                                  | ✓        |         |      |       |          |
| 实验 4    | ✓        | ✓                                                  | ✓        | ✓       |      |       |          |
| 实验 5    | ✓        | ✓                                                  | ✓        | ✓       | ✓    |       |          |
| 实验 6    | ✓        | ✓                                                  | ✓        | ✓       | ✓    | ✓     |          |
| Ours    | ✓        | ✓                                                  | ✓        | ✓       | ✓    | ✓     | ✓        |

表 4 消融实验对比结果

| Table 4 Comparison of results of ablation experiments |              |              |              |              |             |            |              |            |
|-------------------------------------------------------|--------------|--------------|--------------|--------------|-------------|------------|--------------|------------|
| 编号                                                    | Precision    | Recall       | mAP@50       | mAP@50-90    | Parms/M     | GFLOPs     | F1           | Speed (ms) |
| 实验 1                                                  | 0.688        | 0.752        | 0.754        | 0.435        | <b>2.54</b> | <b>6.4</b> | 0.719        | 2.4        |
| 实验 2                                                  | 0.705        | 0.741        | 0.761        | 0.441        | 2.60        | 6.6        | 0.723        | 2.5        |
| 实验 3                                                  | 0.703        | <b>0.753</b> | 0.772        | 0.446        | 2.65        | 6.7        | 0.727        | 2.6        |
| 实验 4                                                  | 0.707        | 0.738        | 0.791        | 0.451        | 2.55        | 6.6        | 0.722        | 2.5        |
| 实验 5                                                  | 0.746        | 0.703        | 0.777        | 0.443        | 2.59        | 6.6        | 0.724        | 1.8        |
| 实验 6                                                  | <b>0.792</b> | 0.728        | 0.800        | 0.494        | 3.16        | 7.0        | 0.759        | 3.2        |
| Ours                                                  | 0.775        | 0.747        | <b>0.811</b> | <b>0.494</b> | 3.16        | 7.0        | <b>0.761</b> | 2.4        |

3.5 泛化实验

为进一步验证 MFC-YOLO 模型算法对不同数据集的泛化能力，采用第六届全球校园人工智能大赛钢材赛道国赛的钢材缺陷数据集进行泛化能力验证，该数据集中存在大量夹杂物、补丁和划痕混合缺陷以及

复杂缺陷背景环境( 光线过明、光线过暗、椒盐噪点 )。对比 MFC-YOLO 与 YOLOv5 到 YOLOv11 模型在该数据集下的表现，观察可以发现，本模型在精确率和平均精度上依然存在明显优势，且参数和计算量符合钢材缺陷检测的工业轻量化要求。

表 5 泛化实验对比

| Table 5 Comparison of generalization experiments |              |              |              |              |             |            |
|--------------------------------------------------|--------------|--------------|--------------|--------------|-------------|------------|
| 模型                                               | Precision    | Recall       | mAP@50       | mAP@50-90    | Parms/M     | GFLOPs     |
| YOLOv5                                           | 0.798        | 0.816        | 0.837        | 0.539        | <b>2.18</b> | <b>5.8</b> |
| YOLOv6                                           | 0.774        | 0.790        | 0.794        | 0.504        | 4.16        | 11.5       |
| YOLOv8-n                                         | 0.801        | 0.832        | 0.845        | 0.545        | 2.69        | 6.8        |
| YOLOv10-n                                        | 0.746        | 0.794        | 0.812        | 0.487        | 3.79        | 14.2       |
| YOLOv11-n                                        | 0.840        | 0.809        | 0.841        | 0.536        | 2.58        | 6.3        |
| ours                                             | <b>0.871</b> | <b>0.825</b> | <b>0.860</b> | <b>0.578</b> | 3.16        | 7.0        |

4 结束语

针对轻量级钢材表面缺陷检测模型在精度与实时性上的矛盾问题，本文提出 MFC-YOLO 模型，通过多维特征融合与模块优化实现检测性能突破。基于 YOLOv11 架构，设计了包含多分支池化重采样卷积(MPRConv)、改进高效多尺度注意力(S-EMA)、空间到深度下采样(SPDConv)、特征权重聚合(EFWA)以及改

进边界框损失(SMPD-IoU)的协同优化策略。实验表明，该方法在 NEU-DET 数据集上 mAP@50 达到 81.1%，相比基准模型提升 5.5%，精确率提升 4.7%，且未显著增加计算复杂度。改进后的模型有效平衡了复杂背景下的多尺度缺陷特征捕获能力与细粒度特征保留需求，验证了多维度特征交互机制在工业表面缺陷检测中的有效性。未来研究将聚焦于动态自适应特征融合机制



的设计,并探索跨模态数据增强策略以进一步提升模型泛化能力。本工作为轻量化工业视觉检测系统提供了新的技术路径。

## 参考文献:

- [1] 李原, 李燕君, 刘进超, 范衡, 王庆林. 基于改进 Res-UNet 网络的钢铁表面缺陷图像分割研究[J]. 电子与信息学报, 2022, 44(5): 1513–1520. DOI: 10.11999/JEIT211350.  
LI Yuan, LI Yanjun, LIU Jinchao, FAN Zhun, WANG Qinglin. Research on segmentation of steel surface defect images based on improved Res-UNet network[J]. Journal of Electronics & Information Technology, 2022, 44(5): 1513–1520. DOI:10.11999/JEIT211350.
- [2] 王宁, 智敏. 深度学习下的单阶段通用目标检测算法研究综述[J]. 计算机科学与探索, 2025, 19(5): 1115–1140. DOI:10.3778/j.issn.1673-9418.2411032.  
WANG N, ZHI M. Review of one-stage universal object detection algorithms in deep learning[J]. Journal of Frontiers of Computer Science and Technology, 2025, 19 (5): 1115–1140. DOI: 10.3778/j.issn.1673-9418.2411032.
- [3] 杨思念, 曹立佳, 杨洋, 郭川东. 基于机器视觉的 PCB 缺陷检测算法研究综述[J]. 计算机科学与探索, 2025, 19(4): 901–915.  
YANG S N, CAO L J, YANG Y, GUO C D. Review of PCB defect detection algorithms based on machine vision[J]. Journal of Frontiers of Computer Science and Technology, 2025, 19(4): 901–915.
- [4] 王韵琳, 冯天波, 孙宁, 等. 融合注意力与多尺度特征的电力绝缘子缺陷检测方法[J]. 高电压技术, 2024, 50(5): 1933–1942.  
WANG Y L, FENG T B, SUN N, et al. Defect detection method of power insulator based on attention and multi-scale features fusion[J]. High Voltage Engineering, 2024, 50(5): 1933–1942.
- [5] 张政超. 改进 YOLOv5 的轻量级带钢表面缺陷检测[J]. 计算机系统应用, 2023, 32(6): 278–285.  
ZHANG Z C. Lightweight strip steel surface defect detection based on improved YOLOv5[J]. Computer Systems & Applications, 2023, 32(6): 278–285.
- [6] 刘毅, 蒋三新. 基于改进 YOLOX 的钢材表面缺陷检测研究[J]. 现代电子技术, 2024, 47(9): 131–138.  
LIU Y, JIANG S X. Steel surface defect detection based on improved YOLOX[J]. Modern Electronics Technique, 2024, 47(9): 131–138.
- [7] 杨本臣, 李世熙, 金海波, 等. 多尺度融合的轻量级钢材表面缺陷检测[J]. 计算机系统应用, 2024, 33(11): 58–67. DOI:10.15888/j.cnki.csa.009678.  
YANG Benchen, LI Shixi, JIN Haibo, et al. Lightweight steel surface defect detection with multiscale fusion[J]. Computer Systems & Applications, 2024, 33(11): 58–67. DOI:10.15888/j.cnki.csa.009678.
- [8] 李宗祐, 高春艳, 吕晓玲, 张明路. 基于深度学习的金属材料表面缺陷检测综述[J]. 制造技术与机床, 2023(6): 61–67. DOI: 10.19287/j.mtmt.1005-2402.2023.06.011.
- [9] LI Z Y, GAO C Y, LÜ X L, ZHANG M L. A review of surface defect detection for metal materials based on deep learning[J]. Manufacturing Technology & Machine Tool, 2023(6): 61–67. DOI: 10.19287/j.mtmt.1005-2402.2023.06.011.
- [9] WU Z, ZHANG Y, WANG X, et al. Algorithm for detecting surface defects in wind turbines based on a lightweight YOLO model[J]. Scientific Reports, 2024, 14(1): 24558.
- [10] REN F, FEI J, LI H, et al. Steel surface defect detection using improved deep learning algorithm: ECA-SimSPPF-SIoU-Yolov5[J]. IEEE Access, 2024.
- [11] Mo C, Hu Z, Wang J, et al. SGT-YOLO: A Lightweight Method for PCB Defect Detection[J]. IEEE Transactions on Instrumentation and Measurement, 2025.
- [12] MA S, XU Y. Mpdious: a loss for efficient and accurate bounding box regression[J]. arXiv preprint arXiv:2307.07662, 2023.
- [13] 章曙光, 刘洋, 张文韬, 等. 改进 Tiny-YOLOv3 的工业钢材瑕疵检测算法[J]. 机械设计与制造, 2024(5): 97–101.  
ZHANG S G, LIU Y, ZHANG W T, et al. Improved Tiny-YOLOv3 defect detection algorithm for industrial steel[J]. Machinery Design & Manufacture, 2024(5): 97–101.
- [14] TERYEN J, Córdova-Esparza D M, Romero-González J A. A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS[J]. Machine Learning and Knowledge Extraction, 2023, 5(4): 1680–1716.
- [15] HE Y, SONG K, MENG Q, et al. An end-to-end steel surface defect detection approach via fusing multiple hierarchical features[J]. IEEE Transactions on Instrumentation and Measurement, 2019, 69(4): 1493–1504.
- [16] HUSSAIN M. YOLO-v1 to YOLO-v8, the rise of YOLO and its complementary nature toward digital manufacturing and industrial defect detection[J]. Machines, 2023, 11(7): 677.
- [17] GE Z, LIU S, WANG F, et al. YOLOX: Exceeding YOLO series in 2021[J]. arXiv preprint arXiv:2107.08430, 2021.
- [18] KANG S, HU Z, LIU L, et al. Object Detection YOLO Algorithms and Their Industrial Applications: Overview and Comparative Analysis[J]. Electronics, 2025, 14(6): 1104.
- [19] FINDER S E, AMOYAL R, TREISTER E, et al. Wavelet convolutions for large receptive fields[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 363–380.
- [20] CHUDANOV V V, AKSENOVA A E, PERVICHKO V A, et al. Current status and validation of conv2d and 3d code[C]//Proceedings of the Workshop on In-Vessel Core Debris Retention and Coolability. NEA-CSNI-R--1998-18, 1999: 215–226.
- [21] Xia K, Lv Z, Zhou C, Gu G, Zhao Z, Liu K, Li Z. Mixed receptive fields augmented YOLO with multi-path spatial pyramid pooling for steel surface defect detection[J]. Sensors, 2023, 23(11): 5114. <https://doi.org/10.3390/s23115114>.
- [22] Li L, Zhang R, Xie T, He Y, Zhou H, Zhang Y. Experimental design of steel surface defect detection based on MSFE-YOLO—An improved YOLOv5 algorithm with multi-scale feature extraction[J]. Electronics, 2024, 13(18): 3783. <https://doi.org/10.3390/electronics13183783>

- [23] BAO J, YUAN X, WU Q, et al. CCA-YOLO: Channel and Coordinate Aware-based YOLO for Photovoltaic Cell Defect Detection in Electroluminescence Images[J]. IEEE Transactions on Instrumentation and Measurement, 2025.
- [24] WAN W, WANG L, WANG B, et al. Space to depth convolution bundled with coordinate attention for detecting surface defects[J]. Signal, Image and Video Processing, 2024, 18(5): 4861–4874.
- [25] GUO R, JI P, ZHANG Y, et al. Steel surface defect detection based on improved GCHS-YOLO algorithm[J]. IEEE Access, 2024.
- [26] ZHONG R, PENG E, LI Z, et al. SPD-YOLOv8: A small-size object detection model of UAV imagery in complex scene[J]. The Journal of Supercomputing, 2024, 80(12): 17021–17041.
- [27] PENG H, YU S. A systematic IOU-related method: Beyond simplified regression for better localization[J]. IEEE Transactions on Image Processing, 2021, 30: 5032–5044.
- [28] LIU X, HU J, WANG H, et al. Gaussian-IoU loss: Better learning for bounding box regression on PCB component detection[J]. Expert Systems with Applications, 2022, 190: 116178.
- [29] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2020, 34(07): 12993–13000.
- [30] GAO J, CHEN Y, WEI Y, et al. Detection of specific building in remote sensing images using a novel YOLO-S-CIOU model. Case: Gas station identification[J]. Sensors, 2021, 21(4): 1375.
- [31] WANG Y, YAN S, ABDULLAHI H S, et al. Multiclass small target detection algorithm for surface defects of chemicals special steel[J]. Frontiers in Physics, 2024, 12: 1451165.
- [32] Xiong C, Zayed T, Jiang X, Alfalah G, Abelkader E M. A novel model for instance segmentation and quantification of bridge surface cracks—The YOLOv8-AFPN-MPD-IoU[J]. Sensors, 2024, 24(13): 4288. <https://doi.org/10.3390/s24134288>
- [33] YU T, LUO X, LI Q, et al. CRGF-YOLO: an optimized multi-scale feature fusion model based on YOLOv5 for detection of steel surface defects[J]. International Journal of Computational Intelligence Systems, 2024, 17(1): 154.
- [34] ZHAO C, SHU X, YAN X, et al. RDD-YOLO: A modified YOLO for detection of steel surface defects[J]. Measurement, 2023, 214: 112776.